

中国研究生创新实践系列大赛
中国光谷·“华为杯”第十九届中国研究生
数学建模竞赛

学 校

复旦大学

参赛队号

22102460007

队员姓名

1.

王樵之

2.

王晨

3.

桑博涵

中国研究生创新实践系列大赛
中国光谷·“华为杯”第十九届中国研究生
数学建模竞赛

题 目 **多维变分贝叶斯低复杂度超分辨率线谱估计**

摘 要：

随着社会经济的加速发展，高精度移动定位的需求越来越多。现有的雷达基线算法往往使用简单的 FFT 与 MUSIC 方法。受限于分辨率无法满足日益增长的定位需求。

本文使用**多维变分贝叶斯线谱估计** (Multidimensional Variational Line Spectra Estimation, MDValse) [1] 方法，对雷达中频接收信号进行处理，实现了低复杂度超分辨率的多物体定位。并结合**贝叶斯信息准则**，**最近邻数据关联算法**，**拓展卡尔曼滤波**与 **MUSIC+fmincon 优化**结构噪声估计方法，分别解决了模型阶数估计，数据关联，路径优化与鲁棒估计问题。此外我们还对算法的性能下界**克拉美罗界**，理论与数值最优性进行了分析。

问题一，我们通过雷达信号在频域与空域的阵列响应特性，构建了**二维线谱估计模型**定位物体。将整个估计问题分为模型阶数选择，二维频率估计与复增益估计。并计算了雷达分辨率与问题的克拉美罗下界。通过**贝叶斯信息准则**实现了模型阶数的选择。对四种最先进的算法（**多维变分贝叶斯线谱估计**，**二维牛顿下界正交匹配跟踪** [2]，**二维原子范数** [3]，**超快速线谱估计** [4]）选型分析，最终选择**多维变分贝叶斯线谱估计 MDValse** 作为低复杂度超分辨率线谱估计方法。问题一定位到两个物体目标，如图4.5所示，极坐标分别为 **(7.0049,0.0070)** 与 **(7.0049,-0.0024)**（横坐标为距离，纵坐标为角度）。

问题二，考虑高斯白噪声观测模型，由于 MDValse 可以自动估计噪声方差，仍选用 MDValse 作为定位方法。问题二定位到两个物体目标，如图4.11所示，极坐标分别为 **(8.2058,0.0115)** 与 **(8.2058,-0.0099)**。高斯噪声方差估计为 2.12。

问题三，在 MDValse 定位基础上使用最近邻数据关联与拓展卡尔曼滤波实现实时低复杂度（表4.3）计算运动轨迹。如图4.28，问题三有两个物体在极坐标图上的匀速直线运动轨迹，物体一从 **(6.0043,0.01507)** 运动到 **(6.4889,0.26596)**，轨迹函数为 $\theta_1 = 0.484r_1 - 2.757$ 。物体二从 **(6.0042,-0.01616)** 运动到 **(5.5195,-0.26585)**，轨迹函数为 $\theta_2 = 0.515r_2 - 3.108$ 。

问题四，考虑天线阵列结构误差，构建**结构误差观测模型**，并通过 **MUSIC+fmincon 优化算法**实现天线阵列的自校正。使用校正后的观测数据进行鲁棒估计。问题四定位到两个物体目标，如图4.31所示，极坐标分别为 **(6.00424,-0.00527)** 与 **(6.10429,0.00528)**。

关键字： 超分辨率定位 二维线谱估计 变分贝叶斯 天线阵列自校正

目录

1	问题重述	4
1.1	引言	4
1.2	问题的提出	4
2	模型的假设	6
3	符号说明	6
4	模型的建立	7
4.1	问题一分析与求解	7
4.1.1	二维线谱估计定位模型与算法分析	7
4.1.2	估计精度限制分析	10
4.1.3	基线方法：FFT 类方法，二维加窗 FFT	14
4.1.4	基线方法：JADE 问题	14
4.1.5	超分辨率算法选型分析	15
4.1.6	模型阶数选择：信息准则（AIC，GIC，BIC）	16
4.1.7	网格 CS 方法：牛顿梯度下降正交匹配跟踪 2D-NOMP	17
4.1.8	无网格 CS 方法：快速二维原子范数 2D-MANM	20
4.1.9	问题一定位结果	23
4.2	问题二分析与求解	25
4.2.1	贝叶斯方法：多维变分贝叶斯线谱估计 MDVLSE	25
4.2.2	贝叶斯方法：超快速线谱估计的多维拓展	27
4.2.3	问题二定位结果	28
4.3	问题三分析与求解	30
4.3.1	数据关联算法	30
4.3.2	后端优化方法	31
4.3.3	问题三定位结果	32
4.4	问题四分析与求解	35
4.4.1	带有阵列结构误差的鲁棒估计问题与算法	35
4.4.2	问题四定位结果	37
4.5	低复杂度高精度线谱估计算法选择：多维变分贝叶斯线谱估计 MDVASE 优越性分析	39

参考文献	39
附录 A 算法核心函数与程序运行说明	43
1.1 程序运行说明	43
A.2 MDVALUE 核心函数	43
A.3 MDVALUE+EKF 多目标算法代码	50
A.4 MUSIC+fmincon 优化算法代码	54

1 问题重述

1.1 引言

随着社会经济的加速发展，在智能家居，物联网，自动驾驶等领域中，对于移动物体的超分辨率需求越来越大。现有的移动定位产品通常为调频连续波雷达 FMCW，通过发射线性扫频波，利用回波信号进行定位。但现有产品通常使用简单的加窗 FFT 或 MUSIC 等简单信号处理方法，分辨率低，抗噪声性能差，无法满足现有需求。事实上，整个雷达估计问题可以视为一个二维线谱估计问题。在线谱估计领域，超分辨率类的算法主要分为超分辨率子空间方法 [5, 6]，压缩感知类算法 [7, 8, 2] 与贝叶斯类算法 [1, 4]。本文通过对各类算法的估计类型，估计性能，复杂度与抗噪性能进行对比，最终选择多维变分贝叶斯方法最优的低复杂度高精度线谱估计方法。通过结合信息准则 [9] 模型阶数选择，数据关联，后端处理与结构噪声估计 [10, 11]，可以适用于各类复杂场景。

具体来讲，本文解决的问题为：

1.2 问题的提出

整个问题的求解思路如图1.1所示。

问题一：问题一要求根据无噪声仿真数据建立定位模型计算物体位置。我们根据雷达的接收信号模型在频域与角域的阵列响应特性建立了二维线谱估计定位模型，包含模型阶数估计与二维频率估计。并从雷达分辨率与克拉美罗界的角度得到了估计问题的下界。对于模型阶数估计，我们使用贝叶斯信息准则进行判决。超分辨率二维频率估计采用可达克拉美罗界的四类算法：二维牛顿正交匹配跟踪，二维原子范数方法，多维变分贝叶斯线谱估计方法与超快速线谱估计方法中选型。最终选择多维变分贝叶斯线谱估计 MDValse 方法进行超分辨率求解。

问题二：问题二要求在高斯噪声环境下定位多个物体。我们选用能够估计噪声方差的 MDValse 方法结合贝叶斯信息准则进行多目标定位。

问题三：要求设计在线低复杂度算法实现移动超分辨率定位，通过 MDValse 方法结合最近邻数据关联与卡尔曼滤波轨迹优化，实现了两物体轨迹的低复杂度高精度定位，并分析了算法的理论复杂度与实际复杂度。

问题四：要求考虑天线阵列结构误差情景下的鲁棒定位问题。通过 MUSIC+fmincon 优化算法对天线结构误差进行自校正。校正后通过 MDValse 方法进行鲁棒估计。




图 1.1 算法框图

2 模型的假设

1. 雷达与目标距离远大于雷达天线孔径 $r_k \gg L$ ，雷达发射信号视为单点源发射，不考虑不同发射天线间的发射信号区别；
2. 物体到天线的距离假设为到天线阵列中心的距离，不考虑空间宽带效应的影响。
3. 假设回波信号噪声为逐元素高斯噪声，噪声方差相同；
4. 假设物体为单反射点，具有形状的对象考虑由多个反射点组成；

3 符号说明

本文信号模型中的符号如下表所示。为了便于表示，各算法中会根据算法的特点重新定义符号，有少量符号混用情况。

符号	意义
N	天线数量
r_k	物体 k 到天线距离
L	天线孔径
T	采样周期
T_s	采样间隔
a_k	第 k 个目标回波信号幅度
ϕ_k	第 k 个目标回波信道相位
γ	调频斜率
Δd	天线间隔
θ_k	第 k 个目标的到达角
λ	波长
$\mathbf{Z}$	N 个天线上的回波信号
$\mathbf{S}_k$	第 k 个目标的回波信号
$\mathbf{W}$	噪声矩阵
σ^2	高斯噪声方差

4 模型的建立

4.1 问题一分析与求解

在本节中，我们推导了问题的信号模型，将问题归纳为二维线谱估计问题，即要估计模型阶数，二维频率与复增益。并从物理雷达分辨率，数学问题克拉美罗界的角度分析的性能界限。进一步，对二维线谱估计中的几类方法（FFT，子空间，压缩感知方法，贝叶斯类方法等）进行了精度，复杂度，估计类型分析。简单推导了两类基础算法（二维 FFT 与 JADE）作为基线算法。最后展示了估计结果。

4.1.1 二维线谱估计定位模型与算法分析

考虑一个二维平面场景中，具有 N 个均匀线性阵列 (Uniform Linear Array, ULA) 接收天线的雷达发射线性调频波经过目标后反射回雷达。承接问题中关于发射信号与回波信号相关描述，假设雷达与目标距离远大于雷达天线孔径 $r_k \gg L$ ，如图4.2所示，第 n 个天线上的经过第 k 个目标的雷达的在一个 chirp 周期 T 中采样后的回波信号可以重写为

$$s_{n,k} = a_k e^{j\phi_k} e^{j(4\pi\gamma T_s t r_k / c)} e^{-j(2\pi\Delta d n \sin(\theta_k) / \lambda)} \quad t = 0, 1, 2, \dots, \left\lceil \frac{T}{T_s} \right\rceil - 1 \quad (4.1)$$

其中， $a_k \in \mathbb{R}$ 为第 k 个目标回波信号幅度， $\phi_k \in [-\pi, \pi)$ 为第 k 个目标回波信道相位， γ 为调频斜率， T 为 chirp 周期， j 为虚数单位， T_s 为采样间隔， r_k 为第 k 个目标到雷达的距离， Δd 为天线间隔， θ_k 为第 k 个目标的到达角， λ 为波长。

定义等效频率

$$\omega_{1,k} \triangleq -2\pi\Delta d \sin(\theta_k) / \lambda \quad (4.2)$$

$$\omega_{2,k} \triangleq 4\pi\gamma T_s r_k / c \quad (4.3)$$

阵列响应向量

$$\mathbf{a}_N(\omega) \triangleq [1, e^{j\omega}, \dots, e^{j(N-1)\omega}]^T \quad (4.4)$$

与下列辅助参数与变量

$$M \triangleq \left\lceil \frac{T}{T_s} \right\rceil - 1 \quad (4.5)$$

$$x_k \triangleq a_k e^{j\phi_k} \quad (4.6)$$

N 个天线上第 k 个目标回波信号为

$$\mathbf{S}_k = x_k \mathbf{a}_N(\omega_{1,k}) \mathbf{a}_M(\omega_{2,k})^T \quad (4.7)$$

雷达的回波信号为

$$\mathbf{Z} = \sum_{k=1}^K \mathbf{S}_k + \mathbf{W} \quad (4.8)$$




图 4.2 信号到达不同天线间的延时示意图

其中, $\mathbf{Z} \in \mathbb{C}^{N \times M}$ 表示 N 个天线上的回波信号, $\mathbf{S}_k \in \mathbb{C}^{N \times M}$ 为第 k 个目标的回波信号, $\mathbf{W} \in \mathbb{C}^{N \times M}$ 为噪声, 为后续模型推导方便, 这里假设噪声逐元素服从高斯分布 $\mathcal{CN}(0, \sigma^2)$ 完整的回波信号模型为

$$\mathbf{Z} = \sum_{k=1}^K x_k \mathbf{a}_N(\omega_{1,k}) \mathbf{a}_M(\omega_{2,k})^T + \mathbf{W} \quad (4.9)$$

则第 k 个目标 O_k 的相对位置为


$$\theta_k = \arcsin\left(\frac{-\lambda \omega_{1,k}}{2\pi \Delta d}\right) \quad (4.10)$$

$$r_k = \omega_{2,k} c / 4\pi \gamma T_s \quad (4.11)$$

题目给定的问题要求我们从模型 (4.9) 中估计物体的位置。由于物体的位置与等效频率一一关联, 因此这个问题是一个典型的雷达方位估计问题。在数学上, 我们称该类问题为二维线谱估计 (Line Spectral Estimation, LSE) 问题。本问题中仅有一次观测, 因此是单测量向量 (Single Measurement Vector, SMV) 二维线谱估计问题 (SMV-2D-LSE)。线谱估计旨在从有限数量的观测中推断信号的不同频率成分。因此, 我们需要从观测中估计目标个

数/模型阶数 K ，每个目标的二维频率 $(\omega_{1,k}, \omega_{2,k}), \forall k$ （对应目标的方位），每个目标的复增益估计 $x_k, \forall k$ 作为可选项。

为了解决二维线谱估计问题，人们做了大量工作，通常是对一维技术的扩展，具体来讲，如图4.3所示，可以分为以下几类方法：



1. FFT 类，基于二维 FFT 加汉明窗等方法，优点是复杂度低，但精度很差。

2. 超分辨率子空间方法，包括二维 ESPRIT[12]、二维 MUSIC[13]、矩阵增强矩阵束[14] 和基于张量的估计 [15]。如果可以使用多个快照来近似信号协方差，这些技术可以有效地工作。此外，它们通常要求源是不相关的。为了克服这些问题，平滑技术已被纳入子空间方法，例如二维阻尼 MUSIC[16]、2-D RARE[5] 和 2-D IMDF[6]。通过平滑处理，这些方法可在只有一个快照时用于相关源，但代价是减少有效阵列孔径变小，从而牺牲分辨率。此外，子空间方法依赖于信号的一些先验知识，例如信号源的数量。

2. 网络压缩感知 (Compressed sensing, CS) 方法，基于压缩感知 (CS) 的方法利用空间域中的源稀疏性，由于其强大的理论基础和高分辨率等优点，已成为一种具有吸引力的方法 [17]。此外，基于 CS 的方法需要较少的测量次数 [7, 18, 19, 3, 8]。传统的基于 CS 的方法建立了一个离散的网格，并假设所有峰值都精确地位于网格上。这种假设是不切实际的，当峰值不在网格上时，会发生基失配 [20]。为了克服基失配，可以采用更精细的网格，但这增加了计算复杂性 [21]。为了增强性能与降低复杂度，通过牛顿梯度下降方法，提出了多维近似最优牛顿正交匹配追踪 (Newtonized Orthogonal Matching Pursuit, NOMP) [2] 来解决线谱估计问题。

4. 无网格压缩感知，通过原子范数最小化 (Atomic Norm Minimization, ANM) 和半定规划 (Semi-Definite Programming, SDP)，以实现从压缩测量中恢复无网格正弦分量 [22, 23,

24, 25]。它利用信号的 Vandermonde 结构实现超分辨率的无网格估计。当沿着谱线收集测量值时，通过总变差范数最小化得到了类似的结果 [26]。由于在一维问题中的成功应用，ANM 也被应用于二维谱估计问题 [27, 28, 29]。主要思想是将接收的二维信号矢量化，然后将信号的二维 Vandermonde 结构转换为 ANM 的合适 SDP 公式。基于矢量化的 ANM 显示了巨大的性能优势，包括单快照适用性、信号相关性恢复能力和无网格恢复能力，但是，由于矢量化操作导致的问题规模巨大，计算成本很高。仿真结果表明，在常规 PC 机上， 32×32 二维线谱估计问题的矢量化 ANM 不能在两天内完成。这一事实限制了二维 ANM 在实践中的应用。最近，快速的二维原子范数方法 [3] 降低了多维原子范数方法的复杂度，但复杂度仍难以接受。

以上方法必须用模型阶数 K (目标数量) 估计方法加以补充。流行的选择包括广义信息准则 (如 AIC、BIC) [9] 或更专业的方法，如基于估计信号协方差矩阵特征值的 SORTE [30]。如果模型阶数 K 已知，以上方法性能有保证，但如果模型阶数 K 未知，它们的估计精度会显著降低。

5. 贝叶斯类方法，另一系列工作采用了贝叶斯框架，并增强了稀疏贝叶斯学习 (Sparse Bayesian Learning, SBL) 的概率模型 [31, 32]。在 SBL 中，稀疏权重向量通过为其条目选择参数化/层次化先验模型来提升 [31, 32]。使用变分推理方法 [33, 34, 35] 或边缘化后验概率密度最大化方法 [36] 对增强模型进行估计。所有现有的基于 SBL 的方法的共同点是，它们局限于计算频率的点估计 (即 MAP/ML 估计)。另一个限制是，虽然提供了良好的重建性能，但基于 SBL 的方法高估了模型阶数，即，它们始终输出小功率的额外杂散分量 (伪影) [33, 35]。因此，使用变分贝叶斯线谱估计 [37, 38] 的估计方法通过完整的贝叶斯处理获得了更好的性能。通过伯努利高斯分布描述频率不确定性，并通过 Von mises 分布描述频率点，获得了模型阶数，模型噪声，频点与复增益的完整估计。

几类方法的比较如表 4.1 与表 4.2 所示，可以看到，网格 CS 与贝叶斯类方法在复杂度与精度方面都展现出很好的性能。而子空间类方法与无网格 CS 方法复杂度过高，在实践中往往无法使用。

4.1.2 估计精度限制分析

雷达方位估计问题/线谱估计问题的精度受到雷达分辨率与问题的克拉美罗界 (Cramér-Rao bound, CRB) 限制。下面我们分别推导两类精度限制。在本问题中，超分辨率即指的是超越雷达分辨率，尽可能达到数学问题的 CRB。

物理限制：雷达分辨率限制

假定两个目标在同一角度保持同一速度但处在不同距离时，可以用距离模糊函数来衡量分辨能力，见下式

$$|\chi(\tau, 0)| = \left| \int_{-\infty}^{\infty} uu^*(t + \tau) dt \right| \quad (4.12)$$

表 4.1 LSE 算法精度与复杂度比较

算法类型	相关文献	估计精度	复杂度	超分辨率	格化
FFT		分辨率精度	低	否	是
子空间类方法	[13, 16, 5, 6]	分辨率精度与 CRB 之间	高	是	是
网格 CS	[7, 18, 19, 8, 2]	CRB 可达	低	是	是
无网格 CS	[23, 24, 25, 28, 29, 3]	CRB 可达	高	是	否
贝叶斯类方法	[31, 32, 33, 35, 1, 4]	CRB 可达	低	是	否

表 4.2 LSE 算法估计类型比较

算法类型	频率估计	模型阶数估计	噪声估计	搜索空间可调
FFT	点估计	否	否	否
子空间类方法	点估计	否	否	是
网格 CS	点估计	否	否	是
无网格 CS	点估计	否	否	是
贝叶斯类方法	分布估计	是	是	是

一般用距离模糊函数的主瓣宽度定义距离分辨率 δR ，即

$$\delta R = \frac{c}{2} \frac{\int_{-\infty}^{\infty} |\chi(\tau, 0)|^2 d\tau}{|\chi(0, 0)|^2} = \frac{c}{2B} \quad (4.13)$$

其中 B 为带宽，即带宽越大，距离分辨率越高，本问题中，距离分辨率为

$$\delta R = \frac{c}{2(M-1)\gamma T_s} = 0.0596m \quad (4.14)$$

距离动态范围 ΔR 为

$$\Delta R = \frac{c}{2\gamma T_s} = 15.19m \quad (4.15)$$

由式 (4.10)，角度估计受 $\sin$ 函数的影响，很难有一个绝对的角度分辨率判据，一般用以下近似关系表示

$$\delta\theta \approx \lambda/\Delta d(N-1) \quad (4.16)$$

即天线孔径越大，角度分辨率越高。

数学问题下界：克拉美罗界 [2]

本问题中我们要估计目标个数/模型阶数 K ，每个目标的二维频率 $(\omega_{1,k}, \omega_{2,k}), \forall k$ （对应目标的方位）。在推导克拉美罗界时，我们假设模型阶数已知，估计二维频率的克拉美罗界。

定义

$$\boldsymbol{\omega} = [\boldsymbol{\omega}_1^T, \boldsymbol{\omega}_2^T]^T \quad (4.17)$$

$$\boldsymbol{\omega}_1 = [\omega_{1,1}, \omega_{1,2}, \dots, \omega_{1,K}]^T \quad (4.18)$$

$$\boldsymbol{\omega}_2 = [\omega_{2,1}, \omega_{2,2}, \dots, \omega_{2,K}]^T \quad (4.19)$$

模型 (4.9) 可以重写为

$$\mathbf{y} = \mathbf{A}(\boldsymbol{\omega}_1, \boldsymbol{\omega}_2) \mathbf{x} + \mathbf{n} \quad (4.20)$$

其中 $\mathbf{A}(\boldsymbol{\omega}_1, \boldsymbol{\omega}_2) = [\mathbf{a}(\omega_{1,1}, \omega_{2,1}), \mathbf{a}(\omega_{1,2}, \omega_{2,2}), \dots, \mathbf{a}(\omega_{1,K}, \omega_{2,K})]$ ，且 $\mathbf{y} = \text{vec}(\mathbf{Y})$ ， $(\omega_{1,k}, \omega_{2,k}) = \mathbf{a}_M(\omega_{2,k}) \otimes \mathbf{a}_N(\omega_{1,k})$ ， $\otimes$ 为克罗内克积， $\mathbf{x} = [x_1, x_2, \dots, x_K]$ 。在下文中，为了简洁起见，我们使用 $\mathbf{A}$ 代替 $\mathbf{A}(\boldsymbol{\omega}_1, \boldsymbol{\omega}_2)$ 。注意，在高斯观测的情况下 $\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}(\boldsymbol{\kappa}), \sigma^2/2\mathbf{I})$ ， $\boldsymbol{\mu}(\boldsymbol{\kappa})$ 表示 $\boldsymbol{\mu}$ 依赖于信道参数 $\boldsymbol{\kappa} \in \mathbb{R}^P$ 。Fisher 信息矩阵 (FIM) 由下式给出

$$\mathbf{I}(\boldsymbol{\kappa}) = \frac{2}{\sigma^2} \left[\frac{\partial \boldsymbol{\mu}(\boldsymbol{\kappa})}{\partial \boldsymbol{\kappa}} \right]^T \left[\frac{\partial \boldsymbol{\mu}(\boldsymbol{\kappa})}{\partial \boldsymbol{\kappa}} \right], \quad (4.21)$$

其中

$$\frac{\partial \boldsymbol{\mu}(\boldsymbol{\kappa})}{\partial \boldsymbol{\kappa}} = \begin{bmatrix} \frac{\partial [\boldsymbol{\mu}(\boldsymbol{\kappa})]}{\partial \kappa_1} & \frac{\partial [\boldsymbol{\mu}(\boldsymbol{\kappa})]}{\partial \kappa_2} & \dots & \frac{\partial [\boldsymbol{\mu}(\boldsymbol{\kappa})]}{\partial \kappa_P} \end{bmatrix} \quad (4.22)$$

观测可以拆分为 $[\Re\{\mathbf{y}\}; \Im\{\mathbf{y}\}]$ ， $\boldsymbol{\kappa} \in \mathbb{R}^{4K}$ ， $\boldsymbol{\mu}(\boldsymbol{\kappa}) \in \mathbb{R}^{2MN}$ 为

$$\boldsymbol{\kappa} = \begin{bmatrix} \Re\{\mathbf{x}\} \\ \Im\{\mathbf{x}\} \\ \boldsymbol{\omega}_x \\ \boldsymbol{\omega}_y \end{bmatrix}, \boldsymbol{\mu}(\boldsymbol{\kappa}) = \begin{bmatrix} \Re\{\mathbf{Ax}\} \\ \Im\{\mathbf{Ax}\} \end{bmatrix} \quad (4.23)$$

注意到

$$\frac{\partial \boldsymbol{\mu}(\boldsymbol{\kappa})}{\partial \boldsymbol{\kappa}} = \bar{\mathbf{A}} \bar{\mathbf{D}} \quad (4.24)$$

其中

$$\bar{\mathbf{A}} = \begin{bmatrix} \Re\{\mathbf{A}\} & -\Im\{\mathbf{A}\} \\ \Im\{\mathbf{A}\} & \Re\{\mathbf{A}\} \end{bmatrix} \quad (4.25)$$

$$\bar{\mathbf{D}} = [\bar{\mathbf{D}}_x, \bar{\mathbf{D}}_y] \quad (4.26)$$

$$\bar{\mathbf{D}}_x = \begin{bmatrix} \frac{\partial \Re\{\mathbf{Ax}\}}{\partial \omega_x} \\ \frac{\partial \Im\{\mathbf{Ax}\}}{\partial \omega_x} \end{bmatrix}, \quad (4.27)$$

则有

$$\mathbf{I}(\boldsymbol{\kappa}) = \begin{pmatrix} - & - \\ \mathbf{H} & \boldsymbol{\Delta}_1 \\ - & - \\ \boldsymbol{\Delta}_1^T & \boldsymbol{\Gamma} \end{pmatrix} \quad (4.28)$$

其中

$$\bar{\mathbf{H}} = \bar{\mathbf{A}}^T \bar{\mathbf{A}}, \quad (4.29)$$

$$\bar{\boldsymbol{\Delta}} = \bar{\mathbf{A}}^T \bar{\mathbf{D}} = \begin{bmatrix} \Re \{ \mathbf{A}^H [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \} \\ \Im \{ \mathbf{A}^H [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \} \end{bmatrix}, \quad (4.30)$$

$$\bar{\boldsymbol{\Gamma}} = \bar{\mathbf{D}}^T \bar{\mathbf{D}} = \Re \left\{ \left[\frac{\partial(\mathbf{A}\mathbf{x})}{\partial \boldsymbol{\omega}} \right]^H \frac{\partial(\mathbf{A}\mathbf{x})}{\partial \boldsymbol{\omega}} \right\} \quad (4.31)$$

$$\frac{\partial(\mathbf{A}\mathbf{x})}{\partial \boldsymbol{\omega}} = [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \quad (4.32)$$

$$\mathbf{D}_x = \left[\frac{\partial \mathbf{a}(\omega_{1,1}, \omega_{2,1})}{\omega_{1,1}}, \frac{\partial \mathbf{a}(\omega_{1,2}, \omega_{2,2})}{\omega_{1,2}}, \dots, \frac{\partial \mathbf{a}(\omega_{1,K}, \omega_{2,K})}{\omega_{1,K}} \right], \quad (4.33)$$

$$\mathbf{D}_y = \left[\frac{\partial \mathbf{a}(\omega_{1,1}, \omega_{2,1})}{\omega_{2,1}}, \frac{\partial \mathbf{a}(\omega_{1,2}, \omega_{2,2})}{\omega_{2,2}}, \dots, \frac{\partial \mathbf{a}(\omega_{1,K}, \omega_{2,K})}{\omega_{2,K}} \right]$$

$$\mathbf{X} \triangleq \text{diag}(\mathbf{x}) \quad (4.34)$$

注意，对于块矩阵的逆矩阵

$$\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^T & \mathbf{C} \end{bmatrix}^{-1} = \begin{bmatrix} \mathbf{A}^{-1} + \mathbf{A}^{-1} \mathbf{B} \mathbf{S}^{-1} \mathbf{B}^T \mathbf{A}^{-1} & -\mathbf{A}^{-1} \mathbf{B} \mathbf{S}^{-1} \\ -\mathbf{S}^{-1} \mathbf{B}^T \mathbf{A}^{-1} & \mathbf{S}^{-1} \end{bmatrix}, \quad (4.35)$$

其中 $\mathbf{S} = \mathbf{C} - \mathbf{B}^T \mathbf{A}^{-1} \mathbf{B}$.

$$\text{CRB}(\boldsymbol{\omega}) = \frac{\sigma^2}{2} \left(\bar{\boldsymbol{\Gamma}} - \bar{\boldsymbol{\Delta}}^T \bar{\mathbf{H}}^{-1} \bar{\boldsymbol{\Delta}} \right)^{-1} \quad (4.36)$$

$$\text{CRB}^{-1}(\boldsymbol{\omega}) = \frac{2}{\sigma^2} \left(\bar{\boldsymbol{\Gamma}} - \bar{\boldsymbol{\Delta}}^T \bar{\mathbf{H}}^{-1} \bar{\boldsymbol{\Delta}} \right) \quad (4.37)$$

注意

$$\bar{\mathbf{H}}^{-1} = \begin{pmatrix} \Re \left\{ (\mathbf{A}^H \mathbf{A})^{-1} \right\} & -\Im \left\{ (\mathbf{A}^H \mathbf{A})^{-1} \right\} \\ \Im \left\{ (\mathbf{A}^H \mathbf{A})^{-1} \right\} & \Re \left\{ (\mathbf{A}^H \mathbf{A})^{-1} \right\} \end{pmatrix}. \quad (4.38)$$

$$\bar{\mathbf{H}}^{-1} \bar{\boldsymbol{\Delta}} = \bar{\mathbf{H}}^{-1} \bar{\mathbf{A}}^T \bar{\mathbf{D}} = \begin{pmatrix} \Re \left\{ (\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \right\} \\ \Im \left\{ (\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \right\} \end{pmatrix}. \quad (4.39)$$

因此

$$\text{CRB}^{-1}(\boldsymbol{\omega}) = \frac{2}{\sigma^2} \Re \left\{ [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}]^H \left[\mathbf{I}_{MN} - \mathbf{A} (\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H \right] [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \right\} \quad (4.40)$$

最终的 CRB 为

$$\text{CRB}(\boldsymbol{\omega}) = \frac{\sigma^2}{2} \left[\Re \left\{ [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}]^H \left[\mathbf{I}_{MN} - \mathbf{A} (\mathbf{A}^H \mathbf{A})^{-1} \mathbf{A}^H \right] [\mathbf{D}_x \mathbf{X}, \mathbf{D}_y \mathbf{X}] \right\} \right]^{-1} \quad (4.41)$$

4.1.3 基线方法：FFT 类方法，二维加窗 FFT

在 FMCW 毫米波雷达定位场景中，最为常见方案的是采用 FFT 变换的频谱分析法。FFT 的基础是离散傅立叶变换 (DFT)，是一种离散信号频谱分析算法，特点是时域信号数值离散、时间离散。N 点离散信号 $x(n)$ 的 DFT 计算公式为：

$$X(k) = \text{DFT}[x(n)] = \sum_{n=0}^{N-1} x(n) \cdot W_N^{kn} \quad , \quad k = 0, 1, \dots, N-1 \quad (4.42)$$

由于 DFT 的系数 W_N^{kn} 具有对称性、周期性和可约性，FFT 利用这些特性以及蝶形运算架构实现了计算复杂度的极大简化（时间复杂度由 $O(N^2)$ 降为 $O(N \log_2(N))$ ）。随着点数 N 不断增大，FFT 所能节省的时间越多，计算速度提升越大。考虑到问题中的具体条件以及求解要求，二维 FFT 由于其能够更加直接地体现出天线阵列的频率分量与相位梯度的优势成为 FFT 类的解决方案。二维 DFT 计算公式如下：

$$F(u, v) = \frac{1}{MN} \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi(\frac{ux}{M} + \frac{vy}{N})} \quad (4.43)$$

由于传统 FFT 算法中频谱泄漏、主瓣能量衰减以及主瓣与旁瓣相互串扰等缺陷，单纯借助二维 FFT 进行高分辨率定位是难以实现的。加窗 FFT 技术能够有效抑制频谱泄露问题，进一步提升定位精度。由实验数据表明，FFT 运算中在对信号加标准矩形窗时，对于信号离散频谱的幅值计算误差最大为 36.4%，同时相位误差可达 $\pi/2$ ；在其他加窗操作中，效果最好的是加汉宁窗，但在极端情况下，其幅值计算误差最大将达到 15.4%。由公式 (4-1) 所表示的信号模型可知，k 个待测物体将会在二维傅里叶频谱中显像为 k 个峰值。借助各个二维频谱峰的相对位置坐标，待测物体所反射的距离差与反射角可以求解得到。相较于本文所提出的其他求解方案，FFT 类的方案计算复杂度较低，易于在线实现，但是其精度受制于频谱泄露等方案本身缺陷以及采样点数，采样速率等硬件条件限制。

4.1.4 基线方法：JADE 问题

在 FMCW 毫米波定位中，子空间法一直是一类重要的方法。JADE (Joint Angle and Delay Estimation，到达角和时延联合估计) 方法 [39] 通过时空信道估计来自数字调制信号源到达天线阵的多径信号的到达角和时延即可实现目标的定位。

该方法的第一步是估计从目标到天线阵的信道冲激响应。这可以通过使用训练序列或者盲信道估计实现，根据 M 个连续时隙收集的数据来获得估计。将时隙索引记为 q，则我们对真实信道 $\mathbf{H}$ 的估计采用以下形式：

$$\mathbf{Y}_q = \mathbf{H}_q + \mathbf{V}_q, \quad q = 1, \dots, M \quad (4.44)$$

其中 $\mathbf{V}_q$ 是对于噪声矩阵的估计，如此就分离出了噪声子空间。通过向量化运算（取矩阵每一行的转置，并将其堆叠在前一行转置的下方）可以得到

$$\mathbf{h} = (\mathbf{A}(\boldsymbol{\theta}) \diamond \mathbf{G}(\tau)) \text{diag}(\mathbf{D}) =: \mathbf{U}(\boldsymbol{\theta}, \tau) \boldsymbol{\beta} \quad (4.45)$$

$$\mathbf{y}_q = \mathbf{U}(\boldsymbol{\theta}, \tau) \boldsymbol{\beta}_q + \mathbf{v}_q, \quad q = 1, \dots, M \quad (4.46)$$

其中 $\diamond$ 代表按列的克罗内克乘积，即 $\mathbf{U}(\boldsymbol{\theta}, \tau)$ 的第 l 列是 a_{θ_l} 和 g_{τ_l} 的克罗内克乘积，所得的 $\mathbf{U}(\boldsymbol{\theta}, \tau)$ 就是时空矩阵，受到达角和路径时延的影响。

进一步地，由 $\mathbf{Y} = [\mathbf{y}_1, \dots, \mathbf{y}_M]$ 以及相似的运算可以得出

$$\mathbf{Y} = \mathbf{U}(\boldsymbol{\theta}, \tau) \mathbf{B} + \mathbf{V} \quad (4.47)$$

最后，根据给定噪声矩阵和测得的时空矩阵估计每个目标对应的两个参数 (θ 和 τ 即可)。通过最大似然法收敛估计这些参数或是通过 MUSIC 算法搜索谱峰即可得到估计结果。

4.1.5 超分辨率算法选型分析

问题一给出一个 chirp 周期内的 IF 信号，即要根据线谱估计模型 (4.9) 进行超分辨率估计。由于稀疏估计类的方法大多需要已知模型阶数或噪声方差，因此我们先通过信息准则 (Information Criterion, IC) [9] 进行模型阶数 (目标个数) 的估计，如赤池信息准则 (Akaike Information Criterion, AIC)，贝叶斯信息准则 (Bayesian Information Criterion, BIC) 与广义信息准则 (Generalized Information Criterion, GIC)。然后通过几类超分辨率算法中的最优秀 (State-of-the-art, SOTA) 的算法进行性能与复杂度比较，得到低复杂度高精度的雷达定位算法。我们选择的算法分别为：网格压缩感知：牛顿梯度下降正交匹配跟踪 2D-NOMP[2]，无网格压缩感知：快速二维原子范数 2D-MANM(Matrix ANM, MANM)[3]，贝叶斯类：多维变分贝叶斯线谱估计 MDVLSSE(Multidimensional Variational Line Spectra Estimation, MDVLSSE)[37, 38, 1]，超快速线谱估计 (Superfast Line Spectral Estimation, SLSE) [4] 的多维拓展版本多维超快速线谱估计 (Multidimensional SLSE, MDSLSE)。

选择的几类低复杂度高精度算法的比较如表4.3所示，其中 2D-NOMP 的复杂度为

$$\mathcal{O}(KMN \log(MN) + K^2MN) \quad (4.48)$$

MANM 复杂度为

$$\mathcal{O}(N^{3.5}M^{3.5}) \quad (4.49)$$

MDVLSSE 复杂度为

$$\mathcal{O}(MN \log(MN) + KMN) \quad (4.50)$$

MDSLSE 复杂度为

$$\mathcal{O}(MN \log^2 MN + KMN \log MN) \quad (4.51)$$

可以看出 2D-NOMP, MDVASE 与 MDSLSE 复杂度较低, MANM 精度高, 列为备选算法。在估计结果中我们进一步比较几种算法的估计性能。在问题一中, 我们详细 2D-NOMP 与 MANM 两类需要给定噪声方差的高精度估计方法。在问题二中推导带有噪声估计的 MDVASE 与 MDSLSE 方法。讲述为了表述方便, 在之后的算法推导中, 我们承接4.1中信号模型相关表述并在本节中混用一些符号。

表 4.3 低复杂度超分辨率 LSE 算法比较

算法名称	精度界	复杂度	频率估计	模型阶数 估计	噪声估计	直接二维 估计
2DNOMP[2]	CRB	(4.48)	点估计	否	否	是
MANM[3]	CRB	(4.49)	点估计	否	否	否
MDVASE[1]	CRB	(4.50)	分布估计	是	是	是
MDSLSE[4]	CRB	(4.51)	分布估计	是	是	否

4.1.6 模型阶数选择: 信息准则 (AIC, GIC, BIC)

从表4.2中可以看到, 大多数的方法并不附带模型阶数估计。因此我们首先要估计的就是模型阶数。模型阶数选择在本问题中指估计 K 的数值, 即在 LSE 问题中选择一种稀疏模型。信息准则即通过一定的惩罚项, 在拟合优度与模型的简单性之间进行权衡, 平衡过拟合与欠拟合的风险。根据 [9], 所有的信息准则有一个统一形式即:

$$-2 \ln p_n(y, \hat{\theta}^n) + \eta(n, N)n \quad (4.52)$$

其中 $p_n(y, \hat{\theta}^n)$ 表示模型阶数为 n 时, 观测 y 在参数 $\hat{\theta}^n$ 下的似然函数, n 为模型阶数, N 为观测数量, 几类准则的惩罚项 $\eta(n, N)$ 分别为:

赤池信息准则:

$$\text{AIC: } \eta(n, N) = 2 \quad (4.53)$$

修正赤池信息准则:

$$\text{AIC}_c: \eta(n, N) = 2 \frac{N}{N - n - 1} \quad (4.54)$$

广义信息准则:

$$\text{GIC: } \eta(n, N) = \nu \quad (4.55)$$

其中 ν 为可选择常数。

贝叶斯信息准则:

$$\text{BIC: } \eta(n, N) = \ln N. \quad (4.56)$$

在噪声为逐元素高斯白噪声时，(4.52) 可以重写为

$$n \ln(RSS/n) + \eta(n, N)n \quad (4.57)$$

其中 RSS 为信号残差。

有经验证据表明， AIC_c 在小样本中的表现优于 AIC （而在中型或大型样本中，这两个规则几乎相等）。此外，因为 BIC 是最优最大后验概率规则的渐近近似，理论角度较其他算法更优。关于 GIC ， GIC 有 $\nu \in [2, 6]$ 。在不同的研究情景中精确选择可以超越 AIC 和 AIC_c 。因此，由于缺乏更精确的指导，我们可以考虑使用 $\nu = 4$ 的 GIC ，该值位于上述区间的中间。在图4.4中，上述规则的惩罚系数作为观测数量的函数，以进一步说明它们之间的关系。由于本问题中样本数量较大，我们选择理论性能更好的 BIC 准则作为模型选择的信息准则。




图 4.4 不同准则惩罚项随观测数量的变化曲线

4.1.7 网格 CS 方法：牛顿梯度下降正交匹配跟踪 2D-NOMP

2D-NOMP[2] 针对的场景为多目标多测量向量场景，本问题只需将多测量向量转换为单测量向量即可使用。NOMP 使用牛顿求精和反馈策略来获得接近最优的估计性能。此外，充分利用快速傅里叶变换，NOMP 的计算复杂度很低。

我们首先研究单个目标的 2D 线谱估计问题，然后将结果推广到多目标场景。单目标场景中， T 个测量值的噪声测量模型简化为

$$\mathbf{Y}(t) = x(t)\mathbf{a}_N(\omega_x)\mathbf{a}_M^T(\omega_y) + \mathbf{N}(t) \quad (4.58)$$

振幅 $x(t)$ 和频率 $\omega \triangleq [\omega_x, \omega_y]^T$ 的最大似然 (ML) 估计可以等效地表示为最小化剩余功率

$\sum_{t=1}^T \|\mathbf{Y}(t) - x(t)\mathbf{a}_N(\omega_x)\mathbf{a}_M^T(\omega_y)\|_F^2$, 等于最大化函数

$$S(x(1), \dots, x(T), \boldsymbol{\omega}) = \sum_{t=1}^T S(x(t), \boldsymbol{\omega}) \quad (4.59)$$

其中

$$S(x(t), \boldsymbol{\omega}) = 2\Re \{x(t)\mathbf{a}_M^T \mathbf{Y}^H(t)\mathbf{a}_N\} - |x(t)|^2 \|\mathbf{a}_N \mathbf{a}_M^T\|_F^2 = 2\Re \{x(t)\mathbf{a}_M^T \mathbf{Y}^H(t)\mathbf{a}_N\} - |x(t)|^2. \quad (4.60)$$

在所有振幅和频率上直接优化 $S(x(1), \dots, x(T), \boldsymbol{\omega})$ 是困难的。因此, 实施了两阶段方法 [40]:

1. 检测阶段, 通过将 $\boldsymbol{\omega}$ 限制为离散集合, 找到 $\boldsymbol{\omega}$ 的粗略估计。
2. 优化阶段, 其中对检测目标的振幅和频率进行迭代优化。

对于任何给定 $\boldsymbol{\omega}$, 使 $S(x(t), \boldsymbol{\omega})$ 最大化的增益为 $\hat{x}(t) = \frac{\mathbf{a}_N^H \mathbf{Y}(t) \mathbf{a}_M^*}{\|\mathbf{a}_N \mathbf{a}_M^T\|_F^2}$. 将 $S(x(1), \dots, x(T), \boldsymbol{\omega})$ 中的 $\hat{x}(t)$ 代入, 可以得到 $\boldsymbol{\omega}$ 的广义似然比检验 (Generalized Likelihood Ratio Test, GLRT) 估计, 这是以下优化问题的解决方案:

$$\underset{\boldsymbol{\omega}}{\operatorname{argmax}} G_Y(\boldsymbol{\omega}), \quad (4.61)$$

其中 $G_Y(\boldsymbol{\omega})$ 是 GLRT 成本函数, $\mathbf{Y}$ $\text{CN } M \times T$ 定义为

$$\mathbf{Y} = [\operatorname{vec}(\mathbf{Y}(1)), \operatorname{vec}(\mathbf{Y}(2)), \dots, \operatorname{vec}(\mathbf{Y}(T))] \quad (4.62)$$

$$G_Y(\boldsymbol{\omega}) = \sum_{t=1}^T G_{Y(t)}(\boldsymbol{\omega}) \quad (4.63)$$

其中

$$G_{Y(t)}(\boldsymbol{\omega}) = |\mathbf{a}_N^H \mathbf{Y}(t) \mathbf{a}_M^*|^2 \quad (4.64)$$

为了找到 (4.61) 的全局解, 在下文中提出了一种称为检测和细化的两阶段方法。

检测: 通过将 $\boldsymbol{\omega}$ 限制为由 $\boldsymbol{\Omega} \triangleq (\Omega_x, \Omega_y)$ 表示的有限离散集对, 我们可以得到 $\boldsymbol{\omega}$ 的粗略估计, 其中 $\Omega_x \triangleq \{k(2\pi/\gamma_x N) : k = 0, 1, \dots, (\gamma_x N - 1)\}$, $\Omega_y \triangleq \{k(2\pi/\gamma_y M) : k = 0, 1, \dots, (\gamma_y M - 1)\}$, (γ_x, γ_y) 是与离散傅里叶变换 (DFT) 网格相关的过采样因子。这里, 我们将 $(\mathbf{DFT}_x, \mathbf{DFT}_y)$ 定义为 $\mathbf{DFT}_x \triangleq \{2\pi n/N : n = 0, 1, \dots, N - 1\}$ 和 $\mathbf{DFT}_y \triangleq \{2\pi m/M : m = 0, 1, \dots, M - 1\}$ 分别是。设 $\boldsymbol{\omega}_c = [\boldsymbol{\omega}_{c,x}, \boldsymbol{\omega}_{c,y}]^T$, 有

$$\boldsymbol{\omega}_C = \underset{\boldsymbol{\omega} \in \boldsymbol{\Omega}}{\operatorname{argmax}} G_Y(\boldsymbol{\omega}) \quad (4.65)$$

使成本函数 (4.63) 最大化的是这个阶段的输出, 相应的 $\hat{x}(t)$ 估计值是

$$\hat{x}(t) = [\mathbf{a}_N^H(\boldsymbol{\omega}_{c,y}) \mathbf{Y}(t) \mathbf{a}_M^*(\boldsymbol{\omega}_{c,x})] / \|\mathbf{a}_N(\boldsymbol{\omega}_{c,x}) \mathbf{a}_M^T(\boldsymbol{\omega}_{c,y})\|_F^2 \quad (4.66)$$

精细化：让 $(\hat{x}(1), \dots, \hat{x}(T), \hat{\omega})$ 表示当前估计值。对于成本函数 $S(\hat{x}(1), \dots, \hat{x}(T), \omega)$ ，频率细化的牛顿程序为

$$\hat{\omega}' = \hat{\omega} - \left[\sum_{t=1}^T \ddot{S}(\hat{x}(t), \hat{\omega}) \right]^{-1} \left(\sum_{t=1}^T \dot{S}(\hat{x}(t), \hat{\omega}) \right) \quad (4.67)$$

其中

$$\dot{S}(\hat{x}(t), \hat{\omega}) = \left[\frac{\partial S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_x}, \frac{\partial S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_y} \right]^T, \quad (4.68)$$

$$\ddot{S}(\hat{x}(t), \hat{\omega}) = \begin{bmatrix} \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_x^2} & \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_x \partial \hat{\omega}_y} \\ \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_y \partial \hat{\omega}_x} & \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_y^2} \end{bmatrix} \quad (4.69)$$

是 $S(\hat{x}(t), \omega)$ 在 $\hat{\omega}$ 处计算的梯度矩阵和 Hessian 矩阵。然后增益参数更新为

$$\hat{x}'(t) = \frac{\mathbf{a}_N^H(\hat{\omega}'_x) \mathbf{Y}(t) \mathbf{a}_M^*(\hat{\omega}'_y)}{\|\mathbf{a}_N(\hat{\omega}'_x) \mathbf{a}_M^T(\hat{\omega}'_y)\|_F^2} = \mathbf{a}_N^H(\hat{\omega}'_x) \mathbf{Y}(t) \mathbf{a}_M^*(\hat{\omega}'_y) \quad (4.70)$$

具体来说，梯度和 Hessian 矩阵可以计算为

$$\begin{aligned} \frac{\partial S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_x} &= 2\Re \left\{ \hat{x}(t) \mathbf{a}_M^T(\hat{\omega}_y) \mathbf{Y}^H(t) \frac{d\mathbf{a}_N(\hat{\omega}_x)}{d\hat{\omega}_x} \right\}, \\ \frac{\partial S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_y} &= 2\Re \left\{ \hat{x}(t) \frac{d\mathbf{a}_M^T(\hat{\omega}_y)}{d\hat{\omega}_y} \mathbf{Y}^H(t) \mathbf{a}_N(\hat{\omega}_x) \right\}, \end{aligned} \quad (4.71)$$

与

$$\begin{aligned} \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_x^2} &= 2\Re \left\{ \hat{x}(t) \mathbf{a}_M^T(\hat{\omega}_y) \mathbf{Y}^H(t) \frac{d^2 \mathbf{a}_N(\hat{\omega}_x)}{d\hat{\omega}_x^2} \right\}, \\ \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_y^2} &= 2\Re \left\{ \hat{x}(t) \frac{d^2 \mathbf{a}_M^T(\hat{\omega}_y)}{d\hat{\omega}_y^2} \mathbf{Y}^H(t) \mathbf{a}_N(\hat{\omega}_x) \right\}, \\ \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_x \partial \hat{\omega}_y} &= \frac{\partial^2 S(\hat{x}(t), \hat{\omega})}{\partial \hat{\omega}_y \partial \hat{\omega}_x} = 2\Re \left\{ \hat{x}(t) \frac{d\mathbf{a}_M^T(\hat{\omega}_y)}{d\hat{\omega}_y} \mathbf{Y}^H(t) \frac{d\mathbf{a}_N(\hat{\omega}_x)}{d\hat{\omega}_x} \right\}, \end{aligned} \quad (4.72)$$

在成本函数局部凹的条件下，我们通过使用更新规则 (4.67) 使 $S(\hat{x}(1), \dots, \hat{x}(T), \omega)$ 最大化。

多目标情况下，假设我们已经检测到 L 个目标，并让 $P = \{(\hat{\mathbf{x}}_l, \hat{\omega}_l), l = 1, \dots, L\}$ 表示检测到的目标的估计集，其中 $\hat{\mathbf{x}}_l = [\hat{x}_l(1), \hat{x}_l(2), \dots, \hat{x}_l(T)]$ 。与这些估计相对应的剩余测量值为

$$\mathbf{Y}_r^P(t) = \mathbf{Y}(t) - \sum_{l=1}^L \hat{x}_l(t) \mathbf{a}_N(\hat{\omega}_{x,l}) \mathbf{a}_M^T(\hat{\omega}_{y,l}) \quad (4.73)$$

估计多个目标的方法是采用单目标程序对剩余能量进行牛顿坐标下降 $\|\mathbf{Y}_r^P(t)\|_F^2$ 。坐标下降的一步包括调整所有 $\sum_{t=1}^T \|\mathbf{Y}_r^P(t)\|_F^2$ 。细化 l th 目标的步骤如下： $\mathbf{Y}_r^{P \setminus \{\hat{x}_l(t), \hat{\omega}_l\}}$ 现在称为测量值 $\mathbf{Y}$ 并且单目标更新步骤用于细化 $\hat{\omega}_l$ 和 $\hat{x}_l$ 。

总的来说，我们通过最大化成本函数 (4.63) 检测离散集对 Ω 上的频率。然后，我们利用成本函数的一阶和二阶导数的知识来改进估计。接下来，我们使用所有其他先前检测到的目标的信息来进一步提高每个先前检测到目标的估计性能。这一步对于 2D-MNOMP 的收敛和精度至关重要。最后，我们用最小二乘法更新振幅。2D-MNOMP 在算法1中进行了总结。值得一提的是，循环细化步骤对于实现 2D-MNOMP 中的高估计精度非常有益。

算法 1 2D-NOMP

输入: $(\mathbf{Y}, \tau)$

- 1: $m \leftarrow 0, P_0 = \{\}$
 - 2: **循环:** $\max_{\omega_x \in \text{DFT}_x, \omega_y \in \text{DFT}_y} G_{\mathbf{Y}_r^{P_m}}(\omega) > \tau$
 - 3: $m \leftarrow m + 1$
 - 4: **确定** $\omega_c = \arg \max_{\omega_x \in \Omega_x, \omega_y \in \Omega_y} G_{\mathbf{Y}_r^{P_{m-1}}}(\omega)$ 与对应的 $\hat{x}(t)$ 估计
 - 5: $\hat{x}(t) = [\mathbf{a}_N^H(\omega_{c,y}) \mathbf{Y}(t) \mathbf{a}_M^*(\omega_{c,x})] / \|\mathbf{a}_N(\omega_{c,x}) \mathbf{a}_M^T(\omega_{c,y})\|_F^2$
 - 6: $P'_m \leftarrow P_{m-1} \cup \{(\{\hat{x}(t)\}_{t=1}^T, \omega_c)\}$
 - 7: **单次精细化** $(\{\hat{x}(t)\}_{t=1}^T, \omega_c)$: 使用单正弦牛顿更新步长 (Rs-Newton 步长) 获得改进的估计 $(\{\hat{x}'(t)\}_{t=1}^T, \hat{\omega}')$
 - 8: $P''_m \leftarrow P_{m-1} \cup \{(\{\hat{x}'(t)\}_{t=1}^T, \hat{\omega}')\}$
 - 9: **循环精细化:** 每次观测精细化参数 P''_m : 对于 $(\{\hat{x}'(t)\}_{t=1}^T, \hat{\omega}') \in P''_m$, 我们将 $\mathbf{Y}_r^{P''_m \setminus \{(\{\hat{x}'(t)\}_{t=1}^T, \hat{\omega}')\}}$ 视为 $\mathbf{Y}$ 。并应用“单次精细化”步骤。我们执行循环精细化。让 P'''_m 表示新的参数集。
 - 10: **更新:** 通过最小二乘 $\mathbf{B} \triangleq [\mathbf{a}_M(\hat{\omega}_{y,1}) \otimes \mathbf{a}_N(\hat{\omega}_{x,1}), \dots, \mathbf{a}_M(\hat{\omega}_{y,m}) \otimes \mathbf{a}_N(\hat{\omega}_{x,m})]$ 与 $[\hat{x}_1(t), \dots, \hat{x}_m(t)]^T = (\mathbf{B}^H \mathbf{B})^{-1} \mathbf{B}^H \text{vec}(\mathbf{Y}(t))$ 更新 $P'''_m = \{(\{\hat{\omega}_{x,l}, \hat{\omega}_{y,l}\}_{l=1}^m)\}$ 中的 $\{x_k(t)\} (t = 1, \dots, T, k = 1, \dots, m)$
 - 11: 让 P_m 表示新的参数集
 - 12: **循环结束:**
 - 13: **输出:** P_m
-

4.1.8 无网格 CS 方法: 快速二维原子范数 2D-MANM

Chi[28] 开创了向量化 ANM 二维频率估计的先河，它将二维频率估计转化为双重 Toeplitz 矩阵 SDP 问题。该方法保留了 ANM 方法在单次快照观测超分辨率和对源相关性鲁棒性方面的优点。但它的计算复杂度很高，当天线阵列尺寸变大时，运算时间是不可接受的。MANM[3] 将双折叠 Toeplitz 矩阵转化为含有一维调和分量的两个 Toeplitz 矩阵，给出了 ANM 的新定义。因此，MANM 形成了一个新的 SDP 问题，大大减小了优化问题的规模，并显著提高了计算效率。

MANM 针对的问题模型为：

$$\mathbf{X} = \sum_{k=0}^K s_k^* \cdot \mathbf{a}_X(f_{x,k}) \cdot \mathbf{a}_Y^T(f_{y,k}) = \mathbf{A}_X \cdot \mathbf{S} \cdot \mathbf{A}_Y^T \quad (4.74)$$

其中

$$\mathbf{a}_X(f_{x,k}) \triangleq [1, e^{-j2\pi \cdot f_{x,k}}, \dots, e^{-j2\pi \cdot (M-1)f_{x,k}}]^T \quad (4.75)$$

$$\mathbf{a}_Y(f_{y,k}) \triangleq [1, e^{-j2\pi \cdot f_{y,k}}, \dots, e^{-j2\pi \cdot (N-1)f_{y,k}}]^T \quad (4.76)$$

$$\mathbf{S} \triangleq \text{diag}(\mathbf{s}^*), \mathbf{s}^* = [s_1^*, s_2^*, \dots, s_K^*]^T \quad (4.77)$$

$$\mathbf{S} \triangleq \text{diag}(\mathbf{s}^*), \mathbf{s}^* = [s_1^*, s_2^*, \dots, s_K^*]^T \quad (4.78)$$

$$\mathbf{A}_X \triangleq [\mathbf{a}_X(f_{x,1}), \mathbf{a}_X(f_{x,2}), \dots, \mathbf{a}_X(f_{x,K})] \quad (4.79)$$

$$\mathbf{A}_Y \triangleq [\mathbf{a}_Y(f_{y,1}), \mathbf{a}_Y(f_{y,2}), \dots, \mathbf{a}_Y(f_{y,K})] \quad (4.80)$$

估计目标为从 (4.74) 中的观测值 $\mathbf{X}$ 中恢复 $\{(f_{x,k}, f_{y,k})\}_{k=1}^K$ 。

在 [28, 29] 中，向量原子范数是通过向量化数据矩阵来定义的，以得到一个大维原子集。设 $\mathbf{x} = \text{vec}(\mathbf{X}) \in \mathbb{C}^{MN \times MN}$ 是矢量化的数据矩阵，则有

$$\begin{aligned} \mathbf{x} &= (\mathbf{A}_Y \otimes \mathbf{A}_X) \cdot \text{vec}(\mathbf{S}) = \sum_{k=1}^K s_k^* \cdot \mathbf{a}_Y(f_{y,k}) \otimes \mathbf{a}_X(f_{x,k}) \\ &= \sum_{k=1}^K \sqrt{MN} s_k^* \cdot \mathbf{c}(\mathbf{f}_k) \end{aligned} \quad (4.81)$$

其中

$$\mathbf{c}(\mathbf{f}_k) \triangleq \mathbf{c}(f_{x,k}, f_{y,k}) = \frac{1}{\sqrt{MN}} \mathbf{a}_X(f_{x,k}) \otimes \mathbf{a}_Y(f_{y,k}) \quad (4.82)$$

原子集 $\mathcal{A}_v$ 定义为所有归一化 2-D 复谐波的集合：

$$\begin{aligned} \mathcal{A}_v &= \{\mathbf{c}(\mathbf{f}) \mid \mathbf{c}(\mathbf{f}) \in \mathbb{C}^{MN}, \mathbf{f} \in [0, 1] \times [0, 1]\} \\ \mathbf{c}(\mathbf{f}) &\triangleq \mathbf{c}(f_x, f_y) = \frac{1}{\sqrt{MN}} \mathbf{a}_X(f_x) \otimes \mathbf{a}_Y(f_y) \end{aligned} \quad (4.83)$$

$\mathbf{x}$ 的原子范数可以计算为

$$\begin{aligned} \|\mathbf{x}\|_{\mathcal{A}_v} &= \inf \left\{ \sum_k |d_k| \mid \mathbf{x} = \sum_k d_k \mathbf{c}(\mathbf{f}_k), \mathbf{c}(\mathbf{f}_k) \in \mathcal{A}_v \right\} \\ &= \min_{\mathbf{U} \in \mathbb{C}_v \in \mathbb{C}} \left\{ \frac{1}{2}v + \frac{1}{2} \text{Tr}(\mathcal{T}_{2D}(\mathbf{U})) \right\} \\ &\quad \text{s.t.} \begin{bmatrix} \mathcal{T}_{2D}(\mathbf{U}) & \mathbf{x} \\ \mathbf{x}^H & v \end{bmatrix} \succeq \mathbf{0} \end{aligned} \quad (4.84)$$

其中, $\mathbf{U} = [u_{(i,k)}]_{M \times N}$ 和 $\mathcal{T}_{2D}(\mathbf{U})$ 是一个双折叠块 Hermite Toeplitz 矩阵, 其定义为

$$\mathcal{T}_{2D}(\mathbf{U}) = \begin{bmatrix} \mathbf{T}_1 & \mathbf{T}_2 & \cdots & \mathbf{T}_M \\ \mathbf{T}_2^* & \mathbf{T}_1 & \cdots & \mathbf{T}_{M-1} \\ \vdots & \vdots & \cdots & \vdots \\ \mathbf{T}_M^* & \mathbf{T}_{M-1}^* & \cdots & \mathbf{T}_1 \end{bmatrix} \quad (4.85)$$

$$\mathbf{T}_l = \begin{bmatrix} u_{(l,1)} & u_{(l,2)} & \cdots & u_{(l,N)} \\ u_{(l,2)}^* & u_{(l,1)} & \cdots & u_{(l,N-1)} \\ \vdots & \vdots & \cdots & \vdots \\ u_{(l,N)}^* & u_{(l,N-1)}^* & \cdots & u_{(l,1)} \end{bmatrix} \quad (4.86)$$

根据信号模型 (4.74), 矩阵原子集定义为由 $\{(f_{x,k}, f_{y,k})\}_k$ 决定的所有矩阵, 即:

$$\mathcal{A}_m \triangleq \{\mathbf{A}_m(\mathbf{f}) \mid \mathbf{f} \in [0, 1] \times [0, 1]\} \quad (4.87)$$

其中

$$\mathbf{A}_m(\mathbf{f}_k) = \mathbf{a}_X(f_{x,k}) \cdot \mathbf{a}_Y^T(f_{y,k}) \quad (f_{x,k}, f_{y,k}) \in [0, 1] \times [0, 1] \quad (4.88)$$

$\mathbf{X}$ 的原子范数可以计算为

$$\|\mathbf{X}\|_{\mathcal{A}_m} = \inf \left\{ \sum_k |s_k| \mid \mathbf{X} = \sum_k s_k \mathbf{A}_m(\mathbf{f}_k), \mathbf{A}_m(\mathbf{f}) \in \mathcal{A}_m \right\}. \quad (4.89)$$

这是与 $\mathcal{A}_m$ 凸包相关的规范函数。矩阵原子范数满足以下等效 SDP 形式, 详细证明见 [3]。

定理 1: 如 $\mathbf{X} \in \mathbb{C}^{M \times N}$, 则矩阵原子范数 $\|\mathbf{X}\|_{\mathcal{A}_m}$ 可以改写为

$$\begin{aligned} \|\mathbf{X}\|_{\mathcal{A}_m} &= \inf_{(\mathbf{u}, \mathbf{v}) \in \mathbb{C}^M \times \mathbb{C}^N} \text{Tr} \left(\frac{1}{2M} \mathcal{T}(\mathbf{u}) + \frac{1}{2N} \mathcal{T}(\mathbf{v}) \right) \\ \text{s.t.} \quad &\begin{bmatrix} \mathcal{T}(\mathbf{u}) & \mathbf{X} \\ \mathbf{X}^H & \mathcal{T}(\mathbf{v}) \end{bmatrix} \succeq \mathbf{0} \end{aligned} \quad (4.90)$$

其中, $\mathcal{T}(\mathbf{u})$ 和 $\mathcal{T}(\mathbf{v})$ 是分别以向量 $\mathbf{u}$ 和 $\mathbf{v}$ 作为第一列的 Hermite Toeplitz 矩阵。

考虑了加性噪声情况下的 2D 问题, 其观测模型如下所示

$$\mathbf{Y} = \mathbf{X} + \mathbf{W} \quad (4.91)$$

其中, $\mathbf{W} = [w_{i,j}]_{M \times N} \in \mathbb{C}^{M \times N}$ 是噪声数据部分, $\mathbf{X}$ 是数据部分。在这种情况下, 矩阵原子范数正则化恢复方法被提出为

$$\hat{\mathbf{X}} = \underset{\mathbf{X}}{\text{argmin}} \frac{1}{2} \|\mathbf{Y} - \mathbf{X}\|_F^2 + \lambda \|\mathbf{X}\|_{\mathcal{A}_m} \quad (4.92)$$

这里， λ 是正正则化参数。很容易看出，(4.92) 等价于寻求以下 SDP 问题

$$\begin{aligned} \underset{(\mathbf{u}, \mathbf{v}, \mathbf{X})}{\operatorname{argmin}} \quad & \frac{1}{2} \|\mathbf{Y} - \mathbf{X}\|_F^2 + \lambda \operatorname{Tr} \left(\frac{1}{2M} \mathcal{T}(\mathbf{u}) + \frac{1}{2N} \mathcal{T}(\mathbf{v}) \right) \\ \text{s.t.} \quad & \begin{bmatrix} \mathcal{T}(\mathbf{u}) & \mathbf{X} \\ \mathbf{X}^H & \mathcal{T}(\mathbf{v}) \end{bmatrix} \succeq \mathbf{0}. \end{aligned} \quad (4.93)$$

通过使用 CVX 工具，可以有效地实现上述算法 [41]。我们可以使用 Vandermonde 分解从 $\mathcal{T}(\mathbf{u}), \mathcal{T}(\mathbf{v})$ 中获得二维频率 $\mathbf{f} = \{(f_{x,i}, f_{y,i})\}_{i=1, \dots, K}$ ，即

$$\begin{cases} \mathcal{T}(\mathbf{u}) = \mathbf{A}_{X(\mathbf{f}_x)} \cdot \mathbf{D}_x \cdot \mathbf{A}_{x(\mathbf{f}_x)}^T, & \mathbf{D}_x \succ \mathbf{0} \\ \mathcal{T}(\mathbf{v}) = \mathbf{A}_{Y(\mathbf{f}_y)} \cdot \mathbf{D}_y \cdot \mathbf{A}_{Y(\mathbf{f}_y)}^T, & \mathbf{D}_y \succ \mathbf{0}. \end{cases} \quad (4.94)$$

通过求解 (4.93) 中的 SDP，可以通过对其一级 Toeplitz 矩阵进行 Vandermonde 分解来获得 2D 谐波信息，然后通过最大相关法将谐波分量配对成 K 对，如下所示：

$$j_i = \underset{j}{\operatorname{argmax}} \left| \mathbf{a}_{X(f_{x,i})}^H \cdot \hat{\mathbf{X}} \cdot \mathbf{a}_{Y(f_{y,j})}^* \right|. \quad (4.95)$$

其中， j_i 表示与 $f_{x,i}$ 匹配的 $\mathbf{f}_y$ 的频率指数， $\hat{\mathbf{x}}$ 表示恢复的数据矩阵。

4.1.9 问题一定位结果

在模型阶数估计方面，我们对各类算法的在不同阶数的残差通过 AIC, BIC, GIC 准则进行模型阶数估计。在问题一数据上的估计结果如表4.4所示。

表 4.4 问题一模型阶数估计结果

算法	AIC	BIC	GIC($\nu = 6$)
MDVALUE	2	2	2
2DNOMP	2	2	2
MDSLSE	2	2	2
ANM	2	2	2

在表4.4中, 可以清晰的看到, 问题一的模型阶数为 2。各类算法计算的物体相对位置具体数值在表4.5中, 角度单位为弧度, 距离单位为米。各类算法计算的物体相对位置如图4.5到图4.8所示。

从图4.5到图4.8中我们可以清晰的看出, 问题一的两个点距离相同, 角度相差很小。事实上, 从二维 FFT 的频谱图4.9中, 是无法分辨两个点的。因此只能估计一个物体的位置, 而我们提出的各类算法都可以分辨两个物体并且精确估计位置, 其中, 我们倾向于选择 MDVALUE 的估计结果作为正确结果。这是由于其他三个算法的估计结果中角度距离很远,

表 4.5 问题一物体相对位置估计结果

算法	估计点 1 距离	估计点 1 角度	估计点 2 距离	估计点 2 角度
MDValse	7.0049	0.0070	7.0049	-0.0024
2DNOMP	7.0054	0.0249	7.0051	-0.0141
MDSLSE	7.0048	0.0133	7.0051	-0.0112
ANM	7.0048	0.0241	7.0048	-0.0206




图 4.5 变分贝叶斯线谱估计 MDValse 问题一估计结果




图 4.6 2DNOMP 问题一估计结果




图 4.7 MDSLSE 问题一估计结果




图 4.8 二维原子范数问题一估计结果

这可能是由于算法的分辨率不足造成的。且从理论角度来讲，MDLSE 的估计是同时进行两个点的估计，其他几类算法在估计时往往是通过迭代估计策略（如 NOMP）。先估计一个物体，在固定物体后在估计其他物体的位置，不断迭代得到最终结果。因此不可避免的会造成两个物体信号相互混叠的情况，尤其是在物体距离较近时。根据以上分析，我们得出最终的问题一物体估计结果为 (7.0049,0.0070) 与 (7.0049,-0.0024)。




图 4.9 问题一二维 FFT 结果




图 4.10 二维 FFT 问题一估计结果

4.2 问题二分析与求解

在问题二中，我们承接4.1.5中算法选型相关分析，进行具有噪声与模型阶数估计的 MDVLSE 与 MDSLSE 算法的推导。并对几类算法的估计结果进行分析。

4.2.1 贝叶斯方法：多维变分贝叶斯线谱估计 MDVLSE

VALSE 算法通过将频率作为随机变量来使用完整的贝叶斯处理 [37]。除了权重的不确定性外，这种方法自然允许频率估计与权重的不确定性。从数值上讲，考虑频率与权重不确定性有利于线谱估计性能。此外，VALSE 自动估计模型阶数、噪声方差。下面我们讲解多维变分线谱估计 MDVLSE 方法 [1]。

考虑 D 维 LSE 问题的测量模型，表示为其中 $\mathbf{X} \in \mathbb{C}^{M_1 \times \dots \times M_D}$ 是由 K 个复正弦组成的无噪声线谱

$$\mathbf{X} = \sum_{k=1}^K w_k \mathbf{A}(\boldsymbol{\theta}_k) \quad (4.96)$$

$$\mathbf{Y} = \mathbf{X} + \mathbf{N} \quad (4.97)$$

$\mathbf{N}$ 是加性高斯白噪声 (AWGN)，即 $\mathbf{N}_{\mathcal{M}} \sim \mathcal{CN}(\mathbf{N}_{\mathcal{M}}; 0, \nu)$ ，其中 $\mathcal{M} = (m_1, \dots, m_D)$ 。 w_k 表示第 k 个频率的复振幅 $\mathbf{A}(\boldsymbol{\theta}_k) \in \mathbb{C}^{M_1 \times \dots \times M_D}$ 和 $\mathcal{M}$ 元素是 $\prod_{d=1}^D e^{j(m_d-1)\theta_{k,d}}$ ，其中 $\theta_{k,d} \in [-\pi, \pi]$ 是 $\boldsymbol{\theta}_k$ 的第 d 个元素。为了简单起见，我们定义了 $a(\mathcal{M}, \boldsymbol{\theta}_k) = \prod_{d=1}^D e^{j(m_d-1)\theta_{k,d}}$ 与 $\boldsymbol{\theta} = [\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K]$ 。由于谱 K 的数量未知，因此采用了过完备模型，其中谱的数量假定为 N 且 $N > K$ 。因此，引入二进制隐变量 $\mathbf{s} = [s_1, \dots, s_N]^T$ 来表征第 i 个分量是否有效。概率质量函数 $p(\mathbf{s}; \rho) = \prod_{k=1}^N p(s_k; \rho)$ ，其中 $s_k \in \{0, 1\}$ 和

$$p(s_k; \rho) = \rho^{s_k} (1 - \rho)^{(1-s_k)} \quad (4.98)$$

此外， $p(\mathbf{w} | \mathbf{s}; \tau) = \prod_{k=1}^N p(w_k | s_k; \tau)$ ，其中 $p(w_k | s_k; \tau)$ 服从伯努利-高斯分布

$$p(w_k | s_k; \tau) = (1 - s_k) \delta(w_k) + s_k \mathcal{CN}(w_k; 0, \tau) \quad (4.99)$$

其中 $\delta(\cdot)$ 是 Dirac-delta 函数。 ρ 控制了第 k 个频率处于活动状态的概率。此外，第 k 个频率使用无信息先验分布，即 $p(\boldsymbol{\theta}_k) = (1/(2\pi))^D$ 。对于测量模型 (4.96)，似然函数 $p(\mathbf{Y} | \mathbf{X}; \nu)$ 为

$$p(\mathbf{Y} | \mathbf{X}; \nu) = \prod_{\mathcal{M}} \mathcal{CN}(Y_{\mathcal{M}}; X_{\mathcal{M}}, \nu) \quad (4.100)$$

设 $\boldsymbol{\beta} = \{\nu, \rho, \tau\}$ 和 $\boldsymbol{\Phi} = \{\boldsymbol{\theta}, \mathbf{w}, \mathbf{s}\}$ 为模型和估计参数。一般来说，首先应通过边缘化 $\boldsymbol{\Phi}$ 的后验概率密度函数，找到 $\boldsymbol{\beta}$ 的最大似然估计，然后找到 $\boldsymbol{\Phi}$ 的最大后验或最小均方误差估计。

变分法试图通过最小化 $q(\boldsymbol{\Phi} | \mathbf{Y})$ 和 $p(\boldsymbol{\Phi} | \mathbf{Y})$ 之间的 Kullback-Leibler (KL) 散度来寻找等价概率密度函数 $q(\boldsymbol{\Phi} | \mathbf{Y})$ ，这等价于最大化

$$\mathcal{L}(q(\boldsymbol{\Phi} | \mathbf{Y}); \boldsymbol{\beta}) = \mathbb{E}_{q(\boldsymbol{\Phi} | \mathbf{Y})} \left[\ln \frac{p(\mathbf{Y}, \boldsymbol{\Phi}; \boldsymbol{\beta})}{q(\boldsymbol{\Phi} | \mathbf{Y})} \right] \quad (4.101)$$

其中

$$p(\boldsymbol{\Phi} | \mathbf{Y}) \propto p(\mathbf{Y} | \mathbf{X}) \prod_{k=1}^N (p(\boldsymbol{\theta}_k) p(w_k | s_k) p(s_k)) \quad (4.102)$$

是变量的后验概率密度函数。

与 [37] 类似， $q(\boldsymbol{\Phi} | \mathbf{Y})$ 的结构如下

$$q(\boldsymbol{\Phi} | \mathbf{Y}) = \prod_{k=1}^N q(\boldsymbol{\theta}_k | \mathbf{Y}) q(\mathbf{w} | \mathbf{Y}, \mathbf{s}) q(\mathbf{s} | \mathbf{Y}) \quad (4.103)$$

其中 $q(\mathbf{s} | \mathbf{Y}) = \delta(\mathbf{s} - \hat{\mathbf{s}})$ 。

最大化 $\mathcal{L}(q(\boldsymbol{\Phi} | \mathbf{Y}))$ 是很困难的。设 $\mathbf{z} = [\boldsymbol{\theta}_1; \dots, \boldsymbol{\theta}_N; \mathbf{w}; \mathbf{s}]$ 是所有潜在变量的向量， $\mathbf{z}_1 = \boldsymbol{\theta}_1, \dots, \mathbf{z}_N = \boldsymbol{\theta}_N, \mathbf{z}_{N+1} = [\mathbf{w}; \mathbf{s}]$ 。根据 Gauss-Seidel 方法，我们将 $\mathcal{L}(q(\boldsymbol{\Phi} | \mathbf{Y}); \boldsymbol{\beta})$ 关于后验近似 $q(\mathbf{z}_n | \mathbf{Y})$, $n \in \{1, \dots, N+1\}$ ，其他变量是固定的。 $q(\mathbf{z}_n | \mathbf{Y})$ 为

$$\ln q(\mathbf{z}_n | \mathbf{Y}) = \mathbb{E}_{q(\mathbf{z} \setminus \mathbf{z}_n | \mathbf{Y})} [\ln p(\mathbf{Y}, \mathbf{z})] + \text{const} \quad (4.104)$$

其中，期望值与除 $\mathbf{z}_n$ 以外的所有变量 $\mathbf{z}$ 有关，常数确保概率密度函数的标准化。

由于 (4.103) 的因式分解性质，频率 θ_k 和 $a(\mathcal{M}, \boldsymbol{\theta}_k)$, $k \in \{1, \dots, N\}$ 可以从边缘分布 $q(\boldsymbol{\theta}_k | \mathbf{Y})$ 估算为

$$\hat{\theta}_{k,d} = \arg \left(\mathbb{E}_{q(\boldsymbol{\theta}_k | \mathbf{Y})} [e^{j\theta_{k,d}}] \right), \quad d \in \{1, \dots, D\} \quad (4.105)$$

$$\hat{a}_{\mathcal{M}, \boldsymbol{\theta}_k} = \mathbb{E}_{q(\boldsymbol{\theta}_k | \mathbf{Y})} [a(\mathcal{M}, \boldsymbol{\theta}_k)], \quad \forall \mathcal{M} \quad (4.106)$$

其中， $\arg(\cdot)$ 返回角度。

假设 $q(\mathbf{s} | \mathbf{Y}) = \delta(\mathbf{s} - \hat{\mathbf{s}})$ ， $\mathbf{w}$ 的后验概率密度为

$$q(\mathbf{w} | \mathbf{Y}) = \int q(\mathbf{w} | \mathbf{Y}, \mathbf{s}) \delta(\mathbf{s} - \hat{\mathbf{s}}) d\mathbf{s} = q(\mathbf{w} | \mathbf{Y}; \hat{\mathbf{s}}) \quad (4.107)$$

对于给定的后验概率密度函数 $q(\mathbf{w} | \mathbf{Y})$ ，权重的平均值和协方差估计为

$$\hat{\mathbf{w}} = E_{q(\mathbf{w}|\mathbf{Y})}[\mathbf{w}] \quad (4.108)$$

$$\hat{\mathbf{C}} = E_{q(\mathbf{w}|\mathbf{Y})}[\mathbf{w}\mathbf{w}^H] - \hat{\mathbf{w}}\hat{\mathbf{w}}^H \quad (4.109)$$

其中 $(\cdot)^H$ 表示厄米转置算子。设 $\mathcal{S}$ 是 s 的非零分量的标号集，即 $\mathcal{S} = \{k | 1 \leq k \leq N, s_k = 1\}$ 。让 $\hat{\mathbf{S}}$ 为是 $\mathbf{S}$ 的估计值，模型顺序估计为 $\hat{K} = |\hat{\mathcal{S}}|$ 。无噪声信号被重构为 $\hat{\mathbf{X}} = \sum_{k \in \mathcal{S}} \hat{w}_k \hat{\mathbf{A}}_k$ ，的其中第 $\mathcal{M}$ 个元素 $\hat{\mathbf{A}}_k$ ， $\hat{a}_{\mathcal{M}}, \theta_k$ 。

4.2.2 贝叶斯方法：超快速线谱估计的多维拓展

超快速 LSE 算法用于解决完整测量矢量可用的场景（完整数据案例）中的 LSE 问题。主要新颖之处在于超快速 LSE 的计算方面。SLSE 方法基于几种技术：超快速 Toeplitz 反演算法 [42, 43]、低复杂度 Capon 波束形成 [44]、Gohberg-Semencul 公式 [45] 和非均匀快速傅里叶变换 [46]。超快速 LSE 算法具有以下优点：它固有地估计所有模型参数，例如噪声方差和模型阶数，并且每次迭代的计算复杂度较低。经验表明，它在几次迭代（通常少于 20 次）后收敛。这意味着，对于较大的问题规模，我们的算法的计算时间可以低于当前方法的数量级。这样做不会对估计精度造成任何损失。由于 SLSE 使用了多类数值快速算法，我们简单推导算法的概率模型，具体的算法详见 [4]。

我们现在详细介绍观察模型和 LSE 问题的具体目标。观测向量 $\mathbf{y} \in \mathbb{C}^M$ 包含时域样本，由下式给出

$$\mathbf{y} = \sum_{k=1}^K \Phi \psi(\tilde{\theta}_k) \tilde{\alpha}_k + \mathbf{w} = \Phi \Psi(\tilde{\boldsymbol{\theta}}) \tilde{\boldsymbol{\alpha}} + \mathbf{w} \quad (4.110)$$

其中，转向矢量函数 $\psi(\theta_k) : [0, 1) \rightarrow \mathbb{C}^{N \times 1}$ 给出了一个傅里叶向量，即它第 n 项 $[\psi(\theta_k)]_n \triangleq \exp(j2\pi(n-1)\theta_k)$ for $n = 1, \dots, N$ 。我们还定义了 $\Psi(\boldsymbol{\theta}) \triangleq [\psi(\theta_1) \cdots \psi(\theta_{\dim(\boldsymbol{\theta})})]$ 。测量矩阵 $\Phi \in \mathbb{C}^{M \times N'}$ 是单位矩阵。矢量 $\mathbf{w}$ 是具有分量方差 β 的高斯白噪声矢量。LSE 问题是恢复模型阶数 K 以及频率 $\tilde{\theta}_k \in [0, 1]$ 和系数 $\tilde{\alpha}_k \in \mathbb{C}$ ， $k = 1, \dots, K$ 。

算法基于近似于 (4.110) 的估计模型中的贝叶斯推断。基于 (4.110)，估计模型为

$$\mathbf{y} = \sum_{k=1}^{K_{\max}} \Phi \psi(\theta_k) z_k \alpha_k + \mathbf{w} = \mathbf{A}(\boldsymbol{\theta}_z) \boldsymbol{\alpha}_z + \mathbf{w} \quad (4.111)$$

其中 $\theta_k \in [0, 1)$ 和 $\alpha_k \in \mathbb{C}$ ， $k = 1, \dots, K_{\max}$ 是频率和系数，我们定义了 $\mathbf{A}(\boldsymbol{\theta}) \triangleq \Phi \Psi(\boldsymbol{\theta})$ 。

由于高斯噪声假设，我们有

$$p(\mathbf{y} | \boldsymbol{\alpha}, \mathbf{z}, \boldsymbol{\theta}; \beta) = \text{CN}(\mathbf{y}; \mathbf{A}(\boldsymbol{\theta}_z) \boldsymbol{\alpha}_z, \beta \mathbf{I}) \quad (4.112)$$

其中， $\text{CN}(\mathbf{y}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ 表示均值为 $\boldsymbol{\mu}$ ，协方差矩阵为 $\boldsymbol{\Sigma}$ 的圆对称复正态随机变量 $\mathbf{y}$ 的概率密度函数。我们假设 $\beta \in [\varepsilon_\beta, \infty)$ ，其中 $\varepsilon_\beta > 0$ 是一个任意小的常数，保证似然函数在以下有

界。伯努利先验用于促进某些频率的失活:

$$p(\mathbf{z}; \zeta) = \prod_{k=1}^{K_{\max}} \zeta^{z_k} (1 - \zeta)^{1-z_k} \quad (4.113)$$

式中 $\zeta \in [0, 1/2]$ 是激活概率。限制 $\zeta \leq 1/2$ 确保先验是稀疏的。假设系数为独立的零均值高斯

$$p(\boldsymbol{\alpha}; \boldsymbol{\gamma}) = \prod_{k=1}^{K_{\max}} \text{CN}(\alpha_k; 0, \gamma_k) \quad (4.114)$$

其中, $\gamma_k \in [0, \infty)$ 为有效分量方差。稀疏促进先验先前已用于基选择 [32] 和 LSE[36]。我们上面采用的伯努利-高斯先验结构在 [47] 中首次引入, 并在 [37] 中用于 LSE。

我们最后对 θ 中的项使用独立同分布一致先验:

$$p(\boldsymbol{\theta}) = \prod_{k=1}^{K_{\max}} p(\theta_k) = \prod_{k=1}^{K_{\max}} 1 = 1. \quad (4.115)$$

如果关于频率的进一步先验信息可用, 则可以通过 $p(\boldsymbol{\theta})$ 轻松合并

最后, 我们需要注意, SLSE 算法进行的是频率的一维估计, 可以使用类似 (4.95) 的方法进行二维频率配对。

4.2.3 问题二定位结果

在模型阶数估计方面, 我们对各类算法的在不同阶数的残差通过 AIC, BIC, GIC 准则进行模型阶数估计。在问题二数据上的估计结果如表4.6所示。

表 4.6 问题二模型阶数估计结果

算法	AIC	BIC	GIC($\nu = 6$)
MDValse	2	2	2
2DNOMP	2	2	2
MDSLSE	2	2	2
ANM	2	2	2

在表4.6中, 可以清晰的看到, 问题二的模型阶数为 2。各类算法计算的物体相对位置具体数值在表4.7中, 角度单位为弧度, 距离单位为米。各类算法计算的物体相对位置如图4.11到图4.14所示。

从图4.11到图4.14可以看到两个距离估计相同, 角度估计不同的物体。从二维 FFT 图4.15中, 可以依稀看到两个分离不清晰的峰。这从侧面佐证了算法的正确性。注意到问题二中两个峰的间隔是要大于问题一的, 2D-NOMP 算法与 ANM 算法并没有很明显的

表 4.7 问题二物体相对位置估计结果

算法	估计点 1 距离	估计点 1 角度	估计点 2 距离	估计点 2 角度
MDVASE	8.2058	0.0115	8.2058	-0.0099
2DNOMP	8.2064	0.0339	8.2058	-0.0234
MDSLSE	8.2058	0.0133	8.2058	-0.0121
ANM	8.2076	0.0241	8.2076	-0.0206




图 4.11 变分贝叶斯线谱估计 MDVASE 问题二估计结果




图 4.12 2DNOMP 问题二估计结果




图 4.13 MDSLSE 问题二估计结果




图 4.14 二维原子范数问题二估计结果

体现这一点，MDSLSE 算法甚至出现了间隔变小的情况，与数据不符。因此 MDVASE 的估计结果是可信的，问题二最终的物体估计结果为 (8.2058,0.0115) 与 (8.2058,-0.0099)。MDVASE 噪声方差估计为 2.12，MDSLSE 噪声方差估计为 1.85。




图 4.15 问题二二维 FFT 结果




图 4.16 二维 FFT 问题二估计结果

4.3 问题三分析与求解

本问题要求依据线性天线阵列所获得的一帧中频信号，来估计多个运动物体的轨迹。在移动场景中，雷达获得一帧 (N_f 个 chirp 周期) 中频信号组 $\{Z_q, q = 0, \dots, N_f - 1\}$ 。这里对于任意给定的 q ，中频信号 $Z_q = \left\{ z_n(t), n = 0, \dots, N_a - 1, t = 0, \dots, \left\lfloor \frac{T}{T_s} \right\rfloor - 1 \right\}$ 表示第 q 个 chirp 周期内采集的信号，由于 chirp 周期 (50 微秒) 内时间极短，可认为此周期内物体静止不变。在一帧时间内，物体的相对位置有明显的移动。本问题解决核心思路如下：

- (1) 依据高分辨率定位算法分析一帧中频信号所蕴含的多个 chirp 周期中天线阵列接收信号以完成单个 chirp 周期内的定标
- (2) 根据数据关联算法，分析各个 chirp 周期之间定标位置的关联关系以确定各个待测运动物体的大致运动轨迹
- (3) 根据自适应滤波算法，削弱雷达定位的不确定性以确定待测运动物体的真实运动轨迹

4.3.1 数据关联算法

依据问题所提出的实际背景，假如待测物体之间的间距较为紧密，我们需要数据关联算法进行目标追踪以保证之后物体运动轨迹分析的正确性。设在一个密集环境中（环境中多个目标紧邻）对 N 个目标进行跟踪，该任务具有以下特征：

- (1) 每一个传感器的观测结果以一定的时间间隔传输至融合节点；
- (2) 传感器可能在特定的时间间隔内没有观测结果输出（目标处于盲区或噪声掩盖）；
- (3) 系统是因果的，因此对于任意目标，在每一个时间间隔内，不能预先获知传感器的输出结果；

现在针对不同多目标运动目标检测场景有多种相应算法进行目标跟踪，包括近邻算法，概率数据关联算法，多重假设检验，图形算法等。其中，近邻算法计算复杂低实时性较好，但是难以分清较为接近或是交叉的轨迹。考虑到实际问题场景，我们选择近邻算法

作为数据关联算法以加强整体算法的实时性。此外，我们发现本问题中路径具有角度相反性，可以根据该性质简单的实现较好的数据关联。如果实际中遇到复杂数据关联问题，则可以使用概率数据关联算法等方法得到更好的效果。

4.3.2 后端优化方法

本问题中，针对待测运动物体的运动轨迹特性（语义特性）选择了以下后端数据优化方法以进行轨迹自适应滤波与拟合：

(1) 拓展卡尔曼滤波：扩展卡尔曼滤波（Extended Kalman Filter, EKF）是标准卡尔曼滤波在非线性情形下的一种扩展形式，EKF 算法是将非线性函数进行泰勒展开，省略高阶项，保留展开项的一阶项，以此来实现非线性函数线性化，最后通过卡尔曼滤波算法近似计算系统的状态估计值和方差估计值，对信号进行滤波。线性问题一般存在于预测和观测过程，分别对这两部分求雅可比矩阵，作为卡尔曼滤波中的预测矩阵和观测矩阵。

首先定义状态转换方程和观测方程：

$$\begin{aligned} x'_k &= f(x_{k-1}) + u_k \\ z_k &= h(x'_k) + y \end{aligned} \quad (4.116)$$

这里 x_k 代表 k 时刻的状态， z_k 则是观测值， u_k 为预测处理过程中的噪声， f 与 h 分别代表了状态转移函数与观测函数。在已知状态转移函数的前提下，就可以得到表示系统不确定度的状态协方差矩阵 P ：

$$P'_k = F P_{k-1} F^T + Q \quad (4.117)$$

其中， Q 表示过程噪声， P 矩阵需要在算法运行之前进行初始化，而 Q 则需要根据具体问题赋值。在转台观测阶段中， y 表示观测值与预测值之间的误差，因此可以得到状态最优估计值如下：

$$x_k = x'_k + K y \quad (4.118)$$

其中，增益 K 可以通过以下公式获得：

$$\begin{aligned} K_k &= P_k H^T S_k^{-1} \\ S_k &= H P_k H^T + R \end{aligned} \quad (4.119)$$

至此，拓展卡尔曼滤波最为关键的部分便是推算观测转移矩阵 H 。在非线形系统中， $h(x_k)$ 往往是一个非线性响应函数。为了获得线性的观测转移矩阵，我们需要将非线性转移函数线性化。非线性函数可以在 (x_0, y_0) 按照泰勒级数展开：

$$h(x) = h(x_0) + \frac{\dot{h}(x_0)}{1!} (x - x_0) + \frac{\ddot{h}(x_0)}{2!} (x - x_0)^2 + \dots \quad (4.120)$$

如果非线性函数是多维的，就要求各个偏量的偏导数，即多维函数的雅克比矩阵：

$$H_j = \begin{bmatrix} \frac{\nabla h_1}{\nabla x_1} & \frac{\nabla h_1}{\nabla x_2} & \cdots & \frac{\nabla h_1}{\nabla x_n} \\ \frac{\nabla h_2}{\nabla x_1} & \frac{\nabla h_2}{\nabla x_2} & \cdots & \frac{\nabla h_2}{\nabla x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\nabla h_n}{\nabla x_1} & \frac{\nabla h_n}{\nabla x_2} & \cdots & \frac{\nabla h_n}{\nabla x_n} \end{bmatrix} \quad (4.121)$$

拓展卡尔曼滤波即将多维函数的雅克比矩阵作为该拓展卡尔曼滤波的观测矩阵。拓展卡尔曼滤波扩展卡尔曼（EKF）与经典卡尔曼（KF）的区别在于测量矩阵 H 的计算。EKF 对非线性函数进行泰勒展开后，进行一阶线性化的截断，忽略了其余高阶项，进而完成非线性函数的近似线性化。

(2) 多项式拟合：

假设有一个实值变量 t ，现有 m 个对变量 t 的观测值，

$$\{(x_1, y_1) (x_2, y_2) \dots (x_m, y_m)\} \quad (4.122)$$

多项式拟合算法将对这些所观测到的样本点进行 n 次多项式的拟合。首先，多项式拟合算法将会假设 t 与自变量 x 中存在着 n 次多项式的联系

$$\hat{y} = a_0 x^n + a_1 x^{n-1} + a_2 x^{n-2} + \dots + a_{n-1} x + a_n \quad (4.123)$$

之后，将所观测到的样本值代入多项式中评估预测值与样本值之间的误差。依据总样本点数误差最小的原则，完成对于多项式系数的搜索。在本问题中，最佳系数的搜索方案为最小二乘算法。

4.3.3 问题三定位结果

在本问中，我们将依据二维 FFT、2D-NOMP、MDValse 这三种基本超分辨率定位算法以及 EKF、多项式拟合算法完成对于待测运动物体轨迹的测定，数据关联以及滤波优化。本题一共提供一帧中频信号（内含 32 个 chirp 周期），以完成这段时间内的运动物体测定。不同算法方案测定结果如图 4.17 到 4.28 所示。各图中，散点表示定位算法在各个 chirp 周期中所测定的具体位置；不同点颜色则是代表了多个待测物体；直线则是根据测定出的各个 chirp 周期的位置依据滤波算法或拟合算法估计出的物体运动轨迹。可以从图中看出，二维 FFT 算法由于自身角度以及距离测定分辨率的限制，难以测定运动物体的微小位移，导致位置点离散，难以提取轨迹有效信息。三种定位算法中，MDValse 所测定的离散位置与其拟合的运动轨迹残差最小，可以有效实现超分辨率的运动轨迹测定。因此，我们将依据 MDValse+EKF 的拟合运动轨迹作为该问题最优解：本小题中共有两个待测物体，其运动轨迹近乎一条直线，在以距离为横坐标，角度为纵坐标的坐标图中物体一从 (6.0043, 0.01507) 运动到 (6.4889, 0.26596)，轨迹函数为 $\theta_1 = 0.4846r_1 - 2.7572$ 。物体二从




图 4.17 二维傅里叶变换 + EKF 滤波问题三估计结果




图 4.18 二维傅里叶变换 + 一阶多项式拟合问题三估计结果




图 4.19 二维傅里叶变换 + 三阶多项式拟合问题三估计结果




图 4.20 二维傅里叶变换 + 五阶多项式拟合问题三估计结果




图 4.21 2D-NOMP + EKF 滤波问题三估计结果




图 4.22 2D-NOMP + 一阶多项式拟合问题三估计结果




图 4.23 2D-NOMP+ 三阶阶多项式拟合问题三估计结果




图 4.24 2D-NOMP+ 五阶多项式拟合问题三估计结果




图 4.25 MDValse+EKF 滤波问题三估计结果




图 4.26 MDValse+ 一阶多项式拟合问题三估计结果




图 4.27 MDValse+ 三阶多项式拟合问题三估计结果




图 4.28 MDValse+ 五阶多项式拟合问题三估计结果

(6.0042,-0.01616) 运动到 (5.5195,-0.26585), 轨迹函数为 $\theta_2 = 0.51500r_2 - 3.108402$ 。计算复杂度分析: 以题目所提供的一帧中频信号为基准 (32*86*256 个复数信号), 从载入用例数据开始, 二维 FFT, 2D-NOMA, MDValse 分别需要 1.67s, 7.45s, 10.21s 输出估计运动轨迹。和 2D-NOMP 相比, MDValse 可以在同样复杂度量级下取得优秀得多的性能表现。且根据表4.3MDValse 的理论复杂度最低。

4.4 问题四分析与求解

随着时间的变化, 天线阵列会受到风力变形、重力变形、阵列安装的误差等引起的阵元位置误差的校正问题。目前校正技术大致分两类有源校正和自校正。在问题四中, 初始未知源的真实位置, 因此是一个未知源校正问题。许多自校准方法基于优化成本函数以联合估计未知阵列和源参数 (例如阵列传感器和源的位置)。在本问题中, 我们选择了 MUSIC 成本函数以及 MATLAB 中的 fmincon 优化算法估计结构误差并校正观测信号, 结合 MDValse 算法来实现鲁棒估计。

4.4.1 带有阵列结构误差的鲁棒估计问题与算法

首先我们将阵列结构误差进行建模。考虑均匀线性天线阵列, 包含阵列结构误差的接收信号 [10, 11] 为:

$$\mathbf{X}(t) = \mathbf{G}\mathbf{A}\mathbf{s}(t) + \mathbf{G}\mathbf{N}(t) \quad (4.124)$$

其中 $\mathbf{X}(t)$ 为阵列接收数据向量; $\mathbf{A}$ 为理想阵列响应矩阵, $\mathbf{A} = [\mathbf{a}(\theta_1), \mathbf{a}(\theta_2), \dots, \mathbf{a}(\theta_N)]$, $\mathbf{a}(\theta_i)$ 为对应于入射角 θ_i 的导向矢量; $\mathbf{S}(t)$ 为入射信号向量; $\mathcal{N}(0, \sigma_n^2)$ 为空间时间平稳的噪声向量, 满足 $\mathcal{N}(0, \sigma_n^2)$ 分布, σ_n^2 为噪声平均功率。 $\mathbf{G}$ 为阵列通道误差扰动矩阵, 即如下的复增益扰动矩阵, 主要包含通道增益误差和相位误差。

$$\mathbf{G} = \text{diag} [g_1 e^{j\varphi_1}, g_2 e^{j\varphi_2}, \dots, g_M e^{j\varphi_M}] \quad (4.125)$$

其中 g_i 为增益误差, φ_i 为相位误差。阵列接收的协方差矩阵为:

$$\begin{aligned} \mathbf{R}_X &= \mathbf{G}\mathbf{A}\mathbf{R}_S\mathbf{A}^H\mathbf{G}^H + \mathbf{G}\sigma_n^2\mathbf{I}\mathbf{G}^H \\ &= \mathbf{G}\mathbf{A}\mathbf{R}_S\mathbf{A}^H\mathbf{G}^H + \sigma_n^2\mathbf{\Sigma} \end{aligned} \quad (4.126)$$

为分析简便, 假设 $\mathbf{\Sigma} = \mathbf{I}$ 。

由经典 MUSIC 算法 [48], 式4.125描述的阵列模型的零谱函数可以写成

$$D(\theta) = \mathbf{a}^H(\theta)\mathbf{G}^H\mathbf{U}_N\mathbf{U}_N^H\mathbf{G}\mathbf{a}(\theta) \quad (4.127)$$

其中 $\mathbf{U}_N$ 为由小特征值对应的特征向量构成的噪声子空间。信源角度和阵列误差参数的联合估计问题, 即角度 θ 与 $\mathbf{G}$ 的联合优化问题:

$$\{\hat{\mathbf{G}}, \hat{\theta}\} = \arg \min_{\mathbf{G}, \theta} \sum_{i=1}^K \mathbf{a}^H(\theta_i) \mathbf{G}^H \mathbf{U}_N \mathbf{U}_N^H \mathbf{G} \mathbf{a}(\theta_i) \quad (4.128)$$

定义代价函数：

$$J = \sum_{i=1}^K \mathbf{a}^H(\theta_i) \mathbf{G}^H \mathbf{U}_N \mathbf{U}_N^H \mathbf{G} \mathbf{a}(\theta_i) \quad (4.129)$$

令 $\mathbf{\Gamma}_a(\theta_i) = \text{diag}[a_1(\theta_i), a_2(\theta_i), \dots, a_M(\theta_i)]$, $\boldsymbol{\delta} = [g_1 e^{j\varphi_1}, g_2 e^{j\varphi_2}, \dots, g_M e^{j\varphi_M}]^T = \mathbf{G} \mathbf{1}$ 其中 $\mathbf{1} = [1, 1, \dots, 1]^T$, 则式 (4.129) 可以改写成

$$\begin{aligned} J &= \boldsymbol{\delta}^H \left\{ \sum_{i=1}^K \mathbf{\Gamma}_a^H(\theta_i) \mathbf{U}_N \mathbf{U}_N^H \mathbf{\Gamma}_a(\theta_i) \right\} \boldsymbol{\delta} \\ &= \boldsymbol{\delta}^H \mathbf{Q} \boldsymbol{\delta} \end{aligned} \quad (4.130)$$

其中

$$\mathbf{Q} = \sum_{i=1}^K \mathbf{T}_a^H(\theta_i) \mathbf{U}_N \mathbf{U}_N^H \mathbf{\Gamma}_a(\theta_i) \quad (4.131)$$

借鉴 MATLAB 例程 SelfCalibrationExample, 使用 fmincon 优化算法对目标函数 (4.130) 进行优化, 即可得到结构误差 $\mathbf{G}$ 。使用结构误差 $\mathbf{G}$ 可以计算去除结构误差的纯净接收信号, 实现鲁棒估计。进一步, 使用 $\mathbf{G}$ 可以反算出天线阵列的真实位置, 即图4.29与图4.30所示。值得注意的是, 计算结果显示天线阵列只具有二维误差, Z 轴没有误差。




图 4.29 雷达天线阵列校正结果图




图 4.30 雷达天线阵列校正结果局部放大图

4.4.2 问题四定位结果

注意，本节提到的算法都是已经经过 MUSIC+fmincon 优化算法校正过的数据中进行估计。在模型阶数估计方面，我们对各类算法的在不同阶数的残差通过 AIC, BIC, GIC 准则进行模型阶数估计。在问题四数据上的估计结果如表4.8所示。

表 4.8 问题四模型阶数估计结果

算法	AIC	BIC	GIC($\nu = 6$)
MDValse	2	2	2
2DNOMP	2	2	2
MDSLSE	2	2	2
ANM	2	2	2

在表4.8中,可以清晰的看到,问题四的模型阶数为 2。各类算法计算的物体相对位置具体数值在表4.9中,角度单位为弧度,距离单位为米。我们得出最终的问题四物体估计结果为 (6.00424,-0.00527) 与 (6.10429,0.00528)。各类算法计算的物体相对位置如图4.31到图4.34所示。

表 4.9 问题四物体相对位置估计结果

算法	估计点 1 距离	估计点 1 角度	估计点 2 距离	估计点 2 角度
MDValse	6.00424	-0.00527	6.10429	0.00528
2DNOMP	6.00759	-0.0003	6.10967	0.01046
MDSLSE	6.0041	-0.0292	6.1044	0.0398
ANM	6.0088	-0.00572	6.1088	0.0039




图 4.31 变分贝叶斯线谱估计 MDValse 问题四估计结果




图 4.32 2DNOMP 问题四估计结果




图 4.33 MDSLSE 问题四估计结果




图 4.34 二维原子范数问题四估计结果

在问题四中，由于算法良好的抗噪声能力。结构误差对估计精度影响较小，但不可否认的是修正结构误差对于正确估计物体有很大帮助。

4.5 低复杂度高精度线谱估计算法选择：多维变分贝叶斯线谱估计 MDValse 优越性分析

从理论角度分析，MDValse 算法在备选算法中具有最强的优越性。首先，MDValse 是二维直接估计而不是像原子范数与 MDSLSE 一样使用两个一维数据关联后再进行频率配对。其次，MDValse 估计了模型阶数，噪声方差与频点的不确定度，使得整个算法在各类噪声环节中都能够有效与精确估计，估计的准确性也可以使用 Von mises 分布的 κ 参数来准确衡量。此外，与 2D-NOMP 相比，MDValse 能够使用无限精度估计与多频点同时估计，而不是采用多个单频点迭代估计的方法，联合估计提高了准确性。表4.3的复杂度分析显示，MDValse 在超分辨率方法中是复杂度最低的。

从数值结果角度分析，MDValse 算法的分辨率是最高的，在问题一二中距离估计最为精确，角度的变化趋势也符合频点的变化趋势。问题三中，路径估计最为清晰，使得后处理变得极为容易。且复杂度与 2D-NOMP 在同一数量级。这对于一个高精度算法是非常不容易的。

综上所述，本文最终选择 MDValse 算法作为最终的低复杂度高精度线谱估计算法。结合结构噪声修正与数据关联，后端优化等算法，可以适配移动，结构误差等场景，具有非常好的超分辨率性能与抗噪能力。

参考文献

- [1] Zhang Q, Zhu J, Zhang N, et al., Multidimensional variational line spectra estimation, IEEE Signal Processing Letters, 27:945-949, 2020.
- [2] Han L, Liu X, Zhang N, et al., Two-dimensional multi-snapshot Newtonized orthogonal matching pursuit for DOA estimation, Digital Signal Processing, 121:103313, 2022.
- [3] Pan J, Tang J, Niu Y, Fast two-dimensional atomic norm minimization in spectrum estimation and denoising, arXiv preprint arXiv:1807.08606, 2018.
- [4] Hansen T L, Fleury B H, Rao B D, Superfast line spectral estimation, IEEE Transactions on Signal Processing, 66(10):2511-2526, 2018.
- [5] Pesavento M, Mecklenbräuker C F, Böhme J F, Multidimensional Rank Reduction Estimator for Parametric MIMO Channel Models, Eurasip Journal on Advances in Signal Processing, 2004(9):1-10, 2004.
- [6] Liu J, Liu X, An Eigenvector-Based Approach for Multidimensional Frequency Estimation With Improved Identifiability, IEEE Transactions on Signal Processing, 54:4543-4556, 2006.
- [7] Yang Y, Chu Z, Ping G, Two-dimensional multiple-snapshot grid-free compressive beamforming, Mechanical Systems and Signal Processing, 124:524-540, 2019.

- [8] Zhang Z, Wang Y, Tian Z, Efficient two-dimensional line spectrum estimation based on decoupled atomic norm minimization, *Signal Processing*, 163:95-106, 2019.
- [9] Stoica P, Selen Y, Model-order selection: a review of information criterion rules, *IEEE Signal Processing Magazine*, 21(4):36-47, 2004.
- [10] 黄传禄, 晁坤, 毛云志, 空间谱估计中误差自校正方法研究, *雷达学报*, 3(5):6, 2014.
- [11] Rockah Y, Schultheiss P, Array shape calibration using sources in unknown locations—Part I: Far-field sources, *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 35(3): 286-299, 1987.
- [12] Haardt M, Zoltowski M, Mathews C, et al., 2D unitary ESPRIT for efficient 2D parameter estimation, 1995 International Conference on Acoustics, Speech, and Signal Processing: volume 3, 2096-2099 vol.3, 1995.
- [13] Hua, Y, A pencil-MUSIC algorithm for finding two-dimensional angles and polarizations using crossed dipoles, *IEEE Transactions on Antennas and Propagation*, 41(3):370-376, 2002.
- [14] Hua, Y., Estimating two-dimensional frequencies by matrix enhancement and matrix pencil, *IEEE Transactions on Signal Processing*, 40(9):2267-2280, 1992.
- [15] Ortiz M T, Groll H, Zöchmann E, et al., Vehicle Tracking through Vision-Millimeter Wave Doppler Shift Fusion, 2019 IEEE-APS Topical Conference on Antennas and Propagation in Wireless Communications (APWC), 359-362, 2019.
- [16] Li Y, Razavilar J, Liu K J R, A high-resolution technique for multidimensional NMR spectroscopy, *IEEE Transactions on Biomedical Engineering*, 45(1):78-86, 2002.
- [17] Eldar Y C, Kutyniok G, Compressed sensing: theory and applications, Cambridge university press, 2012.
- [18] Tian Z, Zhang Z, Wang Y, Low-complexity optimization for two-dimensional direction-of-arrival estimation via decoupled atomic norm minimization, 2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), IEEE, 3071-3075, 2017.
- [19] Yang Y, Chu Z, Ping G, et al., Resolution enhancement of two-dimensional grid-free compressive beamforming, *The Journal of the Acoustical Society of America*, 143(6):3860-3872, 2018.
- [20] Chi Y, Scharf L L, Pezeshki A, et al., Sensitivity to basis mismatch in compressed sensing, *IEEE Transactions on Signal Processing*, 59(5):2182-2195, 2011.
- [21] Duarte M F, Baraniuk R G, Spectral compressive sensing, *Applied and Computational Harmonic Analysis*, 35(1):111-129, 2013.
- [22] Bhaskar B N, Tang G, Recht B, Atomic norm denoising with applications to line spectral estimation, *IEEE Transactions on Signal Processing*, 61(23):5987-5999, 2013.

- [23] Candes E, Fernandez-Granda C, Towards a Mathematical Theory of Super-Resolution, 2012.
- [24] Tang G, Bhaskar B N, Shah P, et al., Compressed Sensing Off the Grid, IEEE Transactions on Information Theory, 59(11):7465-7490, 2013.
- [25] Yang Z, Xie L, On Gridless Sparse Methods for Line Spectral Estimation From Complete and Incomplete Data, IEEE Transactions on Signal Processing, 63(12):3139-3153, 2015.
- [26] Xu W, Cai J F, Mishra K V, et al., Precise Semidefinite Programming Formulation of Atomic Norm Minimization for Recovering d -Dimensional ($d \geq 2$) Off-the-Grid Frequencies, 2014 Information Theory and Applications Workshop (ITA), 2014.
- [27] Xu W, Cai J F, Mishra K V, et al., Precise semidefinite programming formulation of atomic norm minimization for recovering d -dimensional ($d \geq 2$) off-the-grid frequencies, 2014 information theory and applications workshop (ITA), IEEE, 1-4, 2014.
- [28] Chen, Yuxin, Chi, et al., Compressive Two-Dimensional Harmonic Retrieval via Atomic Norm Minimization, IEEE Transactions on Signal Processing: A publication of the IEEE Signal Processing Society, 63(4):1030-1042, 2015.
- [29] Yang Z, Xie L, Stoica P, Vandermonde decomposition of multilevel Toeplitz matrices with application to multidimensional super-resolution, IEEE Transactions on Information Theory, 62(6):3685-3701, 2016.
- [30] He Z, Cichocki A, Xie S, et al., Detecting the number of clusters in n -way probabilistic clustering, IEEE Transactions on Pattern Analysis and Machine Intelligence, 32(11):2006-2021, 2010.
- [31] Tipping M E, Sparse Bayesian learning and the relevance vector machine, Journal of machine learning research, 1(Jun):211-244, 2001.
- [32] Wipf D P, Rao B D, Sparse Bayesian learning for basis selection, IEEE Transactions on Signal processing, 52(8):2153-2164, 2004.
- [33] Shutin D, Fleury B H, Sparse variational Bayesian SAGE algorithm with application to the estimation of multipath wireless channels, IEEE Transactions on signal processing, 59(8):3609-3623, 2011.
- [34] Hu L, Shi Z, Zhou J, et al., Compressed sensing of complex sinusoids: An approach based on dictionary refinement, IEEE Transactions on Signal Processing, 60(7):3809-3822, 2012.
- [35] Shutin D, Wang W, Jost T, Incremental sparse Bayesian learning for parameter estimation of superimposed signals, 10th International Conference on Sampling Theory and Applications: number 1, 6-9, 2013.
- [36] Hansen T L, Badiu M A, Fleury B H, et al., A sparse Bayesian learning algorithm with dictio-

- nary parameter estimation, 2014 IEEE 8th Sensor Array and Multichannel Signal Processing Workshop (SAM), IEEE, 385-388, 2014.
- [37] Badiu M A, Hansen T L, Fleury B H, Variational Bayesian Inference of Line Spectra, *IEEE Transactions on Signal Processing*, 65(9):2247-2261, 2017.
 - [38] Zhu J, Wen C K, Tong J, et al., Grid-Less Variational Bayesian Channel Estimation for Antenna Array Systems With Low Resolution ADCs, *IEEE Transactions on Wireless Communications*, 19(3):1549-1562, 2020.
 - [39] Vanderveen M, Papadias C, Paulraj A, Joint angle and delay estimation (JADE) for multipath signals arriving at an antenna array, *IEEE Communications Letters*, 1(1):12-14, 1997.
 - [40] Mamandipoor B, Ramasamy D, Madhow U, Newtonized Orthogonal Matching Pursuit: Frequency Estimation Over the Continuum, *IEEE Transactions on Signal Processing*, 64(19):5066-5081, 2016.
 - [41] Grant M, Boyd S, CVX: Matlab Software for Disciplined Convex Programming, version 2.1, 2014.
 - [42] Ammar G S, Gragg W B, The generalized Schur algorithm for the superfast solution of Toeplitz systems, *Rational approximation and its applications in mathematics and physics*, Springer, 315-330, 1987.
 - [43] Ammar G S, Gragg W B, Numerical experience with a superfast real Toeplitz solver, *Linear Algebra and its Applications*, 121:185-206, 1989.
 - [44] Musicus B, Fast MLM power spectrum estimation from uniformly spaced correlations, *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 33(5):1333-1335, 1985.
 - [45] Gohberg I, Fel'dman I A, Convolution equations and projection methods for their solution: volume 41, American Mathematical Soc., 2005.
 - [46] Greengard L, Lee J Y, Accelerating the nonuniform fast Fourier transform, *SIAM review*, 46(3):443-454, 2004.
 - [47] Kormylo J, Mendel J, Maximum likelihood detection and estimation of Bernoulli-Gaussian processes, *IEEE transactions on information theory*, 28(3):482-488, 1982.
 - [48] Friedlander B, Weiss A J, Performance of direction-finding systems with sensor gain and phase uncertainties, *Circuits, Systems and Signal Processing*, 12(1):3-35, 1993.

附录 A 算法核心函数与程序运行说明

1.1 程序运行说明

MDVALUE 参考论文 [37, 38, 1] 及论文开源代码, 并修改为 2 维版本。运行 MDVALUE 文件夹中 p1.m, p2.m, p3.m, p4.m 可以得到问题一到四的物体估计结果图。

MDVALUE+EKF 优化算法参考 MATLAB 官方例程 extendedKalmanFilter。运行 MDVALUE 文件夹中 p3trackMDVALUE.m 可以得到问题三多物体轨迹追踪。

MUSIC+fmincon 优化算法参考 MATLAB 官方例程 SelfCalibrationExample。运行 p4refine 文件夹中 p4refine.m 可以得到问题四修正后的天线阵列结果图。

A.2 MDVALUE 核心函数

funcVALUE2D.m

```
function out = func_VALUE2D(Y, iterMax, Kmax, nu)
% 2D spectral analysis by VALSE

[M, N] = size(Y);
if nargin == 2
    Kmax = M*N;
end
Y2 = sum(conj(Y).*Y, 'all');
m = (0: M - 1).';
n = (0: N - 1).';
A = zeros(M, N, Kmax);
J = zeros(Kmax, Kmax);
h = zeros(Kmax, 1);
w = zeros(Kmax, 1);
C = zeros(Kmax, Kmax);
th = zeros(2, Kmax);

base2D = @(x) exp(1j*x(1)*m)*exp(1j*x(2)*n. ');

% hyper-parameter initialization
% extract 1D and using toeplitz
y1D = Y(:, 1);
if nargin < 4
    R = y1D*y1D';
    sR = zeros(M-1, 1);
    for ii = 2: M
```

```

        for jj = 1:ii-1
            sR(ii - jj) = sR(ii - jj) + R(ii, jj);
        end
    end

    Rh = toeplitz([sum(diag(R)); sR])/M;
    evs = sort(real(eig(Rh)), 'ascend');
    nu = mean(evs(1:floor(M/4)));
end

K = floor(Kmax/2);
rho = K/Kmax;
tau = (Y2/M/N - nu)/(rho*Kmax);

% frequencies and weights initialization
res = Y;
for kk = 1:Kmax
    % initialize frequencies
    th(:,kk) = FftFreqEst(res);
    A(:, :, kk) = base2D(th(:,kk));

    wTmp = w(1:kk-1); CTmp = C(1:kk-1, 1:kk-1);
    h(kk) = sum(Y.*conj(A(:, :, kk)), 'all');
    J(kk, kk) = M*N;
    for pp = 1:kk-1
        J(pp, kk) = sum(conj(A(:, :, pp)).*A(:, :, kk), 'all');
    end
    J(kk, 1:kk-1) = J(1:kk-1, kk)';
    v = nu/(N*M + nu/tau - real(J(1:kk-1, kk)'*CTmp*J(1:kk-1, kk))/
        nu);
    u = v.*(h(kk) - J(1:kk-1, kk)'*wTmp)/nu;
    w(kk) = u;
    ctemp = CTmp*J(1:kk-1, kk)/nu;
    w(1:kk-1) = wTmp - ctemp*u;
    C(1:kk-1, 1:kk-1) = CTmp + v*(ctemp*ctemp');
    C(1:kk-1, kk) = -v*ctemp;
    C(kk, 1:kk-1) = C(1:kk-1, kk)';
    C(kk, kk) = v;

    xHat0 = sigModel(A(:, :, 1:kk), w(1:kk), [M, N]);
    res = Y - xHat0;

```

```

end

% figure();
% stem3(th(2,:), th(1,:), abs(w));

% start 2D VALSE
isloop = 1;
ii = 0;
while isloop
    ii = ii + 1;
    % update weights and supports
    [K, s, w, C] = maxZ(J, h, M, N, nu, rho, tau);

    % update hyper-parameters
    if K > 0
        if nargin < 4
            nu_tmp = real(Y2 - 2*real(h(s)'*w(s)) + w(s)'*J(s,s)*w(
                s) + trace(J(s,s)*C(s,s)))/(M*N);
            nu = max([nu_tmp, 1e-3]);
        end
        tau = real(w(s)'*w(s)+trace(C(s,s)))/K;
        if K < Kmax
            rho = K/Kmax;
        else
            rho = (Kmax-1)/Kmax;
        end
    else
        rho = 1/Kmax;
    end
    % update frequencies
    inz = 1:Kmax;
    inz = inz(s);

    for kk = 1:K
        if K == 1
            eta = 2/nu*(w(inz(kk))*conj(Y));
        else
            wkk = C(inz([1:kk-1 kk+1:end]),inz(kk)) + w(inz(kk))*
                conj(w(inz([1:kk-1 kk+1:end])));
        end
    end
end

```

```

        Akk = conj(A(:, :, inz([1:kk-1 kk+1:end])));
        eta = 2/nu*(w(inz(kk))*conj(Y) - sigModel(Akk, wkk, [M,
            N]));

    end

    d1 = zeros(2,1); d2 = zeros(2,2);
    tmpkk = eta.*A(:, :, inz(kk));
    d1(1) = -imag(sum(diag(m)*tmpkk, 'all'));
    d1(2) = -imag(sum(tmpkk*diag(n), 'all'));
    d2(1,1) = -real(sum(diag(m.^2)*tmpkk, 'all'));
    d2(2,2) = -real(sum(tmpkk*diag(n.^2), 'all'));
    d2(1,2) = -real(sum(diag(m)*tmpkk*diag(n), 'all'));
    d2(2,1) = d2(1,2);

    th(:, inz(kk)) = th(:, inz(kk)) - d2\d1;
    kappa = Ainv(exp(0.5./diag(d2)));
    Ak1 = besseli(m,kappa(1),1)/besseli(0,kappa(1),1);
    Ak2 = besseli(n.',kappa(2),1)/besseli(0,kappa(2),1);
    A(:, :, inz(kk)) = base2D(th(:, inz(kk))).*(Ak1*Ak2);
% A(:, :, inz(kk)) = base2D(th(:, inz(kk)));
end

%     if ii == 1
%         disp(table([th(1,s).', th(2,s).']));
%     end

% update J, h
for kk = 1:K
    for pp = 1:Kmax
        J(pp, inz(kk)) = sum(conj(A(:, :, pp)).*A(:, :, inz(kk)
            ), 'all');
    end
    h(inz(kk)) = sum(Y.*conj(A(:, :, inz(kk))), 'all');
end
J(s,:) = J(:,s)';
J(s,s) = J(s,s) - diag(diag(J(s,s))) + N*M*eye(K);

% stopping criterion
xHat = sigModel(A(:, :, s), w(s), [M, N]);
if (norm(xHat-xHat0)/norm(xHat0)<1e-6) || ...

```

```

        (norm(xHat0)==0&&norm(xHat0-xHat)==0) || (ii >= iterMax
        )
        isloop = 0;
    end
    xHat0 = xHat;
end
out = struct('freqs', th(:,s).', 'amps', w(s), 'x_estimate',xHat, '
    noise_var',nu);
end

function X = sigModel(A, w, Xsize)
K
    = length(w);
X
    = zeros(Xsize(1), Xsize(2));
if K ~= 0
    for p = 1:K
        X = X + w(p)*A(:, :, p);
    end
end
end

function th = FftFreqEst(Y)
gamma
    = 16;
th
    = zeros(2,1);
[M, N]
    = size(Y);
% m
    = (0: M - 1).';
% n
    = (0: N - 1).';
Yfft
    = fft2(Y, gamma*M, gamma*N);
Yfft
    = fftshift(Yfft);
[~, ind]
    = max(abs(Yfft(:)));
[row, col]
    = ind2sub([gamma*M, gamma*N], ind);
th(1) = pi*(-1 + 2/(gamma*M)*(row-1));
th(2) = pi*(-1 + 2/(gamma*N)*(col-1));

end

% function th = Fft1DFreqEst(Y)
% th
    = zeros(2,1);
% [M, N]
    = size(Y);

```



```

% Yfft          = fft(Y, 8*M);
% Yfft          = fftshift(Yfft);
% [~, ind]      = max(abs(Yfft(:)));
% th(1) = pi*(-1 + 2/(8*M)*(ind-1));
% th(2) = 0
% end

function [K, s, w, C] = maxZ(J, h, M, N, nu, rho, tau)

Kmax = size(h, 1);
cnst = log(rho/(1-rho)/tau);

K = 0;
s = false(Kmax, 1);
w = zeros(Kmax, 1);
C = zeros(Kmax, Kmax);
u = zeros(Kmax, 1);
v = zeros(Kmax, 1);
Delta = zeros(Kmax, 1);

if Kmax > 1
    isloop = 1;
    while isloop
        if K < Kmax - 1
            v(~s) = nu./(N*M + nu/tau - real(sum(J(s,~s).*conj(C(s,
                s)*J(s,~s)),1))/nu);
            u(~s) = v(~s).*(h(~s) - J(s,~s)'*w(s))/nu;
            Delta(~s) = log(v(~s)) + u(~s).*conj(u(~s))./v(~s) +
                cnst;
        else
            Delta(~s) = -1;
        end

        if ~isempty(h(s))
            Delta(s) = -log(diag(C(s,s))) - w(s).*conj(w(s))./diag(
                C(s,s)) - cnst;
        end

        [~, k] = max(Delta);
    end
end

```

```

    if Delta(k) > 0
        if s(k) == 0 % activate
            w(k) = u(k);
            ctemp = C(s,s)*J(s,k)/nu;
            w(s) = w(s) - ctemp*u(k);
            C(s,s) = C(s,s) + v(k)*(ctemp*ctemp');
            C(s,k) = -v(k)*ctemp;
            C(k,s) = C(s,k)';
            C(k,k) = v(k);
            s(k) = ~s(k); K = K+1;
        else % deactivate
            s(k) = ~s(k); K = K-1;
            w(s) = w(s) - C(s,k)*w(k)/C(k,k);
            C(s,s) = C(s,s) - C(s,k)*C(k,s)/C(k,k);
        end
        C = (C + C')/2;
    else
        break;
    end
end
elseif Kmax == 1
    if s == 0
        v = nu/(N*M + nu/tau);
        u = v*h/nu;
        Delta = log(v) + u*conj(u)/v + cnst;

        if Delta > 0
            w = u; C = v;
            s = 1; K = 1;
        end
    else
        Delta = -log(C) - w*conj(w)/C - cnst;
        if Delta > 0
            w = 0; C = 0;
            s = 0; K = 0;
        end
    end
end
end
end

```

```

function [x] = Ainv(y)
x    = y; % define A with same dimensions
in1 = (y<.53); % indices of the entries < .53
in3 = (y>=.85); % indices of the entries >= .85
in2 = logical(1-in1-in3); % indices of the entries >=.53 and <.85
R1  = y(in1); % entries < .53
R2  = y(in2); % entries >=.53 and <.85
R3  = y(in3); % entries >= .85

% compute for the entries which are < .53
if ~isempty(R1)
    t      = R1.*R1;
    x(in1) = R1 .* ( 2 + t + 5/6*t.*t );
end
% compute for the entries which are >=.53 and <.85
if ~isempty(R2)
    x(in2) = -.4 + 1.39*R2 + 0.43./(1-R2);
end
% compute for the entries which are >= .85
if ~isempty(R3)
    x(in3) = 1./( R3.*(R3-1).*(R3-3) );
end
end

```

A.3 MDVALUE+EKF 多目标算法代码

p3trackMDVALUE.m

```

clc; clear; close all;

c=3e8;
gamma=78.986* 10^12;
Ts=1.25*10^(-7);
f0=78.8e9;
lambda1=c/f0;
L=0.0815;
deltad=L/85;
T = 3.2E-5;

load data_q3

```

```

for kk= 1:32
    Z_noisy=squeeze(Z_time(kk,:,:));
    [M,N]=size(Z_noisy);
    tmp = randperm(N-1)';
    N_cal = [sort(tmp(1:N-1),'ascend'); N]-1;
    tmp = randperm(M-1)';
    M_cal = [sort(tmp(1:M-1),'ascend'); M]-1;
    Iter_max=5000;
    outVALUE=func_VALSE2D(Z_noisy,Iter_max,3);
    [a,b]=sort(outVALUE.freqs(:,1));
    outVALUE.freqs(:,1)=outVALUE.freqs(b,1);
    outVALUE.freqs(:,2)=outVALUE.freqs(b,2);
    for i=1:length(outVALUE.amps)
        if outVALUE.freqs(i,1)>pi
            outVALUE.freqs(i,1)=outVALUE.freqs(i,1)-2*pi;

        end
        if outVALUE.freqs(i,2)<0
            outVALUE.freqs(i,2)=outVALUE.freqs(i,2)+2*pi;

        end
        theta(kk,i)= asin(lambdal*outVALUE.freqs(i,1)/(-2*pi*deltad
            ));
        dis(kk,i)=outVALUE.freqs(i,2)/(4*pi*Ts*gamma/c);
        xx(kk,i)=dis(kk,i)*cos(theta(kk,i));
        yy(kk,i)=dis(kk,i)*sin(theta(kk,i));
    end
end

plot(xx,yy,'*');
plot(dis,theta,'*');
%% EKF 曲线拟合
theta_EKF_1 = theta(:,1);

k = 0.519;
f = @(x,u,v) (x+k*(u-v));
h = @(x) (x);
obj = extendedKalmanFilter(f,h,theta_EKF_1(1), '

```

```

        HasAdditiveMeasurementNoise',false);
obj.MeasurementNoise = 0.01;

for j=1:31
    theta_EKF_1(j+1) = predict(obj,dis(j+1,1),dis(j,1));
end

k = 0.519;
theta_EKF_2 = theta(:,2);

f = @(x,u,v) (x+k*(u-v));
h = @(x) (x);
obj = extendedKalmanFilter(f,h,theta_EKF_2(1), '
    HasAdditiveMeasurementNoise',false);
obj.MeasurementNoise = 0.01;

for j=1:31
    theta_EKF_2(j+1) = predict(obj,dis(j+1,2),dis(j,2));
end

hfig = figure;
figWidth = 3.5; % 设置图片宽度
figHeight = 3.5/4*3; % 设置图片高度
set(hfig,'PaperUnits','inches'); % 图片尺寸所用单位
set(hfig,'PaperPosition',[0 0 figWidth figHeight]);
set(gca, 'FontSize',8);

plot(dis(:,1),theta(:,1),'*');hold on;
plot(dis(:,2),theta(:,2),'*');hold on;
plot(dis(:,1),theta_EKF_1,'-');hold on;
plot(dis(:,2),theta_EKF_2,'-');hold off;
legend('物体1原始轨迹','物体2原始轨迹','物体1EKF后轨迹','物体2EKF后
    轨迹','Location','Northwest');
xlabel('距离 (米) ')
ylabel('到达角 (弧度) ')
saveas(gcf, 'MDValse+EKF滤波问题三估计结果图', 'png')
%% 多项式曲线拟合
theta_poly1 = fit(dis(:,1),theta(:,1),'poly5','Normalize','on');
theta_poly2 = fit(dis(:,2),theta(:,2),'poly5','Normalize','on');
hfig = figure;

```

```

figWidth = 3.5; % 设置图片宽度
figHeight = 3.5/4*3; % 设置图片高度
set(hfig,'PaperUnits','inches'); % 图片尺寸所用单位
set(hfig,'PaperPosition',[0 0 figWidth figHeight]);
set(gca, 'FontSize',8);

plot(dis(:,1),theta(:,1),'*');hold on;
plot(dis(:,2),theta(:,2),'*');hold on;
theta_plot(:,1) = theta_poly1(dis(:,1));
theta_plot(:,2) = theta_poly2(dis(:,2));
plot(dis(:,1),theta_plot(:,1),'-');hold on;
plot(dis(:,2),theta_plot(:,2),'-');hold off;
legend('物体1原始轨迹','物体2原始轨迹','物体1拟合轨迹','物体2拟合轨
迹','Location','Northwest')
xlabel('距离 (米) ')
ylabel('到达角 (弧度) ')
saveas(gcf, 'MDValse+五阶多项式拟合问题三估计结果图', 'png')
theta_poly1 = fit(dis(:,1),theta(:,1),'poly3','Normalize','on');
theta_poly2 = fit(dis(:,2),theta(:,2),'poly3','Normalize','on');
hfig = figure;
figWidth = 3.5; % 设置图片宽度
figHeight = 3.5/4*3; % 设置图片高度
set(hfig,'PaperUnits','inches'); % 图片尺寸所用单位
set(hfig,'PaperPosition',[0 0 figWidth figHeight]);
set(gca, 'FontSize',8);

plot(dis(:,1),theta(:,1),'*');hold on;
plot(dis(:,2),theta(:,2),'*');hold on;
theta_plot(:,1) = theta_poly1(dis(:,1));
theta_plot(:,2) = theta_poly2(dis(:,2));
plot(dis(:,1),theta_plot(:,1),'-');hold on;
plot(dis(:,2),theta_plot(:,2),'-');hold off;
legend('物体1原始轨迹','物体2原始轨迹','物体1拟合轨迹','物体2拟合轨
迹','Location','Northwest')
xlabel('距离 (米) ')
ylabel('到达角 (弧度) ')
saveas(gcf, 'MDValse+三阶多项式拟合问题三估计结果图', 'png')
theta_poly1 = fit(dis(:,1),theta(:,1),'poly1','Normalize','on');
theta_poly2 = fit(dis(:,2),theta(:,2),'poly1','Normalize','on');

```

```

hfig = figure;
figWidth = 3.5; % 设置图片宽度
figHeight = 3.5/4*3; % 设置图片高度
set(hfig, 'PaperUnits', 'inches'); % 图片尺寸所用单位
set(hfig, 'PaperPosition', [0 0 figWidth figHeight]);
set(gca, 'FontSize', 8);

plot(dis(:,1), theta(:,1), '*'); hold on;
plot(dis(:,2), theta(:,2), '*'); hold on;
theta_plot(:,1) = theta_poly1(dis(:,1));
theta_plot(:,2) = theta_poly2(dis(:,2));
plot(dis(:,1), theta_plot(:,1), '-'); hold on;
plot(dis(:,2), theta_plot(:,2), '-'); hold off;
legend('物体1原始轨迹', '物体2原始轨迹', '物体1拟合轨迹', '物体2拟合轨迹', 'Location', 'Northwest')
xlabel('距离 (米) ')
ylabel('到达角 (弧度) ')
saveas(gcf, 'MDValse+一阶多项式拟合问题三估计结果图', 'png')

view(90, 90);

```

A.4 MUSIC+fmincon 优化算法代码

p4refine.m

```

clc; clear; close all;

c=3e8;
gamma=78.986* 10^12;
Ts=1.25*10^(-7);
f0=78.8e9;
lambda1=c/f0;
L=0.0815;
deltad=L/85;
deltatheta=asin(lambda1/(4*deltad));

load data_q4
Z_noisy=Z_antnoisy;
N=86;
M=1;
x_in=Z_noisy';

```

```

Rxx=x_in'*x_in;
ula = phased.ULA('NumElements',N);
spatialspectrum = phased.BeamscanEstimator('SensorArray',ula,...
    'DOAOutputPort',true,'NumSignals',M);
[y,estimated_az] = spatialspectrum(x_in);
designed_pos=[zeros(1,N);-(N-1)/2:(N-1)/2;zeros(1,N)]*deltad;
fun = @(x_in)helperMUSICIteration(x_in,Rxx,designed_pos);
nvars = 2*N - 3 + M; % Assuming 2D
    uncertainties
x0 = [0.1*randn(1,nvars-M),estimated_az]; % Initial value
locTol = 0.1*2e-3; % Location
    tolerance
angTol = 20; % Angle tolerance
lb = [-locTol*ones(nvars-M,1);estimated_az.'-angTol]; % lower bound
ub = [locTol*ones(nvars-M,1);estimated_az.'+angTol]; % upper bound

options = optimoptions('fmincon','TolCon',1e-6,'DerivativeCheck','
    on',...
    'Display','off');
[x,fval,exitflag] = fmincon(fun,x0,[],[],[],[],lb,ub,[],options);

% Parse the final result
[~,perturbed_pos_est,postcal_estimated_az]=helperMUSICIteration(...
    x,Rxx,designed_pos);

helperCompareArrayProperties('Position',perturbed_pos_est,
    designed_pos,...
    {'实际天线阵列','理想天线阵列'});

view(90,90);

```