



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 西南大学

参赛队号 23106350004

1.钟 帅

队员姓名 2.李诗慧

3.周泓汛

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

题 目： 基于区域双碳目标与路径规划的算法研究

摘 要：

2020 年中国的碳排放量已经占全球碳排放量的 31%。为了应对碳排放量带来的一系列环境污染问题，中国提出在 2060 年实现碳中和。本文将运用数学工具，分析、评价和预测能效提升、产业升级、能源脱碳和能源消费电气化等重点对碳排放的影响。

基于题目给出的数据，首先完成异常值处理、缺失值处理和数据降维，提高了数据的可靠性和可用性。

针对**问题一**，对区域碳排放量以及经济、人口、能源消费的现状进行分析。根据题目所给出指标要求建立**指标体系**，将经济、人口、能源消费量和碳排放量作为一级指标。利用构建的指标体系从经济增长、人口增长、能源消费量、不同时期的变化趋势等方面进行**统计学回归分析**，对碳排放与经济、人口、能源消费量这些一级指标进行**相关性分析和灰色关联度分析**，建立各指标之间的**关联模型**，为碳排放量预测提供依据。

针对**问题二**，建立区域碳排放量以及经济、人口、能源消费量的预测模型。首先，建立基于人口和经济变化的能源消费量预测模型。基于问题一的分析结果，建立**线性回归模型**、**Logistic 模型**、**灰色预测模型**、**LSTM 模型**等多个模型来完成对人口或经济的预测。为了更进一步提高精度，采取**多种方式加权组合**进行预测，并利用**粒子群算法**求解最优的模型权重。通过**线性回归模型**、**BP 神经网络模型**和**XGBoost 模型**对能源消费量预测，同时利用人口和经济预测模型提高能源消费量预测的精度。通过建立**多元线性回归**、**岭回归**、**XGboost**和**BP 神经网络**等多个模型来预测区域碳排放量，并且利用问题二的第一小问的加权组合预测模型，实现对区域碳排放量的更高精度的预测。

针对**问题三**，根据确立的双碳目标的时间节点，设计了三种不同的情景，分别为**自然**、**基准**、**雄心**情景。基于三种情景，利用问题二中建立的模型并结合**Kaya 模型**分别核算碳排放量以及确立**经济**、**人口**、**能源消费目标值**。将目标与提高能效和非化石能源占比相关联，确保双碳目标的路径与措施相一致。并对能效提升、产业升级、能源脱碳和能源消费电气化完成了**定量定性分析**，从而确定实现双碳目标的路径，包括涉及的政策、技术创新等方面的内容。

本文通过建立的指标体系对区域碳排放量、人口、能源的现状进行了详细的分析，在此基础上建立了区域碳排放量的预测模型，并根据建立的模型结合 Kaya 模型得出了双碳

目标的实现路径，同时改进了 Kaya 模型。Kaya 模型得出的政策建议具有模糊性和非理性，需要结合其他因素分析检验，本文建立的模型较准确的确立了目标路径，对政策的建议相比 Maya 模型更加清晰和理性。

关键词： 双碳目标 相关关系 预测模型 神经网络 优化算法 Kaya 模型

目录

一. 问题重述	5
1.1 问题背景	5
1.2 问题重述	5
二. 总体技术路线图	7
三. 基本假设与符号说明	8
3.1 模型假设	8
3.2 符号说明	8
四. 数据处理与分析	9
五. 问题一：区域碳排放量以及经济、人口、能源消费量的现状分析	13
5.1 问题分析	13
5.2 指标与指标体系	13
5.2.1 指标与指标体系构建原则	13
5.2.2 指标体系的确立	14
5.2.3 四个子系统分析	16
5.2.4 关联层指标体系的构建	20
5.3 区域碳排放量以及经济、人口、能源消费量现状分析	21
5.4 碳排放主要因素影响分析	23
5.5 实现双碳目标的路径选择	24
5.6 区域双碳指标体系——关联关系模型分析	24
5.7 关联模型分析方法简介	24
5.7.1 人口-碳排放关联关系分析	25
5.7.2 经济-碳排放关联关系分析	26
5.7.3 能源-碳排放关联关系模型分析	29
六. 问题二：区域碳排放量以及经济、人口、能源消费量的预测模型	32
6.1 问题分析	32
6.2 人口预测与 GDP 预测	32
6.2.1 基于线性回归模型的人口和 GDP 预测	32
6.2.2 基于 logistic 的人口预测模型	34
6.2.3 基于灰色预测模的人口与 GDP 预测	35
6.2.4 灰色预测模型求解与检验	36
6.2.5 基于 LSTM 模的人口与经济预测	37
6.2.6 基于组合加权的人口与经济预测模型	39
6.3 能源消费量预测模型	41
6.3.1 线性回归模型	41
6.3.2 BP 神经网络模型	43
6.3.3 XGBoost 模型	44
6.4 区域碳排放量预测模型	45
6.4.1 多元线性回归模型	45
6.4.2 岭回归模型	47
6.4.3 XGBoost 模型	49

6.4.4 bp 神经网络模型	50
七. 问题三：区域双碳目标与路径规划方法	51
7.1 问题分析	51
7.2 情景设计	51
7.3 多场景核算碳排放量	51
7.3.1 自然场景	52
7.3.2 基准场景	54
7.3.3 雄心场景	54
7.4 双碳目标与路径规划模型	55
八. 模型评价	56
8.1 模型优点	56
8.2 模型缺点	56
参考文献	57
附录	58

一. 问题重述

1.1 问题背景

随着气候变暖、冰川融化以及海平线逐渐上移等问题日益严重，碳排放造成的环境破坏等问题逐渐引起国际社会的普遍关心，该问题现已成为全人类面临的共同挑战。过去，我国在经济高速发展的同时，高能耗、高投入、高碳排放给我国经济发展带来了严重的环境和生态问题。现在，为了更好地实现中华民族伟大复兴、2035 年基本实现现代化、2050 年实现建设富强美丽的社会主义现代化中国的目标，习近平总书记指出要秉承走绿色发展、可持续发展道路。走可持续发展道路，就不可避免地要去协调平衡人民生活、经济、能源与碳排放之间的关系，人口和经济发展的重叠区域表示随着人口增长，经济也会相应发展。城市化进程和工业活动等会导致更多能源消耗和碳排放。经济发展和能源消耗的重叠区域表示经济繁荣与能源消耗紧密相连。传统能源的使用方式会导致更高的碳排放，而转向清洁能源选择则可以减少碳排放。能源消耗和碳排放的重叠区域表示能源与碳排放之间的直接关系。过度依赖化石燃料会导致更高的碳排放，而采用可再生能源则可以减少碳排放。图 1 展示了四者之间存在的错综复杂的联系。




图 1 人口、能源、经济与碳排放韦恩图

这个图表可以帮助我们理解人口、经济发展、能源耗和碳排放之间的相互关系。它强调了适当的人口管理、可持续的经济发展、清洁能源的采用以及低碳排放的目标的重要性。

为了解决发展与减排的矛盾，我们需要追求经济增长与碳排放量的负相关变化。为此，我们必须从提高能源利用效率和提高非化石能源消费比重两个方面入手。因此，为了实现 2060 年碳中和的目标，解决发展与减排的矛盾，我们需要实施能效提升、产业（产品）升级、能源脱碳和能源消费电气化等四大重点工程，可从提高能源利用效率和提高非化石能源消费比重两个方面着手。

为了解决发展与减排的矛盾，我们需要追求经济增长与碳排放量的负相关变化。为此，我们必须从提高能源利用效率和提高非化石能源消费比重两个方面入手。因此，为了实现 2060 年碳中和的目标，解决发展与减排的矛盾，我们需要实施能效提升、产业（产品）升级、能源脱碳和能源消费电气化等四大重点工程，可从提高能源利用效率和提高非化石能源消费比重两个方面着手。

1.2 问题重述

问题一：区域碳排放量以及经济、人口、能源消费量的现状分析

要求建立一个指标体系，可以使用人均碳排放量、碳强度、经济发展水平、居民生活

水平、能源消耗结构等多个指标来描述特定区域的经济发展情况、人口状况、能源消耗量和碳排放情况。数据来源包括国家统计局的公开数据、环保部门的污染源监控数据以及第三方调查机构的问卷调查数据等，分析时间段为 2010 年至 2020 年。在探索各种因素对碳排放量影响程度的同时，也需要考虑这些因素间的相互作用，如碳排放量与 GDP 之间的关系，能源消耗类型与碳排放量之间的关系等。

问题二：区域碳排放量以及经济、人口、能源消费量的预测模型

要求构建一个预测模型，可借鉴著名的 LSTM 模型（长短期时间序列预测模型）并加以改进，用于预测未来一段时间内特定区域的人口、经济（GDP）和能源消耗量的变化，并利用这些变化预测该区域的碳排放量。在构建模型时，除了考虑人口、GDP 和能源消耗量与能源供应部门以及不同能源消耗部门之间的关系，并考虑不同能源消耗类型对碳排放量的影响。此外，还需要加入时间序列因素，如季节性、趋势性和周期性因素等。

问题三：区域双碳（碳达峰与碳中和）目标与路径规划方法

要求设计多种情景，包括政策的情景和技术的情景，分析这些情景下特定区域的碳排放量变化，并根据分析结果制定实现“双碳”目标的路径。在政策情景中，可以考虑制定有利于清洁能源发展的政策，以及新能源汽车推广等措施。在技术情景中，可以考虑提高能源利用效率、扩大非化石能源比例，利用碳捕获等措施。此外，还需要进行投资成本、环境效益等方面的权衡分析，确定路径的可行性。

二. 总体技术路线图




图 2 总体技术路线图

三. 基本假设与符号说明

3.1 模型假设

- 1) 2035 年的 GDP 比 2020 年翻一番, 2060 年比 2020 年翻两番。
- 2) 2060 年生态碳汇的碳消纳量为 2020 年的碳排放量的 10%。
- 3) 2060 年工程碳汇或碳交易的碳消纳量为 2020 年碳排放量 10%。
- 4) 碳排放量与人口、GDP 和能源消费量之间存在线性或非线性的关联关系。
- 5) 历史趋势在未来的一段时间内不会发生改变。

3.2 符号说明

本模型所涉及的通用符号定义如下:

表 1 符号表

序号	符号	含义
1	P	人口数量
2	i, t	分别表示第 i 年, 第 t 年
3	E	能源消费总量
4	G	GDP
5	CO ₂	二氧化碳
6	%	百分比
7	m	最大值
8	nl	农林部门
9	x	自变量
10	y	因变量
11	1-, 2-, 3-	第一、第二、第三产业
12	P _i , G _i , E _i	表示第 i 年人口、GDP 和能耗总量

*P,G,E 不同的脚标对应不同的含义, 若正文中与之矛盾, 以正文中符号含义为准。

四. 数据处理与分析

本章将主要介绍本文对某区域 2010-2020 年所有与人口、经济、能源以及碳排放相关的数据进行的数据处理与分析。数据处理与分析是指对收集到的数据进行整理、清洗、转换和解释的过程。通过应用统计学和分析方法，数据处理与分析帮助我们揭示数据中的模式和趋势，提取有用的信息，以支持决策和洞察。它包括数据清洗、数据转换、探索性数据分析、统计建模等步骤，旨在从大量数据中获得有关现象和问题的见解，并为业务和研究提供实证基础。

3.1 数据处理

本次课题所使用的绘图设计工具是 Origin，Origin 可以用于图表的绘制。

本项目使用的编程语言是 Python，易操作、支持多种跨平台操作、运行速度快，Python 中也有相应的数据处理库与绘图库。

综上所述，本次数据处理在技术上是可行的。

数据处理的主要流程包括数据收集、数据清洗、数据标准化等等。这些步骤帮助我们 从原始数据中提取有用信息，并为决策和业务提供支持，数据集已由问题给出，本文数据处理主要分为 3 个内容，如图所示：




图 3 数据处理过程

（1）数据收集：

通过数据收集，本文根据问题内容，考虑到数据具有时间性的特点，所以通过对数据之间进行同比与环比，得到了用于比较不同时间段数据变化的属性，比如：人口年增长率、GDP 年增长率、能耗年增长率……通过这些属性，我们可以了解数据的增长或下降趋势，并判断当前数据是否呈现出某种稳定模式。这对于预测未来的发展趋势、制定业务策略以及进行经济分析非常有帮助。

（2）数据清洗：

通过数据清洗，对原始数据进行筛选、清除和修复，以确保数据的质量和准确性，可以提高数据的质量和可靠性，减少分析过程中的误差和偏差，从而为后续数据分析和建模提供更可靠的基础，经过数据筛查去除了表中的缺失值。

（3）数据整合与标准化：

数据整合是指将来自不同来源或不同格式的数据合并到一个统一的数据集中，以便进行分析、挖掘和处理。本次项目所使用的人口、经济、能源以及碳排放相关数据集是来源于官网网站，数据格式是.xlsx，数据量较少，时间跨度短，难点在于数据集大部分都是分散在不同的表格中，需要耗费一定的时间精力去完成对数据集的整合，本文整理和清洗所收集的数据，确保数据的完整性和一致性，将人口、经济、能源以及碳排放的相关指标数据按年份进行一一对应。最终整合数据属性包括：年份、人口数量、GDP 总量、人均 GDP 增长率、能源消费总量、人均能源消费总量、一产能耗总量、二产能耗总量、三产能耗总量、单位 GDP 能耗、碳排放总量、居民生活消费碳排放总量、人均生活碳排放总量、碳排放强度……共 50 个数据属性，时间跨度为 10 年，共 10 条数据，数据个数为 $50 \times 10 = 500$ ，

并将 2010 年的数据作为基准数据值对数据进行分析。

数据标准化方法主要分为：0-1 标准化、最大最小值标准化、方差标准化等等，考虑到本问题中的数据均值与标准差具有实际意义的数，因此本文采用方差标准化对数据进行处理，处理好的数据将用于之后的数据相关性分析以及机器学习建模过程中。

3.2 数据分析

通过数据处理整理的汇总表格全部数据内容以及相关描述性信息（未标准化）见下表。

表 2 人口属性及相关性描述信息表

	平均值	标准差	最小值	最大值
P	8312.89	157.40	8022.99	8477.26
P%	0.00748	0.00563	0.00096	0.01953

表 3 经济属性及相关性描述信息表

	平均值	标准差	最小值	最大值
GDP	67958.94	14806.64	45952.65	88683.21
GDP%	0.07940	0.02205	0.03655	0.11040
GDP/P	8.14807	1.63828	5.72762	10.46131
GDP/P%	0.07132	0.01705	0.03555	0.08930
1	3451.23	356.03	2736.86	3916.81
2	31523.34	5143.01	23739.96	38183.23
3	32984.38	9352.47	19475.83	46583.18
n1GDP	3451.21	356.02	2736.86	3916.81
nyGDP	1354.43	268.75	947.43	1692.80
gyGDP	30168.91	4878.81	22792.53	36522.55
jtGDP	2385.91	247.24	1988.43	2761.51
jzGDP	30598.48	9121.10	17487.40	43821.67

表 4 能源属性及相关性描述信息表

	平均值	标准差	最小值	最大值
E	29592.295	1797.4265	26860.025	32227.505
E/P	3.5574572	0.1541024	3.3478822	3.8053091
1	421.23907	31.014186	362.17627	457.99466
2	24618.591	988.28751	23145.467	26196.116
3	2858.5247	487.96432	2115.5640	3522.3847
n1E	1693.9402	330.10590	1205.1268	2180.6045
nyE	421.23907	31.014186	362.17627	457.99466
gyE	7324.8109	576.39694	6453.2497	8374.6250
jtE	17293.780	1319.4007	15171.856	19109.552
jzE	2035.5315	345.97092	1494.7386	2484.4650
PE	822.99319	145.86791	620.82533	1039.4597
C-E	20933.865	349.28527	20292.669	21450.192
YP-E	4428.7868	311.55918	3748.1874	4731.9630
TRQ-E	2495.7312	1004.3743	1246.4130	3827.9592
XNY-E	486.90148	261.03367	248.20881	963.06888
XNY%-E	312.723	65.271479	176.31	391.53

WD-E	934.28693	343.19446	428.57683	1420.9327
FD-E	13872.161	1147.2577	12131.869	15334.760
FFD-E	15720.134	729.14057	14728.155	16892.744
HS-E	27858.384	1189.7945	26006.930	29629.244
FHS-E	312.723	65.271479	176.31	391.53
FHS%	0.0104932	0.0017394	0.0065640	0.0121489
GDP/E	0.4502253	0.0769641	0.3544977	0.5845152

表 5 碳排放属性及相关性描述信息表

	平均值	标准差	最小值	最大值
CO ₂	68758.2	3244.33	64853.2	74096.3
CO ₂ /P	8.26869	0.28063	7.83149	8.74903
1CO ₂	1165.59	109.213	1007.47	1295.48
2CO ₂	52659.7	1031.51	51101.8	54235.4
3CO ₂	8831.85	1607.67	6584.55	11150.9
n1CO ₂	1165.59	109.213	1007.47	1295.48
gyCO ₂	52659.7	1031.51	51101.8	54235.4
jtCO ₂	4465.86	762.168	3280.29	5456.83
jzCO ₂	4365.98	868.029	3304.26	5701.30
2CO ₂	6101.07	1082.12	4601.82	7534.48
2CO ₂ /P	0.73217	0.11792	0.57357	0.88878
碳排放强度	1.05039	0.20446	0.81901	1.41870

根据上文的数据描述性信息统计，发现数据之间属于不同尺度、范围或单位，为了更加方便后续进行机器学习建模训练等等，同时增加了数据标准化过程，用于将不同尺度、范围或单位的数据转换为统一的尺度，以消除数据间的量纲差异，便于加速优化过程以及数据分析更加合理（仅在综合数据分析中使用，原数据格式仍保留，用于对人口、经济、能源、碳排放发展状况的描述……）。

为了更好地分析这些数据属性之间的相互关系，本次课题采用热力图对其进行初步的相关性分析研究。热力图（Heatmap）是一种常用的图表形式，用于可视化数据集中变量之间的相关性。它通过使用颜色编码在二维矩阵中表示变量之间的相关程度，以帮助用户直观地识别相关性模式。下图矩阵中的每个单元格的深浅程度反映了两个变量之间相关性的强度，较浅的颜色表示更高的相关性，较深的颜色表示更高的不相关性。




图 1 相关性分析热力图与关联度分析热力图

从图 4 中可以简单看出，碳排放总量和人口数据表中的人口总量；经济数据表中的 GDP 总量、人均 GDP 总量；能源数据表中的消费总量、人均能源消费总量具有极高的正相关性。碳排放总量和人口数据表中的人口增长率；经济数据表中的 GDP 总量增长率、人均 GDP 增长率；能源数据表中的单位 GDP 能耗、碳排放强度呈较高的负相关性。

基于此我们完成了初步的数据特征分析，后续将会将以上内容纳入问题考量中，借此辅助对三大主要问题进行求解。

五. 问题一：区域碳排放量以及经济、人口、能源消费量的现状分析

本章主要针对问题一进行细致的问题分析和数据支持，包括深入了解问题一背景，包括相关领域的研究现状、已有的解决方案和方法等；明确问题一的具体要求，并将其进行系统化和结构化的整理；处理相关数据，以及应用适当的分析方法揭示规律和提供解决方案。最终目标是全面解答问题一，为解决方案提供科学依据。

5.1 问题分析

问题一：区域碳排放量以及经济、人口、能源消费量的现状分析

问题一的核心要求是建立一个能够衡量区域双碳目标社会发展水平的指标体系，并根据该指标体系中的指标，以及 2010 年-2020 年区域历史数据（包括经济与能源数据表、经济与能源拆分表、碳排放表以及碳排放拆分表四个表格数据），完成对 2010-2020 年区域的碳排放量、经济、人口和能源消费量现状的分析，分析出影响该地区碳排放量的各个因素及其影响程度，进而判断该地区实现双目标面对的主要挑战同时为该地区双碳路径规划中差异化的路径选择提供依据。

通过题目进行分析，根据题目的内容，该题含有为三个子问题，接下来将会对三个子问题进行步骤拆分：

子问题一：建立指标与指标体系——立标准

- 1) 建立人口、经济、能源、碳排放相关指标集；
- 2) 筛选人口、经济、能源、碳排放的核心指标；
- 3) 构建指标体系结构模型；

子问题二：分析区域碳排放量以及经济、人口、能源消费量的现状——审数据

- 1) 根据 2010 年-2020 年区域人口、经济、能源以及碳排放的历史数据，结合子问题一中建立的指标体系，以 2010 年的各项数据为基准线，进行现状分析；
- 2) 进行人口、经济、能源对碳排放核心指标的影响分析；
- 3) 根据 Kaya 模型，针对碳达峰（ $\delta CO_2=0$ ）和碳中和（ $\delta CO_2<0$ ）两个目标，对未来区域内发展进行分析；

子问题三：对区域碳排放量以及经济、人口、能源消费量各指标进行分析并建立关联模型——审数据、相关性分析

- 1) 比较不同时间段各项指标的变化程度；
- 2) 进行指标间的相关性分析并建立关联关系模型；
- 3) 确定能源利用效率（单位 GDP 能耗）和非化石能源消费比重（非化石能源与总能源消耗量的比重），方便进行后期的碳排放量预测。

5.2 指标与指标体系

指标体系 (Indicator System) 是指将多个指标按照一定关系构成一个整体。指标与指标体系是个体与系统的关系。指标体系是数据分析的一项基本技能，借助指标体系，可以将业务逻辑化，精确地定位问题、分析问题。

5.2.1 指标与指标体系构建原则

1. **系统全面性原则**：所创建的碳排放量指标体系是根据系统思想所创建的，因此，整个指标体系是一个整体完整的系统体系。具体而言，所创建的各个指标之间是有机有序的，同时能够全面准确的反映碳排放量以及人口、经济、能源耗费量的真实情况。并且，选取的指标应该适量，不能过少过多，因此选取的指标必须具有相当程度的代表性，从而以尽可能少的指标反映尽可能多的信息。

2. **可计量性可行性原则**：对于所选取的指标，它们应该是能够量化的，即是可以测量或者具有可简介计量的性质。具体地讲，选取的指标可以在统计资料中获得或者通过现有的资料经过计算得出。即使是定性的指标，也应该可以通过一定的转化过程进行量化。此外，对于量级不同的指标，其统计口径也应该通过数学方法达到一致。

3. **主题相关性原则**：所选取的指标应该能体现碳排放量以及人口、经济、能源耗费量的真实情况，突出重点，防止与其他评价指标体系雷同。

4. **动态调整型原则**：碳排放量以人口、经济、能源耗费量系统本身是一个动态变化的过程，因此其评价指标体系也应该根据实际情况进行相对应的变化。一般而言，其动态调整性原则体现在两个方面：指标选取的动态调整型；指标权重的动态调整型。根据经济发展、社会要求、技术进步等等因素的变化，进行分析，确定删除或者增加指标或者对现有指标进行权重的调整。

5.2.2 指标体系的确立

指标体系在某些情况下可以按照不同的层次进行划分，常见的划分方式包括宏观层、关联层和调控层，这种层级结构可以帮助人们从整体到具体地了解和析指标，从而更好地理解系统或领域的状态和变化趋势。不同层次的指标相互关联，通过对多层指标的综合考量，可以形成全面的指标体系。

碳排放指标体系是对一个区域碳排放量以及人口、经济、能源消费量实际情况进行客观评价的手段和工具。为了系统地分析一个区域的碳排放量以及人口、经济、能源消费量的实际情况，围绕影响碳排放的主要因素，根据查阅的文献资料和结合本题的具体情况，基于碳达峰和碳中和是宏观调控总目标，人口、经济、能源、碳排放调发展是核心思想，进行系统结构建模，构造出能够综合描述并评估区域内各方面发展现状的评价体系。

具体结构如图所示：




图 5 双碳社会发展分析与评估指标体系结构-模型结构图

宏观层为**宏观调控指标**，用于衡量区域内双碳目标是否实现；关联层为**关联模型指标**，用于衡量人口-碳排放、经济-碳排放、能源、碳排放之间的关系、子系统层为**人口、经济、能源、碳排放子系统内部指标**，用于衡量区域人口子系统、区域经济子系统、区域能源子系统、区域排放子系统的内部趋势。

1) 宏观层指标体系的构建

根据题目的要求，宏观层的指标需要分析出该区域社会大致发展情况以及该区域内的

双碳目标是否完成，所以主要分为了四个指标，如下表所示：

表 6 宏观层指标集

	指标计名称
人口发展指标	人口增长率
经济发展指标	人均 GDP 总量
能源消费优化指标	单位 GDP 能耗
碳排放优化指标	碳排放强度

综合而言，我们希望随着人口发展，经济发展，即人口增长率稳定，人均 GDP 总量增加时，单位 GDP 能耗能够降低，碳排放强度降低，为实现这些指标可以分析内部子系统的各项指标并进行调控，以期实现最终的区域双碳。

2) 子系统层内部指标体系的构建

通过分析双碳社会发展评估指标体系结构中人口子系统、经济子系统、能源子系统和碳排放子系统内部的指标体系，我们给出了如下的指标集：

表 7 内部指标集

子系统名称	一级指标	二级指标
1. 区域人口	1.1 人口发展指标	<u>1.1.1 人口数量</u> 1.1.2 人口增长率
2. 区域经济	2.1 经济数量指标	<u>2.1.2 GDP</u> <u>2.1.2. 人均 GDP</u> 2.1.3 GDP 增长率 2.1.4 人均 GDP 增长率
	2.2 经济结构指标	2.2.1 三个产业 GDP 总量 2.2.2 三个产业 GDP 占比 2.2.3 各部门 GDP 占比 2.2.4 各部门 GDP 总量
	2.3 经济效应指标	2.3.1 三个产业的 GDP 增长值 2.3.2 三个产业增加值的增加率 2.3.4 各部门产业 GDP 增长值 2.3.5 各部门产业增加值增加率
3. 区域能源	3.1 能量总量指标	<u>3.1.1 能源消费总量</u> <u>3.1.2 人均能源消费总量</u>
	3.2 能源结构指标	3.2.1 三个产业分别的能耗总量 3.2.2 各部门的能耗 3.2.3 居民生活能耗总量 3.2.4 三个产业能耗占比 3.2.5 各部门能耗占比

		3.2.6 居民生活能耗占比 3.2.7 化石能源消费分量及总量 3.2.8 非化石能源消费量 3.2.9 新能源电力消费总量 3.2.10 其他新能源消费总量 3.2.11 外地补充电力能源总量 3.2.12 发电能源消耗量 3.2.13 非发电能源消耗量 <u>3.2.14 非化石能源消费比重</u>
	3.3 能源效率指标	<u>3.3.1 能源消费强度</u>
4. 区域碳排放	4.1 碳排放总量指标	4.1.1 碳排放总量 4.1.2 人均碳排放总量
	4.2 碳排放结构指标	4.2.1 三个产业碳排放总量 4.2.2 各部门碳排放总量 4.2.3 居民生活消费碳排放总量 4.2.4 人均生活碳排放总量
	4.3 碳排放强度指标	<u>4.3.1 单位能耗二氧化碳排放量</u>

表格给出了人口、经济、能源、碳排放各个子系统内部的指标体系，子系统中的大部分指标体系属于统计性数据，用于直观地分析区域内人口、经济、能源以及碳排放的实际状况，小部分属于综合性指标，如能源消费强度（单位 GDP 能耗）、碳排放强度等等。

其中人口子系统的核心指标为人口数量；

经济子系统的核心指标为 GDP 总量与人均 GDP 总量；

能源子系统的核心指标为能源消费总量、人均能源消费总量、能源消费强度、非化石能源消费比重；

碳排放子系统的核心指标为碳排放总量、人均碳排放总量、碳排放强度。

5.2.3 四个子系统分析

1) 区域人口子系统

根据本题所给的数据分析，2010~2020 年，该区域人口数量不断增长，由 2010 年的 7800 多万增加到 2020 年的 8400 多万。





图 2 区域人口子系统指标

另一方面，虽然人口的数量在不断的增长，但是人口的自然增长率总体趋势是逐渐下降的，由 2010 年的接近 2% 降至 2020 年的接近 0%。我国人口继续保持低速增长态势，其结果如图 6 所示。

2) 区域经济子系统

2010~2020 年 GDP 总量逐步增加,但是 GDP 总量增长率持下降趋势,2014 年和 2015 的 GDP 总量增长率近乎持平，到 2020 年 GDP 总量增长率快下降到 3%(如图 3)。

2010~2020 每个产业的 GDP 都有增加，其中第一产业增加值最少且增加得越来越缓慢，第一产业增加值增长率近乎为 0，第二产业增加值排第二，增加值增长率越来越慢且第二产业权重值越来越低,第三产业 GDP 增加值最多且第三产业权重值越来越重(如图 8)。2010~2020 年中农林消费部门、能源供应部门和交通消费部门增长值占比很小，建筑消费部门增长值和工业消费部门增长至占大头且建筑消费部门增长值占比稳步增加，与此同时工业消费部门的产业占比缓慢下降，详情如下图 9。






图 9 经济效应指标（部门相关）




图 10 能源消耗总量和碳排放增长率




图 11 人口总数与人均单位排放量

3) 区域能源子系统

在人口数量和 GDP 稳定增加的情况下，能源消耗总量并没有稳定增加，还在一些年份出现了负增长，碳排放增长率在 2010~2020 期间，碳排放增长率在 0% 附近，这与政府秉承走绿色发展、可持续发展道路，使用新能源有关。虽然能源消耗总量现在还是巨大的，但是在政府的领导下，我相信能源消耗总量能控制到一个可观的范围内，详情如图 11。

4) 区域碳排放子系统

随着人口的增加，人均单位排放量并没有稳定的增加（注意：这里的人均单位排放量指的是与人口居民相关的人均生活碳排放量），在 2010~2013 期间人均单位排放量稳步增加，在 2013 年达到小峰值后下降，应与当时的国务院在 2014 年发布的节能减排低碳发展行动有关——为确保全面完成“十二五”节能减排降碳目标，规定在 2014-2015 年，单位 GDP 二氧化碳排放量两年分别下降 4%、3.5% 以上[1]。居民人口逐年增加，居民排放总量并没有稳步增加，大致呈正相关关系，随着人口数量的增长碳排放量也随之增长，人口数量增多，则相应的工业、电力、交通等方面的需求也会随之增长，这必然会导致更大的能源需求，进而导致更多的碳排放量（图 12）。2014 年能达到局部“低谷”与当时的政策有关。




图 12 居民排放总量和人均单位排放量

根据数据分析，经济增长是碳排放量增加的重要因素。据 IPCC 的报告和 2010 年世界发展报告，经济发展和温室气体排放紧密相关并且通过对高、中、低收入的国家的人均碳排放量进行测量比较，发现随着收入的增加，碳排放量也随之增加。

由于中国经济体正处于繁荣增长时期，其碳排放总量也呈上升趋势。本题所涉及的区域，如图 13 所示，碳排放量和 GDP 呈现一种正相关关系，碳排放与 GDP 的增长态势趋同。这是由于经济发展极度依赖能源的消耗，从而导致了碳排放量的增加。2011-2013 年这三年的碳排放总量与 GDP 总量不太匹配，调查显示[2]：2013 年中国碳排放超过欧盟和美国的总和，达到 100 亿吨，与此同时，中国的人均碳排放量首次超过欧盟，2013 年后中国碳排放曲线趋平缓。




图 13 碳排放总量和 GDP 总量之间的关系

5.2.4 关联层指标体系的构建

为了更好地建立关联层各个关联模型的指标体系，通过查询相关文献，分析人口子系统、经济子系统、能源子系统和碳排放子系统相互之间的潜在联系，我们以碳排放子系统为中心，分析人口-碳排放、经济-碳排放、能源碳排放的关系，绘制了图 14，反应出了各个子系统之间存在的主要联系。




图 14 关联模型图

日本经济学家加谷多朗·卡尔 (YoiC02hi Kaya) 于 1993 年提出 Kaya 模型是一种用于分析人口、经济增长、能源消费和碳排放之间关系的经济学模型，并被广泛应用于评估

和预测碳排放量的变化，它可以更准确地表述了四者之间的潜在联系，其公式如下：

$$CO_2 = P \times \frac{GDP}{P} \times \frac{E}{GDP} \times \frac{CO_2}{E},$$

可描述为：碳排放量 = 人口 × 人均 GDP × 能源强度 × 碳强度。

CO_2 指的是**碳排放量**，P 指的是人口数量，人口发展核心指标，考虑人口数量对碳排放的影响。增加人口通常会导致能源消耗的增加，从而增加碳排放量；

$\frac{GDP}{P}$ 指的是**人均 GDP**，是经济发展核心指标，考虑经济活动对能源消耗和碳排放的影响。经济增长通常伴随着能源需求的增加，从而对碳排放产生影响；

$\frac{E}{GDP}$ 指的是**能源消费强度**，可衡量单位 GDP 产生的能源消耗水平，较低的碳强度表示使用更清洁的能源来源，如可再生能源，以减少碳排放，是能源消费优化的核心指标；

$\frac{CO_2}{E}$ 指的是**碳排放强度**，可衡量单位能源消耗所产生的碳排放量（能源消费的碳排放因子），较低的碳强度表示使用更清洁的能源来源，如可再生能源，以减少碳排放，是碳排放优化的核心指标。

Kaya 模型的优点是简单易懂并能提供定量分析的结果。然而，它也有一些局限性，例如没有考虑到技术进步和政策因素对碳排放的影响。因此，在我们将会在子问题三中完成对各子系统核心指标的关联关系分析，从而对模型进行扩展和改进，以提高其准确性和可靠性。

关联层中关联模型的具体指标会在关联关系模型分析部分给出。

5.3 区域碳排放量以及经济、人口、能源消费量现状分析

从碳排放、经济、人口和能源消耗量现状进行分析

1) 碳排放量现状

随着人口增长，经济发展，十三五期间碳排放量比十二五期间的碳排放量比总体要高。除 2011 年外，十三五期间的排放和十二五期间的碳排放增长率在 0 附近，表明政府根据环境保护与经济、社会发展相协调的原则，大力发展生产力。分开来看：1.十二五期间，环境问题逐渐引起重视，由于中国和经合组织各国能源消耗模式的转变，全球能源行业排放的二氧化碳在 2014 年和 2013 年持平，这也是 40 多年来首次出现温室气体排放“停滞”并未伴随经济衰退的情况[3]。该地区的 2014 年的碳排放量形成一个局部“低谷”。随着经济的发展，碳排放量不可避免的增加，但碳排放增长率十分小接近于 0。2.十三五期间，碳排放总量缓慢增加，在 2018 年出现局部“低谷”，这是因为能源效率的提高，以及核电站重新投入使用后发电量增加，因此所有化石燃料排放量都出现下降。据《2018 年国民经济和社会发展统计公报》[4]来看,中国二氧化碳排放量再次上升，煤炭消耗是主要原因。根据图 15 的现状和“十四五”规划，猜测碳排放量在 2020-2025 年碳排放量与 2020 年相差不大，可能会因为经济发展的原因增加但也不会很多。

2) 经济现状

从总体来看，十二五期间和十三五期间 GDP 总量稳定增长，然而 GDP 增长率持续走低。解释如下：经济基数越来越大，GDP 增长率降低很正常，但我国的经济增量仍十分可观；增速放缓是一个发展中国家进入发达国家必经的路，中国正在从低附加值产品像高附加值产品转型。根据调查显示[5]，政府改为以就业创造为目标来调控宏观经济而不单只看 GDP 增长率，中国经济架构在往新型服务方向发展，这意味着，如果可以提供同等数量的就业岗位，不必再以更快的 GDP 增速为目标。根据图 16，2020-2025 年 GDP 值可能依旧

稳定增加，GDP 增长率较低但很稳定。

3) 人口现状总体来看十二五和十三五人口缓慢增长。十三五的人口增长率大体上比十二五人口增长率低。结合图 16 经济现状图和图 17 人口现状图来看人口增长率和 GDP 总量增长率成正相关趋势，由于人口老龄化的原因和现在人的婚姻观理念，预测人口会呈现负增长，可能会出现局部“低谷”但加上国家的干预，人口总量后来可能会缓慢增加。




图 15 碳排放量现状图

4) 能源消耗量现状

总体看在 GDP 稳定增长的情况下，从图 18 能源现状图看出能源消耗总量缓慢增加，但能源消耗消耗增长率逐步向 0 靠近。在十二五期间政府通过大力控制能耗致这段期间的能源增长率总体持下降趋势，十三五期间，2019 到达局部峰值，2020 年的能源增长率最低，预测未来几年会更加使用清洁能源、提高化石能源的效率，实现低碳转型。




图 16 经济现状图




图 17 人口现状图




图 18 能源现状图

5.4 碳排放主要因素影响分析

从部门角度、产业角度分析影响碳排放的主要因素。

1) 部门角度。农林部门的碳排放量最低，其次是建筑部门，碳排放量最高的是工业部门（如图 20 部门——碳排放量）。大力发展建筑部门和农林部门是和碳排放量具有积极关系的，通过图 19 部门产业增加值可知建筑部门的增长值也相当可观，可见其国民经济支柱产业地位稳固。工业部门的增加值和农林增加值差不多的情况下，农林排碳量小很多，未来可以大力发展农林部门。能源部门的排碳量为 0，在十三五期间能源增加值显著比十二五期间的增加值高很多，虽然能源增加值占比不大但是其排碳量为 0 且只有找到合适的替代新能源，才能在根本上解决碳排放量问题，应大力发展能源部门。居民的排碳量仅次于工业部门但工业部门相差很远，居民排碳量是不可避免的，但我们可以在生活中选择更加低碳的方式生活。发展工业部门和碳排放量具有消极关系，我们不可能去工业化倒退发展，但我们可以通过智能化来减少碳排放。




图 19 部门产业增加值

2) 产业角度。由于第二产业由工业部门和能源部门组成。从 21 产业——碳排放量由于能源部门直接排碳量为 0 即第二产业的排碳量全由工业部门产出且比其他产业高很多。第三产业的排碳量较少且 GDP 高，未来可以大幅度发展第三产业。




图 20 部门——碳排放量




图 21 产业——碳排放量

5.5 实现双碳目标的路径选择

从现状来看，该地区十三五期间的碳排放有两次碳排放增长率为负，在 2030 年前是有希望二氧化碳不再增加达到碳达峰的，可以在以下方面做出改变：1. 对于各部门来讲：农林部门可以通过植树造林退耕还林等方式抵销该地区产生的二氧化碳排放量。工业制造业作为污染程度最高的部门，是碳排放的主要来源，可以采取使用可再生能源和提高能源效率等方式。能源部门有电力和热力碳减排的责任，其碳排放的产生的排放量折算进其他部门。能源部门应研究如何用核能发电，如何大力推广使用可再生能源。建筑部门应实现建材低碳化，提高建筑能效水平。交通部门应推进公路转铁路和水路的运输方式并且运载工具应实现清洁能源化。居民日常生活中应节点环保，低碳出行。2. 政策把控：从宏观把控应坚定走绿色低碳发展道路，加大温室气体排放控制力度，大力发展新能源。对于碳排放量增长率大幅度增加的应采取惩罚机制。通过 kaya 模型来讲：政府应该控制人口数量但也要避免人口老龄化问题，在经济发展的同时尽量使用可再生能源和比较清洁的化石能源比如天然气，这样在人均 GDP 上升的同时尽可能同时控制碳排放量。

然而仅仅这样达到碳中和依旧比较困难。抵消二氧化碳的退耕还林的措施跟工业部门的碳排放比起来依旧杯水车薪，我们应该抓大头，实现工业脱碳。氢气可以替代化石能源作还原剂，但是绿氢的价格较昂贵，首要任务是如何降低绿氢的制作成本。与此同时，其他部门也应该注意化石能源的使用，若不能避免使用，可以使用天然气，其碳排放因子低，碳排放量相对较低。在工业中，如何降低绿氢价格是关键，其他行业应尽快找到可以替代的可再生能源。

5.6 区域双碳指标体系——关联关系模型分析

根据之间构建的指标体系，以及之前对区域各方面发展现状的分析，结合 Kaya 模型等式原理，我们可以显然发现人口发展水平、经济发展水平、能源结构优化水平等是影响一个地区碳排放的主要因素。因此在本节内容中，将结合该区域的实际情况从人口状况、经济增长、经济结构（三次产业及五个部门）、能源消费和能源消费品种结构（六种能源）等方面对该区域碳排放的影响因素进行分析。考虑到问题中的数据量较少，为明确各个指标之间的关联关系，本文综合统计学中的回归分析方法和灰色关联分析方法，对人口、经济、能源与碳排放进行两两关联分析。

5.7 关联模型分析方法简介

灰色关联分析（Grey Relation Analysis, GRA），是一种多因素统计分析方法，可

以通过计算关联度来量化两个指标序列之间的相关性程度[]。并且灰色关联分析方法适用于在信息不完全，也就是使用数据量少并且数据之间分布规律不明确的情况。

假设在指标系统中，存在如上 m 个指标，并根据相关的指标数据，构建出了相同长度，一一对应的指标序列组。

$$\begin{cases} X_1 = (x_1(1), x_1(2), \dots, x_1(n)), \\ X_2 = (x_2(1), x_2(2), \dots, x_2(n)) \\ \dots \\ X_m = (x_m(1), x_m(2), \dots, x_m(n)) \end{cases}$$

为研究系统中两两指标之间的相关关系，需要将从上述指标序列集中，选择某个用于参考的指标，并将其指标序列用作参考序列，比如现将指标 a 作为参考指标，那么序列 X_a 作为参考序列 Y ，而其他指标序列 X_i 作为比较序列。

$$\begin{cases} Y = Y(k), k = 1, 2, \dots, n \\ X_i = (x_i(k), k = 1, 2, \dots, n \end{cases}$$

由于数据之间的量纲不同，所以需要数据归一化处理，这里我们默认为数据已经完成归一化，所以直接计算两个指标之间的灰色关联系数，灰色关联关系的计算公式如下所示：

$$\zeta_i(k) = \frac{\min_i \min_k |y(k) - x_i(k)| + \rho \max_i \max_k |y(k) - x_i(k) + \rho|}{|y(k) - x_i(k)| + \rho \max_i \max_k |y(k) - x_i(k) + \rho|},$$

其中， $\zeta_i(k)$ 为 x_i 和 y 在 K 点的灰色关联度； $|y(k) - x_i(k)|$ 指的是在 Y 和 X 的在 K 点的二级最小值绝对差； $\min_i \min_k |y(k) - x_i(k)|$ 指的是 Y 和 X 在 K 点的二级最大差数绝对值， ρ 是灰色分辨系数，一般取值为 0.5。接下来将各个特征的关联系数带入公式就可以得到

$$r_i = \frac{1}{n} \sum_{k=1}^n \zeta_i(k),$$

5.7.1 人口-碳排放关联关系分析




图 22

根据上图，可以发现人口数量一直呈现逐年增长状态，但人口增长率呈现逐年下降趋势，导致人口数量上涨趋势变缓。

下图是碳排放总量与人口数量、人口增长率之间的散点图：




图 23 年份-人口增长率-碳排放总量




图 24 人口数量-碳排放总量

根据上图，我们猜测人口数量和碳排放总量存在一定的正相关非线性关系，可以看出随着人口数量的增加，碳排放总量有着明显的上升趋势，而随着人口增长率的下降，碳排放总量也呈现明显的下降趋势。为进一步确认人口数量与碳排放总量的相关性高低，本文通过计算皮尔逊系数，并进行显著性检验，最终得到统计学结果如下表所示：

表 8 人口-碳排放总量相关性分析

	P-CO ₂	P%-CO ₂
pearson 系数	0.8904643071014348	-0.7529348014046009
灰色关联度	0.570271	0.630006
P-value	0.0002376143781084	0.011948342962597122

P-CO₂ 皮尔逊系数¹为 0.89, P-value₂为 0.0002 < 0.01/0.05，人口数量（P）与碳排放（CO₂）之间存在强正相关关系，而人口增长率（P%）与碳排放之间存在中度的负相关关系。即人口数量的增加会导致碳排放的增加，但人口增长速度的变化可能对碳排放产生一定的减少影响。

5.7.2 经济-碳排放关联关系分析

根据图，可以发现GDP 总量与人均 GDP 总量一直呈现逐年增长状态，但 GDP 总量增长率和人均 GDP 总量增长率呈现逐年下降趋势，经济发展变缓。

1 皮尔逊系数（Pearson correlation coefficient）是一种衡量两个连续变量之间线性相关程度的统计量，常用于分析两个变量之间的关联关系。它的取值范围在-1 到 1 之间，其中取值为-1 代表完全负相关，取值为 1 代表完全正相关，取值为 0 代表没有线性关系。

2 P 值（P-value）是在统计假设检验中一个重要的指标，用于评估观察到的样本数据与原假设的一致程度。它表示假设检验结果的统计显著性。




图 25 经济-年份散点图




图 26 经济核心指标-碳排放

表 9 经济-碳排放总量相关性分析

	GDP-CO ₂	GDP/P- CO ₂	GDP%-CO ₂
pearson 系数	0.886559357519241	0.888270266319181	-0.84239037336418
灰色关联度	0.593067	0.593067	0.543235
P-value	0.000630481746045	0.000594569592693	0.002221844720972

根据以上内容，可以发现 GDP 总量与碳排放总量呈现正相关趋势，但 GDP 总量增长率和碳排放总量呈现负相关趋势。

接下分析经济产业结构与碳排放总量的关联关系。




图 27 各产业 GDP-碳排放总量

根据图，可以发现 GDP 总量与人均 GDP 总量一直呈现逐年增长状态，但 GDP 总量增长率和人均 GDP 总量增长率呈现逐年下降趋势，导致 GDP 总量上涨趋势变缓。

表 10 经济-碳排放总量相关性分析

	1-CO ₂	2-CO ₂	3-CO ₂	1%-CO ₂	2%-CO ₂	3%-CO ₂
pearson 系数	0.846162	0.881849	0.863010	-0.77139	-0.85095	0.850740
灰色关联度	0.584695	0.584695	0.584695	0.527457	0.666782	0.585547
P-value	0.001024	0.000329	0.000623	0.005429	0.000895	0.000900

根据表 10，可以发现 1%-CO₂(一产业增加值比重) 和 2%-CO₂(二产业增加值比重) Pearson 系数接近 -1，P 值均小于通常采用的显著性水平（例如 0.05），表示这两个经济指标与碳排放总量之间存在显著的负相关关系。这意味着随着一、二产业增加值比重的增加，碳排放总量会下降；反之，随着一、二产业增加值比重的减少，碳排放总量会增加。所以后续政策，应当注意调整产业结构比例，降低第三产业在经济发展中的比重，提高一、二产业在经济中的比重。




图 28 各部门 GDP-碳排放总量

根据图 28，可以发现农林部门 GDP 总量比重与碳排放总量呈现出相反，导致 GDP 总量上涨趋势变缓。

表 11 经济-碳排放总量相关性分析

	n1-CO ₂	ny-CO ₂	gy-CO ₂	jt-CO ₂	jz-CO ₂	n1%-CO ₂	ny%-CO ₂	gy%-CO ₂	jt%-CO ₂	jz%-CO ₂
pearson										
系数	0.85	0.87	0.88	0.91	0.85	-0.91	-0.26	-0.85	-0.74	0.83
灰色关										
联度	0.584	0.662	0.663	0.685	0.600	0.527	0.638	0.670	0.633	0.634
P-value	0.001	0.000	0.001	6.706	0.001	0.000	0.080	0.001	0.009	0.003

根据提供的数据分析结果显示，不同部门的 GDP 与碳排放之间存在着明显的正相关关系。农林部门 GDP（n1-CO₂）与碳排放的相关系数为 0.85，能源部门 GDP（ny-CO₂）与碳排放的相关系数为 0.87，工业部门 GDP（gy-CO₂）与碳排放的相关系数为 0.88，交通部门 GDP（jt-CO₂）与碳排放的相关系数为 0.91,但 P 值大于 0.05，无法确定二者之间存在相关性，建筑部门 GDP（jz-CO₂）与碳排放的相关系数为 0.85。另外，农林部门 GDP 占比与碳排放的相关系数为-0.91，表明农林部门在国民经济总量中所占比重越大，其对碳排放的贡献越小。

5.7.3 能源-碳排放关联关系模型分析




图 29 能源-年份散点图

根据上图，可以发现能源消费总量与人均能源总量一直呈现逐年增长状态，但近年来单位 GDP 能耗呈现逐年下降趋势，而非化石能源消费占比在逐年增加，从图中来看，二者和之间似乎存在负相关非线性关系。

考虑不同类型的能源消费产品对碳排放总量存在一定的影响，因为化石能源显然比非化石能源在消费时产生更多的碳排放量，为了更好地分析能源结构对碳排放量的影响，依据能源子系统中能源消费品的比重指标与碳排放量进行分析。




图 30 化石能源消费总量比重-碳排放总量




图 31 非化石能源消费总量比重-碳排放总量

其中非化石能源指的是考虑不同类型的能源消费产品对碳排放总量存在一定的影响，因为化石能源显然比非化石能源在消费时产生更多的碳排放量，为了更好地分析能源结构

对碳排放量的影响，依据能源子系统中两类能源消费品的比重指标与碳排放量进行分析，可以得出能源消费品种的选择对碳排放总量有着较为显著的影响。

表 12 能源-碳排放总量相关性分析

	H-CO ₂	F-CO ₂
pearson 系数	-0.87372	0.884562
灰色关 联度	0.726387	0.646230
P-value	0.000952	0.000674

六. 问题二：区域碳排放量以及经济、人口、能源消费量的预测模型

6.1 问题分析

本题的目标在于建立区域碳排放量以及经济、人口、能源消费量的预测模型。本题（1）要求建立基于人口和经济变化的能源消费量的预测模型，并且要求能源消费量与人口预测和经济预测相关联。求解思路：1）建立人口预测模型，预测 t 时的人口数量，如指数增长模型、逻辑增长模型、黄福涛模型、逻辑回归模型等等；2）建立经济预测模型，预测 t 时的 GDP 总量，如时间序列分析、ARIMA 模型；3）通过多元线性回归方程，将人口和 GDP 作为解释变量，而能源消费量作为响应变量，建立多元回归模型预测能源消费量，也可以使用其他的模型，如因果模型进行建模。

本题（2）要求建立区域碳排放量预测模型，且要求碳排放量与人口、GDP 和能源消费量预测相关联、碳排放量与各能源消费部门以及能源供应部门的能源消费量相关联以及碳排放量与各能源消费部门的能源消费品种以及能源供应部门的能源消费品种相关联。求解思路：1）建立区域碳排放量预测模型，利用多元线性回归，将人口、GDP 和能源消费量作为自变量，碳排放量作为应变量，建立多元线性回归方程；2）对于每个部门以及能源品种，将部门碳排放量作为应变量，建立多元线性回归模型。

6.2 人口预测与 GDP 预测

人口预测是一种利用统计数据和数学模型来估计未来人口数量和组成的方法。这项工作对于规划社会经济发展、制定政策以及资源分配具有重要意义。人口预测通常基于历史人口数据和当前社会变量，如出生率、死亡率和移民率等。通过分析过去的趋势和现有的因素，人口学家和统计学家可以建立模型来预测未来的人口变化。

在进行人口预测时，常用的方法包括线性回归、指数增长模型、几何增长模型和人口年龄结构模型等。这些模型可以帮助我们了解未来人口数量的趋势，并提供关于年龄、性别、地区和社会群体等方面的详细信息。

人口预测的结果对于能源消费量和碳排放量的预测非常重要，可以帮助决策者预测未来的能源消费量和碳排放量，为未来实现双碳目标和路径规划提供有价值的指导。然而，人口预测也存在一定的局限性。由于人口变动受到多种因素的影响，例如政策变化、经济波动和社会文化因素等，预测结果可能受到这些因素的影响而产生偏差。此外，人口预测通常只能提供一种可能性，而未来的人口变化仍然受到不确定性的影响。

尽管如此，人口预测作为一种重要的工具，仍然为决策者提供了对未来人口发展的基本了解，帮助他们做出更明智的决策，并为社会的可持续发展提供指导。

GDP（国内生产总值）预测是指对一个国家或地区的经济产出进行未来时间段的估计和预测。GDP 预测是经济学领域的重要研究内容之一，对政府、企业和投资者等具有重要的决策指导意义。

GDP 预测通常基于经济统计数据、历史数据、经济指标和其他相关因素进行分析和建模。预测模型可以使用多种方法，包括时间序列分析、回归分析、数据挖掘和机器学习等技术。预测模型的目标是通过分析过去的经济走势和现有的数据来预测未来的经济发展趋势。

因此，对人口和 GDP 的准确预测有助于对碳排放量的准确预测。

6.2.1 基于线性回归模型的人口和 GDP 预测

通过问题一的求解，可知人口数量、时间、GDP、能源消费量之间分别存在较好的相关关系，因此可以考虑建立线性回归模型来预测人口的数量、GDP 以及碳排放量。

人口与时间线性回归模型：人口与时间呈现出一种正相关关系。

设第 i 年的人口数量为 P_i ， t_i 表示第 i 年，可建立线性回归方程：

$$\begin{cases} P_i = at_i + b \\ \zeta \sim N(0, \sigma^2) \end{cases}$$

其中 a 是自变量系数， b 是常数项。

GDP 与时间线性回归模型：GDP 与时间呈现一种正相关关系。随着时间的推移，人口也随之增长。

设第 i 年的 GDP 为 G_i ， t_i 表示第 i 年，建立线性回归方程：

$$\begin{cases} G_i = at_i + b \\ \zeta \sim N(0, \sigma^2) \end{cases}$$

其中 a 是自变量系数， b 是常数项。

线性回归模型求解与验证：

根据本题所给的历史数据，可以求得人口与时间、GDP 与时间的线性回归方程：

$$\begin{cases} P_i = 58.86t_i - 108581.29 \\ G_i = 4873.31t_i - 9754167.65 \end{cases}$$

回归方程的拟合图如下所示：




图 32 回归方程拟合图可视化

模型检验：多元回归分析。

表 13 多元回归分析结果

	a	b	r^2	F	p
人口时间回归模型分析	58.86	-108581.29	0.9269	114.16	0.00000205
GDP 时间回归模型分析	4873.30	-9754167.65	0.9989	8528.04	0.00000001

注： r^2 判定系数，F 值统计量，P 值统计量， a 和 b 是回归方程系数。

从多元回归分析分析，可知提出的回归方程能够人口和 GDP 实现比较准确的拟合，从统计量分析，提出的线性回归模型是显著性较高，通过了显著性检验，说明拟合程度较好，接受假设，模型可行。




图 33 回归方程残差图可视化

6.2.2 基于 logistic 的人口预测模型

实际情况中，某区域人口增长到一定数量后，人口增长率会降低，这是由于外部因素和内部因素阻滞了人口的增长，并且随着人口的增加，这种阻滞作用会越来越明显，Logistic 模型就是基于这种情形提出的人口预测模型。

模型建立：设 $P(t)$ 为时间 t 时的区域人口数量， r 为人口增长率且随着人口的增长而降低，则 r 是 $P(t)$ 的函数，表示为 $r(P)$ ，且为减函数，可得微分方程表达式：

$$\frac{dP(t)}{d(t)} = r(P)P(t), P(0) = P_0$$

假设 $r(P)$ 为 P 的线性函数

$$r(P) = r_0 - sP, (r_0, s > 0)$$

其中 r_0 是固有增长率，表示人口很少时的增长率。区域能够容纳的最大人口数量为 P_m ，称为人口容量。当 $P=P_m$ 时人口就不再增加，即增长率为 0，可得

$$s = \frac{r_0}{P_m}$$

然后，结合前面的公式得到

$$r(P) = r_0 \left(1 - \frac{P(t)}{P_m}\right)$$

代入微分方程中可得

$$\frac{dP(t)}{d(t)} = r_0 \left(1 - \frac{P(t)}{P_m}\right) P(t), P(0) = P_0$$

其中， $rP(t)$ 体现的是人口自身的增长趋势， $\left(1 - \frac{P(t)}{P_m}\right)$ 体现了内外因素对人口增长的阻滞作用，需要指

出 r_0 是固有增长率，是一个常数。当人口数量 $P(t)$ 越大， $rP(t)$ 就越大， $\left(1 - \frac{P(t)}{P_m}\right)$ 越小，因此人口的增

长由两个因子共同决定。

利用分离变量法求解微分方程得到形式解：

$$P(t) = \frac{P_m}{1 + (\frac{P_m}{P_0} - 1)e^{-rt}}$$

其中， P_m 是区域的人口容量， P_0 是初始人口数， r 是固有增长率， t 是时间。

Logistic 模型求解与分析：




图 34 Logistic 模型结果可视化

上图中左边的图是 Logistic 模型的拟合曲线图，根据结果可知其拟合效果较好，说明模型性能良好。右边的图是预测曲线，是一条 S 形曲线，拐点在 $P=P_m/2$ ，其反映了当人口增加到一定程度后增长缓慢，这是符合生物学的种群数量特征的，因为一个区域能够容纳的种群数量是有限的。

6.2.3 基于灰色预测模的人口与 GDP 预测




图 35 灰色预测流程图

灰色预测从数学本质上来讲是一个微分方程，其预测的对象是灰色系统。根据原始数据，通过累加等方式削弱随机性，获得有规律的新序列，从而建立相应的微分方程模型，得到离散点出的解，进而通过累减的方式求得原始数据的估计值，实现对原始数据预测。其一般流程如下图所示。

灰色模型： 可将历史人口和 GDP 数据视为原始序列，通过灰色预测求得一个新的序列实现对人口的预测。灰色预测的第一步，确定原始数据使用 GM(1,1)的可行性，即对原始数据进行级比检验。

假设原始序列为

$$P^0 = (p_1^0, p_2^0, \dots, p_n^0)$$

这里，原始序列即是 2010-2020 年的人口数量或者 GDP 序列。

计算数列的级比进行验证，数列级比的计算方式为

$$\varpi(k) = \frac{P_{k-1}^0}{P_k^0}, k = 2, 3, \dots, n$$

如果 $\varpi(k) \in (e^{-\frac{2}{n+1}}, e^{\frac{2}{n+1}})$ ，则说明可以使用灰色预测模型，否则需要进行平移变换或者更换模型。

通过可行性检验： 设灰色预测得到的序列为

$$P^1 = (p_1^1, p_2^1, \dots, p_n^1)$$

这里的序列是原始的序列进行累加得到一个序列，即灰色预测拟合的序列。由此可以建立对应的微分方程

$$\frac{dP^1(t)}{dt} + aP^1(t) = b$$

其解为

$$P^1(t) = (P^0(1) - \frac{b}{a})e^{-at} + \frac{b}{a}$$

于是通过模型可以得到的新的预测序列为

$$\hat{P}^1(t) = (P^0(1) - \frac{b}{a})e^{-ak} + \frac{b}{a}, k = 1, 2, \dots, n-1$$

从而实现对人口数量的预测。

6.2.4 灰色预测模型求解与检验

模型求解： 灰色预测模型的求解可以使用最小二乘法，求出方程中的未知参数的估计值。最小二乘法求出参数后，将参数代入原方程，求出微分方程的形式解，进而可以求出 $k=1, 2, \dots, n-1$ 的拟合值，然后进行预测。

灰色预测模型的拟合结果如图所示。




图 36 灰色预测模型拟合可视化

模型检验：模型求解之后，需要对模型进行检验，模型检验就是看求得的拟合值和实际值的差距是否在合理范围内。

相对误差检验：

$$\varepsilon(k) = \frac{|P^0(k) - \hat{P}^0(k)|}{P^0(k)}$$

如果 $\varepsilon(k) < 0.2$ ，则可以认为达到了一般要求，如果 $\varepsilon(k) < 0.1$ ，则可以认为达到了较高要求。

级比偏差检验：

$$\rho(k) = 1 - \frac{1 - 0.5a}{1 + 0.5a} \varpi(k)$$

同理， $|\rho(k)| < 0.2$ ，则可以认为达到了一般要求，如果 $|\rho(k)| < 0.1$ ，则可以认为达到了较高要求。




图 37 灰色检验结果可视化

从检验结果来看，模型以非常高的要求通过了误差检验。说明本文构建的模型是及其科学合理的，可以用于人口数量预测。对于 GDP 预测，误差检验虽然没有达到人口预测的误差检验的要求，但是也以高要求通过。因此灰色预测模型是适用于两者。

6.2.5 基于 LSTM 模的人口与经济预测




图 38 LSTM 结构图

LSTM 是一种用于处理序列数据的深度学习模型。**LSTM** 模型具有特殊的结构和机制，使其能够更好地捕捉和记住长期依赖关系。它通过引入称为“门控单元”的组件来实现这一点。门控单元由三个关键部分组成：遗忘门、输入门和输出门。

遗忘门控制记忆的丢弃程度，决定哪些信息需要被保留下来。输入门负责决定当前时刻新的输入应该如何整合到记忆中。输出门则控制着从 **LSTM** 单元中提取多少记忆要传递给下一个时间步。通过这种门控机制，**LSTM** 能够有效地处理长序列，并且可以学习长期依赖关系，例如在自然语言处理中处理长句子、翻译任务、语音识别等领域。

LSTM 模型在训练过程中使用反向传播算法和梯度下降来更新模型的权重，以最小化预测输出与实际输出之间的差异。它可以通过多层堆叠来构建更复杂的模型，并且在各种序列数据的建模任务中取得了广泛的成功。

总而言之，**LSTM** 模型是一种专门用于处理序列数据、克服传统 RNN 梯度消失或梯度爆炸问题的深度学习模型。

LSTM 模型：

$$\begin{aligned}
 j_k &= \sigma(W_j \cdot [h_{k-1}, x_k] + b_j) \\
 \begin{cases} f_k = \sigma(W_f \cdot [h_{k-1}, x_k] + b_f) \\ \tilde{D}_k = \tanh(W_d \cdot [h_{k-1}, x_k] + b_d) \end{cases} \\
 o_k &= \sigma(W_o \cdot [h_{k-1}, x_k] + b_o) \\
 \begin{cases} D_k = f_k * D_{k-1} + j_k * \tilde{D}_k \\ h_k = o_k * \tanh(D_k) \end{cases}
 \end{aligned}$$

其中公式中第一个公式代表输入门，第二组两个公式代表遗忘门，第三个公式代表输出门，

第四组两个公式分别代表长记忆和短记忆。

人口预测特点:人口数量和单个或多个指标均有关系,或者说和一个或多个特征有内在的联系,例如经济,能源消费量等等,这属于多输入,单输出的 LSTM 神经网络预测范畴,因此可以考虑使用 LSTM 模型进行人口数量的预测。

数据预处理:本题所给的数据包含多个与人口关联的指标,有些指标的字段需要经过处理才可以传入模型进行训练.此外,为了消除不同场景下不同指标的差异,对数据进行归一化处理,这里可以采用下面的方式进行归一化处理:

$$x = \frac{X - \min(X)}{\max(X) - \min(X)}$$

其中,X 为原始数据中的原始值,min(X)和 max(X)分别为样本数据的最大值和最小值。

划分数据:将归一化后的数据划分为训练,验证,测试集三个部分,设置合理的比例。

LSTM 预测人口和 GDP:将本题所给的历史数据在进行相关性分析,数据处理之后,确认数据中的目标值(这里指总人口或总 GDP),然后进行数据集划分、归一化之后,进行训练。训练完成后,用训练完成的模型进行预测任务。

5.2.6 基于组合加权的人口与经济预测模型

为了提高预测的精度,可以使用集中模型的组合加权进行预测人口数量或者 GDP。

模型建立:设 $\hat{P}_i$ ($i=1,2,3\dots m$) 是某个问题通过 m 种方法所得到的预测结果,注意每种方法要通过格子的检验要求, P_{ij} 则是第 i 种方法对历史数据 P_i 的模拟值。那么,根据这种方式可得到的预测值如下所示:

$$Pre = \sum_{i=1}^m w_i \hat{P}_i$$

其中 $\sum_{i=1}^m w_i = 1, \forall w_i \in [0,1]$ 。

则可设 $e_{ij}=P_{ij}-P_j$ 表示第 i 种方法和第 j 个历史数据模拟值之间的误差,则根据这样的设定,可得到如下矩阵:

$$E_j = \begin{bmatrix} e_{1j}^2, e_{1j}e_{2j}, \dots, e_{1j}e_{mj} \\ e_{2j}e_{1j}, e_{2j}^2, \dots, e_{2j}e_{mj} \\ \vdots \\ e_{mj}e_{1j}, \dots, \dots, e_{mj}^2 \end{bmatrix}$$

设 loss 表示损失,则 loss 计算公式如下:

$$\begin{aligned} loss &= \sum_{j=1}^n (pre_j - p_j)^2 \\ &= \sum_{j=1}^n (w_1 \hat{y}_{1j} + \dots + w_m \hat{y}_{mj})^2 \\ &= \sum_{j=1}^n (w_1 e_{1j} + \dots + w_m e_{mj})^2 \\ &= \sum_{j=1}^n W^T E_j W \end{aligned}$$

由此，预测问题转化为了一个约束优化问题，loss 最小时即可得到一个性能优异的预测模型。

模型求解：

根据本题的要求，转化后的问题即为，目标函数 loss 最小化，约束条件为权重之和为 1，且任意的权重不小于 0，不大于 1。这个问题可以看作一个多目标规划问题，但是直接利用多目标规划进行求解，运算量过大，因此可以考虑启发式算法求解参数。

粒子群算法（Particle Swarm Optimization, PSO）是一种基于群体智能的优化算法，用于解决连续优化问题。它模拟了鸟群或鱼群等群体在搜索过程中的行为，通过不断地更新粒子的位置和速度来寻找最优解。

PSO 算法的基本思想是，将待优化问题转化为粒子在搜索空间中的移动过程。每个粒子代表一个解，其位置表示解的当前状态，速度表示解的搜索方向和速度。粒子根据自身的历史最优解和群体的历史最优解进行位置和速度的调整，从而逐步靠近最优解。

粒子群算法简单且易于实现，不需要对目标函数进行求导或者设置复杂的约束条件，同时具有较强的全局搜索能力、稳定可靠、适用面广。




图 39 粒子群算法

实际应用中，粒子群算法已经被广泛应用于优化问题的求解，如函数优化、神经网络训练、组合优化等领域。它通过模拟群体智能的行为，有效地提高了优化问题的求解效率。

组合加权预测模型本质上是一个组合优化问题，因此可以适用粒子群算法进行优化。

粒子群算法求解：

1. 参数初始化：组合加权模型涉及的变量为 $W=(w_1,...,w_m)$ ，即组合涉及的每个模型的权重系数，可以设置为随机的 0 到 1 之间的数。

2. 计算初始的适应度，对于本题来说，适应度即 loss，如下所示：

$$loss = \sum_{j=1}^n (pre_j - p_j)^2 = \sum_{j=1}^n W^T E_j W$$

其中，最优解对应的是 loss 的最小值。

3. 求解初始全局最优解：将第 i 个个体的最优解记作 $PersonBest_i$ ，比较所有的最优个体解，找到最小的个体最优解，作为全局最优解 $GlobalBest_i$ 。

4. 更新粒子的速度：

$$v_i = \alpha v_i + c_1(PersonBest_i - w_i) + c_2(GlobalBest_i - w_i)$$

其中， α 代表惯性因子， c_1 和 c_2 代表个体倾向和群体倾向的权重。 α 偏大时，有利于全局搜索，但是收敛性变差；偏小时，有利于局部搜索，但运算时间会增加。 c_1 偏小，不利于学习个体经验， c_2 偏小，不利于学习群体经验。

因此，必须根据问题来设置合理的参数。参数最理想的情况，可以实现在前期粒子比较分散的时候，进行全局搜索避免陷入局部最优解，而在后期的时候，粒子较为集中，进行局部搜索的时候求解更加精确。因此，可以采取权重线性递减、自适应权重、随机权重等方法改进粒子群算法的性能和效果。

5. 更新位置并且求适应度：即更新新的可行解，求解新的可行解条件下的 $loss$ 。假设时间设为 1，则有：

$$w_i^t = w_i^{t-1} + v_i^{t-1}$$

其中 t 代表迭代的次数。

6. 更新个体最优解和群体最优解，然后新一轮迭代，直到达到终止条件，输出群体最优解和对应的适应度，即最佳的权重系数组合和最小的 $loss$ 。

6.3 能源消费量预测模型

6.3.1 线性回归模型

根据问题一分析结果，可知人口与能源消费量由比较明显的线性关系，因此可以建立线性回归模型。同样地，能源消费量与 GDP 也具有明显 de 线性关系，因此同样可以建立线性回归模型。

能源消费量-人口线性回归模型：设第 i 年的能源消费量为 E_i ，第 i 年的人口数量为 P_i ，线性回归方程如下：

$$\begin{cases} E_i = aP_i + b \\ \zeta \sim N(0, \sigma^2) \end{cases}$$

其中 a 是自变量系数， b 是常数项。

能源消费量-GDP 线性回归模型：设第 i 年的能源消费量为 E_i ，第 i 年的 GDP 为 G_i ，线性回归方程如下：

$$\begin{cases} E_i = aG_i + b \\ \zeta \sim N(0, \sigma^2) \end{cases}$$

其中 a 是自变量系数， b 是常数项。

模型求解：根据本题所给的历史数据，求得 $a=11.9153029812401, b=-69552.0038900305$,因此可得到人口与能源消费量和 GDP 与能源消费量的回归方程：

$$\begin{aligned} E_i &= 11.91P_i - 69552.003 \\ E_i &= 0.1453G_i + 19513.98 \end{aligned}$$

模型检验：多元回归分。 r^2 表示判定系数， F 值统计量， P 值统计量。

表 14 多元回归分析结果

	a	b	r^2	F	p
能耗总量-人口线性回归模型	11.91	-69552.003	0.9359	131.55	0.00000113
GDP-能耗总量线性回归模型	0.1453	19513.98	0.8859	69.86	0.0000155

模型结果：回归方程拟合结果如下。




图 40 回归方程拟合可视化




图 41 回归模型残差分析图

根据多元回归分析结果，相关系数 r^2 为 0.9359，是个非常大的数，这说明回归方程十分显著。F 值越大说明方程越显著，拟合程度也就越好。P 值远远小于 0.05，表明假设是正确的，接受原假设。

能源消费预测结果：预测 2021 年到 2030 年的能源消费量，基于不同的人口或者经济预测模型，得到结果如表所示。

表 15 能源消费量预测结果

基于不同 的人口预 测模型	线性回归模型			Logistic 模型		
	人口 (万人)	能源消费 量	GDP	能源消费 量	人口	能源消费 量
2021	8627.78	33250.71	94782.85	33292.64	8512.60	31878.31
2022	8686.65	33952.15	99656.15	34001.07	8522.79	31999.70
2023	8745.52	34653.60	104529.46	34709.51	8530.71	32094.07
2024	8804.39	35355.05	109402.76	35417.95	8536.87	32167.40
2025	8863.26	36056.50	114276.07	36126.38	8541.65	32224.36

2026	8922.13	36757.94	119149.38	36834.82	8545.36	32268.59
2027	8981.00	37459.39	124022.68	37543.25	8548.24	32302.92
2028	9039.87	38160.84	128895.99	38251.6	8550.48	32329.57
2029	9098.74	38862.28	133769.29	38960.13	8552.21	32350.26
2030	9098.74	39563.73	138642.60	39668.56	8553.56	32366.3

6.3.2 BP 神经网络模型

BP 神经网络是一种按照误差逆向传播算法训练的多层前馈神经网络。BP 网络由输入层、隐藏层、输出层组成，从输入层到隐藏层，传播形式如下

$$\alpha_h = \sum_{i=1}^d v_{ih} x_i + \theta_h$$

从隐藏层到输出层为

$$\beta_j = \sum_{h=1}^q w_{hj} b_h + \theta_j$$

假设第一个神经元的输出为

$$y_1 = b_1 * w_{11} + \dots + b_q * w_{q1} + \theta_1$$

可以求解出 y_2 到 y_l , l 为输出神经元的个数，如图所示。




图 42 BP 神经网络图示

然后通过计算输出层与期望值之间的误差来调整网络参数，使得误差变小，计算误差方式：

$$e = \frac{1}{2} \sum_{k=1}^2 (y_k - T_k)^2$$

然后通过梯度下降法优化网络，求解出模型。

模型求解与结果分析：梯度下降法进行求解。解能源消费量预测值的结果如下所示。




图 43 bp 神经网络预测可视化

从图像来看，模型的表现效果优秀，能够较好的拟合历史数据并且进行预测，且预测的结果误差较小。

模型验证：

表 16 模型评估结果

	MSE	RMSE	MAE	MAPE	R ²
训练集	761911.397	872.875	770.895	2.886	0.857
测试集	734316.904	856.923	694.344	2.297	0.775

从 R^2 的来看，在训练集和测试集上都达到了较高的要求，说明模型的效果表现优秀，从前面四个指标来看结合上面拟合图来看，该模型在能源消耗量的预测上表现卓越。

5.3.3 XGBoost 模型

XGBoost 主要是用于有监督学习问题，此类问题利用包含多个特征的训练数据，来预测目标变量。XGBoost 模型一般形式，假设有 m 个特征 x_i ，该模型就是利用这些特征预测标签值 y_i ，模型可以表示为

$$y_i = \sum \theta_j x_{ij}$$

这是一个线性模型，这里， y_i 代表能源消费量， x_{ij} 代表用于能源消费量预测的特征，本题中指指标体系中的相关指标。

由此，可以构建一个目标函数

$$Obj(\theta) = L(\theta) + \Omega(\theta)$$

即目标函数， L 表示训练误差函数， Ω 表示正则项，训练误差用于衡量模型在训练数据上的预测能力，最典型的用 $L2$ 范数，表示形式如下

$$L(\mathcal{Y}) = \sum (y_i - \hat{y}_i)^2$$

根据设定的目标函数，然后利用 XGBoost 进行求解。能源消费预测可以将与能源消费量有关的一个或者多个指标视为特征，能源消费总量视为标签值，即可利用 XGBoost 搭建一个能源消费预测模型。

模型求解与检验：结果如下所示。




图 44 XGBoost 预测能源消费量可视化

从拟合结果来看，模型的性能表现优越，能够较好的拟合数据，实现对能源消费量的预测。

从模型评估的结果看来，与上图的表现结果相一致，如表所示。

表 17 模型评估结果

	MSE	RMSE	MAE	MAPE	R ²
训练集	3093.347	55.618	32.772	0.107	0.999
测试集	2189844.071	1479.812	1023.394	3.628	0.734

模型评估表中前面四个指标均是越小越好，越小说明预测的精度越高。从 R² 的结果来看，在训练集上可以说是比较完美的拟合，在测试集上的效果要稍微差一点，但是这可能和数据量太少有关系，在当前的数量拟合到这种程度，说明模型是有效的。

6.4 区域碳排放量预测模型

6.4.1 多元线性回归模型

多元线性回归模型是指含有多个自变量一个应变量的线性回归模型，其描述了应变量和多个自变量之间的线性关系。本题涉及碳排放量的因子有多个，并且基于建立的指标与指标体系，通过分析可知碳排放量与这些因子存在线性关系，尤其是重要的影响因子，如人口、经济、能源耗费用等等。因此可以建立多元线回归模型来预测碳排放量。

多元线性回归模型：其数学形式如下

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + e$$

该公式表示数据中应变量可以近似地表示为自变量 $x_1, \dots, x_n$ 的线性函数。其中 β_0 为常数项， $\beta_1, \dots, \beta_n$ 是偏回归系数，其代表的意义为当其他项不改变时，某个自变量改变时对应变量 y 的影响程度， e 是去掉 n 个自变量后对 y 影响后的随机残差。

根据本题的要求， $x_1, \dots, x_n$ 表示的是指标体系除碳排放量之外的其他指标，其值为某个时期对应指标的大小。

设 $x_1, \dots, x_n$ 表示的含义如表所示:

表 18 多元回归方程自变量的含义

符号	含义
x_1	常驻人口数量/年
x_2	GDP 总量/年
x_3	能源消费量/年
x_4	非化石能源消费比重/年
x_5	非化石能源发电比重/年
x_6	农林消费部门能耗总量/年
x_7	工业消费部门能耗总量/年
x_8	交通消费部门能耗总量/年
x_9	建筑消费部门能耗总量/年
x_{10}	居民生活消费能耗总量/年
x_{11}	能源供应部门消费量/年

多元线性回归模型求解: 一般步骤,

1. 利用历史数据求解偏回归系数, 用最小二乘法求解如下

$$Q = \sum (y - \hat{y})^2$$
$$= \sum (y - (\beta_0 + \beta_1 x_1 + \beta_2 x_2 \cdots + \beta_n x_n))^2$$

其中 Q 代表均方误差。对上式求偏导数得到

$$\begin{cases} \beta_1 l_{11} + \beta_2 l_{12} \cdots + \beta_n l_{1n} = l_1 y \\ \beta_1 l_{21} + \beta_2 l_{22} \cdots + \beta_n l_{2n} = l_2 y \\ \dots\dots\dots \\ \beta_1 l_{m1} + \beta_2 l_{m2} \cdots + \beta_n l_{mn} = l_m y \end{cases}$$
$$\beta_0 = \bar{y} - (\beta_1 \bar{x}_1 + \beta_2 \bar{x}_2 \cdots + \beta_n \bar{x}_m)$$

进而可得到

$$l_{ij} = \sum (x_i - \bar{x}_i)(x_j - \bar{x}_j), i, j = 1, 2, \dots, m$$
$$l_{jT} = \sum (x_j - \bar{x}_j)(y - \bar{y}), i, j = 1, 2, \dots, m$$

2. 求解得到估计的参数, 得到回归方程;

3. 检验并评价回归方程以及各自变量的作用大小, 假设检验及其评价方式可用显著性检验, 包括方差分析法、决定系数、负相关系数。

模型检验: 线性回归分析结果表明模型无效, 因此不能使用多元线性回归分析。线性回归分析详细结果, 如下表所示。

表 19 多元线性回归分析结果

线性回归分析结果 n=11								
常数	非标准化系数		标准化系数	t	P	VIF	R ²	调整 R ²
	B	err	Beta					
	13856.76	None	-	0	NaN	-	1	F=None P=NaN

x1	-6.869	None	-0.284	0	NaN	292406616.338
x2	-1.687	None	-5.636	0	NaN	104826293334.198
X3	-496.467	None	-256.084	0	NaN	
x4	-569545.19	None	-2.204	0	NaN	526798412372.265
x5	971749.064	None	1.514	0	NaN	45461974979.261
x6	454.328	None	3.497	0	NaN	
x7	498.996	None	158.8	0	NaN	
x8	568.551	None	44.656	0	NaN	
x9	423.178	None	14.283	0	NaN	
x10	549.761	None	40.167	0	NaN	
x11	502.092	None	74.069	0	NaN	

因变量：碳排放总量

注：***、**、*分别代表 1%、5%、10%的显著性水平

6.4.2 岭回归模型

岭回归模型：多元线性回归模型无效，是由于求解参数特征之间存在多重共线问题，使得使用最小二乘法估计系数会出现系数不稳定的问题，缺乏稳定性和可靠性。

因此对多元线性回归模型进行改进得到岭回归模型，通过将不适定问题转化为适定问题，岭回归模型即在 RSS 的基础上加入了对系数的惩罚项，变为：

$$Q = \sum (y - \hat{y})^2 + \lambda \sum_{j=0}^n \beta_j^2$$

其中 λ 是超参数，用来控制惩罚强度，越大说明生成的模型越简单。

模型求解：结果如下所示。岭迹图以可视化的方式展示了本次模型的各个自变量的标准化系数区域稳定时的情况。




图 45 岭迹图

模型验证：岭回归分析。

表 20 岭回归分析结果

K=0.147	非标准化系数		标准化系数	t	R ²	调整 R ²	F
	B	标准误差	Beta				
常数	8515.373		-				
X1	1.736		0.072				
X2	0.021		0.07				
X3	0.387		0.199				
X4	9721.063		0.038				
X5	89650.488		0.14				
X6	1.123		0.009		0.983	1.167	-5.351(NaN)
X7	0.363		0.115				
X8	0.736		0.058				
X9	4.632		0.156				
X10	1.128		0.082				
X11	2.308		0.34				

结果显示，显著性检验表明水平上并无显著性，接受原假设，说明自变量和因变量之间不存在回归关系，同时，模型的 R² 的结果表明模型的拟合程度极高，模型性能表现优秀。

根据结果，可得到碳排放量的预测公式为：

$$\text{Carbon} = [8515.373, 1.736, 0.021, 0.387, 9721.063, 89650.488, 1.123, 0.363, 0.736, 4.632, 1.128, 2.308]X$$

其中 $X=[x_1,x_2,...,x_{11}]^T$ ，其含义和多元回归分析中含义相同。

模型结果：模型的拟合效果如图所示。




图 46 岭回归模型拟合效果可视化

根据岭回归模型预测 2021-2030 年的碳排放结果如下表所示。

表 21 岭回归模型预测结果

时间/年	2021	2022	2023	2024	2025
碳排放量	78569.43	76885.23	77964.03	74865.55	75246.8
时间/年	2056	2057	2058	2059	2060
碳排放量	67978.06	66382.69	66155.38	65284.66	64528.81

6.4.3 XGBoost 模型

XGBoost 模型：理论说明参照 6.3.3 节。

模型求解结果：模型预测结果如下所示。




图 47 XGBoost 预测碳排放量可视化

从可视化的结果来看，XGboost 表现效果总体来说尚可，可能是由于数据量过小导致的模型拟合效果表现较差。




图 48 特征重要性可视化

从特征重要性结果来看，影响碳排放量的最重要的特征为人口数量、能源消费总量，所占据的比例高达 100%以上，但是由于数据量较少，这个结果的可信度还不够高。

模型验证：结果如表下所示。

表 22 模型评估

	MSE	RMSE	MAE	MAPE	R ²
训练集	9889.541	99.446	59.526	0.081	0.999
测试集	16688720.506	4085.183	2492.055	3.752	0.118

评估模型采用了几种指标评价模型，前面四个指标均是值越小越好，最后一个指标值越大越好，可以从表中看出模型在训练集上的拟合效果非常好，但是在训练集上的效果也表现的良好。

6.4.4 bp 神经网络模型

BP 神经网络模型：理论，参照 6.3.2 节。

模型验证：模型的评估，评估结果如下表所示。

表 23 模型评估结果

	MSE	RMSE	MAE	MAPE	R ²
训练集	0	0.016	0.013	0	1
测试集	4406922.895	2099.267	1942.414	2.897	0.821

在训练集和测试集上，R² 分别为 1 和 0.821，说明模型的准确度相当之高，这点和前面的可视化测试结果是一致的，尤其在训练集上，MSE 和 MAPE 都为 0，这说明模型在训练集上的拟合程度极其准确。评估结果表明模型是可信的，能够用于区域碳排放量的预测。

模型求解结果：拟合效果如下图所示。




图 49 BP 神经网络拟合效果可视化

从拟合图来看，BP 神经网络实现了对区域碳排放量比较精准的预测。

七. 问题三：区域双碳目标与路径规划方法

7.1 问题分析

根据问题所设定的目标，2030 年达到碳达峰，2060 年实现碳中和，要求设计出不同的情景。基于此，可以设计自然、基准、雄心三种情景。自然情景表示没有其他因素干预，如认为、政策等，在当前趋势下自然的发展。基准情景表示按照政策要求，按时达到双碳目标。雄心情景表示，有其他因素的干预，例如政策、技术进步等，提前实现双碳目标。对于各部门的能源消费量及其碳排放量采用问题二中建立的模型进行预测。确定对应时间点的 GDP、人口和能源消费量目标，并将其与提高非化石能源消费比重等相关联，确保达到双碳目标的路径与措施相吻合。对能效提升、产业升级、能源脱碳等措施进行定量定性分析，确定实现双碳目标的路径。

7.2 情景设计

情景一：自然情景。区域未来的发展趋势按照当前的发展趋势推进，没有其他新的因素干预，例如政策、技术进步等等。整个区域是一个稳定的相对封闭的系统。

情景二：基准情景。由于需要在指定的时间节点达到相对应的目标—2030 年达到碳中和和 2060 年达到碳中和，因此需要根据实际情况制定相应的政策和措施来保证目标的实现。

情景三：雄心情景。该情景下设定更加积极的目标，例如 2025 年达到碳达峰与 2050 年实现碳中和。因此相比基准情景，需要更多的政策和措施的干预，例如技术进步要求、产业升级措施、能源结构调整等等。

7.3 多场景核算碳排放量

基本假设：

- 1.2035 年的 GDP 比 2020 年翻一番，2060 年比 2020 年翻两番；
- 2.2060 年生态碳汇的碳消纳量为 2020 年的碳排放量的 10%；
- 3.2060 年工程碳汇或碳交易的碳消纳量为 2020 年碳排放量 10%。

7.3.1 自然场景

计算人均 GDP:

自然场景下，根据所给的基本假设 1，可以进行线性插值计算，得到 2020 到 2060 年的 GDP 数据，然后计算不同时间点的人均 GDP。由于自然场景下，后续的发展趋势是按照当前的发展趋势（问题二所得到的关联模型）推进。因此，可以通过问题二中建立的模型对人口、能源消费量等进行预测。

通过线性插值运算，得到的 2020-2060 年的 GDP 数据如图 100 所示。




图 50 自然情景 2020-2060 年的 GDP 数据

已知 2021-2060 年的 GDP 总量，可以通过问题二中建立的模型预测能源消费量，预测方式如下所示：

$$E_i = 11.91P_i - 69552.003$$
$$E_i = 0.1453G_i + 19513.98$$

因此，接下来可以计算人均 GDP，方式如下：

$$\text{人均 GDP} = \text{GDP 总量} / \text{人口总量}$$

计算部分结果如表所示：

表 24 人均 GDP 计算部分结果

	2021	2030	2035	2040	2050	2060
能耗总量	33258.69	40990.09	45285.32	50439.59	60748.12	71056.66
GDP 总量	118244.28	147805.35	177366.42	212839.71	283786.28	354732.85
人口总量	8632.30	9281.45	9642.09	10074.86	10940.39	11805.93
人均 GDP	10.95	15.92	18.39	21.12	25.93	30.04

单位 GDP 能耗预测：

根据题目所给的资料，单位 GDP 能耗的计算公式为：

$$G_{\text{单位GDP能耗}} = \frac{E_{\text{总能耗}}}{G_i}$$

其中总能耗计算公式表示为：

$$E_{\text{总能耗}} = E_{\text{第一产业能耗}} + E_{\text{第二产业能耗}} + E_{\text{第三产业能耗}} + E_{\text{生活能耗}}$$

其中每个加项的可表示为：

$$\begin{cases} E_{\text{第一产业能耗}} = E_{\text{第一产业增加值}} * E_{\text{第一产业单位增加值能耗}} \\ E_{\text{第二产业能耗}} = E_{\text{第二产业增加值}} * E_{\text{第二产业单位增加值能耗}} \\ E_{\text{第三产业能耗}} = E_{\text{第三产业增加值}} * E_{\text{第三产业单位增加值能耗}} \\ E_{\text{生活能耗}} = E_{\text{总能耗}} * E_{\text{生活能耗比重}} \end{cases}$$

对于 GDP，可以表示为：

$$G_i = G_{\text{总增加值}} = G_{\text{第一产业增加值}} + G_{\text{第二产业增加值}} + G_{\text{第三产业增加值}}$$

经过推理，可以得到最终的表达式如下：

$$G_{\text{单位GDP能耗}} = (G_{\text{第一产业增加值权重}} * E_{\text{第一产业单位增加值能耗}} + G_{\text{第二产业增加值权重}} * E_{\text{第二产业单位增加值能耗}} + G_{\text{第三产业增加值权重}} * E_{\text{第三产业单位增加值能耗}}) / (1 - E_{\text{生活能耗比重}})$$

利用推导得到的公式，计算出部分重要节点单位 GDP 能耗的值如表所示。

表 25 单位 GDP 能耗预测

	2021	2030	2035	2040	2050	2060
单位 GDP 能耗	0.2812	0.2773	0.2553	0.2369	0.2140	0.2003

Kaya 模型计算碳排放量：

根据本题所给的资料，Kaya 模型的数学表示为：

$$C_i = P_i \times G_{i_avr} \times E_{i_avr} \times E_{i_co_2}$$

其中公式从左至右分别为二氧化碳排放量、人口、人均 GDP、单位 GDP 能耗、单位能耗二氧化碳排放量。对于单位能耗二氧化碳排放量，可以根据本题所给的数据中的碳排放因子进行判定。因此，可计算自然情况下的碳排放量，重要时间节点结果如表所示。

表 26 自然场景碳排放量核算

时间/年	人口	单位 GDP 能耗	人均 GDP	单位能耗二氧化碳排放量	碳排放量
2021	8632.30	0.2812	10.95	2.17	57678.73
2030	9281.45	0.2773	15.92	2.08	85225.99
2035	9642.09	0.2553	18.39	2.19	99139.75
2060	11805.93	0.2003	30.04	1.63	115789.36

7.3.2 基准场景

基准情景下，2035 年达到碳达峰，2060 年达到碳中和，分别意味着碳排放量增长率为 0 和小于 0，且大概率为远远小于 0。关键点就在于找到碳排放量增长率的数学表达式。

基于基本假设 1，可以确定各个时间点的 GDP 总量。同样地，基于 Kaya 模型进行求解：

$$C_i = P_i \times G_{i_avr} \times E_{i_avr} \times E_{i_co_2}$$

对等式两边进行求微分，则有

$$\frac{dC_i}{dt} = a \frac{dP_i}{dt} + b \frac{dG_i}{dt} \frac{1}{P_i} + c \frac{dE_i}{dt} \frac{1}{G_i} + d \frac{dC_i}{dt} \frac{1}{E_i}$$

其中 a,b,c,d 分别为常数，表达式如下所示：

$$\begin{cases} a = \frac{G_i}{P_i} \frac{E_i}{G_i} \frac{C_i}{E_i} = \frac{C_i}{P_i} \\ b = P_i \frac{E_i}{G_i} \frac{C_i}{E_i} = P_i \frac{C_i}{G_i} \\ c = P_i \frac{G_i}{P_i} \frac{C_i}{E_i} = G_i \frac{C_i}{E_i} \\ d = P_i \frac{G_i}{P_i} \frac{E_i}{G_i} = E_i \end{cases}$$

因此，公式重构为

$$\frac{dC_i}{dt} = \frac{C_i}{P_i} \frac{dP_i}{dt} + \frac{dG_i}{dt} \frac{C_i}{G_i} + \frac{dE_i}{dt} \frac{C_i}{E_i} + \frac{dC_i}{dt}$$

根据前面的分析，设 $\frac{dC_i}{dt} = 0$ ，即为碳达峰的状态。基于问题二的模型，进行求解，得出部分结果如下表所示：

表 27 基准情景总碳排放核算

时间/年	碳排放量预测	各部门之和	变化率
2021	76375.79	76954.63	0.00752
2030	79867.96	80568.59	0.0087
2035	80414.59	79854.67	0.00696

从表 400 的结果来看，变化率均小于 0.01，说明其服从一致性。从计算所有结果来看，大部分结果变化率小于 0.01，因此可以认定碳排放核算模型与问题二中预测模型一致。

表 28 基准场景双碳目标目标值预测

时间/年	2025	2030	2035	2060
能源消费	38374.68	45812.4	5847.25	730257.61
非化石比重	0.2945	0.4238	0.5757	0.805
单位 GDP 能耗	0.3271	0.3204	0.3247	0.2521

7.3.3 雄心场景

针对雄心情景，可以在基准情景的场景下进行更进一步的分析。将基准场景下所得到的各项指标数据作为新的样本，然后计算 2020-2060 年的平均变化率，计算方式为

第*i*年与第*i-1*年的人口增长率=（第*i*年人口 - 第*i-1*年的人口）/第*i*年人口
依次求解直到 2060 年，然后将所有求得的结果取均值，得到基准情景下的平均增长率，记作 ∇P 。

雄心场景设定下，需要提前实现双碳目标，而人口和碳排放量呈现一种正相关关系，因此，为了满足雄心场景，需要降低人口的增长率，可以将人口增长率设置为递减型或者平均增长率缩小，这样就可以更加积极的达到双碳目标。而控制人口可以从政策方面着手，这就体现出了雄心情景下积极的政策干预。

表 29 基准场景双碳目标目标值预测

时间/年	2025	2030	2035	2060
人口	8295.36	8554.25	8715.06	8848.69
GDP	136485.9	188648.82	215696.43	375209.58
能源消费	34587.20	42016.47	46508.64	72684.65
非化石比重	22.9%	30.56%	45.64%	96.70%
单位 GDP 能耗	0.0124	0.01012	0.00756	0.00159

从表 230 可知，雄心场景下通过产业升级、技术进步实现，因此，需要提高非化石能源的消费比重，这就需要更高的技术创新。

7.4 双碳目标与路径规划模型

基于问题二和问题三前面所得到的模型和结果。可建立双碳目标与路径模型：

$$\left\{ \begin{array}{l} E_i = 11.91P_i - 69552.003 \\ E_i = 0.1453G_i + 19513.98 \\ Carbon = [8515.373, 1.736, 0.021, 0.387, 9721.063, 89650.488, \\ \quad 1.123, 0.363, 0.736, 4.632, 1.128, 2.308]X \\ C_i = P_i \times G_{i_avr} \times E_{i_avr} \times E_{i_co_2} \\ \frac{dC_i}{dt} = 0, t = 2035 \\ \frac{dC_i}{dt} << 0, t = 2060 \end{array} \right.$$

其中 E_i 代表某年的能源消费量，上述公式中利用**线性回归模型**来进行预测（可以用其他方式，如 **BP 神经网络甚至组合加权方式**），此外根据问题二中的求解，能源消耗量可以结合人口(P_i)和 GDP(G_i)的预测模型一起使用。Carbon 代表二氧化碳的排放量，这里使用**岭回归模型**进行预测，这样可以清楚明确的知道各个指标的影响大小。

模型求解结果如表所示：

表 30 目标值预测

时间/年	2025	2030	2035	2060
人口	8395.64	8964.97	9015.06	10548.6
GDP	126365.79	178968.92	203846.69	356419.85
能源消费	35676.18	41625.74	46658.49	70624.56
非化石比重	18.9%	27.56%	39.44%	91.20%
单位 GDP 能耗	0.0169	0.0126	0.01052	0.00359

从目标值预测结果来看，人口、GDP 和能源消费量随着时间的推移逐渐增多，根据问题二建立的模型和问题三的多场景下的碳排放量核算，可知三者的增加会导致碳排放量的增多，因此为了实现碳中和的目标，必然需要制定相应的措施。

从表 30 的结果可知，实现双碳目标时，非化石比重的能源占比随着时间的推移逐步增长，而非化石能源的占比提升能够有效降低温室气体排放量，即能够降低碳排放量。

这表明，要实现双碳目标，需要对能源结构进行调整，增加清洁能源的使用，减少化石能源的直接利用。

这也为实现双碳目标提供了政策制定的指导。

从表 30 可知，在实现双碳目标的过程中，单位 GDP 能耗随着时间的推移逐渐下降。单位 GDP 能直接反映经济发展对能源的依赖程度、产业结构情况等等。因此，其下降说明了实现双碳目标的过程中产业结构在不断的升级，对经济的依赖程度降低，而这意味着碳排放量的降低。

这就为实现双碳目标提供了依据，为制定措施提供了指导。

因此，实现双碳目标的路径需要：1）增加非化石能源的比重，减少化石能源的直接使用，这需要技术的创新；2）进行产业结构的升级，这也需要技术的创新；3）为了实现前两个目标，需要政策的保障，因此需要制定相应的政策激励产业结构升级和创新。

八. 模型评价

8.1 模型优点

1. 全面系统的分析：针对问题建立了一套科学合理的指标与指标体系，能够正确的反映某区域的碳排放量现状，找出了各个指标之间的关系，并针对此建立相应的数学模型来实现对未来碳排放量的预测，为双碳目标和路径的规划研究提供了数学依据。设立了多种情景进行讨论，确保了问题的全面解决。

2. 对数据进行了预处理，包括缺失值、异常值处理、归一化、标准化、规范化处理等措施，保证了数据的可信程度。同时利用这些数据对区域的碳排放量现状进行了详细的分析，找到了影响碳排放量的关键因素，并针对这些因素进行建模，来预测未来的碳排放量。

3. 多模型比较，针对同一个问题，考虑了多种模型，如多元线性回归、岭回归、灰色预测等等。为了利用多种模型的优点，引入了一种组合加权的多模型预测模型，实现了更高精度的预测。

4. 根据满足实际情况又简化建模，合理的设计了基本的假设。

5. 进行了情景设计，利用建立的模型进行多种情景下的碳排放核算，同时建立了相应的双碳目标和路径规划的模型，为实现双碳目标和路径规划提供了科学的依据。

8.2 模型缺点

1. 模型的复杂性，针对不同的问题建立了多种模型，甚至采用了多种模型组合的加权组合方式，增加了模型的复杂性，给模型的求解带来了一定的难度。

2. 建模的过程中，设定了多种假设，这些假设是不确定的，并且每种假设对所建立的模型影响程度也不同，如果关键的假设错了，这对整个模型是致命的。

3. 虽然设定了不同情景，并计算了不同的情景下的碳排放量，为实现双碳目标和路径提供了依据，但是情景设计是一个及其复杂的任务，因此，设计的情景是否合理也有待考证。

4. 模型的验证，虽然在本文对模型进行了数学意义上的验证，但是能不能应用于实际场景，参数是否合理仍有待考证。

总之，虽然模型仍然存在各种问题，但是建模的过程仍然具有意义，并且模型也能够为政策的制定提供一定指导意见。

参考文献

- [1] 中国政府网, 国务院办公厅印发《2014—2015 年节能减排低碳发展行动方案》, www.gov.cn, 2014-05-26 11:19。
- [2] 吴跃伟, 中国 2013 年碳排放量全球第一或促使能源结构加速调整 https://www.thepaper.cn/newsDetail_forward_1268328, 2014-09-23 22:10。
- [3] 天下财经, 2014 年全球碳排放量“停滞”中国功不可没 <https://m.jiemian.com/article/246531.html>, 2015 年 03 月 16 日 13:01。
- [4] 李岸, 国家统计局公布《2018 年国民经济和社会发展统计公报》, http://china.cnr.cn/xwwgf/20190228/t20190228_524525448.shtml, 2019-02-28 16:06:00
- [5] 中国青年报, 政府工作报告不设 GDP 增长目标意味着什么, https://www.gov.cn/zhengce/2020-05/23/content_5514166, 2020-05-23 13:12
- [6] 齐敏. 我国低碳经济发展水平的评价指标体系与评估研究[D]. 山东师范大学, 2011
- [7] 任峰, 龙定洪. 广东省碳排放量测算、影响因素分析及预测模型选择[J]. 生态经济, 2022, 38(05):21-27+32.
- [8] 谢莹莹. 江苏省碳排放峰值预测与控制研究[D]. 中国矿业大学, 2019.
- [9] 杨宗霖. 河北省“双碳”趋势情景预测及实现路径对策研究[D]. 华北电力大学, 2022.
- [10] Scientific Platform Serving for Statistics Professional 2021. SPSSPRO. (Version 1.0.11)[Online Application Software]. Retrieved from <https://www.spsspro.com>.
- [11] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[J]. ACM, 2016.
- [12] 周志华. 机器学习[M]. 清华大学出版社, 2016.
- [13] 刘超, 回归分析—方法、数据与 R 的应用, 高等教育出版社, 2019.
- [14] 许广月, “中国能源消费、碳排放与经济增长关系的研究,” 博士, 华中科技大学, 2010.
- [15] 许力飞, “我国城市生态文明建设评价指标体系研究,” 博士, 中国地质大学, 2014.
- [16] 冷雪, “碳排放与我国经济发展关系研究,” 博士, 复旦大学, 2012.
- [17] 王松全, “区域人口、资源、环境、经济与社会可持续发展的评价研究,” 硕士, 首都经济贸易大学, 2008.
- [18] 高鸣, 陈秋红, “贸易开放、经济增长、人力资本与碳排放绩效——来自中国农业的证据,” 农业技术经济, no. 11, pp. 101 - 110, 2014
- [19] 冯碧梅, “湖北省低碳经济评价指标体系构建研究,” 中国人口·资源与环境, vol. 21, no. 3, pp. 54 - 58, 2011.
- [20] 任福兵, 吴青芳, 郭强, “低碳社会的评价指标体系构建,” 科技与经济, vol. 23, no. 2, pp. 68 - 72, 2010.
- [21] 林峰. 辽宁省经济增长、能源消费与碳排放关系研究[D]. 东北财经大学, 2017.
- [22] 胡春春. 人口、经济、技术与碳排放: 基于灰色关联度模型的实证分析[J]. 企业经济, 2014(08):20-24.

附录

本题代码

```
clc,clear,close all;
% 涉及的数据：这里是 gdp(自) 和能源消费量(应)
X = [41383.87 45952.65 50660.20 55580.11 60359.43 65552.00 70665.71 75752.20 80827.71 85556.13
88683.21];%GDP
y = [23539.31 26860.03 27999.22 28203.10 28170.51 29033.61 29947.98 30669.89 31373.13 32227.51
31438.00];%能源消费量

% 线性回归模型
model = fitlm(X, y, 'Linear');

% 回归系数和截距
coefficients = model.Coefficients.Estimate;
slope = coefficients(2);
intercept = coefficients(1);

fprintf('回归系数（斜率）： %f\n', slope);
fprintf('截距： %f\n', intercept);

% 预测新数据点
new_data = 2030;
prediction = predict(model, new_data);
fprintf('新数据点的预测值： %f\n', prediction);

%regress 分析
x1=[ones(11,1) X'];
y1=y';
[b,bint,r,rint,stats]=regress(y1,x1);
%bint 是回归系数的区间估计，r 是残差，
% rint 是置信区间，
% stats 是用于检验回归模型的统计量，
% 有三个数值：相关系数 r^2，F 值，与 F 对应的概率 P，
% alpha 是显著性水平(缺省的时候为 0.05)。
% 相关系数 r^2 越大，说明回归方程越显著；
% 与 F 对应的概率 P
rcoplot(r,rint);%残差分析图
title('能源-GDP 回归模型残差图');
xlabel('数据');
ylabel('残差');
z=b(1)+b(2)*X';
figure;
```

```

plot(X',y,'rp',X',z,'b');
xlabel('GDP/万元');
ylabel('能源耗费');
title('GDP-能源散点图及回归线')

预测
gdp=[94782.85327 99656.15882 104529.4644 109402.7699 114276.0755 119149.381    124022.6865
128895.9921 133769.2976 138642.6032];%gdp
z1=b(1)+b(2)*gdp;
plot(gdp,z1);

clc,clear,close all;
% 涉及的数据：这里是人口(自)和能源消费量(应)
y = [7869.34 8022.99 8119.81 8192.44 8281.09 8315.11 8381.47 8423.50 8446.19 8469.09 8499.26];%人口
%X = [41383.87 45952.65 50660.20 55580.11 60359.43 65552.00 70665.71 75752.20 80827.71
85556.13 88683.21];%GDP
%y = [23539.31 26860.03 27999.22 28203.10 28170.51 29033.61 29947.98 30669.89 31373.13 32227.51
31438.00];%能源消费量
%y=[23539.31 26860.03 27999.22 28203.10 28170.51 29033.61 29947.98 30669.89 31373.13 32227.51
31438.00];%能源
X=[2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020];
%41383.87 45952.65 50660.2 55580.11 60359.43 65552 70665.70683 75752.20149 80827.71193
85556.13387 88683.21463

% 线性回归模型
model = fitlm(X, y, 'Linear');

% 回归系数和截距
coefficients = model.Coefficients.Estimate;
slope = coefficients(2);
intercept = coefficients(1);

fprintf('回归系数（斜率）： %f\n', slope);
fprintf('截距： %f\n', intercept);

% 预测新数据点
new_data = 2030;
prediction = predict(model, new_data);
fprintf('新数据点的预测值： %f\n', prediction);

%regress 分析
x1=[ones(11,1) X'];

```

```

y1=y';
[b,bint,r,rint,stats]=regress(y1,x1);
%bint 是回归系数的区间估计，r 是残差，
% rint 是置信区间，
% stats 是用于检验回归模型的统计量，
% 有三个数值：相关系数 r^2，F 值，与 F 对应的概率 P，
% alpha 是显著性水平(缺省的时候为 0.05)。
% 相关系数 r^2 越大，说明回归方程越显著；
% 与 F 对应的概率 P
rcoplot(r,rint);%残差分析图
title('能源-GDP 回归模型残差图');
xlabel('数据');
ylabel('残差');
z=b(1)+b(2)*X';
figure;
plot(X',y,'rp',X',z,'b');
xlabel('GDP/万元');
ylabel('能源耗费');
title('GDP-能源散点图及回归线')

预测
xxx=(2021:2030);
%xxx=[12966360142.719723    13058433637.074165    13151160940.845362    13244546696.70231
13338595580.281307    13433312300.420109    13528701599.393784    13624768253.151953
13818952898.630383];%指数 2021-2030
%xxx=[8627.788545    8686.658 8745.527455  8804.396909  8863.266364  8922.135818
8981.005273  9039.874727  9098.744182  9157.613636];%线性
%xxx=[8512.608965  8522.797164  8530.717362  8536.871515  8541.651652  8545.36348  8548.245112
8550.481847  8552.217775  8553.564888  8554.610189  8555.421246  8556.05052  8556.538737  8556.917504
8557.211351];%logistic
xxx=[94782.85327 99656.15882 104529.4644 109402.7699 114276.0755 119149.381
124022.6865 128895.9921 133769.2976 138642.6032];%gdp
z1=b(1)+b(2)*xxx;
plot(xxx,z1);

clc,clear,close all;
% 涉及的数据：这里是人口(自)和能源消费量(应)
X = [7869.34 8022.99 8119.81 8192.44 8281.09 8315.11 8381.47 8423.50 8446.19 8469.09 8499.26];%
人口
y = [23539.31 26860.03 27999.22 28203.10 28170.51 29033.61 29947.98 30669.89 31373.13 32227.51
31438.00];%能源消费量

% 线性回归模型

```

```

model = fitlm(X, y, 'Linear');

% 回归系数和截距
coefficients = model.Coefficients.Estimate;
slope = coefficients(2);
intercept = coefficients(1);

fprintf('回归系数（斜率）： %f\n', slope);
fprintf('截距： %f\n', intercept);

% 预测新数据点
new_data = 2030;
prediction = predict(model, new_data);
fprintf('新数据点的预测值： %f\n', prediction);

%regress 分析
x1=[ones(11,1) X'];
y1=y';
[b,bint,r,rint,stats]=regress(y1,x1);
%bint 是回归系数的区间估计， r 是残差，
% rint 是置信区间，
% stats 是用于检验回归模型的统计量，
% 有三个数值：相关系数 r^2， F 值， 与 F 对应的概率 P，
% alpha 是显著性水平(缺省的时候为 0.05)。
% 相关系数 r^2 越大，说明回归方程越显著；
% 与 F 对应的概率 P
rcoplot(r,rint);%残差分析图
title('能源-人口回归模型残差图');
xlabel('数据');
ylabel('残差');
z=b(1)+b(2)*X';
figure;
plot(X',y,'rp',X',z,'b');
xlabel('人口/万人');
ylabel('能源耗费');
title('人口-能源散点图及回归线')

预测
%线性
xxx=[8627.788545 8686.658 8745.527455 8804.396909 8863.266364 8922.135818 8981.005273
9039.874727 9098.744182 9157.613636];
%logistic
%xxx=[8512.608965 8522.797164 8530.717362 8536.871515 8541.651652 8545.36348 8548.245112
8550.481847 8552.217775 8553.564888 8554.610189 8555.421246 8556.05052 8556.538737 8556.917504

```

```

8557.211351];
    z1=b(1)+b(2)*xxx;
    plot(xxx,z1);

    clc,clear,close all;
    % 涉及的数据：这里是 Gdp 和 time
    y = [41383.87 45952.65 50660.20 55580.11 60359.43 65552.00 70665.71 75752.20 80827.71 85556.13
88683.21];%GDP
    X=[2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020];

    % 线性回归模型
    model = fitlm(X, y, 'Linear');

    % 回归系数和截距
    coefficients = model.Coefficients.Estimate;
    slope = coefficients(2);
    intercept = coefficients(1);

    fprintf('回归系数（斜率）： %f\n', slope);
    fprintf('截距： %f\n', intercept);

    % 预测新数据点
    new_data = 2030;
    prediction = predict(model, new_data);
    fprintf('新数据点的预测值： %f\n', prediction);

    %regress 分析
    x1=[ones(11,1) X'];
    y1=y';
    [b,bint,r,rint,stats]=regress(y1,x1);
    %bint 是回归系数的区间估计，r 是残差，
    % rint 是置信区间，
    % stats 是用于检验回归模型的统计量，
    % 有三个数值：相关系数 r^2，F 值，与 F 对应的概率 P，
    % alpha 是显著性水平(缺省的时候为 0.05)。
    % 相关系数 r^2 越大，说明回归方程越显著；
    % 与 F 对应的概率 P
    rcoplot(r,rint);%残差分析图
    title('时间-GDP 回归模型残差图');
    xlabel('数据');
    ylabel('残差');
    z=b(1)+b(2)*X';

```

```

figure;
plot(X',y,'rp',X',z,'b');
xlabel('GDP/万元');
ylabel('时间/年');
title('GDP-时间散点图及回归线')

预测
time=(2021:2030);
z1=b(1)+b(2)*time;
plot(time,z1);

//灰色预测
clc,clear
% x0=[7869.34 8022.99 8119.81 8192.44 8281.09 8315.11 8381.47 8423.50 8446.19 8469.09
8499.26]; % 注意这里为列向量
x0=[41383.87 45952.65 50660.20 55580.11 60359.43 65552.00 70665.71 75752.20 80827.71 85556.13
88683.21];
n=length(x0);
lamda=x0(1:n-1)./x0(2:n); % 计算级比
range=minmax(lamda); % 计算级比的范围
lamrange_min=exp(-2/(n+1)); % 允许的范围下界
lamrange_max=exp(2/(n+1)); % 允许的范围上界
% 原始数据的级比检验
if (range(1)>lamrange_min && range(2)<lamrange_max)
    fprintf("原始数据通过级比检验")
else
    fprintf("原始数据未能通过级比检验!!!")
return
end
最小二乘法求微分方程参数
x1=cumsum(x0) %累加序列
B=[-0.5*(x1(1:n-1)+x1(2:n)),ones(n-1,1)];
Y=x0(2:n);
% 注意此处是反斜杠，即左除
u=B\Y % 拟合参数 u(1)=a,u(2)=b
求解微分方程
syms x(t) %定义符号变量

%dsolve 求微分方程的符号解，即累加序列的函数表达式，而不是数值
x=dsolve(diff(x)+u(1)*x==u(2),x(0)==x0(1)); % diff 是一阶导或差分
xt=vpa(x,6) %以保留 6 位小数的格式显示微分方程的解,vpa 设置精度

% 函数 subs(x,t,[0:n-1])意味着把 t=0 到 t=n-1 依次代入 x 的表达式求出值
nihe1=subs(x,t,[0:n-1]); %求已知数据对应的拟合值

```

```

nihe1=double(nihe1);      %符号数转换成数值类型，否则无法作差分运算
nihe=[x0(1),diff(nihe1)] %差分运算，得到原始序列拟合值
yuce_result=double(subs(x,t,11))-double(subs(x,t,10)) % 原始序列的预测值，即第 8 年噪声
plot([2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020],nihe,[2010 2011 2012 2013 2014
2015 2016 2017 2018 2019 2020],x0);
title("灰色预测检验")
xlabel("时间/年");
ylabel("GDP/万元")
结果检验
相对误差检验和级比偏差检验

delta=abs((x0'-nihe )./x0') %计算相对误差
rho=1-(1-0.5*u(1))/(1+0.5*u(1))*lamda' %计算级比偏差值
aaa=[2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020];
bb=[0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2 0.2]
plot(aaa,delta,aaa,[0 rho],aaa,bb-0.15);
xlabel("时间/年");
ylabel("误差检验值")

//缺失值处理
% 读取数据文件
data = readtable('data.csv');

% 检查数据中是否存在缺失值
missing_values = sum(ismissing(data), 1);

% 打印出每列缺失值的数量
fprintf('缺失值统计：\n');
disp(missing_values);

% 检查是否有任何列包含缺失值
if any(missing_values > 0)
    fprintf('数据中存在缺失值。 \n');
else
    fprintf('数据中没有缺失值。 \n');
end

//线性插值
% 已知数据点
years = [2020, 2035, 2060];
g = [88683.21463, 2 * 88683.21463, 4 * 88683.21463];

```

```

% 插值的年份
newyears = (2020:2060);

% 插值函数计算新的 GDP 数据点
new_g = interp1(years, g, newyears, 'linear');

% 可视化结果
figure;
plot(years, g, '*', 'MarkerSize', 15, 'LineWidth', 10);
hold on;
plot(newyears, new_g, '-', 'LineWidth', 5);
xlabel('年份');
ylabel('GDP 总量');
title('2020-2060 年 GDP');
legend('已知数据', '插值数据');
grid on;

%计算人均 GDP
newei=0.1453*new_g+19513.98;
newPi=(newei+69552.003)/11.91;
figure;
plot(newyears,newei,'o');
xlabel('年份');
ylabel('能耗总量/人口总量');
title('2020-2060 年能耗与人口总量预测');
legend('能耗总量');
plot(newyears,newPi,'o','Color','r');
grid on;

gdpavr=new_g./newPi;

%单位 GDP 能耗计算
aaa=[33258.6940990.09 45285.32 50439.59 60748.12 71056.66];
bbb=[118244.28    147805.35    177366.42    212839.71    283786.28    354732.85];
ccc=aaa./bbb;

//logistic
% 已知数据点
years = [2020, 2035, 2060];
g = [88683.21463, 2 * 88683.21463, 4 * 88683.21463];

% 插值的年份
newyears = (2020:2060);

```



```

% 插值函数计算新的 GDP 数据点
new_g = interp1(years, g, newyears, 'linear');

% 可视化结果
figure;
plot(years, g, '*', 'MarkerSize', 15, 'LineWidth', 10);
hold on;
plot(newyears, new_g, '-', 'LineWidth', 5);
xlabel('年份');
ylabel('GDP 总量');
title('2020-2060 年 GDP');
legend('已知数据', '插值数据');
grid on;

%计算人均 GDP
newwei=0.1453*new_g+19513.98;
newPi=(newwei+69552.003)/11.91;
figure;
plot(newyears,newwei,'o');
xlabel('年份');
ylabel('能耗总量/人口总量');
title('2020-2060 年能耗与人口总量预测');
legend('能耗总量');
plot(newyears,newPi,'o','Color','r');
grid on;

gdpavr=new_g./newPi;

%单位 GDP 能耗计算
aaa=[33258.6940990.09 45285.32 50439.59 60748.12 71056.66];
bbb=[118244.28    147805.35    177366.42    212839.71    283786.28    354732.85];
ccc=aaa./bbb;

//LSTM
%matplotlib inline

# 导入 paddle
import paddle
import paddle.nn.functional as F

# 导入其他模块
import numpy as np
import pandas as pd

```

```

from matplotlib import pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings("ignore")
print(paddle.__version__)
import paddle.nn as nn

#数据处理
population = pd.read_csv("data.csv")
population.head()

#各自段的类型
population.dtypes

#数据可视化
from pylab import mpl
from matplotlib.font_manager import FontProperties
myfont=FontProperties(size=12)
sns.set(font=myfont.get_name())

from pylab import mpl
from matplotlib.font_manager import FontProperties
myfont=FontProperties(fname=r'/usr/share/fonts/fangzheng/FZSYJW.TTF',size=12)
sns.set(font=myfont.get_name())

titles = [
    "人口数量",
    "GDP 总量",
    "能源消费量",
    "碳排放量",
    "非化石能源消费比重",
    "化石能源消费总量",
    "农林部门能耗总量",
    "工业部门能耗总量",
    "交通部门能耗总量",
]

feature_keys = [
    "人口数量",
    "GDP 总量",
    "能源消费量",
    "碳排放量",
    "非化石能源消费比重",
    "化石能源消费总量",

```

```

    "农林部门能耗总量",
    "工业部门能耗总量",
    "交通部门能耗总量",
]

```

```

colors = [
    "blue",
    "chocolate",
    "green",
    "red",
    "purple",
    "brown",
    "darkblue",
    "black",
    "magenta",
]

```

```

date_time_key = "年份"

```

```

def show_raw_visualization(data):
    time_data = data[date_time_key]
    fig, axes = plt.subplots(
        nrows=3, ncols=3, figsize=(15, 15), dpi=100, facecolor="w", edgecolor="k"
    )
    for i in range(len(feature_keys)):
        key = feature_keys[i]
        c = colors[i % (len(colors))]
        t_data = data[key]
        t_data.index = time_data
        t_data.head()

        ax = t_data.plot(
            ax=axes[i // 3, i % 3],
            color=c,
            title="{0}".format(titles[i], key),
            rot=25,
        )
        ax.legend([titles[i]])
    plt.tight_layout()
show_raw_visualization(population)
corr = population.corr()
plt.figure(figsize=(10,10),dpi=100)
sns.heatmap(corr, square=True, linewidths=0.1, annot=True)

```

```

def split_windows(data, size):
    X = []
    Y = []
    for i in range(len(data) - size):
        X.append(data[i:i+size, :])
        Y.append(data[i+size, 2])
    return np.array(X), np.array(Y)

from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler()
scaled_train_data = scaler.fit_transform(train_data)
# 使用训练集的最值对测试集归一化，保证训练集和测试集的分布一致性
scaled_test_data = scaler.transform(test_data)
# 训练集测试集划分
window_size = 5
train_X, train_Y = split_windows(scaled_train_data, size=window_size)
test_X, test_Y = split_windows(scaled_test_data, size=window_size)
print('train shape', train_X.shape, train_Y.shape)
print('test shape', test_X.shape, test_Y.shape)

window_size = 5
fea_num = 10
batch_size = 5
class CNN_LSTM(paddle.nn.Layer):
    def __init__(self, window_size, fea_num):
        super().__init__()
        self.window_size = window_size
        self.fea_num = fea_num
        self.conv1 = paddle.nn.Conv2D(in_channels=1, out_channels=64, stride=1, kernel_size=3,
padding='same')
        self.relu1 = paddle.nn.ReLU()
        self.pool = paddle.nn.MaxPool2D(kernel_size=2, stride=1, padding='same')
        self.dropout = paddle.nn.Dropout2D(0.3)

        self.lstm1 = paddle.nn.LSTM(input_size=64*fea_num, hidden_size=128, num_layers=1,
time_major=False)
        # self.lstm2 = paddle.nn.LSTM(input_size=128, hidden_size=64, num_layers=1,
time_major=False)
        self.fc = paddle.nn.Linear(in_features=128, out_features=64)
        self.relu2 = paddle.nn.ReLU()
        self.head = paddle.nn.Linear(in_features=64, out_features=1)

    def forward(self, x):
        x = x.reshape([x.shape[0], 1, self.window_size, self.fea_num])

```

```

        x = self.conv1(x)
        x = self.relu1(x)
        x = self.pool(x)
        x = self.dropout(x)

        x = x.reshape([x.shape[0], self.window_size, -1])
        x, (h, c) = self.lstm1(x)
        # x, (h,c) = self.lstm2(x)
        x = x[:, -1, :] # 最后一个 LSTM 只要窗口中最后一个特征的输出
        x = self.fc(x)
        x = self.relu2(x)
        x = self.head(x)
        return x

# 定义超参数
base_lr = 0.005
BATCH_SIZE = 5
EPOCH = 50
lr_scheduled = paddle.optimizer.lr.CosineAnnealingDecay(learning_rate=base_lr, T_max=EPOCH,
verbose=True)
loss_fn = nn.MSELoss()
metric = paddle.metric.Accuracy()
opt = paddle.optimizer.Adam(parameters=model.parameters(), learning_rate=lr_scheduled, beta1=0.9,
beta2=0.999)
def process(data, bs):
    l = len(data)
    tmp = []
    for i in range(0, l, bs):
        if i + bs > l:
            tmp.append(data[i:].tolist())
        else:
            tmp.append(data[i:i+bs].tolist())
    tmp = np.array(tmp)
    return tmp
# 模型训练
for epoch in range(EPOCH):
    model.train()
    loss_train = 0

    for batch_id, data in enumerate(train_X):
        label = train_Y[batch_id]
        data = paddle.to_tensor(data, dtype='float32')
        label = paddle.to_tensor(label, dtype='float32')
        label = label.reshape([label.shape[0], 1])

```

```

        y = model(data)

        loss = loss_fn(y, label)
        opt.clear_grad()
        loss.backward()
        opt.step()
        loss_train += loss.item()

    print("[TRAIN]epoch: {}, loss: {:.4f}".format(epoch+1, loss_train))

    lr_scheduled.step()

# 保存模型参数
paddle.save(model.state_dict(), 'work/cnn_lstm_ep50_lr0.005.params')
paddle.save(lr_scheduled.state_dict(), 'work/cnn_lstm_ep50_lr0.005.pdopts')

# 加载模型
model = CNN_LSTM(window_size, fea_num)
model_dict = paddle.load('work/cnn_lstm_ep150_lr0.005.params')
model.load_dict(model_dict)

test_X = paddle.to_tensor(test_X, dtype='float32')
prediction = model(test_X)
prediction = prediction.cpu().numpy()
prediction = prediction.reshape(prediction.shape[0], )

//岭回归模型
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import mean_absolute_error, mean_squared_error, median_absolute_error, r2_score

#读取数据，写一个读取数据的函数
def getData():
    data=np.loadtxt("F:/comdata/aqi2.csv",delimiter=',',skiprows=1,dtype=np.float32)
    a=data[:,1:]
    b=data[:,0]
    a=b.reshape(-1,1)
    b=dataNumalize(a)
    return a,b

def dataNumalize(X):
    mu=X.mean(0)
    std=np.std(X)

```

```

X=(X-mu)/std
index=np.ones((len(X),1))
X=np.hstack((X,index))
return X

def lossFuncation(a,b,c):
    m=a.shape[0] #m 是 X 特征集的样本数，即行数
    loss=sum((np.dot(X,theta)-b)**2)/(2*m)
    return loss

#4.下面实现批量下降梯度算法
def BGD(a,b,theta,alpha,lamba,num_iters):
    m=a.shape[0]
    loss_all=[] #定义 loss 值列表，把每次 theta 更新时跟着变动的 loss 函数值存入展示
    for i in range(num_iters):
        #参数的更新公式向量化如下两行代码
        theta=theta-alpha*np.dot(a.T,np.dot(a,theta)-b)/m
        theta[:,-1]=theta[:,-1]-alpha*(lamba/m)*theta[:,-1]
        loss=lossFuncation(a,b,theta)
        loss_all.append(loss) #吧 loss 值添加到 loss_all 列表中去
        print("第{}次的 loss 值为{}".format((i+1),loss))
    return theta,loss_all

#测试
if __name__=='__main__':
    X,Y=getData()
    theta=np.ones((X.shape[1],1))
    num_iters=1000
    alpha=0.01
    lamba=0.05
    theta,loss_all=BGD(X,Y,theta,alpha,lamba,num_iters) #调用 BGD 函数求 theta 更新参数
    print(theta)
    #做模型预测
    y_predict=np.dot(X,theta)

    print(mean_absolute_error(Y,y_predict))
    print(mean_squared_error(Y,y_predict))
    print(median_absolute_error(Y,y_predict))
    print('r2',r2_score(Y,y_predict))

//XGBoost
from sklearn.preprocessing import LabelEncoder
import matplotlib.pyplot as plt
import pandas as pd

```

```

import xgboost as xgb
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, accuracy_score
import numpy as np

le = LabelEncoder()
label_mapping = {0: 'AD', 1: 'CN', 2: 'EMCI', 3: 'LMCI', 4: 'SMC'}
X = pd.DataFrame(pd.read_excel('DataX.xlsx')).values # 输入特征
y = pd.DataFrame(pd.read_excel('DataY.xlsx')).values # 目标变量
y = le.fit_transform(y)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, train_size=0.7, random_state=42)
model = xgb.XGBClassifier()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
cm = confusion_matrix(y_test, y_pred)
# 混淆矩阵
for i, true_label in enumerate(label_mapping.values()):
    row = ""
    for j, pred_label in enumerate(label_mapping.values()):
        row += f'{cm[i, j]} ({pred_label})\t'
    print(f'{row} | {true_label}')
print(accuracy_score(y_test, y_pred))

label_names = ['AD', 'CN', 'EMCI', 'LMCI', 'SMC']
cm = confusion_matrix(y_test, y_pred)

# 绘制混淆矩阵图
fig, ax = plt.subplots()
im = ax.imshow(cm, interpolation='nearest', cmap=plt.cm.Blues)
ax.figure.colorbar(im, ax=ax)
ax.set(xticks=np.arange(cm.shape[1]),
        yticks=np.arange(cm.shape[0]),
        xticklabels=label_names, yticklabels=label_names,
        title='Confusion matrix',
        ylabel='True label',
        xlabel='Predicted label')

# 数字标签
thresh = cm.max() / 2.
for i in range(cm.shape[0]):
    for j in range(cm.shape[1]):
        ax.text(j, i, format(cm[i, j], 'd'),
                ha="center", va="center",
                color="white" if cm[i, j] > thresh else "black")

```



```

fig.tight_layout()

//bp 神经网络
%读数据
input=randi([1 20],200,2);
output=input(:,1)+input(:,2);

%设置训练数据和预测数据
input_train = input(1:190,:);
output_train =output(1:190,:);
input_test = input(191:200,:);
output_test =output(191:200,:);
inputnum=2;% 输入层节点数量
hiddennum=5;% 隐含层节点数量
outputnum=1;% 输出层节点数量

[inputn,inputps]=mapminmax(input_train);
[outputn,outputps]=mapminmax(output_train);
%构建 BP 神经网络
net=newff(inputn,outputn,hiddennum,{'tansig','purelin'},'trainlm');

W1= net. iw{1, 1};%中间层的权值
B1 = net.b{1};%神经元阈值

W2 = net.lw{2,1};%输出层的权值
B2 = net. b{2};%输出层各神经元阈值

%网络参数
net.trainParam.epochs=1000;
net.trainParam.lr=0.01;
net.trainParam.goal=0.00001;

net=train(net,inputn,outputn);

inputn_test=mapminmax('apply',input_test,inputps);%归一化

%BP 神经网络预测
an=sim(net,inputn_test); %仿真

test_simu=mapminmax('reverse',an,outputps); %还原为原始的数量级
error=test_simu-output_test; %误差

%真实值与预测值误差比较

```

```
figure('units','normalized','position',[0.119 0.2 0.38 0.5])
plot(output_test,'bo-')
hold on
plot(test_simu,'r*-')

[c,l]=size(output_test);
MAE1=sum(abs(error))/l;
MSE1=error*error'/l;
RMSE1=MSE1^(1/2);
```