



中研研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 昆明理工大学

参赛队号 23106740070

	1. 董 航
队员姓名	2. 唐 程
	3. 史智予

中研研究生创新实践系列大赛

华为杯”第二十届中国研究生

数学建模竞赛

题 目： 区域双碳目标与路径规划研究

摘 要：

摘要：本研究对某区域的碳排放现状、未来趋势以及双碳目标路径进行了全面的模型建立与分析求解^[1]。在问题一中，通过构建指标体系、分析历史数据变化趋势以及建立碳排放关联预测模型，对区域碳排放现状进行了分析与评估。在问题二中，首先对某区域两个期间的人口和经济进行了预测，并利用岭回归模型对能源消费量与碳排放量进行了预测。在问题三中，设计了三种碳中和情景，并通过建立优化模型找出了实现碳中和的最佳路径。

对问题一，构建以该区域经济、人口、能源消费量和碳排放量为一级指标的指标评价体系，初步建立了关于碳排放量的 Kaya 模型^[2-4]，在此基础上对数据进行分析找到相关二级指标，在此基础上建立了关于碳排放量的 STIRPAT 模型^[5-7]。针对数据缺失问题进行补全，并通过对补全后的数据可视化分析了在“十二五”和“十三五”期间经济、人口、能源消费结构以及碳排放量的变化情况。通过 person 相关性分析，找出影响碳排放的关键因素，如人口、GDP 和能源消费量，确定了碳排放预测模型中的参数，为后续建模奠定了基础^[8-9]。

对问题二的经济、人口和能源消费量的预测模型。本研究整合并处理了人口和 GDP 的历史数据，建立了回归预测模型，通过自相关函数和偏自相关函数确定 ARIMA 模型的阶数，对两个期间的人口和经济进行预测^[10-13]。在预测未来人口与 GDP 的基础上，本研究建立了岭回归模型，预测未来的能源消费量。对问题二的区域碳排放量预测模型。本研究分析了碳排放量与人口、GDP 和能源消费量之间，以及碳排放量与各能源消费及供应部门和能源消费品种之间的关联关系，利用 ARIMA 模型对每个能源消费及供应部门和能源消费品种的碳排放量进行预测，结果表明所建立的碳排放预测模型能够反映关键因素，对未来趋势具有较好的预测效果^[14]。

对问题三，本研究拟以 2030 年达到碳达峰，2060 年实现碳中和为确定时间节点，利用 IDMI 模型计算不同情景的难度系数，构建自然、基准与雄心三种情景下的碳中和路径，分别对应为无人干预、按时和提前达到碳达峰碳中和的情况^[15-16]。在对社会经济参数、终端能源消费和能源转换等三个维度进行考虑后，建立了 LEAP 模型进行碳排放量核算与碳达峰和中和^[17-20]。求解得到各情景下最佳年度单位 GDP 能耗增长率和最佳年度碳排放因子增长率，并利用碳排放因子增长率反推得到非化石能源消费比重增长率，给出了实现碳中和的最佳途径，即提高能源利用效率与非化石能源消费比重的年度增长率^[21]。

最终，本研究通过构建相关模型，对区域碳排放现状与未来趋势进行了较为全面的预测与规划，以实现双碳目标。

关键词：STIRPAT 模型、回归预测模型、路径规划、双碳目标

目录

一、问题重述	4
1.1 问题背景	4
1.2 问题回顾	4
二、问题分析	5
2.1 问题一分析	5
2.2 问题二分析	6
2.3 问题三分析	6
三、模型假设	7
四、符号说明	8
五、问题一模型的建立与求解	9
5.1 数据处理	9
5.2 区域碳排放指标建立	11
5.2.1 区域碳足迹追寻	11
5.2.2 指标体系的建立	12
5.3 该区域的发展现状分析	13
5.4 各指标之间的关联模型建立	15
5.4.1 区域碳排放系数核算法	15
5.4.2 各指标之间的关联模型建立	16
5.5 模型求解结果分析	18
5.5.1 碳排放量驱动因素分析	18
5.5.2 各指标之间的碳排放量相关性分析	20
5.5.3 碳排放量影响因素定量分析	24
5.6 “碳达峰”和“碳中和”的难点和政策性意见	27
六、问题二模型的建立与求解	27
6.1 相关模型的建立	27
6.1.1 使用的模型简介	27
6.1.2 人口预测模型建立与求解	29
6.1.3 GDP 预测模型建立与求解	31
6.1.4 能源消费总量模型的预测和求解	33
6.1.5 相关预测结果	34
6.2 区域碳排放量预测模型	35
6.2.1 平均碳排放因子	35
6.2.2 各部门碳排放量预测	36
6.2.3 各部门碳排放量和 GDP 的关系	41
6.2.4 用 STIRPAT 模型计算区域碳排放量	43
七、问题三模型的建立与求解	44
7.1 情景设计	45
7.1.1 自然情景	45
7.1.2 基准情景	45
7.1.3 雄心情景	46
7.1.4 分析决策	46
7.2 多情景下碳排放量核算方法	47

7.2.1 情景设置.....	48
7.2.2 碳排放核算结果.....	48
7.3 双碳（碳达峰与碳中和）目标与路径规划.....	51
7.3.1 GDP、人口、能源消费量目标值.....	51
7.3.2 能源利用的目标值.....	53
7.3.3 确定非化石能源消费比重的目标值.....	54
7.3.4 双碳目标路径规划和政策性意见.....	57
八、模型评价.....	58
8.1 模型优点.....	58
8.2 模型缺点.....	58
8.3 模型推广.....	59
九、参考文献.....	59
附录.....	62
附件清单.....	62
模型建立过程中的 Python 代码.....	63

一问题重述

1.1 问题背景

2020 年 9 月 22 日，习近平主席在第七十五届联合国大会宣布中国将提高国家自主贡献力度，采取更加有力的政策和措施，二氧化碳排放力争于 2030 年前达到峰值，努力争取 2060 年前实现碳中和。我国是世界上最大的发展中国家，为实现中华民族伟大复兴，规划了在 2035 年基本实现现代化、在 2050 年实现中国式现代化的经济社会发展目标。因此，实现 2060 年碳中和的目标，必须破解发展与碳减排之间的矛盾。其中，推动经济社会高质量发展是矛盾的主要方面。经济增长与能源消费量之间存在关联关系，因此，要实现经济增长与碳排放量的负相关变化，必须从提高能源利用效率入手。可以通过开展管理节能、技术节能和结构节能等能效工程，降低单位产品与服务的能耗。此外，还可以通过开展以科技创新为基础的产业升级工程，增加单位产品与服务的科技附加值。这些措施可为实现经济增长与能源消费量增长的负相关变化提供支持。另一方面，要实现能源消费量与碳排放量增长的负相关变化，必须从提高非化石能源消费比重入手。可以通过开展新能源发电、火电脱碳与新型电网等能源脱碳工程，提升非化石能源发电占比；此外，还可以通过开展以电能替代化石能源为核心的能源消费电气化工程，提升电力消费比重。

综上所述为了破解发展与减排之间的矛盾必须从提高能源利用效率和非化石能源消费比重两个方面入手实施能效提升、产业升级、能源脱碳和能源消费电气化等四大重点工程以促进经济社会的高质量发展最终实现碳中和的目标。

1.2 问题回顾

问题一：区域碳排放量以及经济、人口、能源消费量的现状分析

1. 建立综合指标体系：

（1）创建指标，能够描述区域经济、人口、能源消费量和碳排放量情况。

（2）描述不同部门（能源供应、工业、建筑、交通、居民生活、农林）的碳排放情况。

（3）建立各主要指标之间的相互关系，以及部分指标的变化可用于碳排放量预测。

2. 分析区域碳排放量以及经济、人口、能源消费量的现状：

（1）以 2010 年为基准，研究某区域在十二五（2011-2015 年）和十三五（2016-2020 年）期间的碳排放情况。（如总量、变化趋势等）

（2）分析各因素对碳排放的影响以及它们的贡献。

（3）探讨实现碳达峰和碳中和所面临的主要挑战，为制定不同路径的双碳规划提供依据。

3. 区域碳排放量以及经济、人口、能源消费量各指标及其关联模型

（1）分析相关指标的环比和同比变化。

- (2) 建立各指标之间的关联关系模型。
 - (3) 根据相关指标的变化、双碳政策和技术进步等多重因素，确定碳排放预测模型参数。
- 问题二：区域碳排放量以及经济、人口、能源消费量的预测模型
- 1. 基于人口和经济变化的能源消费预测模型：
 - (1) 以 2020 年为基准，预测在十四五（2021-2025 年）至二十一五（2056-2060 年）期间的人口、经济（GDP）和能源消费量的变化。
 - (2) 建立与人口和经济相关的能源消费模型。
 - 2. 区域碳排放预测模型：
 - (1) 建立碳排放与人口、GDP 和能源消费量之间的关联模型。
 - (2) 分析碳排放与各能源消费部门以及能源供应部门之间的关系，包括反映能效提升对各部门的影响。
- 问题三：区域双碳目标与路径规划方法
- 1. 情景设计：
 - (1) 设计不少于三种情景，包括自然情景、按时碳达峰与碳中和的基准情景、以及雄心情景。
 - (2) 与碳达峰和碳中和时间节点相关联。
 - (3) 考虑与能效提升和非化石能源比例提高相关的情景。
 - 2. 多情景下的碳排放核算方法：
 - (1) 制定基本假设，包括 GDP 增长和碳消纳量。
 - (2) 确保碳排放核算与各部门的碳排放总和一致。
 - (3) 确保碳排放核算模型与问题二中的预测模型一致。
 - 3. 确定双碳目标与路径：
 - (1) 设定 GDP、人口和能源消费量的目标值。
 - (2) 设定提高能源利用效率和非化石能源比例的目标。
 - (3) 进行能效提升、产业升级、能源脱碳和电气化等分析。

二、问题分析

2.1 问题一分析

问题一的主要目标是构建一个综合的指标评价体系，以研究某区域的碳排放量，并建立相关模型。首先，文章建立了一级指标，包括经济、人口、能源消费量和碳排放量，并初步引入了 Kaya 模型来探讨碳排放量。接着，通过分析数据，找到了与碳排放相关的二级指标，并建立了 STIRPAT 模型，以深入研究碳排放的影响因素。

在解决数据缺失问题方面，研究通过整理和分析给定数据，并完成了能源供应部门碳排放量的数据补全，确保了研究的数据准确性。

通过可视化分析，“十二五”和“十三五”期间经济、人口、能源消费结构以及碳排放量的变化情况得以呈现。此外，通过进行 person 相关性分析，作者找出了关键因素，如人口、GDP 和能源消费量，这些因素将被用于碳排放预测模型的参数设定。

在问题一种，通过建立指标体系和模型，分析数据，填补缺失值，可视化展示趋势，以及确定关键因素，为深入研究该区域的碳排放问题提供了坚实的基础。

2.2 问题二分析

问题二的目标是建立经济、人口和能源消费量的预测模型，然后基于这些预测结果，构建区域碳排放量的预测模型。

对于经济和人口的预测模型，问题二整合并处理了历史数据，采用回归分析方法，确定了相关关系，并借助自相关函数和偏自相关函数确定了 ARIMA 模型的阶数，以便预测未来的人口和经济趋势。同时，通过岭回归模型，预测未来的能源消费量，考虑了这两个因素的影响。

针对问题二中区域碳排放量的预测，首先分析碳排放与人口、GDP、能源消费量以及各能源消费部门和品种之间的关系。然后，利用 ARIMA 模型对每个能源消费部门和品种的碳排放量进行预测，从而综合考虑了各个关键因素对碳排放的影响。

问题二通过建立多个预测模型，深入研究了人口、经济、能源消费以及碳排放之间的关联，为解决问题二提供了系统的方法和预测工具。这些模型能够更好地反映未来趋势，有助于区域碳排放量的预测和管理，为环境保护和政策决策提供了重要支持。

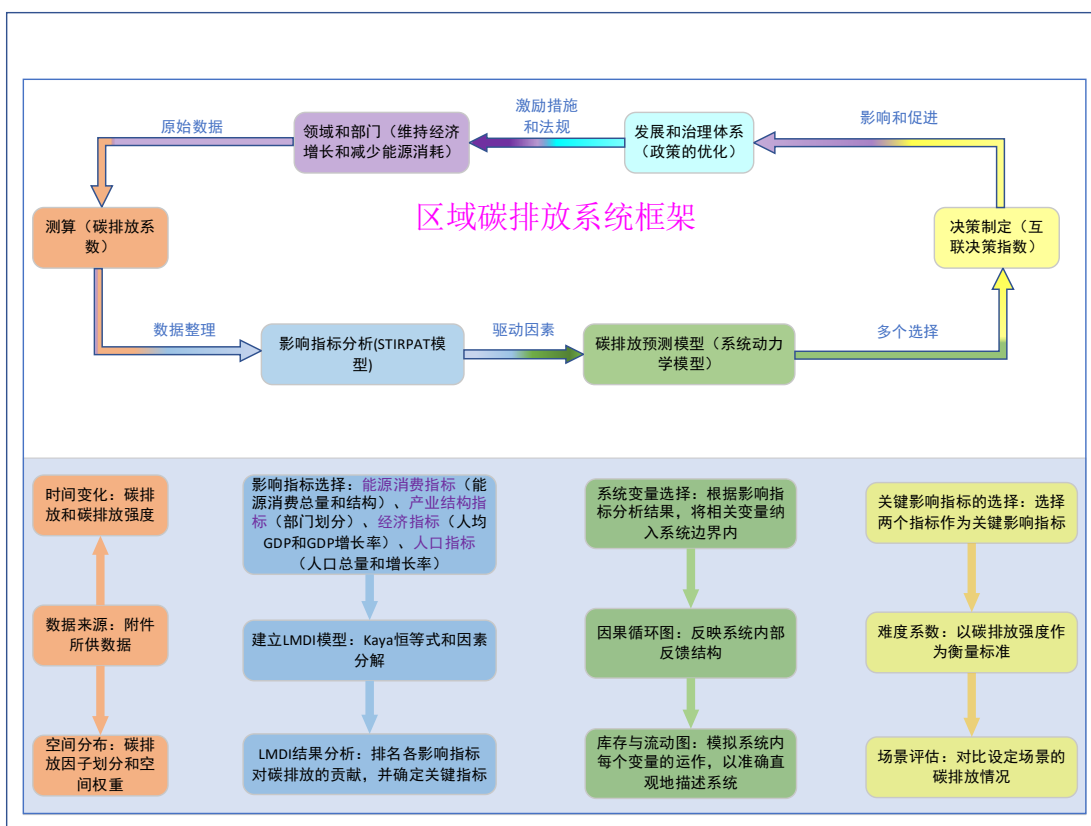
2.3 问题三分析

问题三的主要问题是确定碳达峰和碳中和的时间节点并为实现这些目标提供路径。问题三采用了 IDMI 模型，通过计算不同情景下的难度系数，包括无人干预、按时和提前达到碳达峰碳中和的情况。在考虑社会经济参数、终端能源消费和能源转换等维度后，建立了 LEAP 模型，用于核算碳排放量和实现碳达峰和中和的路径。

通过 LEAP 模型的求解，问题三得出了各情景下最佳的年度单位 GDP 能耗增长率和最佳年度碳排放因子增长率。进一步，通过反推，确定了非化石能源消费比重的年度增长率，从而提供了实现碳中和的最佳途径，即通过提高能源利用效率和增加非化石能源消费比重来实现碳中和目标。

问题三采用多维度模型，结合不同情景下的难度系数计算，为确定碳达峰和碳中和的时间节点提供了科学依据。同时，通过 LEAP 模型的运用，提供了明确的行动路径，即在碳中和过程中关注能源利用效率和非化石能源消费比重的增长率，为碳中和目标的实现提供了战略指导。

区域碳排放预测和目标规模模型建立逻辑图如下所示：



三、模型假设

假设在区域双碳目标与路径规划中扮演着关键角色，原因如下：首先，假设为建立科学的碳减排模型和决策支持系统提供了基础，有助于政府和决策者做出明智的减排决策。其次，它允许我们探索不同的碳减排情景，从而更好地理解不同政策和行动对碳排放的可能影响。此外，通过假设，可以明确设定碳达峰和碳中和的目标，并用作规划和监测的基准，以便实时追踪进展。此外，基于假设的模型还可用于评估政策效果，优化政策制定，以实现碳减排目标。最后，它有助于识别潜在的风险和挑战，从而为风险管理策略提供有力支持。总之，假设是碳减排规划不可或缺的一部分，为制定策略、规划未来行动和管理碳减排提供了基础和指导。这些假设应根据实际情况不断修正和优化，以适应不断变化的环境和需求。故我们做出如下假设：

假设 1、2035 年的 GDP 比基期（2020 年）翻一番；2060 年比基期翻两番；

假设 2、2060 年生态碳汇的碳消纳量为基期碳排放量的 10%；

假设 3、2060 年工程碳汇或碳交易的碳消纳量为基期碳排放量 10%。

假设 4、假设未来的经济增长速度不会下降，以年度的 GDP 增长率来表示。这可以包括基准情景、自然情景和雄心情景下的不同经济增长假设。

假设 5、假设未来的人口增长率会一直增长且不会下降，这对于计算每人碳排放和能源需求非常重要。

假设 6、假设未来能源结构不会变化，包括非化石能源（如太阳能、风能、核能等）和化石能源（如煤、石油、天然气等）会一直存在。

假设 7、假设未来将采取哪些政策和措施来减少碳排放，如碳定价、能源税、能源效率标准、清洁能源补贴等。

假设 8、假设未来化石能源的碳排放因子保持不变，即单位能源产生的碳排放量。

假设 9、假设未来不会发生的自然灾害、能源供应中断或其他外部因素。

四、符号说明

为了方便我们模型的建立与求解过程，对使用到的关键符号进行以下说明：

n	部门总数	x_i	第 i 个缺失项
C_e	能源的总碳排放量	j	能量类型
C_{e_j}	j 能量的碳排放量	E_j	j 能量的总消耗量
CE_j	j 能量的碳排放系数	NCV_j	单位 j 能量燃烧产生的热值
CC_j	单位 j 能量的净热值的碳排放量	OF_j	单位 j 能量的碳氧化速率
$\frac{44}{12}$	二氧化碳与碳的分子量比	C	碳排放量
G	地区国内生产总值	E	能量消耗
i	部门类型	m	能源类型总数
E_{ij}	第 i 部门第 j 类能源消耗	E	行业的能耗
G_i	行业 i 的经济产出	P	总人口数
CE_{ij}	能源碳排放系数	ES_{ij}	能源消费结构
EG_i	各部门的能源消费结构	GG_i	各部门的比例
HPG	人均 GDP	CT	T 年的碳排放量
C^0	基准年的碳排放量	ΔC_{CE}	能源的碳排放系数
ΔC_{EG}	各部门的能源消费强度	ΔC_{GG}	各部门的结构比例
ΔC_{HPG}	人均 GDP	ΔC_P	人口规模
$\rho_{X,Y}$	皮尔逊相关系数	X_i	2010 年到 2020 年间每年碳排放量
$\bar{X}$	碳排放总量的均值	Y_i	2010 年到 2020 年间每年经济、人口以及能源消费量
$\bar{Y}$	对应的均值	u	常数项
$\alpha, \beta, \sigma, \phi, \tau, \delta$	相应因子的弹性系数	Y_T	时间序列数据
φ_1	AR 模型参数	θ_1	MA 模型参数
e_t	t 时间点的误差项	c	常数项
B	滞后运算	y_i	真实值

$\hat{y}_i$	预测值	λ	岭系数
β_j	总共 P 个特征中的 第 j 个特征的系数	$\lambda \ \beta\ ^2$	收缩惩罚项
δ_0	碳排放因子	Cm	平均碳排放量
cs_i	第 i 个部门碳排放量 标准差	$IDMI_i$	方案 i 的 IDMI 值
C_{ij}	方案 i 的变量 j 的值	D_i	方案 i 的实施难度系 数
Q_{ij}	方案 i 的非关键变量 j 与实施难度系数的 乘积	C_n	第一个关键变量
C_{n-1}	第二个关键变量	CEI_0	基线情景的碳排放 强度
CEI_i	情景 i 的碳排放强度	C'_j	变量 j 的标准化值
C_j	变量 j 的实际值	C_{jmax}	变量 j 的最大值
C_{jmin}	变量 j 的最小值	A_i	不同种类化石能源 的消费量(标准量)
EF_i	不同种类化石能源 的 CO2 排放因子	A_e	城市调入电量
EF_e	调入电量所属区域 电网平均供电排放 因子	C_{Ei}	第 i 种能源产生的碳 排放
E_i	第 i 种能源消费量	R_{nf}	非化石能源消费比 重
E_{nf}	非化石能源消费量	E_{total}	能源消费量
E_{nf-gen}	非化石能源发电量	P_{nf-gen}	非化石能源发电比 重
E_{con}	电力消费量	$P_{nf-gen-ratio}$	非化石能源发电占 比
$P_{ele-con}$	电力消费比重	$C-g-rate$	碳排放因子增长率
$R_{nf-rate}$	非化石能源消费比 重增长率		

五、问题一模型的建立与求解

5.1 数据处理

在对数据的分析过程中，我们发现数据存在一定的缺失和异常，因此采用 MATLAB 中的空缺值查找函数进行处理，通过查找发现在附表碳排放拆分表里有大量以“—”表示的缺失值，但其表中“—”该年该项能源未使用，无法计算实际的碳排放因子。但仔细观察，发现在能源消费部门碳排放因子表里的第三产业建筑消费部门的煤炭的碳排放因子在 2012 为“—”，但其前后几年的使

用情况均正常，判断该数据存在缺失；而在发电项目中，热力的碳排放因子同样在 2012 年存在缺失；而在其他转换的项目中，天然气的碳排放因子在 2020 年为-14.920，与其前一年的 0.881 和尝试存在较大差异，该值判定为异常值。异常值和缺失值的存在会对我们分析结果产生巨大影响。

表 1 附件中数据的缺失或异常值

项目	子项	单位	细分项	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020
第三产业	建筑消费部门	tCO ₂ /tce	热力	2.906	2.916	-	2.967	2.998	3.107	3.190	3.278	3.745	3.662	3.705
发电	-	tCO ₂ /tce	煤炭	2.664	2.664	-	2.653	2.664	2.623	2.664	2.664	2.664	2.664	2.700
其他转换	-	tCO ₂ /tce	天然气	-	-	-	-	0.477	0.829	1.157	-	-	0.881	-14.920

为得到准确的分析结果，我们采用一定的数学方式进行处理，使用拉格朗日插值公式进行数据补全^[22]，其计算公式如下：

$$L_n(x) = l_0(x)y_0 + l_1(x)y_1 + \cdots + l_n(x)y_n \quad (1)$$

其中：

$$l_i(x) = \frac{(x-x_0)(x-x_1)\cdots(x-x_{i-1})(x-x_{i+1})\cdots(x-x_n)}{(x_i-x_0)(x_i-x_1)\cdots(x_i-x_{i-1})(x_i-x_{i+1})\cdots(x_i-x_n)} \\ = \prod_{j=0, j \neq i}^n \frac{x-x_j}{x_i-x_j} \quad (2)$$

于是可得：

$$L_n(x) = l_0(x)y_0 + l_1(x)y_1 + \cdots + l_n(x)y_n \quad (3)$$

式中，n 为缺失项个数， x_i 表示第 i 个缺失项。

将数据导入，利用 MATLAB 自带的拉格朗日插值函数计算的如下处理结果：

表 2 缺失值补全和异常值修正的结果

项目	子项	单位	细分项	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020
第三产业	建筑消费部门	tCO ₂ /tce	热力	2.906	2.916	2.946	2.967	2.998	3.107	3.190	3.278	3.745	3.662	3.705
发电	-	tCO ₂ /tce	煤炭	2.664	2.664	2.661	2.653	2.664	2.623	2.664	2.664	2.664	2.664	2.700
其他转换	-	tCO ₂ /tce	天然气	-	-	-	-	0.477	0.829	1.157	-	-	0.881	1.217

5.2 区域碳排放指标建立

5.2.1 区域碳足迹追寻

碳足迹的概念来源于生态经济学家 William E.Rees 在 1992 年提出的“生态足迹”，主要用来衡量人类活动对环境的影响^[23-25]。从消费视角看，人们所购买商品或服务会带动上游流通、运输包装、生产及原材料开采过程产生碳排放——相当于这次消费在上游各生产环节留下的“碳足迹”。如果各个生产环节的碳足迹很高，经济活动就会持续带来温室气体排放，加剧全球气候变化。

从社会发展角度来看，GDP 的增长必然带动人口和能源消耗量的增长，能源消耗增长伴随着碳排放的增长，CO₂ 在各行各业产生流动，形成碳流，在整个区域内流动。因此，寻求各社会指标之间的碳流过程可为碳减排提供有力依据。因果关系图通常包括多个反馈回路和变量，可以分为正反馈回路和负反馈回路。当一个变量的增加导致同一变量的增加，从而增强了原始趋势时，这是一个正反馈回路，而负反馈回路可以抑制趋势，并有助于系统稳定。通过整理碳排放系统的每个子系统之间的关系，构建了碳排放系统的内部反馈关系，并绘制了碳排放系统的因果循环图（图 1）^[26]。

- 系统主要具有以下反馈回路。
- (1) GDP→+生活标准→+人口→+国内能源消耗→+总能源消耗→+碳排放→-环境质量→+ GDP
 - (2) GDP→+土地利用→+碳汇→-碳排放→+碳排放强度→- GDP
 - (3) GDP→+各行业的产值→+工业能耗→+总能源消耗→+能源结构→+ GDP
 - (4) GDP→+各行业的产值→+工业能耗→+总能源消耗→+碳排放+碳排放强度→- GDP




图 1：各社会指标之间的因果关系图

从图中可以看出，其因果循环图中重要汇聚点为 GDP、能源消耗总量、碳排放，证明其三者之间的重要关系地位。GDP 作为社会发展程度的衡量标准，

其变化带动着各社会指标的变换，从而成为碳排放量的间接驱动因素；而能源作为驱动经济发展的主要动力，且是碳排放量的主要来源，是的其成为影响碳排放量的直接驱动因素，而人口规模在一定程度上决定着 GDP 和能源消耗的总量，也是衡量碳排放量一个关键指标。

5.2.2 指标体系的建立

结合碳流循环情况和本研究中附件已经给出 GDP、人口、能源消费量、产业结构、部门碳排放量和能源消耗结构等数据信息，因此我们选取区域经济指标、人口指标、能源消费指标、部门划分指标作为衡量碳排放强度的一级指标自变量，分析它们在在解释碳排放强度时起什么作用，而碳排放指标作为目标量，建立它们之间的数学关系，分析它们之间的敏感性和弹性。

在人口指标中，使用人口规模和增长率作为二级指标；在经济指标中，使用 GDP 总量，第一、二、三、产业的 GDP 产值作为衡量碳排放量的二级指标；对于能源消费指标，选择能源消费总量和能源消费结构作为二级指标；对于碳排放量，选择碳排放总量、各产业和各部门碳排放量作为二级指标^[27]。其指标划分如下表所示：

表 3 指标评价体系表

一级指标	二级指标	一级指标	二级指标
经济指标	GDP 总量	能源消费指标	能源消费总量
	第一、二、三、产业的 GDP 产值		能源消费结构
人口	人口规模	碳排放量	总量
	人口增长率		各部门碳排放量

另外，我们建立了完善的区域碳排放存量与流量图（图 2），能够描述各主要指标之间的相互关系，是用于研究碳排放与其驱动因素之间关系的重要工具。该图形象地展示了碳排放在一个特定地区的累积及流情况，从选定指标出发，展示了一个区域内复杂的相互影响关系，以及各社会指标是如何排放 CO₂ 的过程。例如 GDP 如何影响人口、产业结构等，能源消费结构反映了不同能源的碳排放过程。该图中不同因素对碳排放的影响，可帮助决策者更好地理解碳排放的动态过程，从而更全面地评估碳排放的趋势，找到关键的减排机会，制定更有效的政策来实现碳中和和可持续发展目标。




图 2：区域碳排放存量与流量图

5.3 该区域的发展现状分析

区域碳排放量以及经济、人口、能源消费量的现状


①碳排放量特征及变化趋势

在不同的经济发展阶段经济、人口、能源消费量、碳排放量四者间会有不同的关系，其间关系具有阶段特征。具体而言：


在经济发展的初级阶段经济发展水平低下，第一产业比重较大能源需求也较小，因此，温室气体的排放也较少。

在经济发展的中级阶段，经济增速稳定，人口增速加快，能源消耗量加大，第二产业所占比重较大，碳基能源需求增加，因此碳排放量增加。在这一阶段，能源消费持续增加，碳排放不断增加，经济增长方式粗放型特征明显。这个阶段是典型的高碳经济阶段，该阶段具有能源消费高、碳排放量高、污染严重的典型特征。


在经济发展的高级阶段，人口增速减缓，人均收入水平增加，第三产业比重较大，碳基能源的需求开始出现下降的趋势，因此，碳排放量减缓，该阶段是一个高收入、能源消耗和碳排放逐渐稳定甚至下降的低碳经济阶段。




(a) 十二五期间各指标变化趋势



(b) 十二五期间各指标年均增长率



(c) 十三五期间各指标变化趋势



(d) 十三五期间各指标年均增长率

图 3: 碳排放量与经济、人口、能源消费量的特征及变化趋势

如图 3 中(a),(b)所示, 随着区域经济、人口、能源消费总量发生了巨大变化, 以 2010 年为基期, 该区域十二五期间的碳排放量由 2011 年的 65193.342 万吨 CO₂ 增长到 2015 年的 66074.810 万吨 CO₂ 呈现上升趋势, 总体增长率达 1.35%, 其中 2011 年的碳排放量年均增长率达 15.67% 远高于其它年份, 2012 年后碳排放量显著减少, 2014 年碳排放量年均增长率为 -2.84%, 低于经济、人口、能源消费量的年均增长率, 之后有所反弹, 可看出其变化趋势有跟随能源消费量的趋势, 碳排放量受能源消耗量影响较大; (c),(d)所示为该区域十三五期间的特征及变化趋势, 碳排放量由 2016 年的 68526.125 万吨 CO₂ 变化到 2020 年的 72633.324 万吨 CO₂, 总体增长率为 5.99%, 相较于十二五期间有所增长, 其间经济、人口、能源消费量以及碳排放量的年均增长率呈下降趋势, 2019 年后较为显著, 2020 年能源消费量和碳排放量及年均增长率降至最低, 但十四五期间碳排放量受能源消耗量影响依旧较大。

5.4 各指标之间的关联模型建立

5.4.1 区域碳排放系数核算法

(1) 碳排放系数核算方法

为减缓气候变化，实现可持续发展目标，20 世纪末以来，《京都议定书》、《巴黎协定》等一系列全球减排协议相继问世。碳排放核算的重要性已被多次重申。碳排放系数法由于数据获取方便、计算量适中、结果精度高，成为目前应用最广泛的碳排放核算方法。因此，我们选择了碳排放系数作为碳排放核算方法。根据 2019 年修订的 IPCC 《2006 年国家温室气体清单指南》，选择在国家或区域地理边界内发生的直接排放作为碳排放核算的边界。自然界中动植物的碳排放对该边界内的总体碳排放贡献很小。因此，仅考虑了由于人类活动造成的碳排放^[28]。

人类活动产生的碳排放是指化石燃料燃烧过程中排放的二氧化碳。碳排放源被定义为地理边界内的所有相关活动。具体计算公式如下：

$$C_e = \sum_j^8 C_{ej} = \sum_j^8 E_j \times CE_j = \sum_j^8 E_j \times NCV_j \times CC_j \times OF_j \times \frac{44}{12} \quad (4)$$

式中， C_e 代表能源的总碳排放量； j 是能量类型； C_{ej} 是 j 能量的碳排放量； E_j 是 j 能量的总消耗量； CE_j 是 j 能量的碳排放系数； NCV_j 是单位 j 能量燃烧产生的热值； CC_j 是单位 j 能量的净热值的碳排放量； OF_j 是单位 j 能量的碳氧化速率； $\frac{44}{12}$ 是二氧化碳与碳的分子量比。

表 4 能源碳排放系数

能源类型	NCV_j	CC_j	OF_j	碳排放系数
	(GJ/t 或 GJ/10 ⁴ m ³)	(tack/GJ)	(%)	
煤	21	0.0260	81.62	1.6541
焦炭	28	0.0310	89.00	2.8673
原油	43	0.0200	96.00	3.0393
燃料	43	0.0210	96.00	3.1937
汽油	43	0.0190	96.00	2.8607
煤油	44	0.0200	96.00	3.0356
柴油	43	0.0200	96.00	3.0575
天然气	389	0.0150	98.00	21.4144

(2) Kaya 碳排放恒等式

在以国内生产总值（Gross Domestic Product，简称 GDP）衡量经济体的碳排放量时，经常会用到经典的 Kaya 碳排放恒等式。该等式如下：

$$C = P \times \frac{G}{P} \times \frac{E}{G} \times \frac{C}{E} \quad (5)$$

式中，C 为碳排放量；P 为人口规模；G 为地区国内生产总值；E 是能量消耗。

类似地我们通过 Kaya 碳排放恒等式构建出了其他影响因素对进行碳排放衡量。其总碳排放因素量化如下：

$$C = \sum_{i=1}^n \sum_{j=1}^m CE_{ij} \times ES_{ij} \times EG_i \times GG_i \times HPG \times P \quad (6)$$

式中， i 为部门类型， n 为部门总数， j 是能源类型， m 为能源类型总数， E_{ij} 为第 i 部门第 j 类能源消耗，按标准煤计算； E 为行业的能耗； G_i 为行业 i 的经济产出； G 是实际 GDP； P 是总人口数； CE_{ij} 为能源碳排放系数； ES_{ij} 为能源消费结构； EG_i 为各部门的能源消费结构； GG_i 为各部门的比例； HPG 为人均 GDP；

（3）LMDI 指数分解

对数平均迪氏指数法（Logarithmic Mean Divisia Index，LMDI）分解法是一种用于分解和分析能源或资源消耗的方法，旨在揭示不同因素对总体变化的贡献程度。LMDI 分解法有助于解释碳排放变化趋势的原因，揭示哪些因素推动了碳排放的增减，为制定更有效的碳减排政策提供支持。

采用 LMDI 模型的加法分解方法进行计算。T 年碳排放量相对基准年的变化可由下式计算：

$$\begin{aligned} \Delta C &= C^T - C^0 \\ &= \frac{C^T - C^0}{\ln C^T - \ln C^0} \times (\ln C^T - \ln C^0) \\ &= \Delta C_{CE} + \Delta C_{ES} + \Delta C_{EG} + \Delta C_{GG} + \Delta C_{HPG} + \Delta C_P \end{aligned} \quad (7)$$

式中， C^T 为 T 年的碳排放量， C^0 为基准年的碳排放量， ΔC_{CE} 为能源的碳排放系数， ΔC_{ES} 为能源消费结构， ΔC_{EG} 为各部门的能源消费强度， ΔC_{GG} 为各部门的结构比例， ΔC_{HPG} 为人均 GDP 代表经济发展水平， ΔC_P 为人口规模。

5.4.2 各指标之间的关联模型建立

（1）区域经济指标关联模型

GDP 总量是国民经济核算的核心指标，也是衡量一个国家或地区经济状况和发展水平的重要指标，许多经济活动涉及碳排放，因此 GDP 总量与碳排放存在一定相关性。同时 GDP 用于国际比较和责任分配，有助于气候协议和碳市场的运作。此外，GDP 可用于预测未来碳排放趋势，支持长期气候政策和可持续发展规划。因此，我们可以选择 GDP 作为评估区域经济发展的重要指标，并将该指标应用于计算区域碳排放量，以便进行后续的分析与研究。

故 GDP 与碳排放的关系计算公式为：

$$\Delta C_{HPG} = \sum_{i=1}^6 \sum_{j=1}^6 L(C_{ij}^T, C_{ij}^0) \ln \left(\frac{HPG^T}{HPG^0} \right) \quad (8)$$

（2）人口指标关联模型

人口规模可以作为碳排放量计算的指标之一，这源于其在碳排放与经济发展之间的关联性。一国或区域的人口数量显著影响着其能源需求、工业活动、交通运输、及基础设施需求，而这些因素均是导致碳排放的根源。因此，人口规模与碳排放水平之间存在紧密的关联性，这为将人口规模视为计算碳排放的指标提供了理论基础。人口规模还在国际气候谈判中扮演关键角色，用以确定各国的碳排放贡献，支持责任分配和气候协议制定。

故人口规模与碳排放关系计算公式为：

$$\Delta C_p = \sum_{i=1}^6 \sum_{j=1}^6 L(C_{ij}^T, C_{ij}^0) \ln\left(\frac{P^T}{P^0}\right) \quad (9)$$

(2) 能源消费量指标关联模型

能源消费总和及能源消费结构可以作为碳排放量计算的指标之一。碳排放与能源消费直接相关，因为大部分碳排放来自化石燃料的燃烧，如煤、石油和天然气，以及其他能源资源的利用。因此，监测和分析能源消费情况能够提供关于碳排放水平的关键信息。在我国能源消费数据通常由国家能源局公布获取方便。这些数据也是进行碳排放估算的重要基础，有助于科学家和政策制定者更准确地了解和量化碳排放的来源和规模。

能源消费结构指的是化石能源和非化石能源在能源消费结构中的比例，该比例对于碳排放计算具有重要影响。这两者代表了不同的能源来源和能源消费模式，对一个国家或地区的碳排放水平和气候变化影响产生重要影响。能源消费结构中化石能源的比例直接关联到碳排放水平。化石燃料，如煤、石油和天然气，燃烧时释放大量的二氧化碳等温室气体，导致碳排放的增加。因此，高比例的化石能源在能源消费结构中意味着更高的碳排放。相反，非化石能源，如太阳能、风能和水力能源，通常具有较低或零碳排放，有助于减少碳排放水平。

此外，能源消费结构对于碳排放计算的影响在于它反映了一个地区对可持续性和环保的承诺。政府和国际组织可以利用这一信息来评估该地区的碳减排潜力以及实现减排目标的可能性。非化石能源在消费结构中的比例越高，表明该地区更倾向于采用低碳和可持续的能源，有望在减少碳排放方面取得更大的成功。

故能源消费总量与碳排放关系计算公式为：

$$\Delta C_{ES} = \sum_{i=1}^6 \sum_{j=1}^6 L(C_{ij}^T, C_{ij}^0) \ln\left(\frac{ES_{ij}^T}{ES_{ij}^0}\right) \quad (10)$$

能源结构与碳排放的关系计算公式为：

$$\Delta C_{GG} = \sum_{i=1}^6 \sum_{j=1}^6 L(C_{ij}^T, C_{ij}^0) \ln\left(\frac{GG_i^T}{GG_i^0}\right) \quad (11)$$

(4) 部门划分指标关联模型

将不同产业部门划为能源供应部门、工业消费部门、建筑消费部门、交通消费部门、居民生活消费、农林消费部门有利于进行碳排放规划计算。不同部门承担着不同的碳排放源，这有助于我国政府更准确地了解各个领域的碳排放情况，以制定相应政策和措施。

同时，我国政府的有关部门可以根据不同部门的碳排放情况有针对性地制定政策，以减少碳排放。此外，这种划分也在国际气候谈判中发挥重要作用，有助于确定各国的碳排放贡献和责任分配。通过定期收集和分析各部门的碳排放

放数据，可以及时识别问题领域，并采取措施来应对碳排放的增长或减少，从而更好地管理碳排放。

故产业结构与碳排放的关系公式为：

$$\Delta C_{EG} = \sum_{i=1}^6 \sum_{j=1}^6 L(C_{ij}^T, C_{ij}^0) \ln \left(\frac{EG_i^T}{EG_i^0} \right) \quad (12)$$

(5) 碳排放指标与碳排放关系公式的权重求解

对于形如 $\Delta C_K = \sum_{k=1}^h L(C_k^T, C_k^0) \ln \left(\frac{K^T}{K^0} \right)$ 的式子中， $L(x,y)$ 为权重函数。在具体的指标中引入权重函数，将对数权重函数定义为：

$$L(x,y) = \begin{cases} \frac{x-y}{\ln x - \ln y} & x \neq y \\ x & x = y \\ 0 & x = y = 0 \end{cases} \quad (13)$$

由于 LMDI 模型中存在小数和对数运算，在计算过程中可能会出现零值问题，即位于分母或对数位置的变量或表达式趋于零，计算结果趋于无穷大。因此，本研究中的零值问题按照表 5 中的方法进行处理。

表 5 在 LMDI 模型中对于“0”值的处理结果

编号	X_i^0	X_i^T	V^0	V^T	$\Delta V_{x_i} = (V^T - V^0) \frac{\ln(X_i^T/X_i^0)}{\ln(V^T/V^0)}$
1	0	+	0	+	$\Delta V_{x_1} = V^T$
2	+	0	+	0	$\Delta V_{x_1} = -V^0$
3	0	0	0	0	0
4	+	+	+	+	0
5	+	+	+	0	0
6	+	+	0	0	0

利用所建模型对数据进行编程分析，可得出各指标之间的相关性和碳排放的关键因子。

5.5 模型求解结果分析

5.5.1 碳排放量驱动因素分析

为了更加直观的看各个指标之间的关系，我们对历史数据的分析和整理，绘制出从 2010 年到 2020 年的该地区碳排放量、能源消耗量、GDP 在不同产业结构和部门划分下随时间的变化趋势。




图 4：历史数据整理分析图

(1) 产业结构的变化趋势分析

从图 4 (a) 可得，从 2010 到 2020 年该地区的生产总值增长迅速，第一产业的产值基本不变，增长缓慢，而第二产业有所增长，但增长速度逐渐放缓，第三产业增长最快，到 2020 年成为产值最高的产业。可看出十二五期间的其 GDP 增长率基本保持不变，但十三五期间，其增长率有下降趋势；而第一产业在十三五期间相比十四五期间有所增长，但增速缓慢，趋于稳定；第二产业在十三五期间稳步增长，但十四五期间其增速大幅下降；第三产业十三五期间稳步增长，十四五期间增长迅速。且第三产业的产值在 2015 年首次超过第二产业，即十四五期间其产值结构发生变化，这和我国十四五期间由高速发展向高质量发展的政策相吻合，表明该地区严格执行国家政策，高质量发展取得显著成效。

图（b）反映了不同产业结构的能源消耗量随时间的变化图，能明显看出总耗能的变化趋势和第二产业的耗能趋势基本一致，且第二产业的耗能占比极高，超过 80%，虽 2020 年有所下降，但仍占极大比重，这与其产值贡献低形成鲜明对比。这种高耗低产的产业在节能减排方面有着极大潜力，需要改进生产流程、提高能源效率或采用更环保的技术以实现更高的产值和减少资源消耗。在碳排放方面，降低耗能高产值低的情况可以有助于减少碳排放强度，实现更可持续发展的经济。

图（c）反映了不同产业结构的碳排放随时间的变化图，其碳排放量和耗能成正比，因此其变化趋势和图（b）虽有差别，但差异不大。同理，其第二产业所占碳排放量比重极大，起着决定性作用，与其产值贡献低形成鲜明对比。这种高碳排低产值的产业在碳排放方面，降低耗能高产值低的情况可以有助于减少碳排放强度，实现更可持续发展的经济。

（2）部门划分的变化趋势分析

从图（d）可看出，和产业结构相似，从 2010 到 2020 年该地区的生产总值增长迅速，农林，能源供应、交通部门的产值基本不变，增长缓慢，而工业部门有所增长，但增长速度逐渐放缓，建筑部门增长最快，到 2020 年成为产值最高的部门。可看出十二五期间的其 GDP 增长率基本保持不变，但十三五期间，其增长率有下降趋势；而农林，能源供应、交通部门在十三五期间相比十四五期间有所增长，但增速缓慢，趋于稳定；工业部门在十三五期间稳步增长，但十四五期间其增速大幅下降；建筑部门十三五期间稳步增长，十四五期间增长迅速。且建筑部门的产值在 2015 年首次超过工业部门，即十四五期间其产值结构发生变化，这和我十四五期间由高速发展向高质量发展的政策相吻合，表明该地区严格执行国家政策，高质量发展取得显著成效。

因第三产业主要为工业部门，所以其能源消耗量和碳排放量和产业结构的趋势基本一致。从图（e）可看出，工业部门消耗的能源超 50%，建筑部门虽比例不低，但相对于工业部门所占比例较小。而从图（f）可知，其碳排放量占比超过 80%，成为决定碳排放量的主要部门。其高耗高排地产的属性，注定其成为节能减排的主力军，减少工业部门的能源消耗，进行工业生产转型，生产方式创新，提高能源利用效率，使用新能源，成为碳减排和碳达峰目标的关键。

5.5.2 各指标之间的碳排放量相关性分析

建立相关性分析模型，引入 person 相关性，进行判断指标之间的关系。关联性判断：利用皮尔逊相关系数对 2010 年到 2020 年十年间的碳排放总量与三者间的关系进行相关性分析，其计算公式如下所示：

$$\rho_{X,Y} = \frac{\sum_{i=0}^{10} (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=0}^{10} (X_i - \bar{X})^2 \sum_{i=0}^{10} (Y_i - \bar{Y})^2}} \quad (i = 0, 1, 2, \dots, 10) \quad (14)$$

其中， $\rho_{X,Y}$ 表示 X 与 Y 间的皮尔逊相关系数， X_i 表示 2010 年到 2020 年间每年碳排放量， $\bar{X}$ 表示碳排放总量的均值， Y_i 表示 2010 年到 2020 年间每年经济、人口以及能源消费量， $\bar{Y}$ 表示其对应的均值。

我们认为 $\rho_{X,Y}$ 位于 (0.8, 1.0] 为极强相关，(0.6, 0.8] 为强相关，(0.4, 0.6] 为中等程度相关，(0.2, 0.4] 为弱相关，(0.0-0.2] 极弱相关或无相关，利用相关系数首先研究大部分指标都与碳排放量的相关关系，这里首先展示二级指标之间的相关性，他们之间的相关性系数如下表所示：

表 6 各二级指标相关性之间的皮尔逊相关系数

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
1	1	0.919	0.964	0.998	0.941	0.957	0.959	0.949	0.891	0.874	0.892	0.971	0.997	0.989	0.879
2	0.919	1	0.788	0.867	0.653	0.573	0.949	0.932	0.866	0.999	0.537	0.642	0.921	0.977	0.984
3	0.964	0.788	1	0.996	1	0.999	0.978	0.982	1	0.872	0.977	1	0.995	0.987	0.766
4	0.998	0.867	0.996	1	0.933	0.927	0.951	0.949	0.874	0.571	0.922	0.612	0.999	0.999	0.947
5	0.941	0.653	1	0.933	1	1	0.987	0.989	0.998	0.998	0.994	1	0.982	0.995	0.879
6	0.957	0.573	0.999	0.927	1	1	0.968	0.971	0.998	0.953	0.986	0.999	0.982	0.947	0.957
7	0.959	0.949	0.978	0.951	0.987	0.968	1	0.998	0.942	0.933	0.878	0.942	0.987	0.979	0.999
8	0.949	0.932	0.982	0.949	0.989	0.971	0.998	1	0.949	0.952	0.857	0.945	0.991	0.983	1
9	0.891	0.866	1	0.874	0.998	0.998	0.942	0.949	1	0.878	0.942	0.999	0.801	0.714	0.722
10	0.874	0.999	0.872	0.571	0.998	0.953	0.933	0.952	0.878	1	0.592	0.477	0.549	0.744	0.954
11	0.892	0.537	0.977	0.922	0.994	0.986	0.878	0.857	0.942	0.592	1	0.985	0.981	0.879	0.814
12	0.971	0.642	1	0.612	1	0.999	0.942	0.945	0.999	0.477	0.985	1	0.772	0.648	0.519
13	0.997	0.921	0.995	0.999	0.982	0.982	0.987	0.991	0.801	0.549	0.981	0.772	1	0.989	0.991
14	0.989	0.977	0.987	0.999	0.995	0.947	0.979	0.983	0.714	0.744	0.879	0.648	0.989	1	0.987
15	0.879	0.984	0.766	0.947	0.879	0.957	0.999	1	0.722	0.954	0.814	0.519	0.991	0.987	1

注：表中 1-15 分别代表：GDP 总量、第一产业生产总值、第二产业生产总值、第三产业生产总值、能源消耗总量、能源消费结构、人口规模、人口增长率、碳排放总量、农林消费部门碳排放量、能源供应部门碳排放、工业消费部门碳排放量、建筑消费部门碳排放量、交通消费部门碳排放量、居民生活消费碳排放

其二级指标的碳排放量之间的皮尔逊相关系数热力图如图 5 所示：




图 5：各二级指标之间的皮尔逊相关系数热力图

通过该热力图我们能直观的观察出各二级指标之间碳排放量之间的相关性，从图中可以看出，第二产业总值、能源消费总量、消费结构、工业消费碳排放量、以及碳排放总量存在极强相关性，这为碳减排和碳中和的实现提供关键信息，可作为碳减排的驱动因素。而 GDP 总量和第三产业的产值有极强相关性，而与第二产业的相关性一般，所为提高 GDP 总量和降低碳排放总量提供了可行方案，加快产业转型，减少第二产业比重，提高第三产业比重成为实现碳减排的可行路径。

通过所建模型的求解，得出碳排放总量、不同产业和不同部门碳排放量和一级指标 GDP、人口、能源消费总量之间相关性系数的柱状图，可清晰的看出能源消费量成为每一指标之间的最强相关性，从而确定了能源结构转型，提高非化石能源的利用，成为碳减排的关键。




图 6: 碳排放总量、不同产业和不同部门碳排放量和一级指标 GDP、人口、能源消费总量之间相关性系数的柱状图

为了更清晰地呈现几个一级指标之间的关联，我们对这些多维一级指标进行了降维处理，生成了以下最终数据集。如下表 5-6 所示：

表 7 能源消耗量与相关因素的皮尔逊相关系数

	人口	GDP	能源消费量	碳排放量
人口	1	0.9588	0.9682	0.8905
GDP	0.9588	1	0.9412	0.872
能源消费量	0.9682	0.9412	1	0.9728
碳排放量	0.8905	0.872	0.9728	1

其碳排放量与各因素的皮尔逊相关系数热力图如图 7：




图 7：碳排放量与各因素的皮尔逊相关系数

从图中我们可以看出能源消费量和碳排放量相关性最强、人口次之、GDP 最低，这说明提高 GDP 的同时减少碳排放量是可以实现的，其潜在的可行方式是实现产业转型，使用低碳能源，当前的化石能源比例较高，可通过减少其使用来减少碳排放量。

5.5.3 碳排放量影响因素定量分析

（1）碳排放量测算结果

采用 STIRPAT 模型分析研究区域碳排放的影响因素，该模型的优点在于避免了同比例变动问题的影响，能表征各个影响因素的变动对应的碳排放量的影响，因此被广泛应用于碳排放量预测研究。

结合该区域发展状况，使用建立的指标体系扩展 STIRPAT 模型，构建城市碳排放与其影响因素间的计量模型，其表达式为：

$$\ln(C) = u + \alpha \ln(CE_{ij}) + \beta \ln(ES_{ij}) + \sigma \ln(EG_{ij}) + \tau \ln(HPG) + \delta \ln(P) \quad (15)$$

式中 u 为常数项、 CE 为碳排放强度、 HGP 为地区 GDP 总量， P 为人口规模、 ES 为能源消费总量、 EG 为部门划分、 C 为碳排放总量 α 、 β 、 σ 、 ϕ 、 τ 、 δ 为相应因子的弹性系数，表示当相应因子变化 1% 时引起碳排放量的变化率。

根据 IPCC 排放因子法，以十三五期间的碳排放量来对该地区十四五期间的二氧化碳排放量进行测算值和实际值比较，结果如下表 8 所示：

表 8 十四五期间的二氧化碳排放量测算值与实际值比较

年份	2016	2017	2018	2019	2020
二氧化碳排放量测算值	68524.6	70447.2	71508.6	74094.7	72632.3
二氧化碳排放量实际值	68526.125	70451.557	71502.003	74096.331	72633.324

可以看出，其实际值和测算值偏差极小，验证了测算模型测算结果的合理性。

(2) 岭回归法拟合结果

然后，构建该区域碳排放与影响因素的回归模型，该模型中自变量之间存在高度相关性，这会导致回归系数估计不稳定。为解决这种不稳定的影响，因此采用岭回模型来进行相关性分析。归岭回归是一种线性回归的改进方法，用于处理多重共线性（Multicollinearity）问题，通过添加一个正则化项（Ridge term）来解决这个问题，使得回归系数更稳定。其公式如下所示：

$$x_j^* = \frac{x_j - xm_j}{xs_j} \tag{16}$$

$$y^* = y - ym \tag{17}$$

$$y^* = \beta_1^* x_1^* + \beta_2^* x_2^* + \cdots + \beta_n^* x_n^* \tag{18}$$

$$J(\beta^*) = \sum (y^* - x^* \beta^*)^2 + \sum \lambda \beta^{*2} \tag{19}$$

$$\beta^* = (x^{*T} x^* + \lambda I)^{-1} x^{*T} y^* \tag{20}$$

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n \tag{21}$$

$$y - ym = \sum_{i=1}^n \beta_i^* \frac{x_i - xm_i}{xs_i} \tag{22}$$

$$\beta_0 = ym - \sum_{i=1}^n \beta_i^* \frac{xm_i}{xs_i}, \beta_i = \frac{\beta_i^*}{xs_i} \tag{23}$$

对各自变量(CE 为碳排放强度、HGP 为地区 GDP 总量，P 为人口规模、ES 能源消费总量、EG 为能源结构、EG 为部门划分)进行多元线性回归并进行共线性检验，检验结果如下表 7-9 所示：

表 9 模型

项目	R	R ²	调整 R ²	标准估计的误差
参数	0.99864	0.99713	0.99189	0.041148

表 10 方差分析

项目	平方和	自由度	均方	F 检验统计值	显著性水平 P
回归	2.307	5	0.445	274.779	<0.0001
残差	0.008	6	0.0197	-	-
总计	2.315	11	-	-	-

表 11 模型系数

项目	非标准化系数		标准系数	T 检验统计值	显著性系数	共线性统计量	
	回归系数	标准误差				容差	方差膨胀系数
常数项	-60.784	51.249	-	-1.182	0.277	-	-
ln(CE _{ij})	1.035	0.387	0.204	2.247	0.721	0.161	274.209
ln(ES _{ij})	7.876	0.932	0.297	1.432	0.272	0.001	1474.279
ln(EG _{ij})	-0.154	0.027	-0.573	-0.741	0.428	0.003	360.026
ln(HPG)	1.275	0.458	0.079	2.412	<0.001	0.001	1101.114
ln(P)	7.477	6.443	0.314	17.456	0.181	0.002	249.904

岭回归分析法通过放弃最小二乘法的无偏性，以损失部分信息为代价，可以寻找效果稍差但回归系数更符合实际情况的模型方程，得到相关拟合结果如图 6 和图 7 所示，其中岭参数 K 为惩罚系数。




图 8 岭迹图和岭参数 K 与相关系数 R² 的关系

由表 9 可知，岭回归模型的决定系 R^2 为 0.99864，具有较高的拟合优度。岭回归模型的假设检验中，F-value=274.779，检验显著性 $p < 0.0001$ 。因此，可以得到该地区碳排放量影响因素分析模型如下式所示：

$$\begin{aligned} \ln(C) = & -60.784 + 1.035 \ln(CE_{ij}) + 7.876 \ln(ES_{ij}) \\ & -0.154 \ln(EG_{ij}) + 1.275 \ln(HPG) + 7.447 \ln(P) \end{aligned} \quad (24)$$

由该模型中各个自变量的系数可知，各个影响因素对重庆市建筑碳排放的影响程度按从大到小排序依次为：能源消费总量、人口规模、GDP、碳排放强度、部门划分。

该地区能源消费总量对碳排放量的影响最为显著，其弹性系数达到了 7.876%，能源消费总量增长 1%，使得二氧化碳排放总量增加大约 7.876%。从历史数据分析我们可知，该地区工业占比极高，第二产业发达，消耗量大量的能源，从而排放大量的二氧化碳，使其碳排放量大幅增加。

该地区人口规模对建筑碳排放量也有较大影响影响，其弹性系数达到了 7.447%，即人口数量增长 1%，使得碳排放总量增加大约 7.447%。人口的不断增长导致人口对于建筑面积的需求量增加、能源消费、生活垃圾处理、出行等需求增加，这就导致了碳排放量的增加。

GDP 的弹性系数为 1.275%，即 GDP 增长 1%，碳排放就增加大约 1.275%。GDP 的增长意味着人民生活水平的提升，居民购买奢侈品的数量增多，对各种服务产品的需求增加，从而使得碳排放量增加。

碳排放强度是该地区碳排放量与 GDP 总产值的比重，碳排放强度对该地区的碳排放量业存在着一定的影响，其弹性系数达到了 1.035%，即碳排放强度增加 1%，会导致碳排放总量增加 1.035%。

相比前面 4 个影响因素，部门划分对碳排放量的影响程度最小，其弹性系数为 -0.154%，意味着部门划分程度每增加 1%，会减少 -0.154% 的碳排放总量。因为该地区处于产业转型阶段，第三产业在十四五期间成为支柱产业，工业占比逐年下降，建筑，交通等部门崛起，使得部门划分越来越明确，碳排放量的减少受部门划分的影响。

因此，该地区做好产业转型、淘汰落后的低产高排高耗的工业部门，成为实现碳中和的可能方式。

5.6 “碳达峰”和“碳中和”的难点和政策性意见

(1) 碳达峰和碳中和面临的主要难点包括：

A、技术难题：从前述分析可得出，该地区对能源消费的依赖性非常强，GDP 产值中工业比重极大，且碳排放量和能源消费量有相关性非常强，但实现碳达峰和碳中和需要大规模采用清洁能源技术，但清洁能源当前使用占比低，且成本高，这对实现目标造成巨大阻碍。

B、经济成本：转向低碳经济和减少碳排放通常需要巨大的投资和资源。该地区需要承担转型和升级的成本，这可能会影响经济增长。

C、社会适应：碳达峰和碳中和政策可能导致该地区的失业和产业转型问题。因此，需要实施社会适应措施，确保受影响的社区和工人能够适应新的经济环境。

(2) 政策性意见

以下是一些有用的政策性意见，旨在应对气候变化和降低碳排放：

A、产业转型：第三产业的发展能带动 GDP 高质量发展，且碳排放量低，因此加快产业转型，创新生产机制，淘汰落后产业，减少工业能源消耗成为关键

B、可再生能源推广：通过激励措施和补贴政策，推广可再生能源的使用，如太阳能和风能。鼓励投资和研发清洁能源技术。

C、碳定价机制：建立碳排放定价机制，如碳税或碳市场，以促使企业和个人减少碳排放。收取碳排放税款后，可以将资金用于支持清洁能源和低碳技术的发展。

D、能效标准：实施严格的能源效率标准，包括建筑、交通工具和工业设备。要求企业采用更节能的技术和设备。

六、问题二模型的建立与求解

6.1 相关模型的建立

6.1.1 使用的模型简介

(1) ARIMA 预测模型

ARIMA 模型全称为自回归差分移动平均模型 (Autoregressive Integrated Moving Average Model)。ARIMA 模型主要由三部分构成，分别为自回归模型 (AR)、差分过程 (I) 和移动平均模型 (MA)。其基本思想为利用数据本身的历史信息来预测未来^[29-31]。即 ARIMA 模型通过数据的自相关性和差分的方式，提取出隐藏在数据背后的时间序列模式，然后用这些模式来预测未来的数据。其中：1) AR 部分用于处理时间序列的自回归部分，它考虑了过去若干时期的观测值对当前值的影响；2) I 部分用于使非平稳时间序列达到平稳，通过

一阶或者二阶等差分处理，消除了时间序列中的趋势和季节性因素；3)MA 部分用于处理时间序列的移动平均部分，它考虑了过去的预测误差对当前值的影响。结合这三部分，ARIMA 模型既可以捕捉到数据的趋势变化，又可以处理那些有临时、突发的变化或者噪声较大的数据。所以，ARIMA 模型在很多时间序列预测问题中都有很好的表现。其表达式如式(25)、(26)所示：

$$AR: Y_t = c + \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + \dots + \varphi_p Y_{t-p} + e_t \quad (25)$$

$$MA: Y_t = e_t + \theta_1 e_{t-1} + \dots + \theta_q e_{t-q} \quad (26)$$

式中 Y_t 是我们正在考虑的时间序列数据， φ_1 到 φ_p 是用来描述当前值与过去 p 个时间点值之间关系的 AR 模型参数， θ_1 到 θ_q 是用来描述当前值与过去 q 个时间点的误差之间关系的 MA 模型参数， e_t 为 t 时间点的误差项， c 是一个常数项。

因此将式(25)、(26)相结合得到 ARIMA 模型，如式(27)所示：

$$Y_t = c + \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + \dots + \varphi_p Y_{t-p} + e_t + \theta_1 e_{t-1} + \dots + \theta_q e_{t-q} \quad (27)$$

而在 ARIMA(p, d, q) 模型中， p 代表 "自回归部分(AR)"， q 代表 "移动平均部分 (MA)"， d 代表差分阶数，如式(28)所示：

$$d_order_y = (1-B)^d y_t \quad (28)$$

其中 y_t 为输入的时间序列， B 为滞后运算。

其优点为：模型简单，内生变量不需要借助其他外生变量；同时要求时间序列数据为稳定且有规律的。针对本研究人口、经济（GDP）、能源消费量的变化；碳排放量与各能源消费部门以及能源供应部门的能源消费量的关联关系；碳排放量与各能源消费部门的能源消费品种以及能源供应部门的能源消费品种的关联关系，在对其数据进行分析后认定其为稳定数据，故此模型适用于本研究数据的预测。

(2) 岭回归模型

岭回归(ridge regression, Tikhonov regularization)是一种专用于共线性数据分析的有偏估计回归方法，实质上是一种改良的最小二乘估计法，在存在多重共线性时，尽管最小二乘法（OLS）测得的估计值不存在偏差，它们的方差也会很大，从而使得观测值与真实值相差甚远。岭回归通过给回归估计值添加一个偏差值，来降低标准误差^[32,33]。

在标准线性回归中，通过最小化真实值和预测值的平方误差来训练模型，故该平方误差也称为残差平方和，如式(29)所示：

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (29)$$

其中 y_i 为真实值， $\hat{y}_i$ 为预测值。

最小二乘法即最小化残差平方和，如式(30)所示：

$$J_{\beta}(\beta) = \operatorname{argmin} \sum_{i=1}^p (y_i - x_i \beta_i - \beta_0)^2 \quad (30)$$

其矩阵形式求解，如式(31)所示：

$$\beta = (X^T X) X^T y \quad (31)$$

其中 X^T 和 X 为满秩矩阵。

为解决多重共线导致的不稳定问题，在矩阵 X^T 和 X 上加入一个小的常数值 λ ，取其逆所求系数如式(32)所示：

$$\hat{\beta}_{\text{ridge}} = (X^T X + \lambda I_n)^{-1} X^T Y \quad (32)$$

其中 I_n 为单位矩阵， λ 为岭系数。

因此岭回归模型的公式如(33)所示：

$$J_{\beta}(\beta) = RSS + \lambda \sum_{j=0}^n \beta_j^2 = RSS + \lambda \|\beta\|^2 \quad (33)$$

矩阵形式为：

$$J_{\beta}(\beta) = \sum_{i=0}^p (y_i - X_i \beta)^2 + \lambda \sum_{j=0}^n \beta_j^2 = \sum_{i=0}^p (y_i - X_i \beta)^2 + \lambda \|\beta\|^2 \quad (34)$$

其中 β_j 是总共 P 个特征中的第 j 个特征的系数， λ 为控制对 β_j 惩罚强度的超参数， $\lambda \|\beta\|^2$ 为收缩惩罚项。

其优点为：回归得到的回归系数更符合实际，更可靠；能让估计参数的波动范围变小，变的更稳定。

由于本研究的自变量（人口、经济、能源消费量和能源供应部门的能源消费量等）之间存在高度相关性，因此选取岭回归模型，对模型进行拟合与回归。

6.1.2 人口预测模型建立与求解

以 2020 年的该地区人口规模，记为 P ；使用 ARIMA—岭回归模型对十四五（2021-2025 年）至二十一五（2056-2060 年）期间的人口进行了预测。其结果如图 9 至图 12 所示。




图 9: 2021-2025 年人口预测结果




图 10: 2021-2025 年人口 ARIMA—岭回归模型预测残差检验结果




图 11: 2021-2060 人口预测结果




图 12: 2021-2060 年人口 ARIMA—岭回归模型预测残差检验结果

基于 ARIMA—岭回归模型的分析，我们观察到在未来几十年内，人口数量呈现出增长趋势。该趋势在统计上是显著的，显示出了长期的人口扩张，但整

体呈现出平稳增长的趋势。我们的模型考虑了，碳排放对人口增长的影响，这意味着当碳排放量下降时，人口持续增长但整体增长趋势放缓。

为了验证 ARIMA 模型的质量和拟合程度，我们进行了残差检验，以评估模型的残差序列。标准差是对模型拟合数据质量的重要度量。较低的标准差表明模型能够很好地拟合数据，从图 x 中可以看出，该标准差较小，很好的拟合了数据。图 x 的自相关函数（ACF）用于检测残差之间的相关性。通过 ACF，我们可以知道所显示的滞后值接近于零，表明该残差是白噪声。通过偏自相关函数（PACF）可知残差序列的自相关性受到碳排放因素的影响，人口与碳排放量呈现负相关。在 QQ 图中可知，整体残差服从正态分布，集中于一条直线上。

6.1.3 GDP 预测模型建立与求解

以 2020 年的该地区 GDP 总量为基期，记为 HGP；使用 ARIMA—岭回归模型对十四五（2021-2025 年）至二十一五（2056-2060 年）期间的 GDP 总量进行了预测。其结果如图 13 和 15 所示，图 14 和 16 为其一些评估参数。




图 13： 2021-2025GDP 总量预测结果

图 14: 2021-2025 年 GDP 总量 ARIMA—岭回归模型预测残差检验结果




图 15: 2021-2060GDP 总量预测结果




图 16: 2021-2060 年 GDP 总量 ARIMA—岭回归模型预测残差检验结果

如图 16 所示，2021-2025 年该地区的 GDP 总量增长是显著的，且直到 2060 年，GDP 总量任有明显上升趋势，处于稳步平稳增长期，我们的模型考虑了，碳排放对 GDP 总量的影响，这意味着当碳排放量下降时，GDP 总量仍然飞速增长，这是因为我国采取由高速发展向高质量发展转变带来的显著效果，第三残叶崛起，传统低产高耗产业转型升级，在实现碳减排和碳达峰的过程中仍能兼顾 GDP 飞速上升。

同人口预测模型相似，该模型的大部分残差于 0 附近波动，但存在异常值，整体检验效果较好，相关检验效果都很好，该 GDP 预测模型拟合效果和预测效果都是非常准确的。

6.1.4 能源消费总量模型的预测和求解

建立 5.5.3 中的 STIRPAT 模型分析研究区域碳能源消费总量的影响因素，但本模型仅考虑人口规模和经济的影响，建立如下模型：

$$\ln(ES) = u + \gamma \ln(HGP) + \phi \ln(P)$$
 (35)

式中 ES 为碳排放总量，HGP 为该地区 GDP 总量，P 为人口规模，其系数意义在这里不过多赘述。通过岭回归得线性回归模型结果如下表 11 所示：

表 11 岭回归线性回归模型结果



	非标准化系数		标准化系数	t	P	VIF	R ²	F
	B	标准误	Beta					
常数	19679.863	1259.039	-	17.534	0.000***	-	0.9146	F=73.464 P=0.000***
GDP 总量	0.128	0.0169	0.954	8.668	0.000***	1		
人口规模	0.137	0.0217	0.964	6.522	0.000***	1		

因变量：能源消费量总量
注：***、**、*分别代表 1%、5%、10%的显著性水平

得到结果，如下所示

$$\ln(ES) = 19513.993 + 0.128 \ln(HGP) + 0.137 \ln(P)$$
 (36)

根据关系式建立相同的预测模型，对 2010-2020 年的能源消耗量拟合，并与实际值进行比较，得到结果如下图 17 所示



(c)能源消费量岭回归误差值

(d)岭回归拟合

图 17：能源消费量拟合效果

如图 17(a)(b)所示，用岭回归模型对能源消费量进行拟合，可以看出该模型能较好的对其进行预测，并且拟合曲线呈多段线性函数,具有较少误差;跟据 (c) 可看出该模型的预测值与真实值误差大致为 0，最高误差值为 38tce，通过 X (d) 可以看出该模型的拟合效果较好，因此可以认为岭回归模型能较好的对其进行预测与拟合。

接下来，我们以 2020 年为基期，前面预测的人口规模和 GDP 总量为数据，分别对十四五（2021-2025 年）至二十一五（2056-2060 年）期间的能源消费总量进行预测，其结果如下图 18 所示。




图 18：十四五（2021-2025 年）至二十一五（2056-2060 年）期间的能源消费总量预测结果

从图中可以看出，能源消费总量总体呈增长趋势，但增速缓慢，这和该地区 GDP 总量飞速发展和人口规模缓慢增长有关，虽说为实现碳达峰、碳中和目标，产业转型和能源消费结构变化，会给能源消费总量带来影响，但 GDP 增长需要大量能源来支持，因此能源消费总量仍跟随 GDP 增长，但因产业转型，能源的利用效率提高，绿色能源的发展和国家政策的推行等，释放了经济发展红利，经济飞速增长的同时不至于能源消费总量剧增。

6.1.5 相关预测结果

以 2020 年为基期，结合两个时间节点（2035 和 2050），通过分析国家、省市低碳发展规划中碳排放总量控制目标及分解落实机制相关要求，并结合该区相关部门“十四五”规划任务目标，综合研判各参数的变化趋势，预测该区域十四五（2021-2025 年）的人口、经济(GDP)和能源消费量结果如表 12 所示：

表 12 十四五期间人口、经济(GDP)和能源消费量预测结果

	2021 年	2022 年	2023 年	2024 年	2025 年
人口(万人)	8461.637538	8472.69997	8483.827166	8497.018981	8509.27527
经济(亿元)	91003.26075	92426.16569	92910.37054	93441.73481	93933.94469
能源消费量 (万 tce)	32589.85426	33030.922	33449.52716	33945.31997	34118.63607

该区域在十四五区间人口和能源消费量呈现增速较小，这和国家碳达峰计划如期进行有关，产业转型和能源结构变迁将对 GDP 和人口发展带来一定冲

击，以及基于现有能源消耗趋势预测的未来区域能源发展水平，对于技术的发展与政策的持续性协调性预估判断具有局限性,可能会造成预测值与实际值存在较大偏差。

二十一五期间（2056-2060 年）人口、经济（GDP）和能源消费量变化预测结果如表 13 所示:

表 13 二十一五期间人口、经济(GDP)和能源消费量预测结果

	2056 年	2057 年	2058 年	2059 年	2060 年
人口(万人)	7951.225784	7830.246394	7694.467128	7546.078094	7385.96663
经济(亿元)	267757.336	271375.1978	279753.4821	282497.7520	290145.3326
能源消费量 (万 tce)	57989.53488	58696.16424	59402.7936	60109.42296	60816.05232

根据表 13 可知，在十四五期间人口数量存在下降趋势；经济增长显著，于 2020 年相比，增长幅度接近 3 倍；能源消费量增长接近 2 倍，这说明国家碳减排策略得到有效实施，产业转型，和能源消费结构调整取得巨大成功，清洁能源比例大幅上升，第三产业成为国家 GDP 发展的支柱产业，使得能源消费总量跟随 GDP 增长的强相关关系变弱，经济实现高质量发展。

6.2 区域碳排放量预测模型

6.2.1 平均碳排放因子

根据前文所述，此处由于考虑的是碳排放量与人口、GDP 和能源消费量的关系，碳排放量还与能源消费和能源消费品种有关，因此需要对每个能源消费及供应部门和能源消费品种的碳排放量进行预测。在本问题中，由于居民生活消费的 GDP 为 0 前文所述的总碳排放量计算模型可以简化为^[35,36]:

$$C = \sum_{i=1}^n \sum_{j=1}^m CE_{ij} \times ES_{ij} \times EG_i \times GG_i \times P \quad (37)$$

根据前文所述的，ARIMA 模型和岭回归方法建立本小节的预测模型为:

$$\delta_0 = Cm - \sum_{i=1}^n \beta_i^* \frac{cm_i}{cs_i}, \delta_i = \frac{\delta_i^*}{cs_i} \quad (38)$$

式中， δ_0 为碳排放因子， Cm 为平均碳排放量， i 为第 i 个部门， cs_i 为第 i 个部门碳排放量标准差。

根据附件提供的碳排放因子数据，我们对能源供应部门的各个能源消费品种的碳排放因子进行了详细分析。这些品种包括但不限于煤炭、石油、天然气等。具体而言，我们将碳排放因子按照能源消费部门和消费品种进行了分类。根据问题 1 中计算出的能源供应部门按能源消费品种结构排布的碳排放量计算结果，重新排布后的能源消费结构进行平均碳排放因子计算可得如下结果：

表 14 平均能源碳排放因子

煤炭	2.33	2.62	2.62	2.27	2.03	2.18	2.19	2.14	2.07	1.94	1.95
油品	1.15	1.22	1.41	1.38	1.56	1.55	1.72	1.92	2.32	2.25	2.03
天然气	1.58	1.63	1.57	1.57	1.54	1.57	1.63	1.60	1.59	1.59	1.58
热力	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00

电力	1.47	1.50	1.47	1.51	1.31	1.39	1.38	1.37	1.36	1.37	1.31
其他	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00

根据上表格的计算结果结合能源消费品种结构和能源供应部门的各能源消费品种碳排放因子可以得到各部门各能源消费品种碳排放因子数据和各部门各能源消费品种能源消费数据，其结果见附录文件。

6.2.2 各部门碳排放量预测

类似的，我们对各部门在 2021-260 的碳排放量的进行的预测。部分预测结果如下图所示，所有预测结果见附录文件。

我们针对农林消费部门、工业消费部门、建筑消费部门、交通消费部门以及居民生活消费部门，深入探讨了各自的碳排放模式及其背后的影响因素。因油品包含的种类众多，碳排放强度适中，且其在各个部门的能源使用中不可或缺，因此我们选取其作为例子来分析各部门的碳排放量。

(1) 农林消费部门

我们的研究如图 x 所示，农林消费部门对整体碳排放的影响相对较小。通过对农林消费部门的碳排放量进行分析，我们利用 ACF 和 PACF 的方法，深入探讨了其与主要能源类型之间的关联性。还运用 QQ 图来检验模型的残差分布是否满足正态性。




图 19：农林部门油品碳排放预测图




图 20：农林消费部门碳排放预测残差检验图

研究表明，农林消费部门的碳排放量与油品、煤炭和电力存在一定的关系。具体而言，油品是农林消费部门碳排放的主要来源，其需求量远远超过其他能源。这一发现在能源消费结构和农林部门的生产过程中具有重要意义，为能源供应和碳减排政策提供了指导。

我们通过 ACF 和 PACF 的分析，进一步验证了农林消费部门的碳排放与所涉及的能源之间的密切关系。ACF 和 PACF 的图示表明，在特定滞后阶段，农林消费部门的碳排放与油品、煤炭和电力的消费存在相关性，这反映了它们之间的相互作用。通过 QQ 图的绘制，我们验证了农林消费部门的碳排放模型的残差分布。结果显示，残差呈现出正态分布的特征，基本分布在一条直线上，这表明模型的残差符合正态性假设。这一结果为我们的模型提供了重要的可信度和准确性。

（2）能源供应部门

能源供应部门在能源消耗中扮演着重要角色，尤其是对于油品、天然气、煤炭等三种主要能源。这三种能源一直以来都在支撑各个部门的能源需求，然而，如图 21 所示，我们的模型预测表明，随着清洁能源技术的广泛应用，对这三种传统能源的依赖程度正在逐渐降低。这一趋势与能源供应部门的技术升级和可持续发展政策的实施密切相关。




图 21：能源供应部门油品碳排放预测图




图 22：能源供应部门碳排放预测残差检验图

如图 22 所示，我们通过 ACF 和 PACF 的分析，进一步验证了能源供应部门的碳排放量与油品、天然气和煤炭等能源之间的复杂联系。这些分析显示，能源供应部门的能源消耗在特定滞后阶段与相应的能源类型之间存在负相关，这反映了它们之间的关联性和影响。这种深度分析有助于我们更好地理解不同能源类型在供应部门中的角色和动态变化。

我们的研究结果表明，能源供应部门在能源结构上的多样化对碳中和和可持续发展至关重要。虽然能源供应部门仍然依赖于传统能源，但随着清洁和可再生能源的不断增加，碳排放量逐渐下降，并趋于稳定在一个可控的范围内。这一趋势对于推进碳中和和减缓气候变化具有积极意义，也为能源结构的可持续性提供了有力支持。

（3）交通消费部门

如图 23 的预测结果表明，交通消费部门对非化石燃料的消费量出现了显著上升。与此同时，传统化石燃料，如煤炭、油品和热力的需求呈下降趋势，而对于天然气和电力的需求则持续增加。这一现象反映了中国在能源转型和碳中和方面取得的显著进展，交通消费部门正积极参与并贡献自己的一份力量，推动着可持续能源的使用。




图 23：交通消费部门油品碳排放预测图




图 24：交通消费部门碳排放预测残差检验图

通过 ACF 和 PACF 的分析，如图 x 所示，我们深入研究了交通消费部门的碳排放与不同能源消耗之间的相关性。我们的发现显示，交通消费部门的碳排放与煤炭消费呈正相关关系，这意味着煤炭消耗的增加可能导致碳排放量的上升。同时，我们还观察到交通消费部门的碳排放与油品消耗之间存在正相关性，这说明油品的使用也与碳排放量相关。然而，与电力消耗之间却呈现负相关，这表明电力的使用可能对碳排放产生抑制作用。至于天然气和热力消耗，与交通消费部门的碳排放关联性较小，变化不大。通过 QQ 图的绘制，我们对交通消费部门碳排放与各能源消费之间的残差分布进行了检验。结果显示，残差分布呈现出明显的正态分布特性，符合正态性假设。

(4) 建筑消费部门

我们的研究如图 25 所示，建筑消费部门的碳排放与多种能源消耗之间存在密切关联。具体而言，油品、天然气、电力以及热力等能源呈现正相关性，这表明建筑部门在能源消耗方面对这些能源的需求具有显著影响。这一发现对于未来建筑部门的能源结构调整和碳排放控制提供了重要线索。




图 25：建筑消费部门油品碳排放预测图




图 26：建筑消费部门碳排放预测残差检验图

通过 ACF 和 PACF 的分析，我们进一步探讨了建筑消费部门碳排放与各能源之间的复杂关系。图 x 显示，建筑部门的碳排放与油品、天然气和电力的消耗之间存在正相关性，这意味着这些能源的使用与碳排放量之间存在一定的线性关系。然而，煤炭的消耗呈现出一种波动状态，表明其对碳排放的影响可能受到其他因素的干扰，如技术改进或政策调整。我们通过 QQ 图绘制，验证了建筑消费部门碳排放与各能源消耗之间的残差分布。结果表明，残差分布整体呈现正态分布特性。

（5）工业消费部门

研究结果如图 27 表明，工业消费部门的碳排放量与所有能源品类均呈现正相关关系。这表明工业制成品的生产不可或缺地依赖于各种能源的供应。随着工业水平的不断提升以及生产工艺的不断进步，我们预测碳排放量将逐年减少。然而，值得注意的是，工业消费部门的碳排放因子将保持不变，以确保维持一个稳定的生产水平。这一现象对于工业部门的可持续发展和碳减排政策具有重要意义。




图 27：工业消费部门油品碳排放预测图




图 28：工业消费部门碳排放预测残差检验图

在图 28 中，通过 ACF 和 PACF 的分析，深入研究了工业消费部门的碳排放与各种能源之间的复杂关联性。结果显示，工业消费部门的碳排放与油品、天然气、电力、热力、煤炭以及其他能源的消耗之间存在明显的正相关性。这意味着这些能源的使用与碳排放量之间存在一定的线性关系，工业消费部门在多能源供应中起到了至关重要的角色。

6.2.3 各部门碳排放量和 GDP 的关系

此外，本研究进一步探讨了各部门碳排放与国内生产总值（GDP）之间的关系，并发现不同部门的碳排放与 GDP 之间存在着不同的关联模式，这里我们重点分析了工业消费部门和建筑消费部门的 GDP 预测值，可以看出，到二十一五期间，建筑部门的 GDP 总量是能源消费部门的接近两倍，这两个部门分别是第二产业和第三产业中对 GDP 产值贡献最大的部门，工业消费部门当前呈现低产高耗特性，产业模式落后，产值低，社会经济效益差，环境污染大，因此是产业转型和节能减排措施的重点对象。而建筑消费部门则呈现完全相反的特性，其能源消耗低，社会经济效益高，生产力强和技术创新能力等优点成为重点发展部门，得到大量的经济红利。但一个国家或地区，需要各产业平衡发展，重工业等产业是国民经济的基石，因此工业转型重中之重，从预测结果可以看出，该地区并没有放弃工业发展，相反随发展缓慢，但稳中求进，取得不错成效，这得益于产业创新性转型，大量使用清洁能源，全面贯彻国家减排政策带来的成果。




图 29：工业消费部门 GDP 预测图




图 30：工业消费部门 GDP 预测残差检验图




图 31：建筑消费部门 GDP 预测图




图 32：建筑消费部门 GDP 预测残差检验图

对于其他部门的分析如下所示，预测图详见附录文件。

首先，工业消费部门、建筑消费部门以及农林消费部门的碳排放量与 GDP 呈现正相关关系。这一正相关性反映了这些部门在生产过程中的高能耗和高排放特点。随着经济活动的增加，它们的能源消耗也随之上升，从而导致碳排放量的增加。这一趋势在工业领域、建筑领域以及农林领域得到了充分体现。

其次，能源供应部门和交通消费部门的碳排放量与 GDP 之间呈现负相关关系。这一现象可以归因于能源供应部门的向清洁能源的转型和新能源交通工具的普及。随着碳达峰和碳中和目标的实现，能源供应部门逐渐减少了传统能源的使用，而交通消费部门采用了更环保的出行方式。这些变革导致了碳排放量的下降，与 GDP 之间呈现负相关关系。

综上所述，各部门碳排放与 GDP 之间的关系反映了不同部门在经济增长和碳减排方面的不同贡献和发展方向。正相关的部门需要更多的碳减排政策和技术创新来降低其碳排放强度，而负相关的部门则展示了可持续发展的潜力和路径。这一深入解释有助于更好地理解各部门在碳减排和经济增长之间的平衡关系，为碳减排政策的制定提供了科学依据。

6.2.4 用 STIRPAT 模型计算区域碳排放量

构建扩展 STIRPAT 模型计算区域碳排放量，其自变量分别为人口规模 P、GDP 总量、能源消费总量 ES、能源消费结构 GG、部门划分 EG^[37]。

$$\ln(C) = u + \beta \ln(ES_{ij}) + \sigma \ln(EG_{ij}) + \eta \ln(GG_{ij}) + \tau \ln(HPG) + \delta \ln(P) \tag{39}$$

相比 5.5.3 建立的模型，这里引入了能源消费结构的影响，引入了各种类能源的影响，使其结果更加准确。这里同样使用岭回归对其弹性因子进行求解，具体公式前述已经做过分析，这里不做过多赘述。其岭回归结果如下表 15 所示：

表 15 岭回归结果

K=0.147	非标准化系数	标准化系数	R ²	调整 R ²	F
	B	Beta			
常数	8144.373	-	0.991	1.098	-6.351 P=0.000***
人口规模	1.639	0.068			
GDP 总量	0.081	0.056			
能源消费量总量	0.783	0.269			
能源消费结构	72121.063	0.018			
部门划分	1.5774	0.22			

利用 SPSSPRO 绘制了岭迹图，如下图 33 所示。同时，模型的拟合优度 R² 为 0.991，且由图可得，当 K=0.4 时，图 2 中 5 个自变量的岭迹图趋于稳定且均大于零。因此，本研究选择 K=0.4 作为岭值，获得基于岭回归的线性回归结果在模型表现为较为优秀。




图 33: 碳排放总量模型岭迹图

建立得到, 碳排放量与人口、GDP 和能源消费量等预测相关联关系式为:

$$\ln(C) = 8144.373 + 0.783 \ln(ES_{ij}) + 1.5774 \ln(EG_{ij}) + 72121.063 \ln(GG_{ij}) + 0.081 \ln(HPG) + 1.639 \ln(P) \quad (40)$$

最终, 根据关联式采用加权预测模型, 得到结果如下表 16 所示。

表 16 十四五期间和二十一期五期间碳排放量预测值

年份	2021	2022	2023	2024	2025
区域碳排放量(万 tCO ₂)	74155.3	75495.8	76665	77672.3	78527.1
年份	2056	2057	2058	2059	2060
区域碳排放量(万 tCO ₂)	64180.3	63152.7	62119.5	61082.2	60042.3

其十四五期间和二十一期五期间碳排放量预测值如下柱状图 34 所示




图 34: 十四五期间和二十一期五期间碳排放量预测值

从表中可知, 十四五期间的碳排放量仍处于增长阶段, 增长率较小, 说明减碳相关政策的实施初具成效, 应继续实行相关政策, 加快产业转型, 转变能源消费结构。而到二十一期五期间, 碳排放量已经实现逐年下降, 下降率逐年增大, 说明碳排放相关措施已经取得极大效果, 产业转型出色完成, 能源结构发生巨大转变, 技术创新取得极大成效, 这和我我国制定的实现进入创新新国家行列有着巨大关系。但二十一期五期间碳排放量对比十四五期间的减少量不明显, 使得碳中和任务无法完成, 因此需加大合理性政策的制定, 使碳中和任务按时出色完成, 让我国兑现碳达峰、碳中和诺言成为可能。

七、问题三模型的建立与求解

7.1 情景设计

在面对全球气候变化挑战和中国政府宣布 2060 年实现碳中和的背景下，我们现在迫切需要构建不同情景下的路径规划，以实现这一宏大目标。碳中和目标不仅是一项具有全球影响力的承诺，也是中国迈向可持续发展和生态文明建设的关键一步。为了实现这一目标，我们需要深入思考和规划，以确保碳排放在 2060 年前得以实质性减少，同时维护经济增长和社会发展。

首先，我们需要考虑自然情景，即在没有人政策干预的情况下，碳排放将按照当前趋势继续增加的可能性。这种情景下，碳达峰和碳中和的时间可能较晚，可能导致高碳排放、高能源消耗以及对化石能源的持续依赖。这一情景的分析将有助于我们了解不采取措施的后果。

其次，基准情景下，政府采取一般性政策来推动碳达峰和碳中和。这种情景下，碳达峰和碳中和时间节点较为合理，有望减少碳排放。适度的能源效率提升可以降低能源消耗，并逐步增加非化石能源比重可以减少对化石能源的依赖。这一情景的规划将有助于确定最低程度的碳减排要求。

最后，雄心情景下，政府采取积极的政策来加速碳达峰和碳中和的实现。这包括大幅度提高能源效率和非化石能源比重。在这一情景下，碳达峰和碳中和时间节点较早，有望大幅度减少碳排放，显著降低能源消耗，并减少对化石能源的依赖。这一情景的规划将为中国提供最具雄心的碳减排路径，但可能需要更多的资源和政策支持。对不同情景下的碳排放路径规划至关重要。这将帮助我们更好地理解各种政策和措施对碳减排的影响，为中国实现 2060 年碳中和目标提供明确的方向和决策依据。同时，这也是中国在全球气候领域继续发挥领导作用的机会，为全球气候变化问题作出更大的贡献。

7.1.1 自然情景

在自然情景中，我们假设没有任何人为政策干预，碳排放将按照当前的发展趋势持续增加^[38]。这一情景通常被用来作为其他情景效果的基准对比。在这个情景中，政府没有明确的政策或措施来限制碳排放，这可能会导致碳达峰和碳中和的时间点相对较晚，因而引发更高水平的碳排放。同时，能源效率的改善进展较为缓慢，可能导致高水平的能源消耗，这不仅会增加能源成本，还可能对环境产生不利影响。此外，非化石能源比重的增长也受到限制，可能导致继续依赖化石能源，增加能源供应的不稳定性和环境的不可持续性。因此，了解自然情景的潜在影响是至关重要的，它有助于我们认识到不采取行动可能带来的不利后果，为制定更有效的政策和措施提供了重要参考。

7.1.2 基准情景

在基准情景中，我们设定政府将制定政策和措施，以符合国际共识下的碳达峰和碳中和时间节点。政策的着眼点在于推动碳排放控制，但并没有采取过于激进的手段。这一情景下，碳达峰和碳中和的时间节点相对较为合理，有望实现在可接受的时间内，从而有望减少碳排放的总量。政府的政策努力也包括适度的能效提升，通过改进资源利用效率来减少能源的消耗。这一措施不仅有

助于降低经济活动对能源的依赖，还能提高产业竞争力并降低能源成本。此外，基准情景还鼓励逐步增加非化石能源的比重，这将有助于减少对化石能源的依赖，增强能源供应的多样性，并在环境可持续性方面取得进展。因此，基准情景的规划代表了一种相对平衡的路径，旨在在碳减排方面取得显著进展，同时确保经济的稳健增长和能源的可持续利用。这种情景的制定有望在实践中实现可行的、可持续的碳减排目标。

7.1.3 雄心情景

雄心情景（Ambitious Scenario）

在雄心情景中，我们设想政府采取积极的政策和措施，旨在迅速推动碳达峰和碳中和的实现，这包括采取大胆的行动来提高能源效率和增加非化石能源比重^[39]。在这一情景下，政府的政策举措旨在加速碳减排进程，以应对全球气候挑战。最显著的影响是碳达峰和碳中和时间节点将较早实现，这意味着中国将更早地结束净碳排放，为全球气候目标作出贡献。此外，强烈的能源效率提升将显著减少能源消耗，从而减少了能源成本，提高了资源的可持续利用。政府还将大幅度增加非化石能源比重，这将降低对化石能源的依赖，提高能源供应的多样性，并在环境可持续性方面取得实质性进展。雄心情景的规划代表了一种积极主动的路径，通过强有力的政策措施来应对气候变化，为中国的碳中和目标确立了更具雄心的路线，同时也为可持续发展和环境保护作出了积极贡献。这一情景的制定有望在实践中实现更迅速、更彻底的碳减排，为全球气候保护事业提供了典范。

7.1.4 分析决策

情景模拟结果的评估和决策分析中，我们使用了 IDMI（Integrated Decision Matrix and Indices）作为评价工具。IDMI 是一个无量纲的值，可类比为是一个三角形的面积或四面体的体积，用于比较不同方案的效果。在计算 IDMI 值之前，我们选择了一个或两个关键变量，作为决策评价的标准，然后计算每个方案的 IDMI 值^[41,42]。IDMI 值越小，表示所选方案越优越。

为了确保决策结果的准确性，本研究选定了两个关键变量进行分析，然而，IDMI 的决策过程中不牵涉到变量的权重问题。因为不同变量在实现目标过程中的难度程度各不相同，为了考虑这一因素，我们引入了难度系数 D 。这样，我们可以更全面地评估不同方案，考虑到实施的难易程度，以做出更合理的决策。

若系统中有 m 个场景需要选择，每个场景有 n 个评价变量。修改后的 IDMI 值的计算过程如下：

$$\begin{aligned} IDMI_i &= \left(\sum_{j=1}^{n-2} C_{ij} \right) \times C_n \times C_{n-1} \times D_i \\ &= \left(\sum_{j=1}^{n-2} Q_{ij} \right) \times C_n \times C_{n-1}, i = 1, 2, \dots, m \end{aligned} \quad (41)$$

式中， $IDMI_i$ 为方案*i*的 IDMI 值， m 为备选方案方案个数， n 为变量个数， C_{ij} 为方案*i*的变量*j*的值， D_i 为方案*i*的实施难度系数， Q_{ij} 为方案*i*的非关键变量*j*与实施难度系数的乘积，“ C_n ”为第一个关键变量，“ C_{n-1} ”为第二个关键变量。

本研究以碳排放强度作为衡量标准。假设没有政策强化措施，基线情景的 D 值设为 1。设定基线情景与方案 i 的碳排放强度之比作为情景的难度系数， D_i 值越大，难度系数越大。

$$D_i = \frac{CEI_0}{CEI_i}, i = 1, 2, \dots, m \quad (42)$$

式中， CEI_0 为基线情景的碳排放强度， CEI_i 为情景*i*的碳排放强度。

IDMI 的具体计算步骤分为四个部分。(1)数据输入。将来自统计或场景模拟的初始数据作为输入值输入 IDMI。(2)数据的无因次处理。由于评价变量的单位不同，不能直接用于方程计算。消除尺寸的影响是必要的。此外，还需要使评价变量具有方向一致性，即将小的值设置为偏好项。如下两式所示。(3)计算变量之间的相关系数。为了避免多重共线性的影响，应剔除相关系数过高的变量。(4)计算 IDMI 值。采用 IDMI 方法计算 IDMI 值，值最小的场景为最优场景。

$$C'_j = \frac{C_j}{C_{jmax}} \quad (43)$$

对于正变量（变量越小越好）

$$C'_j = \frac{C_{jmin}}{C_j} \quad (44)$$

对于负变量（变量越小越好）

其中， C'_j 为变量 j 的标准化值， C_j 为变量*j*的实际值， C_{jmax} 为变量 j 的最大值， C_{jmin} 为变量*j*的最小值。

7.2 多情景下碳排放量核算方法

根据题目的假设，即 2035 年的 GDP 比基期（2020 年）翻一番；2060 年比基期翻两番；2060 年生态碳汇的碳消纳量为基期碳排放量的 10%；2060 年工程碳汇或碳交易的碳消纳量为基期碳排放量 10%。故以 2020 年为基期，基本假设量如表 X 所示：

表 17 2060 年碳汇或碳交易的碳消纳量基本假设量

时间(年)	GDP(亿元)	生态碳汇的碳消纳量(万 tCO ₂)	工程碳汇或碳交易的碳消纳量(万/CO ₂)
2035 年	177,366.42	\	\
2060 年	354,732.84	7,263.3324	7,263.3324

7.2.1 情景设置

采用情景分析法，基于给定的关键假设，在不确定环境下解读未来,是低碳发展路径研究的常用方法。受到长期经济、社会能源、技术诸多因素的影响，碳中和路径有很高的不确定性和多样化发展方向，通过多样化情景构建能够帮决策者充分考虑未来可能发展图景，更好地理解 and 应对发展过程中遇到的困难和挑战。

根据 5.5.2 中计算所得的相关系数，我们认为如果相关系数大于 0.8，则变量之间存在较强的多重共线性。因此，本研究最终选取第三产业生产总值、第一产业生产总值、能源消费结构和能源消费总量来作为 IDMI 决策输入值，如表 18 所示：

表 18 不同情境下的 IDMI 决策输入值

变量	自然情景	基准情景	雄心情景
第三产业生产总值	0.8668	0.9668	1.0000
第一产业生产总值	0.8604	0.9304	1.0000
能源消费结构	0.8538	0.9105	0.9927
能源消费总量	0.8929	1.0000	1.0000

根据式（42）可以计算出不同场景下的场景难度系数，如表 19 所示：

表 19 不同场景下的场景难度系数

场景	自然情景	基准情景	雄心情景
难度系数	0.8421	1.0000	1.3327

7.2.2 碳排放核算结果

化石能源燃烧产生的 CO₂由行政区域内化石能源燃烧产生的直接排放和外调电力带来的间接排放两部分构成。化石能源消费活动按部门划分为农林、能源供应、工业、交通和建筑五个终端能源消费部门，化石能源燃烧产生的直接碳排放量计算方法如式（45）：

$$CO_{2, \text{直接}} = \sum A_i * EF_i \tag{45}$$

其中，A_i 表示不同种类化石能源的消费量(标准量)；EF_i 表示不同种类化石能源的 CO₂ 排放因子。

外调电力产生的间接排放量计算公式如式（46）：

$$CO_{2, \text{间接}} = \sum A_e * EF_e \tag{46}$$

其中，A_e 表示城市调入电量，EF_e 表示调入电量所属区域电网平均供电排放因子。

结合城市碳排放经济社会综合性的特点，本研究选择 LEAP 模型作为城市碳排放核算的建模工具，LEAP（Low Emissions nalsis Plaom）是斯尔摩环究(SE 开发的用于能源政策、与变化缓解和空气污染缓解规划的软件工具，由于其具有建模结构灵活、模型框架简单且数库丰富等诸多优势，现已被地方、国家和

全球尺度的多种机构广泛使用。基于 LEAP 搭建城市碳排放核算模型的框架如图 35 所示。




图 35 碳排放核算模型的框架

根据式（45）和式（46），不同场景的碳排放核算如下表 20 所示。

表 20 不同场景的碳排放核算

年份	自然情景（万 tCO ₂ ）	基准情景（万 tCO ₂ ）	雄心情景（万 tCO ₂ ）
2021	74611.14	74155.26	73326.04
2022	76426.89	75495.8	73816.83
2023	78087.59	76664.97	74121.77
2024	79600.02	77672.34	74255.99
2025	80970.7	78527.07	74233.65
2035	88168.68	80424.59	67941.18
2056	80024.49	64180.31	42814.2
2057	79227.27	63152.69	41657.59
2058	78410.13	62119.46	40517.84
2059	77574.8	61082.17	39395.75
2060	76722.91	60042.27	38292.02

表 20 所示，该区域在自然情景下，碳排放于 2035 年达到峰值排放 88168.68 万 tCO₂，较基期增长 21.3%，2060 年约排放 76722.91 万 tCO₂；在基准情景下，该区域碳排放于 2035 年达到峰值，于 2060 年下降到 60042.27 万 tCO₂，相较于基期下降了 17.3%；在雄心情景下，该区域碳排放于 2035 年降至

67941.18 万 tCO₂，相较于基期下降了 6.5%，于 2060 年降至最低为 38292.02 万 tCO₂，相较于基期下降了 47.3%。

以基准情景为例，(其余情景见附件 A)区域碳排放值与各部门碳排放量如图 36 所示。




图 36 碳排放核算模型的框架

如图(a)(b)所示为各部门碳排放量与区域碳排放量的柱状图，可以看出在十四五期间，仅工业在区域碳排放量占有重要比重；二十一五区间工业、交通和建筑在区域碳排放量中占有重要比重。

基准情景下各部门的碳排放量总和和区域碳排放量比较结果如表 21 所示。

表 21 基准情景下各部门的碳排放量总和和区域碳排放量

时间(年)	各部门的碳排放量(万 tCO ₂)	区域碳排放量(万 tCO ₂)	误差量(万 tCO ₂)
2021	73383.24864	74155.26	772.01136
2022	73912.03236	75495.8	1583.768
2023	74440.62835	76664.97	2224.342
2024	74968.65666	77672.34	2703.683
2025	75496.5081	78527.07	3030.562
2056	59831.54207	64180.31	4348.768
2057	60330.79529	63152.69	2821.895
2058	57675.87509	62119.46	4443.585
2059	57308.5798	61082.17	3773.59
2060	57391.32226	60042.27	2650.948

结合所研究城市的城镇化工业化段、经济发展势、自身能源资源等选择可行的城市碳中和路径，以实现“城市战略个性化”的要求，具体应考虑城市的碳达峰中和目标年份、碳达峰峰值量的大小，以及实现碳中和的时间等要求，考虑到未来的经济社会发展形势变化、技术突破和可行性等因素，对实现长期目标还应预留不确定性，允许存在一定误差量。

7.3 双碳（碳达峰与碳中和）目标与路径规划

中国在 2030 年和 2060 年分别设定了碳达峰和碳中和的重要目标。2030 年的碳达峰要求中国在该年前实现国内温室气体排放的峰值，同时提高非化石能源在能源消耗中的比重至约 20%。而 2060 年的碳中和目标则要求中国在 2060 年前实现国内的碳中和，即净碳排放量为零或负值，同时采用大规模的清洁能源、碳捕获和储存技术等措施，以减少碳排放并抵消碳排放。为实现这些目标，中国需采取广泛的政策和行动，包括制定碳减排政策、发展清洁能源、提高能源效率、促进绿色交通和工业、加强碳汇建设、推动科技创新等，需要政府、企业和社会各界的协同努力，以积极应对气候变化挑战，推动可持续发展，为全球气候保护事业作出积极贡献。

7.3.1 GDP、人口、能源消费量目标值

根据 7.2 中的假设，在 2035 年，中国的国内生产总值（GDP）预计将增长至基期（2020 年）的两倍，而到 2060 年，GDP 将增长至基期的 4 倍。2060 年的生态碳汇预计能够吸收相当于基期碳排放量的 10%。2060 年的工程碳汇或碳交易预计也能够消纳相当于基期碳排放量的 10%。这些假设共同构成了中国在碳中和战略中的关键要素，反映了对气候变化应对和可持续发展的承诺。2025 年、2030 年、2035 年、2050 年和 2060 年的 GDP、人口、能源消费量目标值如图 37 和图 38 所示。




图 37：人口在自然情景下和 GDP 增长图




图 38：各情景下能源消费量的目标值

各关键节点的 GDP、人口、能源消费量的目标值如表 22 所示。

表 22 GDP、人口、能源消费量目标值

年份	GDP (亿元)	人口 (万人)	自然情景 (万 tec)	基准情景 (万 tec)	雄心情景 (万 tec)
2025	116766.2	8720.678	38771.85	38575.83	37416.32
2030	146327.3	8880.031	45510.37	45051.37	42383.77
2035	177366.4	9011.057	51670.44	50890.72	46438.27
2050	279352.1	9280.212	66877.5	64874.33	54019.15
2060	354732.8	9389.344	74507.67	71547.01	56047.72

根据提供的数据，中国在 2020 年至 2060 年期间预计人口将增长 19.32%，GDP 将增长 400%。在不同情景下，即自然情景、基准情景和雄心情景下，能源消耗的增长目标分别为 92.16%、85.47% 和 49.79%。具体而言，在碳达峰和碳中和的过程中，中国面临着复杂的挑战，需要实现人口的逐渐增长、高速的经济增长，同时在不同情景下管理能源消耗。在此背景下，基准情景下的目标能源消耗增长相对较为温和，预计能够减缓约 20% 左右，而在雄心情景下，中国将致力于实现目标能源消耗减半的雄心目标。这一过程涉及到综合性的政策和措施，以平衡可持续发展与碳减排的复杂需求。

7.3.2 能源利用的目标值

提高能源利用效率和控制能源消耗量对于实现碳达峰和碳中和目标具有深远的影响。首先，提高能源利用效率是减少碳排放的关键因素之一。通过改善能源系统的效率，可以在生产和消耗过程中减少温室气体的排放，因为更少的能源被浪费或转化为碳排放。这有助于降低环境负担，减少气候变化的影响。

控制能源消耗量对于碳减排同样至关重要。限制能源消耗量有助于降低碳排放，因为更少的能源需求意味着更少的碳被释放到大气中。这对于减少温室气体的排放是必要的，以实现碳达峰和碳中和的目标。

这两个方面的努力互相补充，构成了一个综合性的碳减排策略。提高能源利用效率有助于减少单位产出的碳排放，而控制能源消耗量有助于降低总体的碳排放。这些措施不仅有益于气候保护，还有助于可持续发展，资源保护和环境改善。因此，制定明确的目标值，以衡量和指导能源利用效率和能源消耗量的改进是必要的，可以确保国家在碳减排方面取得可持续和令人满意的进展。这也将有助于提高社会的气候适应能力，应对日益严重的气候变化挑战。在实现碳达峰和碳中和的过程中，明确的数值目标至关重要。这些数值不仅帮助政府和企业评估自身的进展，还允许国际社会进行比较和合作。例如，制定 2025 年、2030 年、2035 年、2050 年和 2060 年的碳排放目标，计算出适当的碳中和措施的量化效果，以及测算出所需的能源转型速度，都需要具体的数值数据支持。这些数据不仅指导着政策制定者和企业的决策，还促使创新、投资和技术发展，以实现更清洁、更可持续的未来。因此，在碳减排的道路上，计算数值目标和结果是确保行动可行性和透明度的基本步骤，它们有助于确保碳达峰和碳中和不仅是抱负，更是可操作的目标。各情景下能源利用效率目标值如表 23 所示。

表 23 各情景下能源利用效率目标值

年份	自然情景	基准情景	雄心情景
2025	21.00%	20.17%	15.80%
2030	31.10%	31.10%	31.10%
2035	29.13%	29.13%	29.13%
2050	23.94%	23.94%	23.94%
2060	21.00%	21.00%	21.00%

各情景下能源利用效率（单位 GDP 耗能目标值）目标值曲线图如下所示：




图 39：2020-2060 年各情景下能源利用效率目标值曲线图

通过上表的各情景下的能源利用效率目标值以及 2020-2060 年各情景下能源利用效率目标值图，我们可以获得关于碳达峰和碳中和目标实现的重要见解。首先，自然情景下的目标值逐年减小，这表明在没有特定政策干预的情况下，能源利用效率改善相对较慢，碳排放水平较高。这暗示了在自然情景下，中国可能会面临碳达峰和碳中和目标的挑战，需要更积极的政策干预。其次，基准情景下的目标值在 2030 年之后趋于稳定，这可能反映了政府采取的一般性政策措施，有助于维持相对稳定的能源利用效率水平。这种稳定性可能有助于实现碳达峰和碳中和目标，但需要确保政策的持续性和有效性。最后，雄心情景下的目标值保持稳定但相对较低，这表明政府采取了积极的政策和措施，以加速碳减排。这包括大幅度提高能源效率和增加非化石能源比重。尽管目标值较低，但这种情景可能代表了更强烈的政策野心，有望在减少碳排放的同时推动碳达峰和碳中和目标的实现。总之，这些能源利用效率目标值反映了政府在碳减排方面的政策取向和行动水平。它们提供了关于不同情景下实现碳达峰和碳中和目标的见解，有助于评估可行性和挑战，以确保中国在应对气候变化方面取得成功。这也强调了政策的关键作用，以实现可持续的能源未来和减少对化石燃料的依赖。

7.3.3 确定非化石能源消费比重的目标值

提高非化石能源消费比重和设定明确的目标值对实现碳达峰和碳中和目标具有至关重要的作用。这些目标不仅有助于减少碳排放，还在多个关键领域产生积极影响。首先，与能效提升紧密相关的提高非化石能源消费比重是一个关键因素。非化石能源，如太阳能、风能和水力能源，通常具有较低的碳排放。然而，如果能源利用效率低下，即使使用非化石能源，也可能导致较高的碳排放。明确的目标值可以促使产业和社会部门进行能效提升，确保清洁能源的充分利用，从而降低碳排放水平。提高非化石能源消费比重需要产业和产品升

级，这包括鼓励清洁技术的研发和应用，以及推动传统产业向更清洁、更高效的方向转型。明确的目标值可以激发企业和产业部门采取创新性的举措，以生产和消费更环保的产品和服务，从而推动经济的可持续增长。

其次，设定非化石能源比重的目标值是能源脱碳的重要步骤。能源脱碳意味着减少对化石燃料的依赖，而非化石能源在此过程中发挥了关键作用。明确的目标值有助于引导国家朝着更清洁、更可持续的能源结构迈进，减少对碳密集型能源的依赖，从而推动碳排放的下降。

最后，提高非化石能源比重与能源消费电气化紧密相关。明确的目标值鼓励能源消费电气化，即将电力作为清洁能源的载体，应用于交通、制造、建筑和家庭等领域。这有助于降低碳排放，提高能源利用效率，并促进可再生能源的大规模利用。

明确提高非化石能源消费比重的目标值在实现碳达峰和碳中和方面发挥着至关重要的作用。这些目标激发着政府、产业和社会各界采取积极的措施，从能效提升到产业升级，以及能源脱碳和电气化等多个层面，推动可持续发展和减少对化石燃料的依赖，为应对气候变化挑战作出积极贡献。这也反映了政策的关键作用，以实现更清洁、更可持续的能源未来。

在这一背景下，我们需要利用附件数据计算每年的非化石能源消费比重，并为提高非化石能源消费比重的目标值计算提供明确的计算公式。以下是相应的计算公式推导：

附件中的碳排放因子计算公式有

$$CE = \frac{C_{Ei}}{E_i} \quad (47)$$

式中， CE 为碳排放因子， C_{Ei} 消费第*i*种能源产生的碳排放， E_i 为第*i*种能源消费量

非化石能源消费比重计算公式有：

$$R_{nf} = \frac{E_{nf}}{E_{total}} \quad (48)$$

式中， R_{nf} 为非化石能源消费比重， E_{nf} 为非化石能源消费量， E_{total} 为能源消费量

多数情况下非化石能源消费的主要集中在电力领域故有：

$$E_{nf} \approx E_{nf-gen} \quad (49)$$

式中 E_{nf-gen} 为非化石能源发电量

非化石能源发电比重的计算公式为：

$$P_{nf-gen} = \frac{E_{nf-gen}}{E_{con}} \times \frac{E_{con}}{E_{total}} = P_{nf-gen-ratio} * P_{ele-con} \quad (50)$$

式中， P_{nf-gen} 为非化石能源发电比重， E_{con} 电力消费量， $P_{nf-gen-ratio}$ 非化石能源发电占比， $P_{ele-con}$ 为电力消费比重

增长率计算公式为：

$$U\% = \frac{a-b}{b} \times 100\% \quad (51)$$

将上述公式带入增长率计算公式有：

$$C-g-rate = \frac{1-R_{nf-rate} \times P_{nf-gen}}{(1-P_{nf-gen})} \quad (52)$$

式中， $C-g-rate$ 为碳排放因子增长率， $R_{nf-rate}$ 非化石能源消费比重增长率

若将非化石能源消费比重增长率分离出来有：

$$R_{nf-rate} = \frac{1-C-g-rate \times (1-P_{nf-gen})}{P_{nf-gen}} \quad (53)$$

通过非化石能源消费比重增长率公式便可以推算出 2020-2060 年的非化石能源消费比重增长率和非化石能源消费比重。计算结果如图 x 所示。




图 40：各情景下能源消费占比目标值

图 40(a)中基准情景下的非化石能源消费增长趋势表明了中国政府采取一般性政策来推动碳达峰和碳中和的实现的有效性。从总体比重为 20%到 2060 年占全部能源消费比重的 67%，显示出中国在逐步减少对化石能源依赖方面取得了重要进展。这表明基准情景下，中国已经制定了较为合理的政策措施，以推动非化石能源的增长，从而在碳排放方面取得积极的进展。

相比之下，图 40(b)中自然情景下的非化石能源消费增长趋势表明，在没有人为政策干预的情况下，碳达峰和碳中和的目标较难实现。尽管非化石能源消费从总体比重为 17%增加到 2060 年占全部能源消费比重的 59%，但增长速度相对较慢。这意味着如果没有积极的政策干预，碳达峰和碳中和的时间节点可能会较晚，导致碳排放较高，不利于气候变化应对。

而图 40(c)中雄心情景下的非化石能源消费增长趋势显示了政府采取积极政策来加速碳达峰和碳中和的实现的效果。非化石能源消费从总体比重为 22%增加到 2060 年占全部能源消费比重的 73%，增长速度较快。这表明政府在雄心情

景下采取的强烈政策和措施，包括大幅度提高能源效率和非化石能源比重，对于实现早期碳达峰和碳中和具有显著的影响。这也说明了政策的重要性，以加速碳减排和推动清洁能源的发展，以更好地适应气候变化挑战。

7.3.4 双碳目标路径规划和政策性意见

通过 IDMI 模型的情景模拟，研究发现区域的能源消费和碳排放存在一定的分歧趋势。随着非化石能源比例的增加，尽管能源消费总量保持较高水平，甚至呈现上升趋势，但碳排放总量可能已经达到峰值。这一现象的背后原因是，基准情景下，能源消费的增长趋势在 2035 年左右趋缓，单位 GDP 的能耗下降率符合“十四五”规划目标，但碳峰值可能要到 2031 年才会出现，距离“2030 碳达峰”的目标还存在一定差距。因此，需要在政策层面有针对性地采取措施，以促进减排，同时降低社会经济成本。

对比三个参照情景的政策有效性发现，自然情景对能源节约要求较为宽松。如果仅侧重于电气化终端能源，预计只有在非化石电力比例大幅提高的情况下，才能取得良好的减排效果。而节能化情景和绿电化情景则分别从需求侧和供给侧推进节能减排，模型结果显示，这两种政策都取得了良好的效果，使能源总量和碳排放总量按时达到峰值，并在 2030 年后逐渐下降。这种整体趋势为实现后续的“2060 碳中和”愿景提供了良好的开端。

从部门分解的结果来看，尽管工业部门的能耗在终端能耗中所占比例逐年下降，但由于涵盖的用能单位较多，仍然是能耗的主要来源。因此，工业需求侧的节能减排能够显著降低全社会的能耗。而第三产业和居民消费两个部门的能耗虽然受益于经济社会的持续增长，但个体排放规模相对较小，且异质性较强，因此对其进行规制可能会产生较高的交易成本。在碳排放方面，电力部门是直接排放最多的部门，其次是供热和工业部门。各情景模拟结果显示，即使到 2035 年，电力部门的直接排放仍将占有排放量的 41%至 52%。因此，能源供给侧的低碳化对于碳达峰和碳中和目标的实现具有决定性影响。

综合分析情景结果，提出以下建议：

1. 持续推动各终端部门的节能降耗措施，包括产业层面的发展新兴产业和现代服务业，以及居民层面的绿色低碳生活方式和消费理念的推广。
2. 深入挖掘电力部门的减排潜力，包括超低排放改造、热电联产机组升级改造、煤改气工程、智慧电厂示范创建等。
3. 提高零碳能源应用比例，积极发展可再生能源，包括光伏、风电、核电等，同时控制煤炭消费。
4. 制定可行的区域中长期碳达峰行动方案，明确每年的碳排放预算，以尽可能压低碳峰值，为后续碳中和目标的实现做好准备。

这些措施有助于实现碳达峰和碳中和目标，减缓气候变化影响，推动可持续发展。所以，围绕国家“碳达峰碳中和”目标，应当根据当前区域能源和碳排放的变动趋势，研究制定可行的区域中长期碳达峰行动方案，明确达峰前每一年的碳排放预算，尽可能压低碳峰值，计划达峰后碳排放的下降路径。积极开展重点领域、重点行业达峰专项行动，鼓励有条件的地区和行业率先达到碳峰值；重点行业碳排放达峰提供数据支撑；发挥森林、湿地、滩涂等地的碳汇功能，积极探索新增碳汇入市，为“绿水青山”转化为“金山银山”开辟新通道。

八、模型评价

8.1 模型优点

(1) Kaya 恒等式作为一个基本的碳排放模型，提供了理解碳排放主要驱动因素的起点。它将碳排放分解为人口、经济活动、能源强度和碳排放强度四个组成部分，帮助我们理解不同因素对碳排放的影响。虽然这个模型相对简单，但它提供了一个基本的框架，可以用来初步估计碳排放趋势和关键影响因素。

(2) 皮尔逊系数分析是用于探究不同因素之间相关性的有力工具。通过计算相关系数，我们可以确定哪些因素与碳排放之间存在相关性，以识别潜在的影响因素。这种分析方法有助于确定影响碳排放的主要驱动因素，为政策制定提供有针对性的建议。

(3) IDMI 模型 (Integrated Dynamic Model of the Interactions between socioeconomic development, energy use, and carbon emissions) 是一个复杂的系统模型，它在分析碳排放与经济、能源消费等之间的动态关系方面具有重要作用。这个模型考虑了多个变量之间的相互作用，可以模拟不同情景下的碳排放趋势，并评估各种政策和措施的效果。IDMI 模型提供了全面的分析，包括人口、GDP、能源消费、碳排放等，有助于更好地理解碳排放的复杂性，为政策制定提供了有力支持。

(4) STIRPAT 模型 (Stochastic Impacts by Regression on Population, Affluence, and Technology) 是一种回归模型，用于分析碳排放与人口、经济、技术等因素之间的关系。这个模型可以帮助识别哪些因素对碳排放产生了最显著的影响，并用于预测未来的碳排放趋势。STIRPAT 模型在解释碳排放的因果关系方面具有一定的优势，可以为政策制定提供有关如何降低碳排放的建议。

(5) ARIMA 模型 (Autoregressive Integrated Moving Average) 和岭回归方法是用于时间序列数据分析和预测的有力工具。ARIMA 模型可以帮助预测碳排放的未来趋势，而岭回归方法则用于解决多重共线性问题，提高模型的预测准确性。这些方法结合了时间序列分析和回归分析的优点，可提供可靠的碳排放预测结果，有助于规划长期减排策略。

综上所述，这些模型和方法在碳排放分析和预测中起到了不同但互补的作用。它们可以帮助我们更好地理解碳排放的驱动因素，制定有效的政策措施，以实现碳达峰和碳中和目标。这些模型的优点在于它们提供了多角度、全面性的分析，为决策者提供了更好的决策支持，有助于规划碳排放的未来路径。然而，这些模型也需要有效的数据支持和合理的参数估计，以提供准确的预测和分析结果。因此，在利用这些模型和方法进行碳排放分析时，需要谨慎选择适合的模型，并确保数据质量和参数估计的准确性，以取得最佳的分析结果。

8.2 模型缺点

这些模型和方法在碳排放分析和预测中发挥着关键作用，但也存在一些缺陷。它们通常需要大量数据支持，具有一定的复杂性，依赖于模型假设和参数

估计，且无法完全考虑不确定性和政策因素。因此，在使用这些模型时需要谨慎，并结合多个模型以获取更全面的信息。决策者应认识到这些模型的局限性，将其作为决策支持的一部分，而不是唯一的决策依据。

8.3 模型推广

对于需要推广和改进碳排放分析模型的情况，关键在于提高模型的数据质量、简化模型复杂性、提高参数估计准确性、引入不确定性分析、考虑政策因素、适应不同时间尺度、促进跨学科合作以及政策支持。

（1）首先，数据质量和可用性是模型改进的基础。确保数据的准确性、及时性和完整性对于减少数据不确定性至关重要。

（2）其次，模型的复杂性应该根据实际需求进行调整，使其更易理解和使用。复杂模型可能需要引入更先进的参数估计方法，以提高模型的性能和准确性。不确定性分析是必要的，因为它有助于识别模型中的薄弱环节和不确定性来源，并提供更可靠的决策支持。政策因素应该被充分考虑，以更准确地反映政府制定的碳减排政策对碳排放的影响。模型还应该适应不同时间尺度的需求，以满足短期和长期内的碳排放变化分析。

（3）跨学科合作是关键，它可以将不同领域的专业知识融入模型中，更全面地理解碳排放的复杂性。最后，政策支持是推广和改进模型的重要动力，政府可以制定相关政策来支持数据采集、技术创新和碳减排措施。

综合而言，这些改进措施将有助于提高碳排放分析模型的准确性和适用性，更好地满足气候变化应对的需求，为决策制定提供更可靠的支持。

九、参考文献

- [1]胡鞍钢.中国实现 2030 年前碳达峰目标及主要途径[J].北京工业大学学报(社会科学版),2021,21(03):1-15.
- [2]邵帅,范美婷,杨莉莉.经济结构调整、绿色技术进步与中国低碳转型发展——基于总体技术前沿和空间溢出效应视角的经验考察[J].管理世界,2022,38(02):46-69+4-10.
- [3]王灿,张雅欣.碳中和愿景的实现路径与政策体系[J].中国环境管理,2020,12(06):
- [3]邵帅,张可,豆建民.经济集聚的节能减排效应:理论与中国经验[J].管理世界,2019,35(01):36-60+226.
- [4]张希良,黄晓丹,张达等.碳中和目标下的能源经济转型路径与政策研究[J].管理世界,2022,38(01):35-66.
- [5]林伯强,蒋竺均.中国二氧化碳的环境库兹涅茨曲线预测及影响因素分析[J].管理世界,2009(04):27-36.
- [6]周守华,陶春华.环境会计:理论综述与启示[J].会计研究,2012(02):3-10+96.
- [7]吴茵茵,齐杰,鲜琴等.中国碳市场的碳减排效应研究——基于市场机制与行政干预的协同作用视角[J].中国工业经济,2021(08):114-132.
- [8]查冬兰,周德群.地区能源效率与二氧化碳排放的差异性——基于 Kaya 因素分解[J].系统工程,2007(11):65-71.
- [9]袁路,潘家华.Kaya 恒等式的碳排放驱动因素分解及其政策含义的局限性[J].气候变化研究进展,2013,9(03):210-215.

- [10]邓宣凯.武汉市土地利用碳排放的影响因素研究——基于扩展的 Kaya 等式和 LMDI 分解方法[J].农业与技术,2021,41(20):104-109.
- [11]王长建,汪菲,张虹鸥.新疆能源消费碳排放过程及其影响因素——基于扩展的 Kaya 恒等式[J].生态学报,2016,36(08):2151-2163.
- [12]冯相昭,邹骥.中国 CO₂ 排放趋势的经济分析[J].中国人口·资源与环境,2008(03):43-47.
- [13] Caldeira K, Brown PT. Reduced emissions through climate damage to the economy. *Proc Natl Acad Sci USA* 2019;116:714–6.
- [14] Hou D, Song Y, Zhang J, Hou M, O'Connor D, Harclerode M. Climate change mitigation potential of contaminated land redevelopment: a city-level assessment method. *J Clean Prod* 2018;171:1396–406.
- [15] Mi ZF, Meng J, Guan DB, Shan YL, Song ML, Wei YM, et al. Chinese CO₂ emission flows have reversed since the global financial crisis. *Nat Commun* 2017;8.
- [16] Li D, Huang G, Zhu S, Chen L, Wang J. How to peak carbon emissions of provincial construction industry? Scenario analysis of Jiangsu Province. *Renew Sustain Energy Rev* 2021;144:110953.
- [17] Xu G, Schwarz P, Yang H. Adjusting energy consumption structure to achieve China's CO₂ emissions peak. *Renew Sustain Energy Rev* 2020;122:109737.
- [18] Dinga CD, Wen Z. China's green deal: can China's cement industry achieve carbon neutral emissions by 2060? *Renew Sustain Energy Rev* 2022;155:111931.
- [19] Li JF, Ma ZY, Zhang YX, Wen ZC. Analysis on energy demand and CO₂ emissions in China following the energy production and consumption revolution strategy and China dream target. *Adv Clim Change Res* 2018;9:16–26.
- [20] Shi HT, Chai J, Lu QY, Zheng JL, Wang SY. The impact of China's low-carbon transition on economy, society and energy in 2030 based on CO₂ emissions drivers. *Energy* 2022;239.
- [21] Saeidi E, Dehkordi AL, Nabavi-Pelesaraei A. Potential for optimization of energy consumption and costs in saffron production in central Iran through data envelopment analysis and multi-objective genetic algorithm. *Environ Prog Sustain Energy* 2022;41:e13857.
- [22] Fang K, Tang Y, Zhang Q, Song J, Wen Q, Sun H, et al. Will China peak its energy related carbon emissions by 2030? Lessons from 30 Chinese provinces. *Appl Energy* 2019;255:113852.
- [23] Cheng Z, Li L, Liu J, Zhang H. Total-factor carbon emission efficiency of China's provincial industrial sector and its dynamic evolution. *Renew Sustain Energy Rev* 2018;94:330–9.
- [24] Zheng R, Cheng Y, Liu H, Chen W, Chen X, Wang Y. The spatiotemporal distribution and drivers of urban carbon emission efficiency: the role of technological innovation. *Int J Environ Res Publ Health* 2022;19:9111.
- [25] Dong F, Li X, Long R, Liu X. Regional carbon emission performance in China according to a stochastic frontier model. *Renew Sustain Energy Rev* 2013;28:525–30.
- [26] Ye B, Jiang J, Li C, Miao L, Tang J. Quantification and driving force analysis of provincial-level carbon emissions in China. *Appl Energy* 2017;198:223–38.
- [27] Wang Z, Li Y, Cai H, Wang B. Comparative analysis of regional carbon emissions accounting methods in China: production-based versus consumption-based principles. *J Clean Prod* 2018;194:12–22.
- [28] Hao Y, Su M, Zhang L, Cai Y, Yang Z. Integrated accounting of urban carbon cycle in Guangyuan, a mountainous city of China: the impacts of earthquake and reconstruction. *J Clean Prod* 2015;103:231–40.

- [29] Andrade JCS, Dameno A, P´erez J, de Andr´es Almeida JM, Lumbreras J. Implementing city-level carbon accounting: a comparison between Madrid and London. *J Clean Prod* 2018;172:795–804.
- [30] Du L, Li X, Zhao H, Ma W, Jiang P. System dynamic modeling of urban carbon emissions based on the regional National Economy and Social Development Plan: a case study of Shanghai city. *J Clean Prod* 2018;172:1501–13.
- [31] Zhang Y, Wu Q, Zhao X, Hao Y, Liu R, Yang Z, et al. Study of carbon metabolic processes and their spatial distribution in the Beijing-Tianjin-Hebei urban agglomeration. *Sci Total Environ* 2018;645:1630–42.
- [32] Chuai X, Huang X, Wang W, Zhao R, Zhang M, Wu C. Land use, total carbon emissions change and low carbon land management in Coastal Jiangsu, China. *J Clean Prod* 2015;103:77–86.
- [33] Wang Q, Zhao M, Li R. Decoupling sectoral economic output from carbon emissions on city level: a comparative study of Beijing and Shanghai, China. *J Clean Prod* 2019;209:126–33.
- [34] Wu L, Zeng W. Research on the contribution of structure adjustment on carbon dioxide emissions reduction based on LMDI method. *Procedia Comput Sci* 2013;17: 744–51.
- [35] Hu E, Abley W, Zou L. Environmental related decision making using the Interlink decision making index (IDMI). *Int J Environ Waste Manag* 2008;2:257–66.
- [36] Crooks S, Sutton-Grier AE, Troxler TG, Herold N, Bernal B, Schile-Beers L, et al. Coastal wetland management as a contribution to the US national greenhouse gas inventory. *Nat Clim Change* 2018;8:1109–12.
- [37] Feroz EH, Raab RL, Ulleberg GT, Alsharif K. Global warming and environmental production efficiency ranking of the Kyoto Protocol nations. *J Environ Manag* 2009;90:1178–83.
- [38] Ishak NA, Ramli MF. Modeling the leadership attributes of top management in green innovation implementation. *AIP Conf Proc* 2015;1660:090002.
- [39] Nauels A, Gütschow J, Mengel M, Meinshausen M, Clark PU, Schleussner C-F. Attributing long-term sea-level rise to Paris Agreement emission pledges. *Proc Natl Acad Sci USA* 2019;116:23487–92.
- [40] Luo W, Zhang Y, Gao Y, Liu Y, Shi C, Wang Y. Life cycle carbon cost of buildings under carbon trading and carbon tax system in China. *Sustain Cities Soc* 2021;66: 102509.
- [41] Shan W, Jin X, Yang X, Gu Z, Han B, Li H, et al. A framework for assessing carbon effect of land consolidation with life cycle assessment: a case study in China. *J Environ Manag* 2020;266:110557.
- [42] Hu M, Chen S, Wang Y, Xia B, Wang S, Huang G. Identifying the key sectors for regional energy, water and carbon footprints from production-, consumption- and network-based perspectives. *Sci Total Environ* 2021;764:142821.
- [43] Xing Z, Jiao Z, Wang H. Carbon footprint and embodied carbon transfer at city level: a nested MRIO analysis of Central Plain urban agglomeration in China. *Sustain Cities Soc* 2022;83:103977.

附录

附件清单

编号	项目名称
1	能源供应部门计算相关数据.xlsx
2	能源消费品种结构表格重排.xlsx
3	能源消费数据.xlsx
4	人口与 GDP 数据.xlsx
5	碳排放量数据.xlsx
6	二十一五（2056-2060 年）GDP arima 预测.xlsx
7	二十一五（2056-2060 年）能源消费量回归预测结果.xlsx
8	十四五（2021-2025 年）GDP arima 预测.xlsx
9	十四五（2021-2025 年）能源消费量回归预测结果.xlsx
10	十四五（2021-2025 年）人口 arima 预测.xlsx
11	预测结果图.zip
12	能源供应部门的按能源消费品种结构排布的碳排放量计算结果.xlsx
13	平均能源供应部门碳排放因子.xlsx
14	二十一五（2056-2060 年）区域各部门各能源消费品种碳排放量预测结果.xlsx
15	二十一五（2056-2060 年）区域总和碳排放量预测结果.xlsx
16	十四五（2021-2025 年）区域各部门各能源消费品种碳排放量预测结果.xlsx
17	十四五（2021-2025 年）区域总和碳排放量预测结果.xlsx
18	所需要的各部门各能源消费品种碳排放因子数据和各部门各能源消费品种能源消费数据.xlsx
19	各部门碳排放预测结果图.zip
20	2010-2020 年非化石能源占比计算结果.xlsx
21	各情景下目标值.zip
22	基准情景非化石能源消费比重的目标值.xlsx
23	基准情景非化石能源消费比重增长率的目标值.xlsx
24	基准情景能源消费量的目标值.xlsx
25	基准情景提高能源利用效率的目标值.xlsx
26	非化石能源占比计算所需数据.xlsx
27	雄心情景非化石能源消费比重的目标值.xlsx
28	雄心情景非化石能源消费比重增长率的目标值.xlsx
29	雄心情景能源消费量的目标值.xlsx
30	雄心情景提高能源利用效率的目标值.xlsx
31	自然情景非化石能源消费比重的目标值.xlsx
32	自然情景非化石能源消费比重增长率的目标值.xlsx
33	自然情景能源消费量的目标值.xlsx
34	自然情景提高能源利用效率的目标值.xlsx
35	源代码

模型建立过程中的 Python 代码

```
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
import pandas as pd
import os
from pmdarima import auto_arima
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from scipy.stats import shapiro, probplot
from statsmodels.graphics.gofplots import qqplot
from statsmodels.stats.diagnostic import acorr_ljungbox
# 加载具有多个工作表的 Excel 文件
excel 文件 = pd.ExcelFile(数据_区域双碳目标与路径规划研究（含拆分数数据表）.xlsx)

# 加载碳排放数据
sheet_name = 碳排放拆分表
# 从指定工作表中读取数据到 Pandas DataFrame
df = pd.read_excel(excel 文件, sheet_name=碳排放拆分表, header=None)

# 将 DataFrame 转换为 NumPy 数组
Energy_supply_factor = df.values

# 定义 Energy_consumption_structure 作为 NumPy 数组（你可以类似地提取它）
Energy_consumption_structure = np.array([
    [2.730, 2.657, 2.656, 2.759, 2.656, 2.784, 2.789, 2.810, 2.878, 2.938, 2.951],
    [2.111, 2.274, 2.141, 2.097, 2.116, 2.085, 2.106, 2.080, 1.971, 2.058, 2.049],
    [1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628],
    [2.906, 2.916, 2.916, 2.967, 2.998, 3.107, 3.190, 3.278, 3.745, 3.662, 3.705],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [2.783, 2.656, 2.657, 2.680, 2.834, 2.824, 2.818, 2.824, 2.791, 2.788, 2.766],
    [2.002, 2.273, 2.078, 1.994, 1.967, 1.956, 1.959, 1.926, 1.934, 1.922, 2.021],
    [1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628, 1.628],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [8.137, 0.165, -4.646, 8.864, 8.042, 7.885, 7.858, 7.320, 7.333, 7.260, 7.277],
    [1.222, 1.250, 1.448, 1.515, 1.688, 1.722, 1.893, 2.037, 2.483, 2.356, 2.088],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [2.906, 2.906, 2.906, 2.906, 2.906, 2.906, 2.906, 2.906, 2.906, 2.906, 2.906],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
    [0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
```



```

[0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
[0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
[0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000],
[3.072, 3.031, 3.157, 3.118, 3.312, 3.399, 3.309, 3.400, 3.919, 3.827, 3.873],
[5.869, 5.995, 5.864, 6.028, 5.227, 5.554, 5.515, 5.490, 5.430, 5.479, 5.246],
[0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000]
])
# 执行乘法和求和以计算 Energy_supply_CO2
Energy_supply_CO2 = np.sum(Energy_supply_factor * Energy_consumption_structure, axis=1)
import pandas as pd
import numpy as np

# 年份
year = [2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018, 2019, 2020]

# 总人口
population = [
    7869.34, 8022.99, 8119.81, 8192.44, 8281.09, 8315.11, 8381.47, 8423.50, 8446.19, 8469.09,
    8477.26
]

# 地区生产总值
GDP = [
    [41383.87, 45952.65, 50660.20, 55580.11, 60359.43, 65552.00, 70665.71, 75752.20,
    80827.71, 85556.13, 88683.21],
    [2409.24, 2736.86, 3057.82, 3228.54, 3358.61, 3636.08, 3690.61, 3568.54, 3591.61,
    3726.61, 3916.81],
    [21853.60, 23739.96, 25612.91, 27298.13, 28907.54, 30700.41, 32013.02, 34514.33,
    36533.74, 37730.14, 38183.23],
    [904.65, 947.43, 1121.15, 1065.45, 1149.82, 1357.63, 1417.90, 1526.98, 1604.56, 1692.70,
    1660.68],
    [20948.95, 22792.53, 24491.76, 26232.68, 27757.72, 29342.78, 30595.12, 32987.35,
    34929.18, 36037.45, 36522.55],
    [17121.03, 19475.83, 21989.47, 25053.44, 28093.28, 31215.51, 34962.07, 37669.33,
    40702.36, 44099.38, 46583.18],
    [1767.22, 1988.43, 2199.51, 2233.94, 2378.93, 2240.39, 2316.43, 2420.17, 2570.68,
    2749.08, 2761.51],
    [15353.81, 17487.40, 19789.96, 22819.50, 25714.36, 28975.11, 32645.64, 35249.16,
    38131.69, 41350.30, 43821.67]
]

# 转换为 NumPy 数组
year = np.array(year)
population = np.array(population)

```

```

GDP = np.array(GDP)

# 计算 GDP_total 和 GDP_bumen_total
GDP_total = GDP[0, :]
GDP_bumen_total = GDP[[1, 2, 6], :]

# 计算各部门 GDP
GDP_bumen = np.vstack((GDP[[1, 3, 4, 7, 8], :], np.zeros((1, 11))))
# 打印或根据需要使用 Energy_supply_CO2# 创建一个 DataFrame 包含所有数据
data_total = pd.DataFrame({
    CO2: CO2_total,
    人口: population,
    GDP: GDP_total,
    能量消费量: Energy_consumption_total
})
# 能源消费量数据
energy_consumption = [
    [23539.31, 26860.03, 27999.22, 28203.10, 28170.51, 29033.61, 29947.98, 30669.89,
    31373.13, 32227.51, 31438.00],
    [345.36, 393.87, 448.95, 362.18, 383.72, 429.37, 433.46, 440.49, 457.99, 438.58, 423.78],
    [20113.07, 23145.47, 23869.22, 23889.14, 23670.13, 24261.96, 24929.67, 25317.56,
    25580.66, 26196.12, 25325.99],
    [5752.10, 6992.75, 7339.98, 7820.62, 6951.05, 7380.49, 7786.52, 8219.69, 8104.87,
    8131.55, 7491.05],
    [204.84, 286.73, 354.09, 335.18, 382.10, 440.86, 415.01, 523.98, 1010.79, 953.12, 1003.97],
    [-610.67, 243.37, 223.05, -968.04, -1181.69, -1275.59, -1334.32, -1635.70, -2028.82, -
    2376.43, -2414.66],
    [454.13, 450.76, 457.50, 353.57, 500.15, 474.01, 337.92, 377.27, 370.15, 378.33, 372.90],
    [14312.68, 15171.86, 15494.59, 16347.81, 17018.53, 17242.19, 17724.55, 17832.32,
    18123.66, 19109.55, 18872.74],
    [1932.84, 2115.56, 2308.96, 2481.88, 2644.20, 2776.11, 2878.53, 3049.20, 3300.79, 3522.38,
    3507.62],
    [1398.26, 1494.74, 1618.15, 1743.67, 1915.88, 2019.29, 2083.59, 2187.96, 2324.65,
    2482.93, 2484.47],
    [534.58, 620.83, 690.81, 738.21, 728.32, 756.83, 794.94, 861.24, 976.14, 1039.46, 1023.15],
    [1148.05, 1205.13, 1372.09, 1469.91, 1472.45, 1566.16, 1706.31, 1862.64, 2033.69, 2070.43,
    2180.60]
]

# CO2 排放量数据
co2_emission = [
    [56360.052, 65193.342, 67502.613, 66749.376, 64853.276, 66074.810, 68526.125,
    70451.557, 71502.003, 74096.331, 72633.324],

```

```

[896.070, 1031.176, 1165.275, 1007.478, 1020.853, 1162.512, 1211.034, 1245.019,
1295.487, 1278.384, 1238.759],
[45225.697, 52975.787, 54048.282, 52229.084, 51187.980, 51101.873, 52382.224,
52975.849, 52506.881, 54235.439, 52954.049],
[5898.284, 6584.556, 7147.774, 7791.472, 7676.077, 8314.531, 8801.016, 9524.015,
10422.113, 11150.957, 10906.028],
[3068.031, 3280.292, 3561.730, 3847.156, 4157.352, 4398.073, 4556.294, 4826.106,
5125.165, 5449.651, 5456.836],
[2830.254, 3304.264, 3586.045, 3944.317, 3518.725, 3916.458, 4244.722, 4697.909,
5296.948, 5701.306, 5449.191],
[4340.001, 4601.822, 5141.282, 5721.341, 4968.367, 5495.894, 6131.851, 6706.674,
7277.522, 7431.551, 7534.489]
]

```

```

# 转换为 NumPy 数组

```

```

energy_consumption = np.array(energy_consumption)
co2_emission = np.array(co2_emission)

```

```

# 计算能源消费总量

```

```

energy_consumption_total = energy_consumption[0, :]

```

```

# 计算各部门能源消费总量

```

```

energy_consumption_bumen_total = energy_consumption[[1, 2, 8], :]

```

```

# 计算各部门能源消费量

```

```

energy_consumption_bumen = np.vstack((energy_consumption[1, :],
np.sum(energy_consumption[[3, 4, 5, 6], :], axis=0)))

```

```

# 计算 CO2 排放总量

```

```

co2_emission_total = co2_emission[0, :]

```

```

# 计算各部门 CO2 排放总量

```

```

co2_emission_bumen_total = co2_emission[[1, 2, 3], :]

```

```

# 计算各部门 CO2 排放量

```

```

co2_emission_bumen = np.vstack((co2_emission[1, :], co2_emission[[4, 5, 6], :]))

```

```

# 输出结果

```

```

print("能源消费总量:", energy_consumption_total)
print("各部门能源消费总量:", energy_consumption_bumen_total)
print("各部门能源消费量:", energy_consumption_bumen)
print("CO2 排放总量:", co2_emission_total)
print("各部门 CO2 排放总量:", co2_emission_bumen_total)
print("各部门 CO2 排放量:", co2_emission_bumen)

```

```

# 计算相关性矩阵
corr_matrix = data_total.corr()
# 定义图片输出目录
folder = img

# 检查文件夹是否存在，如果不存在则创建
if not os.path.exists(folder):
    os.mkdir(folder)
else:
    print(dir is exist)

# 绘制 CO2 排放总量变化图
plt.figure(figsize=(10, 5))
plt.plot(year, CO2_total)
plt.xlabel(年份)
plt.ylabel(CO2 排放总量)
plt.title(2010-2020 年 CO2 排放总量变化)
plt.grid(True)
plt.savefig(os.path.join(folder, 2010-2020 年 CO2 排放总量变化.png), dpi=300)
plt.close()

# 绘制十二五期间 CO2 排放总量变化图
plt.figure(figsize=(10, 5))
plt.plot(year[1:6], CO2_total[1:6])
plt.xlabel(年份)
plt.ylabel(CO2 排放总量)
plt.title(十二五 (2011-2015 年) CO2 排放总量变化)
plt.grid(True)
plt.savefig(os.path.join(folder, 十二五 (2011-2015 年) CO2 排放总量变化.png), dpi=300)
plt.close()

# 绘制十三五期间 CO2 排放总量变化图
plt.figure(figsize=(10, 5))
plt.plot(year[6:11], CO2_total[6:11])
plt.xlabel(年份)
plt.ylabel(CO2 排放总量)
plt.title(十三五 (2016-2020 年) CO2 排放总量变化)
plt.grid(True)
plt.savefig(os.path.join(folder, 十三五 (2016-2020 年) CO2 排放总量变化.png), dpi=300)
plt.close()

# 绘制各产业 CO2 排放量变化图
plt.figure(figsize=(10, 5))
for i in range(3):
    plt.plot(year, CO2_bumen_total[i], label=f第{i + 1}产业)

```

```

plt.xlabel( 年份)
plt.ylabel(CO2 排放量)
plt.title(2010-2020 年各产业 CO2 排放量变化)
plt.legend()
plt.grid(True)
plt.savefig(os.path.join(folder, 2010-2020 年各产业 CO2 排放变化.png), dpi=300)
plt.close()

# 绘制各部门 CO2 排放量变化图
plt.figure(figsize=(10, 5))
for i in range(6):
    plt.plot(year, CO2_bumen[i], label=f 部门 {i + 1})
plt.xlabel( 年份)
plt.ylabel(CO2 排放量)
plt.title(2010-2020 年各部门 CO2 排放量变化)
plt.legend()
plt.grid(True)
plt.savefig(os.path.join(folder, 2010-2020 年各部门 CO2 排放量变化.png), dpi=300)
plt.close()

# 可视化碳排放量与其他变量的相关性
plt.figure(figsize=(8, 6))
sns.barplot(x=corr_matrix[CO2][1:], y=[ 人口, GDP, 能量消费量])
plt.title( 碳排放量与其他变量的相关性)
plt.xlabel( 相关性系数)
plt.ylabel( 变量)
plt.savefig(img/ 碳排放量与其他变量的相关性.png, dpi=300)
plt.close()

# 可视化各项指标间的关联关系
plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=True, cmap=coolwarm, linewidths=0.5)
plt.title( 各项指标间的关联关系)
plt.savefig(img/ 各项指标间的关联关系.png, dpi=300)
plt.close()

# 各产业部门的相关性分析
bumen = [ 农林消费部门, 能源供应部门, 工业消费部门, 交通消费部门, 建筑消费部门,
居民生活消费]

for i in range(len(bumen)):
    data_bumen_total = pd.DataFrame({
        CO2: CO2_bumen[i],
        人口: population,
        GDP: GDP_bumen[i],

```

```

        能量消费量: Energy_consumption_bumen[i]
    })

    corr_bumen_matrix = data_bumen_total.corr()

    plt.figure(figsize=(8, 6))
    sns.barplot(x=corr_bumen_matrix[CO2][1:], y=[ 人口, GDP, 能量消费量])
    plt.title(f'{bumen[i]} 碳排放量与其他变量的相关性')
    plt.xlabel( 相关性系数)
    plt.ylabel( 变量)
    plt.savefig(fimg/{bumen[i]} 碳排放量与其他变量的相关性.png, dpi=300)
    plt.close()
# 计算人均 GDP、单位 GDP 能耗和单位能耗二氧化碳排放量
avg_gdp = GDP_total / population
E_avg_gdp = Energy_consumption_total / GDP_total
CO2_avg_E = CO2_total / Energy_consumption_total

# 构建自变量和因变量的对数值
log_P = np.log(population)
log_avg_gdp = np.log(avg_gdp)
log_E_avg_gdp = np.log(E_avg_gdp)
log_CO2_avg_E = np.log(CO2_avg_E)
log_CO2 = np.log(CO2_total)

# 构建多元线性回归模型
X = np.column_stack((log_P, log_avg_gdp, log_E_avg_gdp, log_CO2_avg_E))
X = sm.add_constant(X) # 添加常数项
Y = log_CO2

model = sm.OLS(Y, X).fit() # 拟合模型

# 打印回归模型摘要
print(model.summary())

# 可视化回归结果
fig, axes = plt.subplots(nrows=2, ncols=1, figsize=(8, 10))

# 观测值 vs. 拟合值
axes[0].scatter(Y, model.fittedvalues, marker='o')
axes[0].set_xlabel( 观测值)
axes[0].set_ylabel( 拟合值)
axes[0].set_title( 观测值 vs. 拟合值)

# 拟合值 vs. 残差

```

```

axes[1].plot(model.fittedvalues, model.resid, o)
axes[1].set_xlabel( 拟合值)
axes[1].set_ylabel( 残差)
axes[1].set_title( 拟合值 vs. 残差)

plt.tight_layout()
plt.show()

import os

# 定义图片输出目录
folder = 'jpgl'

# 检查文件夹是否存在，如果不存在则创建
if not os.path.exists(folder):
    os.mkdir(folder)
else:
    print(dir is exist)

# population arima 预测十四五（2021-2025 年）
AR_Order = 1
MA_Order = 1
data = np.array(population)
savename = '十四五（2021-2025 年）人口'
step = 5 # 预测 5 年
population_forecast_2021_2025 = arima_forecast(AR_Order, MA_Order, data, step, savename)

# population arima 预测二十一五（2056-2060 年）
AR_Order = 1
MA_Order = 1
data = np.array(population)
savename = '二十一五（2056-2060 年）人口'
step = 40 # 预测 40 年
population_forecast_2021_2060 = arima_forecast(AR_Order, MA_Order, data, step, savename)
population_forecast_2056_2060 = population_forecast_2021_2060[36:]

# GDP arima 预测十四五（2021-2025 年）
AR_Order = 2
MA_Order = 1
data = np.array(GDP_total)
savename = '十四五（2021-2025 年）GDP'
step = 5 # 预测 5 年
GDP_forecast_2021_2025 = arima_forecast(AR_Order, MA_Order, data, step, savename)

```

```

# GDP arima 预测二十一五（2056 2060 年）
AR_Order = 1
MA_Order = 1
data = np.array(GDP_total)
savename = 二十一五（2056-2060 年）GDP
step = 40 # 预测 40 年
GDP_forecast_2021_2060 = arima_forecast(AR_Order, MA_Order, data, step, savename)
GDP_forecast_2056_2060 = GDP_forecast_2021_2060[36:]

```

```

def arima_forecast(AR_Order, MA_Order, data, step, savename):
    # 创建 ARIMA 模型
    model = ARIMA(data, order=(AR_Order, 0, MA_Order))

    # 拟合模型
    results = model.fit()

    # 推断残差
    res = results.resid

    # 计算标准化残差
    stdr = res / np.sqrt(results.sigma2)

    # 创建残差检验图
    plt.figure(figsize=(12, 8))

    # 绘制标准化残差时间序列图
    plt.subplot(2, 2, 1)
    plt.plot(stdr, color=#77AC30, linewidth=1.5)
    plt.title( 标准化残差时间序列图, fontsize=12, fontweight=bold)
    plt.xlabel( 时间, fontsize=10)
    plt.ylabel( 标准化残差, fontsize=10)
    plt.grid(True)

    # 绘制标准化残差的自相关图
    plt.subplot(2, 2, 2)
    plot_acf(stdr, ax=plt.gca(), lags=40)
    plt.title( 标准化残差的自相关图, fontsize=12)
    plt.xlabel( 滞后阶数, fontsize=10)
    plt.ylabel( 自相关系数, fontsize=10)
    plt.grid(True)

    # 绘制标准化残差的偏自相关图
    plt.subplot(2, 2, 3)
    plot_pacf(stdr, ax=plt.gca(), lags=40)

```



```

plt.title( 标准化残差的偏自相关图, fontsize=12, fontweight=bold)
plt.xlabel( 滞后阶数, fontsize=10)
plt.ylabel( 偏自相关系数, fontsize=10)
plt.grid(True)

# 绘制标准化残差的 QQ 图
plt.subplot(2, 2, 4)
qqplot(stdr, line=s, ax=plt.gca())
plt.title(QQ 图(样本数据-标准正态), fontsize=10, fontweight=bold)
plt.xlabel( 理论分位数, fontsize=10)
plt.ylabel( 样本分位数, fontsize=10)
plt.grid(True)

# 保存残差检验图像到 "jpg1" 文件夹
if not os.path.exists(jpg1):
    os.mkdir(jpg1)
plt.savefig(fjpg1/{savename}_残差检验图.png, dpi=300)

# 进行预测
forecast, stderr, conf_int = results.forecast(steps=step)

# 计算 95%置信区间
lower = forecast - 1.96 * stderr
upper = forecast + 1.96 * stderr

# 创建预测图
plt.figure(figsize=(12, 6))

# 绘制历史数据
plt.plot(data, color=[.7, .7, .7])

# 绘制预测值及置信区间
plt.plot(range(len(data), len(data) + step), forecast, color=#4B64E0, linewidth=2, label= 预
测值)
plt.fill_between(range(len(data), len(data) + step), lower, upper, color=#E6C719, alpha=0.3,
label=95% 置信区间)

# 添加图例
plt.legend(loc=upper left)

# 设置图标题
plt.title(f{savename} 预测, fontsize=12, fontweight=bold)

# 保存预测图像到 "jpg1" 文件夹

```

```

plt.savefig(f'jpg1/{savename}_预测图.png', dpi=300)

# 返回预测结果
return forecast

# 示例使用方法
# AR_Order = 1
# MA_Order = 1
# data = np.array([your_data_here])
# step = 5
# savename = example
# arima_forecast(AR_Order, MA_Order, data, step, savename)
    return forecast
def create_sarima(ar, ma, sar, sma, season, di):
    # 构建 SARIMA 模型
    p = ar if ar != 0 else None
    d = di
    q = ma if ma != 0 else None
    P = sar if sar != 0 else None
    D = 1 # 季节性差分阶数
    Q = sma if sma != 0 else None
    s = season # 季节性周期

    Mdl = sm.tsa.SARIMAX(endog=None, exog=None, order=(p, d, q), seasonal_order=(P, D,
Q, s))

    return Mdl
# 假设有人口数据 population，以及 arima_forecast 函数的实现

# 初始化变量
population_forecast_2021_2025_all = np.zeros((1, 5))
population_forecast_2056_2060_all = np.zeros((1, 5))

AR_Order = 1
MA_Order = 1
data = population # 人口数据
savename = (2021-2060 年) 人口
step = 40 # 预测 40 年

# 调用 arima_forecast 函数来进行人口预测
population_forecast_2021_2060 = arima_forecast(AR_Order, MA_Order, data, step, savename)

# 提取所需时间段的数据
population_forecast_2021_2025_all[0, :] = population_forecast_2021_2060[0:5]

```

```

population_forecast_2056_2060_all[0, :] = population_forecast_2021_2060[35:40]

# 扩展数据以适应后续计算
population_forecast_2021_2025_all_unroll = np.tile(population_forecast_2021_2025_all, (36, 1))
population_forecast_2056_2060_all_unroll = np.tile(population_forecast_2056_2060_all, (36, 1))

# 输出结果
print("population_forecast_2021_2025_all:", population_forecast_2021_2025_all)
print("population_forecast_2056_2060_all:", population_forecast_2056_2060_all)
print("population_forecast_2021_2025_all_unroll:", population_forecast_2021_2025_all_unroll)
print("population_forecast_2056_2060_all_unroll:", population_forecast_2056_2060_all_unroll)

# 定义部门和品种列表
bumen = [农林消费部门, 能源供应部门, 工业消费部门, 交通消费部门, 建筑消费部门,
居民生活消费]
pinzhong = [煤炭, 油品, 天然气, 热力, 电力, 其他能源]

# 初始化 GDP 预测结果数组
GDP_forecast_2021_2025_all = np.zeros((5, 5))
GDP_forecast_2056_2060_all = np.zeros((5, 5))

# 循环处理各部门数据
for i in range(5):
    AR_Order = 1
    MA_Order = 1
    data = GDP_bumen[i, :].reshape(-1, 1)
    savename = f'（2021-2060 年）GDP（{bumen[i]}）'
    step = 40 # 预测 40 年

    # 调用 arima_forecast 函数进行 GDP 预测
    GDP_forecast_2021_2060 = arima_forecast(AR_Order, MA_Order, data, step, savename)

    # 提取十四五（2021-2025 年）和二十五年（2056-2060 年）的预测结果
    GDP_forecast_2021_2025_all[i, :] = GDP_forecast_2021_2060[0:5]
    GDP_forecast_2056_2060_all[i, :] = GDP_forecast_2021_2060[35:40]

# 对于居民生活消费，将 GDP 设置为 1.0 并添加一行 1.0
GDP_forecast_2021_2025_all = np.vstack((GDP_forecast_2021_2025_all, np.ones(5)))
GDP_forecast_2056_2060_all = np.vstack((GDP_forecast_2056_2060_all, np.ones(5)))

# 扩展数据以适应后续计算，重复 6 次
GDP_forecast_2021_2025_all_unroll = np.tile(GDP_forecast_2021_2025_all, (6, 1))
GDP_forecast_2056_2060_all_unroll = np.tile(GDP_forecast_2056_2060_all, (6, 1))

```

```

# 输出结果
print("GDP_forecast_2021_2025_all:", GDP_forecast_2021_2025_all)
print("GDP_forecast_2056_2060_all:", GDP_forecast_2056_2060_all)
print("GDP_forecast_2021_2025_all_unroll:", GDP_forecast_2021_2025_all_unroll)
print("GDP_forecast_2056_2060_all_unroll:", GDP_forecast_2056_2060_all_unroll)

# 初始化能源消费预测结果数组
Energy_consumption_subdivide_forecast_2021_2025_all = np.zeros((36, 5))
Energy_consumption_subdivide_forecast_2056_2060_all = np.zeros((36, 5))

# 初始化碳排放因子预测结果数组
Carbon_emission_factor_subdivide_forecast_2021_2025_all = np.zeros((36, 5))
Carbon_emission_factor_subdivide_forecast_2056_2060_all = np.zeros((36, 5))

# 循环处理能源消费和碳排放因子数据
for i in range(6):
    for j in range(6):
        index = (i - 1) * 6 + j
        AR_Order = 1
        MA_Order = 2
        data_energy = Energy_consumption_subdivide[index, :].reshape(-1, 1)
        data_carbon = Carbon_emission_factor_subdivide[index, :].reshape(-1, 1)
        savename_energy = f (2021-2060 年) {bumen[i]} {pinzhong[j]} 能源消费
        savename_carbon = f (2021-2060 年) {bumen[i]} {pinzhong[j]} 碳排放因子
        step = 40 # 预测 40 年

        # 调用 arima_forecast 函数进行能源消费和碳排放因子预测
        Energy_consumption_subdivide_forecast_2021_2060 = arima_forecast(AR_Order,
        MA_Order, data_energy, step, savename_energy)
        Carbon_emission_factor_subdivide_forecast_2021_2060 = arima_forecast(AR_Order,
        MA_Order, data_carbon, step, savename_carbon)

        # 提取十四五（2021-2025 年）和二十一五（2056-2060 年）的预测结果
        Energy_consumption_subdivide_forecast_2021_2025_all[index, :] =
        Energy_consumption_subdivide_forecast_2021_2060[0:5]
        Energy_consumption_subdivide_forecast_2056_2060_all[index, :] =
        Energy_consumption_subdivide_forecast_2021_2060[35:40]
        Carbon_emission_factor_subdivide_forecast_2021_2025_all[index, :] =
        Carbon_emission_factor_subdivide_forecast_2021_2060[0:5]
        Carbon_emission_factor_subdivide_forecast_2056_2060_all[index, :] =
        Carbon_emission_factor_subdivide_forecast_2021_2060[35:40]

# 输出结果

```

```

print("Energy_consumption_subdivide_forecast_2021_2025_all:",
      Energy_consumption_subdivide_forecast_2021_2025_all)
print("Energy_consumption_subdivide_forecast_2056_2060_all:",
      Energy_consumption_subdivide_forecast_2056_2060_all)
print("Carbon_emission_factor_subdivide_forecast_2021_2025_all:",
      Carbon_emission_factor_subdivide_forecast_2021_2025_all)
print("Carbon_emission_factor_subdivide_forecast_2056_2060_all:",
      Carbon_emission_factor_subdivide_forecast_2056_2060_all)

# 计算 CO2 排放量
CO2_2021_2025 = (population_forecast_2021_2025_all_unroll *
                  GDP_forecast_2021_2025_all_unroll /
                  population_forecast_2021_2025_all_unroll *
                  Energy_consumption_subdivide_forecast_2021_2025_all /
                  GDP_forecast_2021_2025_all_unroll *
                  Carbon_emission_factor_subdivide_forecast_2021_2025_all)

# 将 CO2 排放量中的负值设为 0
CO2_2021_2025[CO2_2021_2025 < 0] = 0

# 计算 CO2 排放总量
CO2_2021_2025_total = CO2_2021_2025.sum()

# 将 CO2 排放数据保存到 Excel 文件
CO2_2021_2025_df = pd.DataFrame(CO2_2021_2025)
CO2_2021_2025_df.to_excel(问题 2 第 2 小问十四五（2021-2025 年）区域各部门各能源消
费品种碳排放量预测结果.xlsx, index=False)
pd.DataFrame({'Total CO2 Emissions: [CO2_2021_2025_total]}').to_excel(问题 2 第 2 小问十
四五（2021-2025 年）区域总和碳排放量预测结果.xlsx, index=False)

# 计算 CO2 排放量（2056-2060 年）
CO2_2056_2060 = (population_forecast_2056_2060_all_unroll *
                  GDP_forecast_2056_2060_all_unroll /
                  population_forecast_2056_2060_all_unroll *
                  Energy_consumption_subdivide_forecast_2056_2060_all /
                  GDP_forecast_2056_2060_all_unroll *
                  Carbon_emission_factor_subdivide_forecast_2056_2060_all)

# 将 CO2 排放量中的负值设为 0
CO2_2056_2060[CO2_2056_2060 < 0] = 0

# 计算 CO2 排放总量
CO2_2056_2060_total = CO2_2056_2060.sum()

```

```

# 将 CO2 排放数据保存到 Excel 文件
CO2_2056_2060_df = pd.DataFrame(CO2_2056_2060)
CO2_2056_2060_df.to_excel(问题 2 第 2 小问二十一五 (2056-2060 年) 区域各部门各能源
消费品种碳排放量预测结果.xlsx, index=False)
pd.DataFrame({'Total CO2 Emissions': [CO2_2056_2060_total]}).to_excel(问题 2 第 2 小问二
十一五 (2056-2060 年) 区域总和碳排放量预测结果.xlsx, index=False)

# 创建图片输出目录
folder = 'jpg1'
if not os.path.exists(folder):
    os.mkdir(folder)
else:
    print('dir is exist')

# GDP 增长率计算
# 定义数据点
# 2035 年的 GDP 比基期 (2020 年) 翻一番; 2060 年比基期翻两番;
years = np.array([2020, 2035, 2060])
values = np.array([1, 2, 4])

# 使用 polyfit 函数拟合数据点并生成二次多项式
coefficients = np.polyfit(years, values, 2)
a, b, c = coefficients

# 打印拟合的二次多项式
print(f'拟合的二次多项式为: {a:.4f}x^2 + {b:.4f}x + {c:.4f}')

# 计算 2020-2060 年之间的函数值
start_year = 2020
end_year = 2060
years_between = np.arange(start_year, end_year + 1)

# 计算函数值和增长率
GDP_values_between = a * years_between**2 + b * years_between + c
GDP_rate = 1 + np.diff(GDP_values_between) / GDP_values_between[:-1]

# 打印计算结果
print('年份\t函数值\t增长率')
for i in range(len(years_between) - 1):
    print(f'{years_between[i+1]}\t{GDP_values_between[i+1]:.4f}\t{GDP_rate[i]:.4f}')

# 预测人口并计算增长率
year = np.array([2010, 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018, 2019, 2020])

```

```

# 总人口
population = np.array([7869.34, 8022.99, 8119.81, 8192.44, 8281.09, 8315.11, 8381.47, 8423.50,
8446.19, 8469.09, 8477.26])
AR_Order = 1
MA_Order = 1
data = population
savename = (2021-2060 年) 人口
step = 40 # 预测 40 年
population_forecast_2021_2060 = arima_forecast(AR_Order, MA_Order, data, step, savename)
population_all = np.concatenate(([population[-1]], population_forecast_2021_2060))
population_rate = 1 + np.diff(population_all) / population_all[:-1]

print(年份\t 人口\t 增长率)
for i in range(len(years_between) - 1):
    print(f{years_between[i+1]} \t {population_all[i+1]:.2f} \t {population_rate[i]:.4f})

# 年份范围
years = np.arange(2021, 2061)
N = len(years)

# 创建情景数据结构
natural_scenario = {
    name: 自然情景,
    carbon_peak_year: 2040,
    carbon_neutral_year: 2060,
    population_increase: population_rate.tolist(),
    gdp_increase: GDP_rate.tolist(),
    avg_energy_consumption_increase: [0.987] * N,
    carbon_emission_factor_increase: [0.98] * N
}

baseline_scenario = {
    name: 基准情景,
    carbon_peak_year: 2030,
    carbon_neutral_year: 2050,
    population_increase: population_rate.tolist(),
    gdp_increase: GDP_rate.tolist(),
    avg_energy_consumption_increase: [0.986] * N,
    carbon_emission_factor_increase: [0.975] * N
}

ambitious_scenario = {
    name: 雄心情景,
    carbon_peak_year: 2025,

```

```

    carbon_neutral_year: 2045,
    population_increase: population_rate.tolist(),
    gdp_increase: GDP_rate.tolist(),
    avg_energy_consumption_increase: [0.98] * N,
    carbon_emission_factor_increase: [0.97] * N
}

# 模拟碳排放量
emissions_natural = np.zeros(N)
emissions_baseline = np.zeros(N)
emissions_ambitious = np.zeros(N)

# 2020 年的碳排放量为 72633.324 单位
# 区域碳排放与各部门碳排放量的总和相一致;
baseline_emissions_natural = 72633.324
baseline_emissions_baseline = 72633.324
baseline_emissions_ambitious = 72633.324

for i in range(N):
    year = years[i]
    index = year - 2020
    # 自然情景碳排放量核算模型计算
    baseline_emissions_natural = calculate_emissions(index, natural_scenario,
baseline_emissions_natural)
    emissions_natural[i] = baseline_emissions_natural
    # 基准情景碳排放量核算模型计算
    baseline_emissions_baseline = calculate_emissions(index, baseline_scenario,
baseline_emissions_baseline)
    emissions_baseline[i] = baseline_emissions_baseline
    # 雄心情景碳排放量核算模型计算
    baseline_emissions_ambitious = calculate_emissions(index, ambitious_scenario,
baseline_emissions_ambitious)
    emissions_ambitious[i] = baseline_emissions_ambitious

# 创建新的图形
plt.figure()

# 绘制不同情景下的碳排放量
plt.plot(years, emissions_natural, color=#ED75FA, linewidth=2, label= 自然情景)
plt.plot(years, emissions_baseline, color=#5CFAD3, linewidth=2, label= 基准情景)
plt.plot(years, emissions_ambitious, color=#FAD255, linewidth=2, label= 雄心情景)

# 添加坐标轴标签
plt.xlabel(年份)

```



```

plt.ylabel( 碳排放量（万 tCO2）)

# 添加标题
plt.title( 不同情景下的碳排放量)

# 设置图例位置
plt.legend(loc=lower left)

# 添加背景和网格
plt.gca().set_facecolor([1, 1, 1]) # 设置背景颜色
plt.grid(True)

# 改进坐标轴标签字体
plt.rc(font, family=SimSun, size=12) # 设置字体和字号

# 改进标题字体
plt.title( 不同情景下的碳排放量, fontfamily=SimSun, fontsize=14)

# 保存图形为 PNG 文件
plt.savefig(jpg1/ 不同情景下的碳排放量.png, dpi=600)

# 显示图形
plt.show()

# 定义年份范围和索引
years = np.array([2025, 2030, 2035, 2050, 2060])
index = years - 2020

# 2020 年的 GDP 和能源消费总量
GDP_2020 = 88683.21
E_2020 = 31438.00

# 计算 GDP 目标值
GDP_goal = GDP_2020 * GDP_values_between[index + 1]

# 计算人口目标值
population_goal = population_all[index + 1]

# 计算自然情景下提高能源利用效率的目标值（单位 GDP 能耗的目标值）
E_divide_GDP_goal_natural_scenario = (E_2020 / GDP_2020) *
np.cumprod(natural_scenario[avg_energy_consumption_increase])
E_divide_GDP_goal_natural_scenario = E_divide_GDP_goal_natural_scenario[index]

# 将数据保存到 Excel 文件

```

```

pd.DataFrame({'Year': years, GDP Goal: GDP_goal}).to_excel(GDP_goal.xlsx, index=False)
pd.DataFrame({'Year': years, Population Goal:
population_goal}).to_excel(population_goal.xlsx, index=False)
pd.DataFrame({'Year': years, E_divide_GDP_goal_natural_scenario:
E_divide_GDP_goal_natural_scenario}).to_excel(E_divide_GDP_goal_natural_scenario.xlsx,
index=False)

# 计算自然情景下能源消费量的目标值
E_goal_natural_scenario = E_divide_GDP_goal_natural_scenario * GDP_goal

# 将数据保存到 Excel 文件
pd.DataFrame({'Year': years, E_goal_natural_scenario:
E_goal_natural_scenario}).to_excel(E_goal_natural_scenario.xlsx, index=False)

# 计算基准情景下提高能源利用效率的目标值（单位 GDP 能耗的目标值）
E_divide_GDP_goal_baseline_scenario = (E_2020 / GDP_2020) *
np.cumprod(baseline_scenario[avg_energy_consumption_increase])
E_divide_GDP_goal_baseline_scenario = E_divide_GDP_goal_baseline_scenario[index]

# 将数据保存到 Excel 文件
pd.DataFrame({'Year': years, E_divide_GDP_goal_baseline_scenario:
E_divide_GDP_goal_baseline_scenario}).to_excel(E_divide_GDP_goal_baseline_scenario.xlsx,
index=False)

# 计算基准情景下能源消费量的目标值
E_goal_baseline_scenario = E_divide_GDP_goal_baseline_scenario * GDP_goal

# 将数据保存到 Excel 文件
pd.DataFrame({'Year': years, E_goal_baseline_scenario:
E_goal_baseline_scenario}).to_excel(E_goal_baseline_scenario.xlsx, index=False)

# 计算雄心情景下提高能源利用效率的目标值（单位 GDP 能耗的目标值）
E_divide_GDP_goal_ambitious_scenario = (E_2020 / GDP_2020) *
np.cumprod(ambitious_scenario[avg_energy_consumption_increase])
E_divide_GDP_goal_ambitious_scenario = E_divide_GDP_goal_ambitious_scenario[index]

# 将数据保存到 Excel 文件
pd.DataFrame({'Year': years, E_divide_GDP_goal_ambitious_scenario:
E_divide_GDP_goal_ambitious_scenario}).to_excel(E_divide_GDP_goal_ambitious_scenario.xl
sx, index=False)

# 计算雄心情景下能源消费量的目标值
E_goal_ambitious_scenario = E_divide_GDP_goal_ambitious_scenario * GDP_goal

```

```

# 将数据保存到 Excel 文件
pd.DataFrame({'Year: years, E_goal_ambitious_scenario:
E_goal_ambitious_scenario})).to_excel(E_goal_ambitious_scenario.xlsx, index=False)

# 创建一个新图形
plt.figure()

# 第一个子图: GDP 目标
plt.subplot(2, 1, 1)
plt.plot(year_goal, GDP_goal, linewidth=2, color=b)
plt.grid(True)
plt.xlabel(年份, fontname=SimSun, fontsize=12)
plt.ylabel(GDP 目标, fontname=SimSun, fontsize=12)
plt.title(GDP 目标值, fontname=SimSun, fontsize=14)

# 第二个子图: 人口目标
plt.subplot(2, 1, 2)
plt.plot(year_goal, population_goal, linewidth=2, color=g)
plt.grid(True)
plt.xlabel(年份, fontname=SimSun, fontsize=12)
plt.ylabel(人口目标, fontname=SimSun, fontsize=12)
plt.title(人口目标值, fontname=SimSun, fontsize=14)

# 图例设置
plt.legend([自然情景, 基准情景, 雄心情景], loc=best, prop={family: SimSun, size: 12})

# 调整整个图的背景颜色
plt.gcf().set_facecolor(w)

# 导出图像
plt.savefig(jpg1/GDP 和人口的目标值.png, dpi=600, bbox_inches=tight)

# 创建一个新图形
plt.figure()

# 绘制能源利用效率目标值
plt.plot(year_goal, E_divide_GDP_goal_natural_scenario, linewidth=2, color=#7594FA, label=
自然情景)
plt.plot(year_goal, E_divide_GDP_goal_baseline_scenario, linewidth=2, color=#B0FA5D,
label= 基准情景)
plt.plot(year_goal, E_divide_GDP_goal_ambitious_scenario, linewidth=2, color=#FA7855,
label= 雄心情景)
plt.xlabel(年份)

```

```

plt.ylabel(单位 GDP 能耗目标值)
plt.title(各情景提高能源利用效率(单位 GDP 能耗目标值)的目标值)
plt.grid(True)
plt.legend(loc=best)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)

# 保存图像并设置分辨率
plt.savefig(jpg1/ 各情景提高能源利用效率(单位 GDP 能耗目标值)的目标值.png, dpi=600,
bbox_inches=tight)

# 创建一个新图形
plt.figure()

# 绘制能源消费量目标值
plt.plot(year_goal, E_goal_natural_scenario, linewidth=2, color=#5C78FA, label= 自然情景)
plt.plot(year_goal, E_goal_baseline_scenario, linewidth=2, color=#98FA43, label= 基准情景)
plt.plot(year_goal, E_goal_ambitious_scenario, linewidth=2, color=#FA6A3C, label = 雄心情景)
plt.xlabel(年份)
plt.ylabel(能源消费量)
plt.title(各情景能源消费量的目标值)
plt.grid(True)
plt.legend(loc=best)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)

# 保存图像并设置分辨率
plt.savefig(jpg1/ 各情景能源消费量的目标值.png, dpi=600, bbox_inches=tight)

# 显示图形
plt.show()

# 初始化参数
N = len(year_goal) - 1

# 自然情景
prop_natural = np.zeros(N + 1) # 自然情景非化石能源消费比重
prop_increase_natural = np.zeros(N) # 自然情景非化石能源消费比重增长率
prop_natural[0] = proportion_of_non_fossil_energy[-1]

factor_increase_natural = natural_scenario.carbon_emission_factor_increase
for i in range(N):

```

```

# 非化石能源消费比重增长率=(1-碳排放因子增长率*(1-非化石能源消费比重))/非化石
能源消费比重
prop_increase_natural[i] = (1 - factor_increase_natural[i] * (1 - prop_natural[i])) /
prop_natural[i]
prop_natural[i + 1] = prop_natural[i] * prop_increase_natural[i]

# 基准情景
prop_baseline = np.zeros(N + 1)
prop_increase_baseline = np.zeros(N)
prop_baseline[0] = proportion_of_non_fossil_energy[-1]

factor_increase_baseline = baseline_scenario.carbon_emission_factor_increase
for i in range(N):
    # 非化石能源消费比重增长率=(1-碳排放因子增长率*(1-非化石能源消费比重))/非化石
    能源消费比重
    prop_increase_baseline[i] = (1 - factor_increase_baseline[i] * (1 - prop_baseline[i])) /
    prop_baseline[i]
    prop_baseline[i + 1] = prop_baseline[i] * prop_increase_baseline[i]

# 雄心情景
prop_ambitious = np.zeros(N + 1)
prop_increase_ambitious = np.zeros(N)
prop_ambitious[0] = proportion_of_non_fossil_energy[-1]

factor_increase_ambitious = ambitious_scenario.carbon_emission_factor_increase
for i in range(N):
    # 非化石能源消费比重增长率=(1-碳排放因子增长率*(1-非化石能源消费比重))/非化石
    能源消费比重
    prop_increase_ambitious[i] = (1 - factor_increase_ambitious[i] * (1 - prop_ambitious[i])) /
    prop_ambitious[i]
    prop_ambitious[i + 1] = prop_ambitious[i] * prop_increase_ambitious[i]

# 将结果保存到 Excel 文件
np.savetxt(自然情景非化石能源消费比重的目标值.xlsx, prop_natural[index], delimiter= \t)
np.savetxt(自然情景非化石能源消费比重增长率的目标值.xlsx, prop_increase_natural[index],
delimiter= \t)

np.savetxt(基准情景非化石能源消费比重的目标值.xlsx, prop_baseline[index], delimiter= \t)
np.savetxt(基准情景非化石能源消费比重增长率的目标值.xlsx,
prop_increase_baseline[index], delimiter= \t)

np.savetxt(雄心情景非化石能源消费比重的目标值.xlsx, prop_ambitious[index], delimiter= \t)
np.savetxt(雄心情景非化石能源消费比重增长率的目标值.xlsx,
prop_increase_ambitious[index], delimiter= \t)

```

```

# 绘制图表
plt.figure()
plt.plot(year_goal, prop_natural[index], color=#5C78FA, linewidth=2, label= 自然情景)
plt.plot(year_goal, prop_baseline[index], color=#98FA43, linewidth=2, label= 基准情景)
plt.plot(year_goal, prop_ambitious[index], color=#FA6A3C, linewidth=2, label= 雄心情景)
plt.xlabel( 年份)
plt.ylabel( 非化石能源消费比重)
plt.title( 各情景非化石能源消费比重的目标值)
plt.grid(True)
plt.legend(loc=best)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)

# 保存图像并设置分辨率
plt.savefig(jpg1/ 各情景非化石能源消费比重的目标值.png, dpi=600, bbox_inches=tight)

# 显示图形
plt.show()

# 绘制非化石能源消费比重增长率图表
plt.figure()
plt.plot(year_goal, prop_increase_natural[index], color=#5C78FA, linewidth=2, label= 自然情景
)
plt.plot(year_goal, prop_increase_baseline[index], color=#98FA43, linewidth=2, label= 基准情
景)
plt.plot(year_goal, prop_increase_ambitious[index], color=#FA6A3C, linewidth=2, label= 雄心
情景)
plt.xlabel( 年份)
plt.ylabel( 非化石能源消费比重增长率)
plt.title( 各情景非化石能源消费比重增长率的目标值)
plt.grid(True)
plt.legend(loc=best)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)

# 保存图像并设置分辨率
plt.savefig(jpg1/ 各情景非化石能源消费比重增长率的目标值.png, dpi=600,
bbox_inches=tight)

# 显示图形
plt.show()

```