



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 浙江工商大学

参赛队号 23103530067

1.王振宽

队员姓名 2.潘苏

3.郭娜

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

题 目：出血性脑卒中患者预后预测与治疗智能模型构建

摘 要：

出血性脑卒中是一种严重的脑血管疾病，通常由非创伤性脑内血管破裂引发脑出血而发生。为了解决与脑卒中事件相关的多个问题，包括血肿风险、水肿进展和预后因素，我们采取了以下具体方法：

针对问题一，即**血肿扩张**风险相关因素的探索建模。对于 a 题，我们建立数学模型核心思想是将检查时间、血肿体积变化和事件判断结合，以捕捉血性脑卒中患者治疗过程中的关键事件，这一模型使我们能够实时监测患者的血肿状态，最终判断出哪些患者发生了血肿扩张事件以及事件发生的确切时间。对于 b 题，我们首先对数据集进行了**特征选择**，并利用随机森林、LightGBM 和 XGBoost 等**树模型**构建分类模型。我们采用了五折交叉验证法来评估模型性能，最终得到每个患者发生血脉扩张事件的概率预测结果，并将结果填入表 4 中。

针对问题二，即血肿周围水肿建模与治疗关联性研究。对于 a 题，我们首先绘制了水肿体积随时间间隔的散点图以了解数据分布，然后对比**回归模型**、**高斯模型**和**数学函数逼近**等方法拟合曲线的效果，以**高斯模型**的拟合最为逼近真实水肿体积值。最后，我们计算了真实值与高斯模型预测值之间的**残差**。对于 b 题，我们采用 **K-means 算法**、**高斯混合模型**、**FCM 聚类**等聚类算法将患者划分成亚组，最终采用效果最好的 **FCM 聚类模型**。再针对每个亚组构建水肿体积随时间进展的曲线，最后计算出残差并确定其所属类别。对于 c 题，我们对比了决策树回归、随机森林回归等**树回归模型**，然后使用**置换重要性**技术来评估不同特征对不同模型预测的影响程度，最终选择随机森林回归模型。对于 d 题，我们执行**方差分析**和**相关分析**来分析不同治疗方法对血肿体积和水肿体积的影响。最后，使用置换重要性来确定不同变量对结果的影响程度，结果表明：**脑室引流**和**降颅压治疗**在模型中是重要的特征，对预测目标血肿体积和水肿体积有着**积极**的贡献。

针对问题三，出血性脑卒中**预后预测**与关键因素研究。对于 a 题，我们对收集完的相关数据中的大量特征进行特征选择后采用回归模型，对 90 天 mRS 评分的七个值进行随机森林、XGBoost、CART 等**树回归模型**，对模型进行训练，评估，对效果最好的模型进行调参和优化，以提高预测性能。对于 b 题，其数据集加入了多次随访的特征造成了大量的缺失值，我们采用**二进制指示器**有效地整合不同来源的信息，在保留原始变量的**缺失值**信息的情况下对 a 问的模型进行调整，对患者康复状

况的预测准确性较高。对于 c 题，我们首先通过分析相关系数，以查看特征之间的相关性，得出初步关联结论，然后对与 90 天 mRS 评分相关性显著的特征采用方差分析检验，得出是否显著的结论，最后我们基于关联分析，针对患者从**年龄的重要性、疾病史的关注、治疗方法、影响图像、定期随访**这 5 个方面提出临床建议。

关键词： 树回归 FCM 相关分析 特征选择 高斯模型

目录

1. 问题重述	1
1.1 问题背景	1
1.2 问题描述	1
2. 模型假设	3
3. 符号说明	3
4. 问题一：血肿扩张风险相关因素探索建模	4
4.1 问题一 a 题	4
4.1.1 问题一 a 题分析	4
4.1.2 问题一 a 题模型的建立	5
4.1.3 问题一 a 题模型的求解	6
4.2 问题一 b 题	6
4.2.1 问题一 b 题分析	6
4.2.2 b 题数据预处理	7
4.2.3 问题一 b 题模型的建立	11
4.2.4 问题一 b 题模型的求解	17
5. 问题二：血肿周围水肿建模与治疗关联性研究	21
5.1 问题二 a 题	21
5.1.1 问题二 a 题分析	21
5.1.2 问题二 a 题模型的建立	22
5.1.3 问题二 a 题模型的求解	28
5.2 问题二 b 题	34
5.2.1 问题二 b 题分析	34
5.2.2 问题二 b 题模型的建立	34
5.2.3 问题二 b 题模型的求解	38
5.3 问题二 c 题	44
5.3.1 问题二 c 题分析	44
5.3.2 问题二 c 题模型的建立	44
5.3.3 问题二 c 题模型的求解	45
5.4 问题二 d 题	46
5.4.1 问题二 d 题分析	46
5.4.2 问题二 d 题模型的建立	46
5.4.3 问题二 d 题模型的求解	47
6. 问题三：出血性脑卒中预后预测与关键因素研究	50
6.1 问题三 a 题	50
6.1.1 问题三 a 题分析	50
6.1.2 问题三 a 题模型的建立	51
6.1.3 问题三 a 题模型的求解	55
6.2 问题三 b 题	59
6.2.1 问题三 b 题分析	59

问题三 b 题模型的建立	59
6.2.2 问题三 b 题模型的求解	62
6.3 问题三 c 题	63
6.3.1 问题三 c 题分析	63
6.3.2 问题三 c 题模型的建立	63
6.3.3 问题三 c 题模型的求解	64
7. 模型的分析与检验	71
7.1 模型的优点	71
7.2 模型的缺点	72
7.3 模型的改进	72
7.4 模型的推广	72
8. 参考文献	73
9. 附录	75

1. 问题重述

1.1 问题背景

出血性脑卒中是一种严重的脑血管事件，它的发生通常是由于非外伤性脑内血管破裂引起的脑出血。这种类型的脑卒中占据了全部脑卒中发病率的 10~15%，其病因复杂，通常因脑动脉瘤破裂、脑动脉异常等因素，导致血液从破裂的血管涌入脑组织，从而造成脑部机械性损伤，并引发一系列复杂的生理病理反应。出血性脑卒中起病急、进展快，预后较差，急性期内病死率高达 45~50%，大约 80% 的患者会遗留较严重的神经功能障碍，为社会及患者家庭带来巨大的身体和经济负担。因此，识别导致出血性脑卒中的发病风险，将影像学特征、患者临床信息和治疗方案进行综合分析，以精准预测患者的预后，从而优化临床决策，具有重要的临床意义。

一旦出血性脑卒中发生后，血肿范围的扩大成为影响患者预后的一个关键危险因素。在脑出血发生后的短时间内，血肿范围可能会因脑组织受损和炎症反应等多种因素而逐渐扩大，导致颅内压急剧升高，从而进一步恶化神经功能，甚至危及患者的生命。因此，监测和控制血肿扩张是临床管理的一个重要焦点。此外，血肿周围的水肿也引起了广泛的临床关注。这种水肿可能会导致脑组织受到额外的压力，从而影响神经元的功能，导致脑组织进一步受损，加剧患者的神经功能损伤。出血性脑卒中发生后，引起的血肿与水肿的脑部 CT 图如下所示：




图 1-1 左图脑出血患者 CT 平扫，右图红色为血肿，黄色为血肿周围水肿

综上所述，针对出血性脑卒中后的两个重要关键事件，即血肿扩张和血肿周围水肿的发生和发展，进行早期识别和预测对于改善患者的预后和提升其生活质量具有关键性意义。医学影像技术的迅猛发展为实现对脑组织损伤和病情演变的无创动态监测提供了有力工具。近年来，医学领域广泛应用的人工智能技术也为深度挖掘大规模影像数据和智能分析提供了新的机会。

1.2 问题描述

基于上述问题背景，该赛题提供了 160 例出血性脑卒中患者的数据，其中包括 100 例训练数据集和 60 例独立测试数据集，依托所给数据，主要目标是通过对真实临床数据的分析，研究出血性脑卒中患者的血肿扩张风险、血肿周围水肿的发生及演进规律。最终，结合临床和影像信息，预测出血性脑卒中患者的临床预后。这项任务旨在为医疗领域提供有价值的见解和预测模型，以帮助医生更好地理解患者的

病情和康复前景，为临床决策提供支持。我们需要解决以下三个问题：

问题一涉及患者在发生出血性脑卒中后可能发生血肿扩张的情况，并需要解决两个子问题，问题 a 和问题 b。

首先对于问题 a，我们需要使用入院首次影像检查流水号、发病到首次影像检查时间间隔，以及“表 2”中的各个时间点流水号和相应的血肿体积数据，来确定前 100 名患者是否在发病后的 48 小时内经历了血肿扩张事件。具体而言，我们需要计算在发病后 48 小时内随访时间点的血肿体积变化，并将其与特定的判断标准（绝对体积增加 ≥ 6 mL 或相对体积增加 $\geq 33\%$ ）进行比较。我们还需记录哪些患者发生了血肿扩张事件以及事件发生的确切时间。

问题 b 需要我们以是否发生血肿扩张事件作为目标变量，利用“表 1”中前 100 例患者的个人史、疾病史、发病及治疗相关特征，以及“表 2”和“表 3”中的影像检查结果等指标，来构建一个模型。这个模型的目标是预测其他 160 名患者发生血肿扩张事件的概率。因此，我们需要充分利用提供的各项特征，建立一个能够准确预测每位患者血肿扩张风险的模型。

这些问题旨在深入了解出血性脑卒中患者的血肿扩张情况，并为医疗决策提供有力支持。

问题二涉及出血性脑卒中患者的血肿和周围水肿的动态变化，并包括问题 a、问题 b、问题 c 和问题 d 四个子问题。

首先对于问题 a，我们的任务是建立一个描述所有 100 名患者水肿体积随发病至影像检查时间变化的曲线。为实现这一目标，我们需要分析不同时间点的多次检查数据，以描绘水肿体积的变化趋势。此外，我们将计算 100 名患者的实际水肿体积与拟合曲线之间的残差，以评估模型的拟合程度。

在问题 b 中，我们需要研究患者水肿体积随时间推移的个体差异，并将患者分为不同的类别。我们将建立水肿体积随时间变化的曲线，并计算每位患者的残差。然后，我们将确定每位患者所属的水肿体积变化类别，以进一步了解不同个体的水肿体积变化模式。

问题 c 涉及不同治疗方法对患者水肿体积变化的影响。我们需要深入分析数据，以确定不同治疗方法是否对水肿体积产生影响，并在模型中加以考虑。

最后，在问题 d 中，我们需要分析患者血肿体积、水肿体积以及不同治疗方法之间的关系。这将有助于我们理解治疗方法对水肿体积和血肿体积的影响，并为临床决策提供重要信息。

这些问题旨在深入研究出血性脑卒中患者的血肿和水肿情况，以提供更全面的临床支持。

问题三涉及基于多个特征和数据源构建预测模型，以预测出血性脑卒中患者在 90 天后的功能状态和残疾程度，包括问题 a、问题 b 和问题 c 三个方面。

首先对于问题 a，我们需要建立一个预测模型，使用前 100 位患者的个人史、疾病史、发病及治疗相关特征、脑出血前 mRS 评分以及首次影像检查结果等指标。这个模型将用于预测所有脑卒中患者在 90 天后的功能状态和残疾程度。

此外，问题 b 要求我们考虑了 8 次随访影像检查结果，以预测所有接受随访检查的患者在 90 天后的 mRS 评分。这进一步丰富了模型的数据来源，有助于提高预测的准确性。

最终，我们将分析出血性脑卒中患者的预后与其个人史、疾病史、治疗方法以及影像特征之间的关联，以为临床决策提供有益的信息和建议。这将有助于医疗团队更好地了解患者的康复前景，并采取适当的治疗和康复措施。

2. 模型假设

结合本题目的现实情况及查阅的相关文献, 本文给出以下模型假设:

假设 1: 假设水肿体积随时间呈现一定的变化模式, 可能在一定时间内发展或减小。而这些模式可能会影响患者的预后。

假设 2: 假设不同患者的数据点是相互独立的。这意味着一个患者的数据不会直接影响另一个患者的评分。

假设 3: 假设医疗数据的误差项或噪声项服从正态分布, 以便应用一些统计方法。

假设 4: 假设数据中的缺失是随机的, 并且不会引入系统性的偏差。

假设 5: 假设数据中的特定时间点的影响与其他时间点无关, 即模型中的时间变量不会引入时间趋势或季节性影响。

假设 6: 假设模型的性能在不同时间点或数据收集周期内是稳定的, 即模型的预测能力不会因时间变化而显著下降。

假设 7: 假设在某些情况下, 患者群体是同质的, 即所有患者对康复的影响因素相同。

假设 8: 假设不同治疗方法之间的影响是相互独立的, 即一个治疗方法的应用不会影响其他治疗方法的效果。

假设 9: 假设模型的性能在不同亚组中是一致的, 即模型能够在所有亚组中准确拟合水肿体积的变化。

假设 10: 假设数据集中的信息是准确、完整和可靠的。

这些假设为我们提供了问题解决的指导和帮助。在实际问题解决过程中, 我们将验证并根据需要调整这些假设, 以确保所采用的算法在各种情况下都能保持可靠性和有效性。

3. 符号说明

符号	说明
$OobErrorT_i^j$	特征 j 对于随机森林中树 i 的袋外数据误差
e_1	用袋外数据样本计算得到的误差
e_2	随机打乱袋外数据中的第 j 列后所得到的误差
$MOET^j$	特征 j 的平均袋外数据误差
T	随机森林中树的总数量
$weight_j$	特征 j 的权值
D	特征总数
g_i	一阶损失函数的梯度统计量
f_i	损失函数的二阶梯度统计量
(x_i, y_i)	每个数据点的坐标
μ	均值
σ^2	方差
c_k	K 个聚类集的 K 个聚类中心
S_r	已分配数据的第 r 个聚类集
$d_{ij} = \ x_j - v_i\ $	样本 x_j 与聚类中心 v_i 之间的欧氏距离

$x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})$	输入实例即特征向量
N	样本容量

4. 问题一：血肿扩张风险相关因素探索建模

4.1 问题一 a 题

4.1.1 问题一 a 题分析

问题一的第一个问题要求我们根据题目所给数据中的三张表格（表 1、表 2 和附表 1）中的数据来判断 100 名患者（sub001 至 sub100）在发病后的 48 小时内是否发生血肿扩张事件，并且如果发生了，需记录血肿扩张的时间。其中，是否发生血肿扩张是根据血肿体积的前后变化，具体定义为：后续检查比首次检查的 HM_volume（血肿体积）绝对体积增加 ≥ 6 mL 或相对体积增加 $\geq 33\%$ 。

问题一的核心目标是通过计算出随访时间与首次发病之间的间隔在 48 小时内的血肿体积值与其判断指标作比较，最后判断患者是否发生血肿扩张。为了解决这个问题，我们需要进行以下详细的问题分析：

首先，我们从三张数据集（表 1、表 2 和附表 1）中提取出我们所需相关指标，具体说明见表 1。

表 4-1：提取相关指标

表名	列名
表 1	首次检查流水号、发病到首次影像检查时间间隔
表 2	HM_volume、HM_volume(i)、随访 1/2/3/4/5/6/7/8 流水号
附表 1	入院首次检查时间点、随访 1/2/3/4/5/6/7/8 时间点

其中，HM_volume(i)中的 $i = 1, 2, \dots, 8$ ，指对应的随访流水号检查的血肿体积。

我们的数学模型的核心思想是将时间、血肿体积的变化和事件判断结合起来，以捕捉血性脑卒中患者治疗过程中的关键事件。通过这一模型，我们能够实时监测患者的血肿状态，尤其是在治疗后的随访期间。接下来，让我们进一步详细扩展上述过程，以更清晰地描述如何计算血肿事件以及相关时间间隔。以下是扩展后的说明：

计算当前时间点与发病时的时间间隔，定义为：通过将当前时间点的随访时间间隔（随访时间点与首次医院影像检查时间点的时间间隔）与发病到首次影像检查的时间间隔之和。如果大于 48 小时，我们不再判断，因为事件必须在发病后 48 小时内发生。

在计算血肿体积变化的两个指标方面我们进行如下处理：当前时间点的血肿体积与首次检查的血肿体积的绝对差异。当前时间点的血肿体积相对于首次检查的血肿体积的相对差异。如果血肿体积的绝对差异大于等于 6ml 或血肿体积的相对差异大于等于 0.33，则表示发生了血肿扩张事件，并将此时的时间间隔设置为发病时间。最后设计出一个数学模型，在满足上述条件下得到最终结果。

我们给出问题一 a 题的研究思路如图 1 所示：




图 4-1：问题一(a)流程图

4.1.2 问题一 a 题模型的建立

根据问题描述，要求判断患者 sub001 至 sub100 在发病后 48 小时内是否发生了血肿扩张事件，并记录事件的时间。为了解决这个问题，首先需要考虑一些关键步骤：针对每个患者（sub001 至 sub100），获取其发病到首次影像检查的时间间隔。

对于每个患者，检查其首次影像检查后的多个时间点，并获取相应时间点的血肿体积（HM_volume）。

计算每个时间点的血肿体积变化，即当前时间点的血肿体积与首次检查的血肿体积的绝对差异和相对差异。

如果在发病后 48 小时内存在任何一个时间点，其血肿体积的绝对差异大于等于 6ml 或相对差异大于等于 33%，则判定为发生了血肿扩张事件，并记录事件的时间。

最后，根据判断结果，将"是否发生血肿扩张"的二元值和事件的时间填写。

我们对应的伪代码如下所示：

算法：

循环处理每一行数据：

 initialize 是否血肿为 False

 initialize 水肿时间为 None

 开始对每一个特征列的循环遍历：

 计算当前时间点与发病时的时间间隔

 判断时间间隔是否大于 48 小时：

 如果时间间隔大于 48 小时，停止判断

 计算当前时间点的血肿体积与首次检查的血肿体积的绝对差异

 计算当前时间点的血肿体积相对于首次检查的血肿体积的相对差异

 判断血肿体积的绝对差异是否大于等于 6ml 或相对差异是否大于等于

33%：

 如果满足任一条件，表示发生了血肿扩张事件

 添加结果到新表格

4. 1. 3 问题一 a 题模型的求解

通过执行以上步骤，可以对患者 sub001 至 sub100 的数据进行分析，判断是否发生血肿扩张事件，并记录发生时的时间。这样的分析有助于了解患者在发病后 48 小时内是否需要更紧急的医疗干预，以便更好地管理脑卒中患者的治疗和康复过程。

下面展示部分结果：

表 4-2：问题一(a)部分结果表

ID	是否发生血肿扩张(1 是, 0 否)	血肿扩张时间(单位: 小时)
sub001	0	
sub002	0	
sub003	1	9.52
sub004	0	
sub005	1	26.47
...	...	...
sub096	0	
sub097	0	
sub098	1	42.76
sub099	1	17.67
sub100	0	

4. 2 问题一 b 题

4. 2. 1 问题一 b 题分析

根据问题描述，我们的目标是预测患者是否会发生血肿扩张事件。我们将利用前 100 例患者的个人史、疾病史、发病及治疗相关特征，以及他们的每次影像检查结果等特征，构造模型对所有患者发生血肿扩张的概率进行预测。

首先对数据进行预处理，包括缺失值处理、特征编码、数据归一化或标准化等，以使数据适合模型训练。

在构建模型之前，需要对特征进行选择。这可能涉及到特征的筛选、降维或转换，以确保模型具有最相关的输入特征。

接下来我们选择适当的机器学习算法来构建分类模型。常见的算法包括逻辑回归、决策树、随机森林、支持向量机等。使用前 100 例患者的数据，将模型进行训练。这包括将特征变量与目标变量（是否发生血肿扩张事件）进行匹配，以学习模型的参数。对模型进行评估，通常采用交叉验证或保留一部分数据作为验证集，来评估模型的性能。常用的评估指标包括准确度、召回率、精确度、F1 分数等。

最终，我们将得到每个患者发生血肿扩张事件的概率预测结果。




图 4-2：问题一(b)流程图

4.2.2 b 题数据预处理

我们的数据来源如下表所示：

表 4-3：问题一(b)数据来源

表名	列名
表 1	年龄、...、营养神经
表 2	首次检查的 HM_volume、...、ED_Cerebellum_L_Ratio
表 3	original_shape_Elongation、...、NCCT_original_firstorder_Variance

经过对数据的检查可知我们的数据集不存在缺失值。

1.异常值处理

异常点在数据中与缺失值或重复数据不同，通常可以通过肉眼观察到，因为它们通常是数值或数据分布中的明显离群值。然而，异常点的存在往往不是毫无意义的，它们通常携带着其他信息，需要仔细分析异常点出现的原因。判断异常点时需要有依据，不能轻易将正确的数据误判为异常点，因为这可能会导致错误的数据清理和分析结果。正确的异常点检测方法应该基于数据的统计性质、领域知识或模型预测等多种因素。

对所给特征进行分析，根据其是否服从正态分布，将特征分为是否服从正态分布两类。

其中，近似服从正态分布的特征如表 4 所示：

表 4-4：近似服从正态分布的特征

近似服从正态分布的特征	统计值	p-value
original_shape_Flatness	0.9817	0.1810
original_shape_LeastAxisLength	0.9910	0.7487
original_shape_Maximum2DDiameterRow	0.9799	0.1297
original_shape_Maximum2DDiameterSlice	0.9796	0.1234
original_shape_Maximum3DDiameter	0.9841	0.2734
original_shape_MinorAxisLength	0.9841	0.2727

NCCT_original_firstorder_10Percentile	0.9872	0.4523
NCCT_original_firstorder_InterquartileRange	0.9937	0.9247
NCCT_original_firstorder_Maximum	0.9768	0.0753
NCCT_original_firstorder_MeanAbsoluteDeviation	0.9947	0.9673
NCCT_original_firstorder_Mean	0.9765	0.0707
NCCT_original_firstorder_Median	0.9770	0.0771
NCCT_original_firstorder_Minimum	0.9785	0.1023
NCCT_original_firstorder_Range	0.9845	0.2906
NCCT_original_firstorder_RobustMeanAbsoluteDeviation	0.9942	0.9478
NCCT_original_firstorder_RootMeanSquared	0.9753	0.0566
NCCT_original_firstorder_Uniformity	0.9851	0.3237
NCCT_original_firstorder_Variance	0.9889	0.5795

对近似服从正态分布的特征我们可以使用 3σ 原则对其是否存在异常值进行检测， 3σ 原则又称为拉依达准则，该准则定义如下：

假设一组检测数据只含有随机误差，对原始数据进行计算处理得到标准差，然后按一定的概率确定一个区间，认为误差超过这个区间的就属于异常值。如果数据服从正态分布，异常值被定义为一组测定值中与平均值的偏差超过 3 倍的值，如公式 (1) 所示：

$$p(|x - \mu| > 3\sigma) \leq 0.003 \quad (1)$$

其中在正态分布中 σ 代表标准差， μ 代表均值， $x = \mu$ 即为图像的对称轴。

3σ 原则剔除异常值步骤如下所示：

Step1: 计算均值和标准差。首先，对于本题数据集，计算出均值和标准差。均值表示数据的中心位置，标准差用于衡量数据的分散程度。

Step2: 确定异常值的范围。根据 3σ 原则，异常值通常被定义为距离均值三个标准差之外的数据点。因此，我们可以计算出上限和下限，即均值加三倍标准差和均值减三倍标准差。

Step3: 识别异常值。遍历本题数据集，识别那些落在上述计算出的异常值范围之外的数据点。这些数据点即被认为是异常值。

Step4: 处理异常值。

应用 3σ 原则对上面近似服从正态分布的特征进行检查，不曾发现有缺失值。

当我们面对不服从正态分布的特征时，无法使用传统的 3σ 原则来检测异常值。在这种情况下，我们采用了箱型图理论来识别潜在的异常值。

箱型图由五个数据点组成，包括最小值、下四分位数 (Q_1)、中位数 (Median)、上四分位数 (Q_3) 和最大值。我们将平均值添加到箱型图中。如下图所示，下四分位数、中位数和上四分位数形成一个带有隔间的盒子，可以更直观的理解：




图 4-3：箱型图与正态分布类比图

由于现实数据中常常包含各种异常值，为了不让这些少数的离群数据影响整体特征的分布，通常将这些离群点单独标记出来。有一个经验法则是，将最大（最小）观测值设置为与四分位数差距的 1.5 倍，即 1.5 个 IQR （上下四分位数之差）。即 $IQR = Q_3 - Q_1$ ，最小观测值为 $Q_1 - 1.5 \times IQR$ ，最大观测值为 $Q_3 + 1.5 \times IQR$ 。箱型图法来处理异常值，其中在最小观测值至最大观测值之外的数据我们称之为异常值，这与正态分布的 3σ 原则大致相对应。

通过上述方法对不服从正态分布的数据用箱形图来判断其是否存在异常值，不服从正态分布的数据集和异常值如表 4-5 所示：

表 4-5：不服从正态分布的列的异常值

列名	患者编号	异常值
HM_volume	sub006	171129.0
	sub098	188134.0
HM_ACA_R_Ratio	sub002	0.496000
	sub046	0.481129
HM_PCA_R_Ratio	sub020	0.834702
	sub073	0.064725
HM_Pons_Medulla_R_Ratio	sub086	0.082343
	sub092	0.079357
HM_Cerebellum_R_Ratio	sub051	0.121932
HM_ACA_L_Ratio	sub050	0.724112
HM_PCA_L_Ratio	sub032	0.700727
HM_Pons_Medulla_L_Ratio	sub021	0.065705
	sub093	0.085003
HM_Cerebellum_L_Ratio	sub056	0.037834
	sub090	0.053596
ED_volume	sub006	97503.0
ED_ACA_R_Ratio	sub046	0.529512
	sub077	0.561257

	sub098	0.441933
ED_PCA_R_Ratio	sub086	0.477006
	Sub100	0.475227
ED_Pons_Medulla_R_Ratio	sub020	0.556250
	sub086	0.308687
ED_Cerebellum_R_Ratio	sub051	0.045473
	sub090	0.069764
ED_ACA_L_Ratio	sub050	0.911504
	sub076	0.555249
ED_PCA_L_Ratio	sub010	0.393465
	sub081	0.417965
ED_Pons_Medulla_L_Ratio	sub020	0.200000
	sub090	0.112042
	sub093	0.208003
ED_Cerebellum_L_Ratio	sub081	0.163153
	sub090	0.054839
original_shape_MajorAxisLength	sub033	152.838338
original_shape_MeshVolume	sub096	48649.541667
original_shape_Sphericity	sub037	0.61

例如，在 HM_volume（血肿体积）这个指标中存在两个数值异常值：分别是 Sub006 的 171129.0 和 Sub098 的 188134.0。然而，在随后的随访过程中，我们注意到这两个患者的 HM_volume 值在后续时间点都呈现出相对稳定的趋势，与其异常值相差不大。因此，我们可以合理地解释这两个数值，并得出它们并不属于真正的异常值。

类似地，对于其他指标，如 original_shape_MajorAxisLength（主轴长度）、original_shape_MeshVolume（网格体积）和 original_shape_Sphericity（球度），也存在类似的情况。虽然它们在首次检查中可能显示为异常值，但在后续的观察中，它们表现出与异常值不符的稳定性，因此我们认为这些数值并不应被列为异常值。

对于涉及体积占比的指标，例如 HM_ACA_R_Ratio（血肿体积占右侧大脑前动脉体积的比例），我们需要考虑特定患者的生理差异。以 HM_ACA_R_Ratio 中的 sub002 的 0.496000 为例，它表示该患者的血肿体积占右侧大脑前动脉体积的百分之 49.6%。通过进一步观察，我们发现该患者的血肿体积在大脑其他部位的体积占比相对较小，因此 0.496000 的数值是正常的，并不应被视为异常值。类似的情况也适用于其他涉及体积占比的异常值，它们可以合理地解释为患者个体差异所致。

综上所述，我们认为数据集中的异常值都是合理的，不需要进行额外的处理。这种判断基于对患者情况的深入理解以及对后续随访数据的观察，有助于确保我们的分析结果更加准确和可靠。

2.探索性数据分析

我们从数据集中随机选择了几对数据，然后使用散点图进行了可视化展示。这一可视化过程有着重要的意义，因为它能够帮助我们更好地理解数据中的关系和趋势。




图 4-4：部分变量之间的散点图

当主要特征之间的相关性都相对较低时，这意味着这些特征在描述因变量的某个方面特性时，彼此之间的影响相对较小，甚至可以说它们具有一定程度的独立性。这种独立性在数据分析和建模中具有重要的意义，因为它暗示着每个主要变量都可能为解释因变量的某个方面提供独立的信息，而不会出现多个变量提供相似信息或冗余信息的情况。

具有独立性的主要变量有助于模型的稳定性和可解释性。在建立预测模型时，如果特征之间高度相关，模型可能会变得复杂，难以理解，甚至容易过拟合。然而，当主要特征具有独立性时，模型更容易解释，更容易泛化到新的数据集，因为每个特征都提供了独立的信息。

此外，独立的主要变量还有助于识别重要的特征。在特征选择过程中，如果特征之间相关性较低，那么我们可以更自信地选择其中的一个或多个特征作为最终模型的输入，而不必担心信息的重复或冗余。

最后，我们对数据集中的数值型变量进行标准化。

4.2.3 问题一 b 题模型的建立

1. 特征选择

在我们的数据中，包含大量的特征或变量，但并非所有的特征都对解决问题或建立模型有用。不必要的特征会增加计算成本、增加模型复杂度并降低模型的可解释性。特征选择有助于减少特征的数量，提高问题的可管理性。

我们选择特征选择的主要方法是互信息法和随机森林法。

(1) 基于互信息

互信息是信息论中的一个关键概念，通常用于衡量两个随机变量之间的依赖性 or 关联性。在机器学习和数据分析中，互信息常用于特征选择、特征工程和聚类等

任务。不同于相关系数，互信息并不局限于实值随机变量，它更加一般且决定着联合分布 $p(X,Y)$ 和分解的边缘分布的乘积 $p(X)p(Y)$ 的相似程度。互信息是度量两个事件集合之间的相关性。

两个离散随机变量 X 和 Y 的互信息可以定义为公式 (2)：

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} p(x,y) \log \left(\frac{p(x,y)}{p(x)p(y)} \right) \quad (2)$$

其中 $p(x,y)$ 是 X 和 Y 的联合概率分布函数，而 $p(x)$ 和 $p(y)$ 分别是 X 和 Y 的边缘概率分布函数。

以下是基于互信息的特征选择的主要步骤和原理：

首先，针对每个特征和目标变量之间的关系，计算互信息分数。互信息分数通常基于信息熵的概念，用来衡量特征与目标变量之间的信息关联度。分数越高，表示特征与目标变量之间的关联性越强。

对于每个特征，计算其与目标变量的互信息分数，然后按照分数高低对特征进行排序。通常，分数较高的特征被认为更相关。

根据需要选择前 k 个互信息分数最高的特征，作为最终的特征集合。选择的数量 k 可以根据问题和模型的需求来确定。

(2) 基于随机森林

随机森林是一种备受瞩目的机器学习算法，具有出色的灵活性和广泛的应用前景。它在众多分类和回归问题中表现出卓越的准确性。值得一提的是，随机森林算法内置了特征筛选机制，可以评估各个特征在特定问题上的重要性。

在本文中，我们面对的数据集具有众多特征和高度非线性的特性，这与随机森林算法的应用条件非常匹配。因此，我们计划构建一种基于随机森林的操作变量特征筛选模型，以对经过预处理的数据进行有效的筛选。以下是我们的详细步骤，旨在提高模型性能并挖掘数据的潜力：

(2.1) 特征贡献度计算

在基于随机森林的操作变量特征筛选模型中，我们使用特征重要性来量化每个特征对随机森林中每棵树的贡献度的平均值。通过比较不同特征的贡献度大小，我们可以确定它们的相对重要性。这里，贡献度指的是对平均袋外数据误差的影响，而袋外数据误差可以用以下公式 (3) 表示

$$OobErrorT_i^j = |e_1 - e_2| \quad (3)$$

其中， $OobErrorT_i^j$ 表示特征 j 对于随机森林中树 i 的袋外数据误差， e_1 表示用袋外数据样本计算得到的误差， e_2 表示随机打乱袋外数据中的第 j 列后所得到的误差。

根据袋外数据误差，我们可以计算出平均袋外数据误差，如公式 (4) 所示：

$$MOET^j = \frac{\sum_{i=1}^T OobErrorT_i^j}{T} \quad (4)$$

其中， $MOET^j$ 表示特征 j 的平均袋外数据误差， T 表示随机森林中树的总数量。并且，在处理袋外数据时，采用以下方法对第 j 列进行随机打乱：通过对原始样本中所有样本的第 j 个特征值进行重新排列，从而改变其分布。

至此，我们可以通过平均袋外数据误差来衡量特征 j 的重要性。这是基于以下观点的：如果某特征具有重要性，那么它的变化会显著影响测试误差；相反，如果测试误差的变化幅度较小，那么特征 j 可能不是很重要。这种观点有助于我们更好

地理解特征的影响力和相关性。

(2.2) 随机森林训练

在这个基于随机森林的操作变量特征筛选模型中，随机森林的训练过程涵盖以下关键步骤：

Step1: 原始训练集包含 N 个样本，通过使用 Bootstrap 方法（有放回抽样），我们随机抽取 k 个新的自助样本集，然后使用这 k 个自助样本集构建 k 棵分类树。每次抽取自助样本时，未被选中的样本构成了 k 个不同的袋外数据集；

Step2: 如果我们的特征空间总共包含 D 个特征，那么在每一轮生成决策树的过程中，我们会从这 D 个特征中随机选择 d 个特征（其中 $d < D$ ），以构建一个新的特征集。通过使用这个新的特征集，我们生成了 k 个相互独立的决策树，每个决策树都在不同的特征子集上建模，总共进行了 k 轮训练；

Step3: 将生成的多棵树组合成随机森林时，每棵决策树的重要性是相等的，不需要考虑它们的权重或权值差异。这意味着每棵树对最终模型的贡献是平等的。

随机森林算法的流程图如下图所示：




图 4-5: 随机森林流程图

(2.3) 特征权值计算

特征权值反映了操作变量在模型中的重要程度占比。对于每个操作变量的特征权值，它表示该特征的平均袋外数据误差与所有特征的平均袋外数据误差之比。具体的数学表达式如公式（5）所示

$$weight_j = \frac{MOET^j}{\sum_{k=1}^D MOET^k} \quad (5)$$

其中， $weight_j$ 表示特征 j 的权值， $MOET^j$ 表示特征 j 的平均袋外数据误差， D 表示特征总数。

(2.4) 主要操作变量筛选

在获取了所有特征的特征权值后，我们可以将它们按照降序排列，形成一个操作变量特征权值集合 WeightSet（其中， $weight_{ranki}$ 表示排名第 i 的变量的权值）。通

过这个集合，我们可以根据需要筛选出对损失贡献度较高的建模主要操作变量，这些变量在模型中具有重要性，具体公式如下所示：

$$\text{WeightSet} = \begin{bmatrix} \text{weight}_{\text{rank1}} \\ \text{weight}_{\text{rank2}} \\ \vdots \\ \text{weight}_{\text{rankD}} \end{bmatrix} \quad (6)$$

2. 分类模型的选择

(1) XGBoost 算法

在机器学习领域，我们通常将算法分为弱学习器和强学习器两类，而 XGBoost 被认为是目前最优秀的强学习器之一，主要用于树的增强和梯度提升。其基本原理是一种集成学习思想，通过迭代的方式将多个弱学习器集成为一个强大的学习器。这个过程显著提升了分类器的预测性能，使其在性能上超越了其他增强型算法。XGBoost 的强大之处在于它的高效性和准确性，因此被广泛应用于各种机器学习任务中。

XGBoost 算法的核心思想：

- **逐步构建树：**XGBoost 的训练过程是渐进的，它不断地增加树的数量，并进行特征分裂以生长每一棵树。每次添加一棵树，实际上是在学习一个新的函数，以更好地拟合上一次预测的残差。
- **样本分数预测：**在训练完成后，当需要对一个样本进行预测时，算法会根据该样本的特征将其映射到每棵树上的一个叶子节点，每个叶子节点都对应一个分数。
- **汇总预测值：**最后，我们只需将每棵树对应的分数相加，即可得到该样本的最终预测值。

这种渐进式学习和集成方法使 XGBoost 在性能上表现出色，特别适用于回归和分类问题。

XGBoost 包含一个目标函数和一个迭代解过程。首先，我们启动目标函数，以明确模型主要用于解决分类问题还是线性问题。随着迭代的进行（用 t 表示），模型的输出结果逐渐演变如下：

$$y_i^{(t)} = y_i^{(t-1)} + h_t(x_i) \quad (7)$$

XGBoost 的目标函数被定义如下：

$$\gamma^{(t)} = \sum_{i=1}^n l(z_i, y^{(t-1)} + h_t(x_i)) + \theta(h_t) \quad (8)$$

其中

$$g_i = \partial_{y^{(t-1)}} l(z_i, y^{(t-1)}), f_i = \partial_{y^{(t-1)}}^2 l(z_i, y^{(t-1)}) \quad (9)$$

其中， g_i 是一阶损失函数的梯度统计量， f_i 是损失函数的二阶梯度统计量。

(2) LightGBM 算法

LightGBM 是由微软于 2017 年提出的，它是一种基于决策树的 Boosting 集成学习算法，专门用于解决分类和回归问题。LightGBM 是梯度提升决策树的一种实现框架。相对于 XGBoost 算法，LightGBM 在实际应用中具有多项改进和优化，包括支持 GPU 加速和分布式计算，更快的训练速度，更低的内存消耗，更高的准确率，以及能够高效处理大规模数据等优点。

为了使 GBDT 能够更高效地处理大规模数据，LightGBM 算法引入了一系列创新

的优化方法，以在维持模型准确性的同时提升训练速度。这使得 LightGBM 算法能够克服 XGBoost 算法的一些不足之处，更适合于工业界的实际应用。

下面将介绍一些重要的 LightGBM 中的优化算法。

（2.1）直方图 Histogram 优化算法

直方图优化算法的核心思想在于将一个特征中的连续浮点值划分为 k 个整数区间，例如，将年龄分成若干年龄段，如图 6 所示。每个特征因此被离散为 k 个整数“箱子”或区间。在节点分裂时，不再需要扫描所有数据并计算所有数据的分裂结果，而是仅需计算区间的个数，即进行 k 次计算。这种方法不仅加速了运算，还提高了模型的鲁棒性，使其更加稳定，并减少了计算结果所占用的内存。尽管这种方法可能导致分割不够精确的问题，但相对于直方图算法带来的性能提升和优化，这个问题可以被忽略。此外，一旦建立了直方图，在分裂后的子节点仍然可以继续使用直方图，类似于将分裂箱子的左右部分分别分配给左右子节点，这无疑也加速了计算的过程。




图 4-6：直方图优化算法

（2.2）带深度限制的 Leaf-Wise 算法

XGBoost 的树模型分裂策略采用 Level-Wise，这意味着在同一层的叶子节点上进行分裂时没有特定的区分。虽然这种方式容易进行多线程优化，易于控制模型复杂度以防止过拟合，但同时也带来了一个问题，即每一层都可能产生许多低增益的节点，从而增加了额外的计算开销。

与此不同，LightGBM 采用了 Leaf-Wise 算法，它会从当前一层的叶子节点中选择具有最大分裂增益的节点进行分裂，如图 7 所示。这种方法在相同的分裂次数下可以降低误差，提高模型的精度，但也容易导致模型变得较深，可能会增加过拟合的风险。因此，为了控制模型的深度，通常需要额外设置树模型的深度限制。




图 4-7：增长策略对比

（2.3）单边梯度采样算法

单边梯度采样（GOSS, Gradient-Based One-Side Sampling）的核心思想是从样本减少的角度出发。在使用 GBDT 时，每个数据点都具有不同的梯度值，但梯度较小

的样本通常表示它们的误差相对较小，这意味着模型已经充分学习了这些数据。因此，GOSS 方法的策略是丢弃一部分梯度较小的样本，然后利用保留下来的数据来计算信息增益。这种方式有助于减少训练数据的规模，提高训练速度，同时仍然保持了模型的性能。但为了使改变的数据分布降低模型精度的影响，所以采用 $a\%$ 的大梯度数据和 $b\%$ 的小梯度数据，并且使这部分小梯度数据乘以常数 $\frac{1-a}{b}$ 。使算法加强对训练不充分数据的关注度，同时减少数据分布的改变。

3. 交叉验证

五折交叉验证是一种常用的机器学习模型评估技术，通常用于估计模型的性能和泛化能力。其基本思想是将原始数据集分成五个相等大小的子集（或折叠），然后依次将每个子集作为测试集，其余四个子集作为训练集。这个过程重复五次，每次选择不同的一个子集作为测试集，其余的作为训练集。最后，将五次性能评估的结果取平均值，以获得最终的模型评估结果。这种方法有助于更全面地了解模型在不同数据子集上的表现，减少了评估结果的随机性，提高了模型评估的可靠性。

以下是五折交叉验证的主要步骤：

Step1: 数据集划分。将原始数据集均匀地分成五个子集，通常采用随机划分的方式。

Step2: 模型训练和测试。逐一选取其中一个子集作为测试集，将剩余四个子集作为训练集，然后训练模型并在测试集上进行性能评估。这个过程重复五次，确保每个子集都被用作测试集一次。

Step3: 性能度量。在每次测试中，可以使用各种性能度量指标，如准确度、精确度、召回率、F1 分数等，来评估模型在测试集上的性能。

Step4: 汇总结果。将五次测试的性能度量结果取平均值，以得到模型的最终性能评估。如公式（10）所示：（这里可以提供具体的计算公式）

$$CV_{(5)} = \frac{1}{5} \sum_{i=1}^5 MSE_i \quad (10)$$

五折交叉验证有助于更全面地评估模型的性能，减小因随机性引起的误差，提供更可靠的性能估计。同时它提供了对模型在未见过的数据上的泛化性能的估计。通过多次验证，可以更好地了解模型对不同数据分布的适应能力，而不仅仅是在单次验证集上的表现。

我们选择五折交叉验证作为我们分类任务中的标准实践。

4. 分类性能评价指标

用于评估模型性能的指标有多种，其中包括 FP（False Positives）、FN（False Negatives）、TP（True Positives）、TN（True Negatives），以及准确率（Accuracy）、精确率（Precision）、召回率（Recall）等几个关键指标：

FP: 模型错误地将负样本（类别 0, negative）预测为正样本（类别 1, positive）。

FN: 模型错误地将正样本（类别 1, positive）预测为负样本（类别 0, negative）。

TP: 模型正确地将正样本（类别 1, positive）预测为正样本。

TN: 模型正确地将负样本（类别 0, negative）预测为负样本。

这些指标用于量化模型在不同分类任务中的性能，其中准确率（Accuracy）、精确率（Precision）和召回率（Recall）等指标可以帮助我们更全面地评估模型的效果和特性。

准确率（Accuracy）: 是指算法模型正确分类的数据（类别为 0 且预测结果也为 0，或者类别为 1 且预测结果也为 1）占总数据的比例。它的计算公式如下：

$$\frac{TP + TN}{TP + TN + FP + FN} \quad (11)$$

精确率 (Precision): 对于算法模型预测出的所有正例 (TP+FP)，精确率衡量了其中真正是正例 (TP) 的比例。以正负样本检测为例，高精确率表示算法模型在预测正样本时，大部分确实是正样本，只有极少数非正样本被错误地分类为正样本。精确率的计算公式如下：

$$\frac{TP}{TP + FP} \quad (12)$$

召回率 (Recall): 对于数据集中的所有正例 (TP+FN)，召回率衡量了算法模型正确预测出的正例 (TP) 在所有正例中的比例。以正负样本检测为例，高召回率表示算法模型可以找出正样本中更多的真正正样本，即模型能够较全面地捕捉到数据集中的正例。召回率的计算公式如下：

$$\frac{TP}{TP + FN} \quad (13)$$

4.2.4 问题—b 题模型的求解

1. 数据的预处理

原始数据中的信息可能以不方便的格式存在，比如“血压”特征。通过拆分列，可以将数据清理得更加结构化和易于处理。将其拆分为“高压”和“低压”可以更容易地获取每个部分的数值，以便进一步分析。这可以帮助医疗领域的研究人员或医生更好地理解患者的生理状况。

将年龄数据分组为不同的年龄段，我们可以更好地理解数据的分布，将连续的年龄值划分为离散的分类，使数据更具可解释性。同时能够帮我们迅速了解不同年龄段的人数分布情况。

2. 特征筛选

在我们的特征选择流程中，首先采用互信息作为评价标准，以筛选出与目标变量高度相关的特征。互信息能够帮助我们测量每个特征与目标变量之间的关联程度，这对于确定哪些特征在预测任务中最为重要至关重要。

具体而言，我们计算了每个特征与目标变量之间的互信息分数，这些分数反映了特征与目标变量之间的依赖性和相关性。接下来，我们会根据互信息分数的高低对特征进行排序，将与目标变量相关性较高的特征保留下来，而将与目标变量相关性较低的特征进行筛选。

通过这个筛选过程，我们可以建立一个更加紧凑和具有信息量的特征集合，从而为后续的建模过程提供更有力的输入。这有助于提高模型的训练效率、降低过拟合风险，并提高模型性能。

得到的互信息的指标值如表 4-6 所示：

表 4-6: 互信息的指标值

特征名称	MI Score	特征名称	MI Score	特征名称	MI Score
性别	0.7601	降压治疗	0.7565	HM_Pons_Medulla_L_Ratio	0.5638
脑出血前 mRS 评分	0.7455	镇静、镇痛治疗	0.7540	HM_Cerebellum_L_Ratio	0.6878
高血压病史	0.7597	止吐护胃	0.7492	ED_ACA_R_Ratio	0.3528
卒中病史	0.7517	营养神经	0.7455	ED_MCA_R_Ratio	0.3069
糖尿病史	0.7557	HM_ACA_R_Ratio	0.4090	ED_PCA_R_Ratio	0.3248
房颤史	0.7344	HM_MCA_R_Ratio	0.2755	ED_Pons_Medulla_R_Ratio	0.5429

冠心病史	0.7214	HM_PCA_R_Ratio	0.2695	ED_Cerebellum_R_Ratio	0.7301
吸烟史	0.7454	HM_Pons_Medulla_R_Ratio	0.5313	ED_ACA_L_Ratio	0.3010
饮酒史	0.7139	HM_Cerebellum_R_Ratio	0.7092	ED_MCA_L_Ratio	0.2787
发病到首次影像检查时间间隔	0.6661	HM_ACA_L_Ratio	0.3801	ED_PCA_L_Ratio	0.3001
脑室引流	0.7570	HM_MCA_L_Ratio	0.2648	ED_Pons_Medulla_L_Ratio	0.5352
止血治疗	0.7401	ED_Cerebellum_L_Ratio	0.6949	original_shape_Maximum2D DiameterColumn	0.0200
降颅压治疗	0.7470	HM_PCA_L_Ratio	0.2257		

注：剩余指标如 HM_volume、ED_volume 等指标值的 IM Score 为 0，表中不进行详细罗列。

我们利用互信息分数对特征与目标变量之间的关联性进行了可视化呈现，这一过程有助于更清晰地理解每个特征对于预测目标的重要性。通过观察互信息分数的分布，我们可以识别出哪些特征与目标变量之间存在高度相关性。分数较高的特征通常表示在预测目标方面具有更多的信息，因此在建模过程中可能起到关键作用。这种视觉呈现使我们能够更有针对性地选择重要特征，从而提高模型的性能。

其次，互信息分数的可视化有助于识别不相关或弱相关的特征。低互信息分数的特征可能对目标变量的预测几乎没有贡献，因此可以在特征选择阶段将其舍弃，减少了模型的复杂性和计算成本。

最后，互信息分数的可视化还有助于理解特征之间的相互关系。通过观察分数高的特征，我们可以了解它们对目标的影响程度，以及它们之间是否存在共线性或相互依赖的情况。这有助于我们更好地设计特征工程策略，以避免多重共线性等问题。

我们可视化的结果如下图所示：




图 4-8：互信息特征重要性

我们设置阈值为 0.2，最终保留了以下 40 个特征，如表 4-7 所示：

表 4-7：互信息筛选的特征

‘性别’	‘脑出血前 mRS 评分’	‘高血压病史’	‘卒中病史’	‘糖尿病史’	‘房颤史’
‘冠心病史’	‘吸烟史’	‘饮酒史’	‘发病到首次影像检查时间间隔’	‘脑室引流’	
‘止血治疗’	‘降颅压治疗’	‘降压治疗’	‘镇静、镇痛治疗’	‘止吐护胃’	
‘营养神经’	‘HM_ACA_R_Ratio’	‘HM_MCA_R_Ratio’	‘HM_PCA_R_Ratio’		
‘HM_Pons_Medulla_R_Ratio’	‘HM_Cerebellum_R_Ratio’	‘HM_ACA_L_Ratio’			
‘HM_MCA_L_Ratio’	‘HM_PCA_L_Ratio’	‘HM_Pons_Medulla_L_Ratio’			
‘HM_Cerebellum_L_Ratio’	‘ED_ACA_R_Ratio’	‘ED_MCA_R_Ratio’			
‘ED_PCA_R_Ratio’	‘ED_Pons_Medulla_R_Ratio’	‘ED_Cerebellum_R_Ratio’			
‘ED_ACA_L_Ratio’	‘ED_MCA_L_Ratio’	‘ED_Cerebellum_L_Ratio’			
‘ED_PCA_L_Ratio’	‘ED_Pons_Medulla_L_Ratio’	‘高压’	‘低压’	‘Age_Group’	

虽然互信息提供了有关特征的重要信息，但它并不一定能够完全捕捉到特征之间的复杂关系和交互效应。因此，在某些情况下，互信息分数可能无法全面评估特征的价值。我们对筛选后的 40 个特征再度应用随机森林进行筛选。

随机森林通过构建多棵决策树并结合它们的结果来综合评估每个特征的重要性。这种综合性评估可以帮助捕捉到特征之间的复杂关系，包括非线性和交互效应，从而更全面地了解特征对目标变量的影响。

下图展示了随机森林对上面四十个特征重要性的排名：




图 4-9：随机森林特征重要性

我们设置阈值为 0.02，最后选择出 20 个特征，如表 4-8 所示：

表 4-8：随机森林筛选的特征

‘低压’	‘高压’	‘ED_MCA_R_Ratio’	‘ED_PCA_L_Ratio’	‘Age_Group’
‘ED_PCA_R_Ratio’		‘HM_MCA_L_Ratio’		‘HM_PCA_L_Ratio’
‘HM_MCA_R_Ratio’		‘ED_MCA_L_Ratio’	‘发病到首次影像检查时间间隔’	
‘ED_Pons_Medulla_R_Ratio’		‘HM_ACA_L_Ratio’	‘ED_ACA_R_Ratio’	
‘ED_ACA_L_Ratio’		‘HM_ACA_R_Ratio’	‘ED_Pons_Medulla_L_Ratio’	
‘冠心病史’		‘HM_Pons_Medulla_R_Ratio’	‘HM_PCA_R_Ratio’	

经过互信息和随机森林的特征选择方法，最终筛选出了二十个特征，这个结果具有重要的意义。这二十个特征被认为是与目标变量密切相关的，它们包含了对预测目标变量（可能是血肿扩张事件）非常有用的信息。

接下来的步骤是将这二十个特征应用于机器学习模型中，以构建一个能够准确预测血肿扩张事件的模型。

3. 模型的训练与求解

在特征选择后，我们已经准备好了一个相对精简和相关性较高的特征集合。树模型易于理解和解释，医疗专业人员可以根据模型的决策路径进行推理，从而更好地理解患者的预后情况。同时，树模型可以捕获特征之间的非线性关系，这对于医疗数据中复杂的潜在关系非常有用。

因此，我们考虑使用决策树、随机森林、XGBoost 等树模型，根据问题的性质和数据的特点进行选择。

各模型五折交叉验证得分如表 4-9 所示：

表 4-9：五折交叉验证表

模型名称	Cross-Validation Scores					Mean CV Score
Decision Tree	0.6875	0.75	0.5625	0.6875	0.5625	0.65
Random Forest	0.8125	0.8125	0.75	0.75	0.75	0.775
LightGBM	0.8125	0.875	0.6875	0.8125	0.8125	0.8
XGBoost	0.75	0.8125	0.75	0.75	0.75	0.7625

可以看到，随机森林的效果最好，我们选择随机森林作为我们的模型，进行进一步的模型优化。最终得到最佳的模型。

我们的部分预测结果如表 4-10 所示：

表 4-10：部分预测结果表

ID	血肿扩张预测概率
Sub001	0.3034
Sub002	0.1751
Sub003	0.5244
Sub004	0.1959
Sub005	0.1779
...	...
Sub156	0.2146
Sub157	0.2318
Sub158	0.3192
Sub159	0.2907
Sub160	0.1602

5. 问题二：血肿周围水肿建模与治疗关联性研究

5.1 问题二 a 题

5.1.1 问题二 a 题分析

这个问题涉及到构建水肿体积随时间进展的曲线，并计算真实值与所拟合曲线之间的残差。

我们首先需要从附件数据中获取前 100 个患者的水肿体积数据以及相关的重复检查时间点及其对应的各项指标。我们的目标是创建一条曲线，其中 x 轴代表发病至影像检查时间的时间间隔， y 轴代表水肿体积。

为了理解水肿体积随时间的变化趋势，我们首先需要绘制一张散点图。横坐标表示发病至影像检查时间的时间间隔，纵坐标表示水肿体积。每个散点代表一个患者的观测值。通过观察散点图，我们可以初步了解数据的分布情况。这包括水肿体积的变化范围以及是否存在明显的趋势或模式。例如，我们可以检查是否有递增或递减的趋势，或者是否存在异常值。

我们需要选择适当的数学函数或模型来拟合这个曲线。通常，可以使用多项式回归、高斯模型、数学插值等来拟合这种类型的数据。曲线拟合的目标是找到一个函数，使其在时间点上最好地逼近真实的水肿体积值。

一旦曲线模型建立并拟合到数据中，我们可以计算真实值与拟合曲线预测值之间的残差。残差表示实际观测值与模型预测值之间的差异。

分析残差可以帮助我们评估模型的拟合程度。如果残差呈现某种模式或趋势，可能意味着模型没有很好地捕获数据的变化。我们可以使用统计方法来检查残差的正态性和同方差性。

流程图如下所示：




图 5-1：问题二(a)流程图

5.1.2 问题二 a 题模型的建立

1. 回归模型

(1) 线性回归

线性回归模型的研究专注于探究自变量与因变量之间的关系，这个模型是通过一个或多个参数的线性组合来描述的。一元线性回归模型涵盖一个因变量和一个自变量，也被称为简单线性回归模型；而多元线性回归模型则包含一个因变量和多个自变量。在拟合回归直线时，主要任务是估计待定参数 a 和 b 的值，通常采用最小二乘法来完成这一任务。最小二乘法的核心原理是使实际观测值 y 与模型估计值 y_c 之间的差异的平方和最小化。以下是拟合回归直线方程的具体步骤：

Step1: 建立模型。首先，确定使用的线性回归模型类型（一元或多元），并选择适当的自变量与因变量。

Step2: 设定假设。假设因变量与自变量之间的关系可以用线性方程表示，即 $y = a + bx$ ，其中 a 和 b 是待定参数。

Step3: 估计参数。通过最小二乘法，计算使观测值与模型估计值之间的残差平方和最小的参数 a 和 b 。这可以通过最小化公式（14）来实现：

$$\sum (y_i - (a + bx))^2 \quad (14)$$

其中， (x_i, y_i) 表示每个数据点的坐标， a 和 b 是要估计的参数。

Step4: 找到最佳拟合直线。估计出的参数 a 和 b 将确定最佳拟合直线，使其与原始数据的差异最小。

具体运算过程如公式（15）所示：

$$Q = \sum (y - y_c)^2 = \text{最小值} \quad (15)$$

用直线方程 $y_c = a + bx$ 代入公式（15）得

$$Q = \sum (y - a - bx)^2 = \text{最小值} \quad (16)$$

分别求 Q 关于 a 和 Q 关于 b 的偏导并令它们等于零

$$\begin{cases} \frac{\partial Q}{\partial a} = \sum 2(y - a - bx)(-1) = 0 \\ \frac{\partial Q}{\partial b} = \sum 2(y - a - bx)(-x) = 0 \end{cases} \quad (17)$$

整理可得出以下列两个方程式所组成的标准方程组为

$$\begin{cases} \sum y = na + b \sum x \\ \sum xy = a \sum x + b \sum x^2 \end{cases} \quad (18)$$

解得

$$b = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2} \quad (19)$$

$$a = \frac{\sum y - b \sum x}{n} = \bar{y} - b \bar{x} \quad (20)$$

通过这些步骤，我们可以用线性回归模型建立自变量与因变量之间的关系，并通过最小二乘法找到最佳拟合直线的参数。这种方法有助于我们更好地理解数据之间的关系，以及如何用一个线性方程来表示这种关系。

(2) 多项式回归

多项式回归分析是一种统计分析方法，用于根据自变量与因变量之间的依赖关系建立模型。通常，它在自变量和因变量之间呈现非线性关系时得到广泛应用。例如，下图展示了一个简单的一元二次多项式回归拟合结果，其中散点表示每组数据点 (x, y) 。

在实际问题建模过程中，多项式回归的阶数通常会被设置为二阶或三阶，以满足需求。假设我们的数据集 D 包含了 n 个记录： $\{t_1, t_2, \dots, t_n\}$ ，其中包含了 d 个自变量 $\{x_1, x_2, \dots, x_d\}$ 和一个因变量 y 。这种方法有助于捕捉到复杂数据关系中的非线性特征，从而更好地理解自变量与因变量之间的关系。




图 5-2: 简单多项式回归

对于每条记录有 $t_i = (x_{i1}, x_{i2}, \dots, x_{id}, y)$ ，且假设 $\sqrt{\sum_{i=1}^d x_{id}^2} \leq 1$ ，设 $g(x) = x_1^{c_1} \cdot x_2^{c_2} \cdots x_d^{c_d}$ ，其中 $c_1, c_2, \dots, c_d \in \mathbb{N}$ ， $G_j = \left\{ x_1^{k_1} x_2^{k_2} \cdots x_d^{k_d} \mid \sum_{i=1}^d k_i = j \right\}$ ，其中 $0 \leq j \leq m$ ，设 λ_g 是 $g(x)$ 的系数则 d 维 m 阶 ($d > m$) 多项式回归模型就可以表示为公式 (21) 所示

$$y = \sum_{j=1}^m \sum_{g \in G_j} \lambda_g g(x) \quad (21)$$

多项式回归的拟合可以通过变量替换来进行，这样可以将其转换成多元线性回归问题。通过以下映射式，将每个多项式函数 $g(x)$ 转化为新的自变量 z_i ，我们可以建立一个多元线性回归模型：

$$\begin{cases} z_1 = x_1, z_2 = x_2, \dots, z_{c_d^1} = x_d \\ z_{c_d^1+1} = x_1^2, z_{c_d^1+2} = x_1 x_2, \dots, z_{c_d^1+c_d^2-1} = x_{d-1} x_d \\ z_{c_d^1+c_d^2} = x_d^2, z_{c_d^1+c_d^2+1} = x_1^3, \dots, z_{\sum_{i=1}^m c_d^i} = x_d^m \end{cases} \quad (22)$$

这个映射的过程允许我们将多项式回归问题转化为多元线性回归问题，从而利用线性回归的方法来分析数据并拟合模型。这种变换使得我们能够更有效地处理复杂的非线性关系，并利用线性回归工具来研究这些关系。

通过映射过程，我们能够将多项式回归问题转化为关于新变量 z_i 的多元线性回归问题，具体表现如公式 (23) 所示：

$$Y = Z\omega \quad (23)$$

设 $\sigma = \sum_{i=1}^m c_d^i$ ，其代价函数可以表示为下式：

$$\begin{aligned} f_D(t_i, \omega) &= \sum_{i=1}^m f(t_i, \omega) = \sum_{i=1}^n (y_i - \vec{\omega} z_i)^2 \\ &= \sum_{t_i \in D} (y_i) - \sum_{j=1}^{\sigma} \left(2 \sum_{t_i \in D} y_i z_{ij} \right) + \sum_{j \geq 1, l \leq \sigma} \left(\sum_{t_i \in D} z_{ij} z_{il} \right) \omega_j \omega_l \end{aligned} \quad (24)$$

根据最小二乘法即可求解出 $\vec{\omega}$ ：

$$\vec{\omega} = (Z^T Z)^{-1} Z^T Y \quad (25)$$

在这个方程中， z_i 是一个向量，它代表了从多项式回归中的 $g(x)$ 系数 g 转化而来的新自变量。这种映射方式允许我们将多项式回归的复杂性转化为多元线性回归的形式，每个 z_i 的系数可以对应到多项式回归中的 $g(x)$ 的系数。这一转化过程使得我们能够利用多元线性回归的技巧来分析和理解多项式回归模型。

2. 高斯模型

高斯分布也叫正态分布，即用高斯概率密度函数（正态分布曲线）精确地量化事物，将一个事物分解为若干的基于高斯概率密度函数形成的模型。高斯分布主要用于连续变量的分布。假设有一变量 x ，则其一元高斯分布形式为：

$$N(x | \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} \quad (26)$$

其中， μ 是均值（mean）， σ^2 是方差（variance），方差的平方根 σ 叫做标准误差（standard deviation），方差的倒数 $\beta \left(\beta = \frac{1}{\sigma^2} \right)$ 叫做精度（precision）。

高斯分布曲线图如下图所示：




图 5-3: 高斯分布图

高斯分布满足:

$$N(x|\mu, \sigma^2) > 0 \quad (27)$$

高斯分布是归一化的:

$$\int_{-\infty}^{+\infty} N(x|\mu, \sigma^2) dx = 1 \quad (28)$$

变量 x 在高斯分布下的期望:

$$E(x) = \int_{-\infty}^{+\infty} N(x|\mu, \sigma^2) x dx = \mu \quad (29)$$

高斯分布具有清晰的数学性质, 包括均值和方差, 这些性质使得对高斯分布的数据进行统计分析更加方便。均值和方差可用于描述数据的中心位置和离散程度。

3. 数学函数逼近拟合

(1) 牛顿插值

在物理现实世界中, 我们往往只知道部分时间或节点的信息, 为了预测其它未知时间或节点的信息, 我们通常会利用插值的方法来获取我们感兴趣节点的值, 或者当只知道函数在一些节点的位置却不知道函数具体的表达式时, 我们可以利用代数插值方法给出函数的近似形式。常用的插值公式有拉格朗日插值、牛顿插值、埃米尔特插值及样条插值等等。牛顿 (Newton) 插值公式是代数插值方法的一种形式。牛顿插值引入了差商的概念, 使其在插值节点增加时便于计算。

以下是牛顿插值的基本原理和过程:

通过给定插值点的信息, 计算 $f(x)$ 各阶差商, 具体如一下公式所示:

$$f(x, x_0) = \frac{f(x_0) - f(x)}{x_0 - x} \quad (30)$$

$$f(x, x_0, x_1) = \frac{f(x_0, x_1) - f(x, x_0)}{x_1 - x} \quad (31)$$

$$f(x, x_0, x_1, \dots, x_n) = \frac{f(x_0, x_1, \dots, x_n) - f(x, x_0, \dots, x_{n-1})}{x_n - x} \quad (32)$$

通过变形可以得到

$$f(x) = f(x_0) + (x - x_0) f(x, x_0) \quad (33)$$

$$f(x, x_0) = f(x_0, x_1) + (x - x_1) f(x, x_0, x_1) \quad (34)$$

$$f(x, x_0, \dots, x_{n-1}) = f(x_0, x_1, \dots, x_n) + (x - x_n) f(x, x_0, \dots, x_n) \quad (35)$$

依次代入，可得牛顿插值公式：

$$f(x) = f(x_0) + (x - x_0) f(x, x_0) + (x - x_0)(x - x_1) f(x, x_0, x_2) + \dots + (x - x_0)(x - x_1) \dots (x - x_{n-1}) f(x, x_0, \dots, x_n) \quad (36)$$

牛顿插值法的误差为

$$f(x) = N_n(x) + R_n(x) \quad (37)$$

一般通过差商表快速准确得到差商，差商表的计算流程如下：

表 5-1：差商表

x	$f(x)$	一阶差商	二阶差商	三阶差商	四阶差商
x_0	$f(x_0)$				
x_1	$f(x_1)$	$f[x_0, x_1]$			
x_2	$f(x_2)$	$f[x_0, x_2]$	$f[x_0, x_1, x_2]$		
x_3	$f(x_3)$	$f[x_0, x_3]$	$f[x_0, x_1, x_3]$	$f[x_0, x_1, x_2, x_3]$	
x_4	$f(x_4)$	$f[x_0, x_4]$	$f[x_0, x_1, x_4]$	$f[x_0, x_1, x_2, x_4]$	$f[x_0, x_1, x_2, x_3, x_4]$
...	...	...	...	...	...

(2) 分段多项式插值

在多项式插值中，我们了解到利用这 $n+1$ 各插值点去插值 n 次多项式，但是实际上，这样做会有一个问题。即并不是 n 的次数越高，插值就越准确。当插值节点是区间上均匀分布的节点时，会发现当 n 的次数越来越高时，在某些点处会出现震荡的现象，误差严重，这称为龙格现象。这说明，次数的升高并不一定时好的，这就诱导我们去分段地处理插值节点，即分成很多个小区间，在每个小区间上做低次数的插值。当区间划分的足够密时，这样做的精度也是能够保证的，这就叫分段的多项式插值。

总得来说，分段多项式插值有两种情况，一种情况是插值节点就是分段区间的端点，每个区间的插值多项式顺次相连，如下图：




图 5-4：分段多项式插值

这样顺次连接的方式的优点在于最后得到的多项式是连续的，但是有一个致命的问题是，当待插值的函数 f 是间断的，那么这种顺次连接的方式会在间断的地方产生很大的误差。这就引出了另一种插值方式。

那就是插值节点位于分段区间的内部，我们不妨直接设为区间的中点




图 5-5：分段多项式插值的中点

注意这里的 $x_{i-\frac{1}{2}}, x_{i+\frac{1}{2}}$ 只是表示区间端点的一种方法, x_i 才是插值节点。很明显, 这样插值出来的多项式并不连续, 因为只是每个区间单独插值, 并不链接, 但是这种方式能够很好的处理间断点处误差, 并且我们说明, 这两种插值方式在精度上来说相同。

本文我们采用分段三次多项式插值法对数据进行拟合, 在给定 $n+1$ 个点序列, 利用分段三次多项式插值, 使得分段多项式经过所有点序。其中, t_i 必须单调递增, $i = 0, 1, \dots, n$ 。

起点处一阶导数估计:

$$v_0 = \frac{p_1 - p_0}{t_1 - t_0} \quad (38)$$

终点处一阶导数估计:

$$v_n = \frac{p_n - p_{n-1}}{t_n - t_{n-1}} \quad (39)$$

中间点处一阶导数估计:

$$v_k = \frac{d_k + d_{k+1}}{2} \quad (40)$$

其中, $d_k = \frac{p_k - p_{k-1}}{t_k - t_{k-1}}$

设三次多项式为:

$$p(t) = a_0 + a_1(t - t_s) + a_2(t - t_s)^2 + a_3(t - t_s)^3 \quad (41)$$

一阶导数为:

$$p'(t) = a_1 + 2a_2(t - t_s) + 3a_3(t - t_s)^2 \quad (42)$$

对于每一段三次多项式, 利用端点处约束:

$$\begin{cases} p(t_s) = p_s \\ p'(t_s) = v_s \\ p(t_e) = p_e \\ p'(t_e) = v_e \end{cases} \quad (43)$$

容易求得系数:

$$\begin{cases} a_0 = p_s \\ a_1 = v_s \\ a_2 = \frac{[3h - (2v_s + v_e)T]}{T^2} \\ a_3 = \frac{[-2h + (v_s + v_e)T]}{T^3} \end{cases} \quad (44)$$

其中, $h = p_e - p_s, T = t_e - t_s$

(3) 分段三次 Hermite 插值

分段三次 Hermite 插值的目的意义是可以地道在插值区间上光滑的分段插值多项式。

已知 $y_i = f(x_i), m_i = f'(x_i) (i = 0, 1, \dots, n), a = x_0 < x_1 < \dots < x_n = b$ 求一个分段函数 $H(x)$, 使其满足:

$$(1) H(x_i) = y_i, H'(x_i) = m_i (i = 0, 1, \dots, n)$$

(2) 在每个子区间 $[x_i, x_{i+1}]$ 上, $H(x)$ 是次数不超过 3 的多项式。

满足上述 (1)、(2) 条件的函数 $H(x)$ 为分段三次 Hermite 插值多项式。

4. 回归评价指标

回归分析是广泛应用的统计方法, 用于研究自变量与因变量之间的关联。在进行回归分析时, 评估指标起着关键的作用, 它们有助于我们评价模型的拟合程度和预测性能。在本文中, 我们将介绍两个重要的评估指标, 即决定系数 (R 方值) 和均方误差 (MSE), 以帮助我们更全面地理解和评估回归模型的质量。

(1) 决定系数 R^2

R^2 是回归分析中最广泛使用的评估指标之一, 它用于衡量模型对数据的拟合程度, 并表示因变量中可以由自变量解释的部分所占比例。具体而言, R^2 将已被模型解释的方差与总方差相比较, 从而反映了总方差中被模型预测变量所解释或决定的比例。 R^2 的取值范围在 0 到 1 之间, 数值越接近 1 表示模型对数据的拟合越好。然而, 值得注意的是, R^2 也存在一些限制, 例如无法判断模型是否出现过度拟合或不足拟合的问题。

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{MSE}{Var} \quad (45)$$

其中, $\bar{y}$ 是 y 的平均值, $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ 表示真实值于预测值的平方差之和, 类似于均方误差 MSE; $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$ 表示真实值与均值的平方差之和, 类似于方差 Var。

(2) 均方误差 MSE

均方误差 (MSE) 是回归分析中另一个常用的评估指标, 它衡量了预测值与真实值之间的平均差异程度。MSE 的取值范围在 0 到正无穷之间, 数值越接近 0 表示模型的预测值与真实值之间的差异越小。MSE 通常用于评估模型的预测性能, 但需要注意的是, 它对异常值比较敏感。其计算公式如下:

$$MSE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 \quad (46)$$

MSE 提供了一种定量的方式来衡量模型的拟合程度, 更小的 MSE 值通常表示模型的预测效果更好。然而, 当存在异常值时, MSE 可能受到它们的影响, 因此在评估模型时需要谨慎考虑异常值的影响。

5.1.3 问题二 a 题模型的求解

我们的数据集构成如表 5-2 所示:

表 5-2: 问题一(a)数据集

表名	列名
表 1	发病到首次影像检查时间间隔
表 2	首次检查与随访 1/2/3/4/5/6/7/8 检查的 HM_volume
附表 1	入院首次检查时间点、每次随访时间点

为了理解水肿体积随时间的变化趋势, 我们提取出所有随访时点距离发病时的时间间隔, 并绘制散点图:




图 5-6：所有随访时点距离发病时的时间间隔散点图

可以看到，多数数据集中在时间间隔小于 1000 小时内。

1. 回归模型

我们使用线性回归和多项式回归进行拟合，结果如下表所示：

表 5-3：回归模型拟合结果

回归模型	degree	R^2	MSE
线性回归		0.0050	676017.6690
多项式回归	2	0.0100	674231.6549
	3	0.0400	649072.0044
	4	0.1000	613877.4847
	4	0.1100	606804.0481

我们的拟合效果如下图所示：





图 5-7：回归模型拟合效果图


水肿体积随时间变化并不是简单的线性关系，尝试使用非线性回归模型。

下面是多项式回归的结果：


多项式拟合 (degree=2) - R-squared: 0.01



多项式拟合 (degree=3) - R-squared: 0.04



多项式拟合 (degree=4) - R-squared: 0.1






图 5-8: 多项式回归结果图

线性回归和多项式回归都未能获得令人满意的拟合效果，这可能反映了数据本身的复杂性或者其他问题。深入分析模型表现不佳的原因可以帮助我们更好地理解数据和改进建模方法。

如果数据包含复杂的非线性关系，无论是线性回归还是多项式回归都可能难以捕捉这些关系。

多项式回归容易出现过拟合的情况，尤其是当多项式的阶数很高时。过拟合意味着模型在训练数据上表现良好，但在未见过的数据上表现糟糕。

尝试使用高斯模型或数学函数逼近模型是一种应对线性回归和多项式回归效果不佳的替代方法。这些方法的优势在于它们更加灵活，可以更好地拟合复杂的非线性关系。

2. 数学函数逼近

数学函数逼近拟合中的插值方法是一种有效的数据拟合技术，特别适用于连续数据点之间存在缺失值或需要在数据点之间估计未知值的情况。插值的核心思想是根据已知数据点之间的趋势和规律来估计未知位置上的数值。

多项式插值方法使用多项式函数来拟合数据。拉格朗日插值和牛顿插值是常见的多项式插值技术。它们能够精确地通过所有已知数据点，但在高次多项式插值中可能会引入振荡和过拟合问题。

样条插值将数据分段拟合，并使用分段函数来逼近数据。这有助于减少高次多项式带来的振荡问题，并提供更平滑的插值结果。常见的样条插值包括分段线性插值和三次样条插值。

我们分别采用分段多项式插值和分段三次 Hermite 插值，模型结果如下表所示：

表 5-4: 数学函数逼近结果表

数学函数逼近	R^2	MSE
分段多项式插值	0.0756	704133.3285
分段三段 Hermite 插值	0.0865	684667.4767

给出拟合值和真实值之间的对比：




图 5-9：分段多项式插值拟合值和真实值对比图




图 5-10：分段三次 Hermite 插值拟合值和真实值对比图

插值的效果可能会受到数据的复杂性和噪声的干扰。在某些情况下，数据的变化可能非常复杂，不适合通过线性或多项式函数来精确拟合。此外，插值方法通常在已知数据点之间生成平滑的曲线，但可能无法很好地捕捉数据的局部特征或异常值。

3. 高斯模型

采用高斯模型进行数据拟合是一种常见的非线性建模方法，特别适用于数据包含复杂的非线性关系或噪声的情况。与线性回归或插值方法不同，高斯模型可以更灵活地适应数据的特点，并提供更精确的拟合结果。

高斯模型通常基于高斯函数（也称为正态分布函数）来描述数据的分布。该模型的主要思想是通过多个高斯函数的组合来逼近目标数据的分布，每个高斯函数代表了数据中的一个局部模式或成分。这些高斯函数的组合形成了一个复杂的非线性函数，可以更好地拟合非线性数据。

采用高斯模型的好处在于它的非线性表达能力很强，可以拟合各种复杂的数据分布和非线性关系。此外，高斯模型通常对异常值比较鲁棒，不容易受到极端数据点的干扰。因此，当传统的线性模型或插值方法无法满足数据拟合需求时，高斯模型可以成为一个有力的工具。

我们建立的高斯模型为：

$$f(x) = 40074.9163 \frac{e^{-(x-384.834)^2}}{2*(-341.5534)^2} \quad (47)$$

模型的 R^2 为 0.1004，均方误差为 611214.0727。

我们看一下高斯模型对数据集的预测：




图 5-11：高斯模型预测图

4. 模型的预测

最终选择高斯模型进行预测，我们选取第一次的残差作为提交的结果，部分结果展示如下：

表 5-5：残差部分结果图

ID	残差（全体）
Sub001	-27.5011
Sub002	-2.0730
Sub003	-11.2382
Sub004	-0.8784
Sub005	-25.7985
...	...

Sub096	15.3616
Sub097	11.2260
Sub098	-18.4501
Sub099	11.8000
Sub100	13.9106

5.2 问题二 b 题

5.2.1 问题二 b 题分析

为了探索患者水肿体积随时间进展的个体差异，首先我们需要将患者分成不同的亚组。这些亚组可以基于一些潜在的特征或因素来定义，以便更好地理解水肿体积随时间的模式。

首先，我们需要确定将患者分成亚组的依据。这可以基于一些临床特征、疾病史、治疗方案或其他因素来实现。例如，我们可以考虑以下几种可能的依据：

将患者按年龄段划分成不同亚组，例如青年、中年和老年患者。将患者根据疾病严重程度划分成亚组，例如轻度、中度和重度患者。将患者根据接受的治疗方法划分成亚组，例如手术治疗、药物治疗和其他治疗方法。

一旦确定了亚组划分的依据，我们可以针对每个亚组构建水肿体积随时间进展的曲线。这可以通过以下步骤来完成：

Step1: 选择属于每个亚组的患者数据。

Step2: 对于每位患者，根据其重复检查时间点和水肿体积数据，构建水肿体积随时间的曲线。

Step3: 可以选择适当的数学模型（例如高斯模型、多项式拟合或非线性模型）来拟合每个亚组的水肿体积随时间的变化。

在每个亚组的曲线拟合后，我们可以计算前 100 个患者真实水肿体积值与相应曲线预测值之间的残差。残差是实际观测值与模型预测值之间的差异，用于衡量模型对数据的拟合程度。

对于每个亚组，我们可以计算并分析残差的统计性质，例如平均残差、标准差、残差分布等。这些统计信息可以帮助我们了解模型在不同亚组中的表现是否一致，以及是否存在系统性的模型偏差。

通过以上步骤，我们可以深入了解不同患者群体的水肿体积随时间进展的模式，发现个体差异，并评估模型在不同亚组中的性能。

5.2.2 问题二 b 题模型的建立

1. K-means 算法

聚类分析，通常称为聚类，是一种将大规模混合数据对象按照某种标准进行分类和分析的方法。K-means 算法，作为聚类算法中的经典代表之一，具备简单、高速、优秀的聚类效果等优点，因此被广泛认可为卓越的聚类算法之一。该算法将每个类内样本之间的加权均值（称为质心）作为该类的聚类中心，代表了该类的平均特征，具有清晰的几何和统计解释，因此至今仍然是最广泛应用的聚类算法之一。

K-means 算法的核心思想是：首先，将原始数据集中包含 n 个样本的聚类集进行初始化，选择一个聚类数值 K ，并定义相似性度量函数。然后，从数据集中随机选择 K 个样本作为初始聚类中心。接下来，计算每个数据样本到每个聚类中心的距离，将每个样本分配给距离最近的聚类中心，形成初始的聚类集。随后，通过迭代过程，更新聚类中心，重新分配数据样本到聚类集，直到满足终止条件且聚类结果不再发生变化。最后，根据最终得到的聚类集结果，完成整个聚类分析过程。这一过程的

具体流程如下图所示。




图 5-12: K-means 聚类算法流程图

K-means 算法的具体步骤如下：

Step1: 设 $X = \{x_i | x_i \in R^d, i = 1, 2, \dots, n\}$ 为 d 维空间的数据集。 $x_1, x_2, \dots, x_n$ 为 n 个相互独立的样本对象，每个样本都具有 d 个特征。设 $C = \{c_1, c_2, \dots, c_K\}$ 为 K 个聚类中心集合。其中 $c_1, c_2, \dots, c_K$ 为 K 个聚类集的 K 个聚类中心。设 $S_r = \{x_a, x_b, \dots, x_z\}$ ，其中 $r = 1, 2, \dots, K$ ， S_r 表示表示已分配数据的第 r 个聚类集， $x_a, x_b, \dots, x_z$ 表示分配至该聚类集的样本数据。

通常，我们使用欧氏距离来衡量样本对象之间的距离。欧氏距离的计算公式如下：

$$d(x_p, x_j) = \sqrt{(x_p - x_j)^T (x_p - x_j)} \quad (48)$$

其中， $p, j = 1, 2, \dots, n$

从初始种群中随机选取 K 个样本点，将它们作为初始簇的聚类中心。聚类中心的计算公式如下：

$$c_r = \frac{\sum_{x_j \in C_r} x_j}{n_r} \quad (49)$$

Step2: 对于每个样本对象 x_j ，找到与其间距最小的聚类中心 c_r ，将样本对象 x_j 分配到该聚类中心 c_r 对应的族 C_r 中；

Step3: 使用上述公式计算每个簇中样本对象的均值，将其作为新的簇中心点；

Step4: 计算聚类准则函数 SSE:

聚类准则函数为：

$$SSE = \sum_{r=1}^K \sum_{x_j \in C_r} |x_i - c_r|^2 \quad (50)$$

Step5: 重复执行 Step2 至 Step4，直到达到指定的迭代次数 T 或者观察到聚类准

则函数 SSE 不再发生变化为止。

2. 高斯混合模型

高斯混合模型是一种混合模型，其中包含了多个高斯模型的组合。高斯模型采用高斯概率密度函数（也称为正态分布曲线）来精确地描述事物的特性，将事物分解为多个基于高斯概率密度函数的模型。这些模型的组合形成了高斯混合模型，用以更全面地表示事物的概率分布特性。

假设混合高斯模型由 k 个高斯模型组成（即数据包含 k 个类），则 GMM 的概率密度函数如下：

$$p(x) = \sum_{k=1}^K p(k)p(x|k) = \sum_{k=1}^K \Pi_k N(x|\mu_k, \Sigma_k) \quad (51)$$

$$p(x|k) = N(x|\mu_k, \Sigma_k) \quad (52)$$

上式是第 k 个高斯模型的概率密度函数，可以看成选定第 k 个模型后，该模型产生 x 的概率：

$$\sum_{k=1}^K \Pi_k = 1 \quad (53)$$

因此，混合高斯模型并不具备什么新颖之处，其核心思想是将多个单一高斯模型融合在一起，以增加模型的复杂性，从而生成更多样化的样本。从理论上讲，如果混合高斯模型融合的高斯模型数量足够多，它们的权重设置得合理，那么这个混合模型可以用来拟合任何概率分布的样本数据。

下面是一维高斯混合模型图的示例：




图 5-13：一维高斯混合模型

3. 模糊 C 均值聚类

模糊 C 均值聚类算法（FCM）是一种基于划分的聚类方法，它融合了模糊理论的思想。首先，让我们来了解一下模糊集和隶属度函数的概念。在研究范围内的元素集合 U 中，对于每个元素 x ，都存在一个介于 $[0,1]$ 之间的数值 $A(x)$ ，这个数值定义了元素 x 对于模糊集 A 的隶属度。在 FCM 聚类算法中，这些隶属度值用于表示每个样本点在不同聚类簇中的隶属度程度。

在聚类过程中，我们将生成的聚类簇视为一个模糊集合 A ，并为每个样本点 x

计算其隶属度 $A(x)$ 。通过比较隶属度值的大小，我们可以将样本点划分到不同的聚类中。这些隶属度值可以被看作是一种权重，用于衡量每个样本点与不同聚类中心的隶属程度。当隶属度值接近 1 时，表示样本点 x 更有可能属于模糊集 A 中的某一类。

FCM 聚类通过隶属度加权解决了由于硬划分带来的分类误差，因此称为软划分的聚类算法。该算法将经过归一化处理的数据集，划分为 c 类，不断的更新聚类中心 v 和计算从属于某个群的隶属度矩阵 $U = [u_{ij}]$ ，其中 u_{ij} 表示样本数据的隶属度。归一化处理后，数据集的隶属度之和为 1，且隶属度的值大于 0 小于 1，即 u_{ij} 的约束是：

$$\forall j, \sum_{i=1}^c u_{ij} = 1 \quad (54)$$

$$\forall i, \sum_{j=1}^n \mu_{ij} > 0 \quad (55)$$

其中， $\forall i, j \mu_{ij} \in [0, 1]$

价值函数是：

$$J_m = \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m d_{ij}^2 \quad (56)$$

其中 $d_{ij} = \|x_j - v_i\|$ 为样本 x_j 与聚类中心 v_i 之间的欧氏距离； n 为负荷曲线数量， m 为模糊指数， m 越大，模糊程度就越高。

CM 聚类思想与 K-means 算法相似，在数据集上不断计算迭代中心点 v 和隶属度 u 的过程，直至迭代结果达到比较优的状态。为了使价值函数的值达到最小，各中心点和隶属度的计算公式如下：

$$u_{ij} = \frac{1}{\sum_{r=1}^c \left(\frac{d_{ij}}{d_{rj}} \right)^{\frac{2}{m-1}}} \quad (57)$$

$$v_i = \frac{\sum_{j=1}^n u_{ij}^m x_j}{\sum_{j=1}^n u_{ij}^m} \quad (58)$$

FCM 聚类算法的步骤如下图所示：




图 5-14: FCM 聚类步骤

FCM 聚类算法的关键在于选取中心点以及确定隶属度的权重。与传统的硬聚类方法相比，FCM 聚类具有一定的优势，因为它能够提供更可靠的分类结果，相对于硬划分聚类方法（如 K-means 算法）。然而，当处理大规模数据集和高维特征时，FCM 算法的计算效率相对较低。

5.2.3 问题二 b 题模型的求解

为了更好地探索患者水肿体积随时间变化的个体差异，首先需要理解数据集的结构和内容。我们数据集的构造如下表所示：

表 5-6: 问题二(b)数据集

表名	列名
表 1	发病到首次影像检查时间间隔
表 2	首次检查与随访 1/2/3/4/5/6/7/8 检查的 HM_volume
附表 1	入院首次检查时间点、每次随访时间点

基于这个数据集，我们的目标是探索不同患者之间水肿体积随时间变化的个体差异，并构建不同人群的水肿体积随时间进展曲线。

1. K 均值聚类

使用 K 均值聚类算法将患者分成 3-5 个不同的亚组。每个亚组代表了一种水肿体积随时间进展的模式。

肘部法则是一种用于确定 K 均值聚类中最佳聚类数 K 的一种常用方法。它的基本思想是随着聚类数 K 的增加，样本划分会更精细，每个簇的聚合度逐渐提高，因此每个簇的平均畸变程度（簇内的数据点与簇中心的距离平方和，也叫簇内平方和）逐渐减小。但当 K 达到真实聚类数时，增加 K 将不会显著提高每个簇的聚合度，因此簇内平方和的下降幅度会减小，这一点在图形上会呈现出肘部的形状。

通常，选择肘部法则所示的“肘点”对应的 K 值作为最佳的聚类数。这个 K 值在该点之后，簇内平方和的下降幅度不再明显，即不再呈现明显的肘部弯曲。




图 5-15: 肘部法则图

根据肘部法则，我们可以选择的最佳聚类数为 3。我们给出聚类的可视化图：




图 5-16: 聚类可视化

这三个聚类的依据主要是基于患者的特征和历史疾病史：

Cluster 1 这个簇的患者，具有较长的发病到检查时间。水肿体积的波动较大，包括一些较大的水肿体积。大多数患者有高血压病史和吸烟史。少数患者有卒中病史和糖尿病史。

Cluster 2 这个簇的患者，较短的发病到检查时间，相对于 **Cluster 1** 较短。水肿体积的波动仍然较大，但整体水肿体积较高。大多数患者有高血压病史。没有患者有吸烟史，并且没有房颤史和饮酒史。

Cluster 3 这个簇的患者，非常长的发病到检查时间，相对于 **Cluster 1** 和 **Cluster 2** 最长。水肿体积的波动非常大，包括一些较大的水肿体积。大多数患者有高血压病史。少数患者有卒中病史和糖尿病史。

这些聚类是根据不同患者的发病时间、水肿体积以及高血压、卒中、糖尿病等疾病史的组合来划分的，每个簇代表了一组具有相似特点的患者。

我们用依旧用高斯模型对三个亚组进行拟合，模型的 R^2 如下表所示：

表 5-7: 高斯模型拟合亚组结果表

亚组	R^2
亚组 1	0.2156
亚组 2	0.1211
亚组 3	0.0435

三个亚组的拟合效果如下图所示：




图 5-17：高斯模型拟合亚组 1 效果图




图 5-18：高斯模型拟合亚组 2 效果图




图 5-19：高斯模型拟合亚组 3 效果图

2. FCM 聚类

模糊 C 均值（FCM）聚类是一种在聚类分析中常用的方法，相对于传统的 K 均值聚类具有一些优势。在 FCM 中，每个数据点不再被分配到一个确定的簇，而是分配一个隶属度值，表示其属于每个簇的概率。这使得 FCM 在某些情况下比 K 均值更加灵活和强大。

FCM 允许数据点同时属于多个簇，而不像 K 均值那样要求每个数据点只属于一个簇。这对于一些模糊或不明显的聚类问题非常有帮助。

FCM 对噪声和异常值的影响较小，因为它考虑了数据点与每个簇的隶属度，而不是直接将其分配给一个簇。FCM 允许通过调整模糊度参数来控制簇的模糊性。通过调整这个参数，可以在精确性和模糊性之间进行平衡，以满足不同应用的需求。

FCM 聚类在处理模糊性较强、复杂数据结构或需要更灵活隶属度分配的问题时，通常优于传统的 K 均值聚类方法。

下表展示了 FCM 聚类三个亚组后的分布情况：




图 5-20：FCM 聚类三个亚组的分布图

Cluster 1 这个簇包含了 266 名患者。这些患者在发病后的平均时间内进行了影像

检查，平均时间为 191.63 小时。这个簇中的患者几乎都有高血压病史（86.47%），但没有卒中病史、糖尿病史、房颤史或冠心病史。这个簇的吸烟史和饮酒史都很低。

Cluster 2 这个簇包含了 100 名患者。这些患者在发病后的平均时间内进行了影像检查，平均时间为 301.79 小时。这个簇中的患者几乎都有高血压病史（92%），大多数有卒中病史（72%），有少数患者有糖尿病史（33%）。这个簇的患者没有房颤史，吸烟史和饮酒史。

Cluster 3 这个簇包含了 84 名患者。这些患者在发病后的平均时间内进行了影像检查，平均时间为 376.12 小时。这个簇中的患者几乎都有高血压病史（96.43%），有少数患者有卒中病史（9.52%）和糖尿病史（14.29%）。这个簇的患者没有房颤史，吸烟史，但有一些患者有饮酒史（69.05%）。

这三个簇的区别主要在于患者的病史和发病到检查时间。Cluster 1 中的患者发病到检查时间较短，几乎都有高血压病史，但其他疾病史较低。Cluster 2 中的患者发病到检查时间较长，几乎都有高血压病史，同时有较高的卒中病史，但其他疾病史较低。Cluster 3 中的患者也有高血压病史，发病到检查时间较长，但相对较多的患者有糖尿病史，同时有较高的饮酒史。

我们对三个亚类进行拟合，模型的 R^2 如表 5-8 所示：

表 5-8: FCM 拟合亚组结果表

亚组	R^2
亚组 1	0.1303
亚组 2	0.0056
亚组 3	0.2005

拟合效果如下图所示：




图 5-21: FCM 拟合亚组 1 效果图




图 5-22: FCM 拟合亚组 2 效果图




图 5-23: FCM 拟合亚组 3 效果图

通过对比，我们 FCM 聚类比 K 均值聚类效果好一点。我们选择 FCM 聚类作为我们接下来的预测模型。

3. 模型预测

我们预测的部分结果如表 5-9 所示：

表 5-9: 模型预测部分结果表

ID	残差（亚组）	所属亚组
Sub001	-24.0279	1
Sub002	1.4126	1
Sub003	-7.7773	1
Sub004	-4.0361	0
Sub005	-22.2634	1
...	...	...
Sub096	18.7979	1

Sub097	14.7116	1
Sub098	-21.7103	0
Sub099	15.2856	1
Sub100	7.2015	2

5.3 问题二 c 题

5.3.1 问题二 c 题分析

分析不同治疗方法对水肿体积进展模式的影响需要进行深入的数据分析和建模。首先，需要从数据集中提取相关的字段，包括治疗方法和水肿体积的变化情况。确保数据的质量，包括处理缺失值和异常值。进行特征工程以提取或转换数据特征，以便于分析。这可以包括对治疗方法进行编码，以便于模型使用。

使用合适的机器学习或统计模型来研究治疗方法对水肿体积进展的影响。在这里，我们可以选择一个合适的回归模型，如决策树回归或随机森林回归。

一旦模型建立好，我们可以使用置换重要性技术来评估不同特征对模型预测的影响程度。这种技术的基本思想是，随机地对某个特征进行置换（打乱其与目标的关系），然后观察模型性能的变化。

首先，记录原始模型在测试数据上的性能，通常使用均方误差或其他适当的性能指标。接下来对于每个治疗方法特征，将其置换并重新评估模型性能。计算置换后的性能指标。

将原始性能与置换后的性能进行比较。如果某个治疗方法特征对模型性能有显著影响，那么在置换后的性能将下降，导致更差的模型拟合。

根据不同治疗方法特征的性能差异，我们可以量化它们对水肿体积进展的影响。置换后性能下降的特征对水肿体积的影响较大，而性能变化不大的特征可能对水肿体积的进展影响较小。

将分析结果清晰地报告，包括哪些治疗方法特征对水肿体积进展有显著影响，它们的置换重要性值，以及可能的原因或解释。

5.3.2 问题二 c 题模型的建立

置换重要性是一种用于评估特征重要性的方法，它基于模型的预测结果。该方法的核心思想是随机打乱单个特征的值，从而破坏特征与标签之间的关系，然后观察模型准确度对于特征变化的敏感程度，最终得出特征的重要性排序。通常，这种方法在处理数据规模较小、特征较少的情况下表现出色。它特别适用于低维数据集或者需要快速分析特征重要性的场景，因为它具有高效的特点。

在机器学习领域，了解哪些特征对模型性能的影响至关重要。Permutation Importance 是一种计算特征重要性的技术，它提供了一种相对简单且直观的方式，用于评估特征对模型性能的贡献程度。这个方法帮助我们确定哪些特征对于模型的预测能力具有关键作用。

Permutation Importance 的核心概念是通过特征进行随机排列并观察模型性能的变化，来评估特征的重要性。其基本思想是，如果某个特征对模型的预测性能具有重要影响，那么将该特征的值进行随机排列会显著降低模型的准确性。这个方法的关键在于通过比较模型在原始数据和随机排列后的数据上的性能差异来量化特征的重要性。

下表是 Permutation Importance 如何实现的伪代码：

算法： permutation importance algorithm

输入： 拟合的预测模型 m ，表格数据集(训练或验证) D

计算模型 m 在数据集 D 上的参考分数 s （例如分类器的准确度或回归器的 R^2 分数）

- 1 对于数据集 D 中的每个特征 j （即 D 的每一列）
- 2 foreach $k \in K$:
- 3 随机打乱数据集 D 的第 j 列，生成一个被破坏的数据版本，命名为 D_{kj}
- 4 计算模型 m 在损坏的数据 D_{kj} 上的分数 $s_{k,j}$
- 5 计算特征 f_j 的重要性 i_j ，定义如下：

$$i_j = s - \frac{1}{K} \sum_{k=1}^K s_{k,j}$$

5.3.3 问题二 c 题模型的求解

使用置换重要性（Permutation Importance）来评估每个特征对机器学习模型性能的影响程度。

首先将数据集划分为训练集和测试集，其中训练集用于建立机器学习模型，而测试集用于评估模型性能。建立了一个随机森林回归模型，该模型用于预测目标变量。使用模型对测试集进行预测，并使用决定系数来度量模型在测试数据上的性能，得到原始性能指标。对每个特征进行循环遍历。在每次迭代中，对当前特征进行置换，即随机打乱该特征的值。然后使用置换后的数据集来重新预测目标变量，并计算置换后的性能。特征的重要性通过比较原始性能和置换性能之间的差异来计算。如果置换特征后性能下降较大，说明该特征对模型性能具有较高的重要性。

最后，将特征按照其对性能的影响程度进行排序，并通过水平条形图可视化展示。这使我们可以直观地了解哪些特征最重要，哪些不太重要。

置换重要性结果如下表所示：

表 5-10：置换重要性结果表

Feature	Permutation Importance Score
脑室引流	0.0432
止血治疗	0.0032
降颅压治疗	0.2813
降压治疗	-0.0060
镇静、镇痛治疗	0.1297
止吐护胃	0.0050
营养神经	0.0146

可视化展示如下图所示：




图 5-24: 可视化展示图

脑室引流对模型性能有一定的正面影响。这可能意味着在脑部水肿治疗中，使用脑室引流可能对水肿体积的进展起到一定的控制作用。

止血治疗特征的置换重要性得分较低，接近于 0，说明在模型性能方面对止血治疗的特征不太敏感。这可能表示止血治疗与水肿体积的进展之间关联不强。

降颅压治疗在模型中的置换重要性得分相对较高，为 0.2813，表明这个特征对模型性能具有显著的正面影响。这可能表示降颅压治疗在控制水肿体积方面起到了重要的作用。

降压治疗的置换重要性得分接近于 0，甚至稍微为负，说明在模型性能方面对降压治疗的特征不太敏感。这可能表示降压治疗与水肿体积的进展之间的关系相对较弱。

镇静、镇痛治疗这个特征的置换重要性得分为 0.1297，表明镇静、镇痛治疗对模型性能有一定的正面影响。这可能意味着在镇痛和镇静方面采取的治疗措施可能对水肿体积的进展产生积极影响。

止吐护胃特征的置换重要性得分接近于 0，表明在模型性能方面对止吐护胃的特征不太敏感。这可能表示止吐护胃治疗与水肿体积的进展关系较弱。

营养神经特征的置换重要性得分为 0.0146，说明这个特征对模型性能有一定的正面影响，尽管影响较小。这可能表示在提供营养支持方面的治疗可能对水肿体积的进展有轻微影响。

5.4 问题二 d 题

5.4.1 问题二 d 题分析

分析血肿体积、水肿体积以及治疗方法之间的关系是一项重要的任务，它可以帮助我们理解不同因素对于患者健康状况的影响以及潜在的治疗策略。

我们构建所需的数据集，如表 5-11 所示：

表 5-11: 问题二(d)数据集

表名	列名
表 1	脑室引流、...、营养神经、发病到首次影像检查时间间隔
附表 1	入院首次检查时间点、每次随访时间点
表 2	首次检查与每次随访检查的 HM_volume、ED_volume

我们首先关注血肿体积与水肿体积之间的关系。可以使用统计方法来探究血肿体积与水肿体积之间的关系。我们可以拟合一个方程，该方程可以描述血肿体积和水肿体积之间的关系。拟合方程可以帮助我们理解这两个变量之间的相关性。

接下来我们探究不同治疗方法对血肿体积和水肿体积的影响。可以执行方差分析和相关分析来分析不同治疗方法对血肿体积和水肿体积的影响。这将帮助我们确定不同治疗方法是否显著影响了这两个因变量。

最后，我们可以使用置换重要性分析。这种分析可以用于确定不同变量对结果的影响程度。我们可以使用随机置换或其他方法来估计不同治疗方法对血肿体积和水肿体积的重要性。这可以帮助我们识别哪些治疗方法对于改善患者病情最为关键。

总之，通过这些分析方法，可以更全面地了解血肿体积、水肿体积和不同治疗方法之间的关系，以指导医疗决策和治疗选择。

5.4.2 问题二 d 题模型的建立

方差分析是一种用于评估两个或多个样本均值之间是否存在显著差异的统计方法。根据比较的因素数量不同，方差分析可以分为以下三种类型：单因素方差分析、

双因素方差分析和多因素方差分析。

设单因素 A 具有 r 个水平，记为 $A_1, A_2, \dots, A_r$ ，在每个水平 $A_i (i=1, 2, \dots, r)$ 下，对于 r 个总体，假设：

- (1) 每个总体均服从正态分布，即 $X_i \sim N(\mu_i, \sigma^2), i=1, 2, \dots, r$ ；
- (2) 每个总体的方差 σ^2 相同；
- (3) 从每个总体中抽取的样本 $X_{i1}, X_{i2}, \dots, X_{in_i}$ 相互独立， $i=1, 2, \dots, r$ 。

那么，若要比 较各个总体的均值是否一致，就需要检验各个总体的均值是否相等。设第 i 个总体的均值 μ_i ，则原假设为 $H_0: \mu_1 = \mu_2 = \dots = \mu_r$ ，备择假设为

$H_1: \mu_1, \mu_2, \dots, \mu_r$ 不全相等。

总变异：

$$SST = \sum_{i=1}^m \sum_{j=1}^{n_i} (x_{ij} - \mu)^2 \quad (59)$$

组间变异：

$$SSA = \sum_{i=1}^m n_i (\mu_i - \mu)^2 \quad (60)$$

组内变异：

$$SSE = \sum_{i=1}^m \sum_{j=1}^{n_i} (x_{ij} - \mu_i)^2 \quad (61)$$

表 5-12 方差分析基本理论

名称	解释	包含误差来源	表示形式
组内误差平方和	样本内部数据的离散程度	随机误差	SSE
组间误差平方和	不同样本之间数据的离散程度	随机、系统误差	SSA
总误差平方和	全部数据误差大小	随机、系统误差	SST

5.4.3 问题二 d 题模型的求解

首先，我们可以进行相关性分析，计算血肿体积、水肿体积和治疗方法之间的相关系数。这可以告诉我们它们之间是否存在关联，以及关联的强度和方向（正相关或负相关）。




图 5-24: 血肿体积、水肿体积和治疗方法之间的相关系数热力图

ED_volume 和 HM_volume 之间的相关系数为 0.290873，表明它们之间存在一定程度的正相关关系，但相关性不是非常强。治疗方法与 ED_volume 和 HM_volume 之间的相关系数都比较低，表明它们之间的相关性较弱。各种治疗方法对 ED_volume 和 HM_volume 的影响似乎不是很明显。

相关系数仅能表明变量之间的线性相关性，可能存在其他非线性的关系未被考虑。此外，相关性并不等同于因果关系。相关性只是描述变量之间的关系，不能用来确定一个变量是否导致另一个变量的变化。

探究 ED_volume 和 HM_volume 之间的关系，首先绘制散点图如下所示：




图 5-25: ED_volume 与 HM_volume 的散点图

可以看到，两者之间存在某种关系，我们尝试对其进行拟合，普通的回归模型拟合效果都不太好，如下表所示：

表 5-13: 回归模型拟合结果表

回归模型	degree	R^2
线性回归		0.0846
多项式回归	2	0.1643
	3	0.1749
	4	0.1814
幂函数回归		0.1567

本题的数据集中，变量之间的关系可能是非线性的，所以一般的回归模型很难把握，拟合的效果较差。而高斯混合分布在处理具有复杂分布、多模态性、异常值和非线性关系等方面具有明显的优势，包括多个高斯组件，每个组件可以描述不同的数据分布形式，从而更好地拟合非线性数据。

我们使用高斯混合分布拟合，效果如下所示：




图 5-26: 高斯混合分布拟合效果图

此时模型的 R^2 为 0.2020，效果较好。

接下来我们探究不同治疗方法对血肿体积和水肿体积的影响，对其进行方差分析，得到的结果如表 5-14 所示：

表 5-14: 不同治疗方法方差分析表

治疗方法	F 统计量	p 值	是否显著
脑室引流	6.8867	0.0116	显著
止血治疗	4.4628	0.0350	显著
降颅压治疗	3.9564	0.0471	显著
降压治疗	3.7387	0.0535	不显著
镇静、镇痛治疗	3.9562	0.0471	显著
止吐护胃	4.4243	0.0357	显著
营养神经	4.8833	0.0274	显著

从 F-统计量和 p-值来看，不同治疗方法对血肿体积和水肿体积的影响存在显著性差异。具体来说，p-值小于通常的显著性水平（通常为 0.05），这表明至少有一种治疗方法对因变量的影响是显著的。

Permutation Importance 有助于识别哪些特征对模型性能最重要。这可以用于特征选择，帮助决策者在建模过程中选择最重要的特征。它还有助于解释模型，因为它提供了关于每个特征对预测的贡献的信息。

不同治疗方法对血肿体积和水肿体积 Permutation Importance 如下图所示：




图 5-27: 不同治疗方法 Permutation Importance 图

综合而言, 根据 Permutation Importance 的分析结果, 降颅压治疗对模型性能有较大的正向影响, 而脑室引流也对模型性能有正向影响, 其他特征对模型性能的影响相对较小或不显著。这表明, 脑室引流和降颅压治疗在模型中似乎是一个重要的特征, 对预测目标血肿体积和水肿体积有积极的贡献。

6. 问题三：出血性脑卒中预后预测与关键因素研究

6.1 问题三 a 题

6.1.1 问题三 a 题分析

根据前 100 位患者的个人史、疾病史、发病相关信息以及首次影像检查的结果, 我们的任务是构建一个预测模型, 用于预测剩余 60 位患者在接下来的 90 天内的 mRS 评分 (康复程度)。这个模型将有助于医疗团队更好地了解患者的康复前景, 并采取相应的治疗和康复措施。

首先, 需要收集与个人史、疾病史、发病相关信息以及首次影像结果相关的数据。这包括患者的基本信息 (如年龄、性别)、疾病史 (如高血压病史、卒中病史、糖尿病史等)、发病相关信息, 以及首次影像检查的相关特征, 在提供的数据集中。

对于收集到的数据, 我们需要进行数据清洗和预处理, 包括处理缺失值、异常值和数据类型转换。还需要对分类变量进行编码, 以便用于建模。

鉴于数据中可能包含大量特征, 需要进行特征选择, 以确定哪些特征对 90 天 mRS 评分的预测最为重要。可以使用统计方法、特征重要性分析、相关性分析等方法进行特征选择。

根据问题的性质, 可以选择不同类型的预测模型。这可以是回归模型, 对 90 天 mRS 评分的七个值进行回归。问题也可以是分类问题, 将 90 天 mRS 评分的七个值作为七个类别, 使得模型对其进行单标签多分类问题。还可以考虑将其转换成多标签的分类问题。

接下来使用训练集来训练选择的模型, 并使用测试集来评估模型的性能。如果是回归问题, 评估指标可以包括均方误差 (MSE)、R 平方、均方根误差 (RMSE) 等, 以确定模型的预测准确性。如果是多标签分类, 精确度在不平衡的多标签分类问题中可能不是一个很好的指标, 因为模型可能倾向于预测常见的标签。所以可以考虑使用 Hamming Loss、Jaccard Similarity、F1-Score 和平均准确度。如果是多分类模型, 评价指标可以选择准确度、混淆矩阵、精确度、召回率、F1-Score 和多分类 Log Loss (Logarithmic Loss)。

对模型评估后, 如果模型性能不满足要求, 可以考虑模型的参数调整和优化,

以提高预测性能。

最终，我们需要解释构建的预测模型，了解哪些因素对于 90 天 mRS 评分的预测最为关键。这有助于理解患者康复的关键影响因素。




图 6-1: 问题三(a)流程图




图 6-2: 评估指标的选择

6.1.2 问题三 a 题模型的建立

1. 数据集的构建

我们的数据集分别来自表 1、表 2 和表 3，具体选择的特征如下表所示：

表 6-1: 问题 3a 的数据集构建

表名	列名
表 1	90 天 mRS、年龄、...、营养神经
表 2	首次检查的 HM_volume、...、ED_Cerebellum_L_Ratio
表 3	original_shape_Elongation、...、NCCT_original_firstorder_Variance

2. 回归模型

(1) 决策树回归

决策树是一种基础的分类和回归方法，本文着重介绍了其回归部分，特别是关于 CART 算法。回归决策树采用二叉树结构，其中内部节点的特征值判定为“是”或“否”。

回归的本质在于根据特征向量来预测相应的输出值。回归树将特征空间划分成多个单元，每个划分单元对应一个特定的输出值。由于每个节点只进行二元判定，所以划分的边界与坐标轴平行。对于测试数据，我们只需根据其特征将其分配到相应的单元，即可获得对应的输出值。

决策树回归算法通过构建决策树进行回归预测。在创建回归树时，我们使用最小剩余方差来确定最佳划分，该判定准则旨在最小化划分后子树的误差方差。此外，

还可以创建模型树，其中每个叶节点都表示一个机器学习模型，如线性回归模型。这种方法有助于更精准地拟合数据并提高回归模型的性能。

设 X 为输入变量， Y 为输出变量，且 Y 是一个连续变量。考虑给定的训练数据集如公式 (62) 所示：

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\} \quad (62)$$

其中， $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})$ 为输入实例即特征向量， n 为特征个数， $i = 1, 2, \dots, N$ ， N 为样本容量。

决策树回归过程的伪算法如下所示：

算法：最小二乘回归树生成算法

输入：训练数据集 D

输出：回归树 $f(x)$

在训练数据集所在的输入空间中，递归地将每个区域划分为两个子区域并决定每个子区域上的输出值，构建二叉决策树：

(1) 选择最优切分变量 j 与切分点 s ，求解

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right]$$

遍历变量 j ，对固定的切分变量 j 扫描切分点 s ，求出最小值

(2) 用选定的对 (j, s) 划分区域并决定相应的输出值：

$$R_1(j, s) = \{x | x^{(j)} \leq s\}, R_2(j, s) = \{x | x^{(j)} > s\}$$

$$\hat{c}_m = \frac{1}{N_m} \sum_{x_i \in R_m(j,s)} y_i, x \in R_m, m = 1, 2$$

(3) 继续对两个子区域调用步骤 (1)，(2)，直至满足停止条件

(4) 将输入空间划分为 M 个区域 $R_1, R_2, \dots, R_M$ ，生成决策树：

$$f(x) = \sum_{m=1}^M \hat{c}_m I(x \in R_m)$$

(2) 随机森林回归

随机森林回归模型的构建包括三个主要步骤：

Step1: 从原始数据集中以无权重且可重复抽样的方式，为每棵决策树生成独立的训练集。

Step2: 使用每个独立的训练集构建一棵决策树，注意在构建决策树的过程中不需要进行剪枝操作。

Step3: 随机森林由多棵这样的决策树组成，最终的预测结果是所有决策树预测值的平均值。

下图展示了随机森林回归模型的构建过程：




图 6-3: 随机森林回归模型构建过程

这种集成方法能够提高模型的鲁棒性和泛化性能，使得随机森林成为一种强大的回归模型。

(3) XGBoost 回归

XGBoost 是一种机器学习算法，可用于回归、分类和排序任务。它被视为 GBDT 的高效实现之一，可以在处理大规模数据集时表现出色，并展现出出色的泛化性能。XGBoost 是一种提升树模型，这意味着它将多个树模型集成在一起，形成一个强大的分类器。在 XGBoost 中，所使用的树模型通常是 CART 回归树模型。

该算法的核心思想是持续添加决策树，通过不断进行特征分裂来逐渐构建一颗树。每次增加一棵树，实际上是学习一个新的函数，以更好地拟合上一轮预测中的误差残差。一旦我们完成了训练并拥有了 k 棵树，对于要预测的一个样本，实际上是根据其特征在每棵树中找到相应的叶子节点，每个叶子节点都有一个分数，最后只需将每棵树的分数相加，得到该样本的最终预测值。

XGBoost 目标函数定义如公式 (63) 所示：

$$Obj = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (63)$$

上述目标函数由两部分构成，目标函数第一项表示整个强学习器的损失函数，第二项表示强学习器中 K 个弱学习器的复杂度。

以下是使用 XGBoost 进行回归预测的一般步骤概述：

Step1: 准备数据集，分成训练集和测试集，以便评估模型的泛化性能。

Step2: 预处理数据，包括填充缺失值和标准化数据等。

Step3: 定义 XGBoost 回归模型，根据问题的性质调整模型参数。

Step4: 用训练数据训练模型，然后使用测试数据评估模型性能，通常使用均方误差 (MSE) 或均方根误差 (RMSE) 来评估。

Step5: 根据模型性能和需求进行模型调整和优化，可以调整参数或增加特征等。

Step6: 使用优化后的模型进行实际预测。

3. 单标签多分类问题

单标签多分类问题指的是在预测过程中，每个样本只涉及一个标签，但标签可以具有多个不同的取值，也就是说每个实例可能属于多个类别中的一个 $(t_1, t_2, \dots, t_k, \text{其中 } k \geq 3)$ 。常见的处理这类问题的算法包括 Softmax 回归、K 最近邻 (KNN)、决策树等。具体定义如公式 (64) — 公式 (66) 所示：

$$y = f(x), y \in \{t_1, t_2, \dots, t_k\} \quad (64)$$

$$h_\theta(x) = \begin{bmatrix} p(y^{(i)}=1|x^{(i)};\theta) \\ p(y^{(i)}=2|x^{(i)};\theta) \\ \dots \\ p(y^{(i)}=k|x^{(i)};\theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x^{(i)}}} \begin{bmatrix} e^{\theta_1^T x} \\ e^{\theta_2^T x} \\ \dots \\ e^{\theta_k^T x} \end{bmatrix} \Rightarrow \theta = \begin{bmatrix} \theta_{11} & \theta_{12} & \dots & \theta_{1n} \\ \theta_{21} & \theta_{22} & \dots & \theta_{2n} \\ \dots & \dots & \dots & \dots \\ \theta_{k1} & \theta_{k2} & \dots & \theta_{kn} \end{bmatrix} \quad (65)$$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^k I(y^{(i)} = j) \log \left(\frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^k e^{\theta_l^T x^{(i)}}} \right), I(y^{(i)} = j) = \begin{cases} 1, y^{(i)} = j \\ 0, y^{(i)} \neq j \end{cases} \quad (66)$$

鉴于本文涉及多分类问题，我们可以将其视作多个二分类任务的组合，将多分类任务分解为一系列二分类问题来解决。具体而言，我们可以采用 One-Versus-Rest (OvR) 方法，这种方法将每个类别与其余类别分开，以便更有效地解决多分类问题。

One-Versus-Rest (OvR) 方法，也称为 “One-vs-All” 算法，是一种有效地将给定的二分类算法扩展到多分类问题的技术。OvR 是一个估计器 (Estimator)。它通过使用 k 个基础的二分类分类器，针对每个类别创建一个独立的二分类问题。每个二分类分类器被训练用于预测一个类别是否属于某个特定的类别，即将这个类别与其他所有类别区分开来。最后，通过对 k 个二分类分类器逐一评估，选择具有最高置信度的分类器的标签作为样本的类别标签。这种方式能够有效地解决多分类问题，提高了分类的准确性和可靠性。




图 6-4: OVR 原理流程图

假设我们的数据集有四个类别，分别为 C_1 、 C_2 、 C_3 、 C_4 。我们利用 OVR 模型，第一次将 C_1 分为一类， C_2 、 C_3 、 C_4 分为一类，得到模型 f_1 ；第二次将 C_2 分为一类， C_1 、 C_3 、 C_4 分为一类，得到模型 f_2 ；第三次将 C_3 分为一类， C_2 、 C_1 、 C_4 分为一类，得到模型 f_3 ；第四次将 C_4 分为一类， C_2 、 C_3 、 C_1 分为一类，得到模型 f_4 。其中模型 f_1 的预测结果为正，模型 f_2 、 f_3 、 f_4 的预测结果为负，最终我们选择预测结果为正例

的模型为 C_1 。




图 6-5 算法构建过程

6.1.3 问题三 a 题模型的求解

1. 数据预处理

进行模型的预处理是非常重要的步骤，它可以帮助提高模型的性能和稳定性。经过数据集的检查，我们发现数据集中没有任何缺失值，数据完整性得到了保持。

在异常值检查方面，我们首先对数据列进行了正态性分布的检查。对于符合正态分布的数据列，我们采用了 3σ 原则进行异常值检测。而对于不符合正态分布的数据列，我们使用了箱型图来识别异常值。值得注意的是，经过这些异常值检测方法，我们发现数据中存在的异常点都具有实际意义和解释性，与问题背景相关。因此，我们决定不对这些异常点进行处理，以保持数据的完整性和准确性。这个决策是基于严谨的逻辑和问题的实际情况做出的。

在数据编码方面，我们采用了分箱和顺序编码的方法来处理两个特征，即“年龄”和“性别”。首先，对于“年龄”特征，我们将其分为几个有意义的区间，分别是 $(20,40]$ 、 $(40,60]$ 、 $(60,80]$ 、 $(80,100]$ ，然后将这些区间进行顺序编码，以便模型能够更好地理解和利用这一信息。这种编码方式的好处在于它可以将连续的“年龄”数据转化为离散的有序类别，有助于模型捕捉到“年龄”对预测结果的潜在影响，同时减少了数据的复杂性。

对于“性别”特征，我们采用了 0 表示男性，1 表示女性的编码方式。这种二元编码方式简洁明了，易于理解，同时也符合性别的二元分类特性。

这种数据编码的好处在于它能够提供更清晰的输入信息，有助于模型更准确地预测结果。此外，它还能够降低数据的维度，减少模型的复杂性和计算成本。总的来说，这种编码方式有助于提高模型的性能和可解释性，使得模型在处理年龄和性别等特征时更具有可操作性。

我们对连续性数值变量进行了标准化处理。这样做的好处在于它消除了不同数值变量之间的量纲差异，使得它们具有相同的尺度。这有助于模型更好地理解 and 比较不同变量之间的关系，同时减少了模型对某些特征的偏好。

2. 特征选择

当进行特征选择时，我们的目标是从原始特征集中选择出最相关和最具信息量的特征，以提高模型的性能和泛化能力。特征选择有助于减少特征空间的维度，降低模型的复杂性，并防止过拟合。通过选择最重要的特征，我们可以提高模型的效率，减少训练时间，并且更容易解释和理解模型的结果。

我们选择随机森林进行特征选择，选择前 80% 的特征，部分结果如下表所示：

表 6-2: 随机森林选择的前 80%特征

Feature	Importance
NCCT_original_firstorder_Entropy	0.0304
HM_PCA_R_Ratio	0.0283
NCCT_original_firstorder_Uniformity	0.0271
HM_volume	0.0246
NCCT_original_firstorder_Range	0.0244
...	...
ED_Cerebellum_L_Ratio	0.0011
降压治疗	0.0006
营养神经	0.0005
脑出血前 mRS 评分	0.0005
房颤史	0

3. 分类模型

(1) 单标签多分类

在单标签多分类问题中，每个样本只有一个真实的标签，而不像多标签分类问题中可以有多个标签同时存在。为了解决单标签多分类问题，通常使用分类算法，如逻辑回归、随机森林、神经网络等。这些算法可以根据特征来预测每个样本的类别，并且通常使用不同的评估指标来衡量模型的性能，如准确性、精确度、召回率、F1 分数等。

我们的算法结果如表 6-3 所示：

表 6-3: 单标签多分类算法结果表

Model	NN	RF	LB	GBDT
Score	0.20	0.35	0.27	0.15

可以看到我们的最好的模型是随机森林，准确率有 35%，效果较差！

(2) 多标签分类

将一个多分类问题转化为多标签分类问题需要将每个类别拆分成一个二元标签，然后使用二元分类器来预测每个标签的存在或缺失。

我们选择使用 ML-KNN 算法来实现。

首先，对训练数据集中的每个样本，根据其特征向量和对应的多标签进行建模。对于每个标签，ML-KNN 会找到最接近该样本的 k 个最近邻居，然后计算这 k 个邻居中各个标签的出现频率。这样，为每个标签生成了一个条件概率分布。当需要对新样本进行多标签分类时，ML-KNN 会首先找到与该样本最接近的 k 个最近邻居。然后，对于每个标签，它会基于邻居中该标签的出现频率，计算该标签的后验概率。最终，ML-KNN 会为每个标签选择具有最高后验概率的类别，并将其作为预测结果。

我们最后的输出结果如表 6-4 所示：

表 6-4: 多标签分类算法结果表

指标	Score
Hamming Loss	0.1571
F1 Score	0.0667
Precision	0.0500
Recall	0.1000

汉明损失是用来度量多标签分类模型的预测结果与真实标签之间的不匹配程度的指标。它的取值范围在 0 到 1 之间，值越低越好。在这个结果中，汉明损失为 0.1571，

表示模型的平均预测错误率为 15.71%。换句话说，模型在标签预测上平均错误了 15.71% 的标签。F1 分数为 0.0667，表示模型在多标签分类任务中的综合性能相对较低。这可能是因为精确度和召回率都不高。精确度为 0.0500，表示模型在多标签分类中的正例预测相对不准确，只有 5% 的正例预测是正确的。召回率为 0.1000，表示模型在多标签分类中的召回率也相对较低，只能成功捕捉到 10% 的真正正例。

总的来说，这些结果显示模型在多标签分类任务中的性能相对较差。

4. 回归模型

树回归是一种常用的回归算法，它可以用于解决多标签分类问题中的回归任务。树回归以树状结构表示数据集的分布，通过不断地将数据集划分成更小的子集并拟合每个子集的目标值来进行预测。

当面临回归问题时，选择使用 CART 树、随机森林和 XGBoost 回归树这三种算法是一个明智的选择。CART 树非常灵活，可以适用于各种问题，并且易于解释。随机森林在解决高维数据和处理特征重要性方面表现出色，因为它通过集成多个决策树来减小过拟合风险。而 XGBoost 回归树则以其高度优化的性能而闻名，通常在数据竞赛中广泛使用。综合使用这三种算法可以提供更多的建模选择，以便更好地应对各种情况。

我们的三个模型的损失和 R^2 如表 6-5 所示：

表 6-5：三个模型的损失和 R^2 结果表

模型名称	MSE	R^2
CART	2.23	0.208
RF	2.9	0.0668
XGBoost	2.37	0.1024

CART 算法的拟合效果：




图 6-6：CART 拟合效果图

随机森林的拟合效果如下图所示：




图 6-7：随机森林拟合效果图

XGBoost 的拟合效果如下图所示：




图 6-8：XGBoost 拟合效果图

在比较 CART 算法、随机森林和 XGBoost 回归树的表现时，我们发现 CART 算法表现出色，其预测值与实际值之间的接近程度令人印象深刻。CART 算法以其简洁性和直观性而脱颖而出，它生成的决策树模型能够很好地捕捉数据的关键特征和趋势，从而产生了高度准确的预测结果。这表明，对于特定问题，CART 算法可能是一个极具竞争力的选择，能够提供出色的预测性能。

5. 模型预测

在我们的研究中，模型预测是为了预测患者的 90 天 mRS 评分，这对于临床医疗决策和患者管理至关重要。我们使用了 CART 算法、随机森林和 XGBoost 回归树等多种方法来进行预测，其中 CART 算法表现出色，显示出与实际值极为接近的预测结果。

因此，我们使用 CART 算法对全部的 160 位患者进行预测，我们的部分结果展示如表 6-6 所示：

表 6-6：CART 算法预测部分结果表

ID	预测 mRS（基于首次影像）
Sub001	3
Sub002	0
Sub003	5

Sub004	4
Sub005	2
...	...
Sub156	6
Sub157	1
Sub158	3
Sub159	3
Sub160	4

6.2 问题三 b 题

6.2.1 问题三 b 题分析

问题 b 要求根据前 100 个患者的所有已知临床信息、治疗信息、以及表 2 和表 3 的影像结果，来预测包括随访影像检查在内的所有患者的 90 天 mRS 评分。这个问题涉及到更广泛的数据集，因为它包括了随访影像检查的数据，而不仅仅是首次影像检查。

我们首先要明确与问题 a 的区别与联系。两个问题都涉及使用患者的个人史、疾病史、发病相关信息和影像数据来预测患者的 90 天 mRS 评分，共同目标是建立一个预测模型，以便更好地理解患者的病情和预后，为临床相关决策提供支持。

但是问题 a 仅考虑了前 100 名患者的首次影像检查信息，而问题 b 考虑了前 100 名患者以及随访影像检查的数据。问题 b 的数据集更加的全面，因此可能需要更复杂的模型来处理更大的数据集。

总之，问题 a 和问题 b 都涉及使用机器学习方法构建预测模型，但问题 b 的范围更广泛，需要处理更多的数据和更复杂的情况，以便更全面地预测患者的康复状况。

分析这个问题时，我们需要考虑以下几个关键点。

首先，需要确保已经收集和整合了前 100 个患者的所有已知临床信息、治疗信息以及首次和随访影像检查的结果。因为加入了后续多次的随访，所以会有大量的缺失值需要处理。

特征选择和工程：需要仔细选择和工程化特征，这包括表 1 中的临床信息、治疗信息，以及表 2 和表 3 中的影像特征。这些特征可能需要进行编码、归一化和处理，以便用于模型训练。

根据数据集的规模 and 问题的复杂性，选择适当的机器学习算法来构建预测模型。问题 b 和问题 a 的最大区别就是，b 的数据集中存在大量的缺失值需要我们处理，模型我们可以选择和问题 a 一样的模型，即决策树回归模型。评估指标的选择和问题 a 的一致。

这个问题的挑战在于数据集的复杂性和规模，以及如何有效地整合不同来源的信息，以及处理庞大的缺失值，以提高对患者康复状况的预测准确性。

问题三 b 题模型的建立

(1) 二进制指示器

数据集存在很严重的缺失情况，将缺失值可视化如下图所示：




图 6-9：缺失值可视图

数据集部分的缺失情况如表 6-7 所示：

表 6-7：数据集缺失情况表（部分）

缺失值比重	特征名
18.75%	HM_volume.1
	HM_ACA_R_Ratio.1
	...
	ED_Pons_Medulla_L_Ratio.1
	ED_Cerebellum_L_Ratio.1
22.50%	HM_volume.2
	HM_ACA_R_Ratio.2
	...
	ED_Pons_Medulla_L_Ratio.2
	ED_Cerebellum_L_Ratio.2
45.00%	HM_volume.3
	HM_ACA_R_Ratio.3
	...
	ED_Pons_Medulla_L_Ratio.3
	ED_Cerebellum_L_Ratio.3
66.25%	HM_volume.4
	HM_ACA_R_Ratio.4
	...
	ED_Pons_Medulla_L_Ratio.4
	ED_Cerebellum_L_Ratio.4
85.62%	HM_volume.5
	HM_ACA_R_Ratio.5
	...
	ED_Pons_Medulla_L_Ratio.5
	ED_Cerebellum_L_Ratio.5

	ED_Pons_Medulla_L_Ratio.5
	ED_Cerebellum_L_Ratio.5
	HM_volume.6
	HM_ACA_R_Ratio.6
95.00%	...
	ED_Pons_Medulla_L_Ratio.6
	ED_Cerebellum_L_Ratio.6
	HM_volume.7
	HM_ACA_R_Ratio.7
97.50%	...
	ED_Pons_Medulla_L_Ratio.7
	ED_Cerebellum_L_Ratio.7
	HM_volume.8
	HM_ACA_R_Ratio.8
98.75%	...
	ED_Pons_Medulla_L_Ratio.8
	ED_Pons_Medulla_L_Ratio.8

在数据集中，缺失值通常表示为 NaN（Not a Number）或其他占位符。缺失值可能是由于数据采集错误、不完整或其他原因造成的。当数据中存在大量缺失值（例如，80%到90%的数据都缺失）且不能删除这些数据时，缺失值的存在可能会导致模型性能下降，特别是对于某些机器学习算法，模型可能会产生偏差或不准确的预测，因为它们无法利用缺失的信息。其次，缺失值可能会引入不确定性，因为模型无法确定缺失值的真实值。这可能导致不确定性传播到模型的预测结果中。

如何有效的利用大量缺失值的数据是一项挑战性任务！在本文中，我们提出了一种新的方法来学习有效的利用缺失值数据。

在处理缺失值时，使用二进制指示器是一种常见的方法。这种方法通常用于变量中的缺失值，以将缺失信息转化为一个或多个二进制变量，以便在机器学习模型中使用。以下是我们使用二进制指示器来处理缺失值的详细介绍：

首先，选择需要处理缺失值的变量。对于每个需要处理的变量，创建一个对应的二进制指示器变量。

二进制指示器变量是一个二进制（0 或 1）变量，用于表示原始变量是否存在缺失值。如果原始变量中存在缺失值，二进制指示器变量的值为 1；如果没有缺失值，其值为 0。

将原始变量替换为对应的二进制指示器变量。这可以通过简单的数据列替换来实现。替换后，原始变量中的缺失值将被映射到二进制指示器变量中的 1。

我们给出设计的流程图，如下图所示：




图 6-10: 问题三(b)流程图

对于某些变量，可能存在多个缺失值的情况。在这种情况下，可以创建多个二进制指示器变量，每个变量对应一个缺失值。这允许模型更好地捕捉缺失值的模式。

二进制指示器允许在模型中使用原始变量中的信息，同时处理缺失值，且不会丢失原始数据中的信息，因为它们以二进制变量的形式保留。在一些机器学习算法中，如决策树和随机森林，可以直接处理二进制指示器。

总之，使用二进制指示器是一种处理分类变量中缺失值的有效方法，它允许在模型中考虑缺失值的影响，并为模型提供了更多信息。

(2) 选择模型

问题 *a* 中的模型已经在相应数据上进行了训练和调优，因此可以视为一个有效的起点。此外，模型的参数和特征工程可以在问题 *b* 中进行稍微的调整，以适应问题 *b* 的特点，而不必从头开始构建一个全新的模型。这样的一致性和可比性使我们能够更好地理解模型的性能和特征的影响，为问题 *b* 提供一个强有力的预测工具。当然，在应用模型时，我们还会仔细考虑问题 *b* 的特殊背景和数据，以确保模型在新的上下文中能够发挥最佳效果。

6.2.2 问题三 b 题模型的求解

我们利用问题 *a* 中的模型在问题 *b* 上进行训练和测试，得到均方误差为 2.197。给出预测值和真实值之间的对比，如下图所示：




图 6-11: 预测值和真实值对比图

我们的分析表明，尽管问题 *b* 中的数据包含更多的随访影像检查，但与问题 *a* 中相同的模型在预测任务中并没有显示明显的误差增加。这一结果表明，我们选择的模型在处理更多的患者数据和额外的随访信息时表现稳定，没有出现显著的性能下降。这种一致性是鼓舞人心的，因为它意味着我们可以在不同情境下信任我们的模型，并且无需额外的复杂性或资源来适应问题 *b* 的要求。这也证明了我们在问题 *a* 中的模型选择是合理和可行的，为我们提供了可靠的预测工具。

表 6-8:

ID	预测 mRS (基于首次+随访)
Sub001	4
Sub002	1
Sub003	4
Sub004	4
Sub005	3
...	...
Sub156	3
Sub157	3
Sub158	3
Sub159	2
Sub160	2

6.3 问题三 c 题

6.3.1 问题三 c 题分析

针对血性脑卒中患者的预后（90 天 mRS），我们需要考虑多个因素，包括个人史、疾病史、治疗方法以及影像特征。

首先，个人史方面，患者的年龄、性别、吸烟史、酗酒史和家族史都可能与预后有关。年龄通常与恢复能力相关，而吸烟和酗酒可能增加血管疾病的风险，影响恢复。家族史可能揭示遗传因素的影响。

其次，疾病史方面，患者的高血压、糖尿病、高脂血症等慢性疾病可能影响预后。这些疾病可以增加脑卒中的发病风险，同时也可能干扰恢复过程。治疗方法是关键因素之一，包括是否及时接受溶栓治疗、手术干预、抗凝治疗等。治疗的及时性和有效性直接关系到预后。

最后，影像特征方面，血肿/水肿体积、位置、信号强度特征和形状特征都可以提供重要信息。较大的血肿体积通常与更严重的症状和不良预后相关。血肿/水肿位置可能影响特定功能区域的受损程度。信号强度和形状特征可能提示出血的原因，如动静脉畸形或微血管病变。

因此，在制定临床相关决策时，需要综合考虑上述因素。例如，对于年轻患者，可能需要更加积极地管理慢性疾病，以提高预后。对于血肿体积较大的患者，可能需要考虑手术干预的可能性。综合分析个人史、疾病史、治疗方法和影像特征，可以帮助医生制定个性化的治疗计划，以优化血性脑卒中患者的预后。

6.3.2 问题三 c 题模型的建立

对于分析血性脑卒中患者的预后与个人史、疾病史、治疗方法以及影像特征之间的关联关系，可以采用统计分析和机器学习方法。以下是我们的模型的建立过程：

首先，需要从题目的数据集中，整理包括血性脑卒中患者的临床数据、疾病史、治疗记录和影像特征，并将这些数据整理成结构化的格式，确保数据的质量和完整

性。

接下来我们进行初步的数据探索，通过统计图表和可视化工具来了解各个特征之间的关系。例如，可以绘制相关性矩阵热图，以查看特征之间的相关性。选择使用统计方法（如皮尔逊相关系数）或可视化方法（如热力图）来分析各个特征与 90 天 mRS 评分之间的相关性，初步确定哪些特征可能与预后相关。

对于与 90 天 mRS 评分相关性显著的特征，进行进一步的统计分析，例如方差分析（ANOVA）或 t 检验，以确定不同组之间的差异性。

解释分析结果，包括哪些因素与预后相关，以及它们的影响程度。这有助于理解预后的决定因素。

最后我们基于模型的结果，提出针对患者的临床建议。例如，如果模型表明某些治疗方法与更好的预后相关，可以建议医生在相似情况下优先考虑这些治疗方法。另外，如果特定的个人史或疾病史因素与不良预后相关，可以提供相关的预防或干预建议。

综上所述，我们的建模思路如下图所示：




图 6-12：问题三(c)的建模思路

6.3.3 问题三 c 题模型的求解

(1) 数据集的构建

血性脑卒中患者的预后（90 天 mRS 评分）受到多个因素的影响，其中包括个人史、疾病史、治疗方法以及影像特征，其中包括血肿/水肿体积、血肿/水肿位置、信号强度特征和形状特征。这些特征分别来自于不同的附件表格数据，我们整理如下：

表 6-9：问题三(c)的数据集构建

表名	列名
表 1	90 天 mRS、年龄、...、营养神经
表 2	首次检查的 HM_volume、...、ED_Cerebellum_L_Ratio
表 3	original_shape_Elongation、...、NCCT_original_firstorder_Variance

(2) 相关性分析

我们第一步是研究了这些因素之间的相关性，以更好地了解它们对出血性脑卒中患者的预后产生的影响。

首先，我们关注了个人史因素，包括年龄、性别和脑出血前 mRS 评分。这些因素在出血性脑卒中康复中扮演着关键角色，脑出血前 mRS 评分与不利的预后相关，而年龄和性别也是一个重要的预测因子。我们的分析将帮助我们更好地了解患者的个人历史如何影响康复进程。相关系数的热力图如下所示：



图 6-13: 90 天 mRS 与个人史的相关热力图

90 天 mRS 评分与年龄的相关系数为 0.23，这意味着存在一定程度的正相关性。具体来说，随着年龄增长，90 天 mRS 评分也有轻微增加的趋势。这可能意味着年龄较大的患者在康复过程中可能面临一些挑战，康复的速度可能相对较慢，因此他们的 90 天 mRS 评分可能较高。然而，相关系数为 0.23 并不是非常强烈的相关性，因此年龄并不是唯一决定 90 天 mRS 评分的因素。

其次，我们研究了疾病史，特别是高血压和糖尿病病史。这些慢性疾病在出血性脑卒中患者中较为常见，我们猜测它们可能与不利的康复相关。



图 6-14: 90 天 mRS 与疾病史的相关热力图

与糖尿病史有关的患者在 90 天 mRS 评分上表现出较高的相关性。这表明糖尿病可能对脑卒中后的康复产生负面影响。因此，对于糖尿病患者，可能需要更密切地监测其康复进程，并采取额外的康复措施，以提高康复机会。冠心病史与 90 天 mRS 评分之间也存在显著的正相关性。这可能与冠心病对心血管健康的负面影响以及其与脑卒中之间的关联有关。治疗冠心病并维护心血管健康可能对脑卒中患者的康复有积极影响。吸烟史与稍微较低的 90 天 mRS 评分相关。尽管相关性不是很强，但负相关性表明吸烟可能对脑卒中患者的康复产生负面影响。戒烟可能有助于改善康复结果。饮酒史与稍微较高的 90 天 mRS 评分相关。这表明过度饮酒可能对康复产生不利影响。患者可能需要减少饮酒以改善康复前景。

高血压病史和卒中史这两个因素与 90 天 mRS 评分之间的相关性较小。尽管如此，高血压和卒中仍然是脑卒中的主要风险因素，因此对于这些患者，更积极地管理这些疾病仍然至关重要。

治疗方法选择也是关键因素。我们在之前的研究表明，不同的治疗方法可能与康复结果有关。



图 6-15: 90 天 mRS 与治疗方式的相关热力图

脑室引流与稍微较高的 90 天 mRS 评分相关。这可能表明需要脑室引流的患者可能在康复过程中面临更多挑战，因此其 90 天 mRS 评分较高。这也可能反映了脑室引流通常用于重症患者的情况。降颅压治疗可能意味着需要降低颅内压力的患者可能在康复方面面临额外的挑战。降压治疗的相关系数为 0.16)，可能反映了高血压管理在脑卒中治疗中的重要性。对于一些患者，高血压可能会对康复产生不利影响。

止血治疗、止吐护胃和营养神经治疗这些治疗方法与 90 天 mRS 评分之间的相关性相对较低。这可能表明这些治疗方法对 90 天 mRS 评分的影响相对较小，或者在整体分析中没有显著的影响。

最后，我们深入研究了影像特征，包括血肿/水肿体积、位置、信号强度和形状特征。这些特征提供了有关病灶的关键信息，有助于医疗团队为每位患者制定个性化的康复策略。例如，我们在之前的问题研究中发现小型血肿可能对康复有利，这可能需要更早的干预，涉及到的指标较多，如下图所示：




图 6-16: 90 天 mRS 与影响信息血肿及水肿的体积及位置的相关热力图

相关系数为 0.39 表明血肿体积与 90 天 mRS 评分之间存在较强的正相关性。这可能意味着较大的血肿体积可能对康复产生负面影响。较大的血肿通常伴随着更多的神经功能损害，可能导致更高的 90 天 mRS 评分。因此，对于出血性脑卒中患者，及时的血肿管理和治疗可能对改善康复结果至关重要。

相关系数为 0.24 表明水肿体积与 90 天 mRS 评分之间存在一定程度的正相关性，尽管相关性较 HM_volume 稍低。水肿体积的增加可能导致神经组织的压力增加和功能受损，从而对康复产生不利影响。因此，在脑卒中患者的治疗中，应该密切关注水肿体积的管理和控制，以提高康复机会。

与其他因素的相关性相对较低，可能表明这些因素对 90 天 mRS 评分的影响相对较小或与康复不太相关。然而，这并不代表这些因素不重要，而是在整体分析中它们的影响较小。





图 6-17: 90 天 mRS 与影响信息血肿及水肿的形状的相关热力图

血肿和水肿形状与 90 天 mRS 评分的相关性较低。血肿和水肿的形状可能因患者之间的差异而变化很大。每个脑卒中患者的脑部解剖结构和损伤位置都是独特的，因此血肿和水肿的形状可能各不相同。这种多样性可能导致形状与康复结果之间的关联性不明显。



NCCT_original_firstorder_Entropy（熵）与 90 天 mRS 评分之间的相关性系数为 0.21。正相关性表明熵值较高的患者可能具有稍高的 90 天 mRS 评分。熵通常用于表示图像的复杂性，较高的熵值可能反映了脑部组织的不规则性和多样性。因此，与较高熵值相关的 90 天 mRS 评分可能表示患者的脑损伤较为复杂，康复可能更具挑战性。

NCCT_original_firstorder_Maximum（最大值）与 90 天 mRS 评分之间的相关性系数为 0.18。最大值通常表示图像中最亮的像素，较高的最大值可能反映了一些特定区域的高密度或高信号强度。这可能与患者的脑部病变或损伤相关，从而影响康复结果。

NCCT_original_firstorder_Uniformity 表示均匀性。均匀性通常表示图像中像素值分布的均匀程度，较高的均匀性可能反映了相对均匀的组织特征。这可能意味着均匀性较高的患者可能在某种程度上具有更均匀的脑组织，这可能与康复结果的改善相关。

我们的数据集有多个不同的因素或组，想要确定它们是否对 90 天 mRS 评分产生显著影响时，方差分析是一种有力的工具。在研究中，通常存在多个治疗方法、不同患者群体或其他因素，我们需要分析它们之间是否存在显著差异。

同时方差分析可以提供统计显著性的结果，帮助我们确定不同因素是否 90 天 mRS 评分产生了显著影响。这有助于科学研究和临床决策，例如确定哪种治疗方法在提高患者康复方面最有效。对我们下面提出建议提供了一定程度上的统计依据。

表 6-10：个人史对 90 天 mRS 评分的方差分析

特征名	F 统计量	P 值	是否显著
年龄	0.1423	0.0244	是
性别	0.5444	0.4670	否
脑出血前 mRS 评分	0.2149	0.6467	否
高压	0.3261	0.5727	否
低压	0.6035	0.4440	否

年龄与 90 天 mRS 评分之间的显著性关联表明，患者的年龄可能在预测血性脑卒中的预后方面起着重要作用。通常情况下，年龄较大的患者可能更容易受到脑卒中的影响，康复可能较慢或较困难。

与性别之间的非显著关联相比，性别对 90 天 mRS 评分没有统计上的显著影响。这意味着男性和女性患者的康复前景可能是相似的，至少在统计学上没有差异。

类似于性别，脑出血前的 mRS 评分与 90 天 mRS 评分之间的非显著关联表明，脑出血前的严重程度在统计学上不一定决定了患者的长期康复结果。这意味着即使患者在脑出血前评分较低，也不一定意味着其康复更好。

高压和低压与 90 天 mRS 评分之间的非显著关联表明，血压水平对于长期康复结果的影响可能有限。这并不是说血压不重要，而是指出在这个特定的研究中，高低血压水平与康复之间的统计关联不显著。然而，在实际临床中，管理患者的血压仍然是至关重要的，因为它可能对其他方面的健康产生积极影响。

表 6-11：疾病史对 90 天 mRS 评分的方差分析（部分结果）

特征名	F 统计量	p 值	是否显著
糖尿病史	2.5081	0.0230	是
冠心病史	1.7232	0.0318	是
...	...	...	...
吸烟史	0.8334	0.3694	否
饮酒史	0.1335	0.7176	否

患有糖尿病史和冠心病史的患者在统计上显示出不同的康复趋势，这两个因素在预测 90 天 mRS 评分方面具有显著性影响。

糖尿病是一种慢性疾病，它可能对血管和神经系统造成损害，增加脑卒中的风险。糖尿病患者通常具有较高的血糖水平，这可能导致炎症、氧化应激和血管病变等生物学变化，进而影响康复过程。因此，在糖尿病患者中，90 天 mRS 评分可能更倾向于显示出不同的康复趋势，可能更高或更低，这可以解释为什么在统计上存在显著关联。冠心病是心脏疾病的一种，通常伴随着心血管问题。血性脑卒中和冠心病可能共享一些危险因素，例如高血压和高胆固醇水平。冠心病史可能与心脑血管疾病的复杂性有关，这可能会影响康复过程。因此，患有冠心病史的患者在统计上显示出不同的康复趋势，这也可以解释为什么在统计上存在显著关联。

吸烟和饮酒等其他因素虽然也会对健康产生不良影响，但它们可能与脑卒中的康复之间的关联比较复杂。在这个特定的研究中，可能没有足够的样本量或数据来

显示吸烟史和饮酒史与 90 天 mRS 评分之间的显著性关联。

表 6-12: 治疗方法对 90 天 mRS 评分的方差分析 (部分结果)

特征名	F 统计量	P 值	是否显著
脑室引流	1.1135	0.0497	是
止血治疗	0.0760	0.7849	否
...	...	...	...
止吐护胃	0.8752	0.3582	否
营养神经	0.5172	0.4782	否

脑室引流的 F 统计量为 1.1135, p 值为 0.0497。这表示脑室引流与 90 天 mRS 评分之间存在显著关联。因此, 接受脑室引流治疗的患者在康复过程中可能显示出不同的趋势, 可能具有更高或更低的 90 天 mRS 评分。这个结果可能有临床意义, 因为脑室引流是一种用于处理颅内压升高的治疗方法, 它可能会对患者的康复产生影响。

表 6-13: 影像信息血肿及水肿的体积及位置 (部分结果)

特征名	F 统计量	p 值	是否显著
HM_volume	7.5661	0.0086	是
HM_ACA_R_Ratio	9.7905	0.0042	是
ED_ACA_R_Ratio	8.2899	0.0077	是
HM_Pons_Medulla_L_Ratio	1.0397	0.3169	否
...	...	...	...
ED_Cerebellum_L_Ratio	1.9655	0.1723	否

HM_volume 与 90 天 mRS 评分之间存在显著关联。因此, HM_volume (血肿体积) 可能是一个重要的影响因素, 它与患者的康复表现之间存在一定关系。这个结果可能是非常重要的, 因为血肿体积可以反映出脑出血的严重程度, 对康复过程产生重要影响。

ACA (前大脑动脉) 的比率与康复表现之间存在相关性, 这可能与 ACA 在脑血液供应中的重要作用有关。

表 6-14: 影像信息血肿及水肿的形状 (部分结果)

特征名	F 统计量	P 值	是否显著
original_shape_Elongation	2.2656	0.1439	否
original_shape_Flatness	0.0092	0.9242	否
...	...	...	...
original_shape_SurfaceVolumeRatio	0.9299	0.3435	否
original_shape_VoxelVolume	0.5867	0.4503	否

在这个研究中, 影像信息中血肿或水肿的形状特征可能对康复表现的预测没有显著性影响。

表 6-15: 影像信息血肿及水肿的灰度分布 (部分结果)

特征名	F 统计量	P 值	是否显著
NCCT_original_firstorder_10Percentile	1.1836	0.2862	否
NCCT_original_firstorder_90Percentile	1.1313	0.2969	否
...	...	...	...
NCCT_original_firstorder_Uniformity	0.1868	0.6690	否
NCCT_original_firstorder_Variance	0.0250	0.8756	否

血肿或水肿的灰度分布的均匀性和方差特征似乎对康复表现没有显著影响。因

为脑卒中的康复表现受到多种因素的影响，包括病情的严重程度、治疗方法、患者的个体差异等。灰度分布的均匀性和方差特征可能只是其中的一部分因素，不足以单独预测康复表现。

(4) 为临床相关决策提出建议

根据对血性脑卒中患者的预后与个人史、疾病史、治疗方法及影像特征的关联关系的分析，以下是一些建议，可供临床相关决策参考：

- **年龄的重要性：**从相关分析和方差分析都可以看出，年龄是一个重要的个人史因素，与 90 天 mRS 评分呈正相关，这意味着年龄较大的患者更有可能在康复后表现出较差的功能。因此，在评估血性脑卒中患者的康复前景时，应格外关注年龄较大的患者，并提供更全面的康复支持。
- **疾病史的关注：**在疾病史的相关因素中，糖尿病史和冠心病史与 90 天 mRS 评分呈较高的正相关，这表明这些疾病可能对康复产生负面影响。因此，在治疗和管理血性脑卒中患者时，应特别留意这些疾病的存在，并采取措施来控制其影响。
- **治疗方法：**脑室引流是一个重要的治疗方法，在进行相关分析时，呈现了较高的相关性，这表明脑室引流可能对康复产生积极影响。因此，在临床治疗决策中，考虑脑室引流的使用可能有助于改善患者的预后。
- **影响图像：**血肿和水肿的位置、以及形状特征与预后评分之间的显著性和相关性均不明显，这可能意味着在当前的研究条件下，这些特征可能不是预测康复表现的最佳指标。但是依旧不可忽视影响特征的重要性，它们仍然可以提供有关病变的重要信息，对于临床诊断和治疗仍然具有很高的研究价值。
- **定期随访：**对于血性脑卒中患者，定期的康复随访和支持是至关重要的。从提供的附件数据来看，很多患者通过多次随访，从而慢慢的恢复到较为健康的状态。通过定期的评估，医疗团队可以监测患者的康复进展并及时调整治疗计划。

7. 模型的分析与检验

7.1 模型的优点

- 1) 问题三通过添加二进制指示器列，我们保留了缺失值的存在信息，而不是简单地丢弃它们。这可以使模型更好地理解缺失值对于预测的影响。
- 2) 问题二模型提供了一种数学方式来拟合数据，以便更好地理解水肿体积的变化。这可以帮助识别水肿体积的上升或下降趋势。
- 3) 问题二通过将患者分成不同的亚组，可以更精细地理解患者群体之间的水肿体积变化模式。通过针对每个亚组构建自适应的水肿体积随时间的曲线，可以提高模型的准确性。模型更有可能捕捉到亚组内水肿体积变化的特定特征。
- 4) 文中建立的模型基于大量患者的个人史、疾病史、发病相关信息和影像检查结果构建，可以更全面地考虑多个因素对疾病事件的影响，使决策更具有数据支持。
- 5) 通过考虑每个患者的个人史、疾病史、发病相关信息以及首次影像结果，文中建立的模型可以提供个性化的预测，考虑到每位患者的独特情况。
- 6) 简单易懂。本文所选用的决策树、XGBoost、LightGBM、各种插值算法等在视觉上都非常直观，而且容易解释，不需要复杂的数学运算。

7.2 模型的缺点

- 1) **问题二**选择适当的曲线模型可能需要一定的经验和判断。选择不当的模型可能导致对数据的不准确拟合。
- 2) **问题二**模型基于数学函数对数据进行拟合，这可能会引入一些模型假设，例如，曲线的形状或残差的分布。这些假设可能不适用于所有数据集。
- 3) 模型的准确性高度依赖于数据的质量，包括治疗方法的准确记录和水肿体积的精确测量。如果数据存在错误或不完整，模型的结果可能不准确。

7.3 模型的改进

- 1) **扩充数据**：如果可能的话，收集更多数据可能有助于提高模型的性能。更大的数据集可以提供更多的信息，有助于训练更准确的模型。
- 2) **特征工程**：不断探索和改进特征工程方法，以确保模型可以捕捉到数据中的有用信息。考虑引入新特征或更高级的特征工程技术。
- 3) **模型选择和参数调整**：重新评估模型的选择和参数设置。可能有更适合问题的算法或更优的参数组合，可以提高性能。
- 4) **不确定性估计**：对于模型的预测，考虑估计不确定性的方法，如置信区间或概率预测。这对于决策支持非常有价值。
- 5) **解释性**：如果模型需要在临床环境中广泛使用，强调模型的解释性是关键。
- 6) **模型集成**：考虑将多个模型集成在一起，以提高性能。

7.4 模型的推广

- 1) **外部验证**：在推广模型之前，进行外部验证是至关重要的。这可以通过使用新的、独立于模型开发数据的数据集来实现。外部验证可以帮助确定模型的泛化能力，即模型在未见过的数据上的性能。
- 2) **实际临床应用**：将模型集成到实际临床实践中，以评估其对医疗决策的实际影响。在实际应用中，模型的性能和效用需要经过长期监测和评估。
- 3) **改进更新**：建立反馈回路，以便从医疗团队和患者那里获得关于模型性能和实用性的反馈。这些反馈可以用于不断改进模型，以适应变化的需求和数据。
- 4) **伦理和隐私**：确保在模型推广过程中严格遵守伦理和隐私法规。患者的隐私和数据安全必须得到充分保护。

8. 参考文献

- [1] 孔凡梅. 基于数据挖掘技术构建康复期病人缺血性脑卒中复发预测模型的研究[D].右江民族医学院,2023.
- [2] 栾奕.从临床路径视角分析过度医疗中诊疗技术影响因素及建模理论问题[J].中国煤炭工业医学杂志,2013,16(01):151-152.
- [3] 李国垒,夏冬,郭珉江等.基于关联规则的肺炎患者诊疗数据挖掘[J].中国数字医学,2019,14(07):91-93.
- [4] 周航,李建萍,唐斌.高血压脑出血患者颅内血肿周围水肿体积扩大的相关影响因素分析[J].保健医学研究与实践,2019,16(01):48-51.
- [5] 唐亮,段建国,许洪波,等.基于互信息最大化的特征选择算法及应用[J].计算机工程与应用, 2008, 44(13).
- [6] 涂昌慧.特征选择算法的研究与应用[D].华南师范大学,2015.
- [7] 范雪莉,冯海泓,原猛.基于互信息的主成分分析特征选择算法[J].控制与决策, 2013, 28(6).
- [8] 徐佳琳,左国坤.基于互信息与主成分分析的运动想象脑电特征选择算法[J].生物医学工程学杂志, 2016, 33(2).
- [9] 朱颢东,钟勇.一种新的基于多启发式的特征选择算法[J].计算机应用, 2009, 029(003):849-851.
- [10] Chen T , He T , Benesty M .xgboost: Extreme Gradient Boosting[J]. 2016.
- [11] 刘巧红,马雨生,蔡雨晨.基于 XGBoost 算法的糖尿病分类预测模型及应用[J].现代仪器与医疗,2023,29(04):1-6+11.
- [12] 刘小虎,李生.决策树的优化算法[J].软件学报, 1998, 9(10):4.
- [13] 刘勇洪,牛铮,王长耀.Research and Application of the Decision Tree Classification Using
- [14] 姚登举,杨静,詹晓娟.基于随机森林的特征选择算法[J].吉林大学学报: 工学版, 2014(1):5.
- [15] 曹正凤.随机森林算法优化研究[D].首都经济贸易大学[2023-09-25].
- [16] Li X .随机森林模型在分类与回归分析中的应用 Using Random Forest for classification and regression[J].Journal of Applied Entomology, 2013.
- [17] 邢长征,徐佳玉.LightGBM 混合模型在乳腺癌诊断中的应用[J/OL].计算机工程与应用:1-10[2023-09-25].
- [18] 丘敏敏,钟嘉健,欧阳斌等.基于高斯混合模型 Varian NovalisTX 直线加速器盆腔肿瘤放疗摆位误差分布预测模型的构建[J].中山大学学报(医学版),2019,40(02):284-290.
- [19] 谭刚林,萧泽新.基于牛顿插值的九点八线式 CCD 细分技术及其应用[J].长沙民政职业技术学院学报,2022,29(04):133-135.
- [20] 吕冠颖,刘畅,何环莎等.基于 N 阶多项式回归方程的 RMR 分级方法优化[J].矿冶,2023,32(04):6-11.
- [21] 陈静,李华.基于多项式回归模型的软件可靠性预测方法研究[J].黑龙江科学,2021,12(18):29-31.
- [22] 余豪东,陈玉明,吴克寿等.决策粒 K 均值聚类算法[J].闽南师范大学学报(自然科学版),2023,36(03):1-13.
- [23] 何选森,何帆,徐丽等.K-Means 算法最优聚类数量的确定[J].电子科技大学学报,2022,51(06):904-912.
- [24] 何婷,赵春兰,李屹等.基于 FCM 聚类的模糊综合评价方法[J].陕西师范大学学报(自然科学版),2023,51(01):111-119.
- [25] [袁科,黄雅冰,杜展飞等.基于混合梯度提升决策树和逻辑回归模型的分组密码算法识别方案[J].工程科学与技术,2022,54(04):218-227.
- [26] 于秋红,王莉.基于模糊 C 均值聚类算法的系统健康状态研究[J].信息通信技术与政

策,2023,49(04):91-96.

[27] 文锦.保凸 C^1 分段二次多项式插值方法[J].数学理论与应用,2000(02):33-36.

[28] 张恩绮,林颢.浅谈分段三次埃尔米特插值[J].广东蚕业,2018,52(06):71.

[29] <https://scikit-learn.org.cn/view/255.html>

[30] 汪学清,刘爽,李秋燕等.基于 K 折交叉验证的 SVM 隧道围岩分级判别[J].矿冶工程,2021,41(06):126-128+133.

9. 附录

附录 1

介绍：问题 1a

```
# 循环处理每一行数据
for index, row in data.iterrows():
    is_hematoma = False # 初始化是否肿为False
    hematoma_time = None # 初始化水肿时间为空

    for i, column_name in enumerate(column_names):
        time_interval = row[column_name] + row['发病到首次影像检查时间间隔']

        if time_interval > 48:
            break # 如果时间间隔大于48小时，停止判断

        volume_difference = (row[f'HM_volume.{i + 1}'] - row['HM_volume']) / 1000
        volume_percentage = (row[f'HM_volume.{i + 1}'] - row['HM_volume']) / row['HM_volume'] - 1

        if volume_difference >= 6 or volume_percentage >= 0.33:
            is_hematoma = True
            hematoma_time = time_interval
            break

# 添加结果到新表格
result_df = result_df.append({'Unnamed: 0': row['Unnamed: 0'], '是否肿': 1 if is_hematoma else 0, '水肿时间': hematoma_time}, ignore_index=True)
```

附录 2

介绍：问题 1b 特征选择

```
from sklearn.ensemble import RandomForestClassifier

X_rf = data_new.iloc[:, 2:-1]
y_rf = data_new.iloc[:, -1]

rf_classifier = RandomForestClassifier(n_estimators=100, random_state=0)

rf_classifier.fit(X_rf, y_rf)

# 获取特征重要性分数
feature_importances = rf_classifier.feature_importances_
# 获取特征名称
feature_names = X_rf.columns

# 创建一个索引数组，按照特征重要性分数从高到低排列
indices = np.argsort(feature_importances)[::-1]

bar_color = "#B9E0D6"
# 创建两个子图，共享X轴
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 6), sharex=True)

# 子图1: 前20个特征的特征重要性分数
top_features = 20
ax1.barh(range(top_features), feature_importances[indices[:top_features]], align="center", color = bar_color)
ax1.set_yticks(range(top_features))
ax1.set_yticklabels([feature_names[i] for i in indices[:top_features]])
ax1.invert_yaxis() # 反转y轴，使重要性高的特征显示在上面
ax1.set_xlabel("Importance Score")
ax1.set_title("Top 20 Feature Importance Scores")

# 子图2: 后20个特征的特征重要性分数
bottom_features = 20
ax2.barh(range(bottom_features), feature_importances[indices[-bottom_features:]], align="center", color = bar_color)
ax2.set_yticks(range(bottom_features))
ax2.set_yticklabels([feature_names[i] for i in indices[-bottom_features:]])
ax2.invert_yaxis() # 反转y轴，使重要性高的特征显示在上面
ax2.set_xlabel("Importance Score")
ax2.set_title("Bottom 20 Feature Importance Scores")

plt.tight_layout()
plt.show()
```


附录 3

介绍：问题 1b

```
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from sklearn.svm import SVC
from sklearn.model_selection import cross_val_predict
from sklearn.metrics import accuracy_score, roc_auc_score

# 创建基本模型
rf_classifier = RandomForestClassifier(random_state=42, max_depth = 3, n_estimators=100)
xgb_classifier = XGBClassifier(random_state=42, learning_rate=0.01, max_depth=3, min_child_weight=3, n_estimators=50)
svm_classifier = SVC(probability=True, random_state=42)

# 创建次级模型
meta_classifier = RandomForestClassifier(random_state=42)

# 使用基本模型进行五折交叉验证的预测
rf_preds = cross_val_predict(rf_classifier, X_train, y_train, cv=5, method='predict_proba')[:, 1]
xgb_preds = cross_val_predict(xgb_classifier, X_train, y_train, cv=5, method='predict_proba')[:, 1]
svm_preds = cross_val_predict(svm_classifier, X_train, y_train, cv=5, method='predict_proba')[:, 1]

# 将基本模型的预测结果作为特征，构建次级模型的训练集
stacking_X_train = np.column_stack((rf_preds, xgb_preds, svm_preds))

# 使用次级模型进行五折交叉验证的预测
stacking_preds = cross_val_predict(meta_classifier, stacking_X_train, y_train, cv=5, method='predict_proba')[:, 1]

accuracy = accuracy_score(y_train, (stacking_preds > 0.5).astype(int))
roc_auc = roc_auc_score(y_train, stacking_preds)

print("Stacking - Accuracy:", accuracy)
print("Stacking - ROC AUC:", roc_auc)
```

附录 4

介绍：问题 2a

```

import numpy as np
import matplotlib.pyplot as plt
from scipy.optimize import curve_fit

x = data['发病到检查时间']
y = data['ED_volume']
# 定义高斯模型函数
def gaussian_model(x, a, b, c):
    return a * np.exp(-(x - b)**2 / (2 * c**2))
params, covariance = curve_fit(gaussian_model, x, y)
a, b, c = params
x_fit = np.linspace(min(x), max(x), 100)
y_fit = gaussian_model(x_fit, a, b, c)
# 计算概率密度函数 (PDF)
pdf = (1 / (c * np.sqrt(2 * np.pi))) * np.exp(-(x_fit - b)**2 / (2 * c**2))
# 计算残差
residuals = gaussian_model(x, a, b, c) - y

plt.figure(figsize=(12, 6))
plt.subplot(2, 2, 1)
plt.scatter(x, y, label='原始数据', color='b', alpha=0.7)
plt.xlabel('发病到检查时间')
plt.ylabel('ED_volume')
plt.legend()
# 拟合曲线
plt.subplot(2, 2, 2)
plt.scatter(x, y, label='原始数据', color='b', alpha=0.7)
plt.plot(x_fit, y_fit, label='拟合曲线', color='r')
plt.xlabel('发病到检查时间')
plt.ylabel('ED_volume')
plt.legend()
# 残差图
plt.subplot(2, 2, 3)
plt.scatter(x, residuals, label='残差', color='g', alpha=0.7)
plt.axhline(0, color='r', linestyle='--', label='零线')
plt.xlabel('发病到检查时间')
plt.ylabel('残差')
plt.legend()
# PDF图
plt.subplot(2, 2, 4)
plt.plot(x_fit, pdf, label='PDF', color='m')
plt.xlabel('发病到检查时间')
plt.ylabel('概率密度')
plt.legend()
plt.tight_layout()
plt.show()

```

附录 5

介绍：问题 2b

```
import pandas as pd
import matplotlib.pyplot as plt
import skfuzzy as fuzz
import numpy as np
from sklearn.preprocessing import StandardScaler

features = ['高血压病史', '卒中病史', '糖尿病史', '房颤史', '冠心病史', '吸烟史', '饮酒史', '发病到检查时间', 'ED_volume']
X = data[features]

# 标准化数据（特征缩放）
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 指定聚类数量和模糊度（模糊度越高，越接近FCM，通常在1.1到2.0之间）
num_clusters = 3
m = 1.5 # 模糊度参数，您可以根据需要调整

# 执行FCM聚类
cntr, u, u0, d, jm, p, fpc = fuzz.cluster.cmeans(
    X_scaled.T, num_clusters, m, error=0.005, maxiter=1000, init=None)

# 将隶属度矩阵转换为簇标签
cluster_labels = np.argmax(u, axis=0)

# 将聚类标签添加到数据集
data['cluster_fcm'] = cluster_labels

# 绘制聚类结果和簇中心
plt.figure(figsize=(10, 6))
colors = ['r', 'g', 'b', 'c', 'm']
for cluster_id in range(num_clusters):
    cluster_data = data[data['cluster_fcm'] == cluster_id]
    plt.scatter(cluster_data['发病到检查时间'], cluster_data['ED_volume'], label=f'Cluster {cluster_id + 1}', c=colors[cluster_id])

# 绘制聚类中心点
for i, center in enumerate(cntr):
    plt.scatter(center[7], center[8], marker='x', s=200, c='k', label=f'Centroid {i + 1}')

plt.xlabel('发病到检查时间')
plt.ylabel('ED_volume')
plt.title('FCM聚类可视化')
plt.legend()
plt.show()
```

附录 6

介绍：问题 2c

```
import numpy as np
from sklearn.metrics import r2_score
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
import matplotlib.pyplot as plt

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

model = RandomForestRegressor(random_state=42)
model.fit(X_train, y_train)

# 2. 计算原始性能
y_pred = model.predict(X_test)
original_performance = r2_score(y_test, y_pred)

# 3. 对特征进行排列并计算性能差异
feature_names = X.columns
feature_importance = {}

for feature in feature_names:
    X_test_permuted = X_test.copy()
    X_test_permuted[feature] = np.random.permutation(X_test_permuted[feature])
    y_pred_permuted = model.predict(X_test_permuted)
    permuted_performance = r2_score(y_test, y_pred_permuted)
    feature_importance[feature] = original_performance - permuted_performance

# 4. 输出每个特征的 Permutation Importance 分数值
for feature, importance_score in feature_importance.items():
    print(f"Feature: {feature}, Permutation Importance Score: {importance_score}")

# 5. 可视化重要性并在图上显示分数值
sorted_features = sorted(feature_importance.items(), key=lambda x: x[1], reverse=True)
sorted_feature_names, sorted_feature_scores = zip(*sorted_features)

plt.figure(figsize=(18, 6))
plt.barh(sorted_feature_names, sorted_feature_scores, alpha=0.5, color='skyblue')
plt.xlabel('Permutation Importance')
plt.ylabel('Feature')
plt.title('Permutation Importance for Features')

# 在图上显示分数值
for i, v in enumerate(sorted_feature_scores):
    plt.text(v, i, f' {v:.4f}', color='blue', va='center', fontsize=12)

plt.show()
```


附录 7

介绍：问题 2d

```
import pandas as pd
from scipy.stats import f_oneway
import warnings
warnings.filterwarnings("ignore")

treatment_columns = ['脑室引流', '止血治疗', '降颅压治疗', '降压治疗', '镇静、镇痛治疗', '止吐护胃', '营养神经']
hm_volume = data['HM_volume']
ed_volume = data['ED_volume']

anova_results = pd.DataFrame(columns=['Treatment', 'F-statistic', 'p-value'])

# 遍历每个治疗方法，执行方差分析
for treatment in treatment_columns:
    grouped_data = [hm_volume[data[treatment] == 1], ed_volume[data[treatment] == 1]]
    f_statistic, p_value = f_oneway(*grouped_data)
    anova_results = anova_results.append({'Treatment': treatment, 'F-statistic': f_statistic, 'p-value': p_value}, ignore_index=True)

print(anova_results)
```

附录 8

介绍：问题 3a

```
import matplotlib.pyplot as plt

fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(15, 6))

axes[0].hist(y_pred, bins=7, alpha=0.5, color='blue', label='Predicted')
axes[0].hist(y, bins=7, alpha=0.5, color='green', label='Actual')
axes[0].set_xlabel('Class')
axes[0].set_ylabel('Frequency')
axes[0].set_title('Predicted vs. Actual Class Distribution')
axes[0].legend()

axes[1].scatter(y, y_pred, color='blue')
axes[1].plot([min(y), max(y)], [min(y), max(y)], linestyle='--', color='red')
axes[1].set_xlabel('Actual')
axes[1].set_ylabel('Predicted')
axes[1].set_title('Actual vs. Predicted')

plt.tight_layout()
plt.show()
```