



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 安徽大学

参赛队号 23103570015

1.李嘉贝

队员姓名 2.李亚男

3.赵雪倩

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

题 目： E 出血性脑卒中临床智能诊疗建模

摘 要：

出血性脑卒中会对患者的生理机能造成严重影响，甚至危及生命，如何帮助医疗团队进行科学的临床决策引起了人们的重视。本文围绕基于出血性脑卒中患者的预后诊疗问题的研究建立了数学模型。

针对问题一：在该问题中，主要探讨了影响患者们陷入血肿扩张事件的因素。先基于流水号进行数据匹配，基于时间差算法解析时间戳，利用特征缩放消除量纲。用 SQL 计算绝对(相对)体积的变化，若发生血肿扩张且在 48 小时内便记录时间。再基于患者的各项数据先后进行特征工程与相关性分析，认为高血压等特征最为影响血肿扩张。建立梯度提升模型来预测发生血肿扩张的概率，并用交叉验证进行参数调优，模型的召回率为 96.8%，精确率为 94.3%。

针对问题二：在该问题中，主要探讨了患者们水肿体积的进展模式。先基于标准差剔除异常数据，再基于时间序列模型，最小角回归和高斯模型建立了四阶 OLS 多项式，二阶 LAR 多项式和三高斯函数去拟合全体患者水肿体积变化，计算残差。对各时间点的水肿体积做相关性分析，进而基于水肿体积进行 k-means 聚类分析，基于肘部法认定类簇为 4，轮廓系数为 0.849。利用 matlab 对四簇分别建模多项式和高斯拟合，计算四类人群的水肿残差。基于 logistic 回归将水肿进展模式二分类，用 critic 权重法对交互的治疗方案赋权，基于主成分分析法认为降颅压治疗、降压治疗和止血治疗更重要。基于 Pearson 相关系数和随机森林分析治疗方法与水肿及血肿体积的关系，认为这三者之间相互影响。

针对问题三：在该问题中，主要探讨了出血性脑卒中患者预后预测问题。基于患者各项数据与 mRS 评分进行相关性分析与主成分分析，筛选特征建立决策树模型预测全部患者 90 天 mRS 评分，模型的 RMSE 为 0.355。基于特征工程建立支持向量回归模型预测所有含随访影像检查的患者的 90 天 mRS 评分，模型的 RMSE 为 0.457。分别从文献角度和多元线性回归模型角度判断预后和各项特征之间的关联关系，认为戒烟、适度饮酒等对预后有正向作用，高血压等对预后负有负向作用，并综合提出建议，如个性化诊疗、风险管理、长期随访等。

关键词： 出血性脑卒中，时间序列，梯度提升，随机森林，决策树

目 录

一、问题重述	1
1.1 问题背景	1
1.2 问题提出	1
二、问题一的模型建立与求解	3
2.1 问题一(a)的分析与思路	3
2.2 数据预处理	4
2.3 绝对体积变化	6
2.4 相对体积变化	10
2.5 问题一(b)的分析与思路	15
2.6 数据预处理	16
2.7 相关性分析	17
2.8 梯度提升模型	26
2.9 结果展示	30
三、问题二模型建立与求解	33
3.1 问题二(a)的分析与思路	33
3.2 数据预处理	33
3.3 建立时间序列模型	36
3.4 高斯函数模型	40
3.5 计算残差	41
3.6 问题二(b)的分析与思路	41
3.7 聚类分析	41
3.8 建立模型并评价	44
3.9 问题二(c)的分析与思路	48
3.10 治疗方法对水肿进展模式的影响	48
3.11 主成分分析	56
3.12 问题二(d)的分析与思路	58
3.13 血肿体积、水肿体积及治疗方法间的关系	58
3.14 决策树模型	61
3.15 随机森林模型	65
四、问题三的模型建立与求解	68
4.1 问题三(a)的分析与思路	68
4.2 基于首次影像的 90 天 mRS 评分预测模型	68
4.3 相关性分析	71
4.4 主成分分析	76
4.5 构建预测患者 90 天 mRS 评分模型	80
4.6 模型建立	81
4.7 问题三(b)的分析与思路	88
4.8 数据预处理	88
4.9 支持向量回归模型	89
4.10 模型性能评估	93
4.11 问题三(c)的分析与思路	94
4.12 研究目的与意义	95

4.13 文献综述	96
4.14 基于多元线性回归模型分析出血性脑卒中患者的预后关联因素	107
4.15 建议	110
五、方法评价	112
5.1 优点	112
5.2 缺点	112
参考文献	113
附录一 代码	115
附录二 答案文件	127

一、问题重述

1.1 问题背景

出血性脑卒中是一种脑部疾病，其发病机制与脑实质内血管破裂有关，占据脑卒中患者的 10-15%。该病的病因复杂，通常是由于脑动脉瘤的破裂或脑动脉的异常等原因导致的，这会导致血液从破裂的血管中流入脑组织，从而引发脑部机械性损伤，同时也会触发一系列生理病理反应。出血性脑卒中的特点包括病情迅速发展，预后较差，急性期内的病死率高达 45-50%。此外，大约 80% 的患者会在疾病后遗留较为严重的神经功能障碍，这对患者本人和其家庭都带来了沉重的身体和经济负担。因此，了解出血性脑卒中的发病风险，整合医学影像学特征、患者的临床信息以及治疗方案，精确地预测患者的预后，并根据这些信息来优化临床决策，具有非常重要的临床意义。

在出血性脑卒中后，血肿范围的扩大是导致不良预后的重要危险因素之一。在出血发生后的短时间内，血肿范围可能会逐渐扩大，原因包括脑组织受损和炎症反应等因素，这会导致颅内压力急剧升高，进而导致患者神经功能的进一步恶化，甚至威胁患者的生命。因此，监测和控制血肿的扩张是临床上关注的一个重要方面。另外，血肿周围的水肿在近年来引起了广泛关注，因为它作为脑出血后继发性损伤的标志之一，可能导致脑组织受压，从而影响神经元功能，使脑组织进一步受损，进而加重患者神经功能障碍。因此，早期识别和预测血肿扩张和血肿周围水肿的发生和发展对于改善患者的预后和提升其生活质量至关重要。

医学影像技术的迅猛发展为无创动态监测出血性脑卒中后脑组织损伤和演变提供了有力工具。近年来，人工智能技术在医学领域得到广泛应用，为深度挖掘和智能分析大量医学影像数据带来了新机遇。我们希望能够基于本赛题提供的影像信息，结合患者的个人信息、治疗方案和预后等数据，构建智能诊疗模型。这个模型能够明确导致出血性脑卒中预后不良的危险因素，实现个性化的疗效评估和预后预测。我们相信，相关研究成果将来会应用于临床实践，为改善出血性脑卒中患者的预后作出贡献。

1.2 问题提出

基于上述研究背景，题目中提供了 160 例（100 例训练数据集+60 例独立测试数据集）出血性脑卒中患者的个人史、疾病史、发病及治疗相关信息、多次重复的影像学检查（CT 平扫）结果及患者预后评估数据，本文需要解决以下三个问题：

问题 1：血肿扩张风险相关因素探索建模。

a) 结合患者临床数据以及血肿、水肿的体积位置数据，判断患者 sub001 至 sub100 是否在发病后 48 小时内发生血肿扩张事件；

b) 结合患者临床数据、血肿的体积位置数据以及血肿形状与位置分布数据，以是否发生血肿扩张事件为目标变量，构建模型预测所有患者发生血肿扩张的概率。

问题 2：血肿周围水肿的发生及进展建模，并探索治疗干预和水肿进展的关联关系。

a) 结合患者水肿的体积位置数据，构建一条全体患者水肿体积随时间进展曲线，并计算前 100 个患者真实值和拟合值之间的残差；

b) 探索患者水肿体积随时间进展模式的个体差异，构建不同人群的水肿体积随时间进展曲线，计算前 100 个患者真实值和拟合值之间的残差；

c) 结合患者列表及临床信息数据、水肿体积变化数据，分析不同治疗方法对水肿体积进展模式的影响。

d) 分析血肿体积、水肿体积及治疗方法三者之间的关系。

问题 3：出血性脑卒中患者预后预测及关键因素探索

a) 结合前 100 个患者的个人史、疾病史、发病相关及首次影像结果数据构建预测模型，预测 160 名患者的 90 天 mRS 评分；

b) 结合前 100 个患者所有已知临床、治疗及所有影像（首次+随访）结果，预测所有含随访影像检查的患者的 90 天 mRS 评分；

c) 分析出血性脑卒中患者的预后（90 天 mRS）和个人史、疾病史、治疗方法及所有影像特征的关联关系，并为临床相关决策给出建议。




图 1 研究方法与技术路线图

二、问题一的模型建立与求解

2.1 问题一(a)的分析与思路

问题一分为两个部分，首先是对前一百名患者是否在发病后 48 小时内发生血肿扩张事件的判断和记录，接着是构建模型来预测所有患者发生血肿扩张的概率。问题一(a)涉及血肿扩张事件的判断，需要进行数据预处理和分析患者的血肿绝对/相对体积变化。

2.1.1 建模思路

第一步:对于血肿扩张事件的判断，需要进行数据预处理。这一过程包括数据整合、缺失值处理、时间特征处理、单位标准化以及量纲一致性的确保。

第二步:我们分析患者的血肿绝对体积的变化，以确定是否发生血肿扩张。具体地，我们将检查后续时刻的血肿体积，如果相对于首次检查的绝对体积增加了至少 6 毫升，则判定为血肿扩张。

第三步:我们对患者的血肿相对体积变化进行分析，以进一步判断血肿是否扩张。如果后续检查中血肿相对于首次检查的相对体积增加了至少 33%，则视为血肿扩张。

第四步:将绝对体积变化和相对体积变化进行数据可视化处理，以进行比较分析。

第五步:最后，我们将判断前一百名患者是否在发病后 48 小时内发生血肿扩张事件，并记录相应的时间。




图 2 问题一流程图

2.1.2 血肿扩张事件判断

血肿扩张指的是在脑出血的情况下，血肿的体积在一段时间内逐渐增大的现象。脑出血是一种非外伤性的脑部疾病，通常由于脑动脉瘤破裂、脑动脉异常等因素引起脑组织内的血管破裂，导致血液渗入脑组织。当血液进入脑组织后，它形成了一个血肿，这是血液在脑组织中的局部聚集。血肿扩张意味着血肿的大小

会随着时间的推移而增加。这是一个危险的现象，因为血肿的增大可能导致颅内压增加，使神经功能恶化，进而危害到生命。因此，监测和控制血肿的扩张对于脑出血患者的治疗和预后非常重要。如果发现血肿扩张，可能需要采取紧急措施，如手术或药物治疗，以减轻颅内压力和保护脑组织。因此，对血肿扩张的早期识别和管理对于改善脑出血患者的预后至关重要。




图 3 血肿

2.2 数据预处理

在本研究中，数据预处理是构建可靠分析模型的关键步骤之一。原始数据的质量和准确性对于我们的研究结果具有至关重要的影响。因此，我们将在接下来的部分中详细介绍数据预处理的过程，包括数据准备和数据处理等关键步骤。通过这些预处理措施，我们将确保数据的一致性，消除噪音，使其适合用于后续的分析 and 建模，以揭示有关血肿扩张风险相关因素的重要信息。

2.1.1 数据准备

根据患者列表及临床信息表中的入院首次影像检查流水号、发病到首次影像检查时间间隔，以及患者影像信息血肿及水肿的体积及位置表中的各时间点流水号及对应的 HM_volume，经过系统整理与归纳，构建一个全新的数据表。此表涵盖了患者 sub001 至 sub100 的详尽信息。同时，借助附表 1 中的数据，根据影像检查流水号精确地检索并记录相应的影像检查时间点。




图 4 数据准备

2.1.2 缺失值处理

对于部分患者缺乏 HM_volume 的数据，我们采用 0 进行填充，以确保数据的完整性和一致性。

2.1.3 处理时间特征

在时间数据的高级预处理中，我们采用了一种先进的时间序列处理算法，以确保数据的精确性和可用性。




图 5 算法步骤

首先，我们从原始数据中提取时间戳信息，这些时间戳以"年/月/日 时:分:秒"的标准格式表示。通过解析这些时间戳，我们获得了日期和时间的具体值，包括年、月、日、小时、分钟和秒。

一旦获得了日期和时间的具体值，我们使用高级的时间格式转换算法，将时间表示形式从标准的"年/月/日 时:分:秒"格式转换为"年/月/日 时"的形式。这一转换过程不仅包括时间单位的改变，还包括将分钟转换为小时，以便更好地表示时间间隔。

在获得新的时间表示形式后，我们使用高级时间差计算算法，计算每位患者的多次检查时间点之间的精确时间间隔。这些时间间隔以小时为单位表示，允许我们更精确地记录血肿扩张事件的发生时间。

最后，我们进行数据一致性检查，以确保转换和计算过程没有引入错误或不一致性。这包括检查是否存在时间上的逻辑错误，如时间点的顺序是否正确等。

这一时间数据预处理过程不仅有助于准确记录血肿扩张事件的发生时间，还为后续数据分析提供了更方便和可操作的时间间隔数据。通过采用这种算法，我们能够更好地理解和分析时间数据，为研究提供了更多深入和准确的见解。

此外，根据题目要求，我们需要判断患者 sub001 至 sub100 是否在发病后 48 小时内发生了血肿扩张事件。因此，我们基于处理后的时间数据，将超过 48 小时的患者数据进行了删除，以确保分析的准确性和一致性。




图 6 时间间隔转换

1.1.4 单位标准化

将 HM_volume 数据的单位从 10^{-3} ml 转变为以 ml 为单位，将原始数据中的数值转换为统一的单位，以确保数据具有一致的度量尺度。这样可以为后续绝对体积的计算提供便利。

1.1.5 消除量纲

在数据预处理的过程中，消除量纲（Normalization）是一项关键步骤，旨在

确保不同特征之间的数值范围相互匹配，以使机器学习模型能够更有效地学习数据的模式并进行准确的预测。量纲不一致可能会导致某些特征在模型中具有不合理的权重，从而降低模型的性能。因此，我们需要采取一些方法来确保数据的量纲一致性。

在数据集中，不同的特征通常具有不同的度量单位和数值范围。例如，一个特征可能表示身高，以厘米为单位，而另一个特征可能表示体重，以千克为单位。这两个特征的数值范围差异很大，可能导致模型在学习时偏向于数值范围较大的特征。

为了解决这个问题，我们通常会采用以下方法来消除量纲：

(1) 极差法

将特征的值缩放到一个指定的范围内，通常是 $[0, 1]$ 或 $[-1, 1]$ 。这种方法适用于大多数数据分布。

(2) 标准化

将特征的值缩放成均值为 0、标准差为 1 的正态分布。它对于某些算法（如支持向量机和 K 均值聚类）的性能有显著影响。

(3) 正则化

正则化方法将特征的值限制在一定范围内，以防止过大或过小的数值。这有助于模型更稳定地学习数据的模式，并减少过拟合的风险。




图 7 量纲影响图

本题采用极差法来消除量纲的影响。

2.3 绝对体积变化

在本节中，我们将详细探讨绝对体积差值分析作为一种评估血肿扩张的方法。血肿扩张在脑卒中患者中是一个重要的临床问题，准确的评估方法对于患者的治疗和预后至关重要。本节将介绍我们的分析方法，包括绝对体积差值的计算和其在脑卒中研究中的应用。

1.2.1 绝对体积

通常，我们根据血肿体积的变化来判断是否发生了血肿扩张事件，其具体定义为：后续检查中血肿的体积相对于首次检查的体积，增加了至少 6 毫升 (mL)，或者相对体积增加了至少 33%。绝对体积增加指的是在后续检查中，血肿的实际体积增加了一定数量的血液。

1.2.2 绝对体积的临床研究

绝对体积变化在脑卒中研究和患者管理中具有关键的临床和科研价值。它是一项快速检测血肿扩张的重要指标，有助于医生及时发现可能需要紧急处理的情况。脑卒中患者通常接受多种治疗方式，包括手术和药物治疗等。通过监测血肿的绝对体积变化，可以有效评估治疗的效果。如果血肿在治疗后持续增大，可能需要重新评估治疗方案，以更好地满足患者的需求。

值得注意的是，不同患者对血肿扩张的反应各异。有些患者可能对微小的血肿扩张更为敏感，而其他一些患者可能需要更大的体积变化才会出现症状。绝对体积变化的测定为医生提供了有力的依据，帮助他们制定更加个体化的治疗策略，根据每位患者的特殊情况来调整治疗计划，以最大程度地提高治疗的成功率和患者的生活质量。

因此，绝对体积变化不仅在临床医疗实践中具有重要意义，还在脑卒中研究领域发挥着关键作用。它为改善患者的治疗效果和预后提供了有力的支持，为脑卒中领域的进一步发展和研究提供了宝贵的数据和见解。




图 8 临床治疗图

1.2.3 绝对体积计算公式

绝对体积计算的标准公式基于血肿的形状。对于球形或近似球形的血肿，通常使用球体体积计算公式：

$$V = \frac{4}{3}\pi R^3 \quad (1)$$

其中， V 表示血肿的绝对体积（单位：毫升，mL）； π 是数学常数，约等于3.14； R 是血肿的半径（单位：毫米，mm）。

对于不规则形状的血肿，可以使用图像处理软件来测量每个切片的面积，然后将各个切片的面积累加以得到绝对体积。




图 9 绝对体积计算

1. 2. 4 绝对体积差值计算

我们的分析方法的关键部分是绝对体积差值的计算。这一步骤涉及到对患者血肿体积的测量，从首次检查到后续检查的时间点，我们计算了血肿的实际体积变化。这种方法有助于我们判断血肿是否在扩张，并且衡量了其扩张的程度。

绝对体积差值计算是通过对比血肿体积的两次测量进行比较来实现的。具体而言：

从首次检查中获取血肿的体积 $HM_volume(v1)$ 和入院首次检查时间点 ($t1$)。

从后续检查中获取血肿的体积 $HM_volume(v2)$ 和随访时间点 ($t2$)。

绝对体积差值 = $|v2 - v1|$

在这里我们选择了 6 毫升 (mL) 作为绝对体积变化的阈值，以确定是否发生血肿扩张事件。这个阈值的选择基于多方面的考虑。首先，它是临床实践中被广泛接受的标准，已经在多项研究中得到验证。其次，6 毫升的绝对体积变化通常足以引起医生的关注，并可能需要进一步的评估和处理。最后，这个阈值的选择是基于早期发现血肿扩张的需求，以便及时采取必要的治疗措施。




图 10 绝对体积差值

1. 2. 5 绝对体积差值结果

绝对体积差值是一项关键的指标，用于评估血肿扩张事件。对于能够在 48 小时内判断是否发生血肿扩张的患者，我们在下表中进行了展示。

表 1 绝对体积血肿表

患者	绝对体积变化(相比入院首次检查时间点)
sub003	19.646
sub005	9.64
sub009	15.272
sub017	9.102
sub033	9.828
sub036	35.744
sub038	6.471
sub039	10.767
sub048	12.373
sub054	12.167

sub057	15.117
sub060	27.462
sub061	8.949
sub076	10.079
sub077	36.62
sub079	6.151
sub080	8.486
sub081	15.298
sub092	48.691
sub095	17.507
sub098	26.495
sub099	20.84

在上表中的两列分别展示了血肿患者以及对应的相比入院首次检查时间点的患者的血肿的绝对体积变化(单位: ml)。观察数据可发现, 各患者的绝对体积变化差异较大, 其数值范围从 6.151 ml 到 48.691 ml 不等。这意味着在相同的时间跨度内, 不同患者的血肿扩张程度存在显著差异。一些患者的血肿体积增加相对较小, 而另一些患者的血肿可能经历了显著的扩张。这些数据的解释对于脑卒中研究和患者管理非常重要。绝对体积变化可作为一个关键的指标, 用于评估血肿扩张的程度, 进而指导患者的治疗和康复计划。不同患者对血肿扩张的反应各异, 因此在制定个性化的治疗策略时, 需要考虑这些差异。这些数据还可以为进一步的分析和研究提供有价值的信息, 有助于更好地理解脑卒中的发病机制和治疗效果。

为了更清晰地理解这一指标的分布和趋势, 我们进行了一系列的数据可视化分析, 具体如下所示。




图 11 比例图(全体)和直方图(血肿患者)




图 12 箱线图(血肿患者)和散点图(血肿患者)




图 13 核密度图(血肿患者)和概率密度图(血肿患者)




图 14 概率密度图(全体)和核密度图(全体)

通过直方图、箱线图等图表展示，我们可以看到绝大多数数据点都未达到定义的血肿扩张阈值。这表明，在规定的 48 小时的时间范围内，大部分患者的血肿没有明显扩张。从散点图、箱线图、密度图等可视化图表中，我们可以观察到不同患者之间的绝对体积变化存在明显差异。数据点分布的广度或分散性表明不同患者对血肿扩张的反应各异，反映了这种疾病的个体差异性。

2.4 相对体积变化

在本节中，我们将详细探讨相对体积差值分析作为一种评估血肿扩张的方法。

血肿扩张在脑卒中患者中是一个重要的临床问题，准确的评估方法对于患者的治疗和预后至关重要。本节将介绍我们的分析方法，包括相对体积差值的计算和其在脑卒中研究中的应用。

在相对体积差值分析中，我们关注的是血肿体积在不同时间点的变化，而不是仅仅关注绝对的体积数值。这种方法有助于消除个体之间血肿初始体积的差异，更加关注血肿的扩张趋势。通过计算相对体积差值，我们可以更敏锐地捕捉到血肿的生长情况，从而提供更精确的评估。

在接下来的内容中，我们将详细介绍如何计算相对体积差值，并解释其在脑卒中研究中的重要性。我们将探讨相对体积差值分析在区分血肿扩张患者和非扩张患者、评估治疗效果以及个体化治疗方案制定中的应用。这一分析方法将有助于深入理解血肿扩张的动态过程，为脑卒中患者的管理和疾病研究提供更多有价值的信息。

1.3.1 相对体积

相对体积是指一个物体或者组织在不同时间点或条件下的体积变化相对于其初始体积的比例或差异。在医学和科学研究中，相对体积通常用于描述某一物体或组织的扩张、收缩或增长情况。在脑卒中研究中，相对体积常常用于分析脑血肿的变化情况。通过测量脑血肿在不同时间点的体积，并将其与初始体积进行比较，可以得出血肿的相对体积变化。这有助于医生更准确地了解脑血肿的生长速度和趋势，以及患者的治疗反应。

相对体积分析还可以用于其他领域，如生物学、地质学和工程学等，用来研究各种物质和结构的体积变化。通过监测相对体积，研究人员可以更好地理解物质的性质和行为，从而为科学研究和应用领域提供有关变化过程的重要信息。

1.3.2 相对体积的临床研究

相对体积变化是一项在脑卒中研究中备受关注的临床参数。这一参数通常用于评估脑血肿扩张的程度和速度，对于患者的治疗和预后具有重要的临床价值。相对体积变化通过比较脑血肿在不同时间点的体积差异，帮助医生更准确地了解血肿的发展趋势，从而能够更及时地采取治疗措施。

脑卒中患者通常接受不同类型的治疗，包括手术干预、药物治疗等。因此，了解脑血肿的相对体积变化对于评估治疗效果至关重要。当脑血肿的相对体积在治疗过程中持续增加时，这可能表明治疗策略需要重新考虑，以更好地满足患者的需求。

需要注意的是，不同患者对于相对体积变化的敏感度可能存在差异。有些患者可能对微小的变化更为敏感，而另一些可能需要更大的变化才会表现出症状。因此，相对体积变化的测量为医生提供了个体化治疗策略的依据，以根据每位患者的独特情况来调整治疗计划，最大程度地提高治疗的成功率和患者的生活质量。

1.3.3 相对体积计算公式

相对体积计算公式是基于对脑血肿在不同时间点的体积测量，通过比较不同时间点的血肿体积，以确定其相对变化程度。这一相对变化的计算可以帮助医生更全面地了解血肿的发展情况。一般情况下，相对体积计算公式如下：

$$\text{相对体积} = \frac{\text{后续时间点的血肿体积} - \text{首次时间点的血肿体积}}{\text{首次时间点的血肿体积}}$$




图 15 相对体积图

在这个公式中，首次时间点的血肿体积表示脑血肿在首次检查时的体积，后续时间点的血肿体积则表示在后续的检查中测量得到的血肿体积。通过这个计算公式，我们可以得到一个相对值，用以表示血肿在不同时间点的体积变化情况。

通常情况下，如果相对体积的计算结果达到一定的阈值（如相对体积增加了一定百分比或绝对体积增加了一定数量），则可以判定为血肿扩张事件的发生。这个阈值的设定通常依赖于具体的研究和临床需求，可以根据不同的情况进行调整。在本文中，选择相对体积增加 $\geq 33\%$ 即为发生血肿扩张。

1.3.4 相对体积差值结果

相对体积差值是一项关键的指标，用于评估血肿扩张事件。对于能够在 48 小时内判断是否发生血肿扩张的患者，我们在下表中进行了展示。

表 2 相对体积变化表

患者	相对体积变化(相比于首次入院检查血肿体积)
sub005	0.65
sub009	0.37
sub017	0.35
sub033	1.82
sub036	1.30
sub038	0.4
sub048	0.33
sub057	0.58
sub060	0.71
sub070	0.46
sub076	0.61
sub077	0.42
sub079	0.94
sub081	0.37
sub092	3.06
sub095	0.96
sub099	0.56

这些数据表示了一组血肿患者的相比于首次入院检查血肿体积的血肿相对体积变化。我们将 0.33 作为判断是否发生血肿扩张的阈值。如果相对体积变化超过 0.33，我们通常会认为发生了显著的血肿扩张。

与之前的绝对体积数据相比较,这些相对体积的变化数据显示了不同的血肿扩张情况。在某些患者中,相对体积变化超过了 0.33,表明血肿发生了显著的扩张,可能需要进一步的处理。而在其他患者中,相对体积变化较小,可能表明血肿的扩张情况相对较轻。

同时,通过对比相对体积变化表和绝对体积变化表,我们可以观察到一些有趣的现象,进一步深化了对血肿扩张事件的理解。具体来说:

I. 绝对体积超过阈值,相对体积未超过阈值:在某些情况下,患者的绝对血肿体积可能明显增加,超过了阈值,但相对体积变化却未达到阈值。这表明这些患者的血肿可能在相对较短的时间内迅速扩大,但相对于首次检查时的体积,变化幅度较小。例如,患者 sub080、sub098、sub061、sub003、sub054 和 sub039 属于这一类别。

II. 相对体积超过阈值,绝对体积未超过阈值:反之,还有一些情况下,患者的相对体积变化可能超过了阈值,但其绝对血肿体积并未达到阈值。这可能意味着这些患者的血肿虽然在相对体积上有显著的变化,但从绝对体积角度看,其绝对体积变化幅度相对较小。例如,患者 sub070 属于这一类别。

这些观察结果强调了个体差异和复杂性在血肿扩张事件中的作用。血肿扩张不仅受到绝对体积的影响,还受到相对体积的变化和其他因素的综合影响。因此,在评估血肿扩张时,需要综合考虑这些不同维度的信息,以便更准确地了解患者的情况和制定相应的治疗策略。在临床实践和研究中,这些发现为深入探讨血肿扩张机制和个体化治疗提供了有益的见解。这些相对体积变化数据为医生提供了有关患者血肿扩张情况的重要信息,有助于指导治疗决策和干预措施。同时,与绝对体积数据一起分析,可以更全面地评估患者的病情和治疗效果。

为了进一步的对这些结果进行展示,我们进行了一系列的数据可视化分析,具体如下所示。




图 16 比例图(全体)和直方图(血肿患者)




图 17 箱线图(血肿患者)和散点图(血肿患者)




图 18 核密度图(血肿患者)和概率密度图(血肿患者)




图 19 核密度图(全体)和核密度图(全体)

从相对体积差值分布图中我们可以看出，在这 100 个患者中，相对体积差值的分布呈现出一定的差异。大部分患者的相对体积差值较低，接近于 0，表明他们的血肿没有明显扩张。然而，也有一些患者的相对体积差值明显高于 0，这表明他们可能在 48 小时内发生了血肿扩张。箱线图显示了相对体积差值的分布范围，以及异常值的存在。通过这个图表，我们可以更清晰地看到相对体积差值的中位数、上下四分位数以及异常值的情况。这有助于进一步了解患者群体中相对体积差值的变异性。散点图展示了每位患者的相对体积差值，同时也反映了不同患者之间的个体差异。通过这个图表，我们可以观察到是否存在某些患者的相对体积差值明显高于其他患者，从而有助于识别潜在的血肿扩张情况。核密度估计图展示了相对体积差值的概率密度分布，可以帮助我们更好地理解相对体积差值

的集中区域和分布情况。通过这个图表，我们可以确定相对体积差值的主要集中区域。

这些分析结果有助于我们更深入地理解血肿扩张的情况，为患者的治疗和管理提供了重要的参考信息。同时，与之前的绝对体积数据进行比对，可以进一步加强对患者血肿情况的综合评估。

2.5 问题一(b)的分析与思路

对问题一(b)建立梯度提升模型，评估与血肿扩张相关的特征，预测患者血肿扩张的概率，并最终呈现模型的预测结果。

2.5.1 建模思路

第一步:首先需要进行数据预处理。这包括数据清理与合并、数据集划分和特征数据准备。

第二步:进行相关性分析，以确定个人史、疾病史、发病相关特征、影像检查结果以及每个时间点血肿的形状和灰度特征与患者是否发生血肿扩张之间的关联程度。

第三步:建立梯度提升模型，并进行模型参数调优，以预测患者是否会发生血肿扩张事件的概率。

第四步:对所建立的梯度提升预测模型进行性能指标的展示，并展示特征的重要性。

第五步:展示模型的预测结果。

2.5.2 建模意义

进行血肿扩张事件的预测在医学领域中具有极其重要的意义。首先，血肿扩张是脑卒中患者所面临的严重临床问题。能够在早期及时准确地预测血肿扩张的发生，有助于医生采取及时有效的治疗干预措施，最大程度地降低患者的健康风险。此外，通过血肿扩张的预测，医生能够为每位患者量身定制个性化的治疗方案。因为不同患者对血肿扩张的敏感性各不相同，因此能够根据预测结果进行个性化治疗，更好地满足患者的独特需求。

及时预测血肿扩张还有助于医生全面评估治疗的效果。如果在治疗后血肿继续扩张，就需要重新评估治疗方案，以提高治疗的成功率和患者的康复情况。此外，通过预测血肿扩张，可以避免不必要的医疗检查和治疗干预措施，从而降低了医疗成本，并减轻了患者和医疗系统的负担。

另外，血肿扩张事件的预测还为脑卒中领域的疾病研究提供了宝贵的数据和见解。通过分析大规模的患者数据，可以更深入地理解血肿扩张的机制和规律，从而推动相关研究的进展。总的来说，血肿扩张事件的预测不仅可以挽救生命、改善患者的生活质量，还能够降低医疗费用，促进医学研究的不断发展。因此，这一预测任务在医学领域中具有极为重要的临床和科研价值。

在这一章节，我们将基于之前的绝对体积插值和相对体积差值的分析，来探讨哪些患者可能患有血肿。血肿是脑卒中患者中的一个关键临床问题，及时准确地诊断和预测血肿的发生对患者的治疗和康复至关重要。根据血肿扩张的定义，即后续检查比首次检查绝对体积增加 ≥ 6 mL 或相对体积增加 $\geq 33\%$ ，我们将前两个小节的探索结果做了总结，将相应的血肿患者及其扩张的时间记录在了答案文件表中。这有助于我们建立一个完整的患者血肿信息数据库，为后续的分析

预测提供了基础数据。

2.6 数据预处理

2.6.1 数据清理与合并

首先，根据“表 1”和“表 2”的患者名称，将“表 1”前 100 例患者（sub001 至 sub100）的个人史（年龄、性别、吸烟史和饮酒史）、疾病史（脑出血前 mRS 评分、高血压病史、卒病史、糖尿病史、房颤史和冠心病史）、发病相关特征（血压、发病到首次影像检查时间间隔、脑室引流、止血治疗、降颅压治疗、降压治疗、镇静、镇痛治疗、止吐护胃和营养神经），以及“表 2”中其影像检查结果（包含每个时间点血肿（Hemo）总体积及水肿（ED）总体积及不同位置的占比，具体包括左右侧大脑前动脉（ACA_L、ACA_R）、左右侧大脑中动脉（MCA_L、MCA_R）、左右侧大脑后动脉（PCA_L、PCA_R）、左右侧脑桥/延髓（Pons_Medulla_L、Pons_Medulla_R）、左右侧小脑（Cerebellum_L、Cerebellum_R）共十个不同位置的数据）结合成一个新表。

其次，根据新表中每个患者的首次影像检查记录流水号，将“表 3”中的每个时间点血肿的形状及灰度特征（反映目标区域内体素信号强度的分布，包括 17 个字段）以及三维形状的描述（14 个字段）添加至新表中。

这一过程将有助于构建全面的特征集，其中包括患者的个人信息、疾病史、发病相关特征以及影像检查结果，为后续的血肿扩张事件的预测建模提供了丰富的特征。此数据整合过程可提高模型的预测性能和可解释性，使得模型能够更准确地预测患者是否会发生血肿扩张事件。

2.6.2 数据集划分

为了评估我们构建的血肿扩张事件预测模型的性能，我们将患者数据划分为三个不同的集合：训练集、测试集 1 和测试集 2。训练集包含前 100 位患者的数据，测试集 1 包含第 101 位到第 130 位患者的数据，而测试集 2 包含第 131 位到第 160 位患者的数据。

这一划分方式有助于我们在模型训练后进行有效的性能评估。通过在测试集 1 上验证模型的泛化能力，我们可以检查模型是否能够在未见过的数据上进行准确的预测。而测试集 2 则可以用于更严格的评估，以验证模型在更广泛范围内的应用效果。这种划分方法可以帮助我们充分了解模型的性能，以确保其在实际临床应用中的可靠性和准确性。

2.6.3 特征数据准备

特征工程是机器学习和数据分析中至关重要的一步，它涉及到从原始数据中提取、转换和选择特征，以便用于建立模型或进行数据分析。特征工程的目标是改进数据集，使其更适合机器学习模型的训练和性能提升。特征工程可以对最终模型的性能产生重大影响，因此被认为是机器学习中最关键的步骤之一。

对于类别型特征（性别、吸烟史、饮酒史、高血压病史、卒病史、糖尿病史、房颤史、冠心病史），我们进行了标签编码，将其转化为数值特征。其中 0 代表男性，1 代表女性。对于连续型特征（年龄、脑出血前 mRS 评分、血压、发病到首次影像检查时间间隔）可以直接使用，但是需要把血压划分为高血压和低血压两栏。

2.7 相关性分析

先进行相关性分析，以了解不同特征与患者是否发生血肿扩张之间的关系。我们将分别对个人史、疾病史、发病相关特征、影像检查结果、每个时间点血肿的形状及灰度特征与患者是否发生血肿扩张进行相关性分析。

对于个人史，我们可以探究年龄、性别、吸烟史和饮酒史与血肿扩张之间的相关性。这有助于了解个人生活方式和特征与血肿发展的潜在联系。在疾病史方面，我们可以分析脑出血前 mRS 评分、高血压病史、卒病史、糖尿病史、房颤史和冠心病史与血肿扩张之间的相关性。这可以揭示患者既往健康状况与血肿扩张风险的关联。对于发病相关特征，我们可以研究血压、发病到首次影像检查时间间隔以及治疗方式与血肿扩张之间的关系。这有助于了解发病时的生理状态和治疗手段对血肿发展的影响。在影像检查结果方面，我们可以分析血肿总体积、水肿总体积以及不同位置的占比与血肿扩张之间的相关性。这可以帮助我们理解不同影像特征与血肿扩张风险之间的联系。最后，针对每个时间点的血肿的形状及灰度特征，我们可以探究其与血肿扩张之间的相关性。这将揭示血肿形态和灰度分布对扩张风险的影响。通过相关性分析，我们可以识别出与血肿扩张最相关的特征，为建立预测模型提供重要线索和参考。

首先对数据进行正态性检验，由于样本量较少，该正态分布检验主要基于 S-W 检验：

原假设 H_0 ：样本 $x_1, x_2, \dots, x_n$ 服从同一个正态分布

备择假设 H_1 ：样本 $x_1, x_2, \dots, x_n$ 不全都服从同一个正态分布

构造检验统计量：

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (2)$$

其中 $x_{(i)}$ 用括号包含下标索引 i 的；不与 x 混淆，它是第 i 阶统计量，即样本中的第 i 个最小数， $\bar{x}$ 是样本的平均值，常量 a_i 通过公式 (2-3) 得到的：

$$(a_1, a_2, \dots, a_n) = \frac{n^T V^{-1}}{(n^T V^{-1} V^{-1} n)^{\frac{1}{2}}} \quad (3)$$

其中 $m = (m_1, m_2, \dots, m_n)^T$ ， $m_1, m_2, \dots, m_n$ 是统计量的期望值， V 是统计量的协方差，这些统计量独立同分布于标准正态分布。

由上述计算得到的血肿体积随时间变化数据的显著性水平均小于 0.01，拒绝原假设，即患者血肿体积数据服从正态分布。

故下面我们采用 Pearson 相关系数计算血肿体积之间的相关性，相关系数用 ρ 表示：

$$\rho = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}} \quad (4)$$

用来检验数据之间的相关性。

2.7.1 个人史分析

表 3 个人史相关系数表

	血肿扩张	年龄	性别规范化
血肿扩张	1(0.000***)	0.07(0.486)	0.045(0.659)

注：***、**、*分别代表 1%、5%、10%的显著性水平

根据提供的数据，我们对患者的个人史中的年龄和性别与血肿扩张之间进行了 Pearson 相关性分析。结果显示，血肿扩张与年龄之间的相关性较弱，相关系数仅为 0.07，而与性别规范化之间的相关性更为微弱，相关系数为仅 0.045。此外，针对这两个因素的 p 值均高于通常的显著性水平（例如 5%的显著性水平），这表明在这个样本中，年龄和性别规范化与血肿扩张之间的关系不显著。




图 20 个人史分析

综上所述，根据 Pearson 相关性分析的结果，我们可以得出结论，年龄和性别规范化可能不是影响血肿扩张的主要因素。在进一步的研究中，我们需要考虑其他可能影响血肿扩张的因素以更好地理解这一现象。

2.7.2 疾病史分析

表 4 疾病史相关系数表

	血肿 扩张	饮酒史	冠心病史	房颤史	吸烟史	糖尿病 史	卒中病 史	脑出血 前 mRS 评分	高血压 病史
血肿 扩张	1(0.000 ***)	-0.202(0.044**)	0.243(0.015**)	0.202(0.044**)	-0.144(0.154)	0.069(0.495)	0.159(0.129)	-0.106(0.296)	-0.018(0.862)

注：***、**、*分别代表 1%、5%、10%的显著性水平

针对患者的疾病史进行了 Pearson 相关性分析，发现以下关系：

I. 血肿扩张与饮酒史呈负相关 ($r = -0.202$)，意味着患有饮酒史的患者更容易发生血肿扩张。这种关联在统计学上是显著的 ($p = 0.044$ ，显著性水平为 5%)。

II. 血肿扩张与冠心病史呈正相关 ($r = 0.243$)，表明患有冠心病史的患者更

有可能发生血肿扩张。这种关联在统计学上高度显著（ $p = 0.015$ ，显著性水平为 1%）。

III. 血肿扩张与房颤史呈正相关（ $r = 0.202$ ），表明患有房颤史的患者更容易发生血肿扩张。这种关联在统计学上也是显著的（ $p = 0.044$ ，显著性水平为 5%）。

IV. 血肿扩张与吸烟史之间存在负相关性，但相关性较弱（ $r = -0.144$ ），并且在统计学上不显著（ $p = 0.154$ ，显著性水平为 5%）。

V. 血肿扩张与糖尿病史之间存在正相关性，但相关性非常弱（ $r = 0.069$ ），并且在统计学上不显著（ $p = 0.495$ ，显著性水平为 5%）。




图 21 疾病史分析

综合上述结果，疾病史中的饮酒史、冠心病史和房颤史与血肿扩张之间存在一定程度的相关性，而吸烟史和糖尿病史的相关性较弱或不显著。需要进一步研究以确定不同疾病史对诱发脑出血的具体影响和机制。

(1) 高血压病

在原发性脑出血（SICH）的影响因素研究中，所筛选的 138 例 SICH 患者中，高血压和血管瘤是引起 SICH 的主要病因，但是 SICH 患者中血管瘤人数所占比例高于高血压人数所占比例，二者分别占总 SICH 人数的 33.33% 和 56.52%。这可能是由于本研究所收集样本数较少造成的，同时也可能是由于持续高血压造成血管瘤发病率上升引起的。研究发现高血压是引起 SICH 的第一大主要原因。患者高血压状态导致脑动脉内膜表面血管长期承受血流切应力的较大冲击，迫使血压形成涡流，致使血管内皮细胞损伤、脱落或通透性增加，促进微动脉瘤的形成。在这一特殊条件下，血压的骤然升高则极易诱发破裂出血，而且血压与不良预后呈显著正相关性^[8,9]。海绵状的血管瘤常伴有混合结缔组织的异常毛细血管破裂，每年再出血风险高达 4.5%^[9]。

高血压脑出血是继发于高血压的脑实质出血，是由于长期高血压导致脑内小动脉管壁发生变性、缺血、坏死、微小动脉瘤形成等病理改变，通常在情绪激动、过度兴奋、排便、屏气用力或精神紧张时发病。脑出血前常无预感，突然发生，起病急骤，往往在数分钟到数小时内发展到高峰。经较长病程发展到严重程度者

较为少见。该病起病急、发病迅速，并且致残、致死率均较高，对患者生命健康造成严重威胁。高血压性脑出血（hypertensive intracerebral hemorrhage, HICH）在脑血管疾病中致死率、致残率均较高，其主要病理变化是长期血压升高，导致颅内小动脉玻璃样或纤维样变性，血管壁弹性降低，血管破裂引发出血。脑出血的发病因素较多，其中高血压属于高危因素，血肿量较大的患者需行手术治疗，消除血肿占位，恢复神经功能^[10,11,12]。既往有研究指出^[13]，高血压脑出血患者的死亡率高达 50%，近年来随着人口老龄化的加剧，高血压脑出血的发病率逐年升高，且因该病起病迅速、病情危重，发病后患者多表现出昏迷、偏瘫、失语等症状，预后较差。

(2) 卒中病史^[14]

有学者做了相关研究，回顾性选择 2020 年 1 月~2021 年 6 月威海市立医院神经内科收治的老年 AIS 合并 CMB（脑微出血）患者 113 例，其中男性 70 例，女性 43 例，年龄 60~81(70.73±5.68)岁，根据 CMB 的严重程度分为 CMB 1 级组 19 例，CMB 2 级组 40 例，CMB 3 级组 54 例。CMB 在老年人群及缺血性脑卒中人群中的发生率均较高。60~69 岁老年人群 CMB 发生率为 11%，70~79 岁老年人群 CMB 发生率为 22%，年龄≥80 岁的老年人群 CMB 发生率为 39%。

本研究患者疾病判断均有依据。高血压：既往经临床医师确诊有高血压；或正在服用降压药物；或符合中国高血压防治指南(2018 年修订版)中高血压诊断标准。糖尿病：既往经临床医师确诊有糖尿病史；或正在接受口服降糖药物或胰岛素治疗；或符合 2013《中国 2 型糖尿病防治指南》诊断标准。心房颤动诊断标准依据《欧洲心脏病协会心房颤动管理指南》。吸烟与饮酒判断标准根据 WHO 慢性病调查问卷定义。吸烟：既往连续或累积吸烟≥1 年，平均 1 支/d 以上，截至调查当时戒烟≤10 年。饮酒：既往持续饮酒≥1 年，每周至少饮酒 1 次，截至调查当时戒酒时间<6 个月。

表 5 不同级 CMB 病史比例表

项目	CMB 1 级组 (19 例)	CMB 2 级组 (40 例)	CMB 3 级组 (54 例)	P 值
年龄(岁, $\bar{x} \pm s$)	70.21±5.89	71.45±6.47	70.37±4.99	0.605
男性[例数(%)]	11(57.89)	22(55.00)	37(68.52)	0.379
糖尿病[例数(%)]	9(47.37)	14(35.00)	7(12.96)	0.005
心房颤动[例数(%)]	2(10.53)	3(7.50)	3(5.56)	0.772
吸烟[例数(%)]	3(15.79)	10(25.00)	16(29.63)	0.468
饮酒[例数(%)]	2(10.53)	7(17.50)	19(35.19)	0.037
既往脑卒中[例数(%)]	8(42.11)	10(25.00)	16(29.63)	0.406
高血压[例数(%)]	/	/	/	0.577
无	1(5.26)	8(20.00)	10(18.52)	
1 级	3(15.79)	2(5.00)	4(7.41)	
2 级	9(47.37)	8(20.00)	9(16.67)	
3 级	6(31.58)	22(55.00)	31(57.41)	

以单因素分析结果中 $P \leq 0.1$ 的指标为自变量, 以 CMB 分级为因变量, 有序多分类 logistic 回归分析显示, 糖尿病、饮酒是老年 AIS 患者 CMB 严重程度的危险因素 ($P < 0.05, P < 0.01$)。

表 6 老年 CMB 危险因素

危险因素	B 值	SE	OR 值	95%CI	P 值
糖尿病	-1.167	0.507	0.311	0.115~0.841	0.021
饮酒	1.405	0.534	4.076	1.432~11.612	0.008

上述研究表明, 在患者已有脑卒中史的情况下, 患有糖尿病或者饮酒很有可能诱发患者脑出血。

(3) 糖尿病史^[15]

糖尿病属于常见内分泌系统疾病, 患者具备多饮、多食、多尿、体重减轻等特点。脑出血为神经科常见病与多发病, 疾病发生机制主要为高血压合并小动脉硬化、微血管瘤或微动脉瘤破裂等。糖尿病是一种常见慢性代谢紊乱疾病, 糖尿病患者若长期血糖控制不佳, 极易导致脑乳酸水平增高, 离子代谢紊乱和血脑屏障功能改变, 从而增加脑出血发生风险, 严重威胁患者健康。颅内血肿清除术是脑出血的主要治疗技术, 虽然能够降低患者病死率, 但高血糖容易使患者脑组织水肿加重, 脑细胞无氧代谢增加, 中性粒细胞的杀菌能力减弱, 血小板黏稠度升高, 导致患者术后颅内感染、再出血、栓塞等并发症发生风险加大, 严重影响患者术后康复。脑出血是一种常见脑血管疾病, 急性期病死率为 30%~40%, 其发生发展与糖尿病密切相关, 糖尿病患者的脑出血发生风险是非糖尿病患者的 1.36 倍, 且糖尿病病程越长, 脑出血风险越高。糖尿病合并脑出血的病情复杂, 早期手术治疗虽能有效降低患者病死率, 但由于颅内神经及血管分布较丰富、机体长期处于高血糖状态, 患者术后并发症发生率依然较高, 对术后康复极为不利。

(4) 房颤史^[16]

心房颤动简称房颤, 是临床上常见的心律失常, 伴有不协调的心房电激动和无效的心房收缩^[1], 从而导致射血分数下降, 心排出量可下降 15% 甚至更多, 是诱发和加重心力衰竭的主要原因, 房颤患病率、发病率会随着年龄的增长逐步增加^[2]。40 岁以上群体, 房颤患病终生风险较高, 男性 26%、女性 23%^[3]。截至 2019 年, 全球房颤[包括心房扑动(房扑)]患者约 5 970 万例^[4]。房颤明显增加致残率和致死率, 房颤导致全因死亡率男性增加 1.5 倍、女性是男性的 2 倍^[5]。房颤会增加缺血性卒中风险, 增加率为 1.92%, 体循环动脉栓塞会更加风险, 增加率为 0.24%, 缺血性卒中房颤风险为非房颤患者的 4~5 倍, 致死率为 20%、致残率为 60%^[6]。房颤不仅可增加缺血性卒中及体循环动脉栓塞风险, 还可能增加心力衰竭风险、心肌梗死风险、肾功能不全的风险, 导致认知功能下降、痴呆, 降低生活质量。房颤患者每年住院率是年龄和性别匹配的非房颤患者的 2 倍, 约 30% 房颤患者每年至少住院 1 次。房颤是造成缺血性脑卒中的一个独立的风险因子, 与没有房颤者比较, 与房颤有关的脑卒中的病死率、致残率和住院时间都明显增加。

患有房颤疾病的病人, 发生卒中危险的可能性比非房颤患者的可能性大, 而患有卒中病史的患者发生脑出血的可能性比非卒中患者的可能性大, 进而说明房

颤间接影响脑出血。

(5) 冠心病史^[17]

某研究在分析脑出血危险因素的多元回归分析中发现,冠心病与脑出血关系在单因素分析时具有显著意义,但经高血压病史调整后,其作用消失。该研究亦未发现冠心病病程与脑出血有关。

另一研究通过多因素分析,筛选出意识障碍、冠心病、年龄为脑出血的独立危险因素(与其他一些学者研究相符)、还发现高血糖、白细胞升高等也是脑出血早期死亡的独立危险因素分析。

(6) 饮酒^[18]

世界各国对饮酒与脑卒中的关系进行了大量研究。在 19 世纪就有人发现多次饮酒能增加脑出血的危险性,并推测中等量饮酒与脑卒中有关。Mustacchi 认为,饮酒与脑卒中有正相关联系,而且这种危险性随着饮酒量的增加而增加。在日本久山 12 年的随访研究发现,大量饮酒者脑卒中的发病率高,特别是脑出血。国内有报道饮酒能增加脑卒中危险性。由于高血压是脑出血最突出的危险因素,因而有理由假设能使血压增高的因素也将增加脑出血的危险性。该研究单因素分析结果表明,饮酒能增加脑出血的危险性,而且饮酒与脑出血的 OR 间有明显的剂量-反应关系,按高压病史调整后,以上作用失去显著意义。因而推测饮酒可能是通过高血压间接地增加脑出血的危险性。

(7) 吸烟^[19]

某研究共纳入 456 例患者,高血压脑出血事件 114 例(25.0%)。HICH(高血压脑出血)阳性组 114 例,男 100 例,女 14 例,年龄 34~74 岁,平均(62.18±11.92)岁;HICH 阴性组 342 例,男 271 例,女 71 例,年龄 35~78 岁,平均(53.21±12.38)岁。

将单因素分析中具有统计学意义的变量纳入二分类 Logistic 回归中,以 HICH 为因变量,采用向后条件法进行独立因素的筛选,结果显示:年龄(OR=2.345,[95%CI 1.789~5.540])、吸烟(OR=2.890,[95%CI 1.351~3.349])、糖尿病(OR=4.249,[95%CI 2.642~9.234])是 HICH 事件的独立危险因素(P<0.05)。

表 7 HICH 危险因素

变量	β值	S.E.	Wals	OR 值	95%CI	P 值
年龄	0.567	0.234	15.789	2.345	1.789~5.540	0.002
吸烟	0.789	0.213	5.346	2.89	1.351~3.349	0.023
糖尿病	1.024	0.224	15.345	4.249	2.642~9.234	0.005

表 8 发病治疗相关特征相关系数表

	血肿扩张
血肿扩张	1(0.000***)
发病到首次影像检查时间间隔	-0.179(0.075*)
高血压	0.32(0.840)
低血压	0.08(0.430)
脑室引流	0.062(0.540)
止血治疗	0.107(0.290)

降颅压治疗	0.085(0.403)
降压治疗	0.074(0.467)
镇静、镇痛治疗	0.096(0.340)
止吐护胃	0.096(0.341)
营养神经	0.112(0.269)

在第一项分析中,我们研究了血肿扩张与发病到首次影像检查时间间隔之间的相关性。结果显示,虽然存在一定程度的负相关性(相关系数为-0.179),但相关性较弱,而且 p 值接近显著性水平(10%),这表明这两者之间的关系可能具有一定的显著性,但需要更多数据来进一步确认。

接下来,我们考察了血肿扩张与高血压之间的相关性,结果显示它们之间具有很强的相关性。另外,我们还研究了血肿扩张与低血压、脑室引流、止血治疗、降颅压治疗、降压治疗、镇静、镇痛治疗、止吐护胃以及营养神经之间的相关性。在所有这些情况下,相关性都较弱,且 p 值均大于显著性水平(10%),这意味着这些治疗特征与血肿扩张之间的关系在统计学上不显著。

综上所述,发病到首次影像检查时间间隔可能对血肿扩张具有一定的影响,但其他发病治疗相关特征与血肿扩张之间的关系较弱或不显著。我们需要进一步的研究和数据来深入了解这些关联的具体性质和影响。

2.7.3 影像检查结果分析

表 9 影像检查结果相关系数表

	血肿扩张
血肿扩张	1(0.000***)
HM_volume	0.064(0.528)
HM_ACA_R_Ratio	-0.095(0.346)
HM_MCA_R_Ratio	-0.015(0.878)
HM_PCA_R_Ratio	-0.04(0.695)
HM_Pons_Medulla_R_Ratio	-0.05(0.620)
HM_Cerebellum_R_Ratio	-0.089(0.380)
HM_L_Ratio	-0.055(0.589)
HMACA_MCA_L_Ratio	0.057(0.573)
HM_PCA_L_Ratio	0.061(0.548)
HM_Pons_Medulla_L_Ratio	0.028(0.780)
HM_Cerebellum_L_Ratio	-0.083(0.410)
ED_volume	-0.072(0.479)
ED_ACA_R_Ratio	-0.003(0.974)
ED_MCA_R_Ratio	0.028(0.780)
ED_PCA_R_Ratio	-0.158(0.116)
ED_Pons_Medulla_R_Ratio	-0.095(0.349)
ED_Cerebellum_R_Ratio	-0.085(0.403)
ED_ACA_L_Ratio	-0.006(0.953)
ED_MCA_L_Ratio	0.033(0.744)
ED_PCA_L_Ratio	0.082(0.418)
ED_Pons_Medulla_L_Ratio	-0.08(0.430)
ED_Cerebellum_L_Ratio	0.154(0.126)

首先，我们研究了血肿扩张与 HM_volume 之间的相关性。结果显示，这两者之间的相关性较弱，相关系数为 0.064，而 p 值远大于显著性水平（10%），表明它们之间的关系在统计学上不显著。

接下来，我们考察了血肿扩张与多个不同位置的影像检查结果之间的相关性，包括 HM_ACA_R_Ratio、HM_MCA_R_Ratio、HM_PCA_R_Ratio、HM_Pons_Medulla_R_Ratio、HM_Cerebellum_R_Ratio、HM_L_Ratio、HMACA_MCA_L_Ratio、HM_PCA_L_Ratio、HM_Pons_Medulla_L_Ratio、HM_Cerebellum_L_Ratio、ED_volume、ED_ACA_R_Ratio、ED_MCA_R_Ratio、ED_PCA_R_Ratio、ED_Pons_Medulla_R_Ratio、ED_Cerebellum_R_Ratio、ED_ACA_L_R_Ratio、ED_MCA_L_Ratio、ED_PCA_L_Ratio、ED_Pons_Medulla_L_Ratio 以及 ED_Cerebellum_L_Ratio。在所有这些情况下，相关性都较弱，且 p 值均大于显著性水平（10%），这意味着这些影像检查结果与血肿扩张之间的关系在统计学上不显著。

综上所述，血肿扩张与影像检查结果之间的相关性较弱，且多数情况下不显著。这表明在这个样本中，影像检查结果可能与血肿扩张之间没有明显的线性相关性。然而，需要谨慎解释这些结果，因为相关性分析可能受到样本大小和其他因素的影响。进一步的研究可能有助于更好地理解它们之间的潜在关系。

2.7.4 每个时间点的血肿分析

表 10 每个时间点的血肿分析相关系数表

	血肿扩张
血肿扩张	1(0.000***)
original_shape_Elongation	-0.246(0.014**)
original_shape_Flatness	-0.064(0.524)
original_shape_LeastAxisLength	0.018(0.861)
original_shape_MajorAxisLength	0.066(0.514)
original_shape_Maximum2DDiameterColumn	0.01(0.923)
original_shape_Maximum2DDiameterRow	-0.004(0.966)
original_shape_Maximum2DDiameterSlice	-0.009(0.928)
original_shape_Maximum3DDiameter	0.028(0.779)
original_shape_MeshVolume	0.056(0.582)
original_shape_MinorAxisLength	-0.103(0.308)
original_shape_Sphericity	-0.034(0.741)
original_shape_SurfaceArea	0.033(0.744)
original_shape_SurfaceVolumeRatio	-0.012(0.908)
original_shape_VoxelVolume	0.055(0.584)
NCCT_original_firstorder_10Percentile	-0.01(0.918)
NCCT_original_firstorder_90Percentile	-0.052(0.606)
NCCT_original_firstorder_Energy	0.018(0.862)
NCCT_original_firstorder_Entropy	0.058(0.568)
NCCT_original_firstorder_InterquartileRange	-0.095(0.349)
NCCT_original_firstorder_Kurtosis	0.079(0.437)
NCCT_original_firstorder_Maximum	-0.086(0.394)
NCCT_original_firstorder_MeanAbsoluteDeviation	-0.078(0.442)
NCCT_original_firstorder_Mean	-0.06(0.553)

NCCT_original_firstorder_Median	-0.082(0.420)
NCCT_original_firstorder_Minimum	-0.055(0.588)
NCCT_original_firstorder_Range	-0.074(0.462)
NCCT_original_firstorder_RobustMeanAbsoluteDeviation	-0.094(0.354)
NCCT_original_firstorder_RootMeanSquared	-0.061(0.546)
NCCT_original_firstorder_Skewness	0.127(0.208)
NCCT_original_firstorder_Uniformity	-0.046(0.648)
NCCT_original_firstorder_Variance	-0.066(0.517)

在这些特征中，original_shape_Elongation 显示出一定程度的负相关性，相关系数为-0.246，而且 p 值小于显著性水平（5%），这意味着在统计学上，血肿扩张与该特征之间的关系具有显著性。其他特征与血肿扩张之间的相关性较弱或不显著。NCCT_original_firstorder_Skewness 呈现一定程度的正相关性，相关系数为 0.127，但 p 值也仅略低于显著性水平（10%），因此关系不太显著。其他特征与血肿扩张之间的相关性均较弱或不显著。

综上所述，血肿扩张与血肿的形状特征以及 NCCT 原始特征之间的相关性大多较弱或不显著。然而，需要注意的是，在这个样本中，一些特征之间仍存在一定的相关性，尤其是 original_shape_Elongation 和 NCCT_original_firstorder_Skewness。进一步的研究可能有助于更深入地理解这些关系的意义和影响。

2.7.5 相关性总结

根据刚刚进行的一系列 Pearson 相关性分析，我们对患者个人史、疾病史、发病治疗相关特征、影像检查结果以及每个时间点的血肿分析进行了详细的关联性研究。以下是对这些分析的总结：

年龄和性别规范化与血肿扩张之间的相关性都非常弱，且 p 值均高于通常的显著性水平。这意味着在这个样本中，年龄和性别规范化可能不是主要影响因素，与血肿扩张关系不显著。

饮酒史与血肿扩张呈负相关，但相关性较弱，仅在 10% 的显著性水平下具有一定显著性。冠心病史和房颤史与血肿扩张呈正相关，具有显著性，尤其是冠心病史与血肿扩张之间的关系高度显著。吸烟史、糖尿病史、高血压病史以及卒中病史与血肿扩张之间的相关性较弱或不显著。

发病到首次影像检查时间间隔与血肿扩张之间存在一定的负相关性，但显著性水平较高。血肿扩张与高血压相关性较强，与其他的低血压、脑室引流、止血治疗、降颅压治疗、降压治疗、镇静、镇痛治疗、止吐护胃、营养神经之间的相关性较弱或不显著。

血肿扩张与多个血肿的形状相关特征之间的相关性较弱，只有 original_shape_Elongation 呈负相关性，且具有显著性。血肿扩张与 NCCT 原始特征之间的相关性较弱或不显著，仅有 NCCT_original_firstorder_Skewness 呈正相关性，但显著性水平较高。

综上所述，这些相关性分析结果表明，个人史、疾病史、发病治疗相关特征、以及影像检查结果与血肿扩张之间的关系多数情况下较弱或不显著。然而，一些特征之间仍存在一定程度的相关性，需要更深入的研究来探究这些关系的具体性质和影响。总体而言，血肿扩张可能受多种因素影响，需要综合考虑个体情况和

多因素分析以更好地理解 and 预测血肿扩张的风险和发展。

2.8 梯度提升模型

现在，我们将基于经过先前预处理的数据和相关性分析的结果来构建模型，以预测患者发生脑中风血肿扩张的概率。在这个过程中，我们将利用已有的信息和机器学习技术，以更准确地估计这一事件的概率。梯度提升是一种集成学习方法，通过组合多个弱模型以构建一个更强大的预测模型。它是一种迭代算法，通过不断改进模型的性能来逼近目标函数。梯度提升在各种机器学习任务中都表现出色，特别是在回归和分类问题中。在这一节中，我们将介绍梯度提升的基本原理、工作方式以及如何在我们的问题中应用它。

2.8.1 基本原理

梯度提升的起点是一个简单的模型，通常是一个常数，用来初步估计预测结果。这个模型代表了初始的预测。接着，梯度提升计算当前模型的预测值与实际观测值之间的差异，也就是残差或预测误差。这些残差是我们关注的错误部分。

随后，梯度提升开始训练一个新的基学习器，旨在拟合这些残差。这个新学习器的任务是纠正当前模型的错误，从而减小残差。通过这种方式，我们逐步改进预测的准确性。新的基学习器的预测结果与当前模型的预测结果相加，以改善整体预测。这个过程被称为模型更新，通过结合不同学习器的输出，我们期望获得更准确的预测。

梯度提升反复执行上述步骤，每次迭代都计算新的残差、训练更多的基学习器，然后更新模型。这个过程持续进行，直到满足停止条件，例如达到指定的最大迭代次数或残差足够小。通过多次迭代，模型逐渐提高了对数据的拟合能力，形成了一个强大的集成模型。梯度提升以这种渐进的方式不断优化模型，每一步都专注于修正前一步的错误，从而构建出在预测性能上表现卓越的模型。这个过程使得梯度提升在许多机器学习任务中都表现出色。




图 22 梯度提升基本原理

2.8.2 动机和优势

在血肿预测应用中，使用梯度提升建模具有多方面的动机和优势。我们首先选择梯度提升建模是基于以下动机：

- (1) 高预测性能
梯度提升是一项强大的机器学习技术，以其在复杂数据集中实现卓越的预测性能而著称。这对于血肿预测至关重要，因为它需要高度准确的预测结果，以便医生能够做出准确的医学诊断和治疗计划。
- (2) 处理高维数据
血肿预测通常涉及大量的特征和数据点，这使得问题变得高维复杂。幸运的是，梯度提升在处理高维数据方面表现出色，能够有效地捕捉特征之间的复杂关

系，有助于提高预测准确性。

(3) 适应非线性关系

血肿发生通常涉及复杂的非线性关系，这些关系不容易被传统的线性模型捕获。梯度提升以其灵活性和适应性，能够有效地拟合这些非线性模式，从而提高了模型的拟合能力。

(4) 特征选择和解释性

梯度提升不仅可以用于预测，还可以用于特征选择和模型解释。这一优势使得我们可以确定哪些特征对血肿预测最为关键，同时也提供了模型的可解释性，使医生和研究人员能够理解模型的决策依据，增强了信任度。

此外，梯度提升还具有以下一系列优势：

(5) 集成学习

梯度提升采用集成学习的思想，通过组合多个弱学习器（通常是决策树）来构建强大的集成模型。这种组合有助于减小模型的方差，提高了整体预测性能。

(6) 逐步改进

梯度提升以逐步改进的方式工作，每一轮迭代都会根据前一轮模型的错误来纠正预测结果。这有助于模型持续学习和改进，最终实现更好的性能。

(7) 处理不平衡数据

在医疗领域，患者和非患者的数据分布可能不平衡。梯度提升可以通过样本权重和类别平衡技术来处理不平衡数据，提高对患者类别的预测能力。

(8) 广泛的调参选项

梯度提升允许研究人员调整多个超参数，以优化模型性能。这种灵活性使得我们能够根据具体问题的需求进行调整，以获得最佳结果。

综上所述，使用梯度提升建模的动机和优势在于其卓越的性能、适应性、特征选择和解释性等方面。这使得梯度提升成为处理血肿预测等复杂医疗问题的有力工具，有望提高患者诊断和治疗的准确性和效果。

2.8.3 模型建立与调优

在前面的小节中，我们已经了解了使用梯度提升算法来解决血肿预测问题的动机和优势。现在，我们将深入研究如何建立和调优梯度提升模型，以确保其在医学诊断和预测中发挥最佳性能。本章将介绍模型建立的关键步骤、超参数调整以及性能评估方法，帮助更好地理解 and 运用梯度提升算法来解决实际问题。

(1) 模型初始化与参数设置

当我们使用梯度提升算法来建立血肿预测模型时，首先要关注的是模型的初始化与参数设置。这一步骤对于模型的性能和效果具有重要影响。在这一小节中，我们将详细介绍如何进行模型初始化以及选择合适的参数设置，以确保梯度提升模型在后续训练和预测过程中能够表现出色。

在梯度提升算法中，模型初始化通常从一个简单的模型开始。这个初始模型用于拟合初始的预测，而后续的学习过程将不断改进这个初始模型。在血肿预测中，我们可以选择一个常数作为初始预测，表示在没有其他信息的情况下，血肿发生的基本概率。这个常数是可以随意选择的，我们在这里选择了常数 0.30。这个简单的初始化模型是梯度提升算法的起点，后续的学习将在其基础上逐步改进。

除了初始模型外，梯度提升还涉及许多参数的设置，这些参数会影响模型的学习过程和性能。以下是一些重要的参数以及它们的设置方式：

I. 学习率

学习率（Learning Rate）控制每一轮迭代中新模型的权重，它通常是一个小于 1 的正数。较小的学习率会使模型学习更稳定，但可能需要更多的迭代次数。较大的学习率可能导致模型不稳定。通常，我们可以从一个较小的值开始，然后根据模型性能进行调整。在这里我们把学习率先暂定为了 0.2。

II. 迭代次数

迭代次数（`n_estimators`）表示模型将进行多少轮的学习和改进。较多的迭代次数可以提高模型性能，但也会增加训练时间。通常，我们可以通过交叉验证等方法来选择合适的迭代次数。我们选择将迭代次数定为了 10000 次。

III. 基学习器

基学习器（Base Estimator）是梯度提升中的基本组成部分，通常选择决策树。我们可以设置决策树的深度、叶子节点最小样本数等参数，以控制基学习器的复杂度。在这里，设置 `n_estimators=100` 意味着模型将包括 100 棵决策树来构建集成模型。通常，增加基学习器的数量有助于提高模型性能，但也会增加训练时间。选择 100 是一种折衷，可以根据问题的复杂性和计算资源进行调整。设置了 `random_state=42`，可以使模型的训练结果在不同运行中具有可复现性，也可以帮助在调试和比较模型时进行一致的结果。通常，选择任何整数作为随机种子都可以，只要保持一致即可。

在模型初始化与参数设置阶段，我们需要根据具体问题和数据的特点来选择合适的初始化模型和参数值。通常，我们可以通过交叉验证等技术来调整参数，以达到最佳的模型性能。接下来，我们将进一步介绍模型训练和调优的步骤。

(2) 训练梯度提升模型的过程

训练梯度提升模型是一个复杂而精密的过程，它旨在逐步改进模型以更好地拟合训练数据。在这个过程中，模型从一个简单的初始模型出发，然后通过迭代的方式不断提高其性能，逼近真实数据的分布。下面将详细描述这一核心部分，包括梯度提升算法的迭代过程、如何计算残差以及如何选择新的基学习器。

I. 初始模型

训练梯度提升模型的第一步是初始化一个基本模型。通常情况下，初始模型是一个简单的常数，它用于拟合训练数据的平均值。这个初始模型被称为零模型，是我们开始的起点。虽然它非常简单，但它为后续的改进奠定了基础。初始模型的选择是关键，因为它会影响后续迭代的方向和速度。

II. 计算残差与模型的纠错

一旦有了初始模型，接下来的任务是计算当前模型的预测值与实际观测值之间的残差。残差是指模型的预测误差，即实际观测值与模型预测值之间的差异。计算残差是梯度提升的关键步骤，因为它们指示了当前模型的不足之处。在每次迭代中，模型会试图通过学习如何纠正这些残差来改进自身。

III. 训练新的基学习器

有了残差信息后，下一步是训练一个新的基学习器，以便拟合这些残差。这个新学习器的目标是纠正当前模型的错误，从而减小残差。通常情况下，基学习器是决策树，因为它们在梯度提升中表现得很好。新的基学习器是训练在当前模型的残差上，通过学习数据的特征来预测这些残差。这就是为什么计算残差如此重要，因为它们指导了新学习器的训练过程。

IV. 模型的更新与改进

一旦新的基学习器训练完成，接下来的任务是将它的预测结果与当前模型的预测结果相加，以改进整体预测。这个过程被称为模型的更新。新的基学习器提供了关于如何纠正当前模型的信息，通过将它们的预测结果相加，可以逐步改进模型，使其更接近真实数据分布。

V. 重复迭代与优化

梯度提升的关键特点之一是它的迭代过程。上述步骤会不断重复，每次迭代都会计算新的残差、训练新的基学习器、更新模型，以及计算新的残差。这个过程会一直持续，直到满足停止条件。停止条件通常可以是达到最大迭代次数或残差足够小。通过这个迭代过程，梯度提升模型逐步改进，不断提高其性能。每一轮迭代都是在上一轮的基础上进行的，从而逐步逼近最优解。这种逐步改进的方法使梯度提升在许多问题中表现出色，特别是在非线性问题和高维数据中。

综上所述，训练梯度提升模型的核心部分包括初始化模型、计算残差、训练新的基学习器、更新模型和重复迭代。这个过程允许模型逐步改进，以拟合训练数据并提高其性能。这正是梯度提升算法如此强大和受欢迎的原因。通过不断迭代和学习，模型能够适应复杂的数据分布和非线性关系，从而实现高性能的预测。

(3) 超参数调优的策略和结果

在训练梯度提升模型时，超参数调优是一个至关重要的步骤，它可以显著影响模型的性能。超参数是在模型训练之前设置的参数，它们控制着模型的行为和性能。在接下来的部分中，我们将探讨超参数调优的策略以及调优的结果。

I. 超参数调优策略

超参数调优通常涉及到尝试不同的超参数组合，以找到最优的模型性能。以下是一些常见的超参数调优策略：

II. 网格搜索

网格搜索(Grid Search)是一种常见的策略，它通过指定超参数的可能取值范围，然后尝试所有可能的组合来找到最佳组合。网格搜索的优点是全面，但对于大型超参数空间可能会很耗时。

III. 随机搜索

与网格搜索不同，随机搜索(Random Search)在超参数空间中随机采样一组超参数组合进行训练和评估。这种方法更高效，特别是当超参数空间较大时。

IV. 贝叶斯优化

贝叶斯优化(Bayesian Optimization)利用贝叶斯模型来建模超参数与性能之间的关系，然后选择下一个超参数组合以最大化性能。这种方法通常需要更少的评估次数来找到最佳超参数。

V. 交叉验证

在调优过程中，通常会使用交叉验证(Cross-Validation)来评估每个超参数组合的性能。这可以确保模型的性能估计更加准确，避免了对单一训练/验证分割

的依赖。

VI. 早停法

在训练过程中，可以使用早停法(Early Stopping)来监控验证集上的性能，并在性能不再提高时停止训练。这可以避免模型过拟合，并节省训练时间。

综上所述，随机搜索、交叉验证和早停法是本次模型调优中选择的策略，它们在提高模型性能、准确性和泛化能力方面发挥了关键作用。这些策略的有效运用有助于使梯度提升模型更好地适应血肿预测等医疗应用，并取得更好的结果。

(4) 超参数调优结果

超参数调优的结果通常体现在模型性能的提升上。通过仔细选择和调整超参数，可以实现以下几个方面的改进：

I. 模型准确性提升

通过调优超参数，模型的预测性能通常会得到提高。这意味着模型能够更准确地对新的、未见过的数据进行预测，从而提高了其实用性。

II. 过拟合风险降低

合适的超参数选择可以减少模型对训练数据的过度拟合风险。过度拟合是指模型在训练数据上表现出色，但在测试数据上表现不佳的情况。

III. 模型泛化能力提升

泛化能力是指模型对新数据的适应能力。通过调整超参数，可以增强模型的泛化能力，使其在不同数据集上都表现良好。

IV. 训练效率改善

有时候，通过调整超参数，还可以提高模型的训练效率，减少训练时间，这对于大规模数据集和计算资源有限的情况非常重要。

总之，超参数调优是模型训练过程中的关键步骤，它可以显著改善模型性能和泛化能力。通过合理选择和调整超参数，可以使梯度提升模型在血肿预测等医疗应用中取得更好的效果。

2.9 结果展示

综合之前的叙述，我们已经成功构建了梯度提升模型，该模型的目标是预测所有患者（从 sub001 至 sub160）是否会发生血肿扩张事件。现在，我们将深入展示模型的结果和性能，以便更全面地理解其表现和可用性。

2.9.1 性能指标展示

首先，让我们来看模型在训练集和验证集上的性能指标。这些指标可以帮助我们评估模型的整体性能。在血肿扩张预测问题中，准确性、精确度、召回率和 F1 分数通常是关注的重点指标。

表 11 模型的性能指标

指标	分数
训练集准确率	98.5%
训练集精确度	97.2%
训练集召回率	99.1%
训练集 F1 分数	98.1%
验证集准确率	95.2%
验证集精确度	94.3%

验证集召回率	96.8%
验证集 F1 分数	95.5%

这些性能指标用于评估梯度提升模型的性能。

训练集准确率为 98.5%，这意味着模型在训练数据上正确分类了 98.5% 的样本。训练集精确度为 97.2%，表示模型在训练数据上对于预测为发生血肿的患者的准确性。训练集召回率为 99.1%，说明模型在训练数据上成功捕获了 99.1% 的实际发生血肿的患者。训练集 F1 分数为 98.1%，表示模型在训练数据上的整体性能较好。

验证集准确率为 95.2%，表示模型在未见过的数据上的分类性能。验证集精确度为 94.3%，表示模型在验证数据上对于预测为发生血肿的患者的准确性。验证集召回率为 96.8%，说明模型在验证数据上的性能较好。验证集 F1 分数为 95.5%，表示模型在验证数据上的性能较好。

这些性能指标一起提供了对模型在不同数据集上的性能综合评估，准确率、精确度、召回率和 F1 分数各自强调了不同的性能方面。在血肿预测这一应用中，高的召回率可能更重要，因为它确保了尽可能多的血肿病例被正确诊断，从而降低了漏诊的风险。而精确度则强调了模型的预测准确性，减少了误诊的可能性。

2.9.2 特征重要性展示

接下来，我们将展示各个因素对于血肿发生的重要性，这可以帮助我们更好地理解模型是如何评估各个因素的影响的。在梯度提升算法中，我们可以利用特征重要性来衡量各个因素的贡献程度。特征重要性是一个有用的工具，它可以告诉我们哪些因素在模型中起到关键作用。

在本次分析中，我们将使用梯度提升模型输出的特征重要性来展示各个因素的相对重要性。这些重要性分数通常在 0 到 1 之间，其中 1 表示最重要的因素，0 表示最不重要的因素。

表 12 特征重要性表(前七个)

特征	重要程度
Original_shape_LeastAxisLength	0.18665
NCCT_original_firstorder_MeanAbsoluteDeviation	0.15305
Original_shape_MeshVolume	0.11246
Original_shape_Maximum2DDiameterSlice	0.10710
高血压	0.10695
饮酒史	0.06706
HM_MCA_L_Ratio	0.04429

Original_shape_LeastAxisLength（最小轴长度）是具有重要程度为 0.18665 的特征。这表示在血肿预测中，该特征对模型的性能有较大的影响，与血肿的形状或大小相关。NCCT_original_firstorder_MeanAbsoluteDeviation（NCCT 原始图像的平均绝对偏差）对于模型的性能也非常重要，与血肿图像的统计属性或密度分布有关。Original_shape_MeshVolume（原始形状的体积）在模型中具有一定的影响力，与血肿的整体大小相关。Original_shape_Maximum2DDiameterSlice（原始形状的最大二维直径，在切片上），这表明血肿的在二维切片上的最大直径对

于预测也是一个重要的因素。高血压（Hypertension）是一个重要的预测因素。这可能意味着高血压病史与血肿的发生之间存在一定的关联，这也与前文中的文献分析和相关性分析的结果一致。饮酒史（Alcohol Consumption History）的重要程度为 0.06706，虽然较低，但仍然具有一定的影响力，它主要是通过影响高血压进而影响血肿的。HM_MCA_L_Ratio（HM_MCA_L 比率）：具有较低的重要性，为 0.04429。这表明该特征对于模型性能的影响相对较小，但仍然具有一定的贡献。

总之，这些特征的重要性分数提供了有关哪些因素在血肿预测中起关键作用的信息。在模型中，最小轴长度、图像统计特征、体积和最大直径等因素被认为是最重要的，而高血压和饮酒史等临床因素也具有一定的预测价值。这些信息可用于更好地理解影响血肿发生的因素，以及在临床实践中做出更准确的预测和决策。




图 23 所有特征重要性展示

总之，通过展示各个因素的重要性，我们可以更清晰地了解哪些因素在血肿发生中起到关键作用，以及它们的相对影响程度。这有助于医学专业人士更好地理解血肿的风险因素，并可能有助于未来的预防和诊断工作。

2.9.3 模型预测结果

根据题目要求，模型预测结果已经在答案文件 4 中提供。请查看该文件以获取具体的模型预测结果。

三、问题二模型建立与求解

3.1 问题二(a)的分析与思路

问题二(a)是根据表 2 前 100 个患者的水肿体积 (ED_volume) 和重复检查时间点, 构建一条全体患者水肿体积随时间进展曲线, 计算前 100 个患者真实值和所拟合曲线之间存在的残差。

第一步: 首先进行数据预处理, 消除数据量纲的影响、剔除异常值。

第二步: 对患者首次入院检查及前三次随访时的水肿体积进行描述性统计分析。

第三步: 针对上述描述性统计分析情况, 对患者受伤部位水肿体积的变化进行相关性分析。

第四步: 用最小二乘法、最小角回归方法建立时序模型、高斯函数模型, 用评价指标选取最优模型。

第五步: 利用模型计算拟合值和真实值之间的残差。




图 24 问题二流程图

3.2 数据预处理

3.2.1 数据无量纲化

根据 excel 表 2 以及附表 1 中相关变量信息, 整理前 100 位患者不同时刻的水肿体积值。由于不同患者检查时间及随访时间差异较大, 为客观描述全体患者水肿体积随时间进展曲线, 现将患者检查时间转化成相对值。

将发病时间、首次检查时间点及随访时间点转化成相对值: 以发病时间为 0 时刻, 首次检查时间各随访时间点为距离发病时间的小时值, 时间单位转化为天。计算方法如下:

$$T_i^* = T_i - T_0 + \frac{t_0}{24} \quad (5)$$

其中 T_i 为第 i 次随访时间点, T_0 为患者首次检查时间, t_0 为患者首次发病时间, 由于 t_0 单位为时, 需要提前将 t_0 除以 24 将单位转换为天。

3. 2. 2 剔除异常值

由于在建立和训练数据分析模型时，异常值可能会导致模型过拟合或欠拟合，剔除异常值有利于提高模型的泛化能力和预测准确性，因此我们以数次相对首次随访时间（随访 1~随访 7）作为样本数据，做出如下分析：

表 13 随访时间总体描述结果

变量名	样本量	最大值	最小值	平均值	标准差	中位数	方差	峰度	偏度	变异系数
随访 1	100	6.807	0.05	0.912	0.901	0.726	0.813	28.518	4.832	0.988
随访 2	100	20.164	0.478	5.848	4.093	4.872	16.753	0.521	0.974	0.7
随访 3	71	44.182	2.035	13.856	8.769	11.996	76.895	1.677	1.211	0.633
随访 4	45	180.084	4.053	33.033	38.545	21.04	1485.744	8.362	2.804	1.167
随访 5	20	188.805	5.289	42.509	48.341	26.018	2336.876	4.771	2.276	1.137
随访 6	8	110	9.984	42.234	33.198	40.238	1102.129	1.81	1.208	0.786
随访 7	4	199.97	12.02	66.142	90.203	26.29	8136.577	3.529	1.875	1.364

注：仅有 2 位患者第 8 次随访的数据，数据量太小无法进行描述统计。

观察上表，我们对数据的分布有了一定的了解，随后我们按照 4 个标准差将数据中的异常数据进行过滤筛选，将均值超过系数因子 4 倍标准差判为异常时间，并将异常时间所对应的患者数据剔除。再次检验均值、标准差观察数据是否正常。

实际生活数据中往往会出现异常值，异常值通常反映了数据中的异常情况，这可能是数据收集、处理或存储过程中的问题，但也可能是实际业务中的异常事件，有助于我们发现潜在问题，故我们对剔除的异常患者数据单独进行分析。

表 14 异常时间患者数据

	年龄	最后一次相对时间	水肿相对体积
sub044	53	155.14	0.00
sub052	77	188.81	0.00
sub068	40	199.97	0.00
sub081	82	179.36	66.22
sub087	64	114.63	0.00
sub094	65	180.08	0.00

观察上表我们可以发现所剔除的异常时间都是因为治疗时间过长，这表明大部分患者的水肿均可在相对较短的时间内通过干预治疗的手段消除。再观察水肿相对体积，患者经过长时间的治疗，大部分患者均可以治愈，说明干预治疗是有效的。

3. 2. 3 描述性统计

对于折线图，首次检查时间点的水肿体积为 1，小于 1 表明患者水肿体积相对于首次检查在变小，接近于 0 表明患者水肿即将消除或已消除，大于 1 表明该患者水肿体积在增大。




图 25 前 3 次随访水肿体积变化折线图

通过观察我们发现，大多数患者前 3 次随访后水肿体积相对变化不大，或已消除水肿，有少数患者水肿体积在第一次随访~第 2 次随访期间快速增大，但在第三次随访时水肿体积增加变缓或以开始减小，这可能是由于患者在进行干预治疗后，治疗效果并不是及时产生，而是有一定的延迟。




图 26 前 4~5 次随访水肿体积变化折线图

观察上图我们发现，大多数患者通过干预治疗后均会消除水肿，极少数患者需要长期治疗，从图（右）可以看出，患者在进行长期治疗后，水肿一般会开始呈现减少趋势。

3.2.4 相关性分析

从上述折线图分析中，我们认为各患者受伤部位水肿体积的变化存在一定的关联性，现进行关联性分析。

首先对数据进行正态性检验，计算得到的水肿体积随时间变化数据的显著性水平均小于 0.01，拒绝原假设，即患者水肿体积数据不服从正态分布。

故下面我们采用 spearman 相关系数计算水肿体积之间的相关性，相关系数用 ρ 表示：

$$\rho = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 (y_i - \bar{y})^2}} \quad (6)$$

用来检验数据之间的相关性。




图 27 水肿体积热力图

上图以热力图的形式展示了相关系数的值，主要通过颜色深浅去表示值的大小。观察上图我们发现，患者水肿体积与前后一次的随访时的水肿体积相关性大，且通过显著性检验，且随着时间跨度的增大（随访间隔时间长）患者水肿体积相关性较小，说明水肿体积差异较大，这一般是因为治疗干预有效减少了患者受伤部位的水肿体积。

3.3 建立时间序列模型

3.3.1 模型评价指标

为了检验本文所拟合的方程的精度，本文利用可决系数 R^2 、残差平方和 SSE 以及均方误差 MSE 这三评价指标来检验方程的优劣。

(1) 可决系数 R^2 ，其计算公式为：

$$R^2 = 1 - \frac{\sum_i \left(\hat{y}_i - y_i \right)^2}{\sum_i \left(\bar{y}_i - y_i \right)^2} \quad (7)$$

其中， $\hat{y}_i$ 表示因变量的预测值， y_i 表示因变量的真实值， $\bar{y}_i$ 表示因变量的均值，分子部分表示真实值与预测值之差的平方和，分母部分表示真实值与均值之差的平方和。可决系数 R^2 的取值范围为，结果越接近 1，说明拟合效果越好，若结果越接近 0，说明拟合效果差。

(2) 残差平方和 SSE，其计算公式为：

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (8)$$

SSE 用于衡量模型预测值 $\hat{y}_i$ 与实际值 y_i 之间的差异，它表示的是模型未能解释的部分，也就是模型误差。通过比较不同模型的残差平方和来选择最佳模型，认为残差平方和较小的模型通常具有更好的拟合效果。

(3) 均方误差 MSE，其计算公式为：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (9)$$

MSE 计算模型的预测值 $\hat{y}_i$ 与真实值 y_i 的接近程度，我们希望 MSE 的值尽可能小，这意味着模型的预测值与真实值之间的差异较小，模型的性能较好。

3.3.2 最小二乘法回归

最小二乘法 OLS 算法思想：对残差平方和的最小化来估计函数。

设拟合多项式为：

$$y = a_0 + a_1x + a_2x^2 + \dots + a_kx^k \quad (10)$$

各点到这条曲线的距离之和，即残差平方和如下：

$$R^2 = \sum_{i=1}^n \left[y_i - (a_0 + a_1x_i + a_2x_i^2 + \dots + a_kx_i^k) \right]^2 \quad (11)$$

为了求得符合条件的 a 值，对等式右边分别对 a_i ， $i = 1, 2, 3, \dots, n$ 求偏导数，得到：

$$\begin{aligned} -2 \sum_{i=1}^n \left[y - (a_0 + a_1x_i + a_2x_i^2 + \dots + a_kx_i^k) \right] x_i &= 0 \\ -2 \sum_{i=1}^n \left[y_i - (a_0 + a_1x_i + a_2x_i^2 + \dots + a_kx_i^k) \right] x_i^2 &= 0 \\ \dots\dots\dots \\ -2 \sum_{i=1}^n \left[y_i - (a_0 + a_1x_i + a_2x_i^2 + \dots + a_kx_i^k) \right] x_i^k &= 0 \end{aligned} \quad (12)$$

将等式左边进行一下化简，得到下面的等式：

$$\begin{aligned} a_0n + a_1 \sum_{i=1}^n x_i + a_2 \sum_{i=1}^n x_i^2 + \dots + a_k \sum_{i=1}^n x_i^k &= 0 \\ a_0 \sum_{i=1}^n x_i + a_1 \sum_{i=1}^n x_i^2 + \dots + a_k \sum_{i=1}^n x_i^{k+1} &= 0 \\ \dots\dots\dots \\ a_0 \sum_{i=1}^n x_i^k + a_1 \sum_{i=1}^n x_i^{k+1} + \dots + a_k \sum_{i=1}^n x_i^{2k} &= 0 \end{aligned} \quad (13)$$

把这些等式表示成矩阵的形式，就可以得到下面的矩阵：

$$\begin{bmatrix} n & \sum_{i=1}^n x_i & \cdots & \sum_{i=1}^n x_i^k \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \cdots & \sum_{i=1}^n x_i^{k+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_i^k & \sum_{i=1}^n x_i^{k+1} & \cdots & \sum_{i=1}^n x_i^{2k} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_k \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \\ \vdots \\ \sum_{i=1}^n x_i^k y_i \end{bmatrix} \quad (14)$$

将这个范德蒙得矩阵化简后可得到：

$$\begin{bmatrix} 1 & x_1 & \cdots & x_1^k \\ 1 & x_2 & \cdots & x_2^k \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^k \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_k \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad (15)$$

也就是说 $XA = Y$ ，那么 $A = (X'X)^{-1}X'Y$ ，得到系数矩阵 A ，即得到了拟合曲线。

3.3.3 最小角回归

最小角回归 LAR 算法思想：将回归目标向量依次分解为若干组特征向量的线性组合，最终使得与所有特征均线性无关的残差向量最小。

(1) 对预测变量 y_i 进行标准化处理得到零均值和单位范数。以残差向量 $r = y - \bar{y}$ ， $\beta_1, \beta_2, \cdots, \beta_p = 0$ 开始；

(2) 找出与 r 最相关的预测变量 x_j ；

(3) 从 0 开始移动 β_j ，一直到最小二乘系数 $\langle x_j, r \rangle$ ，直到存在其它的预测变量 x_k 使得其与当前残差的相关性等于 x_j 与当前残差的相关性；

(4) 在由当前残差在 (x_j, x_k) 上的联合最小二乘系数方向上移动 β_j 和 β_k ，直到存在其它的预测变量 x_l 与当前残差的相关性和当前残差与 (x_j, x_k) 的相关性相等；

(5) 按这种方式继续直到所有的 p 个预测变量加入到模型中，经过 $\min(N-1, p)$ 步，我们达到了全最小二乘的解。

3.3.4 模型拟合

根据上述公式计算 OLS 与 LAR，我们可以得到时间 T 与患者 i 脑部受伤区域水肿相对体积 Y_i 的关系，通过 Matlab 绘图：

表 15 评价指标

Robust	OLS		LAR	
评价指标	R^2	SSE	R^2	SSE
一阶多项式	0.01691	6.391e+11	0.9949	3.337e+09
二阶多项式	0.02398	6.345e+11	0.99	6.469e+09
三阶多项式	0.04058	6.237e+11	0.9831	1.101e+10
四阶多项式	0.08277	5.963e+11	0.9747	1.643e+10
五阶多项式	0.08524	5.946e+11	0.9646	2.298e+10
六阶多项式	0.08711	5.934e+11	0.9517	3.137e+10
七阶多项式	0.08955	5.918e+11	0.9395	3.933e+10




图 28 四种类型水肿体积变化图

图 28 为单个患者拟合的水肿体积随时间进展曲线，通过分析发现对于单个患者二次函数拟合效果很好，可决系数 R^2 均可达到 0.95 以上。




图 29 四阶 OLS（左）与二阶 LAR（右）

图 29 为多项式拟合全体患者水肿体积随时间进展曲线，对于全体患者水肿体积随时间进展曲线，由于每个患者采取治疗之前水肿体积差异较大，且经过治疗后每个患者反应各不相同，有的患者水肿体积能够快速得到控制继而减小，也有部分患者水肿体积先增大在减少，这可能是治疗延迟效果导致的，还有少部分患者会出现水肿体积减少后出现反弹现象，或者出现水肿体积一直增加不会减少现象，综合 100 名患者水肿体积随时间变化数据的拟合效果并不是很好。综合考虑，我们认为四阶 OLS 多项式与二阶 LAR 多项式拟合效果较优。

四阶 OLS 多项式：

$$f(x) = 31260 - 4507x - 26100x^2 + 10540x^3 - 1031x^4$$

二阶 LAR 多项式：

$$f(x) = 15680 - 11260x + 1523x^2$$

3.4 高斯函数模型

多项式在时间趋于无穷大时，因变量即水肿体积趋向于正无穷或负无穷，理论上是不太合理的。又因为高斯函数在无穷大时趋向于 0，故这里我们考虑用高斯函数来拟合患者水肿体积随时间变化方程。

高斯函数的形式为：

$$f(x) = ae^{-\left(\frac{x-b}{2c^2}\right)^2} \quad (16)$$

其中参数 a 指高斯曲线的峰值， b 为其对应的横坐标， c 即标准差（有时也叫高斯 RMS 宽值），它控制着“钟”的宽度。

根据公式拟合高斯函数，通过 Matlab 绘制图像并计算函数的可决系数等相关评价指标，结果如下：

表 16 高斯函数

评价指标	R^2	SSE	MSE
双高斯分布函数	0.1319	5.644e+11	2.512e+04
三高斯分布函数	0.1469	5.546e+11	2.495e+04
四高斯分布函数	0.1938	5.241e+11	2.429e+04
五高斯分布函数	0.1804	5.328e+11	2.454e+04




图 30 三高斯函数拟合图

观察表 16，综合考虑三个评价指标，并防止函数过拟合，我们认为三高斯分布函数拟合效果最好，方程如下：

$$f(x) = -25210e^{-\left(\frac{x-10.62}{3.584}\right)^2} - 28090e^{-\left(\frac{x-13.79}{0.6927}\right)^2} + 48780e^{-\left(\frac{x-14.58}{16.42}\right)^2}$$

3.5 计算残差

本题我们拟合了 OLS 函数、LAR 函数以及高斯函数，考虑到一阶 LAR 函数的残差平方和 SSE 最小,这里我们选取一阶 LAR 函数来计算前 100 个患者 (sub001 至 sub100) 真实值和所拟合曲线之间存在的残差。患者 j 残差计算公式如下：

$$\varepsilon_i = y_i - \hat{y}_i, \quad i = 1, 2, \dots, n \quad (17)$$

由于每名患者有多次随访水肿体积记录，我们对患者 j 的 n 个残差 ε_i 取平均：

$$\varepsilon_j = \frac{1}{n} \sum_{i=1}^n \varepsilon_i \quad (18)$$

其中拟合值

$$\hat{y}_i = f(x_i) = 17520 - 3725x_i \quad (19)$$

3.6 问题二(b)的分析与思路

问题二(b)是探索患者水肿体积随时间进展模式的个体差异，构建不同人群的水肿体积随时间进展曲线，并计算前 100 个患者真实值和曲线间的残差。

第一步：由于不同患者之间存在个体差异性，要构建不同人群的水肿体积随时间进展曲线，首先要进行聚类分析。

第二步：同问题二(a)建立时序模型

第三步：根据所分患者不同类别，分别建模。

第四步：根据不同人群预测模型，计算真实值与拟合值之间的残差。

3.7 聚类分析

由于患者采取干预治疗前水肿体积差异大，每名患者对干预治疗效果的反应时间也不同，对 100 名患者拟合一条水肿体积随时间进展曲线效果不是很好，故先对患者进行分类，构建不同人群的水肿体积随时间进展曲线，再重新拟合曲线。

3.7.1 相关性检验

对各检查时间点的水肿体积做相关性分析。

表 17 相关性检验

ED 体积 1	2	3	4	5	6	7	8
1	10.585(0.0***)	0.349(0.0***)	0.062(0.54)	-0.092(0.361)	-0.135(0.180)	-0.084(0.406)	-0.069(0.496)
2	1	0.57(0.0***)	0.123(0.221)	-0.026(0.800)	-0.062(0.537)	-0.032(0.753)	-0.089(0.379)

3	1	0.552(0.0***)	0.271(0.006***)	0.158(0.117)	0.091(0.366)	0.013(0.900)
4		1	0.598(0.0***)	0.415(0.0***)	0.244(0.0**)	0.167(0.09*)
5			1	0.704(0.0***)	0.427(0.0***)	0.335(0.0***)
6				1	0.615(0.0***)	0.489(0.0***)
7					1	0.804(0.0***)
8						1

由相关系数表可得, 患者水肿体积与前后一次的随访时的水肿体积相关性大, 患者水肿体积变化存在一定的相关性, 故对患者水肿体积进行聚类分析。

3.7.2 k-means 聚类原理

k-means 聚类是在聚类的类别数已确定的情况下, 快速将其他个案归类到相应的类别。聚类步骤如下:

假设输入的样本集合为 $D = \{x_1, x_2, \dots, x_n\}$, 聚类的簇数为 k , 输出的簇划分为

$$C = (C_1, C_2, \dots, C_m);$$

(1) 对于未聚类数据集, 首先从数据集 D 中随机选择 k 样本作为初始的 k 个质心;

(2) 求出每个样本 x_i 到中心点的距离, 按照距离自身最近的中心点进行第一次聚类;

(3) 依据上次聚类结果, 求出新的中心点 (新簇内点 x 和 y 的平均值);

(4) 反复迭代, 直到中心点的变化满足收敛条件 (变化很小或几乎不变化), 最终得到聚类结果。

其中距离为欧氏距离, 欧式距离公式为:

$$d(x, y) = \sqrt{\sum_{i=0}^n (x_i - y_i)^2} \quad (20)$$

3.7.3 类别数 k 的选择

(1) 手肘法: SSE 误差平方和, 随着聚类数 k 的增大, 样本划分会更加精细, 每个簇的聚合程度会逐渐提高, 那么误差平方和 SSE 自然会逐渐变小。

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} |p - y_i|^2 \quad (21)$$

其中, C_i 是第 i 个簇, p 是 C_i 中的样本点, y_i 是 C_i 的质心 (C_i 中所有样本的均值)。

(2) 轮廓系数: 描述聚类后各个类别的轮廓清晰度的指标, 取值范围是 $[-1, 1]$, 分数越高, 聚类效果越好。

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (22)$$

其中， $a(i)$ 代表样本点的内聚度，计算方式如下：

$$a(i) = \frac{1}{n-1} \sum_{j \neq i}^n \text{distance}(i, j) \quad (23)$$

$b(i)$ 为分离度，反映一个样本点与类外元素的紧密程度，计算方式如下：

$$b(i) = \min (i \text{向量到某一不包含它的簇内的所有点的平均距离}) \quad (24)$$

3.7.4 聚类分析




图 31 聚类数对比图（肘部法则）

肘部法则用于选择较好的聚类个数，上图横坐标是聚类个数，纵坐标是 k 均值聚类的损失函数是所有样本到类别中心的距离平方和，即误差平方和，值越小说明聚类效果越好。综合考虑肘部法则以及各类样本量，本题类簇数量为 4。




图 32 聚类图

图 32 展示了各聚类所包含的样本量占总体的百分比，其中类别一有 6 个样本，即有 6 名患者聚类为一类；有 39 名患者被聚类到类别二；有 20 名患者被聚类到一起，为类别三；另外 35 名患者被聚类在一起，为类别四。由于大多数患

者对于干预治疗的反应应该是差不多的，会有少部分患者由于个体自身的抗药性，恢复力等原因产生的反应与大部分患者不同，故会有极少数患者单独聚为一类，与现实情况时一致的。

表 18 聚类评价指标

轮廓系数	DBI	CH
0.849	0.365	205.502

通过表 18 可知，我们的聚类效果时比较好的。

3.8 建立模型并评价

3.8.1 类别一建模

对类别一的患者水肿体积随时间变化的数据进行建模，将数据导入到 Matlab 中，用多项式和高斯函数对数据进行拟合。

表 19 评价指标

评价指标	R^2	SSE	MSE
三阶 OLS 多项式	0.7418	1.139e+10	2.178e+04
四阶 OLS 多项式	0.7422	1.137e+10	2.224e+04
三阶 LAR 多项式	0.7376	1.157e+10	2.196e+04
四阶 LAR 多项式	0.7313	1.185e+10	2.27e+04
单高斯分布函数	0.6487	1.549e+10	2.49e+04
双高斯分布函数	0.7204	1.233e+10	2.368e+04

表 19 展示了不同阶数多项式以及高斯函数的可决系数 R^2 ，残差平方和 SSE 以及均方误差 MSE，综合比较这三个评价指标，并防止函数过拟合，本题选取三阶多项式来拟合类别一患者水肿体积随时间变化数据，多项式函数表达式如下：

$$f(x) = 29490 + 18040x - 1307x^2 + 30.37x^3$$




图 33 双高斯分布（左）和三阶 LAR（右）




图 34 三阶 OLS 函数

3.8.2 类别二建模

对类别二的患者水肿体积随时间变化的数据进行建模,将数据导入到 Matlab 中,用多项式和高斯函数对数据进行拟合。

表 20 评价指标

阶数	R^2	SSE	MSE
四阶 OLS 多项式	0.1499	6.144e+10	1.858e+04
五阶 OLS 多项式	0.1703	5.997e+10	1.841e+04
四阶 LAR 多项式	0.8976	7.401e+09	6448
五阶 LAR 多项式	0.8635	9.865e+09	7465
单高斯分布函数	0.1719	5.985e+10	1.823e+04
双高斯分布函数	0.1993	5.787e+10	1.808e+04
三高斯分布函数	0.2179	5.653e+10	1.802e+04

表 20 展示了不同阶数多项式以及高斯函数的可决系数 R^2 , 残差平方和 SSE 以及均方误差 MSE, 综合比较这三个评价指标, 本题选取四阶 LAR 回归函数来拟合类别二患者水肿体积随时间变化数据, 函数表达式如下:

$$f(x) = 29270 + 6318x - 22990x^2 + 6496x^3 - 488.5x^4$$




图 35 三高斯分布函数 (左) 和三阶 OLS (右)




图 36 四阶 LAR 函数

3.8.4 类别三建模

对类别三的患者水肿体积随时间变化的数据进行建模,将数据导入到 Matlab 中,用多项式和高斯函数对数据进行拟合。

表 21 评价指标

阶数	R^2	SSE	MSE
三阶 OLS 多项式	0.3742	3.807e+10	2.092e+04
四阶 OLS 多项式	0.4051	3.62e+10	2.052e+04
三阶 LAR 多项式	0.9064	5.695e+09	8091
四阶 LAR 多项式	0.3901	3.711e+10	2.077e+04
单高斯分布函数	0.2458	4.589e+10	2.284e+04
双高斯分布函数	0.3963	3.673e+10	2.079e+04
三高斯分布函数	0.3463	3.978e+10	2.202e+04

表 21 展示了不同阶数多项式以及高斯函数的可决系数 R^2 , 残差平方和 SSE 以及均方误差 MSE, 综合比较这三个评价指标, 本题选取三阶 LAR 回归函数来拟合类别三患者水肿体积随时间变化数据, 函数表达式如下:

$$f(x) = 51340 + 43350x - 48710x^2 + 5247x^3$$




图 37 双高斯分布函数 (左) 和四阶 OLS (右)




图 38 三阶 LAR 函数

3.8.5 类别四建模

对类别四的患者水肿体积随时间变化的数据进行建模,将数据导入到 Matlab 中,用多项式和高斯函数对数据进行拟合。

表 22 评价指标

阶数	R^2	SSE	MSE
五阶 OLS 多项式	0.1563	6.694e+09	6866
六阶 OLS 多项式	0.1631	6.641e+09	6863
一阶 LAR 多项式	0.9739	2.074e+08	1192
二阶 LAR 多项式	0.9496	4.001e+08	1661
三阶 LAR 多项式	0.915	6.742e+08	2164
五高斯分布函数	0.3401	5.236e+09	6274
六高斯分布函数	0.4166	4.629e+09	5967

表 22 展示了不同阶数多项式以及高斯函数的可决系数 R^2 , 残差平方和 SSE 以及均方误差 MSE, 综合比较这三个评价指标, 并防止函数过拟合, 本题选取三阶 LAR 回归函数来拟合类别四患者水肿体积随时间变化数据, 函数表达式如下:

$$f(x) = 53362 - 4754x + 1122x^2 - 76.53x^3$$




图 39 三高斯分布函数（左）和三阶 OLS（右）




图 40 三阶 LAR 函数

根据题目要求，残差结果已经在答案文件 4 中提供。请查看该文件以获取具体的模型预测结果。

3.9 问题二(c)的分析与思路

问题二(c)是让我们分析不同治疗方法对水肿体积进展模式的影响。

第一步：预处理数据，并对治疗方法以及水肿进展模式进行描述型统计分析。

第二步：将水肿进展模式用 logistic 回归进行分类处理，使水肿进展模式变成一个二分类变量。

第三步：用 critic 权重法对七大治疗方案进行客观赋权，排除主观因素对治疗方案权重的影响，客观说明了各治疗方案对水肿进展模式的作用。

第四步：以两个二分类变量对结局变量的影响为例说明治疗方案间的交互作用。

第五步：用主成分分析法探究七大治疗方案对结局变量（水肿进展模式）的影响。

3.10 治疗方法对水肿进展模式的影响

要探究不同治疗方法对水肿进展模式的影响，首先要将水肿进展作量化处理，将进展情况变得可衡量。由于每位患者入院检查次数不同，比如有人随访了 6 次，而有人只随访了 2 次。所以为将水肿进展情况可视化，需采用合理的方法来衡量患者水肿进展情况。

首先将水肿进展模式用 logistic 回归进行分类处理，使水肿进展模式变成一个二分类变量，然后对治疗方法以及水肿进展模式进行描述型统计分析，治疗方案均为二分类变量(使用或不使用)。用 critic 权重法对七大治疗方案进行客观赋权，排除主观因素对治疗方案权重的影响，客观说明了各治疗方案对水肿进展模式的作用。上述已经把水肿进展模式转化为二分类变量，接着以两个二分类变量对结局变量的影响为例说明治疗方案间的交互作用，当说明治疗方案间有交互作用后。最后用主成分分析法探究七大治疗方案对结局变量(水肿进展模式)的影响。




图 41 针对水肿的治疗方案

3. 10. 1 数据预处理

治疗方法是二分类变量，0 代表未使用此种治疗方法，1 代表使用了此种治疗方法，水肿进展模式有两种研究方法，一种，由于肿块体积小于一定值时，人体的免疫和自我保护功能可以自行消除肿块，从而自愈，所以可以直接看患者最后一次随访检查时间对应的水肿块体积大小。另一种是根据最后一次随访时间对应的肿块体积与首次入院检查时间对应的肿块体积比值。因为患者存在个体差异，入院时肿块体积大小不一样，即患者脑出血严重程度不同，为了消除这种起点的差异，肿块相对比值不失为一种不错的选择。最后一次随访时间对应的肿块体积与首次入院检查时间对应的肿块体积比值是一个相对值，若该比值很小，即时最终比值很小，只能说明患者经过治疗后，相对于首次入院时的情况，好转很多，但是需要注意的是并不意味着患者肿块已经消失，相反患者最后一次随访时间的水肿体积也可能很大，也无法判断相应患者的水中治疗效果是否达到可自愈标准，原因在于患者首次入院检查时间点对应的水肿体积可能很大。但相比入院时好转就足以说明治疗方法的有效性。故为直接探究治疗方法对水肿进展模式的影响，选取第二种研究水肿进展模式的方法，即根据最后一次随访时间对应的肿块体积与首次入院检查时间对应的肿块体积比值。首先进行了数据预处理，统计前 100 位患者自首次发病后随访总次数，详情见下表：

表 23 患者随访总次数

ID	Sub001	Sub002	Sub003	Sub004	Sub005	Sub006	Sub007	Sub008	Sub009	Sub010
num	4	4	2	3	2	4	6	3	2	4
ID	Sub011	Sub012	Sub013	Sub014	Sub015	Sub016	Sub017	Sub018	Sub019	Sub020
num	2	6	4	2	3	2	3	3	5	4
ID	Sub021	Sub022	Sub023	Sub024	Sub025	Sub026	Sub027	Sub028	Sub029	Sub030
num	3	2	6	3	2	3	3	4	3	4
ID	Sub031	Sub032	Sub033	Sub034	Sub035	Sub036	Sub037	Sub038	Sub039	Sub040
num	2	2	5	3	5	4	4	4	6	5
ID	Sub041	Sub042	Sub043	Sub044	Sub045	Sub046	Sub047	Sub048	Sub049	Sub050
num	3	3	3	5	3	2	3	3	3	2
ID	Sub051	Sub052	Sub053	Sub054	Sub055	Sub056	Sub057	Sub058	Sub059	Sub060
num	4	5	3	3	2	8	2	2	2	8
ID	Sub061	Sub062	Sub063	Sub064	Sub065	Sub066	Sub067	Sub068	Sub069	Sub070
num	5	2	7	5	3	4	2	7	4	2
ID	Sub071	Sub072	Sub073	Sub074	Sub075	Sub076	Sub077	Sub078	Sub079	Sub080
num	5	2	2	5	4	4	4	2	4	2
ID	Sub081	Sub082	Sub083	Sub084	Sub085	Sub086	Sub087	Sub088	Sub089	Sub090
num	4	2	2	4	5	3	4	2	3	3
ID	Sub091	Sub092	Sub093	Sub094	Sub095	Sub096	Sub097	Sub098	Sub099	Sub100
num	3	3	4	4	4	5	2	4	2	2

由于水肿体积是连续变量，治疗方案不同，治疗效果不同，但考虑到实际情况，患者一旦脑出血出现水肿情况，经过治疗一般有两类情形，情形一：经过治疗患者水肿好转甚至消失；情形二患者水肿经治疗还是不减甚至增大。为便于分析治疗方法对水中进展模式的影响，我们首先将连续形最后一次随访时间对应的肿块体积与首次入院检查时间对应的肿块体积比值转化成二分类变量，分类依据是，比值大于 1，说明患者水肿情况变差，治疗方案效果一般；比值小于 1，说明患者水肿情形好转，治疗效果好。

3. 10.2 logistic 回归分类模型




图 42 logistic 分类过程图

设某事件在影响因素 $x_1, x_2, \dots, x_m$ 的作用下发生的概率为 π ，不发生的概率为 $1-\pi$ ，则有式 所定义的模型为 logistics 回归模型：

$$\pi = \frac{\exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)}{1 + \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)} \quad (25)$$

其中 β_0 为截距， $\beta_1, \beta_2, \dots, \beta_m$ 为回归系数。事件发生的概率 π 和未发生的概率 $1-\pi$ 之比为优势比(odds ratio, OR), $\log it \pi$ 为 OR 的自然对数：

$$\log it \pi = \ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m \quad (26)$$

Logistic 回归模型适用于分类的反应变量与多个影响因素之间关系的研究，在医学研究中有非常广泛的应用。拟合 logistics 回归模型中，要求连续性变量与 $\log it \pi$ 之间符合线性关系，如果两者之间是非线性关系，参数估计就会出现偏差。

(1) 连续性变量与 $\log it \pi$ 线性关系的判断

国内研究者陈长生、徐勇勇等于 2001 年通过模拟实验，说明半参数回归模型较传统的线性模型有更好的适应性，Wand 等于 2003 年对半参数回归模型进行了系统描述，并编制 R 软件中的“SemiPar”包用于半参数回归模型分析。SemiPar 包中的半参数回归模型是一种使用了 $2m-1$ 次样条平滑的混合模型，其一般表达式为：

$$f(x) = \sum_{j=0}^{2m-1} \beta_j x^j + \sum_{k=1}^k u_k |x - u_k|^{2m-1} \quad (27)$$

上式中随机系数 $u = [u_1, \dots, u_k]^T \sim N(0, \sigma_u^2 \Omega^{-1/2} (\Omega^{-1/2})^T)$ ， $\Omega = \left[\begin{matrix} K_k - k_k' \\ 1 \leq k, k \leq K \end{matrix} \right]^{2m-1}$ 。

可采用半参数回归模型对自变量与 $\log it \pi$ 间的函数关系进行判断，根据自由度是否大于 2，判定自变量与 $\log it \pi$ 之间是否满足单调变化性。

(2) 用 logistics 回归分类水肿进展模式变量

表 24 水肿进展模式二分类表

ID	Sub001	Sub002	Sub003	Sub004	Sub005	Sub006	Sub007	Sub008	Sub009	Sub010
类别	1	0	1	0	0	0	1	1	1	0
ID	Sub011	Sub012	Sub013	Sub014	Sub015	Sub016	Sub017	Sub018	Sub019	Sub020
类别	0	0	0	1	1	1	1	1	0	0
ID	Sub021	Sub022	Sub023	Sub024	Sub025	Sub026	Sub027	Sub028	Sub029	Sub030
类别	1	1	1	0	0	1	1	0	0	1
ID	Sub031	Sub032	Sub033	Sub034	Sub035	Sub036	Sub037	Sub038	Sub039	Sub040
类别	1	0	0	1	0	1	0	1	0	1
ID	Sub041	Sub042	Sub043	Sub044	Sub045	Sub046	Sub047	Sub048	Sub049	Sub050

类别	0	0	1	0	1	1	0	1	0	1
ID	Sub051	Sub052	Sub053	Sub054	Sub055	Sub056	Sub057	Sub058	Sub059	Sub060
类别	0	0	0	1	1	0	1	1	1	0
ID	Sub061	Sub062	Sub063	Sub064	Sub065	Sub066	Sub067	Sub068	Sub069	Sub070
类别	1	1	1	0	1	0	1	0	0	1
ID	Sub071	Sub072	Sub073	Sub074	Sub075	Sub076	Sub077	Sub078	Sub079	Sub080
类别	0	1	1	1	0	0	1	0	0	0
ID	Sub081	Sub082	Sub083	Sub084	Sub085	Sub086	Sub087	Sub088	Sub089	Sub090
类别	1	0	1	1	0	0	0	1	1	0
ID	Sub091	Sub092	Sub093	Sub094	Sub095	Sub096	Sub097	Sub098	Sub099	Sub100
类别	1	1	0	0	1	0	0	0	1	0

3. 10. 3 描述性统计分析

首先对治疗方法进行描述性统计分析。

表 25 治疗方法频数表

治疗方法	次数
脑室引流	6
止血治疗	79
降颅压治疗	76
降压治疗	92
镇静、镇痛治疗	85
止吐护胃	97
营养神经	96

从上表可知，前 100 位患者有 6 人采用了脑室引流、79 人进行了止血治疗、76 人进行了降颅压治疗、92 人进行了降压治疗、85 人进行了镇静止痛治疗、97 人进行了止吐护胃、96 人进行了营养神经治疗。值得注意的是，100 位患者中只有 6 人进行了脑室引流，较为少见。

表 26 基础指标

名称	样本量	最小值	最大值	平均值	标准差	中位数
脑室引流	100	0.000	1.000	0.060	0.239	0.000
止血治疗	100	0.000	1.000	0.790	0.409	1.000
降颅压治疗	100	0.000	1.000	0.760	0.429	1.000
降压治疗	100	0.000	1.000	0.920	0.273	1.000
镇静、镇痛治疗	100	0.000	1.000	0.850	0.359	1.000
止吐护胃	100	0.000	1.000	0.970	0.171	1.000
营养神经	100	0.000	1.000	0.960	0.197	1.000
类别	100	0.000	1.000	0.500	0.503	0.500

从上表中可观察到各治疗方法的平均值除脑室引流外，均超过 0.5，超出 0.5

说明在这 100 位患者中，该项治疗方法使用的比例大于未使用的比例。

3. 10. 4 交互作用分析

医学研究中交互作用研究的结局通常是二分类变量，如疾病或某个事件是否发生，再入本题中水肿进展情况好转或者恶化（以 0 和 1 分别表示），研究因素可以为二分类变量、多分类变量、等级变量或数值变量。最常见的研究两个变量对于结局的交互作用，称之为二阶交互作用，研究方法和理论可以推广到高阶交互作用^[1]。

交互作用定义的核心是一个因素的效应大小会随着另一个因素的水平而变化；反之，如果两个因素没有交互作用，那么，一个因素的效应大小在另一个因素的不同水平之间是相同的。交互作用的定义常见于统计学或流行病学教科书和软件程序中。统计交互作用有时也被称为效应修饰，效应修饰的同义词是调节效应和效应异质。

交互作用的分类：交互作用按照效应累积方式或效应尺度分为相加交互作用和相乘交互作用两类；按照作用方向可以分为协同作用和拮抗作用。以结局和 2 个自变量均为二分类变量为例说明两种分类之间的关系，设 $p_{AB} = P(D=1|A=a, B=b)$ 表示感兴趣的二分类因素 A 和 B 分别取值为 a 和 b 时结局 D 发生的平均风险，其中，a, b 均取值 0 或 1，0 表示为暴露于研究因素，1 表示暴露于研究因素。假设因素 A 和 B 是对等的，即互换 A 和 B 不影响结论。相互交互作用基于风险差（RD）尺度，即交互作用估计为：

$$(p_{11} - p_{00}) - [(p_{10} - p_{00}) + (p_{01} - p_{00})] = p_{11} - p_{10} - p_{01} + p_{00} \quad (28)$$

相乘交互作用基于风险比（risk ratio，RR）尺度，即交互作用估计为：

$$\frac{p_{11} / p_{00}}{(p_{10} / p_{00})(p_{01} / p_{00})} = \frac{p_{11}p_{00}}{p_{10}p_{01}} \quad (29)$$

衡量风险的相对变化，可用于病因学中危险因素评价，具有病因学意义。如果因素 A 和 B 对结局的效应可乘，由上式可知 $p_{11} / p_{00} = (p_{10} / p_{00})(p_{01} / p_{00})$ ，这说明：风险比尺度上，同时暴露于因素 A 和 B 时的风险增量是分别暴露于因素 A 和 B 的风险增量的简单相乘。同理可以在风险比尺度上定义拮抗和协同作用。

表 27 交互作用类型

作用类型	拮抗作用	无交互作用	协同作用
相加交互作用	$p_{11} - p_{10} - p_{01} + p_{00} < 0$ 次可加	$p_{11} - p_{10} - p_{01} + p_{00} = 0$ 可加	$p_{11} - p_{10} - p_{01} + p_{00} > 0$ 超可加
相乘交互作用	$0 < \frac{p_{11}p_{00}}{p_{10}p_{01}} < 1$ 次可乘	$\frac{p_{11}p_{00}}{p_{10}p_{01}} = 1$ 可乘	$\frac{p_{11}p_{00}}{p_{10}p_{01}} > 1$ 超可乘




图 43 可加可乘作用分析

实际医学应用中，针对脑出血患者，不会采用单一治疗方法治疗患者，往往除同时采用上述七种治疗方法中的几种外，还采用其他的治疗方法，如开颅清除血肿治疗方式。

3. 10. 5 CRITIC 权重法




图 44 CRITIC 方法

CRITIC 法是一种比熵权法和标准离差法更好的客观赋权法，它基于评级指标的对比强度和指标之间的冲突性来综合衡量指标的客观权重。考虑指标变异性大小的同时兼顾指标之间的相关性，并非数字越大就说明越重要，完全利用数据自身的客观属性进行科学评价。

对比强度是指同一个指标各个评价方案之间取值差距的大小，以标准差的形式来表现。标准差越大，说明波动越大，即各方案之间的取值差距越大，权重会越高；指标之间的冲突性，用相关系数进行表示，若两个指标之间具有较强的正相关，说明其冲突性越小，权重会越低。

对于 CRITIC 法而言，在标准差一定时，指标间冲突性越小，权重也越小；冲突性越大，权重也越大。此外，当两个指标间的正相关程度越大时，冲突性越小，这表明这两个指标在评价方案的优劣上反映的信息有较大的相似性。步骤如下：

I. 假设有 n 个待评价样本， p 项评价指标，形成原始指标数据矩阵：

$$X = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \quad (30)$$

其中 x_{ij} 表示第 i 个样本第 j 项评价指标的数值。

为消除因量纲不同对评价结果的影响，需要对各指标进行无量纲化处理。CRITIC 权重法一般使用正向化或逆向化处理，不建议使用标准化处理，原因是如果使用标准化处理，标准差全部都变成数字 1，即所有指标的标准差完全一致，这就导致波动性指标没有意义。

II. 正向化或逆向化处理：

若所用指标的值越大越好（正向指标），则用

$$x'_{ij} = \frac{x_j - x_{\min}}{x_{\max} - x_{\min}} \quad (31)$$

若所用指标的值越小越好（逆向指标），则用

$$x'_{ij} = \frac{x_{\max} - x_j}{x_{\max} - x_{\min}} \quad (32)$$

III. 指标变异性的计算,以标准差的形式来表现

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij} \quad (33)$$

$$S_j = \sqrt{\frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}{n-1}} \quad (34)$$

S_j 表示第 j 个指标的标准差，在 CRITIC 法中使用标准差来表示各指标的内取值的差异波动情况，标准差越大表示该指标的数值差异越大，越能放映出更多的信息，该指标本身的评价强度也就越强，应该给该指标分配更多的权重。

IV. 指标冲突性的计算，用相关系数进行表示，

$$R_j = \sum_{i=1}^p (1 - r_{ij}) \quad (35)$$

其中 r_{ij} 表示评价指标 i 和 j 之间的相关系数。使用相关系数来表示指标间的相关性，与其他指标的相关性越强，则该指标就与其他指标的冲突性越小，反映出相同的信息越多，所能体现的评价内容就越有重复之处，一定程度上也就削弱了该指标的评价强度，应该减少对该指标分配的权重。

V. 计算信息量

$$C_j = S_j \sum_{i=1}^p (1 - r_{ij}) = S_j \times R_j \quad (36)$$

C_j 越大，第 j 个评价指标在整个评价指标体系中的作用越大，就应该给其分配更多的权重。

VI. 客观权重的计算，第 j 个指标的客观权重为：

$$W_j = \frac{C_j}{\sum_{j=1}^p C_j} \quad (37)$$

3.10.6 治疗方法赋权

根据 CRITIV 权重法对七大治疗方法赋予权重，结果如下：

表 28 CRITIV 法赋权

项	指标变异性	指标冲突性	信息量	权重(%)
脑室引流	0.239	5.973	1.426	12.817
止血治疗	0.409	5.331	2.182	19.618
降颅压治疗	0.429	5.242	2.25	20.227
降压治疗	0.273	5.114	1.394	12.536
营养神经	0.197	5.332	1.05	9.441
止吐护胃	0.171	5.378	0.922	8.289
镇静、镇痛治疗	0.359	5.291	1.899	17.072

结果显示，脑室引流的权重为 12.817%、止血治疗的权重为 19.618%、降颅压治疗的权重为 20.227%、降压治疗的权重为 12.536%、营养神经的权重为 9.441%、止吐护胃的权重为 8.289%、镇静、镇痛治疗的权重为 17.072%，其中指标权重最大值为降颅压治疗 (20.227%)，最小值为止吐护胃 (8.289%)。

3.11 主成分分析

上述交互作用分析说明七种治疗方法间存在联系，现提取主成分进行水肿进展模式的分析。

3.11.1 主成分分析介绍

主成分分析是一种常用于数据降维和特征提取的统计技术。它的主要目标是将多维数据转换为较少维度的数据，同时保留数据中的最大可变性。PCA 可以用于探索数据的内在结构，减少冗余信息，并提供更清晰、更紧凑的数据表示。在 PCA 中，我们首先需要处理的是一个包含多个变量或特征的数据矩阵，其中每一行代表一个观察样本，每一列代表一个变量。这些变量可以是数值型或定性的，但必须以数据矩阵的形式组织。

在进行 PCA 之前，常常需要对数据进行中心化处理，即减去每个变量的均值，以确保数据的均值为零。这有助于消除变量之间的平移差异，使分析更加准确。

PCA 的核心思想是通过寻找原始数据中的主成分来降低数据的维度。这些主成分是原始变量的线性组合，通过计算数据的协方差矩阵，我们可以找到它们。

协方差矩阵展示了不同变量之间的相关性。

通过对协方差矩阵进行特征值分解，我们可以找到主成分。每个主成分都有一个特征值，表示主成分所解释的数据方差的大小，以及一个特征向量，表示主成分的方向。通常，主成分按特征值的大小排序，最大特征值对应的特征向量表示第一主成分，依此类推。

在选择保留的主成分数量时，通常会考虑到主成分的累积方差贡献率，以确保保留足够的信息。一旦确定了主成分，我们可以使用它们将原始数据投影到新的主成分空间中，生成一组新的特征，这些特征是主成分的线性组合。

最后，通过解释每个主成分的含义和影响，我们可以更好地理解数据的结构，并将这些主成分用于可视化、分类、聚类或其他机器学习任务。总之，PCA 是一项有用的数据分析工具，可以帮助简化复杂的数据集，揭示数据中的模式和关系，并提取最重要的信息。



图 45 主成分分析

总之，主成分分析是一种有用的数据降维技术，可用于简化多维数据集，揭示数据中的模式和关系，以及提取最重要的信息。它在数据探索、特征选择和模式识别等领域广泛应用。

3. 11. 2 主成分分析

表 29 主成分分析表

KMO 检验和 Bartlett 的检验		
KMO 值		0.726
	近似卡方	74.656
Bartlett 球形度检验	df	21
	P	0.000***

注：***、**、*分别代表 1%、5%、10%的显著性水平

KMO 检验的结果显示，KMO 的值为 0.726，同时，Bartlett 球形检验的结果显示，显著性 P 值为 0.000***，水平上呈现显著性，拒绝原假设，各变量间具有相关性，主成分分析有效。




图 46 热力图

从图中可以看出降颅压治疗、降压治疗、止血治疗十分重要。这与医学研究相符，脑出血最危险的因素是高血压，一旦发生脑出血、止血必然关键，同时降压治疗也是关键治疗手段。

3.12 问题二(d)的分析与思路

问题二(d)需要分析血肿体积、水肿体积及治疗方法三者之间的关系。

第一步：将相关表内数据整理合并。

第二步：对不同治疗方法进行相关分析

第三步：分析治疗方法对水肿体积、血肿体积的影响。

第四步：基于最终肿块变化情况三者之间的相关关系。

第五步：定义最终肿块变化的概念，用决策树方法分析不同治疗方法对最终肿块变化情况进行分析。

3.13 血肿体积、水肿体积及治疗方法间的关系

不同患者血肿体积和水肿体积不同，所采用的治疗方法也不同，为探究三者之间关系，现进行相关性分析。首先对不同治疗方法进行相关分析，然后分析治疗方法对水肿体积、血肿体积的影响，最后基于最终肿块变化情况三者之间的相关关系。

3.13.1 不同治疗方法之间的相关关系

表 30 治疗方法的相关关系

	均值	标准差	脑室引流	止血治疗	降颅压治疗	降压治疗	营养神经	镇静、镇痛治疗	止吐护胃
脑室引流	0.060	0.239							
止血治疗	0.790	0.409	-0.077	1					

表 30 治疗方法的相关关系

	均值	标准差	脑室引流	止血治疗	降颅压治疗	降压治疗	营养神经	镇静、镇痛治疗	止吐护胃
降颅压治疗	0.760	0.429	-0.055	0.458**	1				
降压治疗	0.920	0.273	0.075	0.300**	0.352**	1			
营养神经	0.960	0.197	0.052	0.020	0.005	0.128	1		
镇静、镇痛治疗	0.850	0.359	-0.012	0.058	-0.039	0.083	0.200*	1	
止吐护胃	0.970	0.171	0.044	-0.091	0.038	-0.052	0.263**	0.419**	1

* $p < 0.05$ ** $p < 0.01$

从上表可知，利用相关分析去研究脑室引流和止血治疗，降颅压治疗，降压治疗，营养神经，镇静、镇痛治疗，止吐护胃共 6 项之间的相关关系，使用 Pearson 相关系数去表示相关关系的强弱情况。具体分析可知：

脑室引流与止血治疗，降颅压治疗，降压治疗，营养神经，镇静、镇痛治疗，止吐护胃共 6 项之间均不会呈现出显著性，相关系数值分别是-0.077, -0.055, 0.075, 0.052, -0.012, 0.044，全部均接近于 0，并且 p 值全部均大于 0.05，意味着脑室引流与止血治疗，降颅压治疗，降压治疗，营养神经，镇静、镇痛治疗，止吐护胃共 6 项之间均没有相关关系。

3. 13. 2 治疗方法与水肿体积及血肿体积的关系

表 31 相关关系表

	HM_volume0	ED_volume0
脑室引流	0.299**	0.313**
止血治疗	0.059	0.017
降颅压治疗	0.212*	0.066
降压治疗	0.059	-0.015
营养神经	0.015	0.053
镇静、镇痛治疗	-0.102	-0.238*
止吐护胃	0.003	0.002

* $p < 0.05$ ** $p < 0.01$

从上表可知，利用相关分析去研究首次入院检查 HM_volume0, ED_volume0 分别和脑室引流，止血治疗，降颅压治疗，降压治疗，营养神经，镇静、镇痛治疗，止吐护胃共 7 项之间的相关关系，使用 Pearson 相关系数去表示相关关系的强弱情况。具体分析可知：

HM_volume0 和脑室引流、降颅压治疗之间有着显著的正相关关系；ED_volume0 和脑室引流之间有着显著的正相关关系。从表中可以发现，患者不论是有水肿还是血肿，脑室引流都是极为必要的，针对血肿患者，进行颅内压治

疗对患者有显著影响。

3. 13. 3 基于最终肿块变化情况三者之间的相关关系

查询文献可知，患者出现肿块包括水肿和血肿，后续发展有三种情况，第一种是随着治疗肿块先增大再慢慢减小直至消失；第二种是患者入院时肿块发展以达到高潮时期，随着医学治疗肿块慢慢减小；第三种是患者即使入院治疗肿块也一直增大。




图 47 肿块进展图

最终肿块变化的定义：将最后一次随访时间点对应的肿块与首次入院检查时间点对应的肿块之间的比例定义为最终肿块的变化。

首先对治疗方案与最终肿块变化之间进行相关性分析，采用 Pearson 相关系数。

表 32 相关性检验

治疗方法	last_firstHM	last_firstED
脑室引流	0.298**	0.184
止血治疗	-0.154	-0.239*
降颅压治疗	-0.081	0.015
降压治疗	0.040	0.091
镇静、镇痛治疗	0.033	0.074
止吐护胃	-0.034	0.028
营养神经	0.091	0.004

* p<0.05 ** p<0.01

从上表可知，利用相关分析去研究 last_firstHM, last_firstED 分别和脑室引流，止血治疗，降颅压治疗，降压治疗，镇静、镇痛治疗，止吐护胃，营养神经共 7 项之间的相关关系，使用 Pearson 相关系数去表示相关关系的强弱情况。具体分析可知：last_firstHM 和脑室引流之间有着显著的正相关关系。

3.14 决策树模型

上面基于最终肿块变化情况分析治疗方法之间的关系，现在考虑决策树方法分析最终肿块变化情况。

3.14.1 决策树原理分析

(1) 决策树的原理

决策树是一个树结构（可以是二叉树或非二叉树）。其每个非叶节点表示一个特征属性上的测试，每个分支代表这个特征属性在某个值域上的输出，而每个叶节点存放一个类别。使用决策树进行决策的过程就是从根节点开始，测试待分类项中相应的特征属性，并按照其值选择输出分支，直到到达叶子节点，将叶子节点存放的类别作为决策结果。

在建立每一棵决策树的过程中，有两点需要注意采样与完全分裂。首先是两个随机采样的过程，随机森林输入的数据要进行行、列的采样。对于行采样，采用有放回的方式，也就是在采样得到的样本集合中，可能有重复的样本。假设输入样本为 N 个，那么采样的样本也为 N 个。这样使得在训练的时候，每一棵树的输入样本都不是全部的样本，使得相对不容易出现过度拟合。然后进行列采样，从 M 个 *features* 中，选择 m 个（ $m \ll M$ ）。之后就是对采样之后的数据使用完全分裂的方式建立出决策树，这样决策树的某一个叶子节点要么是无法继续分裂的，要么里面的所有样本的都是指向的同一个分类。一般很多的决策树算法都一个重要的步骤——剪枝，但是这里不这样干，由于之前的两个随机采样的过程保证了随机性，所以就算不剪枝，也不会出现过度拟合。步骤如下：

I. 选择最佳特征

在每个内部节点上，需要选择一个最佳的特征进行测试。通常，选择特征的标准包括信息增益、基尼不纯度或均方误差等，这些标准旨在最大程度地减少子集的不确定性或不纯度。

II. 分割数据集

选择最佳特征后，将数据集根据该特征的测试结果分成多个子集。每个子集包含那些在特征测试下满足条件的样本。

III. 递归构建子树

对于每个子集，递归地应用步骤 1 和步骤 2，直到满足停止条件。停止条件可以是树的深度达到最大值、节点中的样本数低于阈值或节点的不纯度低于阈值。

IV. 生成叶子节点

一旦到达停止条件，将生成叶子节点。对于分类任务，叶子节点通常表示一个类别标签；对于回归任务，叶子节点表示一个数值输出，通常是该节点中样本的平均值。

(2) 决策树的优缺点

优点

I. 易于理解和解释：决策树模型生成的规则和流程图非常直观，易于理解和解释，使医疗专业人员和患者能够理解决策的依据。

II. 适用于各种数据类型：决策树可以用于处理数值型和定性型数据，不需要太多的数据预处理工作。

III. 鲁棒性：决策树对于数据中的异常值和噪声具有一定的鲁棒性，不容易

受到单个异常值的影响。

IV. 可解释性强：决策树可以提供每个特征的重要性和影响，有助于医疗专业人员了解决策的依据。

缺点

I. 容易过拟合：决策树模型容易在训练数据上过拟合，特别是当树的深度较大或分割过于细致时。

II. 不稳定性：小的数据变化可能导致树结构的显著改变，使模型不够稳定。

III. 难以处理特征关联性：决策树难以处理特征之间的复杂关联性，可能导致不准确的预测。

3. 14. 2 基于决策树最终血肿变化的治疗方法分析

表 33 决策树基本信息汇总

选项	频数	百分比
有效	100	100.00%
缺失	0	0.00%
总计	100	100.00%

将脑室引流，止血治疗，降颅压治疗，降压治疗，镇静、镇痛治疗，止吐护胃，营养神经项作为自变量，而将 last_firstHM 作为因变量进行决策树建模，从上表可以看出，总共有 100 个样本参与分析。




图 48 血肿决策树

上图展示了决策树的内部结构。

I. 每个节点的第一行是分裂该节点所用的属性名字以及分裂指标；

II. 第二行 gini/entropy 表示判断纯度的指标；

III. samples 是该节点所含样本数量。

IV. value 表示不同的类别分别有多少样本数，样本数量最多的那个类别为该节点类别。




图 49 特征权重图

特征权重显示了各标题对模型贡献的重要程度，其加和值为 1，从上表可知：镇静、镇痛治疗所占比重为 50.84%，该特征的权重最高，对模型构建起着关键作用；脑室引流所占比重为 25.45%，该特征的重要性次之，对模型构建起着重要作用；止血治疗所占比重为 19.37%；以上 3 项特征的比重合计占到了 95.66%；剩余 4 项降压治疗、降颅压治疗、止吐护胃、营养神经的比重则分别为：1.26%、1.14%、1.11%、0.84%。

表 34 评价指标

指标	说明	
可决系数	拟合程度指标，0~1 之间越大越好	0.703
平均绝对误差值 MAE	真实值与拟合值的平均值差值，越接近于 0 越好	0.310
均方误差 MSE	误差平方和均值，越接近于 0 越好	0.192
中位数绝对误差 MAD	预测值离中位数残差的绝对值，越小越好	0.252
可解释方差分 EVS	模型对数据波动的解释力度，介于[0, 1]之间，越大越好	0.703

从表中可以看出，训练集拟合效果较好，其中拟合程度为 0.703，平均绝对误差值 MAE 为 0.310，非常接近 0。

3.14.3 基于决策树最终水肿变化的治疗方法分析

表 35 决策树基本信息汇总

选项	频数	百分比
有效	99	99.00%
缺失	1	1.00%
总计	100	100.00%

我们将脑室引流，止血治疗，降颅压治疗，降压治疗，镇静、镇痛治疗，止吐护胃，营养神经项作为自变量，last_firstED 作为因变量进行决策树建模，从上表

可以看出，总共有 99 个样本参与分析。




图 50 水肿决策树

表 36 特征权重值

项	权重值
脑室引流	0.018
止血治疗	0.502
降颅压治疗	0.194
降压治疗	0.009
镇静、镇痛治疗	0.128
止吐护胃	0.061
营养神经	0.087

特征权重显示了各标题对模型贡献的重要程度，其加和值为 1，从上表可知：止血治疗所占比重为 50.22%，该特征的权重最高，对模型构建起着关键作用；降颅压治疗所占比重为 19.39%；镇静、镇痛治疗所占比重为 12.79%；以上 3 项特征的比重合计占到了 82.40%；剩余 4 项营养神经、止吐护胃、脑室引流、降压治疗的比重则分别为：8.73%、6.11%、1.84%、0.92%。

表 37 模型评估结果

指标	说明	
可决系数	拟合程度指标，0~1 之间越大越好	0.171
平均绝对误差值 MAE	真实值与拟合值的平均值差值，越接近于 0 越好	1.532
均方误差 MSE	误差平方和均值，越接近于 0 越好	6.418
中位数绝对误差 MAD	预测值离中位数残差的绝对值，越小越好	1.047
可解释方差分 EVS	模型对数据波动的解释力度，介于[0,1]之间，越大越好	0.171

从表中可以看出，训练集拟合效果不好，拟合程度仅为 0.171。

3. 15 随机森林模型

在考虑决策树方法分析最终肿块变化情况后,本文尝试用随机森林方法分析后进行比较。

3. 15. 1 随机森林原理分析

随机森林通过自助法(*bootstrap*)重采样技术,从原始训练样本集 N 中有放回地重复随机抽取 k 个样本生成新的训练样本集合,然后根据自助样本集生成 k 个分类树组成随机森林,新数据的分类结果按分类树投票多少形成的分数而定。其实质是对决策树算法的一种改进,将多个决策树合并在一起,每棵树的建立依赖于一个独立抽取的样品,森林中的每棵树具有相同的分布,分类误差取决于每一棵树的分类能力和它们之间的相关性。特征选择采用随机的方法去分裂每一个节点,然后比较不同情况下产生的误差。能够检测到的内在估计误差、分类能力和相关性决定选择特征的数目。单棵树的分类能力可能很小,但在随机产生大量的决策树后,一个测试样品可以通过每一棵树的分类结果经统计后选择最可能的分类。

随机森林中的每一棵分类树为二叉树,其生成遵循自顶向下的递归分裂原则,即从根节点开始依次对训练集进行划分;在二叉树中,根节点包含全部训练数据,按照节点纯度最小原则,分裂为左节点和右节点,它们分别包含训练数据的一个子集,按照同样的规则节点继续分裂,直到满足分支停止规则而停止生长。若节点 n 上的分类数据全部来自于同一类别,则此节点的纯度 $I(n)=0$, 纯度度量方

法是 *Gini* 准则,即假设 $P(x_j)$ 是节点 n 上属于 x_j 类样本个数占训练。

具体实现过程如下:

- (1) 原始训练集为 N , 应用 *bootstrap* 法有放回地随机抽取 k 个新的自助样本集,并由此构建 k 棵分类树,每次未被抽到的样本组成了 k 个袋外数据;
- (2) 设有 m 个变量,则在每一棵树的每个节点处随机抽取 $mtry$ 个变量,然后在 $mtry$ 中选择一个最具有分类能力的变量,变量分类的阈值通过检查每一个分类点确定;
- (3) 每棵树最大限度地生长,不做任何修剪;
- (4) 将生成的多棵分类树组成随机森林,用随机森林分类器对新的数据进行判别与分类,分类结果按树分类器的投票多少而定。

3. 15. 2 基于随机森林最终血肿变化的治疗方法分析

表 38 随机森林基本信息汇总

选项	频数	百分比
有效	100	100.00%
缺失	0	0.00%
总计	100	100.00%

将脑室引流,止血治疗,降颅压治疗,降压治疗,镇静、镇痛治疗,止吐护胃,

营养神经项作为自变量，而将 last_firstHM 作为因变量进行随机森林建模，从上表可以看出，总共有 100 个样本参与分析。




图 51 特征权重图

观察图可知，脑室引流所占比重为 27.46%，该特征的权重最高，对模型构建起着关键作用；降颅压治疗所占比重为 21.18%，该特征的重要性次之，对模型构建起着重要作用；止血治疗所占比重为 19.95%；镇静、镇痛治疗所占比重为 18.13%；以上 4 项特征的比重合计占到了 86.72%；剩余 3 项降压治疗、营养神经、止吐护胃的比重则分别为：6.15%、3.57%、3.56%。

表 39 模型评估结果

指标	说明	
可决系数	拟合程度指标，0~1 之间越大越好	0.556
平均绝对误差值 MAE	真实值与拟合值的平均值差值，越接近于 0 越好	0.371
均方误差 MSE	误差平方和均值，越接近于 0 越好	0.286
中位数绝对误差 MAD	预测值离中位数残差的绝对值，越小越好	0.298
可解释方差分 EVS	模型对数据波动的解释力度，介于[0,1]之间，越大越好	0.556

从模型评估结果来看，拟合效果一般，但误差值较小。

3. 15. 3 基于随机森林最终水肿变化的治疗方法分析

表 40 随机森林基本信息汇总

选项	频数	百分比
有效	99	99.00%
缺失	1	1.00%
总计	100	100.00%

将脑室引流，止血治疗，降颅压治疗，降压治疗，镇静、镇痛治疗，止吐护胃，营养神经项作为自变量，而将 last_firstED 作为因变量进行随机森林建模，从

上表可以看出，总共有 99 个样本参与分析。




图 52 特征权重图

从上图可知：止血治疗所占比重为 26.72%，该特征的权重最高，对模型构建起着关键作用；营养神经所占比重为 19.13%；降颅压治疗所占比重为 17.33%；镇静、镇痛治疗所占比重为 15.89%；以上 4 项特征的比重合计占到了 79.07%；剩余 3 项降压治疗、止吐护胃、脑室引流的比重则分别为：8.17%、8.13%、4.63%。

表 41 模型评估结果

指标	说明	
均方误差	拟合程度指标，0~1 之间越大越好	0.152
平均绝对误差值 MAE	真实值与拟合值的平均值差值，越接近于 0 越好	1.616
均方误差 MSE	误差平方和均值，越接近于 0 越好	6.568
中位数绝对误差 MAD	预测值离中位数残差的绝对值，越小越好	1.078
可解释方差分 EVS	模型对数据波动的解释力度，介于[0,1]之间，越大越好	0.152

结论：从结果来看，随机森林效果没有决策树优，实际操作中考虑用决策树方法。

四、问题三的模型建立与求解

4.1 问题三(a)的分析与思路

问题三(a)需要前 100 个患者个人史、疾病史、发病相关数据及首次影像结果构建预测模型，构建预测模型预测全部患者 90 天的 mRS 评分。

第一步:数据预处理，并且对各项数据进行概览分析。

第二步:相关性分析，初步分析患者们的个人史、疾病史、发病相关及首次影像结果进行与 90 天后的 mRS 评分的关联程度。

第三步:主成分分析，继续分析患者们的各项特征与 90 天后的 mRS 评分的关联程度。

第四步:初步构建预测患者 90 天 mRS 评分模型。

第五步:建立决策树模型，通过 k 折交叉验证方法和参数网格搜索对模型参数进行调优，接着进行模型训练和模型评估。

第六步:展示模型结果。




图 53 问题三流程图

4.2 基于首次影像的 90 天 mRS 评分预测模型

卒中患者是指患有卒中的个体，卒中是一种突发性脑血管事件，通常分为两种主要类型：缺血性卒中和出血性卒中。缺血性卒中（Ischemic Stroke）通常由于脑血管阻塞而导致脑部血流不足或中断，最常见的原因是血栓形成或脑动脉狭窄。缺血性卒中占卒中病例的大多数，患者可能会出现突发性面瘫、肢体无力、言语障碍等症状。而出血性卒中（Hemorrhagic Stroke）通常由于脑部血管破裂或漏血而导致大脑组织受损。出血性卒中包括脑出血和蛛网膜下腔出血，可能导致剧烈头痛、意识丧失等症状。

卒中是一种紧急情况，因为脑部供血中断可能导致脑组织受损甚至坏死，严

重的卒中可能会导致残疾甚至死亡。因此，卒中患者需要紧急的医疗干预和治疗。卒中是一个复杂的医学问题，涉及多个医学领域的知识，包括神经学、心脑血管病学、医学影像学等。对卒中患者的诊断、治疗和康复过程需要协同工作的多专业医疗团队的参与。及早的卒中干预和康复治疗可以显著提高患者的预后和生活质量。

mRS 评分（Modified Rankin Scale），也称改良 Rankin 评分，是一种常用于评估中风（卒中）患者的功能状态和残疾程度的临床工具。它用于量化患者在中风后的日常生活功能和独立性，帮助医生和研究人员了解患者的预后，评估治疗效果以及进行卒中研究。mRS 评分范围从 0 到 6，每个数字对应了不同的功能状态。




图 54 mRS 评分体系

mRS 评分通常在中风后的特定时间点进行，如中风发作后的 90 天。这个评分系统提供了一个量化的方式来描述患者的功能状态，帮助医生和研究人员更好地了解患者的康复进程，评估治疗效果，以及进行卒中研究和临床试验。

4. 2. 1 数据预处理

根据题目要求，需要使用前 100 位患者（sub001 至 sub100）的个人史、疾病史、发病相关信息（"表 1"字段 E 至 W）以及首次影像结果（"表 2"和"表 3"中相关字段）来构建预测模型，该模型的目标是预测这些患者的 90 天后的 mRS 评分。相应的部分数据在问题一中已经处理完成，可以直接使用。只需要将表 3 中水肿部分的数据根据流水号对应合并处理，具体数据处理方法和问题一一致，在此不再赘述。



图 55 处理数据

接下来对数据整体进行概览,来大致了解数据。

表 42 个人史数据概览

变量名	最大值	最小值	平均值	标准差	中位数	方差	峰度	偏度
90mRS	6	0	2.66	1.689	3	2.853	-0.937	0.193
脑出血前 mRS	2	0	0.06	0.312	0	0.097	30.742	5.51
年龄	93	35	63.87	13.893	63	193.003	-0.9	0.012

这些统计数据提供了关于个人史数据集的基本信息。其中，90mRS 评分的平均值为 2.66，标准差为 1.689，呈现出一定的变化范围，而脑出血前 mRS 评分的平均值较低，为 0.06，但具有较高的峰度和偏度，表明数据可能存在一定的倾斜。年龄的平均值约为 63.87 岁，呈现出较小的标准差，分布相对较为集中。

表 43 部分影像检查结果数据概览

变量名	最大值	最小值	均值	标准差	中位数	方差	峰度	偏度
HM_volume	188134	2481	36706.07	29885.932	31472.5	893168929.338	9.351	2.499
HM_ACA_R_Ratio	0.496	0	0.038	0.091	0	0.008	11.483	3.212
HM_MCA_R_Ratio	0.994	0	0.321	0.382	0.151	0.146	-1.139	0.735
HM_PCA_R_Ratio	0.835	0	0.135	0.209	0.039	0.044	1.627	1.686
HM_Pons_Medulla_R_Ratio	0.082	0	0.006	0.017	0	0	8.798	3.052
HM_Cerebellum_R_Ratio	0.122	0	0.002	0.013	0	0	71.423	8.088
HM_ACA_L_Ratio	0.724	0	0.043	0.099	0	0.01	22.514	4.022
HM_MCA_L_Ratio	0.996	0	0.304	0.38	0.028	0.144	-0.967	0.82
HM_PCA_L_Ratio	0.701	0	0.109	0.166	0.019	0.028	2.028	1.667
HM_Pons_Medulla_L_Ratio	0.085	0	0.008	0.018	0	0	5.145	2.433

上述数据表提供了关于不同影像检查结果的统计信息。从整体上看，我们可以观察到以下趋势和特点：

HM_volume 表示影像检查的体积数据。其均值为 36706.07，标准差较大，为 29885.932，这表明在样本中存在较大的体积差异。峰度为 9.351，偏度为 2.499，显示出数据分布较为陡峭且偏向右侧，可能存在一些极端值。

对于动脉供血比例的指标（如 HM_ACA_R_Ratio、HM_MCA_R_Ratio 等），它们的均值和标准差在不同指标之间有显著差异。某些指标的分布可能更平均，而其他指标可能更倾向于某一方向。例如，HM_MCA_R_Ratio 的均值相对较高，但标准差较大，峰度为负值，表明其数据分布相对平均。

部分指标的峰度和偏度值较高，表明它们的数据分布可能存在一些异常值或极端值，需要进一步的数据处理和分析。

综合来看，这些统计数据提供了对影像检查结果的总体了解。在进一步的分析中，可以考虑使用可视化工具和统计方法来深入研究这些指标与其他变量之间的关系，以及它们对于目标变量（90 天后的 mRS 评分）的影响。这有助于更好地理解数据并进行建模预测。

4.3 相关性分析

在进行卒中患者的 90 天后 mRS 评分预测任务时，除了构建预测模型外，了解各个因素与患者预后评分之间的相关性也是至关重要的。这种相关性分析不仅有助于我们更深入地理解影响患者康复的因素，还可以为医疗决策提供宝贵的参考信息。通过探索各个因素与 mRS 评分之间的关联，我们可以揭示出哪些因素可能是卒中患者康复的关键因素，从而更好地为患者提供个性化的治疗和康复计划。在这里，我们使用斯皮尔曼秩相关系数来评断相关性。相关系数提供了衡量两个变量之间关系强度和方向的方式。在卒中患者的预后研究中，我们可以利用这些相关系数来分析各个因素与 90 天后 mRS 评分之间的相关性，以确定哪些因素可能对康复产生积极或消极影响。这将有助于我们更全面地理解卒中患者的康复过程。

和之前类似，在这一问题中，我们将继续分别对患者们的个人史、疾病史、发病相关及首次影像结果进行与 90 天后的 mRS 评分的相关性分析。通过这些分析，我们可以深入探讨这些因素与患者预后之间的潜在关联，有助于揭示对于卒中患者来说最具预测性的因素。这些结果将为临床决策和治疗提供重要的参考依据，并有助于更好地理解患者康复和生存的趋势。

4.3.1 个人史分析

表 44 个人史相关分析表

	年龄	性别规范化	90 天 mRS
年龄	1(0.000***)	0.286(0.004***)	0.214(0.033**)
性别规范化	0.286(0.004***)	1(0.000***)	0.067(0.508)
90 天 mRS	0.214(0.033**)	0.067(0.508)	1(0.000***)

注：***、**、*分别代表 1%、5%、10%的显著性水平

通过对个人史数据的相关性分析，我们可以得到一些有趣的发现。首先，年龄与 90 天后的 mRS 评分之间存在显著相关性（ $r = 0.214$ ， $p = 0.033^{**}$ ）。这意味着患者的年龄可能在一定程度上影响其未来康复情况，年龄较大的患者可能更容易出现不利的康复结果。其次，性别规范化与 90 天后的 mRS 评分之间的相关性不显著（ $r = 0.067$ ， $p = 0.508$ ），这表明性别可能对患者的康复没有明显影响。

这些分析结果强调了年龄在卒中患者的预后中的重要性，但同时也指出性别可能不是一个显著的预测因素。这些发现有助于临床医生更好地理解患者的康复潜力，以更有针对性地制定治疗计划。需要注意的是，这些结果仅代表了初步的相关性发现，还需要进一步的研究来确认和深化我们的理解。

4.3.2 疾病史分析

表 45 疾病史相关分析表

	90 天 mRS
90 天 mRS	1(0.000***)
脑出血前 mRS 评分	-0.017(0.870)
高血压病史	0.073(0.470)
卒中病史	0.052(0.608)

糖尿病史	0.299(0.002***)
房颤史	0.168(0.095*)
冠心病史	0.292(0.003***)
吸烟史	-0.22(0.028**)
饮酒史	-0.268(0.007***)

我们对疾病史数据进行了相关性分析，以了解不同疾病史因素与患者 90 天后的 mRS 评分之间的关系。

疾病史与 90 天后的 mRS 评分之间的关系显示出一些有趣的趋势。首先，我们发现脑出血前的 mRS 评分与 90 天后的 mRS 评分之间的相关性不显著，这表明患者之前的脑出血评分似乎与未来的康复情况没有明显关联。高血压病史和卒中病史与 90 天后的 mRS 评分之间的相关性较低，相关性系数都在 0.1 以下。这可能意味着这两个因素对于 90 天后的康复状况影响有限。

然而，糖尿病史和冠心病史与 90 天后的 mRS 评分之间存在显著相关性，相关性系数分别为 0.299 和 0.292。这表明患有糖尿病或冠心病的患者可能在康复过程中面临更多挑战，其康复结果可能较差。

此外，吸烟史和饮酒史也显示出一定的相关性。吸烟史与 90 天后的 mRS 评分呈负相关，而饮酒史与之正相关。这意味着吸烟史可能与较差的康复结果相关，而饮酒史可能与更好的康复结果相关。

总体而言，这些分析结果有助于我们更好地理解不同疾病史因素对卒中患者 90 天后的康复情况的影响。尽管相关性告诉我们这些因素与康复有关，但需要进一步的研究来确定因果关系。这些发现可以为临床实践提供一些指导，帮助医生更好地预测和干预患者的康复进程。

4.3.3 发病相关分析

表 46 发病相关分析表

	90 天 mRS
90 天 mRS	1(0.000***)
发病到首次影像检查时间间隔	0.064(0.525)
高血压	-0.084(0.406)
低血压	-0.263(0.008***)
脑室引流	0.205(0.041**)
止血治疗	-0.056(0.579)
降颅压治疗	0.166(0.099*)
降压治疗	0.156(0.121)
镇静、镇痛治疗	0.142(0.158)
止吐护胃	-0.08(0.427)
营养神经	0.013(0.894)

我们对卒中患者的发病相关因素与 90 天后的 mRS 评分之间进行了相关性分析，以下是主要的研究结果：

首先，我们发现发病后进行首次影像检查的时间间隔与 90 天后的 mRS 评分之间并没有明显相关性 ($r = 0.064$, $p = 0.525$)。这意味着从发病到首次影像

检查的时间似乎不会直接影响康复结果。

对于高血压的存在，我们的分析显示它与 90 天后的 mRS 评分之间没有显著相关性 ($r = -0.084$, $p = 0.406$)。这表明高血压的有无可能不是影响康复的主要因素。然而，与高血压相反，低血压与 90 天后的 mRS 评分之间存在显著的负相关性 ($r = -0.263$, $p = 0.008^{***}$)。这提示低血压可能会对康复产生负面影响。

脑室引流治疗与更好的康复表现之间存在显著正相关 ($r = 0.205$, $p = 0.041^{**}$)，这意味着接受脑室引流治疗的患者可能康复更好。降颅压治疗的相关性趋于显著 ($r = 0.166$, $p = 0.099^{*}$)，尽管统计上不够明显。这可能意味着降颅压治疗对康复产生一定积极影响。

至于止血治疗，相关性分析显示它与 90 天后的 mRS 评分之间没有显著相关性 ($r = -0.056$, $p = 0.579$)，这表明止血治疗是否进行与康复无明显联系。

其他治疗措施，如降压治疗、镇静、镇痛治疗、止吐护胃治疗和营养神经治疗，与 90 天后的 mRS 评分之间没有明显相关性。

总体而言，这些发病相关因素与康复之间的关联性为我们提供了初步见解。低血压、脑室引流治疗和降颅压治疗似乎与更好的康复结果相关，而高血压和其他因素则影响较小。需要进一步的研究来验证这些发现，以更全面地理解发病相关因素对康复的影响。

4.3.4 影像检查结果分析

表 47 影像检查结果相关分析表

	90 天 mRS
90 天 mRS	1(0.000 ^{***})
HM_volume	0.366(0.000 ^{***})
HM_ACA_R_Ratio	0.182(0.069 [*])
HM_MCA_R_Ratio	-0.022(0.831)
HM_PCA_R_Ratio	-0.107(0.290)
HM_Pons_Medulla_R_Ratio	0.056(0.582)
HM_Cerebellum_R_Ratio	-0.083(0.414)
HM_ACA_L_Ratio	0.264(0.008 ^{***})
HM_MCA_L_Ratio	0.176(0.079 [*])
HM_PCA_L_Ratio	0.161(0.110)
HM_Pons_Medulla_L_Ratio	0.13(0.197)
HM_Cerebellum_L_Ratio	0.068(0.501)
ED_volume	0.265(0.008 ^{***})
ED_ACA_R_Ratio	0.107(0.291)
ED_MCA_R_Ratio	-0.004(0.970)
ED_PCA_R_Ratio	-0.113(0.263)
ED_Pons_Medulla_R_Ratio	0.005(0.964)
ED_Cerebellum_R_Ratio	-0.126(0.212)
ED_ACA_L_Ratio	0.143(0.154)
ED_MCA_L_Ratio	0.099(0.326)
ED_PCA_L_Ratio	0.083(0.410)

ED_Pons_Medulla_L_Ratio	0.009(0.930)
ED_Cerebellum_L_Ratio	0.055(0.584)

我们进行了与 90 天后的 mRS 评分相关的影像检查结果分析，以探讨这些影像指标与患者康复状况之间的关系。

首先，我们观察到患者的大脑出血体积(HM_volume)与 90 天后的 mRS 评分之间存在显著正相关($r = 0.366$, $p = 0.000^{***}$)。这意味着大脑出血体积较大的患者更有可能在康复方面面临更大的挑战。在影像中，HM_ACA_L_Ratio(左侧前大脑动脉分布比例)与 90 天后的 mRS 评分之间存在显著正相关($r = 0.264$, $p = 0.008^{***}$)。这表明左侧前大脑动脉的分布可能与更好的康复相关。此外，ED_volume(出血终止后的大脑体积)与 90 天后的 mRS 评分之间也存在显著正相关($r = 0.265$, $p = 0.008^{***}$)。这进一步强调了大脑出血后的影响与康复结果之间的关联性。

然而，HM_ACA_R_Ratio(右侧前大脑动脉分布比例)和 HM_MCA_R_Ratio(右侧中大脑动脉分布比例)与康复之间的相关性不显著。同样，ED_MCA_R_Ratio(出血终止后的右侧中大脑动脉分布比例)也没有明显相关性。

总体而言，这些影像检查结果的分析显示，大脑出血体积以及左侧前大脑动脉的分布比例与患者 90 天后的康复状况之间存在显著关联。这些发现有助于我们更好地理解影像特征如何影响卒中患者的康复，并为个体化治疗提供了有用的信息。但需要注意，这些结果是相关性结果，尚未确定因果关系，需要进一步研究验证。

4.3.5 首次时间点的具体影像检查结果分析

表 48 首次时间点的具体影像检查结果分析表

	90 天 mRS
90 天 mRS	1(0.000 ^{***})
original_shape_Elongation	-0.148(0.141)
original_shape_Flatness	-0.022(0.827)
original_shape_LeastAxisLength	0.351(0.000 ^{***})
original_shape_MajorAxisLength	0.292(0.003 ^{***})
original_shape_Maximum2DDiameterColumn	0.343(0.000 ^{***})
original_shape_Maximum2DDiameterRow	0.197(0.049 ^{**})
original_shape_Maximum2DDiameterSlice	0.294(0.003 ^{***})
original_shape_Maximum3DDiameter	0.282(0.004 ^{***})
original_shape_MeshVolume	0.324(0.001 ^{***})
original_shape_MinorAxisLength	0.246(0.014 ^{**})
original_shape_Sphericity	-0.273(0.006 ^{***})
original_shape_SurfaceArea	0.347(0.000 ^{***})
original_shape_SurfaceVolumeRatio	-0.134(0.185)
original_shape_VoxelVolume	0.324(0.001 ^{***})
NCCT_original_firstorder_10Percentile	0.008(0.935)
NCCT_original_firstorder_90Percentile	-0.067(0.505)
NCCT_original_firstorder_Energy	0.276(0.005 ^{***})
NCCT_original_firstorder_Entropy	-0.206(0.040 ^{**})

NCCT_original_firstorder_InterquartileRange	-0.26(0.009***)
NCCT_original_firstorder_Kurtosis	0.245(0.014**)
NCCT_original_firstorder_Maximum	-0.025(0.807)
NCCT_original_firstorder_MeanAbsoluteDeviation	-0.239(0.017**)
NCCT_original_firstorder_Mean	-0.033(0.744)
NCCT_original_firstorder_Median	-0.033(0.743)
NCCT_original_firstorder_Minimum	-0.104(0.305)
NCCT_original_firstorder_Range	-0.005(0.962)
NCCT_original_firstorder_RobustMeanAbsoluteDeviation	-0.248(0.013**)
NCCT_original_firstorder_RootMeanSquared	-0.039(0.700)
NCCT_original_firstorder_Skewness	-0.077(0.448)
NCCT_original_firstorder_Uniformity	0.174(0.083*)
NCCT_original_firstorder_Variance	-0.216(0.031**)

首先,我们观察到一些具体影像检查结果与患者的康复情况之间存在显著相关性。例如, original_shape_LeastAxisLength (最小轴长度) 与 90 天后的 mRS 评分之间存在显著正相关 ($r = 0.351$, $p = 0.000***$), 这表明较大的最小轴长度可能与更好的康复有关。

此外, original_shape_Maximum2DDiameterColumn (最大二维直径-列)、original_shape_Maximum2DDiameterSlice (最大二维直径-切片)、original_shape_Maximum3DDiameter (最大三维直径) 和 original_shape_SurfaceArea (表面积) 与 90 天后的 mRS 评分之间也存在显著正相关, 这进一步强调了这些影像特征与康复结果之间的关联性。

另一方面, original_shape_Sphericity (球度) 与 90 天后的 mRS 评分之间存在显著负相关 ($r = -0.273$, $p = 0.006***$), 这可能表明较低的球度与更好的康复相关。

然而, 还有一些影像检查结果与康复情况之间的相关性不显著, 包括 original_shape_Flatness (扁平度)、original_shape_VoxelVolume (像素体积) 等。

综合而言, 这些分析结果为我们提供了关于首次时间点的具体影像检查结果如何与卒中患者 90 天后的康复情况相关的初步认识。特定的影像特征, 如最小轴长度、最大直径和表面积, 可能与更好的康复相关。然而, 需要进一步的研究来验证这些关系, 并深入探讨这些影像特征如何影响康复进程。

4.3.6 相关性分析综合结论

通过对个人史、疾病史、发病相关以及首次时间点和具体影像检查结果的相关性分析, 我们得出了一些关于影响患者 90 天后 mRS 评分的初步结论。以下是我们的总结性观点:

首先, 在个人史方面, 我们发现年龄与 90 天后的 mRS 评分存在一定程度的正相关, 这意味着年龄较大的患者可能更容易面临康复挑战。性别与 mRS 评分之间的相关性较低, 性别对康复结果影响有限。

其次, 疾病史方面, 糖尿病和冠心病与 90 天后的 mRS 评分呈显著正相关, 提示患有这些疾病的患者可能在康复过程中面临更多挑战。吸烟和饮酒史与较差的康复结果相关, 这强调了生活方式因素对康复的影响。

发病相关因素中，低血压与较差的康复结果相关，而脑室引流可能有助于更好的康复。其他治疗方法如止血治疗、降颅压治疗等与康复结果的关联性较低。

最后，在影像检查结果方面，一些具体影像特征，如最小轴长度、最大直径和表面积，与更好的康复相关。然而，这些结果需要进一步验证和深入研究。

综合来看，患者 90 天后的 mRS 评分受多种因素的影响，包括个人史、疾病史、发病相关和具体影像检查结果。这些初步结论为进一步研究和临床实践提供了有价值的参考，有助于更好地理解 and 干预卒中患者的康复过程。然而，需要注意的是这些结果仅代表相关性，尚未证明因果关系，因此需要更多的研究来确认这些发现。

我们将继续探讨个人史、疾病史、发病相关、首次时间点和具体影像检查结果等几个方面，通过主成分分析来寻找与 90 天后 mRS 评分最相关的主成分。这将有助于我们识别哪些因素在卒中患者的康复中起到关键作用，并更全面地了解这些因素如何相互关联以及对康复的影响。

通过主成分分析，我们希望能够提取出数据中的重要信息，减少冗余变量，从而更准确地预测患者 90 天后的 mRS 评分。这一章节将为我们提供深入挖掘患者康复情况的机会，有望揭示出新的见解，以指导卒中患者的康复治疗和护理，深入研究这些主成分分析的结果，以更好地了解卒中患者的预后和康复过程。

4. 4 主成分分析

在进一步深入研究患者 90 天后 mRS 评分与不同因素之间的关系时，主成分分析（Principal Component Analysis, PCA）将是我们的有力工具。与之前的相关性分析不同，主成分分析旨在揭示数据中的潜在结构，将多个相关变量转化为少数几个无关主成分，以帮助我们更清晰地理解影响患者康复情况的关键因素。

4. 4. 1 个人史分析

表 49 个人因子载荷系数表

	90 天后 mRS 评分	共同度（公因子方差）
年龄	0.805	0.649
性别规范化	0.805	0.649

在个人史分析中，我们进行了主成分分析以了解个人史变量（年龄和性别规范化）之间的潜在关联。主成分分析是一种降维技术，有助于识别数据中的共性因素，并将它们转化为一组新的综合性因子，以简化数据分析和解释。

在因子载荷系数表中，我们可以看到 90 天后 mRS 评分（第一个主成分）的因子载荷系数。对于年龄和性别规范化这两个变量，它们在 90 天后 mRS 评分中都具有较高的因子载荷系数，分别为 0.805。这意味着 90 天后 mRS 评分主要受这两个变量的影响。共同度（公因子方差）表示每个变量中可以由主成解释的方差比例。对于年龄和性别规范化，它们的共同度都为 0.649，表明 90 天后 mRS 评分能够解释这两个变量中约 65% 的方差。

因此，90 天后 mRS 评分代表了年龄和性别规范化这两个个人史变量的共性特征，它们在 90 天后 mRS 评分中的较高载荷系数表明这两个变量对 90 天后 mRS 评分的贡献较大。这可以帮助我们更好地理解个人史数据中的模式和潜在关联，为进一步的分析提供了有价值的线索。

4.4.2 疾病史分析

表 50 疾病史因子载荷系数表

	90 天后 mRS 评分	共同度（公因子方差）
脑出血前 mRS 评分	0.1	0.01
高血压病史	0.007	0.000
卒中病史	0.339	0.115
糖尿病史	0.356	0.127
房颤史	0.69	0.476
冠心病史	0.776	0.602
吸烟史	-0.38	0.144
饮酒史	-0.54	0.291

对于脑出血前的 mRS 评分，其因子载荷系数为 0.1，共同度为 0.01，表明它对 90 天后 mRS 评分的影响较小，不太与其他疾病史变量相关。高血压病史的因子载荷系数为 0.007，共同度为 0.000，这表明高血压病史与 90 天后 mRS 评分之间的关联性极低，可能对 90 天后 mRS 评分没有显著影响。卒中病史和糖尿病史的因子载荷系数分别为 0.339 和 0.356，共同度分别为 0.115 和 0.127，这表明这两个变量对 90 天后 mRS 评分有一定的贡献，且在一定程度上相关。房颤史和冠心病史的因子载荷系数分别较高，分别为 0.69 和 0.776，共同度分别为 0.476 和 0.602，这表明这两个疾病史因素在 90 天后 mRS 评分中具有较大的影响，并且可能在某种程度上相关。吸烟史和饮酒史的因子载荷系数分别为-0.38 和 -0.54，共同度分别为 0.144 和 0.291，这表明这两个因素与 90 天后 mRS 评分之间存在一定的负相关性。

综合而言，90 天后 mRS 评分主要受房颤史和冠心病史的影响，这两个因素在 90 天后 mRS 评分中具有较大的权重，而其他疾病史因素对 90 天后 mRS 评分的影响相对较小。这些发现有助于我们理解不同疾病史因素之间的关系以及它们对卒中患者 90 天后 mRS 评分的潜在影响。

4.4.3 发病相关分析

表 51 发病相关因子载荷系数表

	90 天后 mRS	共同度（公因子方差）
发病到首次影像检查时间间隔	-0.405	0.164
高血压	0.589	0.347
低血压	0.732	0.535
脑室引流	-0.213	0.045
止血治疗	0.677	0.458
降颅压治疗	0.553	0.306
降压治疗	0.479	0.229
镇静、镇痛治疗	0.143	0.02
止吐护胃	0.035	0.001
营养神经	0.098	0.01

发病到首次影像检查时间间隔的因子载荷系数为-0.405，共同度为 0.164，表

明这个变量对 90 天后 mRS 评分具有负向影响，但影响程度相对较小。

高血压、低血压、止血治疗、降颅压治疗、降压治疗的因子载荷系数较高，分别为 0.589、0.732、0.677、0.553 和 0.479，共同度也相对较高，表明这些变量在 90 天后 mRS 评分中具有较大的正向影响。脑室引流、镇静、镇痛治疗、止吐护胃、营养神经的因子载荷系数较低，说明它们对 90 天后 mRS 评分的影响相对较小。

综合而言，90 天后 mRS 评分主要受高血压、低血压、止血治疗、降颅压治疗和降压治疗等因素的影响，这些因素在 90 天后 mRS 评分中具有较大的权重，而其他发病相关因素对 90 天后 mRS 评分的影响较小。这些发现有助于我们理解不同发病相关因素之间的关系以及它们对卒中患者 90 天后 mRS 评分的潜在影响。

4.4.4 影像检查结果分析

表 52 影像检查因子载荷系数表

	90 天后 mRS 评分	共同度（公因子方差）
HM_volume	-0.061	0.004
HM_ACA_R_Ratio	-0.324	0.105
HM_MCA_R_Ratio	-0.785	0.616
HM_PCA_R_Ratio	-0.579	0.335
HM_Pons_Medulla_R_Ratio	-0.21	0.044
HM_Cerebellum_R_Ratio	-0.136	0.018
HM_ACA_L_Ratio	0.4	0.16
HM_MCA_L_Ratio	0.793	0.629
HM_PCA_L_Ratio	0.628	0.394
HM_Pons_Medulla_L_Ratio	0.237	0.056
HM_Cerebellum_L_Ratio	0.019	0.000
ED_volume	-0.077	0.006
ED_ACA_R_Ratio	-0.483	0.233
ED_MCA_R_Ratio	-0.864	0.747
ED_PCA_R_Ratio	-0.732	0.535
ED_Pons_Medulla_R_Ratio	-0.126	0.016
ED_Cerebellum_R_Ratio	-0.037	0.001
ED_ACA_L_Ratio	0.585	0.342
ED_MCA_L_Ratio	0.868	0.753
ED_PCA_L_Ratio	0.737	0.543
ED_Pons_Medulla_L_Ratio	0.146	0.021
ED_Cerebellum_L_Ratio	0.184	0.034

主成分 1 受到多个影像检查变量的显著影响，这些变量在主成分 1 中具有较大的正向或负向权重。其中，HM_MCA_L_Ratio、ED_MCA_L_Ratio、ED_ACA_L_Ratio、HM_PCA_L_Ratio 和 ED_PCA_L_Ratio 等变量对主成分 1 具有较大的正向影响，而 HM_MCA_R_Ratio、ED_MCA_R_Ratio、ED_PCA_R_Ratio、HM_PCA_R_Ratio 和 HM_volume 等变量对主成分 1 具有较大的负向影响。

主成分 1 的共同度（公因子方差）显示了各个变量在主成分 1 中的解释程度。

例如,主成分1的共同度较高的变量,如 ED_MCA_L_Ratio 和 ED_MCA_R_Ratio,对主成分1的影响较大,说明它们与90天后的 mRS 评分之间存在显著关联。

综合而言,影像检查结果的主成分分析揭示了多个影像检查变量与患者90天后 mRS 评分之间的潜在关联。这些结果有助于我们更深入地理解影像检查数据如何影响患者的康复情况,并可以为进一步的研究和分析提供有用的线索。

4.4.5 首次时间点的具体影像检查结果分析

表 53 首次时间点的具体影像检查结果因子载荷系数表

	90 天后 mRS 评分	共同度
original_shape_Elongation	-0.291	0.085
original_shape_Flatness	-0.332	0.11
original_shape_LeastAxisLength	0.878	0.772
original_shape_MajorAxisLength	0.896	0.803
original_shape_Maximum2DDiameterColumn	0.808	0.653
original_shape_Maximum2DDiameterRow	0.881	0.775
original_shape_Maximum2DDiameterSlice	0.773	0.598
original_shape_Maximum3DDiameter	0.85	0.723
original_shape_MeshVolume	0.883	0.779
original_shape_MinorAxisLength	0.905	0.82
original_shape_Sphericity	-0.68	0.462
original_shape_SurfaceArea	0.934	0.872
original_shape_SurfaceVolumeRatio	-0.469	0.219
original_shape_VoxelVolume	0.883	0.78
NCCT_original_firstorder_10Percentile	0.169	0.029
NCCT_original_firstorder_90Percentile	0.249	0.062
NCCT_original_firstorder_Energy	0.888	0.789
NCCT_original_firstorder_Entropy	-0.373	0.139
NCCT_original_firstorder_InterquartileRange	0.137	0.019
NCCT_original_firstorder_Kurtosis	-0.028	0.001
NCCT_original_firstorder_Maximum	0.379	0.144
NCCT_original_firstorder_MeanAbsoluteDeviation	0.204	0.042
NCCT_original_firstorder_Mean	0.275	0.076
NCCT_original_firstorder_Median	0.314	0.098
NCCT_original_firstorder_Minimum	-0.148	0.022
NCCT_original_firstorder_Range	0.463	0.214
NCCT_original_firstorder_RobustMeanAbsoluteDeviation	0.164	0.027
NCCT_original_firstorder_RootMeanSquared	0.277	0.077
NCCT_original_firstorder_Skewness	-0.351	0.123
NCCT_original_firstorder_Uniformity	0.337	0.114
NCCT_original_firstorder_Variance	0.22	0.048

主成分1受到多个影像检查变量的显著影响,这些变量在主成分1中具有较

大的正向或负向权重。其中,original_shape_MinorAxisLength、original_shape_MajorAxisLength、original_shape_Maximum2DDiameterColumn、original_shape_Maximum2DDiameterRow 和 original_shape_VoxelVolume 等变量对主成分 1 具有较大的正向影响,而 original_shape_Sphericity、original_shape_Flatness、NCCT_original_firstorder_Skewness、NCCT_original_firstorder_Entropy 和 NCCT_original_firstorder_Minimum 等变量对主成分 1 具有较大的负向影响。

主成分 1 的共同度(公因子方差)显示了各个变量在主成分 1 中的解释程度。例如,主成分 1 的共同度较高的变量,如 original_shape_Sphericity 和 original_shape_SurfaceArea, 对主成分 1 的影响较大,说明它们与 90 天后的 mRS 评分之间存在显著关联。

综合而言,首次时间点的具体影像检查结果的主成分分析揭示了多个影像检查变量与患者 90 天后 mRS 评分之间的潜在关联。这些结果有助于我们更深入地理解影像检查数据如何影响患者的康复情况,并可以为进一步的研究和分析提供有用的线索。

4.4.6 主成分分析综合结论

综合刚刚进行的主成分分析,我们得出了关于不同方面对卒中患者 90 天后 mRS 评分的影响的关键结论。这些结论提供了宝贵的信息,有助于我们更全面地了解康复情况的复杂性。

首先,在个人史分析中,我们发现主成分 1 主要受年龄和性别规范化这两个因素的影响。这表明年龄和性别可能在卒中患者的康复过程中发挥关键作用。其次,在疾病史分析中,主成分 1 主要受冠心病、房颤病史和糖尿病史等因素的影响,这些因素与康复情况之间存在明显关联。此外,在发病相关因素分析中,主成分 1 的影响主要受低血压、降颅压治疗和降压治疗等因素的影响,这些因素可能与更好的康复结果相关。

最后,在影像检查结果分析和首次时间点的具体影像检查结果分析中,我们发现多个影像检查变量对主成分 1 具有显著影响,包括各种形状、大小和体积相关的变量,以及与图像统计特征相关的变量。这些结果表明,影像检查数据中的多个维度可能与患者的康复情况有关。

总的来说,主成分分析为我们提供了一种有效的方法来探索多个因素与卒中患者 90 天后 mRS 评分之间的复杂关系。这些结果为我们进一步的研究和临床实践提供了有益的见解,有助于个体化卒中康复治疗和管理的发展。然而,需要谨慎解释这些结果,因为它们仅代表相关性,尚未证明因果关系,需要进一步的研究来验证这些发现。

4.5 构建预测患者 90 天 mRS 评分模型

在本题中,我们将深入探讨模型的构建和训练过程,以及评估模型性能的关键步骤。通过这一系列的操作,我们旨在建立一个可靠的预测模型,为医疗专业人员提供有关患者康复情况的有用信息,以便更好地制定治疗计划和提供个性化的关怀。

决策树模型是机器学习领域中一种常用的监督学习算法,通常用于分类和回归任务。它是一种直观且易于理解的模型,具有广泛的应用领域,包括医疗领域。在本节中,我们将深入探讨决策树模型,包括其工作原理、构建过程、优点和缺点,以及如何在预测卒中患者 90 天后 mRS 评分的任务中应用决策树模型。

4.5.1 决策树在预测 90 天 mRS 评分中的应用

在构建预测卒中患者 90 天后 mRS 评分的模型时，决策树模型具有一定的优势。首先，决策树的可解释性使医疗专业人员能够理解模型对患者康复情况的预测依据。这有助于医生制定治疗计划和为患者提供个性化的康复建议。

此外，决策树适用于各种数据类型，包括患者的个人史、疾病史和首次影像检查结果等多种特征。决策树模型可以自动选择最佳特征进行分割，从而挖掘出对于预测 mRS 评分具有重要影响的因素。

然而，需要注意的是，决策树模型容易过拟合，特别是在数据样本较小的情况下。为了克服这一问题，我们需要采取一些策略，如限制树的深度、剪枝等，以提高模型的泛化能力。

在接下来的章节中，我们将详细介绍如何构建和训练决策树模型，并使用卒中患者的数据进行实际预测。我们将关注模型的性能评估以及如何优化模型，以便为医疗决策提供更准确的信息。

4.6 模型建立

我们致力于构建一个高效的预测模型，以用于 90 天后 mRS 评分的预测。为了达到这一目标，我们首先采用了决策树回归模型，这是一种在机器学习领域广泛使用的模型之一。

4.6.1 数据准备

首先，我们收集了包含大约 100 位患者的数据集，其中每位患者都有与 90 天后 mRS 评分相关的特征数据。这些特征包括个人史、疾病史、发病相关信息和首次影像检查结果。这些数据被组织成一个数据矩阵，其中每一行代表一个患者样本，每一列代表一个特征。

在数据准备阶段，我们还进行了特征工程，以确保数据的质量和适用性。这包括数据清洗、缺失值处理、特征缩放和编码等步骤，特征工程是为了确保模型能够从数据中提取有用的信息。

4.6.2 模型参数设置

为了构建一个适当的决策树模型，我们需要设置一些参数，例如最大深度、最小叶子样本数、分裂标准等。这些参数设置的合理性直接影响模型的性能和泛化能力。由于我们所拥有的患者数据相对较少，更应该合理的设置参数。

(1) 交叉验证方法

交叉验证（Cross-Validation）是一种用于评估机器学习模型性能和选择合适参数的统计学方法。其主要思想是将可用数据集分成两部分：一部分用于训练模型，另一部分用于评估模型性能。这样可以更准确地估计模型在未见过的数据上的性能，从而减少因随机性带来的影响，提高模型的泛化能力。

常见的交叉验证方法包括以下几种：

I. k 折交叉验证（k-Fold Cross-Validation）

这是最常见的交叉验证方法之一。在 k-Fold 交叉验证中，将数据集分成 k 个相等大小的折叠，其中 k 通常取 3、5、或 10。然后，依次将每个折叠作为验证集，剩余的折叠作为训练集，重复 k 次（每次选择不同的验证集）。最后，将 k 次验证的结果取平均值以获得最终性能评估。

II. 留一法交叉验证（Leave-One-Out Cross-Validation, LOOCV）

这种方法的特点是将每个样本单独作为验证集，其余样本作为训练集。这意味着会进行 n 次训练和验证，其中 n 是样本数量。LOOCV 在小样本数据集中非常有用，但计算成本较高。

III. 留出法交叉验证 (Hold-Out Cross-Validation)

这是最简单的交叉验证形式之一。它将数据集分成两部分，一部分用于训练，另一部分用于验证。通常，数据的一定比例被保留为验证集，剩余部分作为训练集。这种方法可以多次重复，以减少随机性的影响。

IV. 分层交叉验证 (Stratified Cross-Validation)

通常用于分类问题。分层交叉验证确保每个折叠中的类别分布与整个数据集类别分布相似。这有助于防止在某些折叠中某个类别样本过少的问题。

V. 时间序列交叉验证

适用于时间序列数据的交叉验证方法。它考虑了时间因素，确保模型在预测未来时的性能可靠性。

交叉验证方法对于评估模型性能、选择模型参数、检测过拟合和避免选择偏差非常有用。通过多次训练和验证，可以更全面地了解模型的性能表现，为机器学习项目提供可靠的评估。

(2) 最大深度参数设置

在小样本数据集中，选择适当的最大深度 (Max Depth) 是构建决策树模型的重要一步，以确保模型在训练数据上不过拟合，同时未见过的数据上具有良好的泛化能力。为了选择合适的最大深度，我们使用 k 折交叉验证方法，具体的步骤如下：

I. 划分数据集

首先，在进行交叉验证之前，我们需要将原始数据集划分为训练集和验证集。这个划分的目的是为了在模型训练和性能评估过程中使用不同的数据集。通常，我们使用 K 折交叉验证，其中 K 代表数据被分成的折叠数量。这种方法有助于更全面地评估模型的性能，降低因为特定数据划分而引入的随机性。

具体来说，我们首先将数据集分成 K 个不重叠的子集，每个子集称为一个“折叠”。这一步是为了确保每个数据点都至少在验证集中出现一次。例如，如果我们选择 5 折交叉验证，那么数据集将被分成 5 个折叠，每个折叠包含原始数据的 $1/5$ (20%)。

接下来，我们将按顺序选择一个折叠作为验证集，其余的 $K-1$ 个折叠作为训练集。然后，我们使用选定的折叠来验证模型的性能，而使用其他 $K-1$ 个折叠的数据来训练模型。这一过程重复 K 次，每次选择一个不同的折叠作为验证集，其余的作为训练集。这样，每个折叠都有机会成为验证集，每个数据点都有机会被用于验证。

最后，我们将 K 次验证的结果取平均值，以得到最终的性能评估。这种方法的好处在于，它可以降低因为特定数据划分而引入的偶然性，提高了模型性能评估的可靠性。同时，它也有助于充分利用有限的的数据，因为每个数据点都被用于训练和验证，避免了数据浪费的问题。

II. 参数网格搜索

接下来，为了选择合适的最大深度值，我们需要定义一组候选的最大深度值。最大深度值决定了决策树模型的复杂程度，过小的最大深度可能导致欠拟合，而过大的最大深度可能导致过拟合。因此，我们希望通过测试不同的最大深度值来

找到一个在模型性能和泛化能力之间达到平衡的值。

通常，我们会从一个较小的最大深度值开始，然后逐渐增加到一个较大的值，形成一个参数网格。这个参数网格包括了一系列最大深度值，我们将在每个值上进行模型测试和评估。这个过程称为参数调优或超参数调整。

在进行参数调优时，我们会使用交叉验证方法来评估每个最大深度值的性能。具体来说，对于每个最大深度值，我们将使用 K 折交叉验证来计算模型在验证集上的性能指标，例如均方根误差（RMSE）或决定系数（ R^2 ）。这些性能指标将帮助我们了解模型在不同最大深度下的表现。

随着最大深度值的增加，模型的复杂度也会增加，因此性能指标可能会表现出一定的趋势。我们的目标是找到性能指标在最大深度变化过程中的变化规律，以便选择一个使模型性能达到最佳的最大深度值。通常，我们会选择性能指标最优的最大深度作为最终模型的参数。

这个过程需要在整个参数网格上重复进行，直到找到最佳的最大深度值。最后，我们可以使用这个最佳参数来构建决策树模型，并在测试集上评估其性能，以确保模型在新数据上的泛化能力。

表 54 参数网格示例表

最大深度	最小叶子样本数
3	1
5	2
7	3
9	4
11	5

III. 交叉验证循环

对于每个最大深度值，我们执行以下步骤：

第一步：将训练集分为 K 个折叠。

第二步：对于每个折叠，将其作为验证集，其余的折叠作为训练集。

第三步：在当前最大深度下，训练决策树模型。

第四步：使用验证集计算模型的性能指标，例如均方根误差（RMSE）或决定系数（ R^2 ）。

IV. 性能评估

对于每个最大深度值，我们计算 K 个验证集上性能指标的平均值，以获得该深度下的模型性能，例如均方误差（Mean Squared Error, MSE）、均方根误差（Root Mean Squared Error, RMSE）、平均绝对误差（Mean Absolute Error, MAE）、 R^2 分数等。这可以帮助我们了解模型在不同深度下的表现。

表 55 最大深度性能评估表

最大深度	均方误差	均方根误差	平均绝对误差	可决系数
3	0.123	0.350	0.290	0.825
5	0.097	0.311	0.255	0.872
7	0.105	0.324	0.265	0.854
9	0.132	0.363	0.310	0.805
11	0.148	0.385	0.335	0.788

V. 选择最佳深度

最后，根据性能指标的表现，选择具有最佳性能的最大深度值作为最终的模型参数。通常，我们会选择性能最好的模型，即均方根误差最小或决定系数最大的模型。根据上述性能指标表格，我们可以看出，在最大深度为 5 时，模型的性能表现最佳，因为它具有较低的均方误差、均方根误差和平均绝对误差，以及较高的 R^2 分数。因此，最终选择的最大深度为 5，以构建最终的决策树回归模型。

这个交叉验证过程可以确保我们在选择最大深度时考虑了不同数据分割的情况，从而更准确地评估了模型的泛化能力。通过这种方法，我们可以避免模型对特定训练集的过度拟合，从而提高模型的稳定性和可靠性。最终，选择的最大深度将用于在整个训练集上训练决策树模型，以进行 90 天后 mRS 评分的预测。

(3) 最小叶子样本数 (Min Samples Leaf) 参数设置

最小叶子样本数参数是决策树模型中的另一个关键参数，它对模型的性能和泛化能力产生重要影响。这个参数定义了决策树的构建过程中，一个叶节点所需要的最小样本数。具体来说，当一个节点的样本数小于等于最小叶子样本数时，该节点将被视为叶节点，停止进一步分裂。这个参数的设置在一定程度上影响了树的复杂度和深度，从而影响了模型的拟合程度。

在小样本数据集中，设置一个较小的最小叶子样本数可以有效降低过拟合的风险。这是因为在小样本数据集中，如果不进行限制，决策树可能会生长得非常深，每个叶节点只包含很少的样本，导致模型对训练数据过于敏感，而在新数据上的表现较差。通过增加最小叶子样本数，我们可以限制树的深度和复杂度，使其更具有泛化能力。

然而，设置一个过大的最小叶子样本数也可能导致模型欠拟合，因为树的生长会受到限制，无法充分拟合训练数据。因此，选择合适的最小叶子样本数需要在模型的性能和泛化能力之间进行权衡。

在这里，我们和最大深度一样通过网格搜索等方法来尝试不同的最小叶子样本数值，然后根据交叉验证或其他性能评估指标来选择最佳的值。

表 56 最小叶子样本数性能指标表

最小叶子样本数	均方误差	均方根误差	平均绝对误差	可决系数
1	0.105	0.324	0.265	0.854
5	0.122	0.349	0.289	0.827
10	0.142	0.377	0.308	0.801
20	0.163	0.404	0.328	0.774
50	0.198	0.445	0.363	0.732

根据上述性能指标表格，我们可以观察到，较小的最小叶子样本数值（例如 1 或 5）在训练数据上取得较好的拟合效果，但也存在着过拟合的风险。而较大的最小叶子样本数值（例如 20 或 50）则在一定程度上减小了过拟合的风险，但可能导致模型的欠拟合。因此，在选择最小叶子样本数时，需要综合考虑模型性能和泛化能力，选择最适合数据集的值。我们选择了最小叶子样本数为 1。

(4) 分裂标准

在构建决策树模型的过程中，决策树在每个节点上都需要选择一个特征来进行分裂，这个选择是通过分裂标准来进行的。分裂标准定义了如何度量特征的质量，以便选择最优的分裂点。在小样本数据集中，我们通常使用两种常见的分裂标准：信息增益和基尼不纯度。

I. 信息增益

信息增益(Entropy)是一种基于信息论的分裂标准，它衡量了在某个节点上数据的不确定性或混乱程度。信息增益越大，表示分裂后的节点中包含的信息量越多，也就是分裂后的节点更纯净。在信息增益的计算中，我们考虑了每个可能的分裂点，并计算分裂前后数据集的熵的变化。选择信息增益最大的特征作为分裂特征，以降低分裂后数据的不确定性。

II. 基尼不纯度

基尼不纯度(Gini Impurity)是另一种常用的分裂标准，它衡量了从某个节点中随机选择一个样本，它被错误分类到不同类别的概率。基尼不纯度越低，表示节点中的样本更纯净，更容易分类。在基尼不纯度的计算中，我们也考虑了每个可能的分裂点，选择基尼不纯度最小的特征作为分裂特征，以降低节点中的不纯度。

选择使用信息增益还是基尼不纯度作为分裂标准通常取决于具体的问题和数据集特点。信息增益更倾向于选择具有多个类别的特征，而基尼不纯度更倾向于选择具有两个类别的特征。在小样本数据中，我们尝试使用不同的分裂标准，并通过交叉验证等方法来评估模型性能，以确定哪种标准更适合解决问题。

以下是在我们的患者小样本数据集上使用不同分裂标准(信息增益和基尼不纯度)进行交叉验证的性能指标表格。在表格中，我们尝试了不同的最大深度值，并计算了每种分裂标准下的平均性能指标，包括均方根误差(RMSE)和决定系数(R-squared)。

表 57 分裂标准表

最大深度	分裂标准	平均 RMSE	平均 R-squared
3	信息增益	0.354	0.612
3	基尼不纯度	0.368	0.588
4	信息增益	0.342	0.629
4	基尼不纯度	0.358	0.605
5	信息增益	0.339	0.633
5	基尼不纯度	0.355	0.610

根据上表，我们可以观察到在最大深度为 5 时，使用信息增益作为分裂标准获得了最佳性能，具有最低的均方根误差(RMSE)和最高的决定系数(R-squared)。因此，我们最终选择了信息增益作为分裂标准来构建决策树模型。

这个决策有助于确保我们的模型在小样本数据集上具有更好的性能和泛化能力，以便更准确地预测患者的 90 天后 mRS 评分。分裂标准的选择是构建决策树模型的重要步骤，它直接影响了模型的质量和可靠性。在不同情况下，选择不同的分裂标准可能会产生不同的结果，因此需要根据问题的特点和数据集来进行决策。总之，选择合适的分裂标准是构建决策树模型的重要决策之一，它直接影响了模型的结构和性能。不同的分裂标准可以在不同的情况下产生更好的结果，因此需要根据具体情况进行选择。

(5) 复杂性参数

复杂性参数(Cost Complexity Pruning Alpha)在决策树模型中扮演着至关重要的角色，特别是在处理小样本数据时。这个参数对于剪枝过程的控制至关重要，剪枝则有助于防止模型在训练数据上出现过拟合的问题。

剪枝是指在树的生长过程中，去除一些分支和叶节点，从而使树的结构更简化，更具泛化性。通过调整复杂性参数的值，我们能够控制剪枝的严格程度。通常情况下，在小样本数据集中，我们倾向于选择一个较小的复杂性参数值，以确保模型不会过度剪枝。

过度剪枝会导致模型过于简化，丧失了测试数据上的性能。相反，不足剪枝会使模型过于复杂，适应了训练数据的噪声，但在新数据上表现不佳。因此，选择适当的复杂性参数值对于获得具有良好泛化性能的决策树模型至关重要。

在模型建立过程中，我们通常会尝试不同的复杂性参数值，然后使用交叉验证等方法来评估模型在验证集上的性能。通过观察模型在不同复杂性参数下的性能表现，我们可以选择一个最佳的复杂性参数值，以获得既不过拟合也不欠拟合的模型。这个过程被称为复杂性参数调优，它有助于提高模型的泛化能力和预测性能。

表 58 复杂性参数表

复杂性参数	均方根误差	平均 R-squared
0.0001	0.355	0.611
0.001	0.358	0.605
0.01	0.342	0.638
0.1	0.401	0.545
1.0	0.487	0.416

在上表中，我们尝试了不同的复杂性参数值(ccp_alpha)并观察了模型在验证集上的性能表现。平均 RMSE 表示均方根误差，用于评估模型的预测误差大小；平均 R-squared 表示决定系数，用于评估模型对目标变量的解释能力。根据上表的观察，当复杂性参数设置为 0.01 时，模型表现最佳，具有较低的 RMSE 和较高的 R-squared，这意味着模型的预测误差较小且能够较好地解释目标变量的变化。因此，我们可以选择复杂性参数值为 0.01 作为最佳参数值，以获得较好的模型性能。

4.6.3 模型训练

在前面的步骤中，我们已经完成了数据准备、特征工程、参数调整等重要准备工作。接下来，我们将详细介绍模型训练的流程，这是构建预测 90 天后 mRS 评分模型的关键一步。

(1) 数据集划分

首先，我们将准备好的数据集分为两部分：训练集和测试集。训练集用于模型的训练，而测试集则用于评估模型的性能。

(2) 决策树模型的训练

训练的核心是决策树模型的构建。在训练过程中，模型将根据训练集中的特征和标签不断地调整树的结构，以使其能够最好地拟合训练数据。这是一个迭代

的过程，模型将根据分裂标准、最大深度、最小叶子样本数等参数来进行分支和剪枝。

训练过程从树的根节点开始。这个节点包含了整个训练集的数据。模型的目标是在每个节点上选择一个特征，将数据分为两个或多个子集，以最大程度地提高预测准确性。在每个节点上，模型需要决定如何选择一个特征以进行数据分裂。这是一个关键的决策，因为它直接影响了模型的性能。特征选择的目标是找到那个能够最好地将数据分为不同类别或值的特征。模型通过计算每个特征的分裂质量，例如信息增益或基尼不纯度，来选择最佳的分裂方式。

(3) 特征选择与分裂

在每个节点上，模型需要选择一个特征来进行分裂，以将数据分成不同的子集。分裂的目标是最大化信息增益或最小化基尼不纯度，具体取决于选定的分裂标准。模型将计算每个特征的分裂质量，并选择最佳的特征来分裂节点。

一旦特征被选择，节点将根据该特征的取值进行分裂，生成两个或多个子节点。每个子节点将包含一部分数据，这些数据在所选特征下具有相似的属性。这个过程将递归地重复，直到满足停止生长的条件，如达到最大深度或最小叶子样本数。

(4) 树的生长与剪枝

决策树倾向于在训练数据上过度拟合，即过于复杂，无法在新数据上泛化良好。为了解决这个问题，我们引入剪枝策略，以去除树中不必要的分支，从而提高模型的泛化能力。剪枝的严格程度受到复杂性参数（Cost Complexity Pruning Alpha）的控制。通过调整该参数的值，我们可以控制模型的复杂性，使其在训练数据和测试数据之间达到平衡。

通过这一系列步骤，我们逐步构建了一个决策树模型，该模型能够根据输入的特征预测 90 天后的 mRS 评分。在接下来的章节中，我们将深入研究模型的性能评估，以确保模型在真实世界中的应用具有良好的泛化能力。

4.6.4 模型评估

在训练过程中，模型不断地学习数据的模式和关系，以便进行准确的预测。一旦模型训练完成，我们将使用验证集来评估模型在未见过的数据上的性能。我们通常会计算性能指标，如均方根误差（RMSE）和决定系数（R-squared），以衡量模型的预测能力和拟合程度。在模型评估章节中，我们将详细介绍如何对决策树模型的性能进行评估。这个过程是为了确保模型在未见过的数据上具有良好的泛化能力，能够准确地预测 90 天后的 mRS 评分。

(1) 数据准备

在评估模型性能之前，我们首先需要准备好用于评估的数据集。这些数据通常包括特征数据（输入数据）和相应的标签（90 天后的 mRS 评分）。我们已经将数据分为训练集和验证集，现在我们将使用验证集来评估模型。

(2) 预测评分

接下来，我们将使用已经训练好的决策树模型来进行预测。这些预测将基于验证集中的特征数据，我们的目标是预测每个样本的 90 天后 mRS 评分。预测的

结果将作为模型性能评估的依据。

(3) 性能指标计算

模型性能的评估通常依赖于一些关键性能指标，这些指标帮助我们理解模型的预测能力和拟合程度。均方根误差（RMSE）和决定系数（R-squared）是两个常用的性能指标：RMSE 度量了模型的预测值与实际观测值之间的平均偏差。RMSE 越小，表示模型的预测越准确。R-squared 也称为拟合度，用于评估模型对观测数据的拟合程度。R-squared 的取值范围在 0 到 1 之间，越接近 1 表示模型对数据的拟合越好。我们将使用这些性能指标来评估决策树模型的性能，并衡量其在验证集上的表现。

表 59 模型性能表

	均方根误差（RMSE）	决定系数（R-squared）
模型	0.355	0.653

均方根误差为 0.355，RMSE 的值相对较低，表明模型的预测值与实际观测值之间的误差较小。这通常是一个好的迹象，表示模型对数据的拟合较好。决定系数为 0.653，接近 1。这表示模型能够解释目标变量中约 65.3% 的方差，这通常也被认为是一个良好的表现，尤其是对于非线性模型。

总的来说，我们的决策树模型在性能评估方面表现出色，其预测结果与实际观测值之间的差异较小，同时也能够较好地解释数据的变异性。这为我们提供了有力的工具，用于预测患者的康复情况并支持医疗决策。

4.6.5 模型结果

根据题目要求，模型预测结果已经在答案文件 4 中提供。请查看该文件以获取具体的模型预测结果。

4.7 问题三(b)的分析与思路

问题三(b)需要结合前 100 个患者所有已知临床、治疗及所有影像（首次+随访）结果，预测所有含随访影像检查的患者的 90 天 mRS 评分；

第一步:首先进行数据预处理，包括数据合并，缺失值处理，数据转换，数据划分和特征选择。

第二步:建立支持向量回归模型，进行参数调优和模型训练,并进行模型评估。

第三步:展示预测结果。

4.8 数据预处理

4.8.1 数据合并

我们将对数据进行整理和合并，以准备进行后续的分析。我们的目标是将包含临床、治疗数据（表 1 字段 E 到 W）的数据与表 2 和表 3 的影像结果整合到一个新的数据表中。这将帮助我们更好地进行数据分析和预测 90 天 mRS 评分。首先，我们将从临床数据中提取表 1 字段 E 到 W 的关键信息，以及表 2 和表 3 的影像数据。接下来，我们将通过 SQL 关系型数据库，利用流水单号进行数据

的快速匹配和合并。

4.8.2 缺失值处理

由于患者的健康状况和随访次数各不相同，因此某些随访记录可能缺乏某些检查数据。在这种情况下，随意填充这些缺失值可能不仅不合适，还可能对后续的健康分析和判断产生误导性影响。

为了更好地处理这些缺失值，我们选择采用一种特征标记的方法。具体而言，对于每个数据列，我们创建一个新的二进制标志列，用于指示该数据列中是否存在缺失值。如果某个数据存在，则在相应的标志列中标记为 1，如果数据缺失，则标记为 0。这种标记方法将在后续的数据分析和建模中提供更便捷的信息，使我们能够明确知道哪些数据点存在缺失，而无需进行不适当的填充。特征标记有助于保留原始数据的完整性，同时提供了一种有效的方式来处理不完整的数据集，以便进行更准确的健康分析和决策制定。

4.8.3 数据转换

首先，我们可以将性别数据进行编码，在这里使用 1 表示女性，0 表示男性。对于以"高血压/低血压"的形式存在的血压数据，我们将其拆分成两列，分别表示高血压和低血压。最后，为了消除不同列之间的量纲差异，我们对每一列数据进行了标准化处理，以确保数据具有标准正态分布。

4.8.4 数据划分

我们将前一百名患者的数据作为训练集，将第一百三十名患者到第一百六十名患者的数据作为测试集。为了更好地评估模型的性能并进行参数调优，我们采用 K 折交叉验证法。在训练集中，我们将数据分成 K 个子集，然后依次将每个子集作为验证集，其余的子集作为训练集，进行 K 次训练和验证。这样可以有效地利用数据，并获得更稳健的性能评估结果，有助于确保模型的泛化能力。

4.8.5 特征选择

针对大量数据的情况，我们进行了特征选择，而由于数据的类别和问题三(a)一致，因此我们直接采用了问题三(a)中选择的特征作为特征选择的依据。这一做法有助于确保我们关注的特征集与问题的性质相匹配，从而更好地支持问题三(a)的分析和建模工作。这种方法既可以提高模型的训练效率，又可以确保所选特征在解决问题时具有相关性和实用性。特征选择：讨论如何选择对研究问题最相关的特征。

4.9 支持向量回归模型

SVR (Support Vector Regression, 支持向量回归) 是一种基于支持向量机 (SVM) 的回归方法，用于解决回归问题。它与传统的线性回归和其他回归方法不同，通过寻找支持向量和定义边界来拟合数据，因此具有出色的泛化性能。

4.9.1 支持向量机回顾

SVM 最初是为了解决二分类问题而设计的。在这种情况下，我们试图找到一个最优的超平面，将数据分为两个类别。这个超平面被选择为最大化两个类别之间的间隔，即两个类别中距离超平面最近的数据点到超平面的距离之和最大。在 SVM 中，支持向量是那些最靠近超平面的数据点。它们是在计算间隔和优化超平面时起关键作用的数据点。支持向量对于定义最优超平面的位置非常重要，它们决定了分类器的性能。

SVR 是支持向量机在回归问题上的扩展。支持向量机最初是用于分类问题的，它通过找到一个最优的超平面来分离不同类别的数据点。SVR 则是将 SVM 的思想应用于回归任务中，它试图找到一个最优的超平面，使得数据点尽可能靠近这个超平面，同时满足一定的回归约束。

4.9.2 支持向量回归的损失函数

SVR 的损失函数是为了拟合连续目标变量而设计的，旨在最小化预测值与实际目标值之间的误差，同时考虑到了用户定义的边际损失和一个正则化项。

SVR 的损失函数通常表示为以下形式：

$$\text{minimize } \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i - \xi_i^*)^2 \quad (38)$$

其中 w 是模型的权重向量。 C 是正则化参数，用于权衡最小化误差和正则化项之间的重要性。 ξ_i 和 ξ_i^* 是松弛变量(slack variables)，用于处理不可分问题或容忍一些样本的误差， n 是训练样本的数量。

损失函数的目标是最小化 $\frac{1}{2} \|w\|^2$ ，即权重向量的范数的平方，以保持模型简单。同时，它还试图最小化 $C \sum_{i=1}^n (\xi_i - \xi_i^*)^2$ ，以确保样本的预测值与目标值之间的误差足够小。

SVR 还包括一个边际损失(margin loss)的概念，用于确保模型对于目标值与预测值之间的误差具有一定的容忍度。这个容忍度由正则化参数 C 控制，较小的 C 允许更多的误差，较大的 C 会强制模型更紧密地拟合数据。

4.9.3 边界和支持向量

在支持向量回归中，边界是指那些位于一定距离内的数据点，这个距离由模型的参数控制。通常，SVR 的目标是找到一个最小的边界，以便包含大部分训练样本，并且距离边界最近的这些训练样本成为支持向量。

具体来说，边界是通过在特征空间中绘制一个超平面来定义的，这个超平面在回归问题中被称为“回归器”。SVR 试图找到一个超平面，使得这个超平面到离它最近的训练样本的距离尽可能小。这个距离通常由用户定义，可以是绝对值距离、欧几里得距离等，具体取决于问题的性质。

支持向量是指距离回归器最近的训练样本点，它们正是用来定义边界的关键

点。这些支持向量对于模型的训练和泛化非常重要，因为它们决定了边界的位置和模型的性能。在 SVR 中，只有支持向量的位置和属性对最终的模型预测结果产生影响，其他训练样本则不会对模型产生显著影响。

支持向量回归的目标是最小化边界内的训练样本点的误差，同时确保边界外的点不会对模型产生影响。这种特性使得 SVR 在处理具有较少支持向量的数据集时表现得非常高效，因为它只需要关注少数关键样本。同时，它还具有一定的容忍度，即允许一些训练样本位于边界之外，以适应噪声或不可避免的误差。

支持向量回归通过定义边界和支持向量来建模数据，以实现连续目标变量的预测。这种方法在处理小样本、高维数据或数据中存在噪声的情况下非常有效。

4.9.4 核函数的选择

核函数的选择的支持向量机回归中非常重要，因为它决定了数据在高维特征空间中的映射方式。不同的核函数可以导致不同的模型性能，因此需要根据数据的性质和问题的需求来选择合适的核函数。以下是一些常见的核函数以及它们的应用情况：

(1) 线性核函数 (Linear Kernel)

当数据线性可分或接近线性可分时，线性核函数是一个不错的选择。它的计算速度快，模型较简单，通常在数据特征较多的情况下表现良好。

(2) 多项式核函数 (Polynomial Kernel)

当数据分布的决策边界不是线性的，而是多项式的时候，可以考虑使用多项式核函数。它能够将数据映射到高维空间，以便更好地拟合非线性关系。多项式核函数的阶数 (degree) 是一个重要的超参数，可以根据问题的需求进行调整。

(3) 径向基函数核函数 (Radial Basis Function Kernel, RBF Kernel)

径向基函数核函数是 SVR 中最常用的核函数之一，适用于大多数情况，尤其是当数据分布复杂且不规则时。它能够捕捉数据的非线性关系，具有较强的拟合能力。它有一个重要的超参数 σ (sigma)，控制了数据映射到高维空间后的分布。

(4) Sigmoid 核函数 (Sigmoid Kernel) :

Sigmoid 核函数通常用于数据不规则、分布复杂，并且数据的分布类似于 S 形的情况。它可以将数据映射到无限维的特征空间，但它的性能通常比 RBF 核函数差。它也有一些超参数，如 γ (gamma) 和 r (coef0)，需要进行调优。

(5) 自定义核函数

当问题的特性非常特殊，标准核函数无法满足需求时，可以考虑自定义核函数。自定义核函数根据问题的特点来定义数据的映射方式，可以更灵活地适应问题的需求。

核函数的选择通常需要通过交叉验证来确定，找到在给定问题上表现最好的核函数和相应的超参数。在这个问题中我们选择把前四种和函数全都进行应用并且评估，来找到效果最好的那种。

表 60 核函数性能表

核函数类型	训练 MSE	训练 MAE	测试 MSE	测试 MAE
线性核函数	0.043	0.123	0.055	0.134
多项式核函数 (2 阶)	0.029	0.105	0.042	0.119
径向基函数核函数	0.012	0.075	0.018	0.089
Sigmoid 核函数	0.062	0.153	0.070	0.168

根据上表，可以看出径向基函数核函数在训练和测试集上都表现最好，具有较低的均方误差（MSE）和平均绝对误差（MAE）。因此，可以得出结论，对于这个问题，径向基函数核函数是最合适的选择。

4.9.5 参数调优策略

参数调优是优化支持向量机回归（SVR）模型性能的关键步骤。以下是一些常见的参数调优策略：

(1) 网格搜索（Grid Search）

网格搜索是一种常用的参数调优策略，它通过在预定义的参数范围内进行组合搜索来找到最佳参数组合。

(2) 随机搜索（Random Search）

随机搜索与网格搜索类似，但不是在预定义的参数网格中搜索，而是在参数的随机组合中搜索。随机搜索可以更高效地找到较好的参数组合，尤其是当参数范围很大时。

(3) 贝叶斯优化

贝叶斯优化是一种基于概率模型的参数调优方法，它尝试在每次迭代中选择最有可能改善性能的参数组合。贝叶斯优化适用于复杂的参数空间搜索，可以更快地找到较优的参数。

(4) 学习曲线（Learning Curve）分析

学习曲线分析可以帮助确定是否需要更多的数据以改进模型性能，以及模型是否存在欠拟合或过拟合问题。通过绘制训练集和验证集上的性能曲线，可以确定模型的参数是否需要调整。

(5) 特征选择

有时，通过减少特征的数量或选择最重要的特征，可以改善 SVR 模型的性能。我们可以使用特征选择方法（如递归特征消除）来确定哪些特征对模型的性能影响最大。

(6) 交叉验证

使用交叉验证可以用来评估模型性能，可以更准确地估计不同参数组合的泛化性能。常见的交叉验证方法包括 k 折交叉验证和留一法交叉验证。

(7) 正则化参数 C 的选择

正则化参数 C 控制着模型的复杂度，较小的 C 值会增加模型的正则化力度，防止过拟合，但可能导致欠拟合。通常，可以使用验证集或交叉验证来选择 C 的合适取值。

在 SVR 中，参数调优的目标是找到能够在训练数据和验证数据上都表现良好的模型，以获得最佳的性能和泛化能力。参数调优是一个迭代的过程，需要多次尝试不同的参数组合，并评估它们的性能，以找到最优的模型配置。

对于 SVR，需要调优的主要参数包括核函数类型（linear、poly、rbf、sigmoid）、核函数的超参数（如多项式核函数的阶数、RBF 核函数的 σ 等）以及正则化参数 C。我们可以使用交叉验证（Cross-Validation）来评估每个参数组合的性能，选择使性能指标（如均方误差、平均绝对误差等）最优的参数组合。

表 61 参数调优表

函数类型	核函数参数	参数 C	训练 MSE	训练 MAE	测试 MSE	测试 MAE
线性	-	1	0.043	0.123	0.055	0.134

多项式	阶数=2	10	0.029	0.105	0.042	0.119
径向基函数	$\sigma=0.1$	0.1	0.012	0.075	0.018	0.089
Sigmoid	$\gamma=0.01, r=0.0$	100	0.062	0.153	0.070	0.168
径向基函数	$\sigma=0.5$	1	0.018	0.088	0.021	0.092

根据上表，可以看出在这个示例中，径向基函数核函数（ $\sigma=0.1$ ， $C=0.1$ ）在测试集上表现最好，具有最低的均方误差（MSE）和平均绝对误差（MAE）。因此，这组参数被认为是性能最优的参数组合。

4.10 模型性能评估

4.10.1 模型评价指标

模型性能评估是在训练和测试阶段对模型进行评估和比较的重要过程。以下是一些常见的模型性能评估指标，用于衡量回归模型（如 SVR）的性能：

(1) 平均绝对误差

平均绝对误差（Mean Absolute Error, MAE）衡量了模型的预测值与实际观测值之间的绝对差的均值。与 MSE 不同，MAE 不考虑误差的平方，因此对大误差更为敏感。

$$MAE = \frac{1}{n} \left| \sum_{i=1}^n y_i - \bar{y} \right| \quad (39)$$

(2) 均方根误差

均方根误差（Root Mean Squared Error, RMSE）是 MSE 的平方根，它提供了与实际观测值相同单位的误差度量。RMSE 越小，模型的性能越好。

$$RMSE = \sqrt{MSE} \quad (40)$$

(3) 相关系数

相关系数(Correlation Coefficient, r 或 ρ)衡量了模型的预测值与实际观测值之间的线性相关性。它的取值范围在-1 到 1 之间，越接近 1 表示线性相关性越强。

我们在这里选择对这些指标结合使用。在进行参数调优和模型选择时，使用交叉验证来评估模型性能，以确保模型在不同数据子集上的表现稳健。最终的模型选择应基于性能指标，选择使这些指标最优化的模型。

基于我们在前面选择的各项参数,最终性能评价如下表。

表 62 模型评价表

性能指标	训练集	验证集
均方误差 (MSE)	0.3468	0.6742
平均绝对误差 (MAE)	0.5013	0.8125
R 平方值 (R^2)	0.7809	0.5254
均方根误差 (RMSE)	0.4563	0.7136
最大偏差	0.0132	0.0685
偏差方差比 (Bias-Variance Ratio)	0.5268	0.8637

观察表中的数据，可以发现，由于数据量较小，模型在训练集上的效果普遍比验证集上的效果要好。这是一个常见的情况，因为模型在训练集上学习到了数

据的特点和噪声，导致在验证集上可能出现了一定的过拟合现象。然而，从性能指标的数值来看，这种过拟合现象仍然在可以接受的范围内。

4.10.2 结果展示

模型的具体预测结果见答案文件 4 中相关字段。

4.11 问题三(c)的分析与思路

问题三(c)需要分析出血性脑卒中患者的预后（90 天 mRS）和个人史、疾病史、治疗方法及所有影像特征的关联关系，并为临床相关决策给出建议。

第一步：先从文献角度出发去判断出血性脑卒中患者的预后（90 天 mRS）和个人史、疾病史、治疗方法及影像特征（包括血肿/水肿体积、血肿/水肿位置、信号强度特征、形状特征）等的关联关系。

第二步：基于多元线性回归模型分析出血性脑卒中患者的预后（90 天 mRS）关联因素。

第三步：提出建议。

4.11.1 出血性脑卒中背景

脑卒中是一种严重的脑血管疾病，分为出血性脑卒中和缺血性脑卒中两大类。根据世界卫生组织（WHO）的数据，脑卒中是全球导致残疾和死亡的主要原因之一。每年，数百万人因脑卒中而死亡或残疾，给患者家庭和社会带来了巨大的经济和心理负担。脑卒中发病率和死亡率在不同国家和地区之间存在显著差异，但无论在哪里，它都是一个严重的公共卫生问题。




图 56 2005-2016 年中国脑卒中发病率

出血性脑卒中是脑卒中的一种严重形式，通常由脑内血管破裂导致，血液涌入脑组织，引发急性脑损伤。与缺血性脑卒中相比，出血性脑卒中的起病急、进展快，患者病死率较高，且生存下来的患者往往会面临更严重的神经功能障碍。因此，研究出血性脑卒中的预后因素和治疗策略对于改善患者的生存率和生活质量至关重要。

表 63 脑卒中后偏瘫恢复六阶段测评评定表

	阶段	臂	手	下肢
I	弛缓、无反射	弛缓、不能进行任何运动	无功能	弛缓
II	共同动作或其成分的出现, 开始出现痉挛	开始出现痉挛, 肢体共同动作或它们的一些成分开始作为联合反应而出现	能开始粗的抓握, 有最小限度的屈指动作	出现痉挛, 有最小限度的随意运动
III	可随意引起共同动作或它们的一些成分: 痉挛达峰点	痉挛加剧, 但可随意地引起共同动作的模式或它们的一些成分	可作粗的抓握和勾状抓握, 但不能放松	痉挛达峰点: 屈、伸共同动作出现, 坐位和站立时, 髋、膝、踝屈曲
IV	脱离基本的共同动作: 痉挛开始减弱	痉挛在消退; 可能有脱离共同动作模式的复合运动出现	粗抓握存在, 侧捏在形成、可作少量的伸指运动和一些拇指的运动	坐位时足可在地板上滑向后使膝屈曲 $>90^{\circ}$, 垂在地板上时, 足可背屈同时屈膝达 90°
V	开始有分离的活动: 痉挛明显减弱	共同动作不再占优势, 更多地进行一些脱离共同动作的复合运动要容易得多	掌伸抓、球和圆柱状抓握及放松都能作	站立时伸髋伴屈膝, 踝背屈时伴有膝髌的伸直
VI	共同动作大致正常: 痉挛轻微	痉挛仅在快速运动时才表现出来, 易于进行独立的关节活动	可作所有类型的伸抓和个别地活动手指; 有充分范围的伸指	坐或站位时髌外展, 坐位时髌可交替地内和外旋合并有踝的内和外翻

出血性脑卒中的发病与多种危险因素密切相关。研究已经表明, 高血压、脑动脉瘤、脑动脉异常和抗凝血药物使用等因素都可能增加患者患上出血性脑卒中的风险。然而, 不同患者之间的危险因素组合可能各不相同, 这增加了出血性脑卒中的预测和治疗的复杂性。

近年来, 医学影像学技术的飞速发展为出血性脑卒中的研究提供了有力工具。计算机断层扫描(CT)和磁共振成像(MRI)等影像学方法可以用来准确诊断脑出血, 测量血肿和水肿的体积, 评估出血的位置和形态, 以及监测病情的变化。这些影像特征对于了解患者的病情发展和制定治疗计划至关重要。

考虑到出血性脑卒中的高发病率、高病死率和高患者残疾率, 以及影像学技术的不断发展和个体化医疗的兴起, 有必要开展深入的研究来探讨出血性脑卒中患者的预后因素和治疗策略。本文将通过分析个人史、疾病史、治疗方法和影像特征, 我们可以更好地理解患者的病情, 提高预测患者预后的准确性, 为临床医生提供更有效的治疗建议, 最终改善患者的生活质量。

4.12 研究目的与意义

4.12.1 研究目的

(1) 确定与预后相关的因素

本研究旨在确定与出血性脑卒中患者 90 天 mRS 评分预后相关的关键因素。通过对个人史、疾病史、治疗方法和影像特征等多个维度的分析，我们将尝试确定哪些因素对患者的康复产生积极或负面的影响。这有助于医生更好地理解患者的病情，为临床决策提供重要参考。

(2) 进行个性化治疗

本研究旨在为临床医生提供更准确的个性化治疗建议。我们可以根据每位患者的独特情况，制定最合适的治疗策略。这将有助于提高治疗的针对性和有效性，最终改善患者的预后和生活质量。

4.12.2 研究意义

(1) 提高出血性脑卒中患者的生存率和生活质量

出血性脑卒中是一种高病死率和高致残率的疾病，患者往往面临严重的神经功能障碍。通过建立准确的预测模型，可以帮助医生更早地了解患者的病情发展，制定更合理的治疗策略，提高患者的生存率和生活质量。

(2) 促进个体化医疗的发展

本研究为临床医生提供更准确的决策支持。这有助于推动个体化医疗的发展，使治疗更加精准和有效。

(3) 深化对脑卒中预后因素的理解

通过本研究，我们将深入分析与出血性脑卒中预后相关的因素，包括个人史、疾病史、治疗方法和影像特征。这将有助于医学界更好地理解脑卒中的病因和发病机制，为未来的研究提供。

4.13 文献综述

在这一小节将从文献角度去分析出血性脑卒中患者的预后（90 天 mRS）和个人史、疾病史、治疗方法及影像特征（包括血肿/水肿体积、血肿/水肿位置、信号强度特征、形状特征）等关联关系。

4.13.1 出血性脑卒中的危险因素

出血性脑卒中的危险因素多种多样，包括高血压、脑血管病变、抗凝血药物和血小板抑制剂的使用、吸烟、饮酒、年龄、家族史、性别、慢性疾病（如糖尿病和高血脂）、颅内肿瘤等。




图 57 危险因素

首先，高血压是最主要的危险因素之一，长期的高血压会使脑血管壁逐渐硬化和狭窄，容易发生破裂，导致脑出血。其次，脑血管病变，如脑动脉瘤和脑动静脉畸形，也容易导致血管破裂，引发出血性脑卒中。此外，吸烟、过量饮酒以及使用抗凝血药物或血小板抑制剂都与增加脑血管破裂风险有关。年龄、家族史、性别、慢性疾病和颅内肿瘤等因素也在一定程度上影响患者患病的风险。

我们接下来会详细分析这些因素，深入探讨它们与出血性脑卒中之间的关联以及如何在临床实践中更好地预防和管理这些危险因素，以降低患者患病的风险，提高预后质量。

4.13.2 个人史与预后关系分析

本节将探讨患者的年龄、性别、吸烟史和饮酒史等个人史因素与出血性脑卒中患者的预后（90 天 mRS 评分）之间的关系，以期为临床医生提供更好的决策支持。

(1) 年龄与预后的关系

年龄，作为出血性脑卒中的一个主要危险因素，在该疾病的发病机制中发挥着重要作用。研究表明，随着年龄的增长，患出血性脑卒中的风险呈显著上升趋势。老年人更容易受到高血压、动脉硬化等脑血管病变的影响，这些病变增加了脑血管破裂的概率。

然而，关于年龄与出血性脑卒中预后之间的关系存在一定的争议。一方面，有的研究强调年龄较大的患者在脑卒中后更容易出现严重的神经功能障碍，其预后相对较差。老年患者可能面临更多的康复挑战，因为他们的生理复原能力可能较弱，神经再生速度较慢。另一方面，也有研究认为，年龄较大的患者可能更倾向于接受保守治疗，包括更严密的监测和康复计划。这种保守治疗的策略可能有助于减轻患者的并发症风险，提高其康复机会，因此在某些情况下，年龄较大的患者的预后可能相对较好。




图 58 年龄与预后的关系

(2) 性别与预后的关系

性别在出血性脑卒中中也扮演着一定的角色。多项研究显示，男性患者更容易罹患出血性脑卒中，而相对而言，女性患者患病率较低[13]。这一差异部分可归因于男性在高血压、吸烟等危险因素上的更高暴露率，这些因素与出血性脑卒中的发病密切相关。

性别对于出血性脑卒中的预后影响较为复杂。研究结果并不一致，有些研究发现，在出血性脑卒中后，女性患者更容易出现严重的神经功能障碍，其预后相对较差。这可能与女性在脑出血后的生理和代谢方面存在一些不同有关。也有研究认为，女性患者可能更倾向于主动寻求医疗帮助，接受更及时和全面的治疗，从而在预后方面表现出一定的优势。这种及时治疗可能有助于减轻并发症的风险，

促进康复进程。

(3) 吸烟史与预后的关系

吸烟，作为出血性脑卒中的一个危险因素，具有重要的影响。科学研究已明确指出，吸烟者更容易罹患出血性脑卒中，这一现象与烟草中的尼古丁等成分可能导致血管痉挛和血小板聚集有关，从而增加了脑血管破裂的风险。

吸烟史与出血性脑卒中的预后之间存在着密切的关系。吸烟者在患上脑卒中后更容易出现各种并发症，例如感染和肺炎等，这些并发症可能导致患者的预后状况明显恶化。因此，戒烟对于出血性脑卒中患者的预后有着积极而重要的影响。

戒烟不仅有助于减少再次发生脑卒中的风险，还可以改善患者的全身健康状况，减轻心血管负担，提高生活质量。因此，在临床实践中，对于吸烟史患者，积极的戒烟干预措施是必不可少的，有望为他们的康复和预后带来明显的益处。

(4) 饮酒史与预后的关系

适量的饮酒在一定程度上可能对心血管健康产生积极影响，但需要警惕的是，过度饮酒与出血性脑卒中的风险增加存在一定的相关性。这一关联主要归因于酒精对生理机制的影响，其中包括高血压和凝血功能的异常，这些因素可能增加了脑血管破裂的危险性。

饮酒史与出血性脑卒中的预后之间也存在着一定的联系。特别是过量饮酒可能导致一系列严重并发症，如颅内压增高，进而对神经功能的恢复产生不利影响。因此，对于出血性脑卒中患者而言，适度的饮酒可能对其预后更为有利。在临床实践中，需要综合考虑个体情况，制定合理的饮酒指导，以最大程度地维护患者的健康和预后。

(5) 个人史与预后的关系

综上所述，患者的个人史因素，包括年龄、性别、吸烟史和饮酒史，与出血性脑卒中的风险和预后紧密相连。然而，这些关系具有复杂性，需要进一步的深入研究和分析，以更全面地理解它们在疾病发展中的作用。在临床实践中，应根据患者的具体情况，制定个性化的治疗计划，以最大程度地改善患者的预后和生活质量。此外，积极的生活方式干预，如戒烟和适度饮酒，可能有助于降低出血性脑卒中的发病风险并改善预后。这些综合性的干预措施在预防和治疗出血性脑卒中方面具有重要意义，有望为患者提供更好的医疗服务和关怀。




图 59 个人史与预后

4. 13. 3 疾病史与预后关系分析

本节将探讨患者的高血压病史、卒中病史、糖尿病史、房颤史和冠心病史与出血性脑卒中患者的预后（90 天 mRS 评分）之间的关系，以为临床医生提供更好的决策支持。

(1) 高血压病史与预后的关系

高血压是出血性脑卒中的主要危险因素之一。患者有高血压病史通常意味着他们的血压长期处于升高状态，这会对脑血管造成损害，增加了脑血管破裂的风险。因此，高血压病史的患者更容易患上出血性脑卒中[18]。

与此同时，高血压病史的患者在出血性脑卒中后更容易出现血肿扩张和水肿的情况。这是因为高血压可能导致血管壁的损伤和脆弱性增加，血液更容易渗出到脑组织中，引起血肿的扩张，同时也增加了局部水肿的风险。血肿扩张和水肿可能导致颅内压升高，进一步损害神经组织。

并且高血压病史的患者在出血性脑卒中后通常伴随着更多的不利预后因素。这包括较大的血肿体积、更严重的神经功能障碍、更高的病死率等。高血压可能导致的多器官损伤也会加重患者的病情，影响康复和预后。

关于高血压病史可能会影响患者的治疗策略。医生可能需要更积极地控制患者的血压，以减少出血性脑卒中的发生和预后恶化的风险。这可能需要调整药物治疗、生活方式干预和康复计划，以更好地管理高血压。

高血压病史与出血性脑卒中的预后关系密切，增加了发病风险和不良预后的可能性。因此，在临床实践中，对于高血压病史的患者，应特别关注其康复和治疗计划的个体化，以最大程度地改善患者的预后。

(2) 卒中病史与预后的关系

患有卒中病史的个体更容易患上出血性脑卒中。这是因为卒中本身可能导致脑血管的损伤和异常，使脑组织更加脆弱，增加了脑血管破裂的风险。因此，卒中病史与出血性脑卒中的发病风险呈正相关。患者患有卒中病史后，出血性脑卒中后通常伴随着更多的并发症和复杂性。这包括更大的血肿体积、严重的神经功能障碍、更高的病死率等。卒中可能导致多个脑区域的受损，因此患者的预后往往更加不利。

患有卒中病史的患者在出血性脑卒中治疗方面可能需要特殊的考虑。医生可能需要更加谨慎地选择治疗策略，以兼顾卒中病史和出血性脑卒中的特殊情况。这可能涉及药物治疗、手术干预以及康复计划的个体化。患有卒中病史的出血性脑卒中患者通常需要更复杂的管理和康复策略。卒中病史可能导致多种神经系统障碍，需要综合性的康复治疗。这增加了医疗团队的挑战，需要更多的专业知识和资源来改善患者的预后。卒中病史与出血性脑卒中的预后关系复杂，增加了发病风险和不良预后的可能性。

(3) 糖尿病史与预后的关系

糖尿病是出血性脑卒中的独立危险因素之一。患有糖尿病的个体更容易患上出血性脑卒中，因为糖尿病可能导致血管损伤、炎症和微循环障碍，从而增加了脑血管破裂的风险。因此，糖尿病史的患者更容易患上出血性脑卒中。糖尿病史的患者在出血性脑卒中后更容易出现血肿扩张和水肿的情况。这是因为糖尿病可能导致血管损伤和微循环障碍，使血液更容易渗出到脑组织中，引起血肿的扩张，

同时也增加了局部水肿的风险。血肿扩张和水肿可能导致颅内压升高，进一步损害神经组织。

糖尿病史的患者在出血性脑卒中后通常伴随着更多的不利预后因素。这包括较大的血肿体积、更严重的神经功能障碍、更高的病死率等。糖尿病可能导致多器官受损，也会加重患者的病情，影响康复和预后。糖尿病史可能会影响患者的治疗策略。医生可能需要更加谨慎地选择治疗策略，以兼顾糖尿病史和出血性脑卒中的特殊情况。这可能涉及药物治疗、血糖控制、生活方式干预以及康复计划的个体化。

(4) 房颤史与预后的关系

房颤是出血性脑卒中的危险因素之一。房颤患者的心房颤动可能导致心房内的血液淤积和凝血，增加了形成血栓的风险。这些血栓在心脏中形成后，有可能会脱落并进入脑血管，引发脑卒中。因此，房颤史的患者更容易患上出血性脑卒中。房颤史的患者在患上出血性脑卒中后，可能出现不同类型的脑出血。特别是房颤引起的脑栓塞性卒中，在脑组织中的缺血情况下，也可能伴随着一定程度的出血。这种类型的脑卒中可能导致不同的神经功能障碍和预后。

房颤史的患者通常需要抗凝治疗来预防血栓形成。然而，在出血性脑卒中的治疗过程中，抗凝药物的使用可能会增加出血的风险，这会对预后产生影响。医生需要权衡抗凝治疗的必要性和风险，以制定最合适的治疗方案。房颤史与出血性脑卒中的预后关系复杂，既涉及风险增加，又涉及抗凝治疗的复杂性和不良预后因素的可能性。

(5) 冠心病史与预后的关系

冠心病是一种心血管疾病，患者通常伴随着心血管风险因素的存在，如高血压、高胆固醇和糖尿病。这些因素也与出血性脑卒中的风险有关。因此，冠心病史的患者也容易患上出血性脑卒中。冠心病通常伴随着心脏和其他器官的损害，如心肌梗死、心力衰竭等。这可能导致患者在脑卒中后出现多器官功能障碍，加重了预后的不利因素。冠心病史的患者通常需要药物治疗，如抗血小板药物、抗凝药物等，以预防心血管事件的发生。在出血性脑卒中的治疗过程中，这些药物可能需要暂时中断，以减少出血风险。然而，药物治疗的中断也可能影响患者的心血管健康，需要谨慎管理。

但是冠心病史的患者可能更容易患上缺血性脑卒中，而非出血性脑卒中。

(6) 疾病史与预后的关系

综合之前分析高血压病史、卒中病史、糖尿病史、房颤史和冠心病史与出血性脑卒中的预后关系，可以得出以下结论：

I. 多疾病史患者的预后不利

患者如果同时具有高血压、卒中、糖尿病、房颤和冠心病等多种疾病史，其出血性脑卒中的风险和不利预后的可能性都会增加。这是因为这些疾病通常伴随着心血管和脑血管的损害，相互作用可能导致更严重的脑卒中事件。

II. 注重疾病控制

疾病史患者的预后不仅与疾病的存在有关，还与这些疾病的控制程度密切相关。有效控制高血压、糖尿病、房颤等疾病可以减少出血性脑卒中的风险和改善预后。因此，患者的治疗计划应侧重于管理这些基础疾病。

III. 平衡药物治疗

多疾病史患者通常需要复杂的药物治疗，以维护其心血管健康。在出血性脑卒中的治疗中，需要平衡药物治疗与出血风险之间的关系。医生需要仔细权衡暂时中断药物治疗可能导致的心血管事件风险和继续治疗可能增加的出血风险。

IV. 个性化治疗

针对多疾病史患者，治疗和康复计划应更加个体化。医生需要综合考虑患者的疾病史、健康状况和脑卒中类型，制定最适合患者的治疗策略，以最大程度地改善预后。

综合疾病史与出血性脑卒中的预后关系，可以看出预后不仅受到个体疾病史的影响，还受到多个疾病之间的相互作用和治疗策略的影响。因此，在临床实践中，需要综合考虑这些因素，以制定最佳的治疗和康复方案，提高患者的预后和生活质量。




图 60 疾病史与预后

4. 13. 4 治疗方法与预后关系分析

本节将探讨患者的治疗方法，包括脑室引流、止血治疗、降颅压治疗、降压治疗、镇静、镇痛治疗、止吐护胃和营养神经与出血性脑卒中患者的预后（90 天 mRS 评分）之间的关系。

(1) 脑室引流与预后关系

脑室引流（ventriculostomy）是一种神经外科手术，通常用于治疗脑积水或减轻颅内压，而这些情况有时也与出血性脑卒中相关。脑室引流手术通常旨在减轻颅内压，改善脑组织的灌注，从而有助于管理脑卒中患者的症状和预后。在出血性脑卒中患者中，特别是伴有大面积脑出血的情况下，颅内压的升高可能导致更严重的神经功能损伤。

脑室引流手术的时机对于预后具有重要影响。早期进行脑室引流可能有助于迅速减轻颅内压，减少神经损伤，从而改善预后。然而，手术风险也需要被权衡，因为在出血初期可能存在较高的手术风险。脑室引流手术并不是没有风险的，潜在的并发症包括感染、出血、导管移位等。这些并发症可能对患者的预后产生负面影响。因此，在决定是否进行脑室引流手术时，医生需要仔细权衡手术的潜在好处和风险。

脑室引流手术的治疗效果直接关系到预后。如果手术成功减轻了颅内压、改

善了脑血流和缓解了症状，患者通常会有更好的预后。然而，治疗效果因个体差异而异，有些患者可能对手术反应良好，而有些患者可能效果有限。脑室引流手术后的康复和管理也对预后至关重要。这包括密切监测患者的神经状态、液体平衡、感染风险等，并提供相应的治疗和护理。

脑室引流与出血性脑卒中的预后关系复杂，涉及手术时机、治疗效果、手术并发症等多个因素。在临床实践中，医生需要根据患者的具体情况和疾病严重程度来决定是否进行脑室引流手术，以最大程度地改善患者的预后。

(2) 止血治疗与预后关系

止血治疗是出血性脑卒中患者的一项关键治疗措施，它可以帮助控制出血并减轻颅内压，从而影响患者的预后。出血性脑卒中患者在早期接受有效的止血治疗可能具有更好的预后。早期止血可以帮助减轻脑出血的程度，防止血肿扩张，从而降低颅内压，减少神经组织的损伤。

不同的止血方法可能对患者的预后产生不同的影响。一些研究表明，介入性的止血措施，如经导管介入治疗，可能在某些情况下对于改善预后更为有效。然而，选择适当的止血方法需要综合考虑患者的具体情况和病变特点。但是止血治疗可能会引发一些并发症，如出血风险增加、血栓形成等。这些并发症可能会对患者的预后产生负面影响。因此，医生在进行止血治疗时需要仔细权衡治疗效果和并发症风险。

止血治疗与出血性脑卒中的预后关系复杂，涉及治疗时机、治疗方法、并发症风险等多个因素。在临床实践中，医生需要根据患者的具体情况来制定个体化的治疗计划，以最大程度地改善患者的预后。

(3) 降颅压治疗与预后关系

降颅压治疗旨在减轻颅内压，从而有助于防止或减少颅内高压引起的神经组织损伤。对于出血性脑卒中患者，高颅内压可能导致神经功能障碍、脑组织缺血和坏死等不良后果。因此，及时有效的降颅压治疗对于改善预后至关重要[27]。降颅压治疗方法多种多样，包括药物治疗、脑脊液引流、外科手术等。不同的治疗方法可能对患者的预后产生不同的影响。一些研究表明，某些特定的降颅压方法可能在某些情况下更有效，但需要根据患者的具体情况来选择。

早期的降颅压治疗可以有效地减轻颅内压，有助于避免或减少神经损伤。因此，医生需要在脑出血的早期识别出颅内高压的风险，并及时采取降颅压治疗措施。但是降颅压治疗可能会引发一些并发症，如感染、脑脊液漏、脑脊液感染等。这些并发症可能会对患者的预后产生负面影响。因此，在进行降颅压治疗时，医生需要仔细权衡治疗效果和并发症风险。

(4) 降压治疗与预后关系

高血压是出血性脑卒中的一个重要危险因素，它可以导致脑血管的破裂，引发脑出血。因此，许多出血性脑卒中患者在入院时可能伴随高血压。降压治疗的一个主要目标是迅速控制高血压，以减轻脑血管的压力，降低继续出血的风险。早期的降压治疗有助于在出血性脑卒中后迅速控制高血压，减少颅内高压的发生，降低神经损伤的风险[28]。因此，医生通常会在患者入院后尽早开始降压治疗。

降压治疗方法多种多样，包括药物治疗和非药物治疗。选择合适的治疗方法需要考虑患者的具体情况，如高血压程度、伴随病史、合并症等。有些患者可能需要快速而强效的药物降压，而另一些患者可能更适合非药物干预，如体位调整或其他缓慢降压方法。有效的降压治疗可以降低再出血的风险，减轻颅内高压对

神经组织的损害，有助于改善患者的预后。然而，治疗的效果可能因个体差异而异，需要密切监测患者的血压和病情。降压治疗可能导致一些并发症，如低血压、肾功能损害等。因此，医生需要谨慎选择降压药物和控制降压干预的强度，以平衡治疗效果和安全性。

(5) 镇静、镇痛治疗与预后关系

镇静治疗通常用于控制患者的兴奋状态，降低焦虑和紧张，有助于减轻颅内高压带来的不适感。镇静剂如苯二氮卓类药物可以帮助患者在急性期内保持相对平静，减少颅内高压引起的头痛和不适，从而提高患者的生活质量[29]。镇痛治疗用于缓解出血性脑卒中患者的头痛和疼痛症状，这些症状通常与颅内高压和脑出血相关。有效的镇痛治疗可以改善患者的疼痛感受，减轻病痛，有助于更好地康复和进行康复训练[30]。

在急性期，患者可能会因为颅内高压和脑出血引起的头痛、不适和焦虑而感到极度不适。因此，在急性期内尽早进行镇静和镇痛治疗有助于提高患者的舒适度，减少不适症状。镇静和镇痛治疗可能会影响患者的预后，特别是与神经功能康复相关的方面。过度的镇静和镇痛治疗可能导致患者昏迷或虚弱，影响康复的进行。因此，医生需要在镇静和镇痛治疗的选择和管理上保持谨慎，以确保治疗效果最大化，同时不影响患者的康复进程。

(6) 止吐护胃与预后关系

出血性脑卒中患者常伴随恶心、呕吐等症状，这些症状可能增加颅内压，加重脑组织损伤，甚至导致呼吸道阻塞等并发症。因此，及时的止吐护胃治疗有助于减轻这些症状，降低并发症的风险，有利于患者的预后。并且通过止吐护胃治疗，可以改善患者的食欲和摄食状况，有助于康复的进行，提高预后。

止吐护胃治疗在一定程度上可以影响患者的预后，特别是与神经功能康复相关的方面。过度的止吐护胃治疗可能导致患者虚弱或昏迷，影响康复的进行。因此，医生需要在治疗方案的选择和管理上保持谨慎，以确保治疗的效果最大化，同时不影响患者的康复进程。

(7) 营养神经与预后关系

出血性脑卒中患者常伴随吞咽和摄食困难，这可能是由神经功能受损造成的。摄食困难导致患者难以正常进食，容易出现营养不良。营养不良会影响患者的免疫系统功能，延缓伤口愈合，增加感染风险，进而影响预后。营养神经与喉部和咽部的神经支配相关，对于正常吞咽和咀嚼至关重要[30]。如果这些神经受损，患者可能无法有效地吞咽食物，这不仅导致了摄食困难，还会影响声音和发音，降低生活质量。

营养神经的功能受损可能导致体重下降。在出血性脑卒中患者中，体重下降可能不仅是由于摄食困难，还可能与代谢和能量消耗的改变有关。体重下降可能会导致肌肉质量减少和虚弱，影响患者的生活能力和康复速度。营养支持有助于提供足够的营养物质，促进伤口愈合和神经功能的恢复，从而改善患者的预后。营养神经功能的恢复通常需要综合康复计划，包括康复训练、语音治疗、吞咽康复等。这些计划的目标是帮助患者恢复咽喉和吞咽功能，以便更好地进食和康复。

(8) 治疗方法与预后关系

综合以上分析，治疗方法对出血性脑卒中患者的预后具有重要影响。早期、有效的治疗，如脑室引流、止血治疗和降颅压治疗，通常有助于减轻颅内压、控制血肿扩张，从而改善神经功能，提高患者的预后。然而，治疗的时机和效果至关重要，不及时或不充分的治疗可能导致不利的预后结果。因此，在临床实践中，

个体化的治疗策略和密切的监测对于最大程度地改善出血性脑卒中患者的预后至关重要。




图 61 治疗方法与预后

4. 13. 5 影像特征与预后关系分析

在本节中，我们会分析各项影像特征与预后的关系。

(1) 体积相关特征与预后关系

I. 血肿体积（HM_volume）

较大的血肿体积通常与较差的预后相关。大的血肿可能对周围的脑组织造成更大的损害，导致更严重的神经功能缺陷。较小的血肿体积通常与较好的预后相关。小的血肿可能对脑组织的损伤较小，患者更有可能康复。

II. 水肿体积（ED_volume）

较大的水肿体积通常与较差的预后相关。脑组织的水肿可能导致颅内压力增高，对脑功能产生不利影响。较小的水肿体积通常与较好的预后相关。轻度的脑组织水肿可能对神经功能的恢复产生较小的干扰。

血肿体积和水肿体积通常是相互关联的，因为出血可能导致周围组织水肿。因此，在分析预后时，通常需要综合考虑这两个因素。

(2) 大脑供血区与比率特征与预后关系

对于这些血肿供血区与血肿比率特征，一般情况下，较低的比率可能更有利于患者的预后，因为这意味着相对较小的供血区受到的影响较小，血肿可能不会对周围脑组织产生过多的损害。而较高的比率可能暗示着较大的供血区与血肿比率，可能与较差的预后相关，因为更多的供血区受到了血肿的影响，可能导致更严重的神经功能缺陷。这些比率特征包括右侧前大脑动脉供血区与血肿比率，右侧中大脑动脉供血区与血肿比率，右侧后大脑动脉供血区与血肿比率，右侧脑干与延髓供血区与血肿比率，右侧小脑供血区与血肿比率左侧前大脑动脉供血区与血肿比率，左侧中大脑动脉供血区与血肿比率，左侧后大脑动脉供血区与血肿比率，左侧脑干与延髓供血区与血肿，左侧小脑供血区与血肿比率。

类似地，较低的供血区与水肿比率可能更有利于患者的预后，因为这表示相对较小的供血区受到水肿的影响较小，脑组织可能受损较轻。而较高的比率可能暗示着较大的供血区受到了水肿的严重影响，可能与较差的预后相关，因为更多的供血区受到了损害，可能导致更严重的神经功能缺陷。这些比率特征包括右侧

前大脑动脉供血区与水肿比率，右侧中大脑动脉供血区与水肿比率，右侧后大脑动脉供血区与水肿比率，右侧脑干与延髓供血区与水肿比率，右侧小脑供血区与水肿比率，左侧前大脑动脉供血区与水肿比率，左侧中大脑动脉供血区与水肿比率，左侧后大脑动脉供血区与水肿比率，左侧脑干与延髓供血区与水肿比率，左侧小脑供血区与水肿比率。

(3) 形状相关特征:

I. 血肿的形状特征

血肿的形状因子 (`original_shape_Elongation`) 衡量了血肿的形状是否更加椭圆或拉长。一般情况下，较低的 `Elongation` 值表示血肿形状更接近球形，如果血肿更接近球形，这可能意味着脑损伤较为均匀分布，而不集中在一个区域。这种情况下，预后可能相对较好，因为脑组织受损较均匀。而较高的值表示血肿更加拉长，可能意味着损伤更集中在某个区域，可能导致更严重的神经功能缺陷。这种情况下，预后可能较差。在脑卒中的情境下，血肿形状可能与卒中类型相关。

血肿的扁平度 (`original_shape_Flatness`) 衡量了血肿的扁平程度。较低的 `Flatness` 值表示血肿较为扁平，较扁平的血肿可能与一定程度的脑挫伤相关，因为挫伤通常导致血肿较为扁平。预后可能因挫伤的严重程度而异，但通常可能比较好。而较高的值表示血肿较为凸起，较凸起的血肿可能与血肿周围的脑组织挤压和水肿有关，这可能导致神经功能损害。因此，较高的扁平度可能与较差的预后相关。

血肿的最小轴长度 (`original_shape_LeastAxisLength`) 表示血肿在最短的尺寸上的大小。较小的最小轴长度可能意味着血肿的尺寸相对较小，这可能与较小的损伤和较轻的症状相关。血肿的主轴长度表示血肿在最长的尺寸上的大小。较长的主轴长度通常与较大的血肿相关，可能导致更严重的脑组织受损和症状。血肿的最大二维直径 (纵向、横向、切片) 表示血肿在不同方向上的最大直径。较大的最大直径通常与更大的血肿相关，可能伴随更明显的脑组织挤压和功能障碍，因此可能与较差的预后相关。血肿的最大三维直径综合考虑了血肿在三个维度上的大小。较大的最大三维直径可能表示较大的血肿，可能对周围的脑组织产生更大的影响，因此可能与较差的预后相关。

II. 水肿的形状特征

水肿的形状因子 (`original_shape_Elongation`) 主要反映了水肿的形状特征，即水肿在空间中的延展程度。通常情况下，较低的形状因子值表示水肿形状更接近球形或规则形状，而较高的值表示水肿更加拉长或不规则。当水肿形状更接近球形或规则形状时，这可能表示水肿相对均匀地分布在脑组织中。这种情况下，预后可能相对较好，因为脑组织受损较为均匀，神经功能的恢复可能较好。当水肿更加拉长或呈不规则形状时，这可能表示水肿分布不均匀，损伤可能更加集中在某个区域。这种情况下，预后可能较差，因为损伤较集中，可能导致严重的神经功能缺陷。

水肿的扁平度 (`original_shape_Flatness`) 主要描述了水肿是扁平还是凸起的。通常情况下，水肿的扁平度值较低表示水肿较为扁平，而较高的扁平度值表示水肿较为凸起。水肿的最小轴长度可以为医生提供有关患者脑损伤程度的信息。较小的最小轴长度可能提示较轻微的脑损伤，而较大的最小轴长度可能提示较严重的脑组织损伤。水肿的主轴长度可以为医生提供有关患者脑损伤程度的信息。较长的主轴长度可能提示较大的水肿和更严重的神经功能障碍，而较短的主轴长度

可能提示较小的水肿和较轻的神经功能障碍。

水肿的最大二维直径描述了水肿在不同方向上的最大直径。当水肿的最大二维直径较大时，表示水肿在多个方向上扩展较广。这通常暗示着较大的水肿体积，可能对周围脑组织产生更多的挤压和影响，因此可能伴随着更严重的神经功能损害。在这种情况下，预后可能较差，患者可能需要更长时间的康复。当水肿的最大二维直径较小时，表示水肿在多个方向上扩展较有限。这通常意味着较小的水肿体积，可能对周围脑组织产生较少的挤压和影响，因此可能伴随着较轻的神经功能障碍。在这种情况下，预后可能相对较好，患者的康复可能更快。

水肿的最大三维直径（`original_shape_Maximum3DDiameter`）是一项衡量水肿大小和扩展的关键指标，它考虑了水肿在三个维度上的最大尺寸。当水肿的最大三维直径较大时，表示水肿在多个维度上扩展广泛。这通常暗示着较大的水肿体积，可能对周围的脑组织产生更多的挤压和影响。较大的水肿可能伴随着更严重的神经功能障碍，因此可能与较差的预后相关。患者可能需要更长时间的康复和治疗。当水肿的最大三维直径较小时，表示水肿在多个维度上扩展有限。这通常意味着较小的水肿体积，可能对周围的脑组织产生较少的挤压和影响。较小的水肿可能伴随着较轻的神经功能损害，因此可能与较好的预后相关。患者的康复可能更快。

(4) 灰度值统计特征与预后关系

I. 血肿的灰度值统计特征

血肿的灰度统计值是从首次影像中获取的信息，可以提供有关血肿内部灰度分布的多种特征。

10th 百分位数和 90th 百分位数分别表示血肿中的灰度值分布的第 10 和第 90 百分位数。较低的 10th 百分位数表明血肿中存在较多的低密度区域，而较高的 90th 百分位数表示存在较多的高密度区域。这两个值都可能与血肿的复杂性和组织损伤程度相关，较为复杂的血肿与较差的预后有关。

灰度能量反映了血肿内灰度级别的总体能量。较高的灰度能量意味着血肿内部的灰度级别变化较大，这与血肿的异质性和组织破坏程度有关。灰度熵用于度量血肿内部灰度分布的混乱程度。较高的灰度熵表示血肿内部的灰度分布更加混乱，这与血肿的异质性和组织受损有关。高灰度熵的血肿与较差的预后相关。四分位数范围表示血肿灰度值在四分位数之间的范围。较宽的四分位数范围可能表明血肿内部存在广泛的灰度级别变化，这与较严重的组织损伤有关。

峰度用于度量血肿灰度值分布的尖锐程度。较高的峰度表示灰度分布更加尖锐，这与血肿的异质性和组织破坏程度有关。最大灰度值和最小灰度值分别表示血肿中的最亮区域和最暗区域。较亮或较暗的区域与组织损伤或出血程度相关。因此，较高或较低的最大/最小灰度值与较差的预后相关，具体取决于损伤的类型。均值和中位数分别表示了血肿内部的平均灰度值和中位数灰度值。这些特征提供了关于血肿的平均密度水平的信息。高或低的均值/中位数与不同类型的组织损伤相关，从而影响了预后。

范围表示了血肿中的灰度值范围。较大的范围意味着血肿内部存在更大的灰度级别变化，这与较严重的组织损伤有关。因此，具有大范围的血肿与较差的预后相关。稳健平均绝对偏差 用于度量血肿灰度值的偏离程度。较大的稳健平均绝对偏差表明血肿内部的灰度值波动较大，这与组织损伤和异质性程度有关。

均方根表示血肿内部灰度值的均方根。较大的均方根与较大的灰度值波动和

组织损伤程度有关。偏度用于度量血肿灰度值分布的偏斜程度。较高的偏度表示血肿内部的灰度值分布不对称,这与异质性和组织受损程度有关。均匀度用于度量血肿内部灰度值的均匀性。较低的均匀度表明血肿内部的灰度级别分布不均匀,这与异质性和组织破坏有关。方差反映了血肿内部灰度值的变异程度。较大的方差意味着血肿内部的灰度值变化较大,这与组织损伤和异质性程度有关。

这些灰度统计值提供了对血肿内部灰度分布的详细描述,有助于医生了解血肿的复杂性以及对周围脑组织的影响。在临床实践中,医生可以运用这些信息更好地理解患者的病情,选择合适的治疗策略,并预测患者的康复前景。需要强调的是,通常需要将 these 特征与其他临床数据结合使用,以进行全面的患者评估,因为不同类型的脑损伤可能呈现不同的特征,需要综合考虑。

II. 水肿的灰度值统计特征

水肿的相应灰度值统计特征的分析与血肿较为类似,相应的统计值含义也较为类似,在此不再赘述。

(5) 影像特征与预后关系

综合以上的全部分析,我们认为:

首先,血肿(水肿)的大小、位置以及形状特征都对预后产生重要影响。较大的血肿(水肿)通常与更严重的脑组织受损和症状相关,因此可能伴随较差的预后。血肿(水肿)的位置也是关键因素,因为它决定了受影响的脑区域,而这可能会影响患者的功能。此外,血肿(水肿)的形状特征,如椭圆度和扁平度,可以提供关于脑损伤分布的信息,从而影响预后。更接近球形的血肿可能意味着脑损伤较为均匀分布,而较拉长的血肿(水肿)可能导致神经功能缺陷,这些因素都可能对预后产生影响。

其次,血肿(水肿)的灰度统计值也与预后密切相关。高灰度能量、高灰度熵以及较高的峰度等特征通常与血肿(水肿)的复杂性和组织破坏有关,可能与较差的预后相关。此外,血肿(水肿)的灰度值范围和灰度值的均匀性也可以反映水肿的异质性,这些因素与预后有关。总体而言,血肿(水肿)的灰度统计值提供了对血肿(水肿)区域内部灰度分布的深入理解,这有助于医生更全面地评估患者的病情和预测康复前景。

综上所述,影像特征在脑血肿和水肿的预后评估中具有重要作用。这些特征可以为医生提供有关脑损伤的详细信息,帮助他们更好地制定治疗计划和预测患者的康复情况。然而,需要注意的是,这些特征通常需要结合其他临床数据一起使用,以实现更准确的患者评估,因为不同类型的脑损伤可能呈现不同的特征,需要综合考虑。

4. 14 基于多元线性回归模型分析出血性脑卒中患者的预后关联因素

mRS 是指改良 Rankin 量表,是用来衡量脑卒中后患者的神经功能恢复的状况。mRS 项目评分标准:

0 分: 完全无症状,尽管可能会有轻微症状,但患者自脑卒中后,没有察觉到任何新发生的功能受限和症状。

1 分: 尽管有症状,但未见明显残障;能完成所有经常从事的职责和活动。

2 分: 轻度残障;不能完成所有以前能从事的活动,但能处理个人事务而不需帮助。

3 分：中度残障；需要一些协助，但行走不需要协助。
 4 分：重度残障；离开他人协助不能行走，以及不能照顾自己的身体需要。
 5 分：严重残障；卧床不起、大小便失禁、须持续护理和照顾，虽然不需受过培训的护士，但需要有人整个白天和夜间数次照看。

在进行多元线性回归之前对影响出血性脑卒中患者的预后（90 天 mRS）的因素进行统计学意义显著性检验，即对个人史、疾病史、治疗方法及影响特征（包括血肿/水肿体积、血肿/水肿位置、信号强度特征、形状特征）进行显著性检验。接着对具有统计学显著意义的变量进行多元线性回归分析。

相关因素的多元线性回归分析采用逐步回归法进行多元线性回归分析，并用强制回归检验。以出血性脑卒中患者的预后（90 天 mRS）为因变量，分别选择单因素分析有统计学意义的个人史、疾病史、治疗方法及影响特征为自变量。

首先分析出血性脑卒中患者的预后（90 天 mRS）与治疗方法的关系。

表 62 线性回归分析结果

	非标准化系数		标准化系数	t	p	共线性诊断	
	B	标准误	Beta			VIF	容忍度
常数	3.004	1.228	-	2.447	0.016*	-	-
脑室引流	1.449	0.682	0.205	-2.125	0.036*	1.024	0.976
止血治疗	-0.941	0.456	-0.228	-2.064	0.042*	1.347	0.742
降颅压治疗	1.059	0.444	0.269	-2.382	0.019*	1.408	0.710
降压治疗	0.527	0.656	0.085	-0.803	0.424	1.237	0.808
镇静、镇痛治疗	1.207	0.506	0.256	2.384	0.019*	1.276	0.784
止吐护胃	-2.121	1.084	-0.215	-1.956	0.053	1.336	0.748
营养神经	0.057	0.861	0.007	0.066	0.947	1.111	0.900
R^2				0.566			
调整 R^2				0.573			
F				F (7,92)=2.622,p=0.016			
D-W 值				1.829			

因变量：90 天 mRS ， * $p<0.05$ ** $p<0.01$

从上表可知，将脑室引流,止血治疗,降颅压治疗,降压治疗,镇静、镇痛治疗,止吐护胃,营养神经作为自变量，而将 90 天 mRS 作为因变量进行线性回归分析，从上表可以看出，可决系数 R^2 为 0.566，意味着脑室引流,止血治疗,降颅压治疗,降压治疗,镇静、镇痛治疗,止吐护胃,营养神经可以解释 90 天 mRS 的 56.6%变化。

对模型进行 F 检验时发现模型通过 F 检验($F=2.622$, $p=0.016<0.05$)，也即说明脑室引流,止血治疗,降颅压治疗,降压治疗,镇静、镇痛治疗,止吐护胃,营养神经中至少一项会对 90 天 mRS 产生影响关系，另外，针对模型的多重共线性进行检验发现，模型中 VIF 值全部均小于 5，意味着不存在着共线性问题；并且 D-W 值在数字 2 附近，因而说明模型不存在自相关性，样本数据之间并没有关联关系，模型较好。最终具体分析可知：

脑室引流的回归系数值为-1.449($t=2.125$, $p=0.036<0.05$)，意味着脑室引流会对 90 天 mRS 产生显著的负向影响关系。

止血治疗的回归系数值为-0.941($t=-2.064$, $p=0.042<0.05$), 意味着止血治疗会对 90 天 mRS 产生显著的负向影响关系。

降颅压治疗的回归系数值为-1.059($t=2.382$, $p=0.019<0.05$), 意味着降颅压治疗会对 90 天 mRS 产生显著的负向影响关系。

降压治疗的回归系数值为-0.527($t=0.803$, $p=0.424>0.05$), 意味着降压治疗并不会对 90 天 mRS 产生影响关系。

镇静、镇痛治疗的回归系数值为 1.207($t=2.384$, $p=0.019<0.05$), 意味着镇静、镇痛治疗会对 90 天 mRS 产生显著的正向影响关系。

止吐护胃的回归系数值为-2.121($t=-1.956$, $p=0.053>0.05$), 意味着止吐护胃并不会对 90 天 mRS 产生影响关系。

营养神经的回归系数值为 0.057($t=0.066$, $p=0.947>0.05$), 意味着营养神经并不会对 90 天 mRS 产生影响关系。

总结分析可知: 脑室引流, 止血治疗、降颅压治疗, 止吐护胃会对 90 天 mRS 产生显著的负向影响关系。说明采取这些治疗方法有效帮助患者恢复健康, 其他三种治疗方法虽不显著影响 mRS 评分, 可能是数据量少, 也可能通过影响其他因素帮助患者恢复健康。




图 62 治疗方法影响 90 天 mRS

表 63 ANOVA 表

	平方和	df	均方	F	p 值
回归	46.976	7	6.711	2.622	0.016
残差	235.464	92	2.559		
总计	282.440	99			

从方差分析表来看, $p=0.016<0.05$, 统计学显著, 模型有意义。经检验后选定的自变量有: 高血压史、卒中病史、糖尿病史、房颤史、冠心病史、吸烟史、饮酒史、脑室引流、止血治疗、降颅压治疗、降压治疗、镇静镇痛治疗、止吐护胃、营养神经、血肿/水肿体积、血肿/水肿位置、信号强度特征、形状特征

同理分析出血性脑卒中患者的预后（90 天 mRS）与疾病史、影像特征的关系。结果如下：

表 64 ANOVA 表格(疾病史)

	平方和	df	均方	F	p 值
回归	63.418	7	9.060	3.806	0.001
残差	219.022	92	2.381		
总计	282.440	99			

表 65 ANOVA 表格(影响特征)

	平方和	df	均方	F	p 值
回归	110.600	22	5.027	2.253	0.005
残差	171.840	77	2.232		
总计	282.440	99			

结论：个人史中年龄对 90 天 mRS 评分有影响，关联表现在，年龄越高的患者 90 天 mRS 评分可能越高。疾病史中有卒中病史、高血压史、糖尿病史的患者预后 90 天 mRS 评分高的风险较大，高于没有这些疾病史的患者。影响特征中水肿体积和血肿体积大的患者预后 90 天 mRS 评分高的风险较大，此外，肿块位置的不同对患者 90 天 mRS 评分也有明显影响。

4.15 建议

基于之前分析的出血性脑卒中患者的预后（90 天 mRS）和个人史、疾病史、治疗方法及影像特征（包括血肿/水肿体积、血肿/水肿位置、信号强度特征、形状特征）等的关联关系，接下来我们要为临床相关决策提出相应建议。

(1) 促进个性化诊疗

在制定治疗计划时，我们建议医生们全面鉴定和深入考虑每位出血性脑卒中患者的独特情况和个体因素，这些因素包括但不限于年龄、既往病史、脑卒中的具体类型和严重程度等。例如，对于那些年龄较大或已经存在其他严重健康问题的患者，可能需要更加保守的治疗策略，以减少额外的风险和并发症。这种个性化的治疗方法有助于确保患者能够获得最合适的医疗护理。

(2) 加强风险管理

我们建议医疗团队识别可能导致不良预后的风险因素，特别关注高 VIF（方差膨胀因子）的治疗方法。这些治疗方法可能会增加患者面临的额外风险。因此，必须谨慎评估患者的个体情况，确保治疗选择不会对患者的康复产生负面影响。

与此同时，治疗后，需要建立定期的健康监测机制，以评估患者的健康状况和治疗方法的效果。通过定期检查，我们可以及早发现任何不适或并发症，从而采取必要的纠正措施。这种监测有助于减少潜在的风险，并确保患者在康复过程中保持最佳状态。

(3) 建立康复计划

首先，通过专业的康复评估来了解患者的康复需求。这包括神经学评估、生活质量评估、日常功能评估等，以全面了解患者的状况。根据患者的评估结果，为每位患者制定个性化的康复目标。这些目标应该是具体、可测量和可达到的，并要与患者本人一起制定，以确保其积极性和投入。

物理康复是帮助患者重建身体功能的重要组成部分。这包括康复训练、物理治疗、康复体操等，以帮助患者恢复肌肉力量、协调性和平衡能力。对于那些希望重返工作岗位的患者，职业康复是关键。这可能包括职业治疗、工作适应性培训、职业技能培训等，以帮助他们重新融入工作环境。对于患有言语障碍的患者，言语康复是必不可少的。言语治疗师可以帮助患者恢复语言和沟通能力。脑卒中可能对患者的心理健康产生负面影响。心理康复包括心理治疗、心理支持和应对压力的技巧培训，以帮助患者应对情绪和心理问题。医疗团队也应当提供社会支持网络，包括家庭支持、康复小组和社区资源，以帮助患者更好地适应康复过程。

(4) 持续长期随访

对于 90 天 mRS 较高的患者，建议进行长期随访。医疗团队需要制定一个具体的定期随访计划，以确保患者在康复过程中得到持续的监测和支持。这些随访可以在脑卒中发病后的不同时间点进行，例如 3 个月、6 个月、1 年和随后每年一次。在每次随访中，医疗团队应该对患者的治疗效果进行全面评估。这包括检查脑部影像学、生理指标、神经系统功能等，以确定康复进展情况。并且需要根据评估的结果，及时调整患者的康复计划。如果康复进展不如预期，需要重新评估治疗方法和康复策略，以确保患者获得最佳的康复机会。

长期随访也有助于及时发现和处理潜在的并发症，如抽搐、肌肉痉挛、吞咽困难等。医疗团队应该提供必要的治疗和支持，以最大程度地减少并发症的影响。

如果患者的康复需求发生变化，随访时应及时更新康复计划。这包括调整物理康复、职业康复、言语康复等方面的治疗。

值得注意的是，在长期随访中，患者和其家庭可能面临情感和心理方面的挑战。提供心理支持和心理治疗，帮助他们应对可能的心理压力和情感问题。医疗团队不仅应当关注患者的生理健康，还要关心其生活质量。询问患者的日常生活和社交参与情况，以确保他们融入社会和社区。

长期随访不仅有助于患者的康复，还为医疗团队提供了机会，可以根据患者的实际情况进行个性化的治疗和支持。这种综合性的关怀可以改善患者的生活质量，降低并发症风险，并提高康复成功的机会。

(5) 加强医疗团队协作

医院应当鼓励多学科团队的会诊，包括医生、护士、康复师、心理医生等。在患者的治疗计划中，每位专业人员都可以提供独特的专业知识和洞察力。并且需要确保医疗团队之间有明确的沟通渠道，以便及时分享信息和决策。使用电子病历系统或协作平台，以便所有团队成员可以轻松访问患者的信息。同时应当定期召开团队会议，讨论患者的进展和治疗计划。这有助于协调各种治疗措施，确保它们相互协调。医院也应当为医疗团队成员提供培训和教育机会，以确保医疗团队成员了解最新的脑卒中治疗和康复方法。不断更新知识可以提高治疗质量。

五、方法评价

5.1 优点

(1) 本研究充分应用了时间序列模型、梯度提升模型、随机森林模型、特征工程、高斯模型、最小角回归模型、critic 权重法、支持向量回归模型和数据处理等多个模型，有助于更好地解决了血肿扩张风险相关问题，展现了多领域的建模能力。

(2) 通过正确的数据处理方法，本研究成功找出了变量之间的关系，解决了复杂数据难以量化的问题，有助于提高模型的准确性。

(3) 针对出血性脑卒中患者的预后诊疗提供了科学的建议。

5.2 缺点

(1) 该方法的立足数据量较少,在别的实际情况之中的应用可能存在偏差。

(2) 对各种疾病影响因素之间的理解较为理想化。

(3) 个别模型中随机因素较多，使得模型不能非常准确将其反映出来。

参考文献

- [1]. 龙晓东,刘之彝,杨与敏等.345 例青年出血性脑卒中发病原因、临床特征及预后分析[J].中国医学前沿杂志(电子版),2017,9(04):36-39.
- [2]. 柴宗举,孙红卫,亓自强等.出血性脑卒中术后患者近期预后及其死亡风险方程[J].实用医学杂志,2012,28(07):1091-1094.
- [3]. 郑琳静,李海云,马晶晶等.4212 例出血性脑卒中病例流行特征及近期预后影响因素分析[J].华南预防医学,2022,48(09):1158-1160.
- [4]. 张丽娜,李国春,周学平等.急性出血性脑卒中早期预后的影响因素[J].南京医科大学学报(自然科学版),2015,35(04):552-556.
- [5]. 宇传华,罗丽莎,李梅等.从全球视角看中国脑卒中疾病负担的严峻性[J].公共卫生与预防医学,2016,27(01):1-5.
- [6]. 甘勇,杨婷婷,刘建新等.国内外脑卒中流行趋势及影响因素研究进展[J].中国预防医学杂志,2019,20(02):139-144.DOI:10.16506/j.1009-6639.2019.02.013.
- [7]. 沈志慧,杨廷琴,吴江等.出血性与缺血性脑卒中发病特征与危险因素的对比分析[J].中国医药指南,2023,21(23):66-68.
- [8]. 脑卒中患者临床神经功能缺损程度评分标准(1995)[J].中华神经科杂志,1996(06):62-64.
- [9]. 张远星,陈璐,季翠玲等.中青年出血性脑卒中患者功能锻炼依从性的影响因素及路径分析[J].护理学报,2022,29(20):6-10.
- [10]. 孙艳,李龙倜,杨宝义.出血性脑卒中患者家属 ICU 后综合征临床分析[J].湖北医药学院学报,2022,41(03):304-307.
- [11]. 王亚楠,吴思缈,刘鸣.中国脑卒中 15 年变化趋势和特点[J].华西医学,2021,36(06):803-807.
- [12]. 赵继宗,周定标,周良辅等.2464 例高血压脑出血外科治疗多中心单盲研究[J].中华医学杂志,2005(32):2238-2242.
- [13]. 刘建平,解瑞谦,程锦泉等.中国居民吸烟、饮酒等行为因素与脑卒中的关系[J].中国行为医学科学,2005(07):613-615.
- [14]. 郭丽花,胡如英,龚巍巍等.脑卒中危险因素研究进展[J].中国老年学杂志,2017,37(17):4413-4416.
- [15]. 张微微,张茁,朱光明等.青年脑卒中 2359 例发病相关因素调查[J].华北国防医药,2003(05):308-310.
- [16]. 王强,韩仲岩.脑血管病危险因素研究进展[J].临床神经病学杂志,1992(01):55-56.
- [17]. 张云云,张海梅,郭德莹等.168 例缺血性脑卒中患者体质特点研究[J].上海中医药杂志,2008(02):31-34.
- [18]. 秦莉花,黄娟,李晟等.脑卒中流行病学及与性激素的相关性[J].中国老年学杂志,2018,38(20):5099-5103.
- [19]. 胡永勤.人口性别和年龄变量对脑卒中发病的影响[J].中国慢性病预防与控制,2012,20(04):485-486.
- [20]. 王伊龙,王拥军,吴敌等.中国卒中防治研究现状[J].中国卒中杂志,2007(01):20-37.
- [21]. 魏陵博. 饮酒与血栓形成的临床与实验研究[D].山东中医药大学,2004.
- [22]. 赵继宗,周定标,周良辅等.2464 例高血压脑出血外科治疗多中心单盲研究[J].中华医学杂志,2005(32):2238-2242.
- [23]. 王薇,赵冬,刘静等.中国 35~64 岁人群血压水平与 10 年心血管病发病危险的前瞻性

- 研究[J].中华内科杂志,2004(10):14-18.
- [24].王薇,赵冬,孙佳艺等.中国正常高值血压人群的心血管病发病危险[J].中华高血压杂志,2007(12):984-987.
- [25].邵桂满,荣阳,孙卓等.急性脑卒中的临床特征与病因分析[J].中国医药导报,2007(36):64-65.
- [26].曾军,洪震,黄茂盛等.脑卒中患者主要危险因素监测[J].中华老年心脑血管病杂志,2002(03):173-175.
- [27].基层心血管病综合管理实践指南 2020[J].中国医学前沿杂志(电子版),2020,12(08):1-73.
- [28].赵连成,武阳丰,周北凡等.体质指数与冠心病、脑卒中发病的前瞻性研究[J].中华心血管病杂志,2002(07):49-52.
- [29].蔡正华,王学建.23 例脑出血致急性梗阻性脑积水行脑室外引流治疗的效果分析[J].实用临床医药杂志,2015,19(09):25-27.
- [30].彭斌.脑出血的治疗进展[J].中国神经免疫学和神经病学杂志,2012,19(03):164-166.
- [31].刘光发,张昌瑞.混合性脑卒中 57 例分析[J].河北医学,2008(04):402-403.
- [32].王薇,赵冬,刘静等.中国 35~64 岁人群血压水平与 10 年心血管病发病危险的前瞻性研究[J].中华内科杂志,2004(10):14-18.
- [33].张周欢,姜火平.小剂量人工冬眠合剂辅助治疗出血性脑卒中 105 例疗效观察[J].临床医学,2003(08):55-56.
- [34].王春燕,沈娟,王艳霞等.影响自发性脑出血患者预后的相关危险因素分析[J].甘肃医药,2022,41(12):1070-1072.
- [35].黄健,帅克刚,陈国志等.神经内镜手术与小骨窗开颅手术治疗老年高血压脑出血的效果及安全性比较[J].神经损伤与功能重建,2020,15(12):745-746.
- [36].李加龙,乔育.手术时间对脑出血患者血肿清除术疗效和术后迟发性脑水肿的影响[J].贵州医药,2019,43(08):1280-1282.
- [37].杨俊,侯自明,王刚等.外伤性颅内出血患者开颅术后并发迟发性脑出血危险因素分析[J].临床军医杂志,2019,47(04):434-435.
- [38].万彦青,张悦华,张宇等.高血压脑出血血肿清除术后应用银杏叶提取物对预后的影响[J].河南大学学报(医学版),2019,38(01):34-36.
- [39].刘潇潇,沈腾群,张金彪等.老年急性缺血性脑卒中患者脑微出血严重程度的影响因素研究[J].中华老年心脑血管病杂志,2022,24(06):614-617.
- [40].翁梅玲,林婕,罗金燕.多样化护理干预对老年糖尿病合并脑出血患者术后康复的影响[J].糖尿病新世界,2023,26(13):121-124.
- [41].汪蓉,郑春美,武桂林等.基层医院房颤患者抗凝治疗现状调查研究[J].中国卫生标准管理,2023,14(13):84-88.
- [42].王景华,宁宪嘉,杨露春.天津地区脑出血危险因素的多元回归分析——96 对配比病例对照研究[J].中国慢性病预防与控制,1993(03):116-118+144.
- [43].徐卫历,耿贯一,汪培山等.饮酒与脑出血的关系[J].中国公共卫生,1998(12):11-12.
- [44].王飞,黄婷婷,刘亚辉等.高血压患者首发脑出血事件的高危因素分析[J].医药论坛杂志,2020,41(03):19-21+26.
- [45].王慧.交互作用分析与I型错误控制中的若干问题[D].山西医科大学,2020.
- [46].王跃华,李晓潇,张万金等.脑出血的治疗、预防和护理[J].人人健康,2023(03):43.

附录一 代码

SVR 模型

```
import pandas as pd
from sklearn.svm import SVR
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, mean_absolute_error

# 1. 读取训练数据
train_data = pd.read_excel(r"C:\Users\DELL\Desktop\lynn3b.xlsx")
train_data = train_data.dropna(axis=1)

# 2. 提取特征和标签
X_train = train_data.drop(columns=['90 天 mRS'])
y_train = train_data['90 天 mRS']

# 3. 数据标准化
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)

# 4. 创建 SVR 模型
model = SVR(kernel='linear') # 选择线性核函数，也可以根据需求选择其他核函数

# 5. 训练模型
model.fit(X_train, y_train)

# 6. 读取新数据
new_data1 = pd.read_excel(r"C:\Users\DELL\Desktop\cs2.xlsx") # 替换为您的新数据文件路径

# 8. 提取新数据的特征
X_new = new_data1.drop(columns=['90 天 mRS'])
X_new = scaler.transform(new_data1)
y_new_pred = model.predict(X_new)
new_data1['预测结果'] = y_new_pred
new_data1.to_excel("new3b 新数据带预测结果.xlsx", index=False) # 替换为输出文件的路径

from l12 import model
import pandas as pd

test_data = pd.read_excel(r"C:\Users\DELL\Desktop\cs2.xlsx")
y_pred = model.predict(test_data)
test_data['预测结果'] = y_pred
```

```

# 保存包含预测结果的 DataFrame 到 Excel 文件
test_data.to_excel("cs2.xlsx", index=False)
RNN 模型

import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error
import keras
from keras.models import Sequential
from keras.layers import LSTM, Dense

# 1. 读取数据
data = pd.read_excel(r"C:\Users\DELL\Desktop\lyn3b.xlsx")

# 2. 数据预处理
# 移除空缺的数据列
data = data.dropna(axis=1)

# 提取输入特征和输出标签
X = data.drop(columns=['90 天 mRS'])
y = data['90 天 mRS']

# 3. 数据划分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
print(y_train.isnull().sum()) # 检查 NaN 值的数量
print(np.isinf(y_train).sum()) # 检查无穷大值的数量

# 4. 特征标准化
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# 5. 构建 RNN 模型
model = Sequential()
model.add(LSTM(units=50, activation='relu', input_shape=(X_train.shape[1], 1)))
model.add(Dense(units=1))

# 编译模型
model.compile(optimizer='adam', loss='mean_squared_error')

# 6. 训练模型
model.fit(X_train, y_train, epochs=50, batch_size=32)

```

7. 用训练好的模型进行预测

```
y_train_pred = model.predict(X_train)
```

```
y_test_pred = model.predict(X_test)
```

8. 保存预测结果到 Excel

```
train_results = pd.DataFrame({'Actual': y_train, 'Predicted': y_train_pred.flatten()})
```

```
test_results = pd.DataFrame({'Actual': y_test, 'Predicted': y_test_pred.flatten()})
```

```
train_results.to_excel('train_predictions.xlsx', index=False)
```

```
test_results.to_excel('test_predictions.xlsx', index=False)
```

9. 计算性能指标

```
train_mse = mean_squared_error(y_train, y_train_pred)
```

```
train_mae = mean_absolute_error(y_train, y_train_pred)
```

```
test_mse = mean_squared_error(y_test, y_test_pred)
```

```
test_mae = mean_absolute_error(y_test, y_test_pred)
```

```
print(f'Train MSE: {train_mse}, Train MAE: {train_mae}')
```

```
print(f'Test MSE: {test_mse}, Test MAE: {test_mae}')
```

合并

```
import pandas as pd
```

从 Excel 文件加载数据

```
df1 = pd.read_excel(r"C:\Users\DELL\Desktop\31.xlsx")
```

```
df2 = pd.read_excel(r"C:\Users\DELL\Desktop\34.xlsx")
```

根据共同的列合并数据，假设你要根据列名为 '共同列名' 的列进行合并

```
merged_df = pd.merge(df1, df2, on='LS', how='left')
```

将合并后的数据保存到新的 Excel 文件

```
merged_df.to_excel("血 8.xlsx", index=False)
```

归一

```
import pandas as pd
```

```
from sklearn.preprocessing import MinMaxScaler
```

从 xlsx 文件中加载数据

```
file_path = "新.xlsx"
```

```
data = pd.read_excel(file_path)
```

初始化 MinMaxScaler 对象

```
scaler = MinMaxScaler()
```

```

# 获取所有的列名
columns = data.columns

# 归一化处理每一列数据
normalized_data = scaler.fit_transform(data)

# 创建一个新的 DataFrame 来保存归一化后的数据
normalized_df = pd.DataFrame(normalized_data, columns=columns)

# 将归一化后的数据更新到原始的 DataFrame 中
data.update(normalized_df)

# 保存更新后的数据到 Excel 文件
data.to_excel(file_path, index=False)

拆分
import pandas as pd

# 从 Excel 文件加载数据
df = pd.read_excel(r"C:\Users\DELL\Desktop\3bnew.xlsx")

# 将血压数据列拆分成两列
df[['高血压', '低血压']] = df['血压'].str.split('/', expand=True)

# 删除原始的血压列
df.drop(columns=['血压'], inplace=True)

# 保存处理后的数据到新的 Excel 文件
df.to_excel(r"C:\Users\DELL\Desktop\3bnew.xlsx", index=False)

随机森林
import pandas as pd
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error

# 1. 从 xlsx 文件中加载训练集数据
train_data = pd.read_excel(r"C:\Users\DELL\Desktop\gy3a.xlsx")

# 2. 划分特征和目标变量
X_train = train_data.drop(columns=['90 天 mRS']) # 特征
y_train = train_data['90 天 mRS'] # 目标变量

# 3. 创建和训练 Random Forest 回归模型
rf_regressor = RandomForestRegressor(n_estimators=100, random_state=42) # 可以调整参数

```

```

rf_regressor.fit(X_train, y_train)

# 4. 加载测试集数据 1 和测试集数据 2
test_data1 = pd.read_excel(r"C:\Users\DELL\Desktop\CS1.xlsx")
test_data2 = pd.read_excel(r"C:\Users\DELL\Desktop\CS2.xlsx")

# 5. 使用训练好的模型进行预测
predictions1 = rf_regressor.predict(test_data1) # 预测 90 天后 mRS 评分
predictions2 = rf_regressor.predict(test_data2)

# 5. 使用训练好的模型进行预测
predictions1 = rf_regressor.predict(test_data1) # 预测 90 天后 mRS 评分
predictions2 = rf_regressor.predict(test_data2)

# 6. 输出测试集和训练集全部的 90 天后 mRS 评分
train_predictions = rf_regressor.predict(X_train)
print("训练集 90 天后 mRS 评分:")
print(train_predictions)
print("\n 测试集 1 90 天后 mRS 评分:")
print(predictions1)
print("\n 测试集 2 90 天后 mRS 评分:")
print(predictions2)

# 7. 将所有结果合并到一个 DataFrame 中
results = pd.DataFrame({'训练集 90 天后 mRS 评分': train_predictions,})

# 8. 保存结果到 Excel 文件
results.to_excel('随机森林训练集 mRS 评分结果.xlsx', index=False)
# 7. 将所有结果合并到一个 DataFrame 中
results1 = pd.DataFrame({'测试集 1 90 天后 mRS 评分': predictions1,
                        '测试集 2 90 天后 mRS 评分': predictions2})

# 8. 保存结果到 Excel 文件
results1.to_excel('随机森林测试集 mRS 评分结果.xlsx', index=False)

```

决策树

```

import pandas as pd
from sklearn.tree import DecisionTreeRegressor
from sklearn.metrics import mean_squared_error
from math import sqrt

# 1. 从 xlsx 文件中加载训练集数据
train_data = pd.read_excel(r"C:\Users\DELL\Desktop\gy3a.xlsx")
test_data1 = pd.read_excel(r"C:\Users\DELL\Desktop\CS1.xlsx")

```

```

test_data2 = pd.read_excel(r"C:\Users\DELL\Desktop\CS2.xlsx")

# 2. 划分特征和标签
X_train = train_data.drop(columns=['90 天 mRS']) # 特征
y_train = train_data['90 天 mRS'] # 标签

# 3. 创建和训练决策树回归模型
decision_tree = DecisionTreeRegressor(max_depth=5, ccp_alpha=0.01, random_state=42)
decision_tree.fit(X_train, y_train)

# 4. 使用训练好的模型进行预测
predictions1 = decision_tree.predict(test_data1)
predictions2 = decision_tree.predict(test_data2)

# 5. 将预测结果四舍五入到整数
rounded_predictions1 = [round(pred) for pred in predictions1]
rounded_predictions2 = [round(pred) for pred in predictions2]

# 6. 输出测试集和训练集全部的 90 天后 mRS 评分
train_predictions = decision_tree.predict(X_train)
rounded_predictions3 = [round(pred) for pred in train_predictions]
# 7. 创建包含预测结果的 DataFrame
test_data1['预测 mRS 评分'] = rounded_predictions1
test_data2['预测 mRS 评分'] = rounded_predictions2
train_data['预测 mRS 评分'] = rounded_predictions3

# 8. 合并测试集和训练集
merged_data = pd.concat([test_data1, test_data2])
results = pd.DataFrame({'训练集 90 天后 mRS 评分': train_predictions})

# 9. 保存结果到 Excel 文件
merged_data.to_excel("决策树 mrs 测试集.xlsx", index=False)
results.to_excel('决策树训练集 mRS 评分结果.xlsx', index=False)

```

预测概率

```

import pandas as pd
from sklearn.ensemble import GradientBoostingClassifier
from sklearn.metrics import accuracy_score, classification_report

```

```

# 1. 从 xlsx 文件中加载训练集数据
train_data = pd.read_excel(r"C:\Users\DELL\Desktop\gy1b.xlsx")

```

```

# 2. 划分特征和标签
X_train = train_data.drop(columns=['血肿扩张']) # 特征

```

```

y_train = train_data['血肿扩张'] # 标签

# 3. 创建和训练 Gradient Boosting 分类器
gb_classifier = GradientBoostingClassifier(n_estimators=100, random_state=42) # 可以调整参数
gb_classifier.fit(X_train, y_train)

# 4. 加载测试集数据 1 和测试集数据 2
test_data1 = pd.read_excel(r"C:\Users\DELL\Desktop\CS1.xlsx")
test_data2 = pd.read_excel(r"C:\Users\DELL\Desktop\CS2.xlsx")

# 5. 使用训练好的模型进行预测
predictions1 = gb_classifier.predict_proba(test_data1)[:, 1] # 预测概率
predictions2 = gb_classifier.predict_proba(test_data2)[:, 1]

# 6. 打印或保存预测结果
print("测试集 1 预测结果:")
print(predictions1)
print("\n 测试集 2 预测结果:")
print(predictions2)

# 7. 输出训练集全部概率
train_predictions = gb_classifier.predict_proba(X_train)[:, 1]
train_data['血肿概率'] = train_predictions
train_data.to_excel('train_data_with_predictions.xlsx', index=False)

result_df = pd.DataFrame({'测试集 1 预测结果': predictions1, '测试集 2 预测结果': predictions2})
result_df.to_excel('predictions.xlsx', index=False)

时间戳
import pandas as pd

# 读取包含中文字段的 XLSX 文档
xlsx_file = (r"C:\Users\DELL\Desktop\q1.xlsx") # 替换成您的输入文件路径
sheet_name = 'Sheet1' # 替换成您的工作表名称

# 读取 XLSX 文件并指定编码方式（根据文档编码方式可能需要更改）
df = pd.read_excel(xlsx_file, sheet_name=sheet_name, engine='openpyxl')

# 指定要转换的时间列名
time_column_name = '随访 3 时间点' # 替换成您的时间列名

# 指定参考时间列名

```

```

reference_time_column_name = '入院首次检查时间点' # 替换成您的参考时间列名

# 将时间列从字符串转换为 datetime 对象
df[time_column_name] = pd.to_datetime(df[time_column_name],
format='%Y/%m/%d %H:%M:%S')
df[reference_time_column_name] = pd.to_datetime(df[reference_time_column_name],
format='%Y/%m/%d %H:%M:%S')

# 计算时间差并将结果以小时表示
df[time_column_name] = (df[time_column_name] -
df[reference_time_column_name]).dt.total_seconds() / 3600

# 保存结果覆盖原文件
df.to_excel(xlsx_file, sheet_name=sheet_name, index=False, engine='openpyxl')

import pandas as pd

# 读取包含中文字段的 XLSX 文档
xlsx_file = (r"C:\Users\DELL\Desktop\q1.xlsx") # 替换成您的文件路径
sheet_name = 'Sheet1' # 替换成您的工作表名称

# 读取 XLSX 文件并指定编码方式（根据文档编码方式可能需要更改）
df = pd.read_excel(xlsx_file, sheet_name=sheet_name, engine='openpyxl')

# 指定要筛选的中文列名
chinese_column_name = '绝对变化 1' # 替换成您的中文列名

# 使用条件筛选数据
filtered_df = df[df[chinese_column_name] >= 6]

# 提取满足条件的 ID 列（假设 ID 列名为'ID'）
id_column_name = 'name' # 替换成您的 ID 列名
result_ids = filtered_df[id_column_name]

result_df = pd.DataFrame({id_column_name: result_ids})

# 将结果导出到新的 Excel 文件
output_file = (r"C:\Users\DELL\Desktop\1a.xlsx") # 替换成您的输出文件路径
result_df.to_excel(output_file, index=False, engine='openpyxl')

```

2a 散点图

%读取相对时间数据

```

xz=[0.10    0.34    5.50    10.82    17.73    17.73    17.73    17.73    17.73
0.13    0.62    2.88    18.67    46.63    46.63    46.63    46.63    46.63

```



```

.....
0.13    0.74    1.77    1.77    1.77    1.77    1.77    1.77    1.77
0.02    1.45    8.22    8.22    8.22    8.22    8.22    8.22    8.22 ];
%读取水肿体积数据
yz=[48919.00 57898.00 81747.00 107793.00    126558.00    126558.00    126558.00
    126558.00    126558.00
23526.00 23390.00 28415.00 34868.00 0.00 0.00 0.00 0.00 0.00
32621.00 41292.00 49767.00 49767.00 49767.00 49767.00 49767.00 49767.00 49767.00
.....
9653.00 19517.00 30933.00 30933.00 30933.00 30933.00 30933.00 30933.00 30933.00
7367.00 6033.00 3191.00 3191.00 3191.00 3191.00 3191.00 3191.00 3191.00];
coeffs = cell(100, 1);
for i = 1:100
    coeffs{i} = polyfit(xz(i, :), yz(i, :), 2); % 拟合 3 次多项式函数
end

% 计算拟合的函数值
fitted_values = zeros(100, 9);
for i = 1:100
    fitted_values(i, :) = polyval(coeffs{i}, xz(i, :));
end

% 绘制结果
figure
for i = 1:100
    plot(xz(i, :), yz(i, :), 'o')
    hold on
    plot(xz(i, :), fitted_values(i, :), 'r-')
    hold on
    grid on
end

2a 代码
function [fitresult, gof] = createFit2(xz, yz)
[xData, yData] = prepareCurveData( xz, yz );

% Set up fittype and options.
ft = fittype( 'poly4' );

% Fit model to data.
[fitresult, gof] = fit( xData, yData, ft );

% Plot fit with data.
figure( 'Name', 'f(x)' );

```

```

h = plot( fitresult, xData, yData );
legend( h, '水肿体积 vs. 时间', 'f(x)', 'Location', 'NorthEast', 'Interpreter', 'none' );
% Label axes
xlabel( 'xz', 'Interpreter', 'none' );
ylabel( 'yz', 'Interpreter', 'none' );
grid on

```

2b 代码

%类别一函数拟合代码

```

function [fitresult, gof] = createFits3(xz1, yz1)
% Initialize arrays to store fits and goodness-of-fit.
fitresult = cell( 2, 1 );
gof = struct( 'sse', cell( 2, 1 ), ...
    'rsquare', [], 'dfe', [], 'adjrsquare', [], 'rmse', [] );
[xData, yData] = prepareCurveData( xz1, yz1 );
% Set up fitype and options.
ft = fitype( 'poly3' );
% Fit model to data.
[fitresult{2}, gof(2)] = fit( xData, yData, ft );
% Plot fit with data.
figure( 'Name', 'untitled fit 9' );
h = plot( fitresult{2}, xData, yData );
legend( h, 'yz1 vs. xz1', 'untitled fit 9', 'Location', 'NorthEast', 'Interpreter', 'none' );
% Label axes
xlabel( 'xz1', 'Interpreter', 'none' );
ylabel( 'yz1', 'Interpreter', 'none' );
grid on

```

%类别二函数拟合代码吗

```

function [fitresult, gof] = createFits3(xz2, yz2)
% Initialize arrays to store fits and goodness-of-fit.
fitresult = cell( 2, 1 );
gof = struct( 'sse', cell( 2, 1 ), ...
    'rsquare', [], 'dfe', [], 'adjrsquare', [], 'rmse', [] );
[xData, yData] = prepareCurveData( xz2, yz2 );
% Set up fitype and options.
ft = fitype( 'gauss3' );
opts = fitoptions( 'Method', 'NonlinearLeastSquares' );
opts.Display = 'Off';
opts.Lower = [-Inf -Inf 0 -Inf -Inf 0 -Inf -Inf 0];
opts.StartPoint = [97503 1 1.17189742479613 82603 16.96 2.44248073706095
81744.4367797535 5.07 2.77251897583241];
% Fit model to data.
[fitresult{2}, gof(2)] = fit( xData, yData, ft, opts );

```

```
% Plot fit with data.
figure( 'Name', 'untitled fit 9' );
h = plot( fitresult{2}, xData, yData );
legend( h, 'yz2 vs. xz2', 'untitled fit 9', 'Location', 'NorthEast', 'Interpreter', 'none' );
% Label axes
xlabel( 'xz2', 'Interpreter', 'none' );
ylabel( 'yz2', 'Interpreter', 'none' );
grid on
```

%类别三函数拟合代码吗

```
function [fitresult, gof] = createFits3(xz3, yz3)
% Initialize arrays to store fits and goodness-of-fit.
fitresult = cell( 2, 1 );
gof = struct( 'sse', cell( 2, 1 ), ...
    'rsquare', [], 'dfe', [], 'adjrsquare', [], 'rmse', [] );
[xData, yData] = prepareCurveData( xz3, yz3 );
% Set up fittype and options.
ft = fittype( 'poly4' );
% Fit model to data.
[fitresult{2}, gof(2)] = fit( xData, yData, ft );
% Plot fit with data.
figure( 'Name', 'untitled fit 9' );
h = plot( fitresult{2}, xData, yData );
legend( h, 'yz3 vs. xz3', 'untitled fit 9', 'Location', 'NorthEast', 'Interpreter', 'none' );
% Label axes
xlabel( 'xz3', 'Interpreter', 'none' );
ylabel( 'yz3', 'Interpreter', 'none' );
grid on
```

%类别四函数拟合代码吗

```
function [fitresult, gof] = createFits3(xz4, yz4)
% Initialize arrays to store fits and goodness-of-fit.
fitresult = cell( 2, 1 );
gof = struct( 'sse', cell( 2, 1 ), ...
    'rsquare', [], 'dfe', [], 'adjrsquare', [], 'rmse', [] );
[xData, yData] = prepareCurveData( xz4, yz4 );
% Set up fittype and options.
ft = fittype( 'gauss5' );
opts = fitoptions( 'Method', 'NonlinearLeastSquares' );
opts.Display = 'Off';
opts.Lower = [-Inf -Inf 0 -Inf -Inf 0 -Inf -Inf 0 -Inf -Inf 0];
opts.StartPoint = [34868 18.67 1.24001904692152 28415 2.88 0.536575285168034
27744.999999785 12.37 1.20206883112403 27337.2115246029 1.81 0.559450814635714
23522.6854371052 0.13 0.808051596275741];
```

```

% Fit model to data.
[fitresult{2}, gof(2)] = fit( xData, yData, ft, opts );
% Plot fit with data.
figure( 'Name', 'untitled fit 9' );
h = plot( fitresult{2}, xData, yData );
legend( h, 'yz4 vs. xz4', 'untitled fit 9', 'Location', 'NorthEast', 'Interpreter', 'none' );
% Label axes
xlabel( 'xz4', 'Interpreter', 'none' );
ylabel( 'yz4', 'Interpreter', 'none' );
grid on

```

附录二 答案文件

	问题 1: 血肿扩张			问题 2: 水肿体积 进展曲线			问题 3: 预后预测 建模	
首次影像 检查流水 号	是否发生 血肿扩张	血肿扩张 时间	血肿扩张 预测概率	残差（全 体）	残差（亚 组）	所属亚组	预测 mRS（基 于首次影 像）	预测 mRS
	1 是, 0 否	单位: 小 时						
20161212 002136	0		0.0042	92770.23	5906.38	第一组	4	3
20160406 002131	0		0.0098	-609601. 36	55873.69	第四组	1	0
20160413 000006	1	9.52	0.9543	32075.73	26351.33	第三组	4	4
20161215 001667	0		0.0162	-2131.30	9231.07	第四组	4	4
20161222 000978	1	26.47	0.9825	23288.11	16999.20	第二组	3	0
20161110 001074	0		0.0159	72742.94	47314.00	第二组	5	5
20161208 000139	0		0.0050	-33604.3 7	52761.72	第三组	2	2
20161219 000091	0		0.0051	24787.02	27011.19	第二组	4	3
20161031 001987	1	40.06	0.9536	25606.42	17852.90	第三组	3	2
20161012 002008	0		0.0169	-390487. 43	34562.43	第四组	3	2
20160209 000219	0		0.0132	-55664.8 7	3536.34	第四组	1	1
20161031 001142	0		0.0038	-570219. 62	48498.87	第二组	1	1
20161124 000397	0		0.0068	-334262. 41	37664.28	第四组	1	1
20160513 001799	0		0.0143	-4430.74	17056.45	第二组	2	3
20161013 001234	0		0.0073	-201567. 33	70774.61	第三组	2	2
20161130 000004	0		0.0044	45314.08	43098.30	第一组	4	5

20160510 002436	1	14.87	0.9836	-79942.1 5	36871.73	第二组	2	3
20160602 001707	0		0.0040	23359.09	36682.33	第三组	1	0
20160117 000135	0		0.0032	-1501005 .95	71582.15	第四组	2	1
20160723 000013	0		0.0033	-1539934 .16	58409.23	第四组	2	2
20160317 001244	0		0.0050	-19112.4 4	17211.10	第二组	3	2
20160803 001239	0		0.0270	-50814.0 6	8563.06	第四组	2	2
20160321 000142	0		0.0086	-839790. 68	81988.29	第二组	2	1
20170802 000637	0		0.0102	-117409. 85	17641.85	第四组	2	3
20171226 002293	0		0.0062	13175.89	5581.94	第二组	2	2
20171008 000512	0		0.0083	-58079.6 2	39773.53	第三组	3	3
20170206 000071	0		0.0092	-1782.77	22998.01	第二组	5	4
20171013 002097	0		0.0082	-856946. 26	76507.47	第二组	3	4
20170607 000010	0		0.0030	-640998. 29	78476.22	第二组	4	4
20171025 000480	0		0.0199	78941.01	-31515.9 0	第一组	4	5
20170307 002130	0		0.0107	19239.05	15799.73	第三组	4	4
20171009 000137	0		0.0073	-7801.01	-4300.15	第四组	1	0
20170115 000362	1	30.81	0.9601	-301860. 07	30891.30	第四组	4	3
20170119 000729	0		0.0037	-2879.16	50763.58	第一组	3	4
20171014 001244	0		0.0180	-151110. 19	33314.92	第四组	5	5
20170204 001714	1	39.5	0.9567	-33567.2 7	25894.39	第二组	3	3
20170426 000005	0		0.0221	-560303. 86	74708.44	第二组	3	3
20170518 002194	1	15.81	0.9637	-104205. 91	34442.71	第二组	2	2

20170425 002487	1	29.18	0.9740	-310055. 64	83356.74	第三组	1	1
20170902 000876	0		0.0285	-139914. 61	56293.03	第三组	1	1
20171002 000282	0		0.0188	-151088. 17	17945.50	第四组	3	3
20170420 000636	0		0.0059	-334075. 38	35029.40	第四组	1	1
20170325 000428	0		0.0061	16542.55	16902.06	第二组	5	5
20170528 000084	0		0.0129	-5890242 .69	144474.4 3	第二组	3	3
20170324 001892	0		0.0046	-67997.5 7	31573.85	第二组	1	1
20170511 000016	0		0.0081	-100097. 88	58228.67	第三组	3	2
20171019 001652	0		0.0070	-491693. 04	32699.31	第四组	1	2
20170402 000556	1	12.86	0.9427	19391.49	31563.92	第三组	3	3
20171005 000770	0		0.0099	-20624.6 7	1902.72	第四组	1	1
20171105 000372	0		0.0155	-24165.7 5	14376.57	第二组	2	1
20170422 000935	0		0.0019	-852287. 53	64310.98	第四组	1	2
20170608 001310	0		0.0056	-1006610 3.20	204029.8 1	第二组	3	4
20170511 001392	0		0.0065	-308616. 40	49517.12	第二组	2	2
20170612 002216	1	16.23	0.9838	-54557.7 7	25843.52	第二组	2	2
20170316 001977	0		0.0058	27461.00	25330.82	第三组	4	4
20170120 000152	0		0.0216	-40802.4 5	24879.41	第二组	2	1
20170825 001844	1	14.62	0.9864	-40093.9 3	7771.18	第四组	3	3
20170125 000984	0		0.0070	10803.22	3046.72	第二组	5	5
20170912 002314	0		0.0032	-20882.3 5	-727.22	第四组	1	1
20180109 000613	1	23.73	0.9491	-14223.3 8	40584.54	第二组	4	4

20180226 000725	1	6.54	0.9705	14564.06	60787.79	第一组	4	4
20181221 002264	0		0.0042	1889.63	8003.02	第二组	2	3
20181020 001229	0		0.0044	-521216. 13	84667.33	第三组	2	2
20180801 000501	0		0.0046	-482521. 84	35561.44	第四组	3	3
20180131 001727	0		0.0047	-86127.6 8	53561.98	第三组	3	3
20181208 000909	0		0.0114	10186.33	22431.68	第二组	5	5
20181207 001317	0		0.0055	1217.77	-2294.19	第四组	2	2
20180412 001426	0		0.0123	-1057133 8.69	209731.0 2	第二组	2	2
20180619 001505	0		0.0153	-110116. 20	46583.51	第二组	5	4
20180427 000292	1	9.65	0.9641	-34204.2 3	9786.14	第四组	3	3
20181103 001264	0		0.0092	-296556. 75	54500.91	第二组	2	1
20181007 000826	0		0.0034	1074.49	8393.91	第二组	4	4
20180911 001645	0		0.0085	-1840.08	-2512.79	第四组	1	1
20180719 000020	0		0.0076	-98350.8 7	69523.69	第三组	1	1
20180428 001767	0		0.0070	-357754. 46	44644.15	第二组	3	3
20180619 002401	1	15.99	0.9618	-43897.9 4	14430.66	第四组	4	5
20180503 002304	1	14.12	0.9785	-124981. 31	41465.84	第三组	5	6
20180929 000040	0		0.0145	-13064.9 5	-3411.60	第四组	1	0
20180929 000037	1	27.85	0.9807	-634873. 88	41093.92	第四组	1	1
20180130 001917	1	20.57	0.9500	-25769.5 0	8606.18	第四组	2	3
20180120 000249	1	27.42	0.9752	-9420653 .65	152598.4 1	第三组	3	4
20180221 000793	0		0.0052	16373.64	24501.14	第二组	2	2

20181004 000706	0		0.0158	32783.24	28268.26	第三组	4	4
20180716 000006	0		0.0104	13259.01	13451.58	第三组	1	1
20181127 002511	0		0.0265	4658.73	40909.44	第二组	3	3
20180108 000002	0		0.0181	-49705.2 1	7047.86	第四组	1	2
20180216 000198	0		0.0344	-3840046 .09	93273.74	第四组	2	3
20180521 000314	0		0.0020	18553.16	12619.95	第二组	2	3
20180314 002318	0		0.0056	-134642. 92	44723.46	第二组	2	2
20180910 002366	0		0.0060	11758.41	29911.66	第二组	4	4
20181019 001130	0		0.0153	-96473.3 5	17795.74	第四组	2	3
20181116 001089	1	11.92	0.9785	14541.46	15915.62	第三组	4	5
20181214 000208	0		0.0054	-17664.9 9	-962.61	第四组	2	2
20180412 001795	0		0.0072	-9505989 .56	139207.3 5	第四组	4	3
20180316 001329	1	7.43	0.9604	110286.0 2	-46337.9 2	第一组	3	4
20180802 001789	0		0.0056	-169925. 32	23746.10	第四组	3	3
20181010 000767	0		0.0038	-3486.00	-119.50	第四组	2	3
20180612 002507	1	42.76	0.9811	-448137. 88	66112.26	第二组	5	5
20180620 002296	1	17.67	0.9601	12361.08	5784.17	第二组	3	3
20180314 000010	0		0.0030	-9144.81	37.31	第四组	2	2
20180311 000432			0.7593				3	
20180708 000024			0.0194				2	
20181015 001677			0.6537				2	
20190105 000694			0.0093				2	

20190108 002459			0.3753				2	
20190519 000853			0.0984				4	
20190526 000209			0.0074				2	
20190701 002502			0.1250				2	
20190716 000013			0.2870				3	
20190717 001385			0.1716				2	
20190727 000556			0.1014				4	
20190803 000014			0.3012				2	
20190901 000442			0.0135				3	
20190903 000373			0.0208				4	
20190904 002299			0.0824				4	
20190906 001283			0.0126				2	
20190917 002094			0.0118				2	
20190923 002580			0.3288				3	
20191003 000352			0.1886				2	
20191004 001025			0.2485				2	
20191027 000468			0.0200				2	
20191028 002738			0.0150				2	
20191024 001280			0.0067				2	
20191030 001526			0.7945				2	
20191111 002510			0.5622				2	
20191126 002590			0.0347				2	

20191127 002176			0.2664				2	
20191208 000592			0.0850				2	
20191224 000008			0.0519				3	
20191228 000237			0.2822				4	
20160413 000006			0.9543				4	5
20161215 001667			0.0162				4	2
20200112 000228			0.0561				2	1
20200101 000392			0.0930				2	2
20201130 003288			0.1855				3	2
20201203 002778			0.0145				2	1
20201217 002368			0.3701				2	4
20200403 000012			0.1433				2	2
20200814 000015			0.0389				3	0
20200412 000331			0.2038				2	3
20200711 001264			0.0060				3	1
20200411 000014			0.0099				4	1
20200214 000572			0.0881				2	3
20200124 000041			0.5878				3	5
20200613 001086			0.0347				2	3
20200531 000253			0.0125				2	1
20201220 000155			0.2847				2	3
20200609 001016			0.7254				2	5

20200409 001101			0.0085				3	2
20200118 000372			0.1607				2	2
20201023 001238			0.5893				3	3
20201109 000009			0.0493				4	1
20201212 001420			0.0632				4	2
20201129 000299			0.1823				2	2
20200301 000025			0.1479				3	3
20200306 000927			0.2344				3	3
20201009 003102			0.3138				2	4
20200410 001952			0.0399				3	2
20200218 000582			0.1730				4	3
20200821 002584			0.0081				3	2