



中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

学 校 南昌大学

参赛队号 23104030073

1.于梓涵

队员姓名 2.陈昊

3.周滢

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

题 目： 出血性脑卒中临床智能诊疗建模分析

摘 要：

出血性脑卒中是一种急性脑血管疾病，主要由创伤性和自发性两种因素导致的脑部局部血管破裂造成脑部机械性损伤，常伴随引发一系列复杂的生理病理反应。我国脑卒中疾病负担仍然沉重，其防治虽然取得了一定进展，但仍面临诸多挑战。本文通过整合真实临床患者的影像学特征、患者临床信息及临床诊疗方案等数据，针对出血性脑卒中进行了一系列的**预测和统计分析**。

本文针对患者的个人史、疾病史、治疗历史以及首次+随访的影像信息进行了合理的量化分析，进行了缺失值和异常值的处理。也通过给出的数据集对患者是否发生**血肿扩张**以及**90天的mRS评分**进行了预测，且分析了**血肿体积、水肿体积和治疗方案**三种之间的关系，并构建了相应的数学模型。本文综合利用了**CNN卷积神经网络、灰色关联度分析、主成分分析、K-means三维聚类算法、BP神经网络、斯皮尔曼相关性分析**等方法进行了研究和预测。

针对问题一(a)：判断48小时内是否发生血肿扩张事件，根据题目所给的判断血肿体积前后变化方法来对原有数据进行**归一化、标准化**处理，去除了一些异常值，最终通过题中所给血肿扩张条件进行判断得到前100位患者是否发生血肿扩张。针对问题一(b)，对特征数据进行分类，使用**灰色关联分析**来获得与是否发生**血肿扩张最具关联性的十五个特征数据**，使用**CNN卷积神经网络**根据阈值进行二分类预测，最终得到所有患者是否发生血肿扩张的概率。并利用**RMSE和MAE**进行模型评价指标，关于血肿扩张的发生以及血肿扩张概率的最终结果为答案表中的列C、列D和列E中。

针对问题二(a)，将数据预处理后的水肿体积和时间点进行了曲线拟合，拟合出了一条较为准确的曲线，用拟合曲线分别对前100个患者按照拟合优度计算**残差评价值**。针对问

题二(b), 将血压分为收缩压和舒张压, 使用 **PCA 主成分分析**来对已有特征进行降维, 最终选定按照**年龄和收缩压、舒张压**作为特征变量, 使用 **K-means 三维聚类**将 160 个患者分为 5 类, 并对前 100 个患者按照所述类别分别进行曲线拟合, 最终得到 5 条拟合较好的曲线。针对问题二(c), 按照单位时间水肿体积变化, 使用**多元线性回归**分析不同治疗方法对水肿进展模式的影响, 并进行了如 **R²检测、SSE** 等多个评价指标对拟合模型进行评价, 得到了较好的评价结果。针对问题二(d), 将单位时间血肿体积变化、单位时间水肿体积变化与治疗方法按照**斯皮尔曼相关系数**分析, 通过**热力图**对三者之间的联系做了较为清晰的比较。最终答案记录在答案表列 F、列 G 和列 H 中。

针对问题三(a), 使用灰色关联分析来选取与前 100 个患者 90 天 mRS 评分最相关的十五个特征变量, 使用 **BP 神经网络**, 按照阈值范围进行分类, 并预测前 160 个患者的 90 天 mRS 评分。针对问题三(b), 将单位时间血肿总体积及各个区域体积变化、单位时间水肿总体积及各个区域体积变化作为首次+随访影像的综合特征变量, 与患者其他特征变量进行整合, 最终通过灰色关联分析选取前 20 个特征变量, 使用 **BP 神经网络对具有随访影像的患者 90 天 mRS 评分**进行预测。针对问题三(c), 对之前所有特征变量, 通过灰色关联分析获得了其与出血性脑卒中患者的预后 90 天 mRS 的相关性, 通过对问题和实际诊疗的分析, 并根据灰色关联度的大小来对临床的决策提出相关建议。最后关于 90 天 mRS 评分的结果填入答案表 I 列和 J 列。

关键词: 脑血肿与水肿分析预测、CNN 卷积神经网络; **K-means 三维聚类; BP 神经网络;**

目录

1. 问题重述	5
1.1. 问题背景	5
1.2. 问题解析	6
2. 模型假设与符号说明	8
2.1. 模型假设	8
2.2. 符号说明	8
3. 问题一建模的分析与求解	9
3.1. 数据集概述	9
3.1.1. 数据缺失处理	9
3.1.2. 数据分析	9
3.1.3. 数据异常分析	10
3.2. 问题（a）分析与计算过程	12
3.2.1. 问题一（a）模型建立	12
3.2.2. 问题一（a）模型求解	13
3.3. 问题（b）分析与计算过程	14
3.3.1. 问题一（b）基于 CNN 卷积神经网络模型建立	14
3.3.2. 问题一（b）模型求解与评价	17
4. 问题二建模的分析与求解	18
4.1. 问题二（a）分析与计算过程	18
4.1.1. 问题二（a）基于多项式拟合模型建立	18
4.1.2. 问题二（a）模型求解	19
4.2. 问题二（b）分析与计算过程	20
4.2.1. 数据处理与基于 K-means 聚类模型建立	20
4.2.2. 问题二（b）模型的求解	23
4.3. 问题二（c）分析与计算过程	29
4.3.1. 问题（c）数据预处理	29
4.3.2. 问题（c）基于多元回归分析模型建立	29
4.3.3. 问题（c）模型求解	30
4.4. 问题二（d）分析与计算过程	31
4.4.1. 问题数据预处理	31
4.4.2. 问题二（d）基于斯皮尔曼相关性分析模型建立	31
4.4.3. 问题二（d）模型求解	32
5. 问题三建模的分析与求解	35
5.1. 问题三（a）建模的分析与求解	35
5.1.1. 数据处理与基于 BP 神经网络模型建立	35
5.1.2. 问题三（a）模型的求解	38
5.2. 问题三（b）建模的分析与求解	39
5.2.1. 数据的处理与整合	39
5.2.2. 问题三（b）模型的求解	40
5.3. 问题三（c）建模的分析与求解	41
5.3.1. 数据处理	41

5.3.2. 数据分析	43
6. 问题解决的模型评价与改进	48
6.1. 模型的优点	48
6.2. 模型的缺点	48
参考文献	49
附录一	50
附录二	58

1. 问题重述

1.1. 问题背景

出血性脑卒中是一种急性脑血管疾病，主要由创伤性和自发性两种因素导致的脑部局部血管破裂造成脑部机械性损伤，常伴随引发一系列复杂的生理病理反应。出血性脑卒中具有起病急、进展快，预后较差等特点，该病在急性期内病死率高达 45-50%，约 80% 的患者会遗留较严重的神经功能障碍。全球疾病负担研究数据显示，2012 年——2022 年 10 年来，我国出血性脑卒中患病率、发病率、死亡率虽然总体呈现相对稳定的变化趋势，但都持续高于全球平均水平和英美日等发达国家同期水平。我国出血性脑卒中疾病负担仍然沉重，其防治虽然取得了一定进展，但仍面临诸多挑战。




图 1-1 近十年出血性脑卒中患病率统计




图 1-2 近十年出血性脑卒中发病率统计




图 1-3 近十年出血性脑卒中死亡率统计

根据出血性脑卒中临床表现，血肿范围扩大和血肿周围水肿是其预后不良的两个关键危险因素。如图 1-1 是同一出血性脑卒中患者不同时间点 CT 平扫，图像中白色部位为血肿，红色部位为血肿周围水肿。其中，血肿范围会因脑组织受损、炎症反应等因素在出血发生后的短时间内逐渐扩大，导致颅内压迅速增加，进一步损害神经功能甚至威胁患者生命，其发生率在 13% 至 38% 之间。其次，血肿周围水肿是脑出血后的次生损伤指标，由此引起的脑组织受压会影响神经元功能，进一步损害脑组织，加剧患者的神经功能损伤。为此，对脑卒中患者血肿扩张和血肿周围水肿的发生及演进进行早期识别和预测对于改善患者预后具有重要意义。




图 1-4 同一出血性脑卒中患者不同时间点 CT 平扫图像[13]

1.2. 问题解析

从上述背景和数据中可以看出，脑血管疾病会严重影响人的生命健康安全。故通过对给出的真实临床数据分析，使用机器学习的方法建立相应的预测分析模型，研究出血性脑卒中患者血肿扩张风险并预测概率、血肿周围水肿发生的演进规律，最终结合临床和影像信息，可以很大程度上为临床预防和治疗出血性脑卒中，并对患者疾病进展、康复或生存情况进行预测/评估。根据给出的问题进行分析：

问题 1：以血肿扩张事件作为目标变量进行建模，探索血肿扩张风险相关因素。其中：
(a) 问要求判断患者样本发病后 48 小时内是否发生血肿扩张。首先查看表 1 和表 2 数据，

对其中的数据进行清洗操作，处理异常值和缺失值。而要求判断病人发病 48 小时之内是否发生血肿扩张现象。则通过比较发病 48 小时内病人首次做检查的血肿总体积和最后做的一次检查血肿总体积的绝对体积是否增加 6 mL 或者相对体积增加 33%，即可判断患者是否发生了血肿扩张。计算的时间不仅包括每次检查的时间间隔，还需要额外加上表 1 中患者发病到首次进行检查的时间间隔。（b）问要求构建模型预测所有患者发生血肿扩张的概率。考虑到有多个变量会对预测结果产生影响，为了更好分析影响因素，通过相关性分析进行降维处理。而观察数据特征可以发现，数据分为离散型数据和连续性数据。为增加模型的准确度，将特征分为离散型和连续性，其中离散型特征有 16 个，连续性数据 35 个，分别进行相关性分析。从两类中分别选取与血肿扩张相关性最强的 5 个离散型变量和 10 个连续性变量作为模型的输入，并考虑利用 CNN 卷积神经网络解决预测血肿扩张发生的概率。

问题 2：对血肿周围水肿的发生及进展进行建模，探索治疗干预和水肿进展的关联关系。其中：（a）问要求构建水肿体积随时间进展曲线和计算残差。首先对数据进行预处理，从表 2 中提取前 100 个患者的水肿体积和检查时间数据，然后建立患者水肿体积（因变量 y 表示水肿体积 ED_volume ）与相对于首次检查时间（自变量 x 表示时间）的关系，采用回归分析拟合数据并获得拟合函数。最后，使用实际数据与拟合曲线计算残差；（b）问要求构建不同亚组的水肿体积曲线以探索个体差异影响。首先使用 PCA 主成分分析进行数据降维和特征提取，选出贡献率最高的两个特征变量，其次对数据进行标准化处理。然后使用 K-means 聚类算法对患者进行分组并对每个分组使用回归分析拟合数据并获得拟合函数。最后使用实际数据和拟合曲线计算残差；（c）问要求分析不同治疗方法对水肿体积进展模式的影响。首先对数据进行处理，从表 1 中提取治疗方法数据，并与表 2 中的水肿体积数据进行整合，然后通过构建多元线性回归模型分析拟合系数并解释统计结果，进而分析治疗方法对水肿体积的影响；（d）问在（c）问的基础上，增加血肿体积这一关联因素，要求分析血肿体积、水肿体积和治疗方法三者之间的关系。首先对表 1 和表 2 中的数据进行整合，然后使用相关性分析研究血肿体积和水肿体积之间的关系，最后根据关联性分析的结果进行统计分析，探究三者之间的关系。

问题 3：建立出血性脑卒中患者的预后预测模型，探索该病预后关键因素。其中：（a）问要求基于患者首次影像预测患者 90 天 mRS 评分，首先对数据进行预处理，从表 1 中提取患者的个人史、疾病史和发病相关数据，从表 2 和表 3 中提取首次影像数据，对这些数据进行标准化与归一化处理。然后通过灰色关联分析对数据进行权重分析以识别关键特征。最后使用 BP 神经网络进行训练和预测；（b）问要求基于患者所有临床、治疗、首次影像和随访影像预测患者 90 天 mRS 评分；通过整合前 100 个患者的所有已知临床、治疗结果，预测所有含随访影像检查的患者。则需要整合所有的表 1、表 2 和表 3 的特征变量，包括患者个人史、治疗方法、疾病史、首次和随访的所有影像信息，并且对血肿/水肿体积在不同位置进行权值计算，统一进行统计分析。最后通过 BP 神经网络进行训练和预测 130 位患者的 90 天 mRS 评分；（c）问要求根据前两问的结果分析出血性脑卒中预后与多个因素的关联关系。考虑对所有特征变量进行灰色关联分析，通过对问题和实际诊疗的分析，并根据灰色关联度的大小来对临床的决策提出相关建议。

2. 模型假设与符号说明

2.1. 模型假设

1. 假设患者无其他基础疾病影响；
2. 假设该临床数据集数据真实有效，无虚假数据，且符合数据统计分析的基本要求；
3. 假设在患者每次随访影像检查间隔时间内不受其他突发因素影响；

2.2. 符号说明

表 2-1 模型符号说明

变量名称	变量说明
Sheet _{i j 列}	表格 i 第 j 列数据，x 表示附表 1
X_i	第 i 个特征序列
x_{ij}	第 i 个特征变量的第 j 个取值
$\varepsilon_i(k)$	灰色关联系数
r_{0i}	灰色关联度
TSS	总平方和
RSS	残差平方和
T_u	发病到首次检查的时间间隔
T_i	第 i 次随访时间点
ρ	灰色关联分辨系数
α	BP 神经网络学习系数
η	血肿体积变化率
Ψ	水肿体积变化率
κ	斯皮尔曼相关系数

3. 问题一建模的分析与求解

3.1. 数据集概述

观察给出的数据，可以看出本题给出了多变量的数据集，所以本文首先根据题目所给条件对原始数据进行一定的处理，观察表 1 和表 3 给出的关于病人个人史、疾病史、发病相关，以及影响检查结果，要求对前 100 位患者进行分析并根据附表 1 给出的检查时间来判断 48 小时内，患者是否发生血肿扩张，并且以是否发生血肿扩张事件为目标变量，基于上述数据前 100 例患者首次影像信息数据，构建模型预测所有患者（sub001 至 sub160）发生血肿扩张的概率。

由于多个变量使得对发生血肿扩张概率的预测变得十分复杂，考虑使用相关性分析。按照一定的法则来对数据的属性进行取舍达到降维的目的。相关性分析主要考量两组数据之间的相关性，以一种指标来判定，观察数据中哪些属性与目标数据的相关性较强，从而做出保留，哪些较弱，进行剔除。同时为了将不同特征的数据缩放到相同的尺度或范围内，以确保不同特征之间的权重在建立机器学习模型时能够平等地影响模型的训练和性能。如图 3-1 为本文数据处理的主要流程图。




图 3-1 数据处理流程图

3.1.1. 数据缺失处理

读取表格数据，统计每次检查的数据，针对问题一(a)，整理所用数据可以发现并没有缺失值的出现。

3.1.2. 数据分析

(1) 归一化处理

针对表 1 中患者的年龄和表 3 中患者影像信息多种形状特征和灰度特征进行归一化处理，由于不同特征可能具有不同的数值范围和单位。例如，一个特征的取值范围在 0 到 1

之间，而另一个特征的取值范围在 0 到 1000 之间。如果不进行归一化处理，那么数值较大的特征可能会在模型训练中占据主导地位，导致模型忽略了数值较小但重要的特征。

同时某些机器学习算法，如梯度下降，对输入数据的尺度非常敏感。特征尺度差异大的数据可能需要更多的迭代才能收敛到最优解。考虑到需要通过机器学习预测患者血肿扩张的概率，通过归一化处理，可以加快模型的收敛速度，减少训练时间。常见的数据归一化方法包括最小-最大归一化和标准化。最小-最大归一化将数据缩放到指定的范围内，通常是[0, 1]。标准化将数据转化为均值为 0，标准差为 1 的分布，使数据更符合正态分布。

故选择最小-最大归一化（Min-Max Scaling）

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (3-1)$$

线性函数将原始数据线性化的方法转换到[0, 1]的范围，计算结果为归一化后的数据， x 为原始数据， $\min(x)$ 和 $\max(x)$ 代表原始数据集中的最小和最大值。具体的归一化处理内容如下。其中将患者血压分为舒张压和收缩压，并将其和年龄和发病到首次检查时间间隔一并归一化处理，将表 1 患者首次检查的流水号以及表 3 共计 576 次检查的流水号进行匹配处理，筛选出 160 名患者首次检查影像信息，并对其进行归一化处理。归一化处理后的表格数据分别为 Sheet_1',Sheet_3'，使得数据处于同一尺度。

（2）离散数据分析

在机器学习中，在处理离散数据时，通常需要进行特征工程，将离散数据转换为适合机器学习算法的特征表示形式。这可能包括独热编码、嵌入表示、特征哈希等技术，以确保机器学习模型能够有效地处理这些数据。

而在针对于表 1 中患者个人史的性别数据，定义

$$\text{Sheet_1}_{\text{F 列}} = \begin{cases} 1, & \text{性别男} \\ 0, & \text{性别女} \end{cases} \quad (3-2)$$

3.1.3. 数据异常分析

异常的数据值往往会干扰我们对问题的分析过程，影响建立模型的准确度，从而导致模型求解出的结果偏离实际情况，所以本文对表 1 和表 3 给出的信息进行了一定的异常值判断和处理。通过比较高斯分布 3σ 原则以及箱型图异常值处理，最终选择箱型图的处理结果。

（1）高斯分布 3σ 原则

正态分布的概率密度函数图像是关于均值点处对称的，假设总体服从均值为 μ ，标准差为 σ 的正态分布，那么从该总体中随机抽取一个样本点，该点落在区间 $[\mu-3\sigma, \mu+3\sigma]$ 上的概率约为 99.73%，而超出这个范围的可能性仅占不到 0.3%，是典型的小概率事件，所以这些超出该范围的数据可以认为是异常值。为对数据进行可视化分析，选取 160 名患者首次影像检查信息进行 3σ 原则去除异常值处理，由于影像信息特征比较多，会占用大量篇幅。所以本文选择了形状特征中的 LeastAxisLength 和 MajorAxisLength 以及灰度特征中的 Energy 和 90Percentil 进行了展示。

对所有的特征进行了数据可视化后，由于影像特征可以发现通过 3σ 原则处理后的部分数据变化并不大，故各个特征并不都满足正态分布，所以考虑箱型图分析，如图 3-2 至 3-5

为挑选的 4 个典型较为典型的特征变量的对比图。




图 3-2 形状特征 LeastAxisLength 分布




图 3-3 形状特征 MajorAxisLength 分布




图 3-4 灰度特征 Energy 分布




图 3-5 灰度特征 90Percentile 分布

(2) 箱型图

箱线图则五个重要统计量：最小值、上四分位数、中位数、下四分位数和最大值。本文对前 100 例患者首次影像检查信息进行了箱型图分析，将其中的异常值用均值代替，从而减少异常值对模型的影响。如如图 3-6 为患者首次影像信息的箱型图。




图 3-6 患者首次影像检查信息箱型图

3.2. 问题（a）分析与计算过程

3.2.1. 问题一（a）模型建立

问题一（a）需要计算患者 48 小时之内的水肿扩张情况，首要目标是对患者数据进行整合，确保能够跟踪每次检查时的水肿总体积。为了便于我们针对每个患者和每个时间点比较水肿体积的变化，我们将所给数据表进行一定的处理。

(1) 表格数据预处理

$$S_{merged} = f(\text{Sheet_1}:T_u, \text{Sheet_2}:HM_volume, \text{Sheet_x}:T_x) \quad (3-3)$$

其中： S_{merged} 表示对表格数据合并预处理的结果； f 表示一个合并操作； Sheet_1 、 Sheet_2 、 Sheet_x 分别表示附件表 1、附件表 2 和附件附表 1 数据； T_u 、 HM_volume 、 T_x 分别表示首次发病到首次影像检查时间间隔、血肿体积、随访时间点。

(2) 血肿扩张发生时间的判别

题目说明需要判别患者在发病 48 小时内是否发生血肿扩张，若在 48 小时内发现血肿扩张，即可确定发生时间。根据合并表格 S_{merged} ，初步筛选出 48 小时内所作的检查的 HM_volume ，初筛条件为

$$T = T_u + (T_1 - T_0) + (T_2 - T_1) + \dots + (T_n - T_{n-1}) \leq 48h \quad (3-4)$$

其中：

T_u 表示首次发病到首次影像检查时间间隔；

T_0 表示入院首次检查时间点；

T_i 表示第 i 次随访时间点， $i=1,2,\dots,13$ 。

(3) 血肿体积变化

$$\Delta HM_{volume} = HM_{volume_48h_max} - HM_{volume_first} \quad (3-5)$$

其中：

ΔHM_{volume} 表示血肿体积变化；

HM_{volume_first} 和 $HM_{volume_48h_max}$ 分别表示首次检查的血肿体积和 48 小时内血肿体积的最大值。

(4) 血肿扩张发生条件

是否发生血肿扩张可根据血肿体积前后变化，具体定义为：后续检查比首次检查绝对体积增加 $\geq 6\text{ mL}$ 或相对体积增加 $\geq 33\%$

$$\text{血肿扩张} = \begin{cases} 1, & \text{如果 } \frac{\Delta HM_{volume}}{HM_{volume_first}} \geq 33\% \text{ 或 } \Delta HM_{volume} \geq 6\text{ml} \\ 0, & \text{否则} \end{cases} \quad (3-6)$$

(5) 计算血肿扩张发生时间

$$T_e = T_{48h_max} - T_{first} \quad (3-7)$$

其中：

T_e 表示血肿扩张发生时间；

T_{first} 和 T_{48h_max} 分别表示第一次检查和在 48h 内检查血肿总体积最大的时间。

3.2.2. 问题一（a）模型求解

将建立模型求得的数据记录到答案表 4 中，（3-8）即为所得结果的数学模型。

$$\text{Sheet_4}_{\text{C列}} = \begin{cases} 1, & \text{如果发生血肿扩张} \\ 0, & \text{否则} \end{cases}, \text{Sheet_4}_{\text{D列}} = \begin{cases} T_e, & \text{如果发生血肿扩张} \\ N/A, & \text{否则} \end{cases} \quad (3-8)$$

3.3. 问题（b）分析与计算过程

3.3.1. 问题一（b）基于 CNN 卷积神经网络模型建立

根据题目所给的要求，需要根据前 100 例患者的个人史、疾病史、发病相关及首次检查的影像信息进行一系列分析，并以问题 a 求解出的结果作为目标变量构建出相应的模型，预测所有病人血肿扩张的概率。考虑到有多个变量会对预测结果产生影响，为了更好分析影响因素，通过相关性分析进行降维处理。选取与血肿扩张相关性最强的 15 个变量作为模型的输入。并考虑利用 CNN 卷积神经网络算法解决预测血肿扩张发生的概率。而观察数据特征可以发现，数据分为离散型数据和连续性数据。为增加模型的准确度，将特征分为离散型和连续性，其中离散型特征有 16 个，连续性数据 35 个，分别进行相关性分析。如图 3-7 为问题一完整的研究思路。




图 3-7 问题一研究思路图

（1）特征工程

定义特征序列，其中序列中的值已经进行了归一化处理。其中离散型特征为 X_i ，连续性数据为 X_i' 。

$$X_i = (X_1(k), X_2(k), \dots, X_{16}(k)) \quad (3-9)$$

$$X_i' = (X_1'(k), X_2'(k), \dots, X_{35}(k)) \quad (3-10)$$

对表格数据进行分析处理

$$X_{\text{merged}} = f(\text{Sheet_1': } X_{E-W}, \text{Sheet_3': } X_{C-W})$$

其中： X_{merged} 表示对表格特征合并的结果； f 表示一个合并操作； Sheet_1' 、 Sheet_3'

分别表示进行归一化处理后的附件表 1 和附件附表 3 数据； X_{E-W} 、 X_{C-W} 分别表示表格 E 列到 W 列和 C 列到 W 列的特征数据。

(2) 灰色关联分析

通过分别对 X_i 和 X_i 进行灰色关联分析。灰色关联分析是一种多变量数据分析方法，用于研究不同变量之间的关联程度。根据最后的关联程度来选择相关性最强的几个数据序列进行训练，从而达到降维的效果。使得数据分析的结果更加可靠，并且改善数据分析和效率，降低计算成本。

确定分析数列：

母序列：反应是否发生血肿扩张的数据序列，此处即为 $Y = [y_1, y_2, \dots, y_m]^T$

子序列：影响是否发生血肿扩张的因素组成的数据序列，即为 X_i 和 X_i

对母序列和子序列中的每个指标进行预处理，先求出每个指标的均值，再用该指标中的每个元素都除以其均值。

$$Z_i(k) = \frac{X_i(k)}{\frac{1}{n} \sum_{i=1}^n X_i} \quad (3-11)$$

得到标准化矩阵 Z:

$$Z = \begin{bmatrix} Z_{11} & Z_{12} & \cdots & Z_{1m} \\ Z_{21} & Z_{22} & \cdots & Z_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ Z_{n1} & Z_{n2} & \cdots & Z_{nm} \end{bmatrix} \quad (3-12)$$

计算灰色关联系数：

$$\varepsilon_i(k) = \frac{\min_i \min_k |x_0(k) - x_i(k)| + \rho \cdot \max_i \max_k |x_0(k) - x_i(k)|}{|x_0(k) - x_i(k)| + \rho \cdot \max_i \max_k |x_0(k) - x_i(k)|} \quad (3-13)$$

将 i 看作固定值，此时公式如下

$$\varepsilon_i(k) = \frac{\min_k |x_0(k) - x_i(k)| + \rho \cdot \min_k |x_0(k) - x_i(k)|}{|x_0(k) - x_i(k)| + \min_k |x_0(k) - x_i(k)|} \quad (3-14)$$

计算灰色关联度

$$r_{0i} = \frac{1}{m} \sum_{k=1}^m \varepsilon_i(k) \quad (3-15)$$

对于某一个因素，其中的每个维度进行计算，得到一个新的序列，这个序列中的每个点就代表着该子序列与母序列对应维度上的关联性，所得数值越大，代表关联性越强。如图为经过灰色关联分析的所有特征变量的灰色相关度，根据特征变量的数据类型分为了离散型图 3-8 和连续性图 3-9 两类。




图 3-8 连续特征值与是否发生血肿扩张之间关联度




图 3-9 离散特征值与是否发生血肿扩张之间关联度

从连续特征值中选择关联度最高的 5 个特征序列，从离散特征值中选择关联度最高的 10 个特征序列作为训练特征。如表 3-1 即为筛选后的结果。

表 3-1 特征序列筛选结果

特征序列筛选		
卒中病史	糖尿病史	房颤史
冠心病史	脑室引流	年龄
发病到首次影像 检查时间间隔	收缩压	舒张压

MajorAxisLength	Maximum2DDiameterColumn	Maximum2DDiameterSlice
MeshVolume	Sphericity	SurfaceArea

(3) CNN 神经网络预测

将通过灰色关联度筛选出的特征序列作为变量，考虑到具有是时序数据，则在 Matlab 工具箱中利用 CNN 卷积神经网络进行预测。CNN 由多个卷积层、池化层、全连接层和输出层组成。

首先，将数据集划分为训练集和测试集，采用前 100 例患者的数据，将归一化、标准化的数据集 S_{merged} 、 X_{merged} 、Sheet_1`和 Sheet\_3`进行整合后传入 CNN,最后可以使用 RMSE 和 MAE 值指标来评估模型的性能。

3.3.2. 问题一（b）模型求解与评价

通过 CNN 卷积神经网络进行预测后的关于 160 例患者是否会发生血肿扩张概率在图 3-10 中展示，同时表 3-2 是通过验证后的模型评价。

表 3-2 模型评价指标

评价指标	数值
根均方差（RMSE）	0.43109
平均相对误差（MAE）	0.34281




图 3-10 模型预测概率的分布

4. 问题二建模的分析与求解

4.1. 问题二（a）分析与计算过程

根据问题一描述，水肿周围的水肿作为脑出血后继性发损伤的标志，对其发生及发展的预测也有利于临床治疗。根据问题二中的要求，需要构建前 100 个患者的水肿体积随时间变化进展曲线，并计算真实数据与拟合值之间存在的残差。如图 4-1 即为问题二的整体研究思路。




图 4-1 问题二研究思路图

4.1.1. 问题二（a）基于多项式拟合模型建立

（1）特征工程

根据表 2 给出的数据，可以知道每名患者的 ED_volume 数据量是有限的，为了更好的构建出数据拟合曲线，需要对数据进行一定的处理。

根据流水号对应的检查时间可以知道，一些患者在首次影像检查与后几次的复查时间存在巨大的时间差，该类型数据由于时间跨度太大，患者自身的身体情况不好判断，所以本文对水肿随时间变化的研究同问题一相同，假设在发病 48 小时之外的水肿体积变化不具有分析价值，故采取 48 小时内的水肿体积 ED_volume 变化。

（2）模型建立与拟合

使用散点图绘制出每个患者 48 小时内水肿体积 ED_volume。则散点图内包含一组数据，假设为 m 个点，称之为样本点。其中 x 轴表示时间， y 轴表示水肿体积 ED_volume。

$$\{(x_1, y_1)(x_2, y_2) \dots (x_m, y_m)\} \quad (4-1)$$

样本点中的某个点可以表示为

$$(x_i, y_i), i = 1, 2, 3, \dots, m \quad (4-2)$$

观察样本点，由于数据有限，且样本点较为离散。故采用多项式拟合。

$$\hat{y} = a_0 x^n + a_1 x^{n-1} + a_2 x^{n-2} + \dots + a_{n-1} x + a_n \quad (4-3)$$

而拟合后的曲线需要通过一个标准来衡量拟合效果，本文使用 R-Squared 衡量回归方程整体的拟合度。首先计算样本的总平方和 TSS 和残差平方和 RSS，最后根据两者求 R^2

$$TSS = \sum_{i=1}^m (y_i - \bar{y})^2 \tag{4-4}$$

$$RSS = \sum_{i=1}^m (\hat{y}_i - y_i)^2 \tag{4-5}$$

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{\sum (Y_{actual} - Y_{predict})^2}{\sum (Y_{actual} - Y_{mean})^2} \tag{4-6}$$

R^2 越大，拟合效果越好。 R^2 的最优值为 1，若模型预测为随机值， R^2 有可能为负值。若预测值恒为样本期望， R^2 为 0。理论上 R^2 取值范围 $(-\infty, 1]$,正常取值范围为[0 1]。实际操作中通常会选择拟合较好的曲线计算 R^2 ，因此很少出现 $-\infty$ 。越接近 1，表明方程的变量对 y 的解释能力越强，这个模型对数据拟合的也较好。越接近 0，表明模型拟合的越差。通过经验值若 $R^2>0.4$ ，则判断拟合效果好。

4.1.2. 问题二（a）模型求解

由于数据量较小，而数据偏差过大，所以采用了问题一的异常值处理方法，去除了一部分异常值。通过拟合工具求得拟合曲线如图 4-2 所示：




图 4-2 问题二(a)模型拟合曲线

该模型使用了一个 5 次多项式来拟合数据，其公式为：

$$f(x) = p_1 \cdot x^5 + p_2 \cdot x^4 + p_3 \cdot x^3 + p_4 \cdot x^2 + p_5 \cdot x + p_6 \tag{4-7}$$

其中，如表 4-1 中 p_1 至 p_6 是拟合后多项式模型的系数，置信区间值为 95%。

表 4-1 问题二(a)模型系数值

系数	系数值
p_1	-0.008387 (-0.02082, 0.004042)
p_2	0.9283 (-0.4669, 2.323)
p_3	-37.17 (-94.48, 20.14)

p4	644.4	(-395.5, 1684)
p5	-4146	(-1.186e+04, 3569)
p6	1.943e+04	(4528, 3.434e+04)

该模型拟合质量共有 4 项指标，误差平方和（SSE）表示模型拟合数据的误差总和、 R^2 （R-square）表示模型对总方差的解释程度、调整后的 R^2 （Adjusted R-square）通常用于多项式拟合，它考虑了模型中的自由度。负值通常表示模型不适合拟合数据，均方根误差（RMSE）表示模型的预测误差的标准偏差，各项指标值如表 4-2 所示：

表 4-2 问题二(a)模型拟合质量评价

拟合质量指标	拟合质量指标值
SSE	5.658e+08
R-square	0.4854
Adjusted R-square	0.33
RMSE	4960

4.2. 问题二（b）分析与计算过程

题目需要探究患者水肿体积随时间进展模式的个体差异，则考虑使用聚类算法 K-means 对患者进行分组，对不同组的患者再分别进行水肿体积变化随时间进展的拟合，查看表 1 可以知道，由于需要考虑的特征变量较多，利用 PCA 主成分分析选出贡献率最高的特征变量进行分析，从而达到降维的效果，提高计算效率。

4.2.1. 数据处理与基于 K-means 聚类模型建立

（1）PCA 主成分分析

PCA 主成分分析方法是一种常用的数据降维和特征提取的统计方法。主要思想是通过线性变换，将原始数据映射到一个新的坐标系中，使得在新坐标系中的数据具有最大的方差。换句话说，PCA 的目标是找到数据中的主要方向（主成分），以便使用较少的维度来表示数据，同时尽量保留数据的信息。

（a）对数据进行相应的标准化处理

如问题一处理后的数据。考虑到本题需要的指标变量与问题一的特征有重合关系，用 $x_1, x_2, \dots, x_m$ ，表示选择的特征变量。用 x_{ij} 表示选择第 i 个特征变量的取值，将其转化为标准化特征变量 $\tilde{x}_{ij}$ 。

$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, (i = 1, 2, \dots, n; j = 1, 2, \dots, m) \quad (4-8)$$

利用 $\bar{x}_j$ 表示第 j 个特征变量的平均值

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij} \quad (4-9)$$

求其标准差为:

$$s_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}, (j = 1, 2, \dots, m) \quad (4-10)$$

(b) 计算相关系数矩阵与其特征值、特征变量

相关系数矩阵 $R_e = (r_{ij})_{m \times m}$, 计算 $R_e = (r_{ij})_{m \times m}$ 的特征值及特征向量, 并且将求得的特征值按大小进行排序。

$$r_{ij} = \frac{\sum_{k=1}^n \tilde{x}_{ki} \cdot \tilde{x}_{kj}}{n-1}, (i, j = 1, 2, \dots, m) \quad (4-11)$$

$$\begin{cases} y_1 = u_{11}\tilde{x}_1 + u_{21}\tilde{x}_2 + \dots + u_{n1}\tilde{x}_n \\ y_2 = u_{12}\tilde{x}_1 + u_{22}\tilde{x}_2 + \dots + u_{n2}\tilde{x}_n \\ \dots\dots\dots \\ y_m = u_{1m}\tilde{x}_1 + u_{2m}\tilde{x}_2 + \dots + u_{nm}\tilde{x}_n \end{cases} \quad (4-12)$$

(c) 选取其中 m 个主成分, 并根据特征值计算评价

根据上述主成分分析的模型, 对原始数据中多个变量的数据集进行了降维操作, 减少需要分析的特征变量, 这样有利于数据处理, 使得模型更为准确, 分析更为全面。采用 PCA 算法, 对患者的个人患病史(高血压史、脑卒中病史、糖尿病史、房颤史、冠心病史、饮酒和吸烟史)、治疗方法(脑室引流、止血治疗、降颅压治疗、降压治疗、镇静、镇痛治疗、止吐护胃和营养神经)、血压和年龄计算并选取最优解。其中血压被分为舒张压和收缩压。

综上, 我们将多特征变量影响转化为年龄和血压两个综合条件指标及其特征信息。

(2) K-means 三维聚类

K-means 聚类是一种无监督学习算法, 用于将数据集划分为 K 个不同的簇, 每个簇包含具有相似特征的数据点。在三维数据中, K-means 可以用于在三维空间中找到 K 个簇, 并将数据点分配到这些簇中。

K-means 的原理及学习步骤:

(a) 选择簇的数量 K 以及数据点

首先, 选择要将数据划分成的簇的数量 K 。这是 K-means 算法中的一个重要参数, 通常需要根据数据的性质或任务来选择。假设我们有一个包含 $N=160$ 个数据点的数据集, 每个数据点是一个三维向量, 可以表示为

$$X_i = (x_{i1}, x_{i2}, x_{i3}) \quad (4-13)$$

其中 i 是数据点的索引。

(b) 初始化聚类中心

随机选择 K 个数据点作为初始聚类中心, 这些中心将作为簇的代表。

$$C_i = (c_{i1}, c_{i2}, c_{i3}) \quad (4-14)$$

(c) 分配数据点到最近的聚类中心

对于每个数据点，计算它与每个聚类中心的距离，并将其分配给距离最近的聚类中心所属的簇。在 K-means 中，我们有 K 个聚类中心，每个聚类中心是一个三维向量，可以表示为其中 j 是聚类中心的索引。使用一个分配矩阵 A 来表示每个数据点分配给哪个簇。A 的大小是 $N \times K$ ，其中 A_{ij} 表示数据点 X_i 是否属于簇 C_j ，通常为 0 或 1。

(d) 更新聚类中心

对于每个簇，计算该簇中所有数据点的平均值，将该平均值作为新的聚类中心。K-means 的目标是最小化数据点与其所属簇中心之间的距离的平方和，这通常被称为“簇内平方和”（inertia）。目标函数可以表示为

$$\text{Inertia} = \sum_{i=1}^N \sum_{j=1}^K A_{ij} \cdot \|X_i - C_j\|^2 \quad (4-15)$$

(e) 迭代并输出结果

重复步骤 3 和步骤 4，直到满足停止条件，例如，簇中心不再发生显著变化或达到预定的迭代次数。一旦停止条件满足，算法将返回 K 个簇，每个簇包含一组数据点，表示数据的不同子群。

K-means 算法的目标是找到最优的分配簇 A 和聚类中心 C，以最小化目标函数。K-means 是一个迭代的算法，通过不断更新分配簇和聚类中心，寻找最优的簇划分。通常，K-means 的性能受到初始聚类中心的选择和迭代次数的影响，因此可以多次运行算法以获得更好的结果。通过算法将 160 个患者数据根据年龄和血压分为了 5 个聚类，如图 4-3 是通过 Matlab 进行 K-means 三维聚类后分出的三维图形，其中五种不同的颜色即代表了不同的聚类。图 4-4 和表 4-3 是对这 5 个聚类进行了统计分析，展示 5 聚类的基本特征。




图 4-3 K-means 聚类最优簇划分




图 4-4 K-means 曲线簇划分占比饼图

其中五个聚类的特征指标分布关系如下：

表 4-3 K-means 聚类特征指标分布关系

	聚类 1	聚类 2	聚类 3	聚类 4	聚类 5
年龄段	35-60	60-90	45-70	50-80	60-90
收缩压/mmHg	160-190	120-160	130-170	190-250	160-210
舒张压/mmHg	100-130	65-85	80-105	100-120	80-105

4.2.2. 问题二（b）模型的求解

对每个聚类拟合完后的曲线进行特征分析。

（a）聚类 1 曲线拟合与评价




图 4-5 问题二(b)聚类 1 模型拟合曲线

该模型使用了一个 5 次多项式来拟合数据，图 4-5 为其拟合曲线图。其公式为：

$$f(x) = p_1 \cdot x^5 + p_2 \cdot x^4 + p_3 \cdot x^3 + p_4 \cdot x^2 + p_5 \cdot x + p_6 \quad (4-16)$$

其中，如表 4-4 中 p_1 至 p_6 是拟合后多项式模型的系数，置信区间值为 95%。

表 4-4 问题二(b)聚类 1 多项式模型系数

系数	系数值
p ₁	0.01008 (-0.01203, 0.03219)
p ₂	-1.141 (-3.859, 1.578)
p ₃	46.32 (-73.63, 166.3)
p ₄	-810.5 (-3085, 1464)
p ₅	5761 (-1.14e+04, 2.292e+04)
p ₆	1.373e+04 (-2.232e+04, 4.979e+04)

该模型拟合质量共有 4 项指标，误差平方和（SSE）表示模型拟合数据的误差总和、 R^2 （R-square）表示模型对总方差的解释程度、调整后的 R^2 （Adjusted R-square）通常用于多项式拟合，它考虑了模型中的自由度。负值通常表示模型不适合拟合数据，均方根误差（RMSE）表示模型的预测误差的标准偏差，各项指标值如表 4-5 所示：

表 4-5 问题二(b)聚类 1 模型拟合质量评价

拟合质量指标	拟合质量指标值
SSE	1.533e+10
R-square	0.4199
Adjusted R-square	0.3345
RMSE	2.155e+04

(b) 聚类 2 曲线拟合与评价




图 4-6 问题二(b)聚类 2 模型拟合曲线

该模型使用了一个 5 次多项式来拟合数据，图 4-6 为其拟合曲线图，其公式为：

$$f(x) = p_1 \cdot x^5 + p_2 \cdot x^4 + p_3 \cdot x^3 + p_4 \cdot x^2 + p_5 \cdot x + p_6 \quad (4-17)$$

其中，如表 4-6 中 p1 至 p6 是模型的系数，置信区间值为 95%。

表 4-6 问题二(b)聚类 2 多项式模型系数

系数	系数值
p ₁	0.02864 (-0.0286, 0.08588)
p ₂	-2.601 (-8.403, 3.2)
p ₃	82.43 (-126.1, 290.9)
p ₄	-1123 (-4290, 2043)
p ₅	6910 (-1.223e+04, 2.605e+04)
p ₆	-1157 (-3.604e+04, 3.372e+04)

该模型拟合质量指标值如表 4-7 所示：

表 4-7 问题二(b)聚类 2 模型拟合质量评价

拟合质量指标	拟合质量指标值
SSE	3.242e+09
R-square	0.4388
Adjusted R-square	0.28944
RMSE	1.423e+04

(c) 聚类 3 曲线拟合与评价




图 4-7 问题二(b)聚类 3 模型拟合曲线

该模型使用了一个 5 次多项式来拟合数据，图 4-7 为其拟合曲线图，其公式为：

$$f(x) = p_1 \cdot x^5 + p_2 \cdot x^4 + p_3 \cdot x^3 + p_4 \cdot x^2 + p_5 \cdot x + p_6 \quad (4-18)$$

其中，如表 4-8 中 p1 至 p6 是模型的系数，置信区间值为 95%。

表 4-8 问题二(b)聚类 3 多项式模型系数

系数	系数值
p1	-0.05085 (-0.08168, -0.02001)
p2	5.279 (1.993, 8.565)
p3	-192.1 (-318.4, -65.82)
p4	2966 (835.4, 5097)
p5	-1.842e+04 (-3.338e+04, -3465)
p6	3.849e+04 (6137, 7.084e+04)

该模型拟合质量指标值如表 4-9 所示：

表 4-9 问题二(b)聚类 3 模型拟合质量评价

拟合质量指标	拟合质量指标值
SSE	5.408e+08
R-square	0.8286
Adjusted R-square	0.7507
RMSE	7012

(d) 聚类 4 曲线拟合与评价




图 4-8 问题二(b)聚类 4 模型拟合曲线

该模型使用了一个包含三个谐波项的傅里叶级数来拟合数据，图 4-8 为其拟合曲线图，其公式为：

$$f(x) = a_0 + a_1 \cdot \cos(x \cdot w) + b_1 \cdot \sin(x \cdot w) + a_2 \cdot \cos(2 \cdot x \cdot w) + b_2 \cdot \sin(2 \cdot x \cdot w) + a_3 \cdot \cos(3 \cdot x \cdot w) + b_3 \cdot \sin(3 \cdot x \cdot w) \quad (4-19)$$

其中，如表 4-10 中 a_0 至 b_3 和 w 是模型的系数， w 表示频率，置信区间值为 95%。

表 4-10 问题二(b)聚类 4 多项式模型系数

系数	系数值
a_0	2.799e+04 (2.003e+04, 3.595e+04)
a_1	3218 (-5618, 1.205e+04)
b_1	-1192 (-1.411e+04, 1.173e+04)
a_2	-1.299e+04 (-2.407e+04, -1920)
b_2	1480 (-1.134e+04, 1.43e+04)
a_3	-1729 (-1.475e+04, 1.129e+04)
b_3	-9455 (-2.029e+04, 1380)
w	0.3951 (0.3738, 0.4164)

该模型拟合质量指标值如表 4-11 所示：

表 4-11 问题二(b)聚类 4 模型拟合质量评价

拟合质量指标	拟合质量指标值
SSE	2.39e+09
R-square	0.48
Adjusted R-square	0.32
RMSE	1.307e+04

(e) 聚类 5 曲线拟合与评价




图 4-9 问题二(b)聚类 5 模型拟合曲线

该模型使用了一个包含三个谐波项的傅里叶级数来拟合数据，图 4-9 为其拟合曲线图其公式为：

$$f(x) = a_0 + a_1 \cdot \cos(x \cdot w) + b_1 \cdot \sin(x \cdot w) + a_2 \cdot \cos(2 \cdot x \cdot w) + b_2 \cdot \sin(2 \cdot x \cdot w) + a_3 \cdot \cos(3 \cdot x \cdot w) + b_3 \cdot \sin(3 \cdot x \cdot w) \quad (4-20)$$

其中，如表 4-12 中 a_0 至 b_3 和 w 是模型的系数， w 表示频率，置信区间值为 95%。

表 4-12 问题二(b)聚类 5 多项式模型系数

系数	系数值
a_0	1.096e+04 (6920, 1.5e+04)
a_1	642.2 (-4029, 5314)
b_1	-2246 (-8417, 3926)
a_2	-4584 (-1.064e+04, 1473)
b_2	-2235 (-1.078e+04, 6308)
a_3	3405 (-4713, 1.152e+04)
b_3	3373 (-3683, 1.043e+04)
w	0.2073 (0.176, 0.2387)

该模型拟合质量指标值如表 4-13 所示：

表 4-13 问题二(b)聚类 5 模型拟合质量评价

拟合质量指标	拟合质量指标值
SSE	3.751e+08

R-square	0.4493
Adjusted R-square	0.36381
RMSE	6125

4.3. 问题二（c）分析与计算过程

需要分析表 1 中不同治疗方法对水肿体积进展模式的影响，所以本文考虑搭建多元线性回归模型，利用多元回归模型分析模型的拟合系数，从而对不同治疗方法对水肿体积变化的影响做出判断。

4.3.1. 问题（c）数据预处理

由于需要分析不同治疗方法对水肿体积进展模式。则需要分析不同患者在随时间变化的过程中，水肿体积的变化，由于每个患者的随访次数不同，水肿体积变化的数据量也不同。故通过计算相邻两次随访水肿体积变化与时间间隔的比值，反应水肿体积在这段时间的变化情况，如果有多次随访记录，则通过求每相邻两次随访水肿体积变化与时间间隔的比值的平均值，来获得患者在整个治疗期间水肿体积的变化情况。

$$\text{水肿体积变化} \Psi = \frac{1}{n} \sum_{i=1}^n \frac{ED_{\text{volume}_i} - ED_{\text{volume}_{i-1}}}{T_i - T_{i-1}} \quad (4-21)$$

其中患者随访次数为 $n = 0, 1, 2, \dots$ ，并认为患者首次影像检查信息为第 0 次。

4.3.2. 问题（c）基于多元回归分析模型建立

多元线性回归的目标是找到最佳的回归系数，以最好地拟合数据并解释因变量的变异性。这通常涉及到最小化残差平方和（SSE），即观测值与模型预测值之间的差异的平方和，来估计回归系数。

其一般性模型的表达式为

$$Y = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p + \varepsilon\sigma^2 \quad (4-22)$$

其中：Y 是因变量，即要预测或解释的变量，x 为自变量，b 表示预测因子，是回归系数，表示自变量对因变量的影响程度，该系数的计算采用最小二乘估计法， ε 是服从正态分布 $N(0, \sigma^2)$ 的随机变量，表示模型不能解释的随机误差。方便起见，引入矩阵记号：

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}, X = \begin{bmatrix} x_1(u_1) & x_2(u_2) & \dots & x_m(u_m) \\ x_2(u_1) & x_2(u_2) & \dots & x_2(u_m) \\ \dots & \dots & \dots & \dots \\ x_n(u_1) & x_n(u_2) & \dots & x_n(u_m) \end{bmatrix}, \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_m \end{bmatrix} \quad (4-23)$$

选取 β 的一个估计值 $\hat{\beta}$ ，使得随机变量 ε 的平方和达到最小，即

$$m\varepsilon^t\varepsilon = m(Y - X\beta)^T(Y - X\beta) \quad (4-24)$$

写成分量形式为：

$$Q(\beta_1, \beta_2, \dots, \beta_m) = \sum_{i=1}^n [y_i - \beta_1 x_1(u_i) - \beta_2 x_2(u_i) - \dots - \beta_m x_m(u_i)]^2 \quad (4-25)$$

$$Q(\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_m) = m Q(\beta_1, \beta_2, \dots, \beta_m) \quad (4-26)$$

由于 $Q(\beta_1, \beta_2, \dots, \beta_m)$ 是非负二次式，根据多元函数取极值的必要条件，可得

$$\frac{\partial Q}{\partial \beta_j} = 0 \quad (j = 1, 2, \dots, m) \quad (4-27)$$

$$\sum_{i=1}^n [y_i - \hat{\beta}_1 x_1(u_i) - \hat{\beta}_2 x_2(u_i) - \dots - \hat{\beta}_m x_m(u_i)] x_j(u_i) = 0 \quad (j = 1, 2, \dots, m) \quad (4-28)$$

$$\begin{cases} [\sum_{i=1}^n x_1^2(u_i)] \hat{\beta}_1 + [\sum_{i=1}^n x_1(u_i) x_2(u_i)] \hat{\beta}_2 + \dots + [\sum_{i=1}^n x_1(u_i) x_m(u_i)] \hat{\beta}_m \\ = \sum_{i=1}^n x_1(u_i) y_i \\ [\sum_{i=1}^n x_1(u_i) x_m(u_i)] \hat{\beta}_1 + [\sum_{i=1}^n x_2(u_i) x_m(u_i)] \hat{\beta}_2 + \dots + [\sum_{i=1}^n x_m^2(u_i)] \hat{\beta}_m \\ = \sum_{i=1}^n x_m(u_i) y_i \end{cases} \quad (4-29)$$

将 $\hat{\beta}_1$ 代入模型（4-23）中，得模型的估计： $\hat{Y} = X^T \hat{\beta}$ 。

综合利用模型拟合程度 R^2 和F检验可以更全面地评估线性回归模型的拟合程度和统计显著性，便于对结果进行分析验证。

线性回归模型的预测值与观测值的相关系数R表示模型对观测数据的解释程度。本文一认为大于0.4认为拟合成功，其表达式如下：

$$R = \frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum (y_i - \bar{y})^2 \sum (\hat{y}_i - \bar{\hat{y}})^2}} \quad (4-30)$$

4.3.3. 问题（c）模型求解

使用多元线性回归，以不同治疗方法作为多维度特征值，以单位时间内水肿总体积变化作为因变量，做出相应的拟合曲线如下：

$$Y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + b_3 \cdot x_3 + b_4 \cdot x_4 + b_5 \cdot x_5 + b_6 \cdot x_6 + b_7 \cdot x_7$$

其中表 4-14 中 b_0 为常数系数， b_1 到 b_7 分别为治疗方法为特征数据的回归系数。

表 4-14 问题二(c)多元线性回归拟合曲线系数

系数	系数值
b_0	-139.2952
b_1	462.3629
b_2	102.7279
b_3	174.6037
b_4	91.1463

b_5	199.8148
b_6	-290.2422
b_7	147.5962

通过拟合所得的曲线如图 4-10 所示，计算出的多项拟合经过 R^2 检测得 $R^2=0.4316$ ，通过 R^2 分析知拟合效果较好。




图 4-10 多元线性回归拟合曲线图

4.4. 问题二（d）分析与计算过程

4.4.1. 问题数据预处理

本题要求分析血肿体积、水肿体积及治疗方案三者之间的联系，可以根据问题（c）同样的数据处理方法对血肿体积进行同样的处理。

$$\text{水肿体积变化}\eta = \frac{1}{n} \sum_{i=1}^n \frac{HM_{\text{volume}_i} - HM_{\text{volume}_{i-1}}}{T_i - T_{i-1}} \quad (4-31)$$

4.4.2. 问题二（d）基于斯皮尔曼相关性分析模型建立

上述的问题对数据的分析可以知道，表中数据整体并不呈现正态分布。本文通过斯皮尔曼相关性分析，分析血肿体积、水肿体积及治疗方案三者的联系，并通过 SPSS 数据分析软件进行计算。通过上述的数据预处理，本文将问题转化为分析血肿体积变化 η 、水肿体积变化 Ψ 以及治疗方法三者之间的关系。

斯皮尔曼相关系数是一种用于衡量两个变量之间的非线性关联关系的统计量。与皮尔逊相关系数不同，斯皮尔曼相关系数不要求变量之间的关系是线性的，而且可以用于评估等级数据或有序数据之间的关联。且斯皮尔曼相关对于异常值并不敏感，实际数值之间的差异大小对于计算结果并没有太大的影响。

计算斯皮尔曼秩的相关系数计算公式：

$$\kappa = \frac{\frac{1}{n} \sum_{i=1}^n (R(x_i) - \overline{R(x)}) \cdot (R(y_i) - \overline{R(y)})}{\sqrt{\left(\frac{1}{n} \sum_{i=1}^n (R(x_i) - \overline{R(x)})^2 \right) \cdot \left(\frac{1}{n} \sum_{i=1}^n (R(y_i) - \overline{R(y)})^2 \right)}} \quad (4-32)$$

其中： $R(x)$ 和 $R(y)$ 分别表示的是 x 和 y 的位次； $\overline{R(x)}$ 和 $\overline{R(y)}$ 分别表示平均位次。
简化其表达公式为：

$$\kappa = 1 - \frac{6\sum d_i^2}{n(n^2-1)} \tag{4-33}$$

其中： d_i 表示第 i 个数据对的位次值之差， n 表示总的观测样本数。

4.4.3. 问题二（d）模型求解

根据模型求解，血肿体积变化 η 、水肿体积变化 Ψ 以及治疗方法（脑室引流、止血治疗、降颅压治疗、降压治疗、镇静、镇痛治疗、止吐护胃和营养神经），分别求其中的关联系数，并对其进行显著性验证。其数据如如表 4-13 所示。

表 4-13 斯皮尔曼相关系数与显著性系数

		脑室引流	止血治疗	降颅压治疗	降压治疗	镇静、镇痛治疗	止吐护理	营养神经	血肿体积变化	水肿体积变化
脑室引流	相 关 系 数	1.000	-0.077	-0.055	0.075	-0.012	0.044	0.052	-0.139	0.088
	显 著 性(双 尾)	.	0.499	0.585	0.461	0.907	0.661	0.610	0.169	0.387
止血治疗	相 关 系 数	-0.077	1.000	0.458**	0.300**	0.058	-0.091	0.020	0.088	0.197*
	显 著 性(双 尾)	0.449	1.000	.	0.002	0.564	0.370	0.843	0.384	0.050
降颅压治疗	相 关 系 数	-0.055	0.458**	1.000	0.352**	-0.039	0.038	0.005	0.038	0.307**
	显 著 性(双 尾)	0.585	1.000	.	1.000	0.698	0.704	0.962	0.706	0.002
降压治疗	相 关 系 数	0.075	0.300**	0.352**	1.000	0.083	-0.052	0.128	0.042	0.236*
	显 著 性(双 尾)	0.461	0.002	1.000	.	0.414	0.608	0.205	0.677	0.018
镇 静 、	相 关 系 数	-0.012	0.058	-0.039	0.083	1.000	0.419**	0.200*	0.063	0.117

镇痛治疗	显著性(双尾)	0.907	0.564	0.698	0.414	.	1.000	0.046	0.536	0.247
	相关系数	0.044	-0.091	0.038	-0.052	0.419*	1.000	0.263**	0.074	-0.031
止吐护理	显著性(双尾)	.661	.370	.704	.608	.000	.	.008	.464	.756
	相关系数	0.052	0.020	0.005	0.128	0.200*	0.263**	1.000	0.175	0.122
营养神经	显著性(双尾)	0.610	0.843	0.962	0.205	0.046	0.008	.	0.082	0.227
	相关系数	-0.139	0.088	0.038	0.042	0.063	0.074	0.175	1.000	.336**
血肿体积变化	显著性(双尾)	0.169	0.384	0.706	0.677	0.536	0.464	0.082	.	0.001
	相关系数	0.088	0.197*	0.307**	0.236*	0.117	-0.031	0.122	0.336**	1.000
水肿体积变化	显著性(双尾)	0.387	0.050	0.002	0.018	0.247	0.756	0.227	0.001	.
	相关系数									




图 4-11 形状特征 LeastAxisLength 分布

根据模型求解出的数据进行绘制出可视化热力图，通过图 4-11 可得：

（1）对血肿体积的影响：水肿体积>营养神经>止吐护胃>镇静、镇痛治疗>降压治疗>降颅压治疗>止血治疗>脑室引流

（2）对水肿体积的影响：血肿体积>降颅压治疗>降压治疗>止血治疗>营养神经>镇静、镇痛治疗>脑室引流>止吐护胃

根据以上分析可以直观分析出适合于患者的情况的治疗方法。

5. 问题三建模的分析与求解

5.1. 问题三（a）建模的分析与求解

题目中说明需要根据前 100 个患者的个人史、疾病史、发病相关及首次影像结果来构建预测模型来预测所有患者 90 天的 mRS 评分，该类问题类似与问题一（b）的预测问题。则考虑利用机器学习的方法，用所给数据集进行训练，故同问题一一样需要对数据集进行一系列的数据预处理操作，将原始数据转换为更适合机器学习模型的形式。通过之前整合的数据 S_{merged} 、 X_{merged} 以及归一化处理后的 $Sheet_1'$ 、 $Sheet_3'$ 。问题三的研究思路由图 5-1 所示。




图 5-1 问题三研究思路图

5.1.1. 数据处理与基于 BP 神经网络模型建立

（1）数据标准化与归一化

通过利用问题一处理后的特征数据，其余缺失值和异常值的处理过程与问题一相同。

（2）基于灰色关联度对变量处理

灰色关联分析是一种用于研究变量之间关联程度的方法，尤其适用于在样本数据有限或者数据质量较差的情况下进行分析。本题需要预测所有患者 90 天的 mRS 评分，计算前 100 个患者的个人史、疾病史、发病相关及首次影像信息结果中的 53 个特征计算与 90 天的 mRS 评分的关联度。把所有的特征分为离散型和连续性，分别进行关联度的计算，根据前面的工作通过确定分析数量、对变量进行去量纲化，计算关联系数：

$$\varepsilon_i(k) = \frac{\min_i \min_k |x_0(k) - x_i(k)| + \rho \cdot \max_i \max_k |x_0(k) - x_i(k)|}{|x_0(k) - x_i(k)| + \rho \cdot \max_i \max_k |x_0(k) - x_i(k)|} \quad (5-1)$$

$$\varepsilon_i(k) = \frac{\min_i \min_k \Delta_i(k) + \rho \max_i \max_k \Delta_i(k)}{\Delta_i(k) + \rho \max_i \max_k \Delta_i(k)} \quad (5-2)$$

其中 $\rho \in (0, \infty)$ 为分辨系数，其值越小分辨相关性的能力越好，通常取 $\rho = 0.5$ 。

计算关联度，其公式为： $r_{0i} = \frac{1}{m} \sum_{k=1}^m \varepsilon_i(k)$ 。最后所得的关联度数值分布如如图 5-2 和图 5-3 所示，根据所有的特征相关度进行排序选择，在已知的 35 个连续性特征和 16 个离散型特征，分别选择 10 个连续性和 5 个离散性，筛选的结果如表 5-1 所示。




图 5-2 离散特征值与患者 90 天 mRS 评分之间关联度




图 5-3 连续特征值与患者 90 天 mRS 评分之间关联度

表 5-1 筛选所得 15 个特征变量

特征变量		
脑出血前 mRS 评分	糖尿病史	房颤史
冠心病史	脑室引流	MajorAxisLength
Maximum2DDiameterColumn	Maximum2DDiameterRow	Maximum2DDiameterSlice
Maximum3DDiameter	MinorAxisLength	MeanAbsoluteDeviation
Range	Uniformity	Variance

(3) BP 神经网络预测

BP 神经网络，也称为反向传播神经网络（Backpropagation Neural Network），是一种

常见的人工神经网络类型，用于解决各种监督学习问题，特别是回归和分类问题。BP 神经网络通过学习从输入到输出之间的映射关系，它的名称源于它的训练算法中的反向传播过程。它的学习规则是使用最速下降法，通过反向传播来不断调整网络的权值和阈值，使网络的误差平方和最小。其最主要的特点就是：信号是正向传播的，而误差是反向传播的。

如图 5-4 是 BP 神经网络的结构图，BP 神经网络由多层神经元组成，通常包括输入层、隐藏层（可以有多个隐藏层）和输出层。每个神经元接受来自前一层神经元的输入，并产生输出，并且每个神经元接收来自其他神经元的是带有权重的输入信号，通过将它们相加，形成总输入值。然后，这个总输入值与神经元的阈值进行比较，类似于模拟阈值电位。接下来，通过一个激活函数对总输入值进行处理，模拟细胞的激活过程，最终得到输出。这个输出会传递给下一层神经元，依此类推，实现信息在神经网络中逐层传递。图 5-5 为其算法的具体实现过程。




图 5-4 BP 神经网络的结构图

该算法的运行步骤如下：




图 5-5 BP 神经网络算法流程

(a) 将训练数据传递给网络，计算预测结果。

其中输入的向量 $X = (x_1, x_2, \dots, x_i, \dots, x_m)$ ，为通过灰色关联分析筛选的特征变量， $Y = (y_1, y_2, \dots, y_k, \dots, y_n)$ 为输出向量。每个神经元正向传播过程中其计算过程为每一层传递的数值乘以对应的权重再加上相应的偏置变量，偏置变量就是选择的激活函数。激活函数的目的是在模型中引入非线性特征，因为无论神经网络有多少层，在没有激活函数的情况下，最终得到的都是一个线性映射，这样对结果的分析就不够准确。

从输入层到隐藏层：

$$\alpha_h = \sum_{i=1}^d v_{ih} x_i + \theta_h \quad (5-3)$$

从隐藏层的输出层：

$$\beta_j = \sum_{h=1}^q w_{hj} b_h + \theta_j \quad (5-4)$$

(b) 计算预测结果与实际目标值之间的误差。

由于计算参数是随机的，所以需要通过多次训练，并根据误差调整参数，从而达到最好的拟合效果。误差函数用来衡量输出结果与期望输出的差距， $d(i)$ 为对应 $x(i)$ 其具体函数为：

$$E = \frac{1}{p} \sum_{i=1}^p E(i) \quad (5-5)$$

其中 $E(i)$ 为单个特征变量样本的训练误差为：

$$E(i) = \frac{1}{2} \sum_{k=1}^n (d_k(i) - y_k(i))^2 \quad (5-6)$$

因此全局误差函数：

$$E = \frac{1}{2p} \sum_{i=1}^p \sum_{k=1}^n (d_k(i) - y_k(i))^2 \quad (5-7)$$

(c) 对于每个权重按照梯度下降法使更新权重。

$$w_{ij} = w_{ij} - \alpha \frac{\partial E}{\partial w_{ij}} \quad (5-8)$$

其中 α 为学习率，通过学习率可以调整每次更新的步幅，合适的学习率可以让模型在合适的时间内收敛。如果学习率设置的太小，可能导致收敛的，计算效率十分低；如果学习率设置的太大，结果会在最优值附近一直反复更新徘徊，难以收敛，一般取值 0.01-0.8。

(d) 重复以上步骤直到达到停止条件（如达到最大迭代次数或误差足够小）。

5.1.2. 问题三（a）模型的求解

在使用 BP 神经网络训练分析后，选择训练次数为 1000 次，学习率 $\alpha=0.01$ ，训练目标最小误差设置为 0.00001。通过多次训练后如图 5-5 为训练所得的曲线，在前 100 例患者数据中，选择了前 80 个进行训练，后 20 个进行测试。最后对所有的患者 90 天 mRS 评分进行预测。




图 5-6 BP 神经网络的预测值与实际值对比图

根据题中所给条件，发病后 90 天 mRS 评分是一个 0-6 的有序等级变量，用于评估卒中后患者功能状态的重要指标。由于预测的值是处于一个[0,6]的区间范围，所需要对结果

进行阈值分析，通过统计 160 名患者基于首次影像信息预测的 90 天 mRS 评分，并用 m 表示所得的预测值，填入答案表数据如下（5-9）。

$$\text{Sheet_4}_{\text{I列}} = 90 \text{ 天 mRS 评分} = \begin{cases} 0, & m < 0.5 \\ 1, & 0.5 \leq m < 1.5 \\ 2, & 1.5 \leq m < 2.5 \\ 3, & 2.5 \leq m < 3.5 \\ 4, & 3.5 \leq m < 4.5 \\ 5, & 4.5 \leq m < 5.5 \\ 6, & m \geq 5.5 \end{cases} \quad (5-9)$$

5.2. 问题三（b）建模的分析与求解

本题需要根据前 100 个患者的所有已知临床、治疗结果，预测所有含随访影像检查的患者。则需要整合所有的表 1、表 2 和表 3 的特征变量，包括患者个人史、治疗方法、疾病史、首次和随访的所有影像信息，统一进行统计分析。

5.2.1. 数据的处理与整合

（1）血肿/水肿位置数据处理

需要对血肿/水肿位置数据进行一定的处理，才能使得血肿/水肿位置的关系能够应用于所有特征变量之间的统计分析。本文将血肿/水肿位置比例系数作为权重，与相应检查中的 HM_volume 和 ED_volume 相乘，从而得到脑部各个位置血肿/水肿的发生情况。进而可以分析血肿/水肿位置对患者 90 天 mRS 评分的影响。

脑部位置分别为 ACA_R、MCA_R、PCA_R、Pons_Medulla_R、Cerebellum_R、ACA_L、MCA_L、PCA_L、Pons_Medulla_L、Cerebellum_L 十个位置特征。以 ACA_R 为例，各个脑部为的血肿和水肿体积可以表示为

$$\text{HM_ACA_R}_{\text{i_volume}} = \text{HM_ACA_R_Radio} \times \text{HM_volume}_i \quad (5-10)$$

$$\text{ED_ACA_R}_{\text{i_volume}} = \text{ED_ACA_R_Radio} \times \text{ED_volume}_i \quad (5-11)$$

其中：

i 表示第 i 次随访影像。通过计算以上所有脑部位置的血肿/水肿体积，再通过处理总的血肿体积变化 η 和水肿体积变化 Ψ 的相同方式处理脑部各个位置的变化。并与个人史、治疗方法、疾病史、首次影像信息和随访的所有信息进行整合，从而进行统计分析，预测 sub001-sub100 和 sub131-sub160 号病人的 90 天 mRS 评分。

（2）灰色关联分析

通过统计所有数据集，总共有 72 个特征变量，所以考虑通过灰色关联分析进行降维处理，其中 72 个特征数据统计表见表 5-3。72 个特征选择关联度最高的前 20 个变量作为模型训练的特征数据。

表 5-2 特征序列筛选结果

特征		
单位时间 PCA_R 区域血肿	单位时间 Pons_Medulla_L	单位时间内水肿体积变化

体积变化	区域血肿体积变化	
单位时间 MCA_R 区域水肿 体积变化	单位时间 PCA_R 区域水肿 体积变化	单位时间 Pons_Medulla_R 区域水肿体积变化
单位时间 MCA_L 区域水肿 体积变化	单位时间 PCA_L 区域水肿 体积变化	收缩压
original_shape_LeastA xisLength	original_shape_MajorAxi sLength	original_shape_Maximum2 DDiameterColumn
original_shape_Maximu m2DDiameterRow	original_shape_Maximum2 DDiameterSlice	original_shape_Maximum3 DDiameter
original_shape_MinorA xisLength	original_shape_SurfaceA rea	NCCT_original_firstorde r_Maximum




图 5-7 各个特征变量与 90 天 mRS 评分之间的影响

5.2.2. 问题三（b）模型的求解

经过 BP 神经网络训练对患者 sub001 至 sub100, sub131 至 sub160 号病人进行预测 90 天的 mRS 评价, 预测值用 m 进行表示, 则填入答案表的结果如 (5-12)。




图 5-8 BP 神经网络测试 90 天 mRS 评分图

故最后的结果数据模型表示为:

Sheet_4_{j列} = 90 天 mRS 评分 =

0

, $m < 0.5$

1

, $0.5 \leq m < 1.5$

2

, $1.5 \leq m < 2.5$

3

, $2.5 \leq m < 3.5$

4

, $3.5 \leq m < 4.5$

5

, $4.5 \leq m < 5.5$

6

, $m \geq 5.5$

(5-12)

5.3. 问题三（c）建模的分析与求解

本题需要根据各影响因素与 mRS 评分的关联关系，为出血性脑卒中临床决策提供建议，这些关联关系的分析有助于改善出血性脑卒中患者的护理和治疗，提供更个性化的医疗建议，以提高患者的康复机会和生活质量。这也突显了数据分析和医学领域的交叉合作的重要性，以促进医疗研究和患者护理的不断改进。

5.3.1. 数据处理

(a) 影响因素

根据所提供的数据以及问题一、问题二和问题三的数据分析和建模求解工作，得到了一个庞大的数据集，其中包含了 100 多个潜在影响因素。为了更好地理解出血性脑卒中患者的预后情况，整合了数据集中所有的 72 个特征变量，作为影响血肿/水肿的因素。这些因素具有潜在的与 90 天 mRS 评分相关的特征，涵盖了患者的个人史、疾病史、治疗方法以及多个影像特征，包括血肿/水肿体积、血肿/水肿位置、信号强度特征以及形状特征等。

表 5-3 整合特征变量集合

影响因素		
脑出血前 mRS 评分	高血压病史	卒中病史
糖尿病史	房颤史	冠心病史
吸烟史	饮酒史	脑室引流
止血治疗	降颅压治疗	降压治疗
镇静、镇痛治疗	止吐护胃	营养神经
单位时间血肿体积变化	单位时间内 ACA_R 区域血肿体积变化	单位时间内 MCA_R 区域血肿体积变化
单位时间内 PCA_R 区域血肿体积变化	单位时间内 Pons_Medulla_R 区域血肿体积变化	单位时间内 Cerebellum_R 区域血肿体积变化
单位时间内 ACA_L 区域血肿体积变化	单位时间内 MCA_L 区域血肿体积变化	单位时间内 PCA_L 区域血肿体积变化
单位时间内	单位时间内 Cerebellum_L 区域血肿	单位时间内水肿体积变化

Pons_Medulla_L 区域血肿 体积变化	体积变化	
单位时间内 ACA_R 水肿体 积变化	单位时间内 MCA_R 水肿体积变化	单位时间内 PCA_R 水肿体积变 化
单位时间内 Pons_Medulla_R 水肿体积 变化	单位时间内 Cerebellum_R 水肿体积 变化	单位时间内 ACA_L 水肿体积变 化
单位时间内 MCA_L 水肿体 积变化	单位时间内 PCA_L 水肿体积变化	单位时间内 Pons_Medulla_L 水 肿体积变化
单位时间内 Cerebellum_L 水肿体积变化	年龄	发病到首次影像检查时间间隔
收缩压	舒张压	original_shape_Elongation
original_shape_Flatnes s	original_shape_LeastAxisLength	original_shape_MajorAxisLen gth
original_shape_Maximum 2DDiameterColumn	original_shape_Maximum2DDiamete rRow	original_shape_Maximum2DDia meterSlice
original_shape_Maximum 3DDiameter	original_shape_MeshVolume	original_shape_MinorAxisLen gth
original_shape_Spheric ity	original_shape_SurfaceArea	original_shape_SurfaceVolum eRatio
original_shape_VoxelVo lume	NCCT_original_firstorder_10Perc entile	NCCT_original_firstorder_90 Percentile
NCCT_original_firstord er_Energy	NCCT_original_firstorder_Entrop y	NCCT_original_firstorder_In terquartileRange
NCCT_original_firstord er_Kurtosis	NCCT_original_firstorder_Maximu m	NCCT_original_firstorder_Me anAbsoluteDeviation
NCCT_original_firstord er_Mean	NCCT_original_firstorder_Median	NCCT_original_firstorder_Mi nimum
NCCT_original_firstord er_Range	NCCT_original_firstorder_Robust MeanAbsoluteDeviation	NCCT_original_firstorder_Ro otMeanSquared
NCCT_original_firstord er_Skewness	NCCT_original_firstorder_Unifor mity	NCCT_original_firstorder_Va riance

(b) 灰色关联度分析

灰色关联度分析是一种多变量分析方法，用于研究不同因素之间的关联关系。本文采用灰色关联度分析来理清这 72 项高质量影响因素对出血性脑卒中预后的影响，通过量化这些因素与患者 90 天 mRS 评分之间的关联程度，识别出对患者的预后产生重要影响因素，并根据此提出可能的干预措施。




图 5-9 各特征值与患者 90 天 mRS 评分之间的关联度

5.3.2. 数据分析

(a) 各因素影响分析

灰度关联度越高，表示这些因素之间可能存在着较强的因果或相关性关系，其中一个因素的变化可能会引起另一个因素的变化。根据图 5-6 各特征值与患者 90 天 mRS 评分之间的关联度对各因素影响力进行分析。从图中可以分析出，所有特征值的灰色关联度都大于 0.5，说明这 72 项高质量影响因素对出血性脑卒中预后的影响都较大，但是这些特征值之间也存在关联度的高度。可以按照 0.05 为一个区间，将特征值分为 5 个梯度。

第一梯度特征值的灰色关联度在 0.70 到 0.75 之间，介于该区间内的 16 个影响因素对值对出血性脑卒中的影响力最高，如单位时间内 HM_PCA_R_Ratio 血肿体积变化、单位时间呢 iHM_Pons_Medulla_L_Ratio 血肿体积变化、单位时间内水肿体积变化、单位时间内 ED_MCA_R_Ratio 水肿体积变化、单位时间内 ED_PCA_R_Ratio 水肿体积变化等。这些因素是研究出血性脑卒中过程中的重点关注对象，对于治疗有着重要的帮助。

表 5-4 第一梯度（灰色关联度：0.70-0.75）影响因素

第一梯度（灰色关联度：0.70-0.75）影响因素	
单位时间内 HM_PCA_R_Ratio	单位时间内 HM_Pons_Medulla_L_Ratio 血肿体 积变化
单位时间内水肿体积变化	单位时间内 ED_MCA_R_Ratio 水肿体积变化

单位时间内 ED_PCA_R_Ratio 水肿体积变化

单位时间内 ED_MCA_L_Ratio 水肿体积变化

单位时间内 ED_PCA_L_Ratio 水肿体积变化

original_shape_LeastAxisLength

original_shape_MajorAxisLength

original_shape_Maximum2DDiameterColumn

original_shape_Maximum2DDiameterRow

original_shape_Maximum2DDiameterSlice

original_shape_Maximum3DDiameter

original_shape_MinorAxisLength

NCCT_original_firstorder_Maximum

NCCT_original_firstorder_Variance

第二梯度特征值的灰色关联度在 0.65 到 0.70 之间，介于该区间内的 24 个影响因素对值对出血性脑卒中的影响力较高，如单位时间血肿体积变化、单位时间内 ED_Pons_Medulla_R_Ratio 水肿体积变化、年龄、收缩压、舒张压等。位于该梯度内的影响因素占比最高，这些因素也是出血性脑卒中预后预测应重点关注的对象。

表 5-5 第二梯度（灰色关联度：0.65-0.70）影响因素

第二梯度（灰色关联度：0.65-0.70）影响因素	
单位时间血肿体积变化	单位时间内 ED_Pons_Medulla_R_Ratio 水肿体积变化
年龄	收缩压
舒张压	original_shape_Elongation
original_shape_Flatness	original_shape_MeshVolume
original_shape_Sphericity	original_shape_SurfaceArea
original_shape_VoxelVolume	NCCT_original_firstorder_10Percentile
NCCT_original_firstorder_90Percentile	NCCT_original_firstorder_Energy
NCCT_original_firstorder_Entropy	NCCT_original_firstorder_InterquartileRange
NCCT_original_firstorder_Kurtosis	NCCT_original_firstorder_MeanAbsoluteDeviation
NCCT_original_firstorder_Mean	NCCT_original_firstorder_Median
NCCT_original_firstorder_Minimum	NCCT_original_firstorder_Range
NCCT_original_firstorder_RobustMeanAbsolut	NCCT_original_firstorder_RootMeanSquared

eDeviation

NCCT_original_firstorder_Skewness

NCCT_original_firstorder_Uniformity

第三梯度特征值的灰色关联度在 0.60 到 0.65 之间，介于该区间内的 10 个影响因素对值对出血性脑卒中的影响力中等，如糖尿病史、冠心病史、脑室引流、单位时间内 HM_Pons_Medulla_R_Ratio、HM_PCA_L_Ratio 血肿体积变化等。这些因素可以在前两个梯度的高影响力影响因素的基础上起辅助预后预测的作用，值得关注。

表 5-6 第三梯度（灰色关联度：0.60-0.65）影响因素

第三梯度（灰色关联度：0.60-0.65）影响因素	
糖尿病史	冠心病史
脑室引流	单位时间内 HM_Pons_Medulla_R_Ratio 水肿体积变化
单位时间内 HM_PCA_L_Ratio 血肿体积变化	单位时间内 ED_ACA_R_Ratio 水肿体积变化
单位时间内 ED_ACA_L_Ratio 水肿体积变化	发病到首次影像检查时间间隔
original_shape_SurfaceVolumeRatio	

第四梯度和第五梯度的灰色关联度分别在 0.55 到 0.60、0.50 到 0.55 之间，介于该区间内的影响因素对出血性脑卒中的影响力较低，如高血压病史、饮酒史、止血治疗、降压治疗等，这些因素在条件允许的情况下也可纳入考虑范围，但不是预后预测的重点关注对象。

表 5-7 第四梯度（灰色关联度：0.55-0.60）影响因素

第四梯度（灰色关联度：0.55-0.60）影响因素	
高血压病史	饮酒史
止血治疗	降压治疗
止吐护胃	营养神经
单位时间内 HM_Cerebellum_R_Ratio 血肿体积变化	单位时间内 HM_Cerebellum_L_Ratio 血肿体积变化
单位时间内 ED_Cerebellum_R_Ratio 水肿体积变化	单位时间内 ED_Cerebellum_L_Ratio 水肿体积变化

表 5-8 第五梯度（灰色关联度：0.50-0.55）影响因素

第五梯度（灰色关联度：0.50-0.55）影响因素	
脑出血前 mRS 评分	卒中病史
房颤史	吸烟史
降颅压治疗	镇静、镇痛治疗
单位时间内 HM_ACA_R_Ratio 血肿体积变化	单位时间内 HM_MCA_R_Ratio 血肿体积变化
单位时间内 HM_ACA_L_Ratio 血肿体积变化	单位时间内 HM_MCA_L_Ratio 血肿体积变化

（b）治疗干预措施分析

针对第一梯度内影响力最高的 16 个影响因素，提出如下几个方面的预后预防措施：

1. 脑出血区域的控制：控制出血扩散的速度可能有助于减少脑组织受损的范围。针对高速扩散的区域，可以考虑局部止血治疗。
2. 水肿管理：针对脑组织的水肿，及时的脱水治疗和神经保护措施可能有助于减轻脑损伤。
3. 形状特征分析：形状特征的分析可以帮助医生更好地理解出血的类型和扩散情况，从而指导治疗策略。
4. 高血压和血压管理：高血压是脑出血的一个重要危险因素，积极管理高血压可能降低出血风险。
5. 个体化治疗：患者的情况因人而异，因此治疗策略应该根据患者的个体情况进行定制化，包括治疗方法的选择和时机。
6. 密切监测和随访：对出血性脑卒中患者的预后情况需要进行定期的临床监测和随访，以及时调整治疗方案。

针对第二梯度内的影响力较高的 24 个因素，提出如下几个方面的预后预防措施：

1. 控制高血压：高血压是脑卒中的重要危险因素之一。患者应定期测量血压，并遵循医生的建议，采取药物治疗或生活方式改变来控制高血压。
2. 年龄管理：年龄是脑卒中风险的非可逆因素。尽管无法改变年龄，但在老年患者中，应特别注意脑卒中的预防和管理。
3. 药物管理：对于高风险患者，如有医生建议，可能需要采取抗凝血药物或抗血小板药物来降低血栓形成的风险。

针对第三梯度内影响力中等的 10 个影响因素，提出如下几个方面的预后预防措施：

1. 病史管理：对于患有各种疾病特别的具有糖尿病史、冠心病史的患者，应该控制相关病的风险因素管理，做好定期检查，以减少血管损伤和脑出血的风险。
2. 脑室引流风险评估：对于需要脑室引流的患者，医生应仔细评估治疗的必要性，并确保引流过程安全无误。患者需要接受定期的医学监测和随访。

3. 发病到首次影像检查时间间隔：尽早进行首次影像检查可以更早地发现脑卒中病变，有助于早期干预和治疗。

针对第四梯度和第五梯度中影响力较低的影响因素，尽管它们在预后中的作用相对较小，但仍然具有一定的辅助作用，特别是在制定个性化的治疗方案时。这些因素虽然不是主要的决定性因素，但在考虑整体治疗策略时应被纳入考虑。

总之，在跨学科团队的协作和大规模数据分析的支持下，应深入分析患者综合临床数据、医学影像、实验室检查和患者历史等多方面信息，以提高出血性脑卒中患者的预后。同时，患者也应积极配合医疗建议，采取健康的生活方式，以降低脑卒中发生和预后恶化的风险。

6. 问题解决的模型评价与改进

6.1. 模型的优点

(1) 本文针对于病人信息进行了合理而仿真的模型建立，将复杂的个人健康状况抽象为易于处理的直观数据，如病人的年龄、性别、过往病史及影像检查信息等。这样的模型能够节约大量的时间和人力成本，从而为后续的数据处理打下了良好的基础。

(2) 本文采用了离散化处理、归一化处理等多种处理方式，来进行数据分析和归纳。一方面能够从多种角度更加科学地分析数据，确保结果更贴近现实；另一方面也弥补了数据缺失等异常情况，确保分析结果的可靠性。

(3) 本文对于模型的建立上采取了规范化的数学分析，对于单一的患者，不仅从静态维度分析了患者的身体情况，而且从动态维度分析了患者在发病过程中的数据变化，还利用了深度学习的方法进行科学的预测。

(4) 本文采用搭建多元线性回归模型的方式，利用多元回归模型分析模型的拟合系数，从而对不同治疗方法对水肿体积变化的影响做出判断，以便于得出不同治疗方式在不同场景下的治疗效果。

(5) 本文通过合理的建模和数据处理，基于灰色关联分析的方法，经过数据标准化、建立灰色关联度矩阵、确定关联系数、排序和分析等步骤，筛选出关联度最高的特征变量。

6.2. 模型的缺点

本文的一切模型建立和数据分析，都是建立题目所给的数据集基础上。虽然本次研究的方法严格按照了规范，但由于数据对象样本较小，可能存在一定的偶尔性和偏差的缘故，最后的模型与实际应用场景还存在一定的差距。

参考文献

- [1]鲁伟,向建平.人工智能在脑血管疾病诊疗中的相关应用[J].人工智能,2021(03):72-78.DOI:10.16453/j.cnki.ISSN2096-5036.2021.03.008.
- [2]陈真诚,蒋勇,胥明玉,等.人工智能技术及其在医学诊断中的应用及发展[J].生物医学工程学杂志,2002,19(3):505-509.
- [3]陈华,张倩,王照丽等.基于主成分分析与聚类分析的水质综合评价研究[J].科技创新与应用,2023,13(26):88-92.DOI:10.19981/j.CN23-1581/G3.2023.26.020.
- [4]李倩,刘芸宏,吴晓慧等.基于决策树和 Logistic 回归预测出血性脑卒中手术后医院感染风险[J].中华医院感染学杂志,2021,31(23):3556-3561.
- [5]韩冬,李其花,蔡巍,等.人工智能在医学影像中的研究与应用[J].大数据,2019,5(1):2019004.
- [6]刘思峰.灰色关联分析模型研究进展.系统工程理论与实践 33.8 (2013): 2041-2046
- [7]张思琪,杨添淞,马帅等.深度学习在脑卒中诊断与防治中的研究进展[J].磁共振成像,2022,13(11):125-128.
- [8]欧艳艳.基于多元回归分析的公共图书馆婴幼儿阅读服务体验评估体系的建立与影响因素量化分析[J].河南图书馆学刊,2023,43(09):35-39.
- [9]沈志慧,杨廷琴,吴江等.出血性与缺血性脑卒中发病特征与危险因素的对比分析[J].中国医药指南,2023,21(23):66-68.DOI:10.15912/j.cnki.gocm.2023.23.022.
- [10]张晓林.基于机器学习的首发缺血性脑卒中患者1年复发危险因素及预测研究[D].南昌大学,2023.DOI:10.27232/d.cnki.gnchu.2022.000640.
- [11]李萍,曾令可,税安泽,等.基于 MATLAB 的 BP 神经网络预测系统的设计[J].计算机应用与软件,2008,25(4):149-150.
- [12]Chang P D, Kuoy E, Grinband J, et al. Hybrid 3D/2D convolutional neural network for hemorrhage evaluation on head CT[J]. American Journal of Neuroradiology, 2018, 39(9): 1609-1616.
- [13]Yihao C, Shengpan C, Jianbo C, et al. Perihematoma Edema After Intracerebral Hemorrhage: An Update on Pathogenesis, Risk Factors, and Therapeutic Advances[J]. Frontiers in Immunology, 2021, 12.
- [14]Kurita, Takio. "Principal component analysis (PCA)." Computer Vision: A Reference Guide (2019): 1-4.

附录一

```
1.  #数据预处理 Matlab 代码
2.  clc
3.  clear all
4.  [num,txt,row] = xlsread('time.xlsx');
5.  [n,m]=size(row);
6.  a=ones(160,1);
7.  for i=1:160
8.      time_vecs=datevec(string(row(i,2)));
9.      start_date=datenum(time_vecs);
10.     for j=3:14
11.         hours=-100000;
12.         if string(row(i,j))=="NaT"
13.             break ;
14.         else
15.             time_vec = datevec(string(row(i,j)));
16.             serial_date = datenum(time_vec);
17.             hours = (serial_date - start_date) * 24;%获得日期对应时
间做差值
18.         end
19.         if hours ~= -100000&&hours+num(i,1)<=48.00%提取 48 小时内水肿
体积数据
20.             a(i)=j-1;
21.         else
22.             break;
23.         end
24.     end
25. end
26. a
27. #正态分布:
28. clc;
29. clear all;
30. [numm,txt,row]=xlsread('归一化后的 160 个特征数据.xlsx');
31. c=numm;
32. for k=2:32
33.     b=numm(1:160,k)
34.     b=b';
35.     aa=mean(b);
36.     sig=std(b); %算出 x 的标准偏差。
37.     m=zeros(1,length(b));
38.     i=1;
39.     for t=1:length(b)
```

```

40.         m(t)=abs(b(t)-aa);
41.         if m(t)>3*sig
42.             n(t)=aa;%异常值使用均值代替
43.             num(i)=b(t);
44.             i=i+1;
45.         else
46.             n(t)=b(t);
47.         end
48.     end
49.     bb=0:1:length(n)-1;
50.     subplot(2,1,1);
51.     plot(bb,b)
52.     title('原特征数据分布')
53.     subplot(2,1,2);
54.     plot(bb,n);
55.     c(1:100,k)=n(1:100);
56.     title('拉依达准则均值处理异常点后特征数据分布')
57.     xlabel('特征索引');
58.     ylabel('特征数值')
59. end
60. c
61. #箱型图:
62. clc
63. clear all
64. close all
65. [num,txt,row] = xlsread('归一化后的 160 个特征数据.xlsx');
66. x = num(1:160,2:32);
67. for i=1:31
68.     y(i)='特征'+string(i);
69. end
70. figure
71. subplot(2,1,1)
72. boxplot(x, 'Labels', y,'LabelOrientation', 'inline')
73. subplot(2,1,2)
74. boxplot(x, 'Labels',y,'PlotStyle','compact')
75. x1=quantile(x,.25);
76. x3=quantile(x,.75);
77. x1;
78. x3;
79. a=zeros(160,32);
80. a(1:160,1)=num(1:160,1);
81. for i=1:160
82.     for j=1:31

```

```

83.         if x(i,j)>x3(j)+1.5*(x3(j)-x1(j))||x(i,j)<x1(j)-1.5*(x3(j)
-x1(j))
84.             a(i,j+1)=1;%标记异常点
85.         else a(i,j+1)=0;
86.     end
87. end
88. end
89. c=zeros(160,32);
90. c(1:160,1)=num(1:160,1);
91. for i=2:32
92.     total=0.0;
93.     sum=0.0;
94.     for j=1:160
95.         if a(j,i)==0
96.             total=total+num(j,i);
97.             sum=sum+1;
98.         end
99.     end
100.    total=total/sum;
101.    total
102.    for j=1:160
103.        if a(j,i)==1
104.            c(j,i)=total;%异常值按均值替代
105.        else
106.            c(j,i)=num(j,i);
107.        end
108.    end
109. end

```

```

1.    %CNN 神经网络 Matlab 代码
2.    clc;clear;close all
3.    [num,txt,row] = xlsread('灰色关联前五数据(第一题).xlsx');
4.    n=100;
5.    train_x=num(1:80,1:15);
6.    train_y=num(1:80,16);
7.    test_x=num(81:100,1:15);
8.    test_y=num(81:100,16);
9.    train_x=train_x';
10.   train_y=train_y';
11.   test_x=test_x';
12.   test_y=test_y';
13.   %改
14.   pre_x=num(1:160,1:15);

```

```

15. pre_x=pre_x';
16. %
17. method=@mapminmax;
18. % method=@mapstd;
19. [train_x,train_ps]=method(train_x);
20. test_x=method('apply',test_x,train_ps);
21. %改
22. pre_x=method('apply',pre_x,train_ps);
23. %
24. [train_y,output_ps]=method(train_y);
25. test_y=method('apply',test_y,output_ps);
26. trainD=reshape(train_x,[15,1,1,80]);%训练集输入
27. testD=reshape(test_x,[15,1,1,20]);%测试集输入
28. %改
29. pre_x=reshape(pre_x,[15,1,1,160]);
30. %
31. targetD = train_y;%训练集输出
32. targetD_test = test_y;%测试集输出
33. layers = [
34.     imageInputLayer([15 1 1]) %输入层参数设置
35.     convolution2dLayer([3,1],16,'Padding','same')%设置卷积核函数
36.     reluLayer%relu 激活函数
37.     maxPooling2dLayer([2 1],'Stride',2)
38.     fullyConnectedLayer(384) %全连接层神经元
39.     reluLayer%relu 激活函数
40.     fullyConnectedLayer(384) %全连接层神经元
41.     fullyConnectedLayer(1) % 输出层神经元
42.     regressionLayer];%添加回归层
43. options = trainingOptions('adam', ...
44.     'MaxEpochs',60, ...
45.     'MiniBatchSize',16, ...
46.     'InitialLearnRate',0.01, ...
47.     'GradientThreshold',1, ...
48.     'Verbose',false,...
49.     'Plots','training-progress',...
50.     'ValidationData',{testD,targetD_test});
51. % 训练
52. net = trainNetwork(trainD,targetD',layers,options);
53. % 预测
54. YPred = predict(net,testD);
55. % 结果
56. YPred=double(YPred');
57. % 反归一化

```

```

58. predict_value=method(YPred,0,1);predict_value=double(predict_value)
;
59. true_value=method(targetD_test,0,1);true_value=double(true_value);
60. %预测所有
61. pre_y = predict(net,pre_x);
62. pre_y=double(pre_y');
63. pv=method(pre_y,0,1);pv=double(pv);
64. %true_value=method(targetD_test,output_ps);true_value=double(true_
value);
65. pv=pv';
66. pv
67. %
68. figure
69. plot(true_value,'-*','linewidth',3)
70. hold on
71. plot(predict_value,'-s','linewidth',3)
72. legend('实际值','预测值')
73. grid on

```

```

1. #BP 神经网络 Matlab 代码
2. clear
3. close all
4. clc
5. [num,txt,row] = xlsread('特征数据.xlsx');
6. input=num(1:130,1:17); %载入输入数据
7. output=num(1:130,18); %载入输出数据
8. input_train = input(1:80,:);
9. output_train =output(1:80,:);
10. input_test = input(1:130,:);
11. output_test =output(1:130,:);训练预测数据
12. inputnum=2;
13. hiddennum=5;
14. outputnum=1; %节点个数
15. [inputn,inputps]=mapminmax(input_train);%归一化到[-1,1]之间, inputps
用来作下一次同样的归一化
16. [outputn,outputps]=mapminmax(output_train);
17. net=newff(inputn,outputn,hiddennum,{ 'tansig', 'purelin'}, 'trainlm');
% 模型建立
18. W1= net. iw{1, 1};
19. B1 = net.b{1};
20. W2 = net.lw{2,1};
21. B2 = net. b{2};各层阈值设置
22. net.trainParam.epochs=1000;

```

```

23. net.trainParam.lr=0.01;
24. net.trainParam.goal=0.00001;
25. net=train(net,inputn,outputn);
26. inputn_test=mapminmax('apply',input_test,inputps);%神经网络参数配置
27. an=sim(net,inputn_test);
28. test_simu=mapminmax('reverse',an,outputps); %反归一化
29. for i=1:130
30.     if test_simu(1,i)<=0.5
31.         test_simu(1,i)=0;
32.     else if test_simu(1,i)<=1.5
33.         test_simu(1,i)=1;
34.     else if test_simu(1,i)<=2.5
35.         test_simu(1,i)=2;
36.     else if test_simu(1,i)<=3.5
37.         test_simu(1,i)=3;
38.     else if test_simu(1,i)<=4.5
39.         test_simu(1,i)=4;
40.     else if test_simu(1,i)<=5.5
41.         test_simu(1,i)=5;
42.     else
43.         test_simu(1,i)=6;
44.     end
45. end
46. end
47. end
48. end
49. end
50. end%阈值计算
51. %test_simu
52. % test_simu=test_simu';
53. error=test_simu-output_test; %预测值和真实值的误差
54. figure('units','normalized','position',[0.119,0.2,0.38,0.5]);
55. plot(output_test,'bo-')
56. hold on
57. plot(test_simu,'r*-')
58. hold on
59. %plot(error,'square','MarkerFaceColor','b')
60. legend('期望值','预测值')
61. xlabel('验证集序号')
62. ylim([0 7])
63. ylabel('患者 90 天 mRS 评分')
64. title('BP 神经网络验证集的预测值与实际值对比图')%画图

```



```

1. #热力图 Matlab 代码
2. clc
3. clear all
4. [num,txt,row] = xlsread('热力图数据.xlsx');
5. %correlationmatrix=corrcoef(num);
6. labels={'脑室引流','止血治疗','降颅压治疗','降压治疗','镇静、镇痛治疗',
', '止吐护胃','营养神经','血肿体积变化','水肿体积变化'
7. };
8. h=heatmap(labels,labels,num,'Title','表格型热力图相关系数矩阵');
9. colormap('jet')

```

```

1. #灰色关联分析 Matlab 代码
2. clc;clear;close all;
3. [num,txt,row] = xlsread('72 个特征数据.xlsx');
4. a=zeros(130,73);
5. a(1:130,1)=num(1:130,73);
6. a(1:130,2:73)=num(1:130,1:72);
7. data=a;
8. data1=mapminmax(data',0,1);%标准化
9. data1=data1';
10. data2=abs(data1(:,2:end)-data1(:,1));
11. d_max=max(max(data2));
12. d_min=min(min(data2));
13. %灰色关联矩阵
14. a=0.5; %分辨系数
15. data3=(d_min+a*d_max)./(data2+a*d_max);
16. xishu=mean(data3);
17. yy=[1:72];
18. plot(yy,xishu);
19. set(gca,'fontsize',20);
20. xlabel('特征值序号');
21. ylabel('灰色关联度');
22. title('各特征值与患者 90 天 mRS 评分之间关联度');
23. mark=zeros(1,72);
24. a1=0;
25. b1=0;
26. for i=1:20%获得关联性最强的前 20 个特征数据
27.     a1=-1;
28.     b1=0;
29.     for j=1:72
30.         if mark(1,j)==0&&xishu(1,j)>=a1
31.             a1=xishu(1,j);
32.             b1=j

```

```

33.         end
34.     end
35.     mark(1,b1)=1;
36. end
37. mark

```

```

1.  #K-means 三维聚类 Matlab 代码
2.  clc;
3.  clear all;
4.  [num,txt,row] = xlsread('聚类1.xlsx');
5.  x = num(1:160,1);
6.  y = num(1:160,2);
7.  z = num(1:160,3);
8.  x=x';
9.  y=y';
10. z=z';
11. k = 5;
12. [resX resY resZ record] = Kmean3D(x,y,z,k);%聚类
13. for i = 1:length(record)
14.     scatter3(resX(i,1:record(i)),resY(i,1:record(i)),resZ(i,1:rec
ord(i)), '*', 'LineWidth',1);
15.     hold on
16. end
17. xlabel('年龄');
18. ylabel('收缩压/mmHg');
19. zlabel('舒张压/mmHg');
20. set(gca, 'FontSize',18);
21. for i = 1:length(record)
22.     scatter3(mean(resX(i,1:record(i)),2)',mean(resY(i,1:record(i))
,2)',mean(resZ(i,1:record(i)),2)', 'Marker', 'square', 'MarkerEdgeColor', 'k', '
MarkerFaceColor', 'k')
23. end
24. legend('聚类 1', '聚类 2', '聚类 3', '聚类 4', '聚类 5', '聚类中心点')

```

附录二

答案表数据:

	首次影像检查流水号	问题1: 水肿扩张 是否发生水肿扩张 1是, 0否	水肿扩张时 单位: 小时	水肿扩张预测概率	问题2: 水肿体积进展曲线 残差 (全体)	残差 (亚组)	所属亚组	问题3: 预后预测建模 预测mRS (基于首次影像)	预测mRS
sub001	20161212002136	0	0	0.291620958	-1.745606329	-0.944217928	4	4	3
sub002	20160406002131	0	0	0.339518908	-483.9334029	-121.609346	5	0	2
sub003	20160413000006	1	9.5225	0.602789748	-1.023077814	0.2717255	5	4	5
sub004	20161215001667	0	0	0.493765317	-8.656730269	-30.47720232	3	4	0
sub005	20161222000978	1	26.4675	0.742082037	-1.533220457	0.625560505	2	3	2
sub006	20161110001074	1	47.874444	0.689501526	0.448153244	-0.001700946	2	5	5
sub007	20161208000139	0	0	0.259428726	0.191197874	-0.048201173	4	3	2
sub008	20161219000091	0	0	0.345393508	-88.62789237	-17.03946319	4	2	4
sub009	20161031001987	1	40.056111	0.691383713	-11.37059262	-18.71609496	4	0	3
sub010	20161012002008	1	15	0.692961814	-1.542698627	0.259504196	5	3	3
sub011	20160209000219	0	0	0.31962566	0.950629458	0.0911758	1	1	1
sub012	20161031001142	0	0	0.335123482	0.743533793	-0.339787281	3	3	0
sub013	20161124000397	0	0	0.294587715	0.111147838	-0.090458859	2	1	1
sub014	20160513001799	0	0	0.374292384	0.498801774	0.480090294	1	2	2
sub015	20161013001234	0	0	0.274892272	-2.623916226	-12.28943492	3	4	3
sub016	20161130000004	0	0	0.295488744	-1.111365417	-3.206442737	4	4	5
sub017	20160510002436	1	14.870278	0.667321642	-111.3618499	-275.0019746	4	1	3
sub018	20160602001707	0	0	0.328334521	-11.50096307	-6.062029371	1	0	2
sub019	20160117000135	0	0	0.29258324	-22.95137248	-84.323955	3	1	2
sub020	20160723000013	0	0	0.326086233	0.25383984	0.722872765	2	1	2
sub021	20160317001244	1	29.279722	0.674595659	0.223394148	-0.643700468	4	3	2
sub022	20160803001239	0	0	0.311289385	0.453669877	0.213324512	1	1	1
sub023	20160321000142	0	0	0.256663146	0.432653038	-0.647887721	5	2	2
sub024	20170802000637	0	0	0.316069208	0.552667659	0.452744104	1	0	0
sub025	20171226002293	0	0	0.297951246	-6.11470922	-0.831128772	5	3	2
sub026	20171008000512	0	0	0.304363963	0.447799219	-1.254377989	2	3	3
sub027	20170206000071	0	0	0.25381825	-1.977009937	-0.082029753	1	5	6
sub028	20171013002097	0	0	0.303786697	0.136331304	0.340811285	1	3	1
sub029	20170607000010	0	0	0.28721508	0.042423319	-0.782689862	2	4	3
sub030	20171025000480	0	0	0.295747273	-1225.759808	-636.6099766	5	3	5
sub031	20170307002130	1	4.1683333	0.698382482	0.559413499	0.329069432	4	3	4
sub032	20171009000137	0	0	0.302058775	-3.354950017	-18.2248007	4	0	0
sub033	20170115000362	1	30.813056	0.674500077	-2.812149959	-3.08374623	2	1	1
sub034	20170119000729	0	0	0.34147815	-9.579610892	-30.22346407	4	2	4
sub035	20171014001244	0	0	0.277991575	0.358859975	0.449501965	1	4	4
sub036	20170204001714	1	39.501111	0.680657883	0.827202788	-8.8309453	3	3	3
sub037	20170426000005	0	0	0.288234933	0.119052044	-2.963228285	3	3	2
sub038	20170518002194	1	15.809167	0.617290753	-18.64733698	-15.08479658	4	3	1
sub039	20170425002487	1	29.176111	0.677279326	0.50470866	0.230836046	4	2	2
sub040	20170902000876	0	0	0.278683325	0.295108722	0.569785347	4	0	2
sub041	20171002000282	0	0	0.360893404	0.220589502	-2.400893521	3	3	2
sub042	20170420000636	0	0	0.317324348	-9.306654201	-30.86950336	3	2	1
sub043	20170325000428	0	0	0.299113646	0.337760949	0.329007729	1	4	5
sub044	20170528000084	0	0	0.202176159	-71.06787863	-17.60526667	5	3	3
sub045	20170324001892	0	0	0.290772423	-40.64321659	-211.4775137	4	1	1
sub046	20170511000016	0	0	0.343830406	0.299631675	-2.365252886	3	3	2
sub047	20171019001652	0	0	0.356303403	0.461572053	-1.195521535	4	1	1
sub048	20170402000556	1	12.860833	0.670472652	-2.249387586	-0.238355762	5	2	3
sub049	20171005000770	0	0	0.295637324	-1.018112756	0.545501004	4	1	1
sub050	20171105000372	0	0	0.282184777	-34.30655261	-2.090716967	2	1	1
sub051	20170422000935	0	0	0.355239382	0.364214423	0.623523612	1	2	2
sub052	20170608001310	0	0	0.325432403	-50.56538364	-56.66767354	1	3	5
sub053	20170511001392	0	0	0.295686433	-24.83871846	-5.966732255	2	4	3
sub054	20170612002216	1	16.225	0.575789228	-5.693811194	-33.0276414	4	2	3
sub055	20170316001977	0	0	0.380175717	0.609759275	0.233019819	2	3	3
sub056	20170120000152	1	25.538611	0.717378152	-11.21100853	-36.3639147	3	4	2
sub057	20170825001844	1	14.615833	0.709220329	-7.23555759	-80.19813322	1	3	3
sub058	20170125000984	0	0	0.308466195	-6.826487181	-12.02365734	1	5	5
sub059	20170912002314	0	0	0.333214564	-1.02521099	-0.474495825	1	0	2
sub060	20180109000613	1	23.726111	0.606979849	0.221917272	-2.44472304	4	4	3
sub061	20180226000725	1	6.5416667	0.763130128	-1.231774114	-7.509215399	4	4	5
sub062	20181221002264	1	18.293889	0.705540994	-25.36878348	-61.02793113	4	2	2
sub063	20181020001229	0	0	0.286169011	0.378236638	-0.38615179	5	2	2
sub064	20180801000501	0	0	0.375045679	-34.26066818	-37.19555641	1	3	1
sub065	20180131001727	0	0	0.340622432	0.610506714	0.924885355	2	3	2
sub066	20181208000909	0	0	0.352197417	0.281093616	0.411295095	1	5	6
sub067	20181207001317	0	0	0.32523058	0.310402053	-3.069955184	3	2	2
sub068	20180412001426	0	0	0.312711594	-4.82430875	0.256655908	4	3	2
sub069	20180619001505	1	45.276389	0.68675729	0.655116578	-0.26976435	1	3	2
sub070	20180427000292	1	9.6533333	0.735568595	-2.868225933	-2.1252536	1	2	3
sub071	20181103001264	0	0	0.293682307	0.781769043	-10.74451307	1	2	1
sub072	20181007000826	0	0	0.309162804	-63.43036322	-143.4603364	3	6	5
sub073	20180911001645	0	0	0.309174444	0.137539736	0.672058046	2	2	1
sub074	20180719000020	0	0	0.341304712	-23.3362973	-4.524391885	5	0	2
sub075	20180428001767	0	0	0.267297167	-1.49910604	-8.294989911	4	2	2
sub076	20180619002401	1	15.993611	0.673087842	-13.95761558	-56.41647792	3	6	6
sub077	20180503002304	1	14.119444	0.705031351	-12216.53104	-21561.45935	1	3	6

sub078	20180929000040	0	0	0.290996353	-4.088196114	-3.014923918	4	1	0
sub079	20180929000037	1	27.847222	0.650797247	0.155464852	-0.083035773	4	2	1
sub080	20180130001917	1	20.573333	0.584938352	0.390464941	-3.727128641	3	1	3
sub081	20180120000249	1	27.421667	0.664670146	-1.053599139	-0.670228989	1	0	3
sub082	20180221000793	0	0	0.379171387	-7.627221806	-0.885131694	5	3	2
sub083	20181004000706	0	0	0.363057693	-205.5935579	-463.4907661	4	3	5
sub084	20180716000006	0	0	0.423012005	0.445585135	-0.510157552	5	0	3
sub085	20181127000112	1	2.1963889	0.652997279	-17.66007773	-29.76888015	4	5	3
sub086	20180108000002	0	0	0.337160697	-2.562414207	-20.34730636	4	1	1
sub087	20180216000198	0	0	0.218878346	-6.407007555	-33.20073759	4	2	2
sub088	20180521000314	0	0	0.24654298	0.147669826	0.272765763	2	4	2
sub089	20180314002318	0	0	0.394315808	0.208538115	-0.381268793	4	2	3
sub090	20180910002366	0	0	0.636395558	0.072895234	0.502574957	4	5	6
sub091	20181019001130	0	0	0.305797115	0.01134188	-4.766010519	4	2	2
sub092	20181116001089	1	11.924722	0.454314646	-14.07493205	-15.9239006	1	6	5
sub093	20181214000208	0	0	0.534815104	0.387079609	-1.376148868	5	1	1
sub094	20180412001795	1	28.910833	0.323947132	-63.80897092	-51.7265367	4	3	1
sub095	20180316001329	1	7.4316667	0.466728898	-23.28653002	-2.900960635	5	1	6
sub096	20180802001789	0	0	0.549305327	-22.35553992	-89.78410399	3	3	2
sub097	20181010000767	0	0	0.424596728	0.491136156	0.323826393	1	1	1
sub098	20180612002507	1	42.756667	0.693326831	0.452729097	-5.267573928	3	5	4
sub099	20180620002296	1	17.672778	0.680040565	-130.4910579	-539.9397145	4	4	3
sub100	20180314000010	0	0	0.367989958	-9.885401356	-19.1494222	1	1	1
sub101	20180311000432			0.579425254				4	
sub102	20180708000024			0.523147198				0	
sub103	20181015001677			0.44911113				0	
sub104	20190105000694			0.179924569				4	
sub105	20190108002459			0.226628				0	
sub106	20190519000853			0.451267554				4	
sub107	20190526000209			0.365352687				3	
sub108	20190701002502			0.500361185				0	
sub109	20190716000013			0.36987511				2	
sub110	20190717001385			0.560596666				4	
sub111	20190727000556			0.690678384				4	
sub112	20190803000014			0.234194113				1	
sub113	20190901000442			0.408746338				0	
sub114	20190903000373			0.656911396				0	
sub115	20190904002299			0.512768509				3	
sub116	20190906001283			0.456059919				5	
sub117	20190917002094			0.494430907				2	
sub118	20190923002580			0.513700339				3	
sub119	20191003000352			0.359136218				1	
sub120	20191004001025			0.434757311				4	
sub121	20191027000468			0.451769931				1	
sub122	20191028002738			0.41220578				2	
sub123	20191024001280			0.516305646				5	
sub124	20191030001526			0.269917202				0	
sub125	20191111002510			0.688465315				1	
sub126	20191126002590			0.544067736				1	
sub127	20191127002176			0.523936088				2	
sub128	20191208000592			0.489722816				2	
sub129	20191224000008			0.21906982				4	
sub130	20191228000237			1				4	
sub131	20160413000006			0.602789761				4	6
sub132	20161215001667			0.493765317				4	0
sub133	20200112000228			0.47031424				2	2
sub134	20200101000392			0.34408546				4	3
sub135	20201130003288			0.274533909				3	4
sub136	20201203002778			0.678028712				4	4
sub137	20201217002368			0.686951349				1	2
sub138	20200403000012			0.327128606				0	0
sub139	20200814000015			0.511672201				2	3
sub140	20200412000331			0.652808505				5	1
sub141	20200711001264			0.20835461				3	2
sub142	20200411000014			0.173264743				4	3
sub143	20200214000572			0.4668081				1	2
sub144	20200124000041			0.334003318				6	4
sub145	20200613001086			0.052144176				0	0
sub146	20200531000253			0				0	1
sub147	20201220000155			0.375600755				0	3
sub148	20200609001016			0.532530161				0	1
sub149	20200409001101			0.482706814				2	0
sub150	20200118000372			0.324906145				0	0
sub151	20201023001238			0.558609918				0	6
sub152	20201109000009			0.327410947				3	1
sub153	20201212001420			0.685673637				4	5
sub154	20201129000299			0.665092631				0	1
sub155	20200301000025			0.355251908				2	2
sub156	20200306000927			0.556278554				6	5
sub157	20201009003102			0.516660469				0	6
sub158	20200410001952			0.398253433				3	1
sub159	20200218000582			0.466417239				1	6
sub160	20200821002584			0.43972213				5	6