



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校

西安交通大学

参赛队号

23106980022

队员姓名

1.

钟朝彬

2.

林宏伟

3.

李程子

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

题 目

出血性脑卒中临床智能诊疗建模

摘 要:

出血性脑卒因其发病急、损伤大、病因复杂、难以预防及治疗而受到人们的广泛关注。幸运的是，血肿扩张及其周围水肿的发展被发现为出血性脑卒的重要临床特征，因此，使用医学影像及人工智能等技术，结合患者的临床治疗方法、过往病史等信息，构建血肿扩张和水肿发展的监测及预测模型，可以为临床决策提供优化建议，是未来预防及治疗出血性脑卒的重要手段。

针对问题一：对于子问题 (a)，结合判断血肿扩张的时间条件和体积条件，判断前 100 名患者于何时是否发生血肿扩张事件，判断结果见表 4。对于子问题 (b)，预测之前先进行特征选择，对特征选择实施**先分类再选取的策略**，将特征分为患者的临床信息，影像体积与位置信息和影像形状与灰度特征三类，利用随机森林算法对患者临床信息特征进行重要度排序，将原 19 个特征减少为 6 个特征；利用 LightGBM 算法对画着影像体积与位置信息特征进行特征提取，将原来 10 个特征减少至 4 个特征；利用斯皮尔曼相关性分析方法对患者影像形状与灰度分布特征进行相关性排序，并采用连乘方法进行**数据融合**。将原来的 23 个特征减少为 10 个。分别采用随机森林算法、支持向量机算法和逻辑回归算法结合处理过的特征对前 100 名患者是否发生血肿扩张进行预测，**通过三个方案的对比**最终确定逻辑回归为最佳方案，预测结果见表 4。

针对问题二：对于子问题 (a)，考虑到不同患者之间存在差异，难以用一段连续曲线拟合出让人满意的结果，结合自身就诊经验和查阅参考文献，将时间分为 **(0,24h]**, **(24h,72h]**, **(72h, 168h]**, **(168h, 720h]** 和 **(720h,∞)** 五段，分别在各段时间范围内进行拟合，分别利用多项式拟合和高斯拟合的方法，得到 5 段拟合曲线，将 5 段拟合曲线的表达式记为分段函数，将各个时间点代入函数表达式中求出残差，结果见表 4。对于子问题 (b)，根据各个患者水肿体积随时间进展模式的不同，利用 K-means 算法将患者分为 4 类，利用多项式拟合和高斯拟合的方法，分别拟合出四类患者的水肿体积随时间的变化曲线，利用拟合方程计算出残差，结果见表 4。对于子问题 (c)：考虑样本不均衡对结果的影像，引入水肿体积进展率，并根据水肿体积进展率将水肿体积进展分为五种模式，采用随机森林算法和灰度关联法得到不同治疗方案的关联度，最终得出对于水肿治疗采用**闹市引流、降颅压治疗、止血治疗和镇静镇痛治疗**这四种方式最为有效的结论。对于子问题 (d)：利用每个患者最后一次检查的血肿体积和水肿体积减去每个患者第一次检查的血肿体积和水肿体积，分别将差值作为因变量，将治疗方案中的各个变量作为自变量进行多元线性回归，分析出各个治

疗方案与血肿体积和水肿体积的关系；以水肿体积变化差为因变量，血肿体积变化差为自变量，利用二次多项式拟合得到水肿体积变化和血肿体积变化之间的关系。

针对问题三：对于子问题 (a)，本文首先通过数据准备将前 100 个患者的所有特征进行了整合，构成了含有 104 维特征的 100 个样本。接着，在数据探索时利用图形可视化的手段筛查出了异常值并进行剔除，为数据的高质量性提供保障。然后，在特征选择方面利用了卡方检验、递归特征消除、XGBoost、递归特征消除、前向选择和后向选择、特征提取结果六种特征提取方法分别提取 30 个特征，使用投票的方法，基于“少数服从多数的原则”，选择 6 个模型投票数超过 4 和超过 3 的特征，再利用这些敏感性较高的特征结合随机森林模型训练模型，并对 160 个样本的 90 天 mRS 值进行了预测。对于子问题 (b)，由于数据的增加，加上由于各种因素，每个参加随访的次数和频率不同，因此造成了样本的特征维度不同，造成了样本不均衡问题，基于此，本文采用多重插补和最近邻插补的方法来补全缺失值，并利用 a) 种的方法放入多个特征选择模型选择敏感度最大的特征来进行模型训练，进而预测所求 130 个样本的 90 天 mRS 值。对于子问题 (c)，根据变量类别分类，对于定类变量之间的关系探究，采用卡方检验的方法进行分析，对于连续变量之间的关系探究，采用斯皮尔曼相关性系数，最后得出 90 天 mRS 等级与患者个人情况，疾病史，影像特征等关系。

关键字： 机器学习 特征选取 拟合 多元线性回归 相关性分析

目录

1	问题重述	5
1.1	引言	5
1.2	问题的提出	5
2	模型的假设	7
3	符号说明	7
4	问题一模型建立与求解分析	8
4.1	子问题 a) 判定是否发生血肿扩张	8
4.1.1	问题分析	8
4.1.2	问题求解	8
4.2	子问题 b) 预测发生血肿扩张的概率	8
4.2.1	问题分析	8
4.2.2	数据预处理	10
4.2.3	特征提取	12
4.2.4	预测过程	17
5	问题二模型建立与求解分析	20
5.1	子问题 a) 构建患者水肿体积随时间进展变化曲线	20
5.1.1	问题分析	20
5.1.2	数据预处理	21
5.1.3	拟合模型	22
5.1.4	拟合结果	23
5.1.5	残差计算	25
5.2	子问题 b) 构建不同人群的水肿体积随时间进展曲线	27
5.2.1	问题分析	27
5.2.2	K-means 聚类分组	27
5.2.3	拟合结果	28
5.2.4	残差计算	31
5.3	子问题 c) 治疗方法对水肿体积进展模式的影响	31
5.3.1	问题分析	31
5.3.2	数据处理	32
5.3.3	灰色关联分析	32
5.3.4	关联度分析	33

5.4	子问题 d) 血肿体积、水肿体积及治疗方法关系分析	35
5.4.1	问题分析	35
5.4.2	线性回归模型	35
5.4.3	相关性探究	35
6	问题三模型建立与求解分析	38
6.1	子问题 a) 基于首次影像预测患者 90 天 mRS 评分	38
6.1.1	问题分析	38
6.1.2	数据处理	38
6.1.3	特征提取	38
6.1.4	预测结果	41
6.2	子问题 b) 预测患者 90 天 mRS 评分	41
6.2.1	问题分析	41
6.2.2	问题求解	42
6.3	子问题 c) 分析患者的预后与临床信息间的关系	44
6.3.1	问题处理	44
6.3.2	数据处理	44
6.3.3	模型求解	44
6.3.4	结果分析	46
7	模型评价	48
7.1	模型的优点	48
7.2	模型的缺点	48
	参考文献	49
	附录 A 部分源程序	50
A.1	程序 1	50
A.2	程序 2	50
A.3	程序 3	51
A.4	程序 4	52

1 问题重述

1.1 引言

出血性脑卒是脑血管疾病的一种严重疾病，通常由脑动脉瘤破裂或脑动脉异常引起，占有脑卒发病率的 10-15%。它的发展十分迅速，在急性期内可能造成将近一半的病死率，并且大概率会对人体的神经系统造成严重的损害。由于它的病因复杂，在当前仍然无法对其进行有效的预防和治疗。出血性脑卒临床通常表现为血肿扩张和其周围水肿的扩张，这为早期识别和预测该疾病提供了可能。医学影像技术和人工智能技术的发展为监测和预测出血性脑卒中的进展提供了新机遇。因此，结合医学影像技术，整合治疗手段、个人病史、个人基本情况等信息，构建对于血肿和水肿的监测与预测模型，分析血肿与水肿与相关数据之间的关系，更好地为临床诊断服务，具有十分重要的意义。

1.2 问题的提出

题目中共给出了 6 组附件数据，表 1 为 160 名患者的个人信息及临床信息，包括性别、年龄及接受过的治疗手段等，并且对这 160 个数据进行了划分，其中有 100 个数据为测试数据，30 个数据为测试集 1，30 个数据为测试集 2；表 2 给出了 160 名患者多次检查的影像信息血肿及水肿的体积及位置，随访次数最大值为 8；表 3 给出了 3 个工作表，命名为“ED”的工作表给出了不同流水号对应水肿的形状及灰度分布，命名为“Hemo”的工作表给出了不同流水号对应血肿的形状及灰度分布，名为为“Sheet1”的工作表是对 31 个形状及灰度值指标的展示；表 4 为答案文件，需要通过模型构建及计算得到；附表 1 详细地给出了共计 13 次随访的流水号以及时间等数据；附件 2 是对一些相关概念的介绍，便于读者理解题意。要求利用以上数据解决以下问题：

问题一：问题是根据表 1 和表 2 中入院首次影像检查流水号，发病到首次影像检查时间间隔、各时间点流水号及对应的血肿体积通过结合血肿扩张的相关定义来判断患者 sub001 至 sub100 发病后 48 小时内是否发生血肿扩张事件。b) 问题中提供的变量信息较多，要求利用已知的各种变量，依据相关理论技术，构建以血肿扩张为目标变量的模型，并通过训练好的模型来预测所有患者发生血肿扩张的概率。

问题二：a) 问题数据点众多，并且分布不太均衡，其中可能包括一些可能会对拟合结果造成影响的异常值，因此通过图像分析及数学分析，采用构建分段函数的方式来拟合数据点，得到真实值与曲线值之间的残差；b) 问题在 a) 问题的基础上加入了分组任务，需要通过相关性分析等方式找到分组的依据，并进行聚类分组，再进行曲线拟合，得到真实值与曲线值之间的残差；c) 问题的水肿体积数据由于患者参与随访检查的次数和频率不一，造成特征维度不一，进而造成样本不均衡，在剔除异常值的基础上，把水肿体积进展模式分为 5 类，结合理论技术对不同治疗方法与水肿体积进展模式进行分析；d) 问题在 c) 问题的基础上加入了血肿体积，以体积绝对变化为参考对三个因素两两进行分析。

问题三：a) 问题需要将前 100 个患者的所用特征进行收集并整合，在数据清洗和数据标准化处理的基础上，采用多个特征选择模型输出多个特征，采用投票的方式选择其中的某几个特征训练给所构建的模型来预测患者的 mRS 评分。b) 问题在 a) 问题的基础上

加上了更多的影像信息，这也造成了缺失值的增加，结合插补等方法补全缺失值，并依据 a) 中的方法进行特征提取和模型构建及后续的预测；c) 问题结合相关知识和假设将问题转换为等级变换——多个定类变量的问题对各种分量的相关性进行分析。

2 模型的假设

1. 假设题目提供的数据真实可靠；
2. 假设患者的治疗方案仅与病情有关，不受其他因素的影响；
3. 假设所有的患者为随机挑选；

3 符号说明

符号	意义
HM_V	首次影像检查中测定的血肿体积
HM_{V_i}	第 i 次随访中测定的血肿体积
HM_V	血肿体积变化值
ED_V	水肿体积变化值
ED_{pr}	水肿体积进展率
HM_V^v	血肿体积绝对变化值
ED_V^v	水肿体积绝对变化值
$TM_{\{\}}$	对应不同名称的治疗方案
$residual$	残差

4 问题一模型建立与求解分析

4.1 子问题 a) 判定是否发生血肿扩张

4.1.1 问题分析

问题一 a) 旨在通过已知数据判断各病人样本是否在 48 小时内发生血肿扩张事件，若发生，则在“表 4-答案文件” C 列填 1，同时在 D 列填写发生血肿扩张事件时距离发病的时间，若未发生，则在“表 4-答案文件” C 列和 D 列均填 0。根据问题描述可知，若在距发病 48 小时内的后续检查中，血肿的绝对体积相比首次增加 $\geq 6 \text{ mL}$ 或血肿的相对体积相比首次增加 $\geq 33\%$ ，则认为发生了血肿扩张事件。

4.1.2 问题求解

现令首次影像检查中测定的血肿体积为 $HMV(\text{mm}^3)$ ，后续随访检查中测定的血肿体积为 $HMV_i, i = 1, 2, 3, \dots$ ，其中 i 表示随访检查的序号，则不考虑时间限制的血肿判定条件如下：

$$(HMV_i - HMV \geq 6\text{m}) \wedge \left(\frac{HMV_i - HMV}{HMV} \geq 33\% \right) \Rightarrow \text{hematomaenlargement} \quad (4.1)$$

若考虑时间条件的限制，则应该在上述条件加上如下限制：

$$(HMV_i - HMV \geq 6\text{ml}) \vee \left(\frac{HMV_i - HMV}{HMV} \geq 33\% \right) \wedge (T_i - T + T') \Rightarrow \text{hematomaenlargement} \quad (4.2)$$

其中 T 表示首次影像检查的时间 (h)， T_i 表示后续随访检查距发病的时间 (h)， T' 表示首次影像检查距发病的时间 (h)。

判定流程如图4.1，并将判定的结果记录了“表 4” C 字段，同时将血肿扩张发生时间记录在了“表 4” D 字段。

4.2 子问题 b) 预测发生血肿扩张的概率

4.2.1 问题分析

问题一 b) 旨在基于前 100 例患者的个人史、疾病史、发病相关信息以及首次影像检查结果等相关信息，预测所有 160 例患者会发生血肿扩张事件的可能性，并将预测结果填写在“表 4”的 E 字段中。本题的解题步骤可以分为三步：数据预处理、特征提取、预测过程，思路框图如图4.2所示。首先对前 100 例患者的数据进行异常值查找和剔除，以提高预测模型的准确性和可靠性；剔除部分异常样本后，对患者的部分临床信息进行编码或者归一化，对患者影响体积与位置信息中的出血位置进行部分合并处理，并考虑患者影像形状与灰度特征的分布，将原始数据转换为适合预测模型处理的形式，同时减少特征的数量，以提高模型的计算效率和可解释性；再次，利用随机森林、*LightGBM* 等模型进行特征提取，且部分特征进行相关性分析，基于相关性分析进行特征融合；最后以模型结果为导向，利用随机森林、支持向量机、逻辑回归等模型直接输出 160 例患者是否发生血肿扩张的概




图 4.1 血肿扩张判定具体流程

率。在预测模型构建的过程中，可以考虑使用机器学习的方法，如随机森林、*LightGBM*、逻辑回归等。最后对预测模型进行验证和评估，以确保模型的预测效果与性能。




图 4.2 血肿扩张概率预测具体流程

4.2.2 数据预处理

A、数据清洗

低质量数据会直接影响模型的准确性，因此，通过数据清洗对不同出血性脑卒患者的个人史、疾病史、发病相关等 72 个变量的异常值进行初步剔除，以确保数据质量的可靠性，进而有效为模型构建及结果预测提供保障具有必要性。箱型图 (Box Plot) 是一种可用于展示数据分布情况的工具，本文采用箱型图来筛选数据中的异常量，进行低质量数据的剔除。如图4.3所示，箱型图由五个部分组成：Q3 表示数据的上四分位数，即数据中小于等于它的值占 75%；Q1 与 Q3 对应，表示数据的下四分位，即有 25% 的数据小于等于它；中位数 (Q2) 代表有一半的数据小于等于它；上下四分位数之差是四分位距 (IQR)，上边缘 (最大值) 是用上四分位数加上四分位距，即 $Q3+IQR$ ；下边缘 (最小值) 是用下四分位数减去四分位距，即 $Q1-IQR$ 。在上边缘之外的数据就是极大异常值，在下边缘之外的数据极小异常值，总之，在上下边缘之外的数据就是异常值 [1]。




图 4.3 箱型图示意图及参数含义


本文对 72 个变量使用了箱型图剔除低质量数据，以 NCCT_original_firstorder_Range 为例，对其箱型图进行了展示，如图4.4所示。由图可知，数据样本中含有异常值，需进行数据清洗。

利用 Box plot(scale=3)，对数据样本自变量的异常值进行初步筛选，筛选后的典型特征取值如图4.5所示。由图可知，所用的方法可以有效剔除数据样本中的异常值，为之后特征选择、特征构建、模型构建及后续的预测工作提供了可靠性保障。


B、特征编码和归一化

对特征编码和归一化是数据预处理中常用的技术，可以将原始数据转换为适合机器学习算法处理的形式，从而提高模型的准确性和效率。观察附件 1，除年龄、性别、脑出血前 mRS 和血压以外，其他特征均为 0,1 分布。为方便后续进行数据处理，在此将性别进行编码（男性：1；女性：0）。将年龄、脑出血前 mRS、血压（分为高压和低压）进行利用式子 (4.3) 进行归一化处理。

$$Feature' = \frac{Feature - \min(Feature)}{\max(Feature) - \min(Feature)} \quad (4.3)$$




(a) NCCT_original_firstorder_Range 原始数据




(b) NCCT_original_firstorder_Range 数据清洗后

图 4.4 NCCT_original_firstorder_Range 箱型图



(a) 异常值剔除前



(b) 异常值剔除后

图 4.5 筛选过的典型特征

其中 $Feature'$ 为特征归一化后的结果, $Feature$ 为特征原始值, $\min(Feature)$ 为该特征的最小值, $\max(Feature)$ 为该特征的最大值。

C、特征合并

观察附表 2 的数据可得, 可将左右侧大脑前动脉 (ACA_L, ACA_R), 左右侧大脑中动脉 (MCA_L, MCA_R), 左右侧大脑后动脉 (PCA_L, PCA_R), 左右侧脑桥/延髓 (Pons_Medulla_L, Pons_Medulla_R), 左右侧小脑 (Cerebellum_L, Cerebellum_R) 共十个不同位置合并为大脑前动脉, 大脑中动脉, 大脑后动脉, 脑桥/延髓, 小脑共五个位置。

D、特征分布

为了寻找合适的预测模型, 分析附表 3 中的数据的概率分布。现展现出附表 3 中 16 个特征的概率分布, 如图 4.6 所示。可以看出附件 3 中的特征符合正态分布, 但图 4.6 中 (a),(b),(g) 等正态分布显著, (e),(h),(m) 等正态分布较弱。

为展示各变量之间的关系, 做出矩阵散点图 (Matrix Scatterplot)。患者影像形状矩阵




图 4.6 患者影像形状及灰度分布图

散点图如图4.7所示。借助图4.7可以更有利于理解数据，发现变量之间和相关性，并选择合适的变量组合进行模型训练。

4.2.3 特征提取

A、随机森林

随机森林是一种集成算法，是包含多棵决策树的分类器。对于小样本数据而言，相较于单棵决策树来讲，随机森林算法会有更好的表现，能够有效防止过拟合现象。具体的实现过程如下：

- *step 1* : 通过有放回的随机选取 n 个训练样本，构成新的训练集；
- *step 2* : 利用新选取的样本构建决策树，对于每个节点，随机选择 m 个特征，根据这 m 个特征选择最佳的分裂点；
- *step 3* : 重复 *step2* 指导达到停止条件；
- *step 4* : 将生成的决策树加入到森林中，重复 *step13*，建立多棵决策树构成随机森林；

B、LightGBM

LightGBM 是一种基于梯度提升决策树 (*GradientBoostingDecisionTree*, *GBDT*) 的机器学习算法，该算法采用了一些优化策略，如基于带深度限制 *leaf_wise* 的叶子生长




图 4.7 患者影像形状矩阵散点图

策略、*Histogram* 算法等，相较于 *GBDT*，在训练速度和准确性方面具有优势 [4,5]。

(1) 带深度限制 *leaf_wise* 的叶子生长策略

level_wise 叶子生长策略，如图4.8所示，能够在每一层节点上同时分裂所有叶子。这种方法虽然容易进行多线程优化，但是会导致很多叶子节点的分裂增益较低，浪费了很多计算资源。相比之下，带深度限制的 *leaf_wise* 叶子生长策略可以在每个节点上选择最优的分裂点进行生长，从而更加高效地构建决策树，并且可以避免过拟合的问题。

level_wise 则是一种高效的决策树构建策略。如图4.9所示，在每次迭代中从当前所有叶子节点中选择分裂增益最大的一个叶子节点进行分裂，以此循环迭代。相比于 *level_wise* 策略，*leaf_wise* 策略在相同的分裂次数下能够降低更多的误差，从而获得更好的精度。此外，*LightGBM* 还提供了额外的参数来限制树的深度，以避免过拟合的情况发生。这种策略的优势在于它能够更加高效地构建决策树，同时通过选择最优的叶子节点进行分裂，能够获得更好的模型精度。

(2) *Histogram* 算法

该方法是通过将连续的特征值离散化为整数，构造一个宽度为 k 的直方图，将连续的数据转化为离散的数据，从而方便进行统计和分析。最终根据离散化后的直方图来确定最




图 4.8 *level_wise* 叶子生长策略




图 4.9 *leaf_wise* 叶子生长策略

优的分割点，以实现数据的分割和分类。

C、相关性分析

相关性分析是一种常见的统计分析方法，用于研究两个及两个以上变量之间的关系。相关性分析通常使用相关系数来衡量变量之间的关系强度，其中最常用的是皮尔逊相关系数（Pearson correlation coefficient）和斯皮尔曼等级相关系数（Spearman's rank correlation coefficient）[2]。

皮尔逊相关系数用于衡量两个连续变量之间的线性相关性，且适用的数据经常具有很强的正态分布。而斯皮尔曼等级相关系数用于衡量两个变量之间的单调关系，即它们是否具有相同的变化趋势（如线性函数、指数函数、对数函数），不仅局限于线性关系。由图4.6可以看出附表 3 中的数据符合正态分布特征，但由图4.7可以看出数据之间的线性相关性较弱。故我们利用斯皮尔曼等级相关系数进行相关性分析。

D、特征提取结果

(1) 患者的临床信息

利用随机森林对患者的临床信息中的年龄，性别，mRS 评分，血压等共 19 项特征进行特征提取，得到如图4.10所示的特征重要度排序。

我们选取患者的临床信息重要度最高的前 6 个特征进行预测血肿出现的概率。6 个特征分别为低压、年龄、高压、冠心病史、卒中病史、和性别，见表4.1。由表4.1可得以上 6 项特征的比重合计占 73.25%，对预测模型的构建起着重要作用。

(2) 患者影像体积与位置信息




图 4.10 患者的临床信息重要性排序

表 4.1 患者的临床信息重要特征

特征	低压	年龄	高压	冠心病史	卒中病史	性别
重要度	22.12%	19.81%	18.56%	6.04%	4.06%	3.65%

利用 *LightGBM* 对整合过的患者影像体积与位置信息（含有五个位置，共十个特征）进行特征提取，得到如图4.11所示的特征重要度排序。




图 4.11 患者影像体积与位置信息重要性排序

我们选取患者的临床信息重要度最高的前 4 个特征进行预测血肿出现的概率。4 个特征分别为 HM_MCA_Ratio（大脑中动脉血肿），ED_PCA_Ratio（大脑后动脉水肿），HM_PCA_Ratio（大脑后动脉血肿）和 ED_ACA_Ratio（大脑前动脉水肿），见表4.2。由

表4.2可得以上 4 项特征的比重合计占 82.02%，对预测模型的构建起着重要作用。

(3) 患者影像形状与灰度分布

利用斯皮尔曼等级相关系数分别对患者影像形状和灰度分布特征进行相关性分析。对于患者影像形状共 14 个特征，得到 9 个特征之间具有显著的相关性，其斯皮尔曼等级相关系数可以由图4.12展现。对于患者影像灰度分布共 17 个特征，得到 14 个特征之间具有显著的相关性，其斯皮尔曼等级相关系数可以由图4.13展现。




图 4.12 患者影像形状特征斯皮尔曼等级相关系数可视化




图 4.13 患者影像灰度分布特征斯皮尔曼等级相关系数可视化

表 4.2 患者影像体积与位置信息重要特征

特征	HM_MCA_Ratio	ED_PCA_Ratio	HM_PCA_Ratio	ED_ACA_Ratio
重要度	30.69%	19.71%	19.59%	12.03%

根据相关性分析结果进行特征融合。将患者影像形状特征和患者影像灰度分布特征中具有显著相关的特征利用公式（4.4）融合为一类特征。

$$Feature_M = \sum_{i=1}^k Feature_i \quad i = 1, 2, \dots, k \quad (4.4)$$

其中， $Feature_M$ 为融合后的特征， $Feature_i$ 为相互之间具有相关性的特征；对于患者影像形状特征而言， $k = 9$ ，对于患者影像灰度分布特征而言， $k = 14$ 。经过特征融合后，患者影像形状特征减少为 6 个，患者影像灰度分布特征减少为 4 个。

4.2.4 预测过程

在构建发生血肿扩张事件的可能性预测模型的过程中，考虑使用随机森林、支持向量机和逻辑回归等机器学习的方法，最后进行预测模型对比与评估。

A、支持向量机

支持向量机（Support Vector Machine，SVM）作为一种常见的机器学习方法，其目的是利用一个最优的超平面将数据集中的不同类别的数据分开。SVM 通过最大化分类器的边际来提高分类器的泛化能力，从而使得分类器能够更好地适应新的数据。同时，SVM 算法在进行回归分析时，对小样本、非线性、噪声较多、小样本等问题等处理时具有优越性 [3]。

对于给定的训练样本 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ $y_i \in \{-1, +1\}$ ，使得训练集中的每一个点拟合到一个线性模型 $y_i = w \cdot \Phi(x_i) + b$ 上。

定义一个常数 $\epsilon > 0$ ，对于训练集上的点 (x_i, y_i) ，如果存在 $|y_i - w \cdot \Phi(x_i) + b| \leq \epsilon$ ，则说明该点完全没有损失；如果 $|y_i - w \cdot \Phi(x_i) + b| > \epsilon$ ，则说明该点具有损失，对应的损失为 $|y_i - w \cdot \Phi(x_i) + b| - \epsilon$ 。如图4.14所示，在黄色条带里面的点为没有损失的，但蓝色条带之外的点是具有损失的，损失大小为蓝色线段的长度。

定义 SVM 回归使用模型的损失函数为：

$$err_{(x_i, y_i)} = \begin{cases} |y_i - w \cdot \Phi(x_i) + b| - \epsilon & |y_i - w \cdot \Phi(x_i) + b| > \epsilon \\ 0 & |y_i - w \cdot \Phi(x_i) + b| \leq \epsilon \end{cases} \quad (4.5)$$

定义目标函数为：

$$\min \frac{1}{2} \|w\|_2^2 \quad s.t \quad |y_i - w \cdot \Phi(x_i) + b| \leq \epsilon \quad i = 1, 2, \dots, m \quad (4.6)$$

可以为目标函数加入松弛变量，改写为拉格朗日函数，利用函数的对偶形式求解最优的 w 和 b 。




图 4.14 SVM 回归过程说明

B、逻辑回归

逻辑回归是一种常用的分类算法，常用于二分类问题或多分类问题。逻辑回归模型通过对输入数据进行线性组合，然后将结果通过一个 sigmoid 函数映射到 0 到 1 的范围内，从而得到预测的概率值。逻辑回归是一种简单、快速、可解释分类算法，且能够处理非线性关系及处理缺失值问题，适用于许多实际应用场景 [4]。

现有二分类问题，输入数据为 x_i ，输出数据为 y_i (取值为 0 或 1)。逻辑回归模型首先构造一个输入的线性组合，并通过 sigmoid 函数预测概率 p_i 。即

$$z = w^T X + b \quad (4.7)$$

$$p = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (4.8)$$

其中， z 为线性组合结果， X 为输入数据矩阵， w 为输入数据的权重， b 为偏置项 $\sigma(z)$ 为 sigmoid 函数。

定义损失函数为：

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \cdot \ln p_i + (1 - y_i) \cdot \ln(1 - p_i)] \quad (4.9)$$

其中， m 为训练集中样本的数量， p_i 是 i 个模型的预测概率。

最小化损失函数的过程常用梯度下降算法进行求解。首先计算损失函数对 w 和 b 求偏导，再根据梯度下降算法更新，即：

$$w = w - \alpha \frac{\partial J(w, b)}{\partial w} \quad (4.10)$$

$$b = b - \alpha \frac{\partial J(w, b)}{\partial b} \quad (4.11)$$

其中， α 为学习率，控制每次更新的步长。

C、预测结果

采用随机深林，SVM，逻辑回归建立预测模型，且在模型训练过程均采用测试集占比 0.2 进行测试。通过混淆矩阵，准确率（accuracy），精确率（precision）、召回率（recall）、F1 来对比分析预测模型的效果。

通过分析混淆矩阵可以帮助我们更好地理解模型在不同情况下的分类表现，从而进行模型调优或者选择最优模型。精确率表示模型预测为正例的样本中，真正为正例的比例；召回率表示真正为正例的样本中，被模型预测为正例的比例；F1 是二分类模型评估指标，它综合了模型的精确率和召回率。其中精确率、召回率和 F1 的计算公式如下：

$$precision = \frac{TP}{TP + FP} \quad (4.12)$$

$$recall = \frac{TP}{TP + FN} \quad (4.13)$$

$$F1 = \frac{2 \times precision \times recall}{precision + recall} \quad (4.14)$$

其中， TP 表示真正为正例的样本数量， FP 表示被模型错误地预测为正例的负例样本数量， FN 表示被模型错误地预测为负例的正例样本数量。精确率、召回率和 F1 取值范围均为 $[0, 1]$ ，且越接近 1 表示模型的性能越好。

随机深林，SVM，逻辑回归三个预测模型的准确率、精确率、召回率和 F1 展现在表4.3中。图4.15为混淆矩阵。由于预测结果中，发生血肿扩张的人数较少，导致模型的精确率、召回率较低。因此，为了更好的评估预测模型的效果，在本文中计算精确率、召回率将 TP（模型正确地将正例样本预测为正例的数量）和 TN（模型正确地将反例样本预测为反例的数量）进行交换，得到表4.3中的准确率。

表 4.3 预测模型的准确率、精确率、召回率和 F1

	准确率	精确率	召回率	F1
随机深林	0.850	0.937	0.882	0.909
SVM	0.800	0.875	0.875	1
逻辑回归	0.900	0.941	0.941	1

对比随机深林，SVM，逻辑回归三个预测模型的效果，由表4.3可得，相较于其他预测模型，逻辑回归的准确率、精确率、召回率、F1 更接近 1，预测效果最好。故选取逻辑回归的预测模型作为最终预测血肿扩张事件可能性的模型。其结果填入表“4”的 E 字段，部分结果展示在表4.4中。由表4.4可以看出，已经发生血肿扩张的患者，其血肿扩张预测概率均大于 50%，未发生血肿扩张的患者，其血肿扩张预测概率均小于 50%，其预测结果符合统计概率学。




图 4.15 患者影像形状及灰度分布图

表 4.4 部分血肿扩张事件可能性的预测结果

	是否血肿扩张	血肿扩张时间	血肿扩张预测概率
sub001	0	0	0.1354
sub003	1	9.5225	0.5989
sub004	0	0	0.3699
sub005	1	26.4675	0.6051
sub010	0	0	0.0889
sub017	1	14.87028	0.5922
sub020	0	0	0.0891
sub030	0	0	0.3835
sub033	1	30.81306	0.7116
sub038	1	15.80917	0.5657

5 问题二模型建立与求解分析

5.1 子问题 a) 构建患者水肿体积随时间进展变化曲线

5.1.1 问题分析

问题二 a) 旨在根据“表 2”前 100 个患者 (sub001 至 sub100) 的水肿数据构建一条全体患者水肿体积随时间进展的曲线，并计算真实值和所拟合曲线之间存在的残差。本题的解题思路为：数据预处理、数据拟合、残差计算，思路框图如图 5.1 所示。首先根据流水号追溯患者检查时间和水肿体积，并根据时间进行排序；对相同时间内存在的多个水肿体积进行处理，并绘制出水肿体积的散点图；接着根据水肿体积的变化趋势，将时间线划分为不同的发病时间段用于构建不同的拟合模型；再次，根据每个发病时间段内的水肿体积变化趋势，构建拟合模型；最后，根据拟合结果得到残差值，并绘制残差曲线。




图 5.1 患者水肿体积进展曲线思路框图

5.1.2 数据预处理

A、数据处理

以患者影像检查流水号为指导，追溯患者对应的检查时间及水肿体积，根据发生脑卒中的时间进行排序。为了更直观地观察数据的变化情况，将水肿体积以 ml 为单位表达，即原始数据除以 1000。若相同时间内存在多个水肿体积，则以水肿体积均值代替。以简单的例子来表示具体实现，如表5.1所示。

表 5.1 相同时间下不同体积间的折换

时间	体积	折换时间	折换体积
1	0.5	1	$\frac{0.5 + 1 + 0.5 + 1}{4}$
1	1		
1	0.5		
1	1		

绘制散点图来观察患者水肿体积随发病时间的变化趋势，如图5.1所示。很明显观察到散点分布并不均匀。表明不同患者之间存在显著差异，同时考虑不同发病时间段水肿变化趋势不同。同时观察到图5.1存在异常点，在后续处理中去除。

B、时间段划分

患者水肿体积随时间变化的趋势因个体差异存在很大的差异。一般来说，患者的水肿程度和变化趋势与病因、病程、治疗措施等因素有关。常见的水肿随时间的变化关系有三




图 5.2 患者水肿体积散点图

种：急性脑水肿，慢性脑水肿，脑外伤后脑水肿及脑卒中水肿。其中急性脑水肿是指在短时间内（数小时至数天）内发生的脑水肿。在急性期，脑水肿的程度可能会迅速加重，导致颅内压增高和神经功能障碍的加重；慢性脑水肿是指在较长时间内（数周至数月）内发生的脑水肿。在慢性期，脑水肿的程度可能会相对稳定，但也可能会逐渐加重。脑外伤后脑水肿是指在脑外伤后发生的脑水肿。在脑外伤后的早期（几小时内），脑水肿的程度可能会迅速加重，导致颅内压增高和神经功能障碍的加重，随着时间的推移，脑水肿的程度可能会逐渐减轻，但也可能会持续加重；特别的，脑卒中水肿是脑卒中后发生的脑水肿，脑卒中后，水肿可能在伤后的一至两天内发生，然后逐渐加重，直到第五到第七天达到峰值，随之，水肿将逐渐消失，通常需要数周或数月的时间 [5, 6, 7]。

可以看出患者的脑水肿体积在不同的发病时间内有着不同的变化趋势，为了更好的构建全体患者水肿体积随时间进展的曲线，将发病时间线分为五个时间段，如表5.2所示。在后续的拟合过程中在不同的时间段内利用不同的拟合方式进行拟合。

表 5.2 划分五个时间段

	时间段 1	时间段 2	时间段 3	时间段 4	时间段 5
发病时间 (单位 h)	(0, 24]	(24, 72]	(72, 168]	(168, 720]	(720, ∞)

5.1.3 拟合模型

A、多项式拟合

多项式拟合是一种通过拟合多项式函数来逼近一组数据的方法。假设有一组数据 $(x_1, y_1), (x_2, y_2), \dots, (x_i, y_i), \dots, (x_n, y_n)$ ，需要找到一个多项式函数 $f(x)$ ，使得 $f(x_i) \approx$

$y_i, i = 1, 2, \dots, n$ 。由于多项式拟合具有简单易用、适应范围强等特点，广泛地应用于数据分析与数据拟合。

若需拟合的多项式函数为 $f(x) = a_0 + a_1x + a_2x^2 + \dots + a_mx^m$ ，其中 m 为多项式的次数， $a_0, a_1, a_2, \dots, a_m$ 是待求的系数。拟合问题可以转化为一个最小二乘问题，即找到一组 $a_0, a_1, a_2, \dots, a_m$ ，使得拟合函数 $f(x)$ 和实际数据 y_i 之间的误差平方和最小：

$$\min_{a_0, a_1, a_2, \dots, a_m} \sum_{i=1}^n (f(x_i) - y_i)^2 \quad (5.1)$$

通过求解式子 (5.1) 这一最小二乘问题，即可得到 $a_0, a_1, a_2, \dots, a_m$ ，从而拟合函数 $f(x)$ 。

B、高斯拟合

高斯拟合是一种通过拟合高斯函数来逼近一组数据的方法。假设有一组数据 $(x_1, y_1), (x_2, y_2), \dots, (x_i, y_i), \dots, (x_n, y_n)$ ，需要找到一个高斯函数 $G(x)$ ，使得 $G(x_i) \approx y_i, i = 1, 2, \dots, n$ 。由于高斯拟合具有高鲁棒性、可控制机等特点，也广泛地应用于具有离群点的数据分析与数据拟合。

若需要拟合的高斯函数为 $G(x)$ ，其表达式为

$$G(x) = ae^{-\frac{(a-b)^2}{2c^2}} \quad (5.2)$$

其中， a 为高数函数的振幅， b 为高斯函数的均值， c 为高斯函数的标准差。高斯拟合的过程可以借助最小二乘法等数学方法，求解高斯函数的三个参数 a, b, c ，使得高斯函数能够最好的逼近给定的数据，可以由下面的具体的步骤实现：

- *step 1* : 初始化高斯函数的三个参数 a, b, c ;
- *step 2* : 定义误差 e_i 为实验数据点 (x_i, y_i) 与拟合曲线 $G(x_i)$ 之间的差值，即 $e_i = y_i - G(x_i)$;
- *step 3* : 对于误差 e_i ，定义误差平方和 $S = \sum(e_i)^2$ ，即所有误差的平方和；
- *step 4* : 目标是最小化误差平方和 S ，即找到最优的参数 a, b, c ，使得 S 最小。可以通过最小二乘法来实现: 对于高斯函数 $G(x)$ ，可以取对数得到：

$$\ln(G(x)) = \ln(a) - (x - b)^2/2c^2$$

将其转化为线性形式，即 $y = s + lx$ ，其中 $y = \ln(G(x))$ $s = \ln(a)$ ， $t = -(x - b)^2/2c^2$ ， $x = x_i$ ，可以用最小二乘法求解参数 s 和 l ；

- *step 5* : 求解参数 s 和 l 后，可以得到参数 a, b, c 的值，其中 $a = e^s$ ， $b = x_i$ ， $c = \sqrt{-2/l}$ ；
- *step 6* : 将求得的参数 a, b, c 带入高斯函数 $G(x)$ 中，得到拟合曲线。

5.1.4 拟合结果

根据不同发病时间段内患者水肿体积变化趋势，选用合适的拟合模型进行数据拟合。为了达到最好的拟合结果，借助 Matlab 的 FitTool，对于时间段 1、时间段 4、时间段 5 进行多项式拟合，对于时间段 2、时间段 3 进行高斯拟合。

对于时间段 1 ($t \in (0, 24]$)，采用五次多项式进行拟合，其拟合函数由 (5.3) 展示。图5.3为时间段 1 拟合函数曲线。

$$ED_V = 0.000328t^5 - 0.01802t^4 + 0.3469t^3 - 2.792t^2 + 9.137t + 5.929 \quad (5.3)$$

对于时间段 2 ($t \in (24, 72]$)，采用双重高斯函数拟合，其拟合函数由 (5.4) 展示。图5.4为时间段 2 拟合函数曲线。

$$ED_V = 18.56e^{-\left(\frac{t-40.17}{15.25}\right)^2} + 1.095 \times 10^{15}e^{-\left(\frac{t-1867}{322.4}\right)^2} \quad (5.4)$$




图 5.3 时间段 1 拟合函数曲线




图 5.4 时间段 2 拟合函数曲线

对于时间段 3 ($t \in (72, 168]$)，采用高斯函数拟合，其拟合函数由 (5.5) 展示。图5.5为时间段 3 拟合函数曲线。

$$ED_V = 42.73e^{-\left(\frac{t-131.3}{78.13}\right)^2} \quad (5.5)$$

对于时间段 4 ($t \in (168, 720]$)，采用四次多项式拟合，其拟合函数由 (5.6) 展示。图5.6为时间段 4 拟合函数曲线。

$$ED_V = 1.359 \times 10^{-8}t^4 - 2.295 \times 10^{-5}t^3 + 0.01385t^2 - 3.468t + 324.2 \quad (5.6)$$

对于时间段 5 ($t \in (720, \infty)$)，采用四次多项式拟合，其拟合函数由 (5.7) 展示。图5.7为时间段 5 拟合函数曲线。

$$ED_V = -0.0003293t + 1.92 \quad (5.7)$$

利用分段函数描述整个时间线的回归模型，如式子 (5.8)。图5.8展示了整个时间线的回归曲线，同时绘制出散点图，并给出回归曲线的置信区间。由图5.8，绝大部分的散点落




图 5.5 时间段 3 拟合函数曲线




图 5.6 时间段 4 拟合函数曲线




图 5.7 时间段 5 拟合函数曲线

在置信区间内，整体回归模型效果较好。

$$ED_V = \begin{cases} 0.000328t^5 - 0.01802t^4 + 0.3469t^3 - 2.792t^2 + 9.137t + 5.929 & 0 < t \leq 24 \\ 18.56e^{-\left(\frac{t-40.17}{15.25}\right)^2} + 1.095 \times 10^{15}e^{-\left(\frac{t-1867}{322.4}\right)^2} & 24 < t \leq 72 \\ 42.73e^{-\left(\frac{t-131.3}{78.13}\right)^2} & 72 < t \leq 168 \\ 1.359 \times 10^{-8}t^4 - 2.295 \times 10^{-5}t^3 + 0.01385t^2 - 3.468t + 324.2 & 168 < t \leq 720 \\ -0.0003293t + 1.92 & t > 720 \end{cases} \quad (5.8)$$

采用 SSE, R^2 和 $RMSE$ 对回归模型进行评估。具体指标展示在表5.3，可以看出在构建水肿体积随时间进展曲线时，使用多项式拟合和高斯拟合相较于其他方法具有较好的性能。

5.1.5 残差计算

残差是实际观测值与回归模型预测值之间的差异。对于每一个观测值，可以通过将自变量的取值代入回归模型中，计算出该观测值的预测值，然后用预测值的实际值减去该观




图 5.8 整个时间线的回归曲线与散点图

表 5.3 五个拟合模型评估指标

时间区间	拟合方式	SSE	R^2	$RMSE$
(0,24h]	五次多项式	6902.6	0.7435	9.7913
(24h,72h]	双重高斯	21811	0.1152	18.1786
(72h,168h]	一重高斯	31398	0.0309	25.8456
(168h,720h]	四次多项式	23193	0.8403	13.6764
(720h,∞)	一次多项式	2520.2	0.848	11.2254

测值，即可得到该观测值的残差，可以用公式 (5.9) 描述。

$$residual = prediction - observation \quad (5.9)$$

其中， $residual$ 表示残差， $prediction$ 表示预测值， $observation$ 表示观测值。

选择首次影像检查和第一次随访的影像检查结果作为计算依据，根据公式 (5.9) 计算出真实值和所拟合曲线之间存在的残差，将首次影像检查结果残差即为 $residual_0$ ，将第一次随访影像检查结果残差即为 $residual_1$ 。则真实值和所拟合曲线之间的残差可以用公式 (5.10) 计算。

$$residual = \frac{residual_1}{residual_2} \quad (5.10)$$

将计算的结果填写在了位置“表 4”F 字段。同时，图5.9将前 100 位患者水肿体积的真实值和所拟合曲线之间存在的残差进行了可视化。




图 5.9 患者水肿体积的真实值和所拟合曲线间的残差

5.2 子问题 b) 构建不同人群的水肿体积随时间进展曲线

5.2.1 问题分析

问题二 b) 旨在探索患者水肿体积随时间进展模式的个体差异，并构建不同人群的水肿体积随时间进展曲线。我们将患者分为 4 组，根据不同亚组的特点分别绘制水肿体积随时间进展的曲线。首先，我们提取出患者水肿体积变化的数据，根据水肿体积变化趋势利用 K-means 聚类将患者分为 4 组；其次，对不同组患者，拟合出不同的水肿体积随时间进展曲线；最后计算真实的水肿体积随时间进展曲线和各亚组的曲线之间的残差，并将分组情况记录在“表 4” H 字段，残差记录在“表 4” G 字段。

5.2.2 K-means 聚类分组

A、K-means 聚类

K-means 聚类是基于样本集合划分的聚类算法，其核心思想是将一组数据划分为 K 个不同的簇。求解 k 的最优值有手肘法、轮廓系数法、基于 DB 指数的方法和 GAP 统计量等方法 [8]。由于手肘法具有直观展示、灵活性强的聚类数量选择等特点，本次 K 求解采用手肘法。该方法通过可视化聚类结果的误差平方和 (SSE) 与簇数 K 的关系，来确定 K 的最优值。具体步骤如下：

- *step 1* : 首先设置要尝试的 K 值范围，通常选择 1 10 等整数；
- *step 2* : 对于每个 K 值，运行 K-means 聚类，计算每个点到其所属簇的中心点的距离的平方和 (SSE)；
- *step 3* : 通过可视化 SSE 随 K 值变化的曲线，观察曲线中的“拐点”，确定最优的 K

值。

一般来说，随着 K 值的增加，簇的个数变多， SSE 会逐渐减小，但是当簇的个数达到一定值时， SSE 的下降速度会减缓，这时有可能出现“拐点”，即曲线上出现一个明显的“弯曲点”。这时，簇的个数应该取拐点处，即为最优的 K 值。

B、K-means 聚类分组结果

据水肿体积变化趋势利用 K-means 聚类对患者进行聚类。聚类数对比图如图5.10所示，该图用于选择较好的聚类数量，横坐标是聚类个数，纵坐标是 K-means 聚类的损失函数是所有样本到类别中心的距离平方和，即为误差平方和，其值越小说明聚类效果越好。分析图5.10得，将患者聚类为 4 组最为合理。




图 5.10 聚类数对比图

图5.11展现聚类为 4 组的结果，其中聚类为 1 组的频数为 6，所占百分比为 6%；聚类为 2 组的频数为 35，所占百分比为 35%；聚类为 3 组的频数为 34，所占百分比为 34%；聚类为 4 组的频数为 25，所占百分比为 25%。表5.4 展示了编号前 10 的患者聚类情况，其他的聚类情况见“表 4” H 字段。

5.2.3 拟合结果

根据不同组患者水肿体积变化趋势，选用合适的拟合模型进行数据拟合。在进行拟合前，利用问题二 a) 数据处理方式折换相同时间内存在多个水肿体积（见表5.1）。为了达到最好的拟合结果，借助 Matlab 的 FitTool，对于 1 组、2 组、4 组进行多项式拟合，对于 3 组进行高斯拟合。

对于组别 1，采用二次多项式进行拟合，其拟合函数由 (5.11) 展示。图5.12为组别 1 拟合函数曲线。

$$ED_V = -0.0004243t^2 + 0.3848t + 36.46 \quad (5.11)$$

对于组别 2，采用二次多项式进行拟合，其拟合函数由 (5.12) 展示。图5.13为组别 2




图 5.11 聚类汇总图

表 5.4 部分患者分组情况

ID	所属亚组
sub001	1
sub002	2
sub003	3
sub004	2
sub005	4
sub006	3
sub007	4
sub008	3
sub009	3
sub010	2

拟合函数曲线。

$$ED_V = -8.273 \times 10^{-6}x^2 + 0.04945x + 12.76 \quad (5.12)$$

对于组别 3，采用高斯函数拟合，其拟合函数由 (5.13) 展示。图5.17为组别 3 拟合函数曲线。

$$ED_V = 45.4e^{\left(\frac{t - 313.9}{615.8}\right)^2} \quad (5.13)$$

对于组别 4，采用三次多项式拟合，其拟合函数由 (5.14) 展示。图5.18为组别 4 拟合函数曲线。

$$ED_V = -8.621 \times 10^{-10}t^3 + 7.038 \times 10^{-6}t^2 - 0.01694t + 11.35 \quad (5.14)$$




图 5.12 组别 1 拟合函数曲线




图 5.13 组别 2 拟合函数曲线




图 5.14 组别 3 拟合函数曲线




图 5.15 组别 4 拟合函数曲线

采用 SSE, R^2 和 $RMSE$ 对回归模型进行评估。具体指标展示在表5.5，可以看出在构建不同人群的水肿体积随时间进展曲线时，使用多项式拟合和高斯拟合相较于其他方法具有较好的性能。

表 5.5 四个拟合模型评估指标

聚类类别	拟合方式	SSE	R^2	$RMSE$
组别 1	二次多项式	13629	0.7459	20.9675
组别 2	二次多项式	2453.5	0.9455	4.7444
组别 3	一重高斯	53415	0.2299	19.9654
组别 4	三次多项式	1128.3	0.89	3.2781

5.2.4 残差计算

同问题二 a) 的残差计算，选择首次影像检查和第一次随访的影像检查结果作为计算依据，利用公式 (5.10) 计算真实的水肿体积随时间进展曲线和各亚组的曲线之间的残差，并将结果填写在“表 4” G 字段。各个组别的残差如图 5.16 所示




图 5.16 各个组别的残差图

5.3 子问题 c) 治疗方法对水肿体积进展模式的影响

5.3.1 问题分析

问题二 c) 旨在根据水肿体积进展模式，分析不同治疗方法对其的影响。具体地，需对不同治疗方法进行比较，探究其对水肿体积进展模式的影响程度。具体的求解思路为：首先，对不平衡样本进行处理，并剔除异常值；接着，根据水肿体积进展模式的不同，将水肿体积进展模式分为 5 类进行处理；再次，利用随机森林和灰度关联法对不同治疗方法进行分析；最后，根据分析结果得到治疗方法对水肿体积进展模式的影响。




图 5.17 组别 3 拟合函数曲线




图 5.18 组别 4 拟合函数曲线

5.3.2 数据处理

A、处理不均衡样本

由于每一位患者进行随访的次数不相同，导致样本不均衡。首先，考虑对样本中缺失值进行插值，但发现样本数量较少，插值效果较差。为了处理不均衡数据，现引入水肿体积进展率 (ED_{pr})，将 ED_{pr} 定义为：

$$ED_{pr} = \frac{\text{水肿变化率}}{\text{时间}} = \frac{\text{最后一次水肿变化体积}-\text{首次检查水肿体积}}{\text{首次检查水肿体积} \times \text{时间}} \quad (5.15)$$

若患者最后几次随访中水肿体积多次为 0，则取最早为 0 的时间利用公式 (5.15) 进行 ED_{pr} 计算。


归一化处理 160 个患者的 ED_{pr} ，并将其展示在图5.19的 (a) 中。由图 X 可以看出， ED_{pr} 存在异常值，将患者 sub127, sub102, sub92, sub31, sub119, sub9, sub48, sub84, sub99, sub101, sub108, sub117, sub129 对应的异常值 ED_{pr} 剔除，并将剔除后的数据用于后续的数据处理中，同时将剔除后的数据展示在图5.19的 (b) 中。

B、水肿体积进展模式分类


观察图5.19发现归一化后的 ED_{pr} 数据存在较为明显的波动，现根据 ED_{pr} 数据将水肿体积进展模式分为急速增长模式，缓慢增长模式，稳定模式，缓慢减小模式，快速减小模式共 5 中模式，并将其分别编号为 1, 2, 3, 4, 5，用于后续的关联性分析。水肿体积进展模式分类依据由表5.6给出。

5.3.3 灰色关联分析

灰色关联分析是一种多因素决策方法，通过对关联度和贡献度的量化计算，评估各个因素对目标因素的贡献程度，从而为决策提供依据。主要思路是将多个影响因素变量的数据序列，转化为具有相同数量等的“灰色数”序列，接着通过计算各个灰色数之间的关联度，从而对影响因素的贡献度进行排序和评估。常用的关联度计算方法有三种，即序列直接匹配法 (GM)、级比关联法 (TOPSIS 法)、相对关联分析法 (GRA 法)。在本模型求解



(a) 原始水肿体积进展率分布图



(b) 剔除后水肿体积进展率分布图

图 5.19 水肿体积进展率分布图

表 5.6 水肿体积进展模式分类依据

模式分类	ED_{pr}	编号
急速增长模式	[0.004431301,0.007431301]	1
缓慢增长模式	[0.00143101,0.004431301)	2
稳定模式	[0.005911514,0.00143101)	3
缓慢减小模式	[0.0149114,-0.0059115)	4
快速减小模式	[-0.0239115,-0.0149154)	5

过程中，采用级比关联法进行求解。

级比关联法是将各因素序列标准化，进行归一化处理，接着计算其级比大小来衡量关联度。其数学方程为：

$$\zeta_{i,j} = \frac{\sum_{k=1}^n w_k \min(x_{ik}, x_{jk})}{\sqrt{\sum_{k=1}^n w_k x_{ik}^2} \sqrt{\sum_{k=1}^n w_k x_{jk}^2}} \quad (5.16)$$

其中， w_k 为权重系数， x_{ik} 和 x_{jk} 分别表示第 i 和 j 个因数在第 k 个时刻的标准取值， $\zeta_{i,j}$ 表示第 i 个因数和第 j 个因数的关联度。

级比关联法通常通过标准化处理、权重确定、加权处理、理想解和负理想解确定以及距离计算等步骤，得到各因素之间的关联度 $\zeta_{i,j}$ 。

5.3.4 关联度分析

利用随机森林和灰度关联法对不同治疗方法进行分析，得到不同治疗方案的关联度表5.7，并绘制出了如图5.20不同治疗方案的关联度条形图。

对于缓慢减小模式和快速减小模式下，即水肿体积的情况下，再次利用灰度关联法进行治疗方法相关性分析，得到结果如表5.8和图5.21。

表 5.7 不同治疗方案的关联度分析

治疗方法	灰度关联法	随机深林
止血治疗	0.932	0.925
止吐护胃	0.635	0.675
镇静、镇痛治疗	0.735	0.758
营养神经	0.362	0.516
脑室引流	0.966	0.965
降压治疗	0.672	0.541
降颅压治疗	0.812	0.843




图 5.20 不同治疗方案的关联度

表 5.8 水肿体积缩小的治疗方案分析

治疗方法	关联度
止血治疗	0.899
止吐护胃	0.758
镇静、镇痛治疗	0.818
营养神经	0.394
脑室引流	0.96
降压治疗	0.798
降颅压治疗	0.859

对比图5.20和图5.21可得，对于水肿治疗而言，脑室引流、降颅压治疗、止血治疗和镇静、镇痛治疗这四种治疗方案最为有效；图5.21展示了治疗效果相对较好的患者采用的质量方法，发现除上述水肿治疗而言，脑室引流、降颅压治疗、止血治疗和镇静、镇痛治疗四种治疗方案，还采用了降压治疗、止吐护胃的治疗方案。说明患者治疗水肿时，针对具体病情，可以同时采用不同的方法进行治疗，能够获得较大的治疗效果。




图 5.21 水肿体积缩小的治疗方案

5.4 子问题 d) 血肿体积、水肿体积及治疗方法关系分析

5.4.1 问题分析

问题二 d) 旨在血肿体积、水肿体积和治疗方法之间的关系, 要探索这些因素之间可能存在的相互影响和依赖关系。具体的求解思路为: 首先计算血肿体积绝对变化和水肿体积绝对变化, 用体积绝对变化与治疗方法进行线性回归分析, 得到血肿体积与治疗方法和水肿体积与治疗方法之间的关系; 其次, 对血肿体积绝对变化和水肿体积绝对变化进行二次多项式拟合, 得到血肿体积与水肿体积之间的关系。

5.4.2 线性回归模型

线性回归是一种常见的统计分析方法, 用于建立自变量 (特征) 与因变量之间的线性关系模型。它适用于预测数值型变量, 并且在许多领域广泛应用。

线性回归模型的数学表达如下:

假设我们有一个自变量 $x_1, x_2, \dots, x_n$ 和一个因变量 y , 线性回归模型可以表示为:

$$y = \beta_0 + \beta_i x_i + \varepsilon \quad (5.17)$$

其中, $i = 1, 2, \dots, n$, y 是待预测的目标变量, 即因变量; x_i 是特征变量, 即自变量; β_0 和 β_i 是回归系数, 即自变量对因变量的影响程度, ε 是误差项即真实值与预测值之间的差异。

线性回归的目标是找到最优的 β_0 和 β_i , 使得预测值 y 与实际观测值之间的误差最小化。通过优化算法 (如梯度下降法), 可以找到最优的 β_0 和 β_i , 从而得到最佳的线性回归模型。

5.4.3 相关性探究

首先计算血肿体积绝对变化 HM_V^v , 水肿体积绝对变化 ED_V^v 。将 HM_V^v 定义为患者最后一次随访影像血肿体积减去首次影像血肿体积, ED_V^v 定义为患者最后一次随访影像水肿体积减去首次影像水肿体积。

分别对血肿体积绝对变化、治疗方法和对水肿体积绝对变化、治疗方法进行线性回归, 得到如图5.22所示的线性回归模型路径图。图5.22中路径权重为归一化后的结果, 具体权

重由线性回归方程 (5.18) 和 (5.19) 描述。




图 5.22 线性回归模型路径图

$$\begin{aligned}
 HM_V^v = & 19.294 + 43.173 \times TM_NSYL - 3.062 \times TM_ZXZL \\
 & + 12.456 \times TM_JLYZL + 5.69 \times TM_ZJZK - 0.16 \times TM_YYSJ \\
 & - 15.318 \times TM_ZTHW + 2.432 \times TM_JYZL
 \end{aligned} \quad (5.18)$$

$$\begin{aligned}
 ED_V^v = & -12.961 - 16.728 \times TM_NSYL + 0.173 \times TM_ZXZL \\
 & + 7.36 \times TM_JLYZL + 16.266 \times TM_ZJZK - 7.911 \times TM_YYSJ \\
 & - 1.323 \times TM_ZTHW + 8.084 \times TM_JYZL
 \end{aligned} \quad (5.19)$$

其中, $TM_{\{\}}^v$ 对应着不同的治疗方案。

利用线性回归方程 (5.18) 和 (5.19) 得到的回归结果如图5.23和图5.24所示。

血肿变化绝对体积 (HM_V^v) 与水肿变化绝对体积 (ED_V^v) 进行二次多项式回归, 以 HM_V^v 为自变量, ED_V^v 为因变量, 得到回归方程 (5.20) 其回归效果如图5.25所示。采用 SSE, R^2 和 $RMSE$ 对回归模型进行评估。具体指标展示在表5.9。由性能评估指标可以看出, 血肿变化绝对体积 (HM_V^v) 与水肿变化绝对体积 (ED_V^v) 进行二次多项式回归效果较好。

$$HM_V^v = -0.004015(ED_V^v)^2 + 0.4254ED_V^v - 5.837 \quad (5.20)$$




图 5.23 血肿变化绝对体积与治疗方法线性回归拟合




图 5.24 水肿变化绝对体积与治疗方法线性回归拟合

表 5.9 HM_V^v 与 ED_V^v 拟合模型评估指标

拟合方式	SSE	R^2	$RMSE$
二次多项式	57541	0.4585	21.2856




图 5.25 血肿变化绝对体积与水肿变化绝对体积回归拟合

6 问题三模型建立与求解分析

6.1 子问题 a) 基于首次影像预测患者 90 天 mRS 评分

6.1.1 问题分析

问题二 a) 旨在根据前 100 个患者的个人史、疾病史、发病相关及首次影像结果构建预测模型，预测 160 个患者 90 天 mRS 评分。具体的求解思路为：首先，将前 100 个患者的所有特征整合成表格，得到所有的特征；接着，进行数据处理，剔除异常值，并对部分特征进行编码或归一化处理；再次，利用卡方检验、递归特征消除、XGBoost 等算法进行特征选择；最后，构建预测模型以预测患者的 mRS 评分，可以借助随机森林，并将预测的 mRS 评分填写在“表 4” I 字段。

6.1.2 数据处理

首先进行数据准备，按照患者编号，将所有特征整合成表格，得到 104 维的特征。同问题一 b) 的数据处理，例如，将性别中男性编码为 1，女性编码为 0；将高压和低压拆分；将年龄进行归一化处理。对异常数据的剔除也同问题一 b)。值得注意的是患者编号为 sub131, sub132 的特征缺失，将其当做异常值进行处理。

6.1.3 特征提取

A、卡方检验

卡方检验是用来统计样本的理论频次和实际频次的吻合程度，可以用来衡量两个变量之间的独立性。在特征选择过程中，可以使用卡方检验来确定每个特征与目标变量之间的

关联程度。卡方检验的公式如下：

$$\chi_c^2 = \sum \left(\frac{O_i - E_i}{E_i} \right) \quad (6.1)$$

其中， c 代表自由度， O 代表观测值， E 代表期望值。

特征选择需要检验两个变量之间的独立性，即特征 f_i 和类别 Y 之间的独立性检验。整个的实现流程有：数据准备、构建列联表、计算期望频数、计算卡方值、计算自由度、查找临界值、比较卡方值和临界值及特征选择。重复以上步骤，对每个待选择特征进行卡方检验，最终可以得到与目标变量显著相关的特征集合。

B、lasso 回归

lasso 回归是通过加入 $L1$ 正则化项来实现特征选择，是一种线性回归的正则化方法。对于给定的数据集 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, x_i 是特征向量， y_i 是对应的目标变量。Lasso 回归的目标是解决以下优化问题：

$$\min J(w) = \frac{1}{2n} \sum (y_i - x_i w)^2 + \alpha \sum |w_j| \quad s.t \sum |w_j| < t \quad (6.2)$$

其中， $w = (w_1, w_2, \dots, w_m)$ 为回归系数向量， $J(w)$ 为损失函数， $\frac{1}{2n} \sum (y_i - x_i w)^2$ 为均方误差， $\alpha \sum |w_j|$ 为 $L1$ 正则化项， α 是正则化参数， t 为约束项。

在这个优化问题中， $L1$ 正则化项通过 $\sum |w_j|$ 这一项来实现。 $L1$ 正范数将回归系数的绝对值之和纳入目标函数，促使回归系数平稳地接近零，从而实现特征选择和产生稀疏模型的效果。通过调整正则化参数 α 的大小，可以控制稀疏性。

C、XGBoost

XGBoost 使用梯度提升算法来进行特征选择。在每一轮迭代中，XGBoost 根据梯度提升的原理计算出当前模型的残差，并将其作为新的目标变量进行拟合。特征选择可以通过以下数学公式描述：

对于二分类问题，给定一个训练集 (x_i, y_i) ，其中 x_i 是特征向量， y_i 是二进制标签（0 或 1）。XGBoost 训练过程中使用的损失函数为二元逻辑损失函数：

$$Loss = \sum_i [y_i \ln(p) + (1 - y_i) \ln(1 - p)] \quad (6.3)$$

其中， p 是模型的预测概率。

在每一轮迭代中，XGBoost 使用梯度和二阶导数来更新模型参数。特征选择主要通过以下几个步骤实现：

- *step 1*：计算每个特征的增益（Gain）：根据当前模型的残差计算出每个特征的增益，表示该特征在解释目标变量时的重要性；
- *step 2*：根据特征增益进行特征排序：将所有特征根据增益进行排序，以确定特征的重要性顺序；
- *step 3*：根据设定的阈值进行特征选择：可以根据设定的阈值选择排名靠前的特征，或者选择增益超过阈值的特征；

- *step 4* : 根据选择的特征重新训练模型：使用选定的特征重新训练模型，获取最终的特征子集。

D、递归特征消除

递归特征消除使用递归的方式来减少特征集合的规模，是一种基于模型的特征选择方法。对于给定的数据集 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, x_i 是特征向量， y_i 是对应的目标变量。进行递归特征消除的步骤为：

- *step 1* : 初始化模型和特征集合：定义一个评估器（例如线性回归、SVM 等）作为模型；初始特征集合 F 包含所有特征 $f_1, f_2, \dots, f_n$ ，其中 n 是特征的总数；
- *step 2* : 确定模型的性能度量：定义一个性能度量函数，例如均方误差或准确率；
- *step 3* : 迭代过程：在每一轮迭代中，训练模型并计算模型的性能度量；取出当前轮次中最不重要的特征（根据模型的权重、系数等）并从特征集合 F 中移除该特征；用剩余的特征重新训练模型，并计算新的性能度量；根据性能度量，判断模型在移除特征后的表现是否变差；如果性能度量变差，说明移除的特征对模型很重要，终止迭代；如果性能度量变好，继续迭代；
- *step 4* : 返回选择的特征子集：当迭代结束时，返回剩余的特征集合 F ，这就是经过递归特征消除后的特征子集。

E、前向选择和后向选择

假设有一个训练集 (x_i, y_i) ，其中 x_i 是特征向量， y_i 是目标变量。利用前向选择进行特征提取的步骤为：

- *step 1* : 初始化特征集合：定义一个空的特征集合 S ；
- *step 2* : 迭代过程：在每一轮迭代中，对于每个未加入特征集合 S 的特征 f_i ，计算加入 f_i 后模型的性能度量；选择使模型性能度量最优的特征 f_{best} ，并将其加入特征集合 S ；如果加入特征 f_{best} 后模型的性能满足事先设定的停止条件，终止迭代；否则，继续下一轮迭代。根据特征增益进行特征排序：将所有特征根据增益进行排序，以确定特征的重要性顺序；
- *step 3* : 返回选择的特征集合：当迭代结束时，返回最终选定的特征集合 S ，其中包含对模型性能有最大贡献的特征。

利用前向选择进行特征提取的步骤为：

- *step 1* : 初始化特征集合：定义一个空的特征集合 S ；
- *step 2* : 迭代过程：在每一轮迭代中，对于特征集合 S 中的每个特征 f_i ，计算移除 f_i 后模型的性能度量；选择使模型性能度量最优的特征 f_{worst} ，并将其从特征集合 S 中移除；如果移除特征 f_{worst} 后模型的性能满足事先设定的停止条件，终止迭代；否则，继续下一轮迭代；
- *step 3* : 返回选择的特征集合：当迭代结束时，返回最终选定的特征集合 S ，其中包含对模型性能有最大贡献的特征。

前向选择和后向选择都是通过不断加入或移除特征来逐步优化模型性能。不同的是，前向选择从空的特征集合开始，逐步添加性能最好的特征；后向选择则从包含所有特征的

初始集合开始，逐步剔除性能最差的特征。

E、特征提取结果

使用卡方检验、lasso 回归、XGBoost、递归特征消除、前向选择和后向选择、*LightGBM* 共六种模型进行特征提取。六种模型共给出六种特征提取结果，为了提高预测模型的准确率，综合各个模型的结果，基于投票的策略，按照“少数服从多数”的原则，采用两类特征集合进行预测模型的构建：一、特征在模型提取结果中出现超过 4 次组成特征集 1；二、特征在模型提取结果中出现超过 3 次组成 2。特征集的数据具体特征如图6.1所示。

房颤史	HM_Pons_Medulla_R_Ratio	ED_Cerebellum_L_Ratio
性别	HM_Cerebellum_R_Ratio	original_shape_LeastAxisLength
年龄	ED_ACA_R_Ratio	original_shape_MajorAxisLength
高压	ED_Pons_Medulla_R_Ratio	
特征集1		
脑出血前mRS评分	HM_Pons_Medulla_R_Ratio	ED_Pons_Medulla_R_Ratio
房颤史	HM_Cerebellum_R_Ratio	ED_Cerebellum_R_Ratio
冠心病史	HM_MCA_L_Ratio	ED_PCA_L_Ratio
发病到首次影像检查时间间隔	HM_Cerebellum_L_Ratio	ED_Cerebellum_L_Ratio
性别	ED_ACA_R_Ratio	original_shape_LeastAxisLength
年龄	ED_MCA_R_Ratio	original_shape_MajorAxisLength
高压	ED_PCA_R_Ratio	original_shape_MeshVolume
original_shape_SurfaceArea	original_shape_Maximum2DDiameterColumn	HM_MCA_R_Ratio
original_shape_Maximum2DDiameterRow	NCCT_original_firstorder_Variance	HM_Pons_Medulla_L_Ratio
特征集2		

图 6.1 特征集中的特征

6.1.4 预测结果

采用随机深林进行预测，得到如图6.2，并将预测结果填写在表 4。

6.2 子问题 b) 预测患者 90 天 mRS 评分

6.2.1 问题分析

问题三 b) 旨在在问题三 a) 的基于上，利用全部影像结果构建预测模型。利用本文的思路：首先是数据清洗，通过对散点图进行可视化，可显著地看出每次随访检查样本数量




图 6.2 随机森林混淆矩阵

随着随访次数的增加而减小。本文采用有效值占比为评价指标对极少数边缘数据进行剔除，选定的阈值为 0.4，即有效检查样本数量至少要达到全部样本的 40%。

6.2.2 问题求解

A、插值

处理前 100 个患者所有已知临床、治疗、影像结果，预测所有含随访影像检查的患者 90 天 mRS 评分是一个解决不平衡样本的问题。由于各种因素的影响，每个患者参与随访检查的次数和频率均不一样，造成了不同患者间检查数据具有差异性，更具体地讲，用来预测患者 90 天 mRS 评分的特征的维度不一致，特征维度高的样本数量少，特征维度低的样本数量多，给模型构建与后续的预测工作带来挑战。

接下来进行缺失值处理，本文采用的方案是利用插补的方法对缺失值进行补全。插补的方法有很多，考虑到本文面临的问题是小样本、不平衡问题，以及很多检查指标的数据与时间序列存在相关性，采取了多重插补和 K 近邻插补的方法。多重插补指的是在多次插补生成多个数据集的基础上，对这些数据及逆行分析并汇总结果，这样做有助于考虑插补的不确定性。K 近邻插指的是综合离缺失值最近的邻居的已知值来得到缺失值的估计值，这是一种较为复杂的方法，可以充分利用检查指标与时间序列呈现的规律性。

B、特征提取

表 6.1 插值前的原始数据

48919.00	57898.00	81747.00	107793.00	126558.00
23526.00	23390.00	28415.00	34868.00	0.00
32621.00	41292.00	49767.00		
22191.00	18956.00	9540.00	5204.00	
47392.00	23182.00	12898.00		

表 6.2 多项式插值后的部分数据

23526	23390	28415	34868	0
32621	41292	49767	50088.77173	36414.36793
22191	18956	9540	5204	5547.45736
47392	23182	12898	7860.863334	2465.979685
97503	95384	81745	50859	24730

表 6.3 最近邻插补后的部分数据

23526	23390	28415	34868	0
32621	41292	49767	62657	48408
22191	18956	9540	5204	4644.2
47392	23182	12898	32346.8	32263
97503	95384	81745	50859	24730

首先对异常值进行了剔除。特征的选取与 a 类似，采用卡方检验选择、前向选择和后向选择、递归特征消除、XGBoost、LightGBM、lasso 回归多个特征选择方法对特征进行选择，并仍然依据投票的原则，即“少数服从多数”，获得了总投票数超过模型总数半数的特征，即总票数大于或者等于 3 的特征。他们分别是：

之后，使用随机森林模型对已选出来的敏感性较强的特征进行学习训练，并保存模型，之后将所有含随访影像检查的患者（sub001 至 sub100,sub131 至 sub160）同样维度的特征再次“喂”给模型进行识别分类，得到 mRS 值。

C、结果分析

结果分析，模型的训练准确度为 0.45，这是因为样本数量匮乏、特征缺失、分类类别多等多方面引起的，并将结果填写在表“4”中。

6.3 子问题 c) 分析患者的预后与临床信息间的关系

6.3.1 问题处理

问题三 c) 在分析出血性脑卒中患者的预后 (90 天 mRS) 和个人史、疾病史、治疗方法及影像特征等关联关系, 为临床相关决策提出建议。问题本质在于探求各个变量与 90 天 mRs 的相关性关系, 并以此为依据给出建议。在, 在各个病人信息的个人史, 疾病史, 治疗方案中除了血压, 其他参数均可认为是定类变量。而在影像特征等信息中, 参数皆为连续变量。因此可以先按照数据类型的不同进行分组, 将已有数据分成定类变量组和定量变量组两组。对于定类变量组, 可以认为 90 天 mRs 为有序等级变量, 这样求解相关性的问题就属于求解“等级变量——多个定类变量”相关性的问题。由上文已知, 卡方检验对于求解“等级变量——多个定类变量”相关性的问题往往具有较好的结果, 因此, 拟采用卡方检验的方法分析 90 天 mRs 与个人史, 疾病史和治疗方案之间的相关关系。在求解 90 天 mRs 和影像特征之间相关性问题时, 由于影像特征均为连续变量, 故将 mRs 特征视作连续变量, 这样, 求解相关性问题的就属于求解“连续变量-多个连续变量”相关性问题的。由上文可知, 斯皮尔曼相关性分析具有适用范围广, 结果解释性强等优点, 故拟采用斯皮尔曼相关性分析的方法求解 90 天 mRs 和影像特征之间的关系。

6.3.2 数据处理

在各个病人信息的个人史, 疾病史, 治疗方案中除了血压, 其他参数均可认为是定类变量。为了便于数据分析, 现将表6.4中血压一类按照如下原则改为定类变量:

表 6.4 血压等级划分

血压值	血压等级
120-139/80-89	0 级 (正常血压)
140-159/90-99	1 级高血压
160-179/100-109	2 级高血压
180/110 及以上	3 级高血压

在影像特征中, 为了减小各个变量之间的差异对结果的影响, 对所有数据进行归一化处理, 归一化公式如下:

$$x_{i_{new}} = \frac{x_i - x_{i_{\min}}}{x_{i_{\max}} - x_{i_{\min}}} \quad (6.4)$$

6.3.3 模型求解

首先求解 90 天 mRs 与定类变量之间的相关性, 利用 SPSS 软件进行卡方检验, 结果如下图6.3:

由上图6.3可知, 各项指标的 P 值均 >0.05, 即各项指标对 90 天 mRs 评分并没有显著性差异。

项目	病例	90天mrs							统计	检验方法	X ²	P	
		0.0	1.0	2.0	3.0	4.0	5.0	6.0					
血运等级		0.0	0	2	2	1	0	0	0	5	pearson-卡方检验	13.041	0.789
		1.0	2	3	1	1	1	1	0	9			
		2.0	0	3	3	1	2	3	0	12			
		3.0	8	11	14	17	9	11	4	74			
合计			10	19	20	20	12	15	4	100			
脑室形态		0.0	10	19	19	19	11	12	4	94	pearson-卡方检验	7.506	0.277
		1.0	0	0	1	1	1	3	0	6			
合计			10	19	20	20	12	15	4	100			
皮质厚度		0.0	2	3	5	4	1	5	1	21	pearson-卡方检验	3.036	0.797
		1.0	8	16	15	16	11	10	3	79			
合计			10	19	20	20	12	15	4	100			
脑沟深度		0.0	3	8	3	5	2	3	0	24	pearson-卡方检验	6.26	0.395
		1.0	7	11	17	15	10	12	4	76			
合计			10	19	20	20	12	15	4	100			
脑室容积		0.0	1	3	1	3	0	0	0	8	pearson-卡方检验	0.802	0.435
		1.0	9	16	19	17	12	15	4	92			
合计			10	19	20	20	12	15	4	100			
髓鞘、髓鞘容积		0.0	9	2	5	2	2	1	0	19	pearson-卡方检验	5.573	0.473
		1.0	7	17	15	18	10	14	4	85			
合计			10	19	20	20	12	15	4	100			
皮质厚度		0.0	0	0	1	0	2	0	0	3	pearson-卡方检验	10.38	0.121
		1.0	10	19	19	20	10	15	4	97			
合计			10	19	20	20	12	15	4	100			
皮质厚度		0.0	0	1	1	1	1	0	0	4	pearson-卡方检验	1.576	0.922
		1.0	10	18	19	19	11	15	4	96			
合计			10	19	20	20	12	15	4	100			

图 6.3 卡方检验结果

利用 SPSS 软件对 90 天 mRs 评分和影像特征进行斯皮尔曼相关性分析，结果如下：




图 6.4 水肿体积及位置热力图




图 6.5 血肿体积及位置热力图




图 6.6 血肿形状热力图




图 6.7 血肿影像热力图

6.3.4 结果分析

由上述分析可知，高血压等级和出血性脑卒中的预后关系很大，患者应该注意饮食和休息，避免较高的高血压等级；采取积极的治疗方案也是非常重要的，但是从已有数据分析并不能得出哪种治疗方案对预后会有较大影响，只能得出积极治疗方案对预后影响较




图 6.8 水肿形状热力图




图 6.9 水肿影像热力图

大。对于疾病史，有糖尿病史和高血压史的患者预后往往不良，且年龄越大的患者预后更加难以控制。

从血肿和水肿体积以及各自发生的位置来看，血肿体积以及水肿体积越大的患者预后越不佳，血肿和水肿发生在大脑左侧前动脉处的患者往往比发生在其他位置的患者预后更不良，其他位置发生水肿对预后的影响没有显著的差异。从血肿和水肿的形状特征及灰度特征来看，血肿和水肿的表面积、体素体积，以及网格体积对预后会有较大的影响。灰度特征中 First Order Statistics 对预后影响很大

以上即结合已有数据分析得出来的结论。

7 模型评价

7.1 模型的优点

1. 在构建发生血肿扩张的事件预测模型中，我们综合考虑了各个特征，建立的整体模型更加精确可信。
2. 在构建患者水肿体积随时间变化进展曲线时，查阅了相关文献，将时间线划分，分别构建不同的拟合函数。相较于单一的拟合函数，分段拟合函数的拟合效果更好。
3. 在评估治疗方法对水肿体积进展模式的影响分析中，创新性构造新的指标参数 ED_{pr} ，有效地解决了不均衡数据的问题。
4. 在构建患者 90 天 mRS 评分预测模型中，采用 6 个特征提取方法对特征进行处理，并构建新的特征数据集，提高了预测模型训练的数据。

7.2 模型的缺点

1. 对于患者的治疗方案，在整个模型的构建中并没有对其相关性进行分析。
2. 在构建患者 90 天 mRS 评分预测模型中，模型的训练准确度为 0.45，考虑到因为样本数量匮乏、特征缺失、分类类别多等多方面引起的。

参考文献

- [1] Byrd J C, Gribben J G, Peterson B L, et al., Select high-risk genetic features predict earlier progression following chemoimmunotherapy with fludarabine and rituximab in chronic lymphocytic leukemia: justification for risk-adapted therapy, *Journal of Clinical Oncology*, 24(3): 437-443, 2006.
- [2] Mittelbach F, Goossens M, Braams J, et al., *The L^AT_EX Companion*, 2nd ed., Reading, MA, USA: Addison-Wesley, 107-109, 2004.
- [3] Wang H, Hu D, Comparison of SVM and LS-SVM for regression, 2005 International conference on neural networks and brain: volume 1, IEEE, 279-283, 2005.
- [4] LaValley M P, Logistic regression, *Circulation*, 117(18):2395-2399, 2008.
- [5] Ho M L, Rojas R, Eisenberg R L, Cerebral edema, *American Journal of Roentgenology*, 199(3):W258-W273, 2012.
- [6] Stokum J A, Gerzanich V, Simard J M, Molecular pathophysiology of cerebral edema, *Journal of Cerebral Blood Flow & Metabolism*, 36(3):513-538, 2016.
- [7] Rabinstein A A, Treatment of cerebral edema, *The neurologist*, 12(2):59-73, 2006.
- [8] Li Y, Wu H, A clustering method based on K-means algorithm, *Physics Procedia*, 25:1104-1109, 2012.

附录 A 部分源程序

A.1 程序 1

code1.m

```
clc;clear all;load('fenduan.mat');
y=[];j=0;
for i=0:0.01:5606
    j=j+1;
    if i<=24&& i>=0
        y(1,j)=0.0003282*i^5-0.01802*i^4+0.3469*i^3-2.792*i
            ^2+9.137*i+5.929;
    else if i>24 && i<=72
        y(1,j)=18.56*exp(-(i-40.17)/15.25)^2)+1.095e15*exp(-(i-1867)/322.4)^2);
    else if i>72 && i<=168
        y(1,j)=42.73*exp(-(i-131.3)/78.13)^2);
    else if i>168 && i<=720
        y(1,j)=1.359e-8*i^4-2.295e-5*i^3+0.01385*i
            ^2-3.468*i+324.2;
    else if i>720
        y(1,j)=-0.0003293*i+1.92;
    end
end
end
end
end
end
end
x=[];k=0;
for i=0:0.01:5606
    k=k+1;
    x(1,k)=i;
end
x(1,1)=0;
plot(x,y);
```

A.2 程序 2

code2.m

```
clc;clear all;
j=0;
for i=0:0.01:5606
    j=j+1;
```

```

if i<=24&& i>=0
    y1(1,j)=i;
    y1(2,j)=0.0003282*i^5-0.01802*i^4+0.3469*i^3-2.792*i
        ^2+9.137*i+5.929;
else if i>24 && i<=72
    y2(1,j)=i;
    y2(2,j)=18.56*exp(-(i-40.17)/15.25)^2+1.095e15*exp
        (-(i-1867)/322.4)^2);
else if i>72 && i<=168
    y3(1,j)=i;
    y3(2,j)=42.73*exp(-(i-131.3)/78.13)^2);
else if i>168 && i<=720
    y4(1,j)=i;
    y4(2,j)=1.359e-8*i^4-2.295e-5*i^3+0.01385*i
        ^2-3.468*i+324.2;
else if i>720
    y5(1,j)=i;
    y5(2,j)=-0.0003293*i+1.92;
end
end
end
end
end
end
end

```

A.3 程序 3

code3.m

```

cclc;clear all;
load('PD.mat');
K=zeros(100,1);
L=zeros(100,1);
for i=1:100
    PD7(i,4)=PD7(i,2)-PD7(i,1);
    PD7(i,5)=PD7(i,4)/PD7(i,1);
end
for j=1:100
    if (PD7(j,4)>6000||PD7(j,5)>0.33)%&&PD8(j,3)<=48
        K(j,1)=1;
    end
end
for k=1:100
    if K(k,1)==1

```

```
L(k,1)=PD7(k,3);  
end  
end
```

A.4 程序 4

code4.m

```
ind=[];  
load('HM_EM.mat');  
for i=1:130  
    for j=2:9  
        if ~isnan(S2(i,j))  
            S2(i,10)=S2(i,j);  
        end  
    end  
end  
for i=1:160  
    S2(i,11)=S2(i,10)-S2(i,1);  
end
```