



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 西安建筑科技大学

参赛队号 23107030070

1.郭歌

队员姓名 2.张倩文

3.毕菲菲

中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

题 目： 出血性脑卒中临床智能诊疗建模

摘 要：

根据国家卫健委最新发布的有关脑卒中的统计数据显示，全球脑卒中患者人数超过 1 亿，我国脑卒中患者的人数超过 2800 万，其发病率逐年增长且趋于年轻化，严重危害了我国人民的生命健康，为社会和患者带来沉重的经济压力。出血性脑卒中的发病率仅次于缺血性脑卒中，在脑卒中各亚型中位居第二。出血性脑卒中是由于非外伤性脑部血管破裂引起的颅内出血，从而导致脑部机械性损伤，并引发一系列脑部异常反应。因此，结合患者临床信息及影像学特征来研究出血性脑卒中的发病概率、演进规律，从而最终精准预测患者的临床预后，这对出血性脑卒中的临床研究具有重要的意义。

针对问题一，对第一小问，对数据进行预处理，根据**影像检查流水号**建立多表之间的**关联性**。首先，依据血肿扩张原则：血肿体积比首次影像检查的绝对血肿体积增加 $\geq 6\text{mL}$ 或者相对体积增加 $\geq 33\%$ ，用 **python** 遍历分析前 100 患者在 48 小时内是否发生血肿扩张。接着，对第二小问，表中数据进行整合，同时进行数据预处理和**归一化**，通过**因子分析法**对数据进行降维，提取主要特征变量，构建基于**逻辑回归模型**和**随机森林**的预测概率模型，通过评价指标及对比分析可得，最终选取了准确率较高的随机森林模型来预测 160 位患者血肿扩张的概率。

针对问题二，通过数据预处理筛选出前 100 位患者的多次影像检查时间点及对应水肿体积的数据。对第一小问，选取**局部加权回归 LOESS**（Epanechnikov 内核、Cauchy 内核）、**七阶多项式**、**二元高斯拟合**四种方式对前 100 位患者数据**散点图**进行拟合，通过 **RMSE**、 **R^2** 、**Adjusted R^2** 三个评价指标进行分析，最终选取**二元高斯拟合**患者水肿体积随时间进展曲线并计算**残差**；对第二小问，通过 **DBSCAN 聚类**和 **k-means 聚类**各分为四个亚组，选取**一元高斯**对各亚组进行曲线拟合并计算两种聚类方式对应的残差，最终选取 **k-means 聚类**的分亚组方式，通过**可视化**验证了分亚组分析的有效性；对第三小问，构建**单个治疗方案与水肿体积进展**一对一的分析模型，再利用**线性混合效应模型**定量分析多个治疗方案与水肿体积进展的一对多的模型，通过**均方差**、**标准误差**、**显著性水平**进行分析；对第四小问，利用**皮尔逊（Pearson）**对血肿体积和水肿体积的**相关性**进行分析，再利用线性混合效应模型对治疗方案与血肿体积进展进行分析，最后对治疗方案、水肿体积、血肿体积的**关联性**两两进行分析得出结论。

针对问题三，对第一小问，首先对数据进行预处理和标准化，使用**灰度关联分析**、**随机森林算法**、**极致梯度提升模型**对变量进行筛选操作，对三种算法筛选出的变量两两取交

再取并，筛选得到 21 个变量，并进行**独立性检验**，其次，以患者的 21 个变量为自变量，患者的 90 天 mRS 评分为因变量，构建了基于 **BP 神经网络**、**梯度提升树（GBDT）**、**极致梯度提升（XGBoost）**的预测模型，发现极致梯度提升算法模型预测的 mRS 评分更加接近于真实值，模型准确率更高。对第二小问，将患者的最后一次随访信息的有关变量进行数据整合，后续进行与第一小问相同的操作，筛选出 28 个特征变量，最终发现在考虑患者随访影像信息的条件下，**BP 神经网络**对患者的 mRS 评分预测最为准确。对于第三小问，在前两问特征筛选的基础上，通过 **Pearson 分析**发现，患者的个人史等影像特征变量与 mRS 评分存在不同程度的相关性，对筛选得到的 28 个特征变量进行分析，最终分为四类关系，并对脑卒中患者的临床给出建议。

关键词：出血性脑卒中；血肿体积；水肿体积；高斯拟合；线性混合效应模型；随机森林模型；BP 神经网络

目 录

一、问题重述	6
1.1 问题背景	6
1.2 待求解问题	7
二、模型假设与符号说明	9
2.1 模型假设	9
2.2 符号说明	9
三、问题 1(a)分析与求解	10
3.1 问题 1(a)分析与思路	10
3.2 数据预处理	10
3.3 血肿扩张的定义	10
3.4 血肿扩张判定模型建立与求解	10
四、问题 1(b)分析与求解	13
4.1 问题 1(b)分析与思路	13
4.2 数据预处理	13
4.2.1 数据整合	13
4.2.2 数据初始化处理	14
4.3 基于逻辑回归模型预测概率的建立	16
4.3.1 模型准备	16
4.3.2 模型建立	16
4.3.3 模型求解与分析	16
4.4 基于随机森林模型预测概率的建立	17
4.4.1 模型准备	17
4.4.2 模型建立	18
4.4.3 特征变量提取结果	18
4.4.4 模型求解与分析	19
五、问题 2(a)分析与求解	21
5.1 问题 2(a)分析与思路	21
5.2 数据预处理	21
5.3 基于局部加权回归 (LOESS) 的水肿体积进展模型	22
5.4 基于七阶多项式的水肿体积进展模型	23
5.5 基于高斯拟合的水肿体积进展模型	23
5.6 模型分析与评价	24
六、问题 2(b)分析与求解	27
6.1 问题 2(b)分析与思路	27
6.2 基于 DBSCAN 聚类的分亚组水肿体积随时间进展模型的建立	27
6.2.1 模型准备	27
6.2.2 模型建立	28
6.2.3 模型求解与分析	28
6.3 基于 k-means 聚类的分亚组水肿体积随时间进展模型的建立	30
6.3.1 模型准备	30
6.3.2 模型建立	31
6.3.3 模型求解与分析	31

6.4 两种聚类模型对比与评价	33
七、问题 2(c)分析与求解.....	37
7.1 问题 2(c)分析与思路.....	37
7.2 基于线性混合效应模型的治疗方式对水肿体积进展影响模型的建立	37
7.2.1 数据预处理	37
7.2.2 模型准备	37
7.2.3 模型建立与分析	38
八、问题 2(d)分析与求解.....	41
8.1 问题 2(d)分析与思路.....	41
8.2 水肿体积、水肿体积、治疗方式的相关性分析模型的建立	41
8.2.1 数据预处理	41
8.2.2 模型建立与分析	41
8.3 模型分析与评价	42
九、问题 3(a)的分析与求解.....	44
9.1 问题 3(a)的分析与思路.....	44
9.2 问题 3(a)的数据预处理.....	44
9.3 基于灰色关联分析的特征筛选	45
9.3.1 模型准备与建立	45
9.3.2 特征筛选结果	45
9.4 基于随机森林算法的特征筛选	46
9.4.1 模型准备与建立	46
9.4.2 特征筛选结果	46
9.5 基于 XGBoost 算法的特征筛选	48
9.5.1 模型准备与建立	48
9.5.2 特征筛选结果	48
9.6 基于交叉分析的主要特征变量的选取	50
9.6.1 三种模型的交叉分析	50
9.6.1 主要特征变量的独立性检验	51
9.7 基于 BP 神经网络的预测模型	51
9.7.1 模型准备与建立	51
9.7.2 模型评分结果	53
9.8 基于 GBDT 算法的预测模型	53
9.8.1 模型准备与建立	53
9.8.2 模型评分结果	54
9.9 基于 XGBoost 算法的预测模型	54
9.9.1 模型准备与建立	54
9.9.2 模型评分结果	55
9.10 模型评价与选择	55
十、问题 3(b)的分析与求解.....	58
10.1 问题 3(b)的分析与思路.....	58
10.2 问题 3(b)的数据预处理.....	58
10.3 特征筛选及交叉分析	58
10.4 独立性检验	59
10.5 mRS 预测模型建立与分析	60

10.6 模型评价与选择	61
十一、问题 3(c)的分析与求解	63
11.1 问题 3(c)分析与思路	63
11.2 问题求解	63
十二、模型评价与改进	65
12.1 模型优点	65
12.2 模型改进	65
十三、参考文献	66
附录	67

一、问题重述

1.1 问题背景

脑卒中，俗称中风，是一种急性脑血管疾病，为急性发生的局灶性血管源性神经功能缺损综合征，主要是由于人体脑部血管突然破裂或因血管堵塞导致血液不能正常流入大脑而引起的脑组织损失的一种疾病，包括出血性脑卒中和缺血性脑卒中，如图 1-1 所示，左侧为出血性脑卒中，右侧为缺血性脑卒中。出血性脑卒中通常又称为颅内出血，病因多为高血压、颅内动脉瘤或血管畸形破裂引起，从而造成脑部机械性损伤，引起一系列的生理复杂病理反应。出血性脑卒中虽然发病率低于缺血性脑卒中，但因其起病急、进展迅猛、预后干预较差、后果严重，但其死亡率和病残率均高于缺血性脑卒中，约 80% 的患者在后期会导致较严重的神经功能障碍，病患家庭因此蒙受巨大的经济损失和身心健康。




图 1-1 出血性与缺血性脑卒中示意图

根据 2019 年全球疾病研究结果显示，我国新增脑卒中病例 394 万，其中，缺血性卒中 287 万例，脑出血 85 万例。同时，脑卒中在不同年龄段和男女中发病的概率不同，其临床数据统计图如图 1-2 结果显示，图中的数据显示脑卒中在 40~70 岁之间发病率相对较高，并且男性人群的发病率高于女性人群。因此，脑卒中是威胁我国人民群众健康的“头号杀手”，可导致患者肢体瘫痪、言语障碍、吞咽困难、认知障碍等症状，应该引起越来越多的人的重视。




图 1-2 部分脑卒中患者临床数据统计图

急性脑出血发病 24 小时内，脑出血引起的卒中治疗方案很少，平均 20% 的脑出血患

者会出现血肿扩大，在随机临床试验中，控制血压和止血治疗可降低血肿范围扩大，但并没有改善功能预后，导致颅内神经功能的进一步恶化损伤等，因此，检测和预防血肿体积是判断预后功能的重要因素之一。此外，血肿周围水肿的动力学和它的峰体积已经被证实会引起脑出血后继发性损伤，增加患者严重颅内压风险，威胁患者生命安全^[1]。脑出血患者脑部结构 CT 平扫图如图 1-3 所示，右图红色部分为脑出血血肿部分，黄色部分为脑出血水肿部分。




图 1-3 左图脑出血患者 CT 平扫，右图红色为血肿，黄色为血肿周围水肿

本文的目的旨在通过对海量的临床医学影像数据及患者信息分析，针对出血性脑卒中的两个重要因素，即血肿扩张和血肿周围水肿的发生，构建出血性脑卒中临床智能诊疗模型，研究血肿扩张、血肿周围水肿扩张及规律，及时准确干预患者疗效和评估预后方案，为后续临床实验提供科学依据，改善出血性脑卒中患者的临床预后反应。

1.2 待求解问题

针对上述问题及有关附件等数据，通过数学建模解决以下问题：

问题 1：建立血肿扩张风险模型，预测血肿扩张事件、时间和概率

a) 根据患者个人信息、血肿及水肿的影像信息等数据，通过血肿前后体积的变化判断前 100 位数据样本的患者是否在 48 小时内发生血肿扩张，发生血肿扩张记录为“1”，否则记录为“0”，并同时记录血肿扩张时间。

b) 基于“表 1、表 2、表 3”的前 100 患者（sub001 至 sub100）的影像检查结果相关字段，构建变量-血肿扩张事件的预测模型，预测表中 160 位患者发生血肿扩张的概率。（注：只包含患者首次影像检查结果的相关记录）。

问题 2：血肿周围水肿进展的模型建立，预测治疗方法与水肿进展的的关联性

a) 构建“表 2”中前 100 个患者水肿体积（ED_volume）随发病至影像检查时间的拟合曲线，计算并分析前 100 个数据样本患者（sub001 至 sub100）对应的真实值与拟合曲线值的残差。

b) 根据个体性差异，划分 3~5 个分组，构建前 100 位患者水肿体积随时间进展的拟合曲线，计算并分析前 100 位患者真实值与拟合曲线值的残差。

c) 构建预测模型，分析“表 2”治疗方式相关列中脑室引流、止血治疗、降颅压治疗等方式对水肿进展的影响。

d) 建立相关模型，预测并分析请分析“表 1”中血肿体积、水肿体积及治疗方法的关系。

问题 3：出血性脑卒中患者预后模型的建立，并对其关键影响因素的探索与分析

a) 根据“表 1”中前 100 位数据样本患者的个人史、疾病史、发病等相关字段及“表 2”、“表 3”中对应的首次影像结果，建立模型预测 160 位所有患者的 90 天 mRS 评分，记录 mRS 的 0-6 等级结果。（注：只包括患者首次影像的检查信息）

b) 根据“表 1”中前 100 位数据样本患者的个人史、疾病史、发病等相关字段及“表 2”、“表 3”中对应的影像检查结果（首次+随访），建立模型预测所有含随访影像患者的 90 天 mRS 评分，记录 mRS 的 0-6 等级结果。

c) 分析出血性脑卒中患者预后的 90 天 mRS 与“表 1”中个人史、疾病史、治疗方法、“表 2”中影像的相关特征的关联性，结合分析提出临床建议。

二、模型假设与符号说明

2.1 模型假设

在分析和建模过程中，根据出血性脑卒中临床数据做出以下假设：

假设 1：假设附件中提供的所有患者的影像数据全部真实有效；

假设 2：假设经预处理的数据可作为构建相关模型的数据集，所剔除的异常值数据对模型的影响忽略不计；

假设 3：假设探究水肿体积随时间进展时，其血肿体积变化、个人史，疾病史，治疗方案对其变化的影响可忽略不计；

假设 4：假设各变量之间存在一定的非线性关系；

假设 5：假设附件提供的 160 位患者数据能全面描述各变量之间的关系。

2.2 符号说明

符号	符号说明
θ	血肿扩张体积阈值
β	血肿扩张比率阈值
i	第 <i>i</i> 次
v_{ai}	随访 <i>i</i> 与首次检查血肿体积差值
v_{oi}	随访 <i>i</i> 与首次检查血肿体积增长率
t	时间
ED_volume _{<i>i</i>}	第 <i>i</i> 次随访水肿体积
HM_volume _{<i>i</i>}	第 <i>i</i> 次随访血肿体积
m	检查重复次数
w_i	<i>i</i> 的权重系数
Δv_i	<i>i</i> 的残差向量
$\bar{v}_j$	患者 <i>j</i> 的平均残差
$d(x, y)$	<i>x</i> 和 <i>y</i> 的欧氏距离
∂	关联系数

三、问题 1(a)分析与求解

3.1 问题 1(a)分析与思路

根据要求构建血肿扩张判定模型，从“表 1”中提取患者入院首次影像检查流水号、发病到首次影像检查时间间隔两个字段，从“表 2”提取患者各时间点流水号以及在该随访时间的血肿体积 HM_volume 多个字段，并且使用“附表 1”来查询每个流水号所对应影像检查时间。分析发病 48 小时内患者 sub001 至 sub100 血肿体积的变化情况，当后续每次随访时通过影像检查血肿体积，若此时血肿体积比首次影像检查的绝对血肿体积增加 $\geq 6\text{mL}$ 或者相对体积增加 $\geq 33\%$ ，则可以判断为该患者在 48 小时内发生血肿扩张，并记录该患者的血肿扩张时间，否则，标记为未发生血肿扩张。

3.2 数据预处理

本文首先检查从“表 1”、“表 2”以及“附表 1”中提取的对应列是否存在全 0 列以及空值的情况，通过 python 算法进行遍历并未检查到 0 值以及空值。同时通过检索发现“表 1”、“表 2”、“附表 1”中出血性脑卒中患者 sub074 的流水号不对应，将此异常值进行更改，在后续数据筛选中仍以“表 1”为准，对本问构建的表格中其余的数据不做剔除操作。

3.3 血肿扩张的定义

48 小时内各出血性脑卒中患者血肿扩张的定义 $f(x)$ 如式 (3-1) 所示：

$$f(x) = \begin{cases} 1, & \text{if } v_{ai} \geq \theta \text{ or } v_{oi} \geq \beta \\ 0, & \text{其余情况} \end{cases} \quad (3-1)$$

其中， θ 的阈值定义为 6mL ， β 的阈值定义为 33% ， $v_{ai} = \text{HM_volume}_{\text{后}} - \text{HM_volume}_{\text{首}}$ ， $v_{oi} = \frac{v_{ai}}{\text{HM_volume}_{\text{首}}}$ ， $\text{HM_volume}_{\text{首}}$ 表示首次影像检查的血肿体积， $\text{HM_volume}_{\text{后}}$ 表示后续每一次随访的影像检查血肿体积。

3.4 血肿扩张判定模型建立与求解

在图 3-1 中， t_0 表示发病到首次影像检查时间间隔， t_i ($i=1, 2, \dots, 5$) 表示同一检查流水号患者对应的第 i 次随访时间-入院首次检查点时间的的时间间隔， v_{ai} 表示血肿块的绝对体积，即第 i 次随访时间的血肿体积-入院首次检查的血肿体积， v_{oi} 表示表示血肿块的相对体积，即血肿块的绝对体积与入院首次检查的血肿体积的比值，利用 python 分别计算 t_i 、 v_{ai} 、 v_{oi} 。完成初步的数据处理后，判断表一前 100 位患者的数据样本在 48 小时内是否发生血块扩张，若发生扩张，同时记录血肿扩张的时间。其处理步骤如下：

Step1: 筛选 t_0+t_1 小于等于 48 小时的样本数据，若 $v_{ai} \geq 6\text{mL}$ 或 $v_{oi} \geq 33\%$ ，认为在 48 小时时间间隔内已发生血肿扩张，标定为 1，并计算血肿扩张时间；

Step2: 筛选出 t_0+t_1 大于 48 小时的样本数据，认为在 48 小时时间间隔内未发生血肿扩张，标定为 0；

Step3: 在 Step1 的数据处理的基础上，若 $v_{ai} \leq 6\text{mL}$ 或 $v_{oi} \leq 33\%$ ，则继续筛选 t_0+t_2 小于等于 48 小时的样本数据，按照 Step1 的方法将 48 小时内已血肿扩张的患者数据样本标定为 1，计算血肿扩张时间；

Step4: 在 Step1 的数据处理的基础上，筛选出 t_0+t_2 大于 48 小时的样本数据，认为该患者样本数据在 48 小时时间间隔内未发生血肿扩张，标定为 0；

.....

Step5: 以此迭代，直到标定完 100 个患者样本数据。




图 3-1 判断血管扩张流程图

对得出的是否发生血肿的标定结果填入“表 4-答案文件.xlsx”中的 C 列，将血肿扩张发生时间填入“表 4-答案文件.xlsx”中的 D 列。表 3-1 统计了 48 小时间隔内发生血肿扩张的患者，如下表所示：

表 3-1 患者血肿扩张发生情况统计表

	是否发生血肿扩张	血肿扩张时间		是否发生血肿扩张	血肿扩张时间		是否发生血肿扩张	血肿扩张时间
	1 是, 0 否	单位: 小时		1 是, 0 否	单位: 小时		1 是, 0 否	单位: 小时
sub001	0		sub035	0		sub068	0	
sub002	0		sub036	1	39.5	sub069	0	
sub003	1	9.52	sub037	0		sub070	1	9.65
sub004	0		sub038	1	15.81	sub071	0	
sub005	1	26.47	sub039	1	29.18	sub072	0	
sub006	0		sub040	0		sub073	0	
sub007	0		sub041	0		sub074	0	
sub008	0		sub042	0		sub075	0	
sub009	1	40.06	sub043	0		sub076	1	15.99
sub010	0		sub044	0		sub077	1	14.12
sub011	0		sub045	0		sub078	0	
sub012	0		sub046	0		sub079	1	27.85

sub013	0		sub047	0		sub080	1	20.57
sub014	0		sub048	1	12.86	sub081	1	27.42
sub015	0		sub049	0		sub082	0	
sub016	0		sub050	0		sub083	0	
sub017	1	14.87	sub051	0		sub084	0	
sub018	0		sub052	0		sub085	0	
sub019	0		sub053	0		sub086	0	
sub020	0		sub054	1	16.23	sub087	0	
sub021	0		sub055	0		sub088	0	
sub022	0		sub056	0		sub089	0	
sub023	0		sub057	1	14.62	sub090	0	
sub024	0		sub058	0		sub091	0	
sub025	0		sub059	0		sub092	1	11.92
sub026	0		sub060	1	23.73	sub093	0	
sub027	0		sub061	1	6.54	sub094	0	
sub028	0		sub062	0		sub095	1	7.43
sub029	0		sub063	0		sub096	0	
sub030	0		sub064	0		sub097	0	
sub031	0		sub065	0		sub098	1	42.76
sub032	0		sub066	0		sub099	1	17.67
sub033	1	30.81	sub067	0		sub100	0	
sub034	0							

四、问题 1(b)分析与求解

4.1 问题 1(b)分析与思路

构建血肿扩张预测概率模型，根据题目要求，基于“表 1”、“表 2”、“表 3”的特征变量，以相关特征变量为输入特征，是否发生血肿扩张事件为目标变量，构建模型预测 160 个患者发生血肿扩张的概率。首先根据要求筛选表中特征变量（例如年龄、性别等），对数据进行归一化预处理，通过因子分析提取主要成分，通过构建逻辑回归和随机森林回归模型预测所有患者血肿扩张现象，通过评价指标进行分析比较，选取结果较好的随机森林为预测模型，结果以概率形式输出。思路流程图如图 4-1 所示。




图 4-1 问题 1(b)思路流程图

4.2 数据预处理

4.2.1 数据整合

1)提取“表 1”中前 100 位患者的“E”到“W”字段的个人史、疾病史、治疗方式相关的等 19 个特征字段；

2)提取“表 2”前 100 位患者的“C”到“X”字段的首次影像检查结果中全脑 10 个不同位置对应的右侧大脑前动脉，左右侧大脑中动脉等 22 个特征字段；

3)根据前 100 位出血性脑卒中患者各自对应的检索流水号，在“表 3”中筛选前 100 位患者对应流水号的首次影像检查结果的血肿的形状及灰度分布的相关数据中 31 个特征字段；

4)对于“表 1”发病相关特征的血压字段，其包括收缩压/舒张压，我们将该列拆分为收缩压、舒张压共计 2 个字段列。

5)将以上前 4 步骤所提取 74 个相关特征变量作为自变量，将患者是否血肿扩张事件

作为目标变量进行整合，为接下来的预处理及模型预测做准备。

4.2.2 数据初始化处理

上述整合的 74 个特征变量可能存在异常值而且变量较多相互影响，如果直接用这些输入变量进行预测，会导致预测结果的准确率下降，因此笔者小组对数据整合后的样本数据进行预处理，流程图如 4-2 所示。




图 4-2 样本数据预处理流程图

1) 数据归一化与数据清洗

由于不同特征变量的取值范围和量纲不一致，这样会对后续数据处理结果产生影响，因此对原始数据中的 74 个特征变量进行归一化处理，将原始数据映射到[0, 1]的区间内，将有量纲的数据转化为无量纲的数据，以便于后续加权处理，使各变量标准化为同一数量级，使其在后续数据分析中具有可比性、达到简便计算的效果。

初值归一化即将原始数据映射到[0, 1]的区间内，其转换公式定义为式（4-1）所示：

$$X_{new} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (4-1)$$

其中， X_{min} 代表数据样本中的最小值， X_{max} 代表数据样本中的最大值， X_{new} 表示归一化后的数据样本。本题将所有变量的数据进行归一化处理，使其数据范围映射到[0,1]的取值范围内，消除原始量纲，加快后续患者是否发生水肿扩张概率预测模型曲线的收敛。

对归一化后的样本数据使用 python 进行数据清洗，针对缺失值、异常值、全为 0 的列等进行检索，通过遍历进行数据清洗。由于“表 1”中性别字段为定类变量，不能在后续

模型预测中读取变量的值，需要将其重新编码改成定量变量数据，利用 python 中的字典映射将性别字段的“女”编码为“0”，“男”编码为“1”。

2) 因子分析

因子分析是基于对数据样本进行降维的思想，在保证不损失或少损失的数据信息的情况下，将原始多个输入变量进行相关性聚合，提取出共性因子，这些共性因子既可以反映出原始众多变量的相关性关系，又可以将众多变量根据相关性进行分组整合，在避免重要数据信息丢失的前提下，将原始变量关系转化为共性因子间的组合，实现变量降维处理，重述变量内在关系，构建模型如下：

$$\begin{cases} x_1 = a_{11}F_1 + a_{12}F_2 + \cdots + a_{1q}F_q + e_1 \\ x_2 = a_{21}F_1 + a_{22}F_2 + \cdots + a_{2q}F_q + e_2 \\ \cdots \cdots \cdots \\ x_m = a_{m1}F_1 + a_{m2}F_2 + \cdots + a_{mq}F_q + e_m \end{cases} \tag{4-2}$$

将公式 4-2 表示为矩阵形式，具体如下所示：

$$\begin{pmatrix} x_1 \\ x_1 \\ \vdots \\ x_m \end{pmatrix} = (a_{ij})_{m \times q} \begin{pmatrix} F_1 \\ F_2 \\ \vdots \\ F_q \end{pmatrix} + \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_m \end{pmatrix} \tag{4-3}$$

式中： $F_1, F_2, \cdots, F_q$ ($m \leq q$) 是公共因子，彼此互不相关，且 $E(F)=0$, $Cov(F)=1$ ； $\varepsilon = (e_1, e_2, \cdots, e_m)^T$ 与 $F = (F_1, F_2, \cdots, F_q)^T$ 相互独立，且 $e_1, e_2, \cdots, e_m$ 相互间独立。在因子分析法中，将 $(a_{ij})_{m \times q}$ 定义为因子载荷矩阵，表示第 i 个变量 x_i 在第 j 个公因子 F_j 上的载荷大小，综上可知，因子分析法可以用少量的 F 代替原有的 X ，实现了变量的降维。

首先通过 KMO 检验和 Bartlett 球形检验的结果显示，水平上呈现显著性，拒绝原假设，各变量间具有相关性，因子分析有效。从方差解释表 4-1 中可以看出，在主成分 19 时，总方差解释的特征根低于 1，因此共提取主成分 18 个，变量解释的贡献率达到 84.78%。由碎石图 4-3 也可以看出，从第 18 个成分之后，特征值下降的坡度趋势非常缓慢，基本保持不变，趋于平缓，因此通过碎石图和方差解释表保留主要因子为 18 个。

表 4-1 方差解释表

总方差解释						
成分	旋转前方差解释率			特征根	旋转后方差解释率	
	特征根	方差解释率 (%)	累积方差解释率 (%)		方差解释率 (%)	累积方差解释率 (%)
1	12.744	17.457	17.457	1199.027	16.425	16.425
2	8.584	11.76	29.217	591.211	8.099	24.524
3	6.063	8.306	37.523	558.767	7.654	32.178
4	5.247	7.187	44.71	456.154	6.249	38.427
5	4.09	5.603	50.313	444.892	6.094	44.521
6	3.088	4.231	54.543	279.907	3.834	48.356
7	2.571	3.522	58.065	277.929	3.807	52.163
8	2.442	3.346	61.411	256.423	3.513	55.675
9	2.289	3.135	64.546	246.975	3.383	59.059
10	2.157	2.955	67.501	237.163	3.249	62.308
11	1.884	2.581	70.083	212.319	2.908	65.216
12	1.727	2.365	72.448	209.785	2.874	68.09

13	1.626	2.227	74.675	206.019	2.822	70.912
14	1.478	2.025	76.7	204.216	2.797	73.709
15	1.395	1.911	78.611	204.148	2.797	76.506
16	1.322	1.811	80.422	179.877	2.464	78.97
17	1.121	1.536	81.958	170.915	2.341	81.311
18	1.077	1.476	83.434	154.921	2.122	83.434
19	0.982	1.346	84.78			




图 4-3 碎石图

随后通过成份矩阵表说明各个成分的所包含的因子得分系数（主成分载荷），用于计算出成分得分，最终得到的关于所有患者的 18 个因子得分表见附表 1-共性因子得分表。

4.3 基于逻辑回归模型预测概率的建立

4.3.1 模型准备

逻辑回归^[2]又称 logistic 回归分析，是一种广义的线性回归分析的模型，主要用于解决分类或回归问题，通过建立代价函数，通过优化方法进行迭代求解出最优解的模型参数，然后进行测试来判断模型的好坏。逻辑回归根据给定的自变量来进行求解因变量事件发生的概率，因此因变量范围取值在 0-1 范围内。

4.3.2 模型建立

Step1: 首先根据前 100 个患者（sub001~sub100）的特征变量按照训练集与测试集 8: 2 的形式来构建逻辑回归模型，进行五折交叉验证。

Step2: 通过建立逻辑回归来计算特征重要性。

Step3: 将 160 个患者（sub001~sub100）作为测试集来测试，得到模型的分类评估结果，预测所有患者的血肿扩张概率。

Step4: 对模型概率预测的结果进行评价分析。

4.3.3 模型求解与分析

通过构建 logistic 回归模型，图 4-4 显示了前 100 个患者和 160 个患者中，真实值（是否发生血肿扩张事件，即 0 或 1）和预测值（血肿扩张预测概率，即 0~1）的拟合图。可以看出在 sub001~sub100 范围内，真实值与预测值出入较大，模型预测的概率结果较差。




图 4-4 逻辑回归拟合图

表 4-2 展现了针对 160 个患者的特征变量（测试集），随机森林模型预测血肿扩张概率的评价指标：

表 4-2 逻辑回归模型评价指标

分类	Precision	Recall	F1-score	Support
0	0.67	0.49	0.51	128
1	0.54	0.36	0.45	32

Precision（精确度）：正确预测为正的，占全部预测为正的比例，越接近于 1 越好。

recall（召回率）：正确预测为正的，占全部实际为正的比例，越接近于 1 越好。

F1-score（F1 值）：精确率和召回率的调和平均数，越接近于 1 越好。

support（各分类样本的数量）。

笔者小组经过综合分析，基于逻辑回归模型来预测血肿扩张事件的概率，模型准确率较低，性能较差。

4.4 基于随机森林模型预测概率的建立

4.4.1 模型准备

随机森林^[3]是一种由决策树构成的算法，不同决策树之间没有关联。决策树是一种树形结构，包括了一个根节点、若干个子节点和内部节点，图 4-5 列举了二分类决策树的形状。在进行分类任务时，对于输入的样本，森林中的每一棵决策树分别进行判断和分类，每个决策树会得到自己的分类结果，哪一个决策树的分类结果中分类最多，那么随机森林就会把这个结果当做最终的结果。随机森林的表现一般往往要优于单一的决策树，因为随机森林的结果是通过多个决策树结果进行投票，从而组成一个强分类器来决定最后的结果，并且由于其随机性，随机森林对于降低模型方差效果显著，有取得较好的泛化性能。




图 4-5 二分类决策树

随机森林每棵树构成的主要步骤如下：

- 1) 如果选取了 N 个样本，针对每个树，在原始样本中通过随机且有放回的抽取 N 个样本来训练决策树，每个树的训练集都是 N 个，他们各不相同但会包含一些重复的训练样本。
- 2) 如果每个样本存在 M 个特征属性，则在每个节点分裂的时候，从 M 中随机选择 m 个特征维度 ($m < M$)，在这些 m 个特征维度中按照最佳特征(最大化信息增益)来分割节点。在森林生长期间， m 的值保持不变。
- 3) 决策树形成过程中每个节点都按照步骤 2 来进行分裂，直到某一次该节点选出来的属性是刚刚其父节点分裂时用过的属性，则该节点已经达到了叶子节点，无须继续分裂了。
- 4) 按照步骤 1~3 建立大量的决策树，构成随机森林，生成过程如下图 4-6 所示。




图 4-6 随机森林的生成过程

4.4.2 模型建立

Step1: 首先根据前 100 个患者 (sub001~sub100) 的特征变量按照训练集与测试集 8: 2 的形式来构建随机森林模型，进行五折交叉验证。

Step2: 通过建立的随机森林来计算特征重要性。

Step3: 将 160 个患者 (sub001~sub100) 作为测试集来测试，预测得到所有患者的水肿扩张概率的值。

Step4: 对模型概率预测的结果进行评价分析。

4.4.3 特征变量提取结果

图 4-7 展示了因子分析后的 18 个特征变量各自的重要性比例，可以看出经过因子分析后所筛选的特征变量均占有较大的重要比例。




图 4-7 特征重要性

4.4.4 模型求解与分析

图 4-8 显示了前 100 个患者和 160 个患者中，真实值（是否发生血肿扩张事件，即 0 或 1）和预测值（血肿扩张预测概率，即 0~1）的拟合图，在 sub001~sub100 范围内，可以看出，对于绝大多数患者来说，概率为 50%以下的，真实值为 0，即属于未发生血肿扩张事件，符合前文判断。反之，概率为 50%以上的，真实值为 1，即属于发生血肿扩张事件，符合前文判断。




图 4-8 随机森林拟合图

表 4-3 展现了针对 160 个患者的特征变量（测试集），随机森林模型预测血肿扩张概率的评价指标：

表 4-3 评价指标				
分类	Precision	Recall	F1-score	Support
0	0.92	0.96	0.94	128
1	0.81	0.69	0.75	32

可以看出，基于随机森林模型得出的拟合结果图及评价指标，随机森林模型预测的结果准确率更好，拟合结果基本匹配。

因此在本小问求解血肿扩张概率时，笔者小组最终构建了随机森林模型为预测模型，以此求解 160 个患者血肿扩张预测概率，其值填入“表 4-答案文件.xlsx”中的 E 列。具体结果如表 4-4 所示。

表 4-4 血肿扩张预测概率

	血肿扩张 预测概率		血肿扩张 预测概率		血肿扩张 预测概率		血肿扩张 预测概率
sub001	0.0559	sub041	0.1007	sub081	0.7575	sub121	0.3026
sub002	0.0052	sub042	0.0030	sub082	0.0012	sub122	0.2070
sub003	0.9061	sub043	0.0079	sub083	0.2044	sub123	0.1045
sub004	0.0595	sub044	0.1081	sub084	0.1012	sub124	0.6096
sub005	0.6068	sub045	0.0577	sub085	0.0568	sub125	0.3511
sub006	0.0554	sub046	0.0583	sub086	0.1558	sub126	0.3565
sub007	0.1503	sub047	0.0514	sub087	0.2093	sub127	0.2512
sub008	0.1015	sub048	0.7571	sub088	0.0084	sub128	0.3050
sub009	0.7030	sub049	0.0057	sub089	0.0532	sub129	0.3081
sub010	0.1006	sub050	0.0523	sub090	0.0574	sub130	0.4561
sub011	0.2547	sub051	0.1039	sub091	0.1071	sub131	0.6578
sub012	0.0050	sub052	0.1563	sub092	0.7052	sub132	0.2002
sub013	0.1092	sub053	0.0058	sub093	0.2518	sub133	0.1531
sub014	0.1077	sub054	0.8035	sub094	0.0545	sub134	0.1562
sub015	0.1526	sub055	0.1057	sub095	0.6067	sub135	0.3025
sub016	0.1038	sub056	0.1053	sub096	0.0006	sub136	0.2072
sub017	0.5567	sub057	0.6030	sub097	0.0523	sub137	0.3511
sub018	0.1576	sub058	0.0075	sub098	0.7056	sub138	0.5573
sub019	0.0018	sub059	0.0078	sub099	0.8519	sub139	0.2514
sub020	0.2563	sub060	0.8507	sub100	0.0043	sub140	0.2551
sub021	0.2041	sub061	0.8003	sub101	0.4521	sub141	0.1068
sub022	0.2543	sub062	0.0025	sub102	0.3059	sub142	0.4537
sub023	0.1049	sub063	0.0584	sub103	0.6063	sub143	0.1537
sub024	0.1587	sub064	0.1564	sub104	0.1002	sub144	0.6057
sub025	0.0534	sub065	0.0012	sub105	0.4510	sub145	0.2600
sub026	0.1035	sub066	0.2074	sub106	0.1088	sub146	0.1023
sub027	0.1086	sub067	0.1015	sub107	0.0053	sub147	0.4557
sub028	0.0085	sub068	0.0076	sub108	0.2068	sub148	0.2082
sub029	0.1071	sub069	0.1542	sub109	0.3066	sub149	0.1594
sub030	0.2075	sub070	0.6531	sub110	0.1572	sub150	0.0544
sub031	0.1555	sub071	0.0566	sub111	0.3542	sub151	0.3077
sub032	0.1077	sub072	0.1034	sub112	0.2504	sub152	0.2519
sub033	0.8037	sub073	0.0566	sub113	0.2022	sub153	0.3073
sub034	0.0032	sub074	0.0511	sub114	0.4014	sub154	0.5572
sub035	0.2539	sub075	0.0096	sub115	0.3599	sub155	0.3597
sub036	0.5054	sub076	0.5032	sub116	0.1056	sub156	0.3048
sub037	0.2046	sub077	0.9036	sub117	0.1506	sub157	0.3521
sub038	0.7097	sub078	0.1566	sub118	0.3595	sub158	0.2569
sub039	0.7525	sub079	0.7530	sub119	0.4027	sub159	0.4056
sub040	0.2004	sub080	0.6096	sub120	0.2067	sub160	0.0535

五、问题 2(a)分析与求解

5.1 问题 2(a)分析与思路

通过数据预处理将前 100 位患者的多次影像检查时刻对应的时间与水肿体积的数据筛选出来，其中，自变量是影像检查时刻，因变量是水肿体积（ ED_volume_i ）。接着，绘制 100 位患者数据的散点图，分别选取局部加权回归 LOESS（Epanechnikov 内核、Cauchy 内核）、七阶多项式、二元高斯拟合四种方式进行曲线拟合，通过 RMSE、 R^2 、Adjusted_ R^2 三个评价指标进行评价。思路流程图如图 5-1 所示。




图 5-1 问题 2(a)思路流程图

5.2 数据预处理

为实现水肿体积关于时间的进展模型建立，需要对多张表格中有关水肿体积以及该水肿体积的记录时间的数据进行整合。首先，从“表 2”中获取患者对应初始水肿体积 ED_volume_0 和第 i 次随访对应的水肿体积记录值 ED_volume_i ，共 8 次随访记录。随后，以“表 2”获取每位患者的多次流水号为索引，通过编写 python 代码，从“附表 1”中获取每个流水号对应的时间（格式为年/月/日 时：分：秒）。同时通过检索发现“表 1”、“表 2”、“附表 1”中出血性脑卒中患者 sub074 的流水号不对应，将此异常值进行更改，在后续数据筛选中仍以“表 1”为准。

考虑到每位患者的入院时间不同，同时从“表 1”中整合了每位患者的从发病到入院的时间间隔。此时，我们从三张 excel 表格中得到了用于运算的初始信息。

为实现所有患者发病时间的统一化，将每位患者的发病时间定义为初始时刻 0，从发病到入院的时间间隔为入院时间 t_0 ，第 i 次随访的时间点 t_i （单位：小时）定义为如式 (5-1) 所示：

$$t_i = \text{TIME}(t_{\text{随访 } i \text{ 时间点}} - t_{\text{首次入院检查时间点}}) + \Delta t_{\text{发病到入院时间间隔}} \quad (5-1)$$

其中，TIME（）将格式为年/月/日 时：分：秒的时间点转化为以小时为单位。

5.3 基于局部加权回归（LOESS）的水肿体积进展模型

在大数据分析中，往往因为数据结构的复杂性，通常采取局部分析的方法，用局部的模型来构建全局数据分布的曲线模型。LOESS（locally weighted regression）^[4]是一种用于局部回归分析非参数统计学习方法，其基本思想是把数据样本划分为多个小段，在每个小段内分别进行加权回归曲线拟合，记录每小段的中心点（ x ， y ），再将每小段拟合曲线的中心点分别连接构成总样本的 LOESS 数据曲线。其中，每小段曲线加权时的权重由预测点 x 与训练样本的距离确定，与 x 的距离越近其权重越大，否则反之。

在 SPSS 中画出前 100 位患者首次发病到后续影像所有样本数据的水肿时间—体积散点图，采用局部加权回归(LOESS)来添加总计拟合曲线，选取拟合效果较佳的 Epanechnikov 核密度估计内核和柯西 Cauchy 内核参数对水肿体积随时间的进展变化进行拟合，其拟合结果如图 5-2、图 5-3 所示：




图 5-2 Epanechnikov 内核曲线拟合图




图 5-3 Cauchy 内核曲线拟合图

从上述曲线拟合结果发现，在利用 Epanechnikov 核密度估计内核和柯西 Cauchy 内核参数的局部加权回归模型进行曲线拟合时，在进行相关治疗预案后，水肿体积曲线随时间逐渐呈下降趋势，但在横坐标为[2500, 3000]的时间段内，其水肿体积随时间开始呈现低于 0mL 的趋势，理论上水肿时间-体积曲线应在 0mL 的附近缓慢波动，水肿体积并最终逐渐趋于 0mL，因此该曲线拟合模型与实际情况存在相悖部分，并且局部加权回归拟合是一

种分段拟合方式，拟合曲线会存在不平滑的现象。

5.4 基于七阶多项式的水肿体积进展模型

多项式拟合^[5]是数学领域中常用的一种曲线拟合方式，其基本思想是通过给定的多个样本数据点利用最小二乘法找到一个最佳曲线来拟合多样本数据的变化趋势，使得给定样本点与拟合曲线之间的误差最小，该方法通常被用于机器学习的回归分析、模型预测等模型中，在医学领域有广泛的应用，为其临床诊断、治疗及其预后提供参考和支持。

多项式拟合是一种线性拟合模型，其目的是构造关于自变量 x 的 m 阶函数，其数学表达式为如式（5-2）所示：

$$f(x) = \sum_{j=0}^m w_j x^j \quad (5-2)$$

其中， m 是多项式的最高次数， x^j 表示 x 的 j 次幂， w_j 表示 x^j 的权重系数。

本组利用 matlab 中的 Curve Fitting Tool 工具箱，构建所有样本数据的水肿时间—体积散点图，并选取多项式中拟合效果相对较佳的七阶多项式来进行曲线拟合，其拟合结果如图 5-4 所示：




图 5-4 七阶多项式拟合曲线图

根据拟合曲线对应的七阶多项式定义如式（5-3）所示：

$$f(x) = p_1 * x^7 + p_2 * x^6 + p_3 * x^5 + p_4 * x^4 + p_5 * x^3 + p_6 * x^2 + p_7 * x + p_8 \quad (5-3)$$

在 95% 的置信区间内，各参数取值为：

$$p_1 = 8.052 \times 10^{-22}, \quad p_2 = -1.447 \times 10^{-17}$$

$$p_3 = 1.027 \times 10^{-13}, \quad p_4 = -3.662 \times 10^{-10}$$

$$p_5 = 6.909 \times 10^{-7}, \quad p_6 = -6.553 \times 10^{-4}$$

$$p_7 = 0.2404, \quad p_8 = 11.98$$

从散点图中可以分析得到，随着时间的增长，在 3500 小时至 5000 小时的范围内，水肿体积已降低为 0ml，表示通过治疗干预患者的病情已好转，水肿已消除。然而拟合曲线在该时间段范围内产生体积最高点峰值，发生先增长后降低的趋势，预测值与真实值在 [3500, 5000] 时间段内不符合，该小段区间偏离实际情况。

5.5 基于高斯拟合的水肿体积进展模型

为更好提取数据样本的特征进行预测和分析，更简便进行数据样本曲线拟合并观察其变化趋势，高斯拟合^[6]是一种有效的数据处理方式。高斯拟合与数多项式拟合类似，高斯拟合中以高斯函数为基函数，多项式拟合中以幂函数为基函数。

其拟合原理是假设一组数据样本 (x_i, y_i) ，高斯函数的定义如式（5-4）所示：

$$y_i = a \times \exp \left[-\frac{(x_i - c)^2}{b} \right] \quad (5-4)$$

给上式两边取对数得：

$$\ln y_i = \ln a - \frac{(x_i - c)^2}{b} \quad (5-5)$$

$$\ln y_i = (\ln a - \frac{c^2}{b}) + \frac{2x_i c}{b} - \frac{x_i^2}{b} \quad (5-6)$$

将上式(5-6)化为二项式拟合函数，利用最小二乘法原理，求解拟合常数构成的矩阵的广义最小二乘解，从而求出参数 a ， b ， c 。

$$a = e^{\frac{-b_1^2}{4 \times b_2 + b_0}}, b = \frac{-b_1}{2 \times b_2}, c = \sqrt{\frac{-1}{b_2}} \quad (5-7)$$

构建所有样本数据的水肿时间一体积散点图，并选取二阶高斯进行曲线拟合，其拟合结果如图 5-5 所示：




图 5-5 高斯拟合曲线图

根据拟合曲线计算二阶高斯函数中多个参数值，其二阶高斯拟合函数如式(5-8)所示：

$$f(x) = a_1 * \exp(-(\frac{x-b_1}{c_1})^2) + a_2 * \exp(-(\frac{x-b_2}{c_2})^2) \quad (5-8)$$

在 95%的置信度区间内，各参数取值分别为： $a_1=30.81$ ， $b_1=101.2$ ， $c_1=82.26$ ， $a_2 = 43.87$ ， $b_2 = 450.2$ ， $c_2=299.5$ ，其中 a_1 在物理意义上表示高斯曲线的峰高、 b_1 表示高斯曲线的峰位置， c_1 表示高斯曲线的半宽度。

从高斯曲线拟合效果观察得到，水肿体积短时间内呈迅速增长的趋势，后逐渐降低轻微幅度，再增长到水肿体积变化的最高点峰值，最后逐渐下降直到曲线平稳收敛于水肿体积为 0mL。由相关出血性脑卒中患者病情变化医学研究报告可以得出，通常于脑出血后的 0~2 天水肿体积快速增长，积极采取相关治疗干预后，患者病情逐渐好转，水肿消除，水肿体积值变为 0，这与高斯拟合后的曲线趋势基本保持一致。但对于拟合结果中[0, 500]时间范围内出现的拟合曲线轻微降低幅度又增长的趋势，是由于该曲线是对 sub001 至 sub100 所有患者首次及后续多次重复检查时间点一水肿体积的总体描述，在此期间，允许部分患者因个体自身差异、首次水肿情况及不同治疗方案诱导其余继发性病理反应，从而有加重病情的可能性，符合实际情况。

5.6 模型分析与评价

对四种曲线拟合的结果利用均方根（RMSE）、确定系数（ R^2 ）、校正确定系数（Adjusted R^2 ）进行评价分析，其取值如表 5-1 所示：

表 5-1 四种拟合曲线指标评价表

	RMSE	R^2	Adjusted R^2
LOESS-Epanechnikov	7.36	0.4853	0.4941

LOESS-Cauchy	8.79	0.4805	0.4860
七阶多项式拟合	7.27	0.5328	0.5824
二元高斯拟合	6.90	0.6077	0.6149

注：RMSE 的值越小越好、 R^2 和 Adjusted_ R^2 的取值越大越好。

通过对以上四种患者水肿体积随时间进展曲线分析对比以及评价指标的分析，可以得出二元高斯拟合的曲线变化趋势越接近患者水肿体积随时间进展的实际情况，且二元高斯拟合在 RMSE、 R^2 、Adjusted_ R^2 三个评价指标上都优于其余三种模型。

因此，考虑到实际病情发展情况及结合三种评价指标，相比较局部加权回归、七阶多项式拟合模型，本题（a）问选取二阶高斯模型拟合水肿体积进展模型，并计算真实值与所拟合曲线值之间的残差。

用 python 计算各时间点真实值与曲线拟合值的残差，依据拟合函数计算前 100 位患者首次影像检查、第一次随访……的各检查时间点对应的水肿预测体积，并将各影像检查点的水肿真实值与与测试值做差并求均值。每位患者真实值与所拟合曲线值之间的残差，定义如式（5-9）所示：

$$\bar{v}_j = \frac{\sum_{i=1}^m \Delta v_i}{m} \quad (5-9)$$

其中， $j=1,2,\dots,100$ ，表示前 100 位患者， m 表示各患者的首次+随访次数。将结果填入“表 4”的 F 字段，如表 5-2 所示。

表 5-2 水肿体积进展曲线残差（全体）

患者编号	残差	患者编号	残差
sub001	56.55818189	sub051	13.54326751
sub002	7.059042099	sub052	17.79918164
sub003	24.53266398	sub053	7.889567708
sub004	16.50628299	sub054	5.885241735
sub005	22.45045035	sub055	8.255870536
sub006	42.41730868	sub056	19.5735803
sub007	12.49403093	sub057	12.00585144
sub008	8.331268602	sub058	6.343629847
sub009	7.96734867	sub059	20.26126395
sub010	6.384693722	sub060	10.96414768
sub011	18.91841441	sub061	35.44097533
sub012	7.373643172	sub062	5.059770588
sub013	14.97918715	sub063	30.05048949
sub014	1.433208479	sub064	18.3824874
sub015	27.06196637	sub065	17.30389481
sub016	30.53569764	sub066	14.29315773
sub017	7.13871149	sub067	17.72039652
sub018	23.05506404	sub068	5.757055447
sub019	4.133841193	sub069	19.08107654
sub020	13.01635232	sub070	8.790384515
sub021	10.39725706	sub071	22.25932734
sub022	14.6741657	sub072	5.73758639

sub023	15.07766306	sub073	17.34862288
sub024	23.27725389	sub074	36.21387511
sub025	4.152267144	sub075	4.624414965
sub026	7.914405202	sub076	15.12957077
sub027	11.02841579	sub077	10.27896273
sub028	12.5327328	sub078	19.09426098
sub029	20.23800899	sub079	14.18116463
sub030	36.60346807	sub080	9.924439008
sub031	19.59874588	sub081	29.2945934
sub032	19.94057265	sub082	10.77600097
sub033	18.11901559	sub083	10.57549533
sub034	24.18963154	sub084	6.399905478
sub035	17.2173008	sub085	27.04355129
sub036	14.79838669	sub086	21.6723689
sub037	16.54987289	sub087	18.58755432
sub038	7.140901943	sub088	10.6826358
sub039	32.62190766	sub089	13.94413839
sub040	17.50919798	sub090	30.52563037
sub041	17.63995918	sub091	18.50599423
sub042	11.83753432	sub092	11.10230767
sub043	8.153261052	sub093	14.70646444
sub044	21.78031569	sub094	11.04704287
sub045	6.436904866	sub095	69.65558056
sub046	13.72389115	sub096	23.48900397
sub047	9.914033086	sub097	15.55521303
sub048	18.59082297	sub098	10.33734262
sub049	23.72796562	sub099	3.694626435
sub050	11.24399705	sub100	15.5723892

六、问题 2(b)分析与求解

6.1 问题 2(b)分析与思路

通过数据预处理将前 100 位患者的多次影像检查时刻对应的时间与水肿体积的数据筛选出来，其中，自变量是影像检查时刻，因变量是水肿体积（ ED_volume_i ）。接着，通过 DBSCAN 聚类 and k-means 聚类各分为四个亚组，选取 2（a）问拟合效果最优的高斯曲线对各亚组进行拟合，通过 RMSE、 R^2 、Adjusted R^2 三个评价指标对两种聚类方法的各亚组进行评价。最后，通过对比 2（a）问前 100 位患者的残差与利用 DBSCAN 聚类 and k-means 聚类得到的残差进行对比分析及可视化，选取效果最佳的分亚组聚类方式对患者水肿体积随时间进展进行拟合分析。思路流程图如图 6-1 所示。




图 6-1 问题 2(b)思路流程图

6.2 基于 DBSCAN 聚类的分亚组水肿体积随时间进展模型的建立

本问的数据预处理过程与 2（a）问方法一致，在 5.2 小节中已经进行了描述。

6.2.1 模型准备

DBSCAN 聚类分析算法^[7]是基于数据样本密度的聚类算法，其算法原理是根据数据点的紧密程度进行聚类，同一簇内数据样本的密度大于簇外数据样本点的密度，将稀疏的数据样本点称为噪声。定义参数 (γ, minpts) ，其中， γ 表示聚类半径，即两个数据样本点之间距离需小于等于 γ ， minpts 表示聚类后各簇的最小样本数。

其聚类步骤为：

Step1:选择初始样本核心点形成初步聚类簇；

Step2:若某个样本点 A 在聚类半径 γ 内的点的数目大于等于minpts，将该点 A 作为核心候选对象，依次处理该点 A 形成的簇中的其余样本点；

Step3:重复迭代 Step2，选取密度直达的点形成临时聚类簇；

Step4: 将临时聚类簇进行合并，直至所有样本点都被聚类，此时达到终止条件。

其 DBSCAN 聚类原理图如图 6-2 所示：




图 6-2 DBSCAN 聚类原理图

6.2.2 模型建立

1) 利用 DBSCAN 聚类将前 100 患者聚为 4 类，每类人数如表 6-1 所示：

表 6-1 DBSCAN 聚类 4 类患者频数表

类别	频数	百分比%
亚组_1	38	38.0
亚组_2	7	7.0
亚组_3	5	7.0
亚组_4	50	50.0
合计	100	100.0

2) 将 DBSCAN 聚类后的 4 个类别的患者水肿体积随时间进展利用 2 (a) 题的最佳拟合方式—高斯模型进行拟合。

6.2.3 模型求解与分析

本题考虑到聚类结果对水肿时间-体积模型拟合的影响，在多次调参之后选取一元高斯进行拟合，其定义如式 (6-1) 所示：

$$f(x) = a_1 * \exp\left(-\left(\frac{x-b_1}{c_1}\right)^2\right) \quad (6-1)$$

其中，不同聚类类别的参数取值不同，如下所示：

类别 1: $a_1=49.4$, $b_1=380.2$, $c_1=403.3$

类别 2: $a_1=22.23$, $b_1=165.4$, $c_1=138.6$

类别 3: $a_1=24.38$, $b_1=131.6$, $c_1=111$

类别 4: $a_1=39.95$, $b_1=445.3$, $c_1=653.3$

同时，4 个类别不同参数取值对应的 4 幅曲线拟合图分别如图 6-3，图 6-4，图 6-5，图 6-6 所示：




图 6-3 DBSCAN 亚组_1 的曲线拟合图




图 6-4 DBSCAN 亚组_2 的曲线拟合图




图 6-5 DBSCAN 亚组_3 的曲线拟合图




图 6-6 DBSCAN 亚组_4 的曲线拟合图

对利用 DBSCAN 聚类分亚组的曲线拟合的结果利用均方根(RMSE)、确定系数(R^2)、校正确定系数 (Adjusted_ R^2) 进行评价分析, 其取值如表 6-2 所示:

表 6-2 DBSCAN 聚类的拟合曲线指标评价表

	RMSE	R^2	Adjusted_ R^2
亚组_1	5.89	0.6717	0.6616
亚组_2	6.08	0.6356	0.5665
亚组_3	3.603	0.8445	0.8860
亚组_4	7.66	0.5715	0.5634

由表 6-2 可以得出, 亚组_1 和亚组_3 的拟合曲线中的 RMSE、 R^2 、Adjusted_ R^2 指标值更优。

6.3 基于 k-means 聚类的分亚组水肿体积随时间进展模型的建立

6.3.1 模型准备

k-means 聚类分析算法^[7]是为将数据划分为 k 个簇, 同一簇内的样本数据距离尽可能小, 使其具有相似性, 不同簇间的样本数据尽可能大, 使其存在很大差距性。

其聚类流程如下:

Step1:初始随机选择 k 个点, 作为初始聚类中心;

Step2:剩余的数据样本点与各聚类中心的距离比较, 每次选择距离最小的聚类中心并将该数据归类到相应簇中;

Step3:重复迭代计算新簇所有数据的均值作为新的聚类中心;

Step4:重复 Step2~Step3 步骤;

Step5:直到所有数据样本点都被聚类到, 且误差平方和最小, 此时达到终止条件。

误差平方和定义如式 (6-2) 所示:

$$E = \sum_{i=1}^K \sum_{p \in C_i} |p - m_i|^2 \quad (6-2)$$

其中, p 表示样本数据, m_i 表示簇中心。

空间上的计算两个簇之间相似性的距离函数选取欧氏距离, 定义如式 (6-3) 所示:

$$d(x, y) = \sqrt{(x_1 + y_1)^2 + (x_2 + y_2)^2 + \cdots + (x_n + y_n)^2} \quad (6-3)$$

k-means 聚类的流程图如图 6-7 所示:




图 6-7 k-means 聚类流程图

6.3.2 模型建立

1) 利用 k-means 聚类将前 100 患者聚为 4 类，每类人数如表 6-3 所示：

表 6-3 k-means 聚类 4 类患者频数表

类别	频数	百分比%
亚组_1	15	15.0
亚组_2	34	34.0
亚组_3	30	30.0
亚组_4	21	21.0
合计	100	100.0

将 k-means 聚类后的 4 个类别的患者水肿体积随时间进展利用 2 (a) 题的最佳拟合方式—高斯模型进行拟合。

6.3.3 模型求解与分析

本题与上述 DBSCAN 聚类拟合方法一致，多次调参之后选取一元高斯进行拟合。其中，不同聚类类别的参数取值不同，如下所示：

类别_1: $a_1 = 60.09$, $b_1 = 454.1$, $c_1 = 480.2$

类别_2: $a_1 = 51.2$, $b_1 = 242.7$, $c_1 = 543.1$

类别_3: $a_1 = 35.08$, $b_1 = 369.5$, $c_1 = 410.8$

类别_4: $a_1=21.51$, $b_1=287.6$, $c_1=428.1$

同时, 4 个类别不同参数取值对应的 4 幅曲线拟合图分别如图 6-8, 图 6-9, 图 6-10, 图 6-11 所示:




图 6-8 k-means 亚组_1 的曲线拟合图




图 6-9 k-means 亚组_2 的曲线拟合图




图 6-10 k-means 聚类亚组_3 的曲线拟合图




图 6-11 k-means 聚类亚组_4 的曲线拟合图

对利用 k-means 聚类分亚组的曲线拟合的结果利用均方根 (RMSE)、确定系数 (R^2)、校正确定系数 (Adjusted R^2) 进行评价分析, 其取值如表 6-4 所示:

表 6-4 k-means 聚类的拟合曲线指标评价表

	RMSE	R^2	Adjusted R^2
亚组_1	5.14	0.6999	0.6870
亚组_2	6.20	0.6044	0.5735
亚组_3	5.85	0.6587	0.6469
亚组_4	4.10	0.7043	0.8092

由表 6-4 可以得出, 亚组_1 和亚组_4 的拟合曲线中的 RMSE、 R^2 、Adjusted R^2 指标值更优。

6.4 两种聚类模型对比与评价

为考虑不同患者的自身个体差异对水肿体积的影响, 将 sub001 至 sub100 的患者在 2 (a) 问的基础上分成亚组, 本题采取 DBSCAN 聚类 and k-means 聚类两种方式, 构建 4 个亚组, 选取一元高斯对每位患者水肿时间一体积对应的散点图进行曲线拟合, 并计算 100 位患者真实值与所拟合曲线值之间的残差, 其残差计算方式已在 4.2.5 节进行描述。

将 2 (a) 问得出的前 100 位患者真实值与所拟合曲线值之间的残差分别与 DBSCAN 聚类、k-means 聚类分亚组后的残差进行拟合对比, 其残差对比图分别如图 6-12、图 6-13 所示:




图 6-12 DBSCAN 残差与 (a) 问残差曲线对比图




图 6-13 k-means 残差与（a）问残差曲线对比图

通过上述两幅残差拟合对比图，可以发现两条残差曲线的趋势一致，大多数波峰波谷点一一对应，蓝色拟合线相较于黄色拟合线 Y 坐标整体向下移，可以直观的得出结论：分亚组对前 100 位患者拟合水肿体积随时间进展曲线后得到的残差更小，验证了考虑不同患者个体性差异影响因素从而进行分亚组方法的有效性和可行性。

上述两幅残差对比图只能直观分析得到：分亚组方法在研究水肿体积随时间变化进展问题上的具有一定的优势。但对于本文采取的两种分亚组聚类方法的对比分析上存在局限性，不能准确的从上述两幅残差图中分析得到哪种聚类方法在此研究问题上具有更好的适用性。

对于上述问题，将残差进行求差，定义如式（6-4）、式（6-5）所示：

$$V_{i1} = \Delta V_1 - \Delta V_D \quad (6-4)$$

$$V_{i2} = \Delta V_1 - \Delta V_K \quad (6-5)$$

其中， ΔV_1 表示 2（a）问求出的残差体积， ΔV_D 表示 DBSCAN 聚类求出的残差体积， ΔV_K 表示 k-means 聚类求出的残差体积。

当 $V_{i1} > 0$ ，即 DBSCAN 聚类残差小于 2（a）问残差，否则反之；

当 $V_{i2} > 0$ ，即 k-means 聚类残差小于 2（a）问残差，否则反之。

将前 100 位患者的进行可视化，将其结果以簇状柱形图进行更直观的表达，如图 6-14、图 6-15 所示：




图 6-14 DBSCAN 聚类优化效果图




图 6-15 k-means 聚类优化效果图

通过上述两幅图可以发现：k-means 聚类后在 X 轴以上的簇状柱形条的个数要大于 DBSCAN 聚类，说明前 100 位患者 k-means 聚类的残差小于 2(a)问残差的患者数量更多。因此，本题选取 k-means 聚类对前 100 位患者分亚组，再利用一元高斯拟合对 4 各个亚组的患者数据样本散点图进行拟合，从而更准确的分析全体患者水肿体积随时间进展趋势。结果如表 6-5 所示。

表 6-5 水肿体积进展曲线残差（亚组）

患者编号	残差（亚组）	所属亚组	患者编号	残差（亚组）	所属亚组
sub001	38.46628264	类别 2	sub051	6.249776924	类别 4
sub002	8.242370462	类别 1	sub052	25.51476487	类别 4
sub003	14.96325621	类别 1	sub053	6.986027658	类别 3
sub004	19.06738156	类别 1	sub054	4.22358213	类别 3
sub005	20.14026748	类别 2	sub055	17.42853278	类别 4
sub006	32.80529331	类别 2	sub056	22.20128832	类别 1
sub007	12.46936186	类别 3	sub057	7.875326673	类别 4
sub008	13.53611867	类别 3	sub058	3.184045504	类别 3
sub009	11.69574006	类别 3	sub059	14.83407552	类别 4
sub010	14.99458147	类别 1	sub060	13.24653412	类别 2
sub011	13.57008483	类别 4	sub061	38.52982059	类别 3
sub012	10.02030341	类别 1	sub062	5.303386743	类别 3
sub013	5.740265718	类别 4	sub063	25.95473427	类别 1
sub014	5.347195053	类别 4	sub064	10.74299712	类别 4
sub015	28.72049075	类别 3	sub065	5.139667479	类别 2
sub016	21.7715796	类别 2	sub066	13.29524276	类别 4
sub017	6.914079214	类别 3	sub067	8.870231058	类别 4
sub018	9.134963365	类别 2	sub068	9.933612831	类别 3
sub019	15.69322085	类别 1	sub069	15.57463068	类别 2
sub020	9.889159579	类别 4	sub070	5.241992021	类别 4
sub021	5.674826023	类别 3	sub071	17.56374856	类别 2
sub022	8.876133945	类别 4	sub072	3.752226209	类别 4
sub023	19.3564158	类别 1	sub073	13.8340137	类别 3

sub024	12.72554649	类别 4	sub074	26.5510329	类别 1
sub025	9.881318801	类别 1	sub075	7.035173697	类别 3
sub026	15.12400854	类别 2	sub076	12.39736654	类别 3
sub027	9.796337474	类别 4	sub077	16.73391871	类别 4
sub028	21.12443532	类别 4	sub078	19.25667283	类别 3
sub029	6.729892818	类别 2	sub079	14.79581521	类别 3
sub030	29.16709395	类别 1	sub080	11.53356331	类别 3
sub031	16.45603284	类别 3	sub081	21.14134201	类别 4
sub032	18.05209063	类别 3	sub082	8.203380281	类别 1
sub033	12.01354719	类别 3	sub083	17.07381261	类别 3
sub034	30.42444509	类别 3	sub084	10.09804103	类别 1
sub035	5.944000102	类别 4	sub085	17.21487889	类别 2
sub036	8.398747747	类别 4	sub086	20.74532803	类别 3
sub037	10.70187552	类别 1	sub087	17.78863033	类别 3
sub038	4.973704475	类别 3	sub088	7.549714399	类别 4
sub039	27.25621225	类别 1	sub089	12.16541154	类别 3
sub040	13.49001725	类别 1	sub090	27.66826594	类别 3
sub041	12.51172052	类别 3	sub091	13.08693288	类别 3
sub042	27.14959931	类别 1	sub092	19.9562053	类别 4
sub043	7.213954321	类别 4	sub093	25.93545118	类别 1
sub044	13.00417052	类别 1	sub094	7.824624332	类别 3
sub045	18.45072535	类别 1	sub095	62.97516395	类别 1
sub046	2.233535122	类别 2	sub096	10.8518593	类别 4
sub047	6.527905034	类别 3	sub097	9.562409408	类别 4
sub048	14.65911686	类别 1	sub098	11.34028433	类别 1
sub049	20.06964125	类别 3	sub099	7.053083613	类别 3
sub050	9.273969915	类别 3	sub100	10.95831273	类别 4

七、问题 2(c)分析与求解

7.1 问题 2(c)分析与思路

构建单个治疗方案与水肿体积进展一对一的分析模型，再利用线性混合效应模型定量分析治疗方案与水肿体积进展的一对多的模型，最后通过均方差、标准误差、显著性水平进行评价与分析。思路流程图如图 7-1 所示。




图 7-1 问题 2(c)思路流程图

7.2 基于线性混合效应模型的治疗方式对水肿体积进展影响模型的建立

7.2.1 数据预处理

将“表 2”中初始水肿体积 ED_volume0、第 i 次随访对应的水肿体积，第 i 次随访的时间点 t_i 与“表 1”中四种治疗方式脑室引流、降颅压、止血治疗、降压治疗建立关联。

7.2.2 模型准备

本小问考虑不同治疗方式对水肿体积随时间变化的影响，归属于重复测量数据问题。其监测 7 种出血性脑卒中治疗方式在不同随访影像检查点时的水肿体积大小，由于所有患者的每一次的随访时间点不同，所以经典的时间序列模型无法使用。同时由于同一个患者的每次影像检查点对应的水肿体积之间存在明显的相关性，不能用传统的方差分析方法来进行分析。

基于此，选取线性混合效应模型^[8]来对该问题进行分析，该方法适用于样本数据内部存在层次性或需要重复测量数据的应用场景。线性混合效应模型近些年来广泛应用于生物学、医药学等研究领域，适用于普通线性回归解决不了的复杂数据结构，是数据分析中的重要模型。线性混合效应模型是固定效应和随机效应的结合，固定效应是指是自变量每变化一个单位，因变量也随之平均变化，随机效应是指样本数据之间的差异性，定义如式(7-1)所示：

$$Y = \sum_{i=0}^k X_i \beta_i + \sum_{i=k+1}^w X_i \beta_i + \varepsilon \quad (7-1)$$

其中， Y 是因变量的观测变量， X_i 表示已知的设计矩阵， β_i 表示未知的回归系数， ε 表示随机误差，假设随机效应向量与随机误差相互独立，且服从均值为 0 的正态分布。选择

不同的协方差可以得到不同的线性混合效应模型，例如随机截距模型、随机斜率模型。

7.2.3 模型建立与分析

(1) 不同治疗方法的重要性分析

为分析不同的治疗方法在临床上应用的重要性，笔者小组分析了 sub001-sub100 共 100 个患者的治疗信息，对每一种治疗方法的使用频次进行了统计，统计结果如图 7-2 所示，数值分别为（6，79，76，92，85，97，96），为进一步分析各治疗方法的作用机理，查阅了相关文献，认为镇静、镇痛治疗，止吐护胃和营养神经三项治疗方法与患者的主观生理感受相关性大，而与患者病情严重程度相关性较小。因此，笔者小组将对其余四项治疗方法进行进一步的分析判断。




图 7-2 每种治疗方法的频数图

(2) 定性分析单个治疗方案与水肿体积进展的相关性

a) 将前 100 位患者的首次影像检查时的初始水肿体积与是否进行脑室引流、止血治疗、降颅压治疗、降压治疗的数据进行直观描述，如图 7-3、图 7-4、图 7-5、图 7-6 所示：




图 7-3 水肿初始体积与脑室引流描述图




图 7-4 水肿初始体积与止血治疗描述图




图 7-5 水肿初始体积与降颅压治疗描述图




图 7-6 水肿初始体积与降压治疗描述图

通过“附件 2—出血性脑卒中临床相关概念”以及查阅相关出血性脑卒中的资料，初步认为对于脑积水一般采取脑室引流和降颅压治疗方式，这与图 7-3、图 7-4 的直观描述基本符合，在水肿体积较大时，易采用这两种治疗方式。止血治疗和降压治疗根据其作用原理通常是针对血肿进行治疗，但观察图 7-5、图 7-6 发现，在水肿体积较大时，也进行了这

两种治疗预案。结合相关资料，笔者小组初步认为与血肿体积存在很大的相关性。因此，基于上述分析，接下来选取线性混合效应模型对治疗方案与水肿体积进展的相关性进一步进行定量分析。

(3) 定量分析多个治疗方案与水肿体积进展的相关性

对不同患者进行治疗方案选取时，结合患者个体自身健康差异性以及生活习惯等通常需要考虑多个治疗方案的影响，因此，选取线性混合效应模型对多个治疗方案与水肿体积进展的相关性进行分析。

将初始水肿体积 ED_volume_0 、第 i 次随访对应的水肿体积、第 i 次随访的时间点 t_i 与四种治疗方式脑室引流、降颅压、止血治疗、降压治疗建立关联，利用线性混合效应模型进行多个治疗方案与水肿体积进展的相关性分析，利用显著性对四种治疗方案随机组合进行分析，当显著性 $p < 0.001$ 时，即表示此治疗方案组对水肿体积进展研究具有有效性。其结果如表 7-1 所示：

表 7-1 水肿体积-治疗方案分析表

项	均值差	标准误差	P
脑室引流-止血治疗	-0.733	0.022	0.000***
脑室引流-降颅压治疗	-0.713	0.023	0.000***
脑室引流-时间差	-249.865	25.938	0.000***
脑室引流-降压治疗	-0.86	0.017	0.000***
脑室引流- ED_volume	-26560.944	1230.129	0.000***
止血治疗-降颅压治疗	0.02	0.028	0.470
止血治疗-时间差	-249.132	25.938	0.000***
止血治疗-降压治疗	-0.127	0.023	0.000***
止血治疗- ED_volume	-26560.211	1230.129	0.000***
降颅压治疗-时间差	-249.152	25.938	0.000***
降颅压治疗-降压治疗	-0.147	0.024	0.000***
降颅压治疗- ED_volume	-26560.231	1230.129	0.000***
时间差-降压治疗	249.005	25.938	0.000***
时间差- ED_volume	-26311.079	1230.402	0.000***
降压治疗- ED_volume	-26560.084	1230.129	0.000***

注：***、**、*分别代表 1%、5%、10%的显著性水平

依据均值差、标准误差、显著性水平对治疗方案的组合进行评价分析，将治疗方案较优的组合方案在表 7-1 中添加底纹显示，其标准差和标准误差较小，显著性水平也符合相关理论值，表示通过选取相应多个治疗方案后，患者脑水肿病情随着时间进展得到好转，符合实际预期情况。

八、问题 2(d)分析与求解

8.1 问题 2(d)分析与思路

利用皮尔逊（Pearson）对血肿体积和水肿体积的相关性进行分析，再利用线性混合效应模型对治疗方案与血肿体积进展进行分析，最后对治疗方案、水肿体积、血肿体积的关联性两两进行分析。思路流程图如图 8-1 所示。




图 8-1 问题 2(d)思路流程图

8.2 血肿体积、水肿体积、治疗方式的相关性分析模型的建立

8.2.1 数据预处理

本问中要求探讨血肿体积、水肿体积以及治疗方法三者之间的关系，首先合并有关数据，分别为表 1 入院首次影像检查时的血肿体积（X 列），水肿体积（AI 列）与治疗方法（Q-W 列），共 160 个样本，9 个特征。考虑到患者个人体质与病情的不同，各样本数据间会有较大的差异性，笔者小组只将不符合实际情况的数据进行异常值处理。

同时，考虑到采用的治疗方案会随时间逐渐对血肿体积和水肿体积产生影响，因此需要记录每位患者的血肿与水肿体积随时间的变化。

8.2.2 模型建立与分析

（1）血肿体积与水肿体积关联分析

考虑到医生为患者制定治疗方案时只能获取到患者入院首次影像检查时的血肿体积和水肿体积，也只能根据初始情况指定治疗方案，因此笔者小组将这 9 个特征利用皮尔逊（Pearson）进行相关性分析，得到各变量之间的相关性程度如图 8-2 所示：




图 8-2 血肿体积、水肿体积及治疗方法相关性的热力图

从图中可以发现，入院时血肿体积与水肿体积具有显著的正相关性，相关系数为 0.659，分析其原因有以下几点：

- 脑血管破裂时，含有较高水分的血液大量涌入脑组织中引起脑水肿。
- 脑血管破裂时，血液中含有的大量蛋白质随之进入脑组织中，导致血浆胶体渗透压变低，水分进入脑组织引起脑水肿。
- 脑血管破裂时，大量血液的涌出对脑组织产生压迫，脑细胞因长时间的压迫而缺氧、缺血导致水肿。

(2) 血肿体积与治疗方法关联分析

水肿体积与治疗方法关联分析已在 7.2.3 小节中进行描述，本小节只对于血肿体积与治疗方法二者之间的关系进行分析。采用与 2(c) 问相同的方法，首先需要对数据进行整合，将每位患者的首次+随访的时间和对应的血肿体积以及采取的治疗方案建立关联。选取线性混合效应模型来分析治疗方案对血肿体积随每次随访影像检查时间的进展，由于血肿体积与水肿体积存在很大的相关性，提取到显著性良好的治疗方案组合与 2(c) 问相似，即主要通过脑室引流、止血治疗、降颅压治疗、降压治疗四种方式进血肿治疗。

分析其原因如下：

- 脑室引流：**脑室引流是一种手术干预方式，通过手术将患者脑中的血肿取出，并引流出多余的血液，对于治疗脑血肿极为有效。但由于其手术风险较高，除非患者病情严重，很少采用此项治疗。
- 止血治疗：**止血治疗是一种使用蛋白酶促进血液凝固的治疗方法，其从根源上修复脑血管破裂情况，减少破裂脑血管处血液的涌出，能够有效治疗脑血肿。
- 降颅压治疗：**血肿主要由于脑血管破裂导致血液涌出凝固，降颅压治疗并不能减少血液在脑部扩散，对血肿体积的影响较小，。
- 降压治疗：**降压治疗可以通过控制血压，减少血管内压力，从而减少血肿体积和水肿体积的增加。
- 镇静、镇痛治疗，止吐护胃，营养神经：**这三种治疗方案主要与患者的主观生理感受有关，通过对前 100 个患者采用的治疗方法的统计也可以看出其治疗频率较高。

8.3 模型分析与评价

通过对血肿体积、水肿体积和治疗方法两两进行关联性分析，可得到以下结论：

a)血肿体积与水肿体积有直接的关联关系，当脑组织中存在血肿时，其低渗透压会导致水分源源不断的增加，导致水肿体积增加。血肿体积、时间对水肿形成的影响最大，水肿在 24 小时内随着血肿的影响和时间进展越来越严重。

b)降颅压治疗与减少血肿体积相关性较低，而是通过调节脑组织的渗透压以减少水分继续向脑组织的扩散，是一种治疗脑水肿的有效方法。

c)脑室引流通过引流脑室内的积液或血液来改善血肿和水肿的现状，可以有效降低血肿和水肿体积；

d)止血治疗和降压治疗通过从源头上遏制血液在脑组织的扩散，控制血肿体积的增加，进而控制水肿体积的增加。

e)镇静、镇痛治疗，止吐护胃和营养神经三项治疗方法与控制血肿、水肿体积相关性较小，主要是缓解患者焦虑心情，为患者提供营养利于预后的恢复，以防患者病情进一步恶化。

然而，在实际治疗中，还需依据患者病情特征和个体差异等具体情况制定最佳的治疗方案。

九、问题 3(a)的分析与求解

9.1 问题 3(a)的分析与思路

首先根据题目要求，将表 1 中提取前 100 个患者(sub001 至 sub100)个人史、疾病史、发病相关等字段（即 E~W），表 2、表 3 提取有关首次影响结果的相关字段进行整合，对整合后的 104 个特征变量进行数据预处理（空值、异常值等筛选），并对其进行标准化处理。随后对预处理后的数据使用灰色关联分析、随机森林算法、极致梯度提升（XGBoost）算法进行特征变量的筛选，最后对三种算法筛选出的特征变量进行两两交集后取并集，筛选得到 21 个变量，并对这 21 个特征变量进行独立性检验，验证了各个变量间有较强的独立性，有利于模型的构建。

随后根据题目要求，在前 100 位患者中，以提取到的 21 个重要的特征变量为自变量，患者的 90 天 mRS 评分为因变量，构建了基于首次影像患者的 90 天 mRS 评分模型。由于预测患者的 90 天 mRS 评分为一个分类问题，我们在基于分类模型的基础上，选取了 BP 神经网络算法、梯度提升树(GBDT)算法、极致梯度提升（XGBoost）三种算法进行构建模型，预测所有患者在 90 天的 mRS 评分。最后，经过对比模型和客观评价指标综合分析可得，XGBoost 模型的性能指标在预测患者 mRS 评分上更为准确。

9.2 问题 3(a)的数据预处理

笔者小组通过对表 1、表 2、表 3 的数据预处理检索发现，表 1 中 sub131、sub132 的首次检查流水号和表 1 中的 sub3、sub4 的首次检查流水号重复，而表二中的 sub131、sub132 的首次检查流水号和表 2 中的 sub3、sub4 的首次检查流水号不同，但在表三中不存在表二中 sub131 和 sub132 所属的首次检查流水号，因此本次数据预处理仍以表 1 为准进行数据筛选处理。通过题目要求将前 100 个患者的个人史等（字段 E 至 W）及首次影像结果进行初次数据整合，随后进行数据空值、异常值筛选等预处理，并对其进行标准化处理，对于不同数据的单位和取值范围，消除不同数据间的量纲影响，减少后续对特征提取及预测模型的影响。思路流程图如图 9-1 所示。




图 9-1 问题 3(a)结果流程图

9.3 基于灰色关联分析的特征筛选

9.3.1 模型准备与建立

灰色关联分析^[9]是指对一个系统发展变化态势的定量描述和比较的方法，其基本思想是通过确定参考数据列和若干个比较数据列的几何形状相似程度来判断其联系是否紧密，它反映了曲线间的关联程度。目标空间中解与解之间关联性大小的量度，称为关联度^[1]。具体操作步骤如下。

Step 1: 确定表示系统总体特征的母序列和影响系统行为的子序列。

Step 2: 针对数据进行无量纲化的处理，消除系统内部各个因子之间的差异。

Step 3: 计算关联系数。

$$\delta_i(k) = \frac{\min_s \min_t |x_0(t) - x_s(t)| + \rho \min_s \min_t |x_0(t) - x_s(t)|}{|x_0(k) - x_i(k)| + \rho \min_s \min_t |x_0(t) - x_s(t)|} \quad (9-1)$$

在式中， δ 为系统的子序列 x_i 在母序列上关于第 k 个指标的关联系数， $\rho \in [0,1]$ 为分辨系数，其中， $\min_s \min_t |x_0(t) - x_s(t)|$ 为两级最小差， $\min_s \min_t |x_0(t) - x_s(t)|$ 为两级最大差。

Step 4: 求解灰色关联度。即 21 个特征变量与 90 天 mRS 评分的相关程度，关联度值介于 0~1 间，依据灰色关联度的值对特征变量进行关联度排序，值越大，关联度越好。

$$r_i = \sum_{k=1}^n \omega_k \delta_i(k), i = 1, 2, 3 \quad (9-2)$$

式中， ω_k 是关于第 k 个指标的权重系数， r_i 为第 i 个评价指标与理想指标的灰色关联度。

9.3.2 特征筛选结果

基于灰色关联分析对前 100 位患者的特征变量进行筛选的结果，基于各变量的关联度大小排序，筛选出了排名前 30 的特征变量，如下表 9-1 所示。

表 9-1 灰色关联分析筛选结果

评价项	关联度
original_shape_LeastAxisLength_HM	0.987
original_shape_Maximum2DDiameterColumn_HM	0.987
original_shape_MinorAxisLength_HM	0.986
NCCT_original_firstorder_Range_ED	0.986
original_shape_MajorAxisLength_HM	0.986
original_shape_Maximum3DDiameter_HM	0.986
original_shape_Maximum2DDiameterSlice_HM	0.986
NCCT_original_firstorder_Uniformity_ED	0.986
年龄	0.986
original_shape_Maximum2DDiameterColumn_ED	0.986
original_shape_Maximum2DDiameterRow_HM	0.985
NCCT_original_firstorder_Kurtosis_ED	0.985
NCCT_original_firstorder_Maximum_ED	0.985
NCCT_original_firstorder_MeanAbsoluteDeviation_ED	0.985
original_shape_MinorAxisLength_ED	0.985
NCCT_original_firstorder_RobustMeanAbsoluteDeviation_ED	0.985
NCCT_original_firstorder_InterquartileRange_ED	0.985
original_shape_Maximum2DDiameterRow_ED	0.985
NCCT_original_firstorder_Variance_ED	0.985
original_shape_Maximum3DDiameter_ED	0.985

评价项	关联度
original_shape_LeastAxisLength_ED	0.985
original_shape_Maximum2DDiameterSlice_ED	0.985
NCCT_original_firstorder_10Percentile_HM	0.985
NCCT_original_firstorder_Uniformity_HM	0.985
original_shape_SurfaceArea_HM	0.985
NCCT_original_firstorder_Mean_HM	0.985
NCCT_original_firstorder_RootMeanSquared_HM	0.985
NCCT_original_firstorder_Entropy_HM	0.985
original_shape_MajorAxisLength_ED	0.985
NCCT_original_firstorder_Kurtosis_HM	0.985

9.4 基于随机森林算法的特征筛选

9.4.1 模型准备与建立

由于笔者小组在 3.4 章节，详细的介绍了基于随机森林算法^[3]的模型准备，因此在此章节只基于本题所给数据进行模型建立。模型建立步骤如下：

Step 1：通过选取前 100 位患者的数据集，训练集与测试集占比为 8：2，来建立随机森林模型，同时进行五折交叉验证。

Step 2：通过建立的模型来计算特征重要性。

Step 3：将建立的随机森林模型用于 160 个患者作为测试数据，得到模型的分类评估结果。

9.4.2 特征筛选结果

基于随机森林模型对前 100 位患者的特征变量进行筛选的结果，基于各变量的关联度大小排序，筛选出了排名前 30 的特征变量，如表 9-2 所示，其中图 9-2 按重要性程度展示了 30 个特征变量。




图 9-2 随机森林筛选柱形图

表 9-2 随机森林筛选结果

特征名称	特征重要性
original_shape_LeastAxisLength_HM	2.80%
HM_ACA_R_Ratio	2.70%
original_shape_SurfaceArea_HM	2.00%
original_shape_MinorAxisLength_HM	1.80%
original_shape_MajorAxisLength_ED	1.80%
NCCT_original_firstorder_RobustMeanAbsoluteDeviation_HM	1.70%
HM_volume	1.60%
original_shape_Elongation_HM	1.60%
original_shape_Flatness_HM	1.60%
original_shape_Maximum2DDiameterColumn_HM	1.60%
original_shape_Elongation_ED	1.60%
NCCT_original_firstorder_Kurtosis_ED	1.60%
original_shape_MeshVolume_HM	1.50%
original_shape_Maximum3DDiameter_ED	1.50%
NCCT_original_firstorder_Skewness_ED	1.50%

NCCT_original_firstorder_10Percentile_HM	1.40%
NCCT_original_firstorder_Median_HM	1.40%
NCCT_original_firstorder_Range_HM	1.40%
NCCT_original_firstorder_RootMeanSquared_HM	1.40%
original_shape_Maximum2DDiameterColumn_ED	1.40%
NCCT_original_firstorder_10Percentile_ED	1.40%
NCCT_original_firstorder_Median_ED	1.40%
舒张压	1.30%
NCCT_original_firstorder_Entropy_HM	1.30%
NCCT_original_firstorder_Mean_HM	1.30%
NCCT_original_firstorder_Uniformity_HM	1.30%
NCCT_original_firstorder_Maximum_ED	1.30%
NCCT_original_firstorder_Mean_ED	1.30%
NCCT_original_firstorder_Uniformity_ED	1.30%
NCCT_original_firstorder_Variance_ED	1.30%

9.5 基于 XGBoost 算法的特征筛选

9.5.1 模型准备与建立

XGBoost 算法^[10]是一个开源框架，XGBoost 是在 GBDT 的基础上对 boosting 算法进行的改进，在 GBDT 中，学习的是损失函数的梯度，在 XGBoost 中，学习的是损失函数的二阶泰勒展开的差值，XGBoost 在代价函数里加入了正则项，用于控制模型的复杂度。在保证高精度的同时又保证了极快的速度。

XGBoost 算法的主要思想是首先不断地进行特征分裂来生长和添加树，对于每一次添加树，相当于构造了一个新的函数，来不断拟合预测的残差值；其次经过不断训练，最终得到 k 个数目，当我们预测某一个样本的分数时，实际上在构成的树中，找寻样本对应的特征，特征会落到树中对应的某一个叶子节点中，这时找寻到的叶子节点就时某一样本的分数，最终将每棵树叶子节点的分数加起来就是该样本的预测值。模型建立步骤如下：

Step 1: 通过选取前 100 位患者的数据集，训练集与测试集占比为 8: 2，设置学习率为 0.01，决策树深度为 10，来建立 XGBoost 分类模型，同时进行五折交叉验证。

Step 2: 通过建立的 XGBoost 模型来计算特征的分。

Step 3: 以 160 位患者的筛选后的数据作为测试集，通过 XGBoost 模型预测模型的评分结果。

9.5.2 特征筛选结果

基于 XGBoost 模型对前 100 位患者的特征变量进行筛选，各变量的特征分数进行大小排序，筛选出了排名前 30 的特征变量，如表 9-3 所示，其中图 9-3 按重要性程度展示了 30 个特征变量。




图 9-3 XGBoost 筛选柱形图

表 9-3 XGBoost 筛选结果

特征名称	特征重要性
NCCT_original_firstorder_MeanAbsoluteDeviation_HM	15.20%
NCCT_original_firstorder_Energy_HM	14.60%
NCCT_original_firstorder_Skewness_HM	12.10%
NCCT_original_firstorder_Mean_HM	8.00%
NCCT_original_firstorder_RobustMeanAbsoluteDeviation_HM	3.50%
original_shape_SurfaceVolumeRatio_ED	3.50%
NCCT_original_firstorder_Maximum_ED	3.10%
NCCT_original_firstorder_InterquartileRange_HM	3.00%
饮酒史	2.90%
HM_ACA_R_Ratio	2.40%
NCCT_original_firstorder_Entropy_ED	2.30%
HM_PCA_R_Ratio	2.00%
NCCT_original_firstorder_10Percentile_ED	2.00%
original_shape_Sphericity_ED	1.90%
NCCT_original_firstorder_Kurtosis_ED	1.90%
original_shape_Maximum3DDiameter_ED	1.60%
original_shape_Sphericity_HM	1.20%
降压治疗	1.00%

ED_MCA_L_Ratio	1.00%
original_shape_Maximum2DDiameterColumn_HM	1.00%
NCCT_original_firstorder_Range_HM	1.00%
NCCT_original_firstorder_InterquartileRange_ED	1.00%
HM_Pons_Medulla_R_Ratio	0.80%
ED_ACA_R_Ratio	0.80%
NCCT_original_firstorder_Energy_ED	0.80%
HM_volume	0.70%
HM_Pons_Medulla_L_Ratio	0.70%
NCCT_original_firstorder_Maximum_HM	0.70%
舒张压	0.60%
original_shape_LeastAxisLength_HM	0.60%

9.6 基于交叉分析的主要特征变量的选取

9.6.1 三种模型的交叉分析

笔者小组按照要求将“表 1、表 2、表 3”中的有关数据进行数据挖掘，从而整合选取多个特征变量，但是众多变量之间有着不同程度的相关性，数据维度较高，存在冗余，因此我们通过灰色关联分析、随机森林算法和 XGBoost 算法对变量进行特征筛选，通过交叉分析选取了具有代表性的 21 个主要的特征变量。

交叉分析的主要步骤如下所示：

Step 1: 小组分别将上述三种算法得到的筛选结果进行重要性从大到小排序，并分别选取了 30 个变量。

Step 2: 对三种方法分别筛选到的各 30 个变量进行两两取交集，最后取并集，这样结合三种算法各自的重要程度筛选，提取到了 21 个主要特征变量，如下表 9-4 所示。其中针对水肿和水肿在表 3 中具有相同变量名称的问题，我们对有关变量进行标签改正，有关水肿的变量更改为变量_HM，有关水肿的变量更改为变量_ED。

表 9-4 21 个主要特征变量

筛选后的特征变量名称
NCCT_original_firstorder_RobustMeanAbsoluteDeviation_HM
NCCT_original_firstorder_Kurtosis_ED
NCCT_original_firstorder_RootMeanSquared_HM
original_shape_SurfaceArea_HM
NCCT_original_firstorder_Uniformity_ED
NCCT_original_firstorder_InterquartileRange_ED
original_shape_MajorAxisLength_ED
NCCT_original_firstorder_Variance_ED
NCCT_original_firstorder_10Percentile_HM
original_shape_Maximum3DDiameter_ED
original_shape_MinorAxisLength_HM
NCCT_original_firstorder_Maximum_ED
original_shape_Maximum2DDiameterColumn_ED
NCCT_original_firstorder_10Percentile_ED
original_shape_Maximum2DDiameterColumn_HM
NCCT_original_firstorder_Range_HM

HM_ACA_R_Ratio
NCCT_original_firstorder_Uniformity_HM
NCCT_original_firstorder_Entropy_HM
舒张压
HM_volume

9.6.1 主要特征变量的独立性检验

我们讲过数据预处理、数据挖掘和数据筛选等一系列方法，提取出最终的 21 个主要特征变量，这些变量都与患者的 90 天 mRS 评分密切相关，但是这些主要特征变量彼此之间也会存在相关程度，因此小组对交叉分析得到的主要特征变量进行皮尔逊相关性分析，验证所选取的变量可独立作用于 90 天 mRS 评分指标，分析结果图如图 9-4 所示。从图中可以看出，绝大多数自变量之间的相关系数都在 0.5 以下，验证了变量间的独立性检验，有利于进一步模型的构建和预测。




图 9-4 21 个变量相关性图谱

9.7 基于 BP 神经网络的预测模型

9.7.1 模型准备与建立

BP 神经网络（Backpropagation Neural Network）^[11]是一种常用的人工神经网络模型，主要广泛应用于分类、回归和模式识别等任务。它是一种前向的多层式的反馈感知机，主要由输入层、隐含层、输出层三部分组成，并使用梯度下降算法进行数据训练，BP 神经网络算法可以实现不同维数之间的映射。其网络结构如图 9-5 所示。




图 9-5 BP 网络结构

BP 神经网络主要通过正向传播和反向传播来训练数据,其构建模型主要基于以下步骤:

Step 1: 网络初始化设置: 学习率设为 0.01, 批次大小为 5, 迭代次数 400 次。

Step 2: 在正向传播过程中, 输入信息从输入层输入, 本模型采用筛选得到的 21 个特征变量作为输入层的变量, 其中设置隐藏层个数为 5 层, 神经元为 42 个。

Step 3: 经过神经网络中激活函数和神经元的共同作用, 并最终传输到输出层, 输出变量为患者 90 天 mRS 评分, 且上一层神经元的状态只会与下一层神经元的状态有关。

Step 4: 将神经网络的输出结果与预期的输出结果进行对比, 计算误差值。

Step 5: 依据误差来判断进行反向传播的权重, 更新参数, 使得预测结果不断拟合预期输出。

Step 6: 不断重复进行以上训练, 不断迭代并调整网络参数和误差, 提高网络模型性能[3]。下图 9-6 给出了 BP 神经网络算法的流程图。




图 9-6 神经网络流程图

9.7.2 模型评分结果

采用 BP 神经网络对患者 90 天 mRS 评分进行预测，以 100 位患者的 21 个特征变量为因变量，患者的 90 天 mRS 评分为因变量来训练 BP 神经网络，训练集与测试集的占比为 8:2，采用五折交叉验证，适当调整了网络层数、迭代次数及神经元的个数，不断优化网络结构参数，减小误差，得到 BP 神经网络预测的结果如图 9-7 所示。可以看出，BP 神经网络在测试集上预测值与真实值存在出入，拟合程度较差，准确率较低。




图 9-7 BP 神经网络预测 (a)

9.8 基于 GBDT 算法的预测模型

9.8.1 模型准备与建立

GBDT 算法^[12]又被称为梯度提升决策树算法，是一种进行迭代的决策树算法。作为一种集成学习算法，首先将构造一组弱的学习器（树），通过不断迭代地训练决策树模型，以逐步减小预测误差，组合树生成强的学习器。它由多个决策树组成，与以往集成学习方法不同的是，它的每棵树都是基于前一棵树的残差进行训练来优化模型的，使用梯度提升算法来集成多棵树。其训练过程如下图 9-8 所示。




图 9-8 GBDT 训练过程

GBDT 模型构建步骤如下所示：

Step 1: 首先使用一个简单的模型来建立初始模型，通常选取一个平均值或者常数作为初始预测结果。选取决策树的深度为 10，学习率设为 0.01。

Step 2: 开始进行迭代，计算残差值和残差的梯度方向，即模型的预测值与实际观测

值之间的残差，也就是预测误差。

Step 3: 根据残差值来训练和优化初始决策树模型。决策树的训练过程是一个贪心算法，它通过迭代选择最佳的特征和分割点来生成一棵新的决策树，每次在当前节点中选择最具有区分度的特征，并确定最佳的分割点，不断重复这个过程直到满足终止条件，形成一棵完整的决策树。

Step 4: 将生成的新的决策树模型加入到初始模型中，并更新模型的预测结果和残差值。新的预测结果是前一轮预测结果与当前决策树的预测结果之和。

Step 5: 迭代训练：重复步骤 2 到步骤 4，迭代训练新的决策树。每一轮迭代都以减小残差值为目的，进行优化模型。

Step 6: 当残差值足够的小或者达到已知条件时，模型终止训练，不再生成决策树。

Step 7: 将上述所有生成的决策树的预测结果进行累加求和，得到最终的集成模型预测结果。

9.8.2 模型评分结果

采用 GBDT 算法模型对患者 90 天 mRS 评分进行预测，同样以 100 位患者的 21 个特征变量为因变量，患者的 90 天 mRS 评分为因变量来训练，训练集与测试集的占比为 8:2，采用五折交叉验证。通过不断调整数的深度、决策树的数目、特征采样比例和学习率等参数，不断改善网络模型性能，GBDT 模型预测结果如图 9-9 所示，可以看出相较于 BP 神经网络，准确率得以改善，预测值与真实值拟合程度增强，总体预测效果较为理想，但仍存在部分预测差异。




图 9-9 GBDT 模型预测 (a)

9.9 基于 XGBoost 算法的预测模型

9.9.1 模型准备与建立

由于笔者小组在 9.5 章节，已详细的介绍了 XGBoost 算法的模型准备过程，因此在此模型准备的基础上，基于本题所给数据进行模型建立。模型建立步骤如下：

Step 1: 首先选取前 100 位患者的数据集，训练集与测试集占比为 8:2，来建立 XGBoost 模型，同时进行五折交叉验证，学习率为 0.01，树的最大深度为 10，采用了 L1 和 L2 正则化。

Step 2: 通过建立的 XGBoost 模型来计算特征的分。

Step 3: 以 160 位患者的筛选后的数据作为测试集，通过 XGBoost 模型预测模型的评分结果。

9.9.2 模型评分结果

采用 XGBoost 算法模型对患者 90 天 mRS 评分进行预测，同样以 100 位患者的 21 个特征变量为因变量，患者的 90 天 mRS 评分为因变量来训练，训练集与交叉集的占比为 8:2，采用五折交叉验证。通过调整模型正则化参数平衡正则化项与损失函数的权重，同时调整数的深度及数目。为了提高模型的泛化能力，减少过拟合的风险，调整了列采样比例，指定了每棵树在训练时使用的特征比例。从图 9-10 可以看出，针对与前 100 个患者，XGBoost 模型预测的 90 天 mRS 评分与真实的评分值在整体趋势上拟合程度较好，相较于 GBDT 模型和 BP 神经网络有明显的好转。




图 9-10 XGBoost 模型预测（a）

9.10 模型评价与选择

三种模型的评价指标如表 9-4、9-5、9-6 所示：
通过以上对三种模型的预测值和测试值进行拟合分析可得，BP 神经网络模型在预测评分值效果较差，其原因可能是在神经网络中，此次样本较少，模型训练未达到最优值。GBDT 模型的往往输入的数据是有序分类的或连续性数值，因此相较于 BP 神经网络，GBDT 模型更适用于解决回归或分类问题。由于 XGBoost 模型在正则化的选取、损失函数的表示、并行计算、特征处理和预排序等方面进行了改进和优化，提高了模型的准确性，改善了模型的性能。因此，在实际应用中，与传统模型相比，XGBoost 模型更适用于预测患者的 90 天 mRS 评分，预测结果优于另两种算法。因此本题选用 XGBoost 模型预测所有患者（sub001~sub160）90 天 mRS 评分，结果如下表 9-7 所示。

表 9-4 BP 神经网络模型评价（a）

评价指标 评价值	准确率	召回率	精确率	F1
训练集	0.842	0.813	0.738	0.801
测试集	0.706	0.732	0.764	0.722

表 9-5 GBDT 模型评价（a）

评价指标 评价价值	准确率	召回率	精确率	F1
训练集	0.986	0.813	0.854	0.887
测试集	0.805	0.797	0.787	0.758

表 9-6 XGBoost 模型评价 (a)

评价指标 评价价值	准确率	召回率	精确率	F1
训练集	0.971	0.876	0.929	0.913
测试集	0.867	0.823	0.852	0.828

表 9-7 基于患者首次影像的 mRS 评分

患者	预测 mRS	患者	预测 mRS	患者	预测 mRS	患者	预测 mRS
sub001	4	sub041	2	sub081	3	sub121	2
sub002	0	sub042	0	sub082	2	sub122	1
sub003	5	sub043	5	sub083	5	sub123	5
sub004	4	sub044	0	sub084	1	sub124	0
sub005	3	sub045	1	sub085	2	sub125	3
sub006	5	sub046	2	sub086	0	sub126	1
sub007	2	sub047	1	sub087	1	sub127	1
sub008	5	sub048	3	sub088	2	sub128	3
sub009	3	sub049	1	sub089	1	sub129	2
sub010	3	sub050	1	sub090	5	sub130	2
sub011	1	sub051	0	sub091	2	sub131	5
sub012	0	sub052	3	sub092	0	sub132	4
sub013	2	sub053	2	sub093	1	sub133	2
sub014	2	sub054	3	sub094	5	sub134	2
sub015	2	sub055	4	sub095	4	sub135	1
sub016	5	sub056	0	sub096	4	sub136	1
sub017	1	sub057	3	sub097	2	sub137	1
sub018	0	sub058	5	sub098	5	sub138	1
sub019	1	sub059	0	sub099	3	sub139	4
sub020	2	sub060	4	sub100	2	sub140	2
sub021	3	sub061	4	sub101	4	sub141	3
sub022	2	sub062	2	sub102	1	sub142	4
sub023	1	sub063	2	sub103	1	sub143	2
sub024	1	sub064	3	sub104	5	sub144	5
sub025	2	sub065	3	sub105	1	sub145	1
sub026	3	sub066	6	sub106	5	sub146	1
sub027	5	sub067	2	sub107	0	sub147	1
sub028	4	sub068	2	sub108	2	sub148	1

sub029	4	sub069	6	sub109	1	sub149	5
sub030	3	sub070	2	sub110	2	sub150	1
sub031	4	sub071	3	sub111	2	sub151	2
sub032	0	sub072	4	sub112	5	sub152	5
sub033	5	sub073	1	sub113	0	sub153	5
sub034	4	sub074	0	sub114	5	sub154	1
sub035	5	sub075	3	sub115	6	sub155	5
sub036	3	sub076	5	sub116	5	sub156	5
sub037	3	sub077	6	sub117	5	sub157	1
sub038	2	sub078	1	sub118	4	sub158	2
sub039	3	sub079	1	sub119	1	sub159	5
sub040	1	sub080	1	sub120	3	sub160	5

十、问题 3(b)的分析与求解

10.1 问题 3(b)的分析与思路

在(a)题数据整合的基础上,加入了患者 sub1~sub100 和患者 sub131~sub160 的随访数据,由于患者 sub101~sub130 没有后期随访数据,因此本题在后续处理中不考虑这 30 个患者的数据。针对患者随访信息的特征变量,小组在患者的随访信息中选取了最具有代表性的随访点,即每位患者的最后一次随访流水号,这反映了患者相较于首次治疗程度的好坏,并根据最后一次的随访流水号,将其有关 105 个特征变量筛选出来。由于在(a)问的基础上,对患者的首次影像信息已进行数据特征筛选,因此基于(b)题,笔者小组将筛选后的 21 个特征变量与 105 个特征变量进行数据整合,得到 126 个特征变量。

后续操作同第三题(a)问处理相同,首先对整合后的数据进行数据预处理和标准化,通过灰色关联分析、随机森林算法、极致梯度提升算法进行特征变量的筛选,进行交叉分析,两两交集取并集后筛选到主要特征变量 28 个,验证变量间的独立性检验。

随后根据题目要求,在前 100 位患者中,以提取到的 28 个重要的特征变量为自变量,患者的 90 天 mRS 评分为因变量,构建了基于随访后影像患者的 90 天 mRS 评分模型。基于 BP 神经网络算法、梯度提升树(GBDT)算法、极致梯度提升(XGBoost)三种算法进行构建模型,预测所有患者在 90 天的 mRS 评分。最终,经过对比模型和客观评价指标综合分析可得,BP 神经网络模型预测患者 mRS 评分更加接近真实值,准确率更高。

10.2 问题 3(b)的数据预处理

笔者小组基于题中患者首次及随访信息,选取了(a)小问筛选的 21 个主要特征变量作为患者首次影像信息变量的主要因子,并基于每位患者的最后一次随访流水号信息筛选有关变量,将其与 21 个变量整合在一起,得到了 126 个特征变量,随后对其进行数据预处理及标准化,消除干扰因素影响。

10.3 特征筛选及交叉分析

笔者小组在(a)小问的基础上,选取了和(a)小问相同的特征筛选模型进行数据筛选,因此模型的准备及建立在此不过多阐述,分别采用灰色关联分析、随机森林、XGBoost 三种模型筛选主要特征变量,并按照重要程度进行排序,笔者小组对每个模型各筛选了 30 个特征变量。通过交叉分析最终选取了具有代表性的 28 个主要的特征变量,如表 10-1 所示。

表 10-1 28 个主要特征变量

筛选后的特征变量名称
NCCT_original_firstorder_Energy_ED_Last
original_shape_SurfaceArea_HM
original_shape_Sphericity_HM_Last
HM_ACA_R_Ratio
NCCT_original_firstorder_Kurtosis_HM_Last
NCCT_original_firstorder_RobustMeanAbsoluteDeviation_ED_Last
NCCT_original_firstorder_Entropy_HM_Last
original_shape_Maximum2DDiameterColumn_HM
original_shape_Maximum2DDiameterColumn_ED
NCCT_original_firstorder_Entropy_HM
NCCT_original_firstorder_Minimum_HM_Last
original_shape_Flatness_HM_Last
NCCT_original_firstorder_Uniformity_HM
NCCT_original_firstorder_Kurtosis_ED

HM_volume
original_shape_MinorAxisLength_HM
HM_volume_Last
NCCT_original_firstorder_Maximum_ED
NCCT_original_firstorder_Uniformity_ED
NCCT_original_firstorder_Maximum_HM_Last
NCCT_original_firstorder_Variance_ED
NCCT_original_firstorder_InterquartileRange_HM_Last
original_shape_Maximum3DDiameter_ED
original_shape_MajorAxisLength_ED
NCCT_original_firstorder_10Percentile_HM
NCCT_original_firstorder_10Percentile_ED
ED_volume_Last
NCCT_original_firstorder_Entropy_ED_Last

10.4 独立性检验




图 10-1 28 个变量相关性图谱

笔者小组对其 28 个特征变量进行了皮尔逊相关性分析，可以看出，绝大多数自变量之间的相关系数都在 0.5 以下，说明变量之间具有较强的独立性，这些变量可以独立作为影响 90 天 mRS 评分的因素。分析结果图如图 10-1 所示。

10.5 mRS 预测模型建立与分析

在对患者所有特征变量信息的数据筛选中，本题采用了和第一小问(a)相同的数据筛选模式。为了保持数据的一致性，在这里选取了和(a)小问相同的三种模型进行预测。通过选取相同的模型进行预测，可以更加方便的比较不同特征组合对预测结果的影响，能更直观的分析含有随访影像信息和不含有随访影像信息对患者 90 天 mRS 评分的影响。本题选取了与(a)问相同的模型，即基于 BP 神经网络、GBDT 算法、XGboost 算法的预测模型，依据前 100 个患者，建立了 28 个特征变量与 90 天 mRS 评分的关系，来预测患者 90 天 mRS 评分结果。

基于三种模型进行训练和测试时，训练集与测试集均为 8: 2，不断网络结构参数，三种预测模型的结果如图 10-2、10-3、10-4 所示。基于这三幅图中真实值与预测值的拟合程度对比情况，可以看出当特征变量中含有随访影像信息特征时，BP 神经网络的拟合程度最好。




图 10-2 BP 神经网络预测 (b)




图 10-3 GBDT 模型预测 (b)




图 10-4 XGBoost 模型预测 (b)

10.6 模型评价与选择

三种模型的评价指标如表 10-2、10-3、10-4 所示：当患者进行随访影像检查时，从三种模型的评价指标可以得出，BP 神经网络在预测患者 90 天 mRS 评分时准确率最好，预测值与真实值拟合程度最优。因此本题通过 BP 神经网络对患者（sub001~sub100，sub131~sub160）90 天 mRS 评分进行预测，预测结果如下表 10-5 所示。

表 10-2 BP 神经网络模型评价 (b)

评价指标 评价值	准确率	召回率	精确率	F1
训练集	0.942	0.893	0.908	0.901
测试集	0.906	0.832	0.864	0.822

表 10-3 GBDT 模型评价 (b)

评价指标 评价值	准确率	召回率	精确率	F1
训练集	0.874	0.773	0.804	0.837
测试集	0.805	0.747	0.797	0.769

表 10-4 XGBoost 模型评价 (b)

评价指标 评价值	准确率	召回率	精确率	F1
训练集	0.910	0.876	0.891	0.893
测试集	0.867	0.823	0.852	0.828

表 10-5 基于患者随访影像的 mRS 评分

患者	预测 mRS	患者	预测 mRS	患者	预测 mRS	患者	预测 mRS	患者	预测 mRS
sub001	4	sub027	6	sub053	2	sub079	1	sub135	4
sub002	0	sub028	4	sub054	3	sub080	1	sub136	2
sub003	5	sub029	3	sub055	4	sub081	3	sub137	2
sub004	3	sub030	5	sub056	0	sub082	2	sub138	1
sub005	3	sub031	4	sub057	3	sub083	5	sub139	4
sub006	5	sub032	0	sub058	5	sub084	1	sub140	1
sub007	2	sub033	5	sub059	0	sub085	2	sub141	3
sub008	4	sub034	4	sub060	4	sub086	2	sub142	4
sub009	3	sub035	5	sub061	4	sub087	0	sub143	1
sub010	3	sub036	3	sub062	2	sub088	1	sub144	1
sub011	1	sub037	3	sub063	2	sub089	3	sub145	1
sub012	0	sub038	3	sub064	3	sub090	5	sub146	2
sub013	1	sub039	1	sub065	3	sub091	1	sub147	2
sub014	2	sub040	1	sub066	6	sub092	3	sub148	1
sub015	2	sub041	3	sub067	2	sub093	1	sub149	6
sub016	5	sub042	0	sub068	2	sub094	5	sub150	1
sub017	3	sub043	5	sub069	6	sub095	4	sub151	4
sub018	0	sub044	3	sub070	3	sub096	4	sub152	4
sub019	1	sub045	1	sub071	2	sub097	1	sub153	5
sub020	2	sub046	2	sub072	5	sub098	5	sub154	1
sub021	3	sub047	1	sub073	2	sub099	3	sub155	1
sub022	2	sub048	3	sub074	2	sub100	2	sub156	6
sub023	1	sub049	1	sub075	1	sub131	5	sub157	2
sub024	1	sub050	1	sub076	5	sub132	3	sub158	2
sub025	2	sub051	0	sub077	6	sub133	2	sub159	5
sub026	3	sub052	3	sub078	0	sub134	2	sub160	4

十一、问题 3(c)的分析与求解

11.1 问题 3(c)分析与思路

本小问的目的在于分析患者个人史（年龄、性别等）、疾病史（高血压病史、卒中病史等 7 个特征）、治疗方法（7 种）及影像特征（血肿/水肿影像数据共 62 个特征）对出血性脑卒中患者的预后 90 天 mRS 的影响。并根据上述分析，对脑卒中患者的临床给出建议决策。

11.2 问题求解

笔者小组基于 Pearson 相关性分析了预后（90 天 mRS）与患者的个人史、疾病史和相关影像特征之间的关联关系。并基于在问题 3(a)和 3(b)中已对影响脑卒中患者的预后 90 天 mRS 评分进行的特征筛选，基于相关性大小进行排序，共得到最终的 28 个影响性较高的特征。




图 11-1 105 个特征与预后的相关性

针对这 28 个特征，将其分为几个类别进行讨论，具体分析如下：

（1）血肿与水肿体积

在 28 个特征中包含了首次检查的血肿体积与最终一次随访的血肿和水肿体积，且体积越大，90 天 mRS 评分越高。首次入院检查时的血肿体积可以准确地反映患者脑部的初始损伤程度。较大的血肿体积则表示着较为严重的脑出血，可能会导致随后更大范围的功能损害。因此，较大的首次检查血肿体积往往与较差的预后 mRS 结果相关。最终一次随访时的血肿和水肿体积则可以反映出经过治疗后患者脑部损伤的最终修复情况。如果经过治疗后的血肿和水肿体积得到了有效减小，则说明治疗取得了较为积极的可观效果，这可能与更好的预后 mRS 评分相关。由于预后 mRS 受多种因素影响，仅凭血肿体积和水肿体积无法准确预测预后结果。

（2）患者脑供血能力

上文中筛选出的 HM_ACA_R_Ratio 特征描述了医学影像中血管供应区域的高密度和低密度的比例，常用于评估脑供血的异常情况。脑供血能力是指大脑获得足够的血液和氧气以满足其正常功能的能力，当脑供血能力受损时，可能会导致脑组织缺血或缺氧，进而引发脑损伤。这种脑损伤可以是暂时性的，例如脑缺血发作，也可以是永久性的，例如脑卒中。脑供血能力受损会导致多种功能障碍，如运动和感觉失调、言语障碍、认知功能障碍等。这些功能障碍可能直接影响患者的生活质量和功能独立性，进而影响预后 mRS 评分。一般来说，脑供血能力受损越严重，预后 mRS 评分越高，表示功能障碍越严重。

（3）患者个人情况

患者的个人情况，如年龄、高血压(如上文筛选出的舒张压特征)、脑卒中史等，均

与患者的预后有影响。一般来说，患者的年龄越大，其身体素质和恢复能力相应也越差，进而导致较差的预后；患者若有高血压（舒张压较高）等疾病，在出血性脑卒中发作时会加速破裂脑血管处的血液流速，导致较严重的脑血肿和脑水肿，进而导致较差的预后；有脑卒中史的患者可能有相关方面的后遗症，在再次发生脑出血时可能产生更严重的影响，进而导致较差预后。一般来说，患者的个人情况越差，预后 mRS 评分越高。

（4）治疗方法

患者在发生脑溢血时，大量血液压迫脑组织，给患者造成了严重的身体负担，采取正确且及时的治疗方法，有利于遏制患者病情加重和促进病情好转。对于脑卒中患者而言，时间是大脑功能恢复的关键。在发病后的前几个小时内采取合适的治疗方法可以最大限度地限制神经损伤，并促进受损区域的再生和修复，进而获得较低的 mRS 评分。

综上所述，当患者综合身体素质较差、血肿体积及水肿体积较大、治疗不及时等情况，其预后 mRS 评分较高。

十二、模型评价与改进

12.1 模型优点

(1) 针对问题一所建立的基于随机森林的模型进行预测血肿扩张概率，预测值与真实值拟合基本匹配，模型的准确率较高，证明了该模型的可行性与通用性。

(2) 针对问题二的前 100 位患者数据样本散点图拟合，本文使用局部加权回归 Epanechnikov 内核、Cauchy 内核)、七阶多项式、二元高斯四种方式进行对比拟合，其中，二元高斯拟合效果最佳，验证了该模型的适用性和可行性。

(3) 针对问题二的前 100 患者数据进行分亚组处理，选取 k-means 聚类进行亚组分类后得到的残差更小，验证了考虑不同患者个体性差异影响因素从而进行分亚组方法的有效性和可行性。

(4) 针对问题二的治疗方案对水肿体积进展的研究，首先考虑治疗方案与患者数据样本之间的一对一、多对一的关系，再选取线性混合效应模型进行定量分析，通过显著性水平和误差验证了该模型的适用性。

(5) 针对问题三关于患者 90 天 mRS 评分及其有关因素的探索，首先基于患者评分的有关影像因素构建了三种模型进行特征筛选，并通过两两模型取交集后并集，来最大程度的筛选出与患者评分有关的特征变量，三种模型共同作用，筛选出的变量具有较高的可行性，随后使用三个预测模型在测试集上预测患者评分，准确率较高，说明了使用该方法构建模型的泛化能力较强。

12.2 模型改进

(1) 在问题一判定血肿是否扩张时，应建立时间与血肿体积的预测模型。

(2) 在问题二数据分亚组时，应进行多次调参，选出最优参数。

(3) 在问题二研究治疗方案对水肿体积进展时，应选取多个模型进行对比分析，选出最佳预测模型。

(4) 在问题三中采用了 BP 神经网络对患者的 90 天 mRS 评分进行预测，发现具有首次影像信息的患者进行 mRS 评分准确率较低，而具有随访影像信息的患者进行 mRS 评分时准确率较高，其原因可能在于 BP 神经网络训练依赖与大量的样本，并且需要不断优化参数，而当患者具有随访影像信息时，模型中的样本增加，网络训练效果增强，因此准确率增强。

十三、参考文献

- [1] 江志. 脑出血后脑水肿形成和血肿吸收影响因素的研究[D].苏州大学,2004.
- [2] 郭志恒,刘青萍,刘芳等.基于机器学习算法的脑卒中疾病早期预测模型研究[J].计算机与数字工程,2021,49(11):2180-2183+2247.
- [3] 徐守权,唐国文,黄舞标等.BP 神经网络、随机森林和决策树预测急性脑梗死患者静脉溶栓后发生早期神经功能恶化的效能比较[J].实用心脑肺血管病杂志,2023,31(02):16-21.
- [4] 虞乐,肖基毅.数据挖掘中强局部加权回归算法实现[J].电脑知识与技术,2012,8(07):1493-1495.
- [5] 郑舒颖. 时间序列拟合模型的应用和改进[D].厦门大学,2018.
- [6] 刘建,李昱旻,李建清等.一种基于高斯拟合优化的血压判定算法研究[J].生物医学工程研究,2022,41(02):101-106.
- [7] 程世超. K-Means 及 DBSCAN 聚类算法的研究与改进[D].江西理工大学,2021.
- [8] 罗天娥. 非正态及非线性重复测量资料分析模型及其医学应用[D].山西医科大学,2007.
- [9] 张美娜. 基于灰色关联分析的多目标智能优化算法[D].长春师范大学,2022.
- [10] 李伟娜. 基于 xgboost 算法的学生学习行为分析研究[D].北方工业大学,2022.
- [11] 邓伟. BP 神经网络构建与优化的研究及其在医学统计中的应用[D].复旦大学,2002.
- [12] 何泊延. 基于 GBDT 的数据分类方法的研究及其应用[D].东北电力大学,2021.

sub121	20191027000468			0.3026				2	
sub122	20191028002738			0.2070				1	
sub123	20191024001280			0.1045				5	
sub124	20191030001526			0.6096				0	
sub125	20191111002510			0.3511				3	
sub126	20191126002590			0.3565				1	
sub127	20191127002176			0.2512				1	
sub128	20191208000592			0.3050				3	
sub129	20191224000008			0.3081				2	
sub130	20191228000237			0.4561				2	
sub131	20160413000006			0.6578				5	5
sub132	20161215001667			0.2002				4	3
sub133	20200112000228			0.1531				2	2
sub134	20200101000392			0.1562				2	2
sub135	20201130003288			0.3025				1	4
sub136	20201203002778			0.2072				1	2
sub137	20201217002368			0.3511				1	2
sub138	20200403000012			0.5573				1	1
sub139	20200814000015			0.2514				4	4
sub140	20200412000331			0.2551				2	1
sub141	20200711001264			0.1068				3	3
sub142	20200411000014			0.4537				4	4
sub143	20200214000572			0.1537				2	1
sub144	20200124000041			0.6057				5	1
sub145	20200613001086			0.2600				1	1
sub146	20200531000253			0.1023				1	2
sub147	20201220000155			0.4557				1	2
sub148	20200609001016			0.2082				1	1
sub149	20200409001101			0.1594				5	6
sub150	20200118000372			0.0544				1	1
sub151	20201023001238			0.3077				2	4
sub152	20201109000009			0.2519				5	4
sub153	20201212001420			0.3073				5	5
sub154	20201129000299			0.5572				1	1
sub155	20200301000025			0.3597				5	1
sub156	20200306000927			0.3048				5	6
sub157	20201009003102			0.3521				1	2
sub158	20200410001952			0.2569				2	2
sub159	20200218000582			0.4056				5	5
sub160	20200821002584			0.0535				5	4

附录二：问题一代码

```

### 问题3a 预处理
import pandas as pd
import numpy as np

# 读取Excel文件
df = pd.read_excel('问题1.1处理结果_160.xlsx')

flag = np.zeros((160, 1))
dtime = np.zeros((160, 1))
# 通过循环获取每一行的数据
for index, sub in df.iterrows():

    for i in range(1,9):

        if pd.notnull(sub['时间差'+str(i)]) and sub['时间差'+str(i)]+sub['发病到首次影像检查时间间隔'] <=48:

            if sub['绝对体积差'+str(i)]>=6000 or sub['相对体积差'+str(i)]>=0.33:
                flag[index]=1
                dtime[index]=round(sub['时间差'+str(i)]+sub['发病到首次影像检查时间间隔'],2)
                break;

        else:
            break

# 对每次复诊进行处理
for index, row in sub.iterrows():
    # 计算总时间间隔
    total_interval = row['interval1'] + row['interval2']

    # 如果总时间间隔超过48小时，则停止处理
    if total_interval > 48:
        break

    # 判断是否满足发病条件
    if row['volume_diff_abs'] > 6000 or row['volume_diff_rel'] > 0.33:
        df.loc[index, 'disease'] = 1
        break
    else:
        df.loc[index, 'disease'] = 0

# 将结果保存到新的Excel文件
df = pd.DataFrame({'血肿': flag.squeeze(), '发病时间': dtime.squeeze()})
df.to_excel('问题1.2处理结果_160.xlsx', index=False)

```

```

### 问题1a 血肿发病模型
import pandas as pd
import numpy as np

# 读取Excel文件
df = pd.read_excel('问题1.1处理结果_160.xlsx')

flag = np.zeros((160, 1))
dtime = np.zeros((160, 1))
# 通过循环获取每一行的数据
for index, sub in df.iterrows():
    for i in range(1,9):
        if pd.notnull(sub['时间差'+str(i)]) and sub['时间差'+str(i)]+sub['发病到首次影像检查时间间隔'] <=48:
            if sub['绝对体积差'+str(i)]>=6000 or sub['相对体积差'+str(i)]>=0.33:
                flag[index]=1
                dtime[index]=round(sub['时间差'+str(i)]+sub['发病到首次影像检查时间间隔'],2)
                break;
            else:
                break
# 对每次复诊进行处理
for index, row in sub.iterrows():
    # 计算总时间间隔
    total_interval = row['interval1'] + row['interval2']
    # 如果总时间间隔超过48小时，则停止处理
    if total_interval > 48:
        break
    # 判断是否满足发病条件
    if row['volume_diff_abs'] > 6000 or row['volume_diff_rel'] > 0.33:
        df.loc[index, 'disease'] = 1
        break
    else:
        df.loc[index, 'disease'] = 0
# 将结果保存到新的Excel文件
df = pd.DataFrame({'血肿': flag.squeeze(), '发病时间': dtime.squeeze()})
df.to_excel('问题1.2处理结果_160.xlsx', index=False)

import pandas as pd
# 读取两个Excel文件
df1 = pd.read_excel('表1-患者列表及临床信息.xlsx')
df2 = pd.read_excel('表3-患者影像信息血肿及水肿的形状及灰度分布.xlsx', sheet_name='Hemo')
# 创建一个空的DataFrame来保存结果
result = pd.DataFrame()
# 遍历第一个表中的每一行
for index, row in df1.iterrows():
    id = row['入院首次影像检查流水号'] # 获取id
    # 在第二个表中找到对应id，并获取该行所有数据
    matched_row = df2[df2['流水号'] == id]
    # 将匹配的行添加到结果中
    result = result.append(matched_row)
# 将结果保存到新的Excel文件中
result.to_excel('问题1b.1结果.xlsx', index=False)

```

```

##逻辑回归
import pandas as pd
import numpy as np
# 导入所需的库
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
df = pd.read_excel('问题1.2数据.xlsx')
df_all=pd.read_excel('问题1.2数据.xlsx')
X_160 = df_all.drop(columns=['index', '血肿'])
df=df.head(100)
X = df.drop(columns=['index', '血肿'])
y = df['血肿']
# 首先, 我们需要将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, random_state=42)
# 初始化LogisticRegression类
log_reg = LogisticRegression()
# 使用训练数据集来训练模型
log_reg.fit(X_train, y_train)
# 使用测试数据集来预测概率
predictions = log_reg.predict_proba(X_test)
print("预测概率: ")
print(predictions)
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score
y_pred = [np.round(x,0) for x in predictions[:,1]]
# 计算准确率
accuracy = accuracy_score(y_test, y_pred)
print("准确率: ", accuracy)
# 计算精确率
precision = precision_score(y_test, y_pred)
print("精确率: ", precision)
# 计算召回率
recall = recall_score(y_test, y_pred)
print("召回率: ", recall)
# 计算F1分数
f1 = f1_score(y_test, y_pred)
print("F1分数: ", f1)
auc_roc = roc_auc_score(y_test, y_pred)
print("AUC-ROC: ", auc_roc)
# 初始化LogisticRegression类
my_model = LogisticRegression()
# 使用训练数据集来训练模型
my_model.fit(X, y)
# 使用测试数据集来预测概率
predictions = my_model.predict_proba(X_160)
# 提取数组的第二列
second_col = [row[1] for row in predictions]
df_logi=pd.DataFrame()
df_logi['预测概率'] = pd.DataFrame({'预测概率': second_col})
df_logi['是否发生血肿']=y
df_logi.to_excel('1b逻辑回归.xlsx', index=False)

##随机森林
import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report
df = pd.read_excel("问题1.2数据.xlsx")
df_all=df
df=df.head(100)
X = df.drop(columns=['index', '血肿'])
y = df['血肿']
X_160 = df_all.drop(columns=['index', '血肿'])
y_ = pd.read_excel("问题1.2处理结果_160.xlsx")
y_=y_['血肿']
my_model = RandomForestClassifier(n_estimators=20, random_state=42)
my_model.fit(X, y)
y_100 = my_model.predict_proba(X)
y_160 = my_model.predict_proba(X_160)
df2 = pd.DataFrame({'1': y_160[:,1].squeeze()})
df2.to_excel("1b随机森林_20.xlsx", index=False)
y_pre = [np.round(x,0) for x in y_100[:,1]]
print(classification_report(y, y_pre))
print('160')
y_pre_160 = [np.round(x,0) for x in y_160[:,1]]
print(classification_report(y_, y_pre_160))

```

附录三：问题二代码

```

###2a 预处理
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
# 读取Excel文件
df = pd.read_excel("问题2a数据.xlsx")
df = df.head(100)
df_melted = df.drop(columns=['index'])
dfX = pd.DataFrame()
dfY = pd.DataFrame()
# 对每一对时间和体积列进行处理
dfX['时间差'] = df_melted['时间差']
dfY['ED_volume'] = df_melted['ED_volume']
for i in range(0, 9):
    # 将时间和体积列转换为数值类型
    df_melted[f'时间差{i}'] = pd.to_numeric(df_melted[f'时间差{i}'])
    df_melted[f'ED_volume{i}'] = pd.to_numeric(df_melted[f'ED_volume{i}'])
    dfX[f'时间差{i}'] = df_melted[f'时间差{i}']
    dfY[f'ED_volume{i}'] = df_melted[f'ED_volume{i}']
for i in range(1, 9):
    dfX[f'时间差{i}'] = np.where(pd.isnull(dfX[f'时间差{i}']) | pd.isnull(dfX[f'时间差{0}']), np.nan, (dfX[f'时间差{i}'] + dfX[f'时间差{0}']))
# 绘制曲线图
plt.figure(figsize=(10, 6))
for i, row in df.iterrows():
    X = dfX.loc[i]
    Y = dfY.loc[i]
    plt.plot(X, Y, '.')
plt.xlabel('时间')
plt.ylabel('水肿体积')
plt.legend()
plt.show()
df_merged = pd.concat([dfX, dfY], axis=1)
df_last=pd.DataFrame()
temp=pd.DataFrame()
df_last['Time']=df_merged['时间差']
df_last['ED']=df_merged['ED_volume']
for i in range(0, 9):
    temp['Time']=df_merged[f'时间差{i}']
    temp['ED']=df_merged[f'ED_volume{i}']
df_last = pd.concat([df_last, temp], axis=0, ignore_index=True)
df_last.to_excel('2a散点数据.xlsx', index=False)

```

问题2b

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
for lei in range(1,5):
    # 读取Excel文件
    df = pd.read_excel("2b合并密度数据.xlsx", f"类别{lei}")
    df_last=pd.DataFrame()
    temp=pd.DataFrame()
    df_last['Time']=df['时间差0']
    df_last['ED']=df['ED_volume0']
    for i in range(1, 9):
        temp['Time']=df[f'时间差{i}']
        temp['ED']=df[f'ED_volume{i}']
        df_last = pd.concat([df_last, temp], axis=0, ignore_index=True)
        #df_last['ID'] = df['ID']
    with pd.ExcelWriter("2b散点数据-密度.xlsx", mode='a', engine='openpyxl') as writer:
        df_last.to_excel(writer, f"类别{lei}")

```

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
# 读取Excel文件
df = pd.read_excel("问题2a数据.xlsx")
df = df.head(100)
df_melted = df.drop(columns=['index'])
dfX = pd.DataFrame()
dfY = pd.DataFrame()
# 对每一对时间和体积列进行处理
dfX['时间差'] = df_melted['时间差']
dfY['ED_volume'] = df_melted['ED_volume']
for i in range(0, 9):
    # 将时间和体积列转换为数值类型
    df_melted[f'时间差{i}'] = pd.to_numeric(df_melted[f'时间差{i}'])
    df_melted[f'ED_volume{i}'] = pd.to_numeric(df_melted[f'ED_volume{i}'])
    dfX[f'时间差{i}'] = df_melted[f'时间差{i}']
    dfY[f'ED_volume{i}'] = df_melted[f'ED_volume{i}']

for i in range(1, 9):
    dfX[f'时间差{i}'] = np.where(pd.isnull(dfX[f'时间差{i}']) | pd.isnull(dfX[f'时间差{0}']), np.nan, (dfX[f'时间差{i}']

dfX.to_excel('2b时间数据.xlsx', index=False)

```


附录四：问题三代码

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, confusion_matrix
import matplotlib.pyplot as plt
import seaborn as sns

# 读取数据
# 读取Excel文件
data = pd.read_excel('3a标准化.xlsx', 'Sheet1')
df = pd.read_excel('3a标准化.xlsx', 'Sheet1')
data=data.head(100)

# 准备自变量和因变量
X = data.drop(columns=['90天mRS'])
y = data['90天mRS']
dfX=df.drop(columns=['90天mRS'])

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 逻辑回归
lr = LogisticRegression(max_iter=1500)
lr.fit(X_train, y_train)
lr_pred = lr.predict(X_test)
lr_160 = lr.predict(dfX)
plt.plot(lr_160)
x = range(1, len(y_train) + 1)
plt.plot(x, y_train)
plt.show()

# 决策树
dt = DecisionTreeClassifier()
dt.fit(X_train, y_train)
dt_pred = dt.predict(X_test)
dt_160 = dt.predict(dfX)
plt.plot(dt_160)
x = range(1, len(y_train) + 1)
plt.plot(x, y_train)
plt.show()

# 随机森林
rf = RandomForestClassifier(n_estimators=1500, max_depth=15, random_state=42, min_samples_leaf=2, min_samples_split=4)
rf.fit(X_train, y_train)
rf_pred = rf.predict(X_test)
rf_160 = rf.predict(dfX)
plt.plot(rf_160)
x = range(1, len(y_train) + 1)
plt.plot(x, y_train)
plt.show()

# 支持向量机
svm = SVC()
svm.fit(X_train, y_train)
svm_pred = svm.predict(X_test)
svm_160 = svm.predict(dfX)
plt.plot(svm_160)
x = range(1, len(y_train) + 1)
plt.plot(x, y_train)
plt.show()

# 计算逻辑回归的性能指标
lr_accuracy = accuracy_score(y_test, lr_pred)
lr_precision = precision_score(y_test, lr_pred, average='weighted')
lr_recall = recall_score(y_test, lr_pred, average='weighted')
lr_f1 = f1_score(y_test, lr_pred, average='weighted')
lr_cm = confusion_matrix(y_test, lr_pred)
print('逻辑回归')
print('accuracy:', lr_accuracy)
print('precision:', lr_precision)
print('recall:', lr_recall)
print('f1:', lr_f1)

# 计算决策树的性能指标
dt_accuracy = accuracy_score(y_test, dt_pred)
dt_precision = precision_score(y_test, dt_pred, average='weighted')
dt_recall = recall_score(y_test, dt_pred, average='weighted')
dt_f1 = f1_score(y_test, dt_pred, average='weighted')
dt_cm = confusion_matrix(y_test, dt_pred)
print('决策树')
print('accuracy:', dt_accuracy)
print('precision:', dt_precision)
print('recall:', dt_recall)
print('f1:', dt_f1)

# 计算随机森林的性能指标
rf_accuracy = accuracy_score(y_test, rf_pred)
rf_precision = precision_score(y_test, rf_pred, average='weighted')
rf_recall = recall_score(y_test, rf_pred, average='weighted')
rf_f1 = f1_score(y_test, rf_pred, average='weighted')
rf_cm = confusion_matrix(y_test, rf_pred)
print('随机森林')
print('accuracy:', rf_accuracy)
print('precision:', rf_precision)
print('recall:', rf_recall)
print('f1:', rf_f1)
```