



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 西安电子科技大学

参赛队号 23107010086

	1. 李丹阳
队员姓名	2. 吴迪龙
	3. 吴大勇

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生 数学建模竞赛

题 目： 强对流降水临近预报建模与优化

摘 要：

针对问题一，为了实现基于前一小时（10 帧）的实测雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ），对后续一小时（10 帧）的 Z_H 进行预报，本文首先建立了**线性拟合与 RMSE 双驱动的局部离群因子检测(LOF)数据清洗模型**，分别检测、去除了数据在时间和空间分布内的异常点，在数据清洗模型中，**LOF 异常阈值设置为 $LOF > 2$** 。然后，本文系统性的分析了降雨各微物理参数对降雨气象模型、降雨散射参数、降雨雷达观测量产生影响的物理机理，说明了降雨气象雷达观测量随降雨量产生变化的本质是各尺寸雨滴粒子散射特性随不同雨滴谱相互耦合的结果。最后，基于降雨雷达观测量参数产生的物理机理，选用 **NARX-RNN** 模型构建神经网络，完成了基于前时间对后续时间雷达观测量的预估，结果表明相比较于测量真值，预估值相关性好（ **> 0.9** ），误差低（ **$FRMSE < 1.7$** ），说明该网络实现了对后续时间雷达观测量的预估，模型性能优异。

针对问题二，为了解决问题一模型中模型预报结果不清晰、不完备的模糊效应问题，本文首先对模糊效应产生机理进行了研究，分别对网络模型进行输入层信息挖掘和输出层信息细化，使网络输入层特征信息增加 **336.67%**，网络输出层信息增加 **133.33%**，实现了信息补足，缓解了模糊效应。在输入层上，本文引入**雷达观测量三维梯度、降雨雷达强点、双偏振雷达类型**参数作为模型补充输入，实现了输入层信息挖掘。在输出层上，本文分别从**雷达回波细节和气象微物理参数**两方面进行了扩充。在雷达回波细节扩充方面，本文基于双偏振雷达运作机理，形成 Z_H ， Z_V ， Z_{DR} ， K_{DP} 双极化四输出完备雷达参数数据集，该数据集完整阐述了两个极化方向上的回波数据以及他们之间的内在关系。在气象微物理细节扩充方面，基于问题一降雨雷达观测量生成机理，推演计算生成包含**气象类型、降水粒子大小、含水量信息**的降雨气象微物理参数集，为含水量预估提供进一步支撑。最后，对扩充后的网络进行训练，完成了对上述输出层参数的预估，并与问题一进行了对比，结果表明**网络预估相似度提升 5.37%**，**网络误差降低 30.54%**，**泛化性能提升 46.94%**，网络性能显著提升。

针对问题三，为了实现基于雷达观测量（ Z_H 、 Z_{DR} ；不可使用 K_{DP} ），对降雨量实现定量估计，本文建立了**测算融合的 BP 神经网络降水量反演模型**。首先，基于问题一中讨论分析的降雨气象雷达观测量生成物理机理，利用自研软件，仿真生成不同降雨量下的气象散射特性，形成不同降雨量下的 Z_H 、 Z_{DR} 仿真数据集，与测试真值对比结果表示仿真数据生成可靠（ **$CC > 0.8$ ； $FRMSE < 2.0$** ）。随后，将仿真与实测数据融合，进一步基于第二问，以雷达观测量扩充降雨气象微物理参数，形成**测算融合数据集**。最后，基于测算融合数据集，构建 **BP 神经网络**。结果表明，对降雨量的预估可靠性高（ **$CC > 0.8$ ； $FRMSE < 2.0$** ），网络性能优异。

针对问题四，为了对双偏振雷达在强对流降水中的贡献进行定量评估，并优化网络融合策略，实现模型针对降雨“突发性”、“局地性”的应对能力提升，本文分别从**熵权-TOPSIS**

评估模型构建和多模型网络融合两方面完成了问题要求。首先，本文基于第二问、第三问研究成果，形成 **NARX-RNN-BP 多模型融合神经网络模型**，作为后续评估基准网络模型。然后，调整基准模型输入层信息，分别对单偏振信息（仅 Z_H ）和不同等级的双偏振信息（仅 Z_{DR} 、仅 K_{DP} 、 $Z_H + Z_{DR}$ 和 Z_H 、 Z_{DR} 、 K_{DP} 全参数）五种网络输入进行网络搭建，并对预估结果进行相关系数(CC)、均方根误差(RMSE)、相对偏置(RB)和分数均方差(FRMSE)四性能计算。随后，基于熵权-TOPSIS 模型构建评估模型，对五种网络输出进行评分，结果表明全参数相对评分 **0.3520**，排名第一，相比最低评分仅 Z_H 组提高 **97.13%**。接着，分别从局地性和突发性对网络进行优化。突发性方面，基于仿真数据构建了“是否有突发降雨”的**随机森林分类模型**，分类模型准确度达到 **99.6%**，完成了数据集的突发性标签制作。局地性方面，基于第二问降雨强点提取，对降雨强点构建 **K-Means 分类模型**，生成了局地雨区，完成了数据集的局地性标签制作。最后，对优化网络进行性能测试和评估，结果表明模型预估相似度极高(CC > **98%**)，误差极低(FRMSE < **1.2**)，相对模型分数提升 **10.71%** 到 **39.26%** 不等，说明模型针对局地性与突发性泛化能力优异。

关键词： 离群因子检测(LOF)；NARX-RNN 神经网络；雷达强散射点；测算融合；BP 神经网络；熵权-TOPSIS 评估模型；随机森林模型；K-Means 算法

目 录

一、问题重述	5
1.1 问题背景	5
1.2 问题重述	5
二、模型的假设	6
三、符号说明	6
四、问题一模型的建立、分析与求解	8
4.1 问题分析	8
4.2 数据清洗与数据集制作	9
4.3 物理机理驱动的未来雷达参数预测:	13
4.3.1 双偏振雷达降雨探测物理机理	13
4.3.2 基于物理机理驱动的 NARX-RNN 神经网络构建	18
4.4 本章小结	22
五、问题二模型的建立、分析与求解	23
5.1 问题分析	23
5.2 模糊效应问题与可行性分析	24
5.2.1 模糊效应	24
5.2.2 可行性分析	25
5.3 输入层扩展	25
5.3.1 空间梯度	25
5.3.2 空间强信息点提取	27
5.3.3 雷达类型区分	28
5.4 输出层扩展	29
5.4.1 雷达细节优化: 双极化四输出完备雷达参数数据集	29
5.4.2 气象细节优化: 气象微物理参数数据集	30
5.4.3 网络性能对比	33
5.5 本章小结	37
六、问题三模型的建立、分析与求解	38
6.1 问题分析	38
6.2 仿真数据生成	38
6.2.1 降雨气象参数	38
6.2.2 降雨气象建模	40
6.2.3 降雨散射特性建模	41
6.2.4 降雨雷达特性建模	42
6.3 测算融合 BP 神经网络	43
6.3.1 测算融合数据集	43
6.3.2 基于测算融合数据集的 BP 神经网络预估模型建立	44
6.4 本章小结	47
七、问题四模型的建立、分析与求解	48
7.1 问题分析	48
7.2 评估模型建立与双偏振雷达贡献度评估	49
7.2.1 考虑单双偏振雷达信息的 NARX-RNN-BP 联合神经网络	49
7.2.2 神经网络反演四性能参数	50
7.2.3 基于熵权-TOPSIS 方法的评估模型建立	51

7.3 优化融合的高泛用性网络构建	53
7.3.1 基于随机森林的突发性判断模型	54
7.3.2 基于雷达强点提取和聚类算法的局地性判断模型	57
7.3.3 考虑局地性和突发性的降雨临近预测多模融合神经网络模型	60
7.4 本章小结	61
八、模型的评价	63
8.1 模型的优点	63
8.2 模型的缺点	63
8.3 模型的推广	63
参考文献	64
附录	65

一、问题重述

1.1 问题背景

我国地域辽阔，自然条件复杂，因此灾害性天气种类繁多，地区差异大。其中，雷雨大风、冰雹、龙卷、短时强降水等强对流天气是造成经济损失、危害生命安全最严重的一类灾害性天气^[1]。以2022年为例，我国强对流天气引发风雹灾害造成的死亡失踪人数和直接经济损失分别占73%和69%。由于强对流天气具有突发性和局地性强、生命史短、灾害重等特点，其短时（0~12小时）和临近（0~2小时）预报通常也是天气预报业务中的难点^[2]。

传统强对流天气临近预报主要依靠雷达等观测资料，结合风暴识别、追踪技术进行雷达外推预报，即通过外推的方法得到未来时刻的雷达反射率因子，并进一步使用雷达反射率因子和降水之间的经验性关系（即 $Z-R$ 关系）估计未来时刻的降水量^[3]。近年来，随着大数据的积累和计算机算力的发展，人工智能及深度学习技术发展迅速。深度学习方法是一类数据驱动的方法，理论上其性能随着训练数据量增大而提升，因此很适合有大量雷达观测数据积累的短临预报领域。目前国际上主要有两类基于深度学习的短临预报模型，一类基于卷积神经网络（Convolutional Neural Networks, CNNs），如 U-Net 等模型^[4]；另一类基于循环神经网络（Recurrent Neural Networks, RNNs），如 ConvLSTM、DGMR 等模型^[5]。

雨滴在降落过程中受到空气阻力作用，形状可呈扁球形或馒头形，并且一般来说越大的雨滴越扁。因此，雨滴对水平偏振（电场振动方向在水平面内）的电磁波和垂直偏振（电场振动方向在垂直平面内）的电磁波的反射特征是不一样的^[6]。传统雷达仅能发射和接收一个偏振方向上的电磁波，而新型的双偏振雷达可同时发射和接收在水平和垂直两个偏振方向的电磁波，可以根据两个偏振方向上的回波的强度差别、相位关系等信息获得降水粒子的大小、相态、含水量等信息^[7]，这些信息被统称为微物理信息。近年来研究表明，双偏振雷达变量反映的微物理信息里包含了对流系统的演变状态、空间动力结构等关键信息^[8]。因此，双偏振雷达变量的应用，理论上对于强对流预报有重要意义。

1.2 问题重述

基于以上研究背景，为了更好地应用双偏振雷达改进强对流降水短临预报，本文需要解决如下问题：

问题一：建立数据预清理模型及未来雷达观测量临近预报模型

利用题目提供的数据，建立某种数据清洗模型，实现实测数据预清洗，剔除异常值。接着，建立某种模型，实现对强对流的临近预报，要求临近预报的输入为前面一小时（10 帧）的雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ），输出为后续一小时（10 帧）的 Z_H 预报。

问题二：建立去模糊化临近预报模型

在第一问的基础上，面对预报总是趋于模糊的问题，优化问题一的模型或重新建立某种新模型，实现以缓解预报的模糊效应，使预报出的雷达回波细节更充分、更真实。

问题三：建立基于雷达观测量的实时降水量模型

利用题目提供的 Z_H 、 Z_{DR} 和降水量数据，设计适当的数学模型，利用 Z_H 及 Z_{DR} 进行定量降水估计。模型输入为 Z_H 和 Z_{DR} （不可使用 K_{DP} 变量），输出为降水量。

问题四：建立双偏振雷达资料的预报贡献评估和高泛用性的高精度降雨临近预报模型

利用一、二、三问模型基础，设计某种数学模型实现评估双偏振雷达资料在强对流降水临近预报中的贡献。随后，基于某种方式优化数据融合策略，是模型可以更好地应对突发性和局地性强的强对流天气。

二、模型的假设

为了对进行准确、合理的描述，我们对关于降水临近预报模型做出以下假设：

- (1) 单位时间内可用于预测的数据量异常值数据不高于 10%，输入量在剔除异常值后仍满足网络最低需求；
- (2) 雷达系统在探测工作中的大气衰减造成的影响可以忽略；
- (3) 数据所使用的双偏振雷达的性能参数与某个“标准单偏振雷达” Z_H 值相同。
- (4) 雷达观测数据不因昼夜、气温因素造成偏差，并且探测范围内不存在非气象干扰（如鸟群、飞机等）；
- (5) 雷达观测数据与降水实况之间存在稳定的统计关系；
- (6) 雷达系统的探测范围内仅存在水粒子气象；
- (7) 在不同的降雨中，相同尺寸的雨滴散射特性与雷达参量相同；

三、符号说明

No.	符号	含义
1	Z_H	水平雷达反射率因子
2	Z_{DR}	差分反射率
3	K_{DP}	比差分传播相移
4	Φ_{DP}	差分传播相移
5	Ψ_{DP}	雷达后向散射回波相位差
6	Φ_s	后向散射差分相移
7	h_R	雨顶高度
8	δ_{HV}	杂波误差
9	RNN	循环神经网络
10	NARX	带有外部输入的非线性自回归神经网络
11	Z_V	垂直雷达反射率因子

12	$N_p(D)$	降水粒子雨滴谱函数
13	$\mathbb{R}_a$	水平方向极化的散射回波相关系数
14	$\mathbb{R}_b^*$	垂直方向极化的散射回波相关系数
15	LOF	局部离群因子
16	LWC	液态含水量
17	RMSE	均方根误差
18	CC	相关系数
19	FRMSE	分数均方差
20	RB	相对偏振
21	QPE	定量定量分析
22	T_s	雷达系统的噪声温度
23	MOET	样本数据平均误差
24	SSE	簇内平方误差

四、问题一模型的建立、分析与求解

4.1 问题分析

问题一需要根据附件一文件夹“NJU_CPOL_update2308”，下属包含“DBZ”，“KDP”，“ZDR”等次级文件，基于附件内数据建立可提取用于强对流临近预报双偏振雷达资料中微物理特征信息的数学模型。实现基于前面一小时（10 帧）的雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ），对后续一小时（10 帧）的 Z_H 进行预报。观察题目所给附件分析，附件内包含了不同雷达作用距离下的雷达针对不同次降雨观测的随时间帧变化的网格化雷达实测数据。因为雷达实测数据受各种因素影响，在进行数学建模分析预测前首先要对数据进行清洗。随后，由于数据量巨大充足，可以根据“DBZ”，“KDP”，“ZDR”三数据随时间帧的变化规律基于神经网络实现未来雷达参数预测。

问题一建模流程如下所示：




图 1 问题一思路流程图

数据清洗与数据集制作模型：基于线性拟合与 RMSE 双驱动的局部离群因子检测 (LOF) 进行数据清洗。首先，对同一 data_dir、同一雷达作用距离、同一网格位置处的同一雷达参数进行随时间帧的线性拟合，并记录每一时间帧下的均方根误差 (RMSE)，随后，基于 LOF 方法对空间位置下的 RMSE 进行异常值分析筛除，最终获得清洗后的“可信”数据集。

物理机理驱动的未来雷达参数预测模型：对降雨的雷达散射特性从降雨粒子级进行分析，得到同一降雨条件下随降雨量变化（即时间帧变化）对雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ）的映射关系，即降雨雷达特性随时间变化的物理本质是雨滴散射特性在不同谱参数下的雨滴谱下以不同方式排列组合。基于这一物理本质和题目需求，建立了 NARX-RNN 神经网络。

络随后，将清洗后数据进行标签化，从 3 种雷达作用距离，258 个 data_dir 共计无数时间帧例中随机抽取充足样例基于物理机理驱动构建神经网络构建。基于 NARX-RNN 模型，通过前一小时雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ），预测后一小时雷达观测量（ Z_H ），并在网格量级上进行验证与真实值对比。

4.2 数据清洗与数据集制作

1) 寻找异常值位置

双偏振雷达在测试气象环境时，分别针对不同雷达、不同降雨样本进行了雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ）和降雨量记录。但在实际测量中，由于各种未知或不可控因素，使得最终数据中往往存在异常数据（如突然断裂式上升、下降、清零等等）。这对于后续建模分析，尤其是神经网络分析会造成严重影响。因此，在进行神经网络构建前，必须要对异常值进行清洗。

为了对数据进行清洗和数据，首先需要对数据构成进行研究分析，通过观察，本题附件包含的数据主要由不同雷达、不同观测场景，不同时间帧下整体区域网格块内的雷达观测数据和降雨数据。这里取 data_dir_001\frame_001 为例，雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ）取 1.0km 数据，如图：




图 2 附件例 1 数据分析

同样，再取 data_dir_001\frame_020 为例，雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ）取 1.0km 数据，如图：




图 3 附件例 2 数据分析

可以看到，在同一 `data_dir` 下，数据集反映同一区域不同网格块内，在随时间帧步进的时空变化规律。因此，在异常值清洗过程中，必须同时需要考虑时间与空间上的异常可能。在常规异常筛除过程中，一般可以直接基于正态分布规律即 3σ -准则（又名拉依达准则）既可剔除异常值^[9]。但在此题目中，由于时间帧存在较大跨度（6min），基于 3σ -准则对于一些特殊情况（如可持续时间极短的雷阵雨）可能产生误判。本文清洗思路如下图：




图 4 数据清洗方法

因此，本文首先基于时间帧对不同位置的数值变化进行了线性拟合并计算 RMSE，形成不同时间帧下的二维 RMSE 矩阵，该矩阵横纵轴包含了位置信息。随后，对于时间轴上异常的点，在该时间帧下对空间位置及其附近 5*5 单元格内位置所有位置的 RMSE 在各自位置附近最大 25*25 网格内进行局部离群因子检测（LOF），如果某位置在某时间帧下，不仅相较于同一位置不同时间帧 RMSE 偏大，而且相比较于同一时间帧下不同位置 LOF 也偏高，则可以判定该位置为异常点。

RMSE 与 LOF 数学语言可描述为：

均方根误差（Root Mean Square Error, RMSE）：观测值与真值偏差的平方与观测次数 N 比值的平方根。均方根误差也用 σ 表示，反映了测量数据偏离真实值的程度， σ 越小，表示测量精度越高。

$$X_{RMSE} = \frac{\sqrt{\sum_{i=1}^N (X_{obs,i} - X_{model,i})^2}}{N^2} \quad (1)$$

其中 $X_{obs,i}$ 是第 i 时间帧下的对应数值， $X_{model,i}$ 是拟合出来的第 i 个真值，共计 N 个时间帧。

局部异常因子（Local Outlier Factor, LOF）：LOF 反应了一个样本点 p 周围的样本点所处位置的平均密度比上该样本点所在位置的密度。如果这个比值越接近 1，说明 p 的其邻域点密度差不多， p 可能和邻域同属一簇；如果这个比值越小于 1，说明 p 的密度高于其邻域点目睹， p 为密度点；如果这个比值越大于 1，说明 p 的密度小于其邻域点密度， p 越可能是异常点。该方法需要对数据的分布做太多要求，还能量化每个数据点的异常程度。算法如下：

(1) **定义第 k 距离**：k-distance

在距离目标位置 p 的所有临近点集内，点 p 与第 k 个最近的点之间的距离称为点 p 的 K -邻近距离，记为 $K\text{-distance}(p)$ 即 $dk(p)$ ，其定义如下：

$dk(p) = d(p, o)$ 并且满足：

- a) 在集合中至少有不包括 p 在内的 k 个点 $o \in C\{x \neq p\}$ ，满足 $d(p, o') \leq d(p, o)$ ；
- b) 在集合中最多不包括 p 在内的 $k-1$ 个点 $o \in C\{x \neq p\}$ ，满足 $d(p, o') \leq d(p, o)$ 的第 k 距离，也就是距离 p 第 k 远的点的距离，不包括 p 。

(2) **定义第 k 距离领域**：点 p 的第 k 距离邻域 $N_k(p)$ 就是 p 的第 k 距离即以内的所有点，包括第 k 距离。因此 p 的第 k 邻域点的个数 $|N_k(p)| \geq k$

(3) **计算可达距离**：可达距离（Reachability distance）：可达距离的定义跟 K -邻近距离是相关的，给定参数 k 时，数据点 p 到数据点 o 的可达距离 $\text{reach-dist}(p, o)$ 为数据点 o 的 K -邻近距离和数据点 p 与点 o 之间的直接距离的最大值：

$$\text{reach-distance}_k(p, o) = \max\{k\text{-distance}(o), d(p, o)\} \quad (2)$$

(4) **计算局部可达密度**：局部可达密度的定义是基于可达距离的，对于数据点 p ，那些跟 p 的距离小于等于 $K\text{-distance}(p)$ 的数据点称为它的 K -nearest-neighbor，记为 $N_k(p)$ ，数据点 p 的局部可达密度为它与邻近的数据点的平均可达距离的倒数。点 p 的局部可达密度表示为：

$$\text{lrd}_k(p) = 1 / \left(\frac{\sum_{o \in N_k(p)} \text{reach-dist}_k(p, o)}{|N_k(p)|} \right) \quad (3)$$


(5) **局部离群因子**：根据局部可达密度的定义，如果一个数据点跟其他点比较疏远的话，

那么显然它的局部可达密度就小。但 LOF 算法衡量一个数据点的异常程度，并不是看他的绝对局部密度，而是它看跟周围邻近的数据点的相对密度。这样做的好处是可以允许数据分布不均匀，密度不同的情况。局部异常因子既是用局部相对密度来定义的。数据点 p 的局部相对密度（局部异常因子）为点 p 的邻居们的平均局部可达密度跟数据点 p 的局部可达密度的比值。


$$LOF_k(p) = \frac{\sum_{o \in N_k(p)} \frac{lrd_k(o)}{lrd_k(p)}}{|N_k(p)|} = \frac{\sum_{o \in N_k(p)} lrd_k(o)}{|N_k(p)|} / lrd_k(p) \quad (4)$$

在这里，在时间帧内计算 LOF 时，空间位置上任意一点的“位置”即为之前计算获取的时间轴上与拟合结果对比的该帧的 RMSE。


基于以上理论，对所有数据集进行遍历，带入清洗模型中计算，并输出异常位置点。在构建神经网络和后续题目建模提取数据的过程中，首先将异常数据在.mat 中替换为拟合正常数据。在进行筛选时，基于现有研究，将 $LOF > 2$ 的异常点进行作为严重异常进行排除。为了直观的表现数据异常的情况，我们列举了四个文件中存在异常数据的例子。




(a) dBZ\7.0km\dir_008\frame_063(212,90)



(b) KDP\3.0km\ dir_169\frame_004(232,94)



(c) ZDR\1.0km\dir_068\frame_040(79,172)



(d) kdpRain\ dir_203\frame_047(17,74)

图 5 异常值示例

图为分别从降雨和三种雷达观测量数据中随机选择的四个异常值位置。括号里的内容表述其在网格内的坐标数据，途中颜色深度代表 LOF 计算结果。一般来说，LOF 大于 1 即可认为存在异常，大于 2 则为严重异常。在实际使用中，当我们读入文件后，会自动对文件数据进行遍历，遍历后将检测的异常点位置用拟合结果进行替代，保存在.mat 文件中。

4.3 物理机理驱动的未来雷达参数预测：

首先，任务书中提供了不同测量场景下不同时间帧的降雨率和雷达测量量，在 4.2 中进行异常值剔除后，基于物理机理构建神经网络实现对未来雷达参数的预测。具体步骤如下：

4.3.1 双偏振雷达降雨探测物理机理

(1) 降雨气象建模

a) 雨滴模型

研究表明，下落雨滴的形状与其尺寸高度相关。雨滴尺寸跨度较大，当前观测到的最小的雨滴仅与云中微小水滴大小类似，处于微米量级，最大的雨滴则一般不会超过 4mm，当雨滴大小超过 4mm 时，一般会发生破裂。因此，一般雨滴的尺寸在 0.05-4mm 之间。

基于高速摄像机记录结果，半径 1mm 下的雨滴通常呈球形，而对于尺寸更大的雨滴，则开始呈现带底部凹槽的扁椭球形状。如图所示：

通常，在计算时，我们用等效体积球进行研究。扁椭球型雨滴的形状可以通过短轴 a 和长轴 b 的比值 a/b 以及等效球半径 a_0 来描述。下图展示了扁椭球雨滴的轴比 a/b 和等效球半径 a_0 的理论和实验结果。扁椭球雨滴在电磁散射计算中常用的轴比关系，可以用以下公式表示：

$$\begin{cases} A: a/b = 1 - 0.1a_0 \\ B: a/b = 1 - (\frac{0.41}{4.5})a_0 \end{cases} \quad (5)$$

式中，等效半径 a_0 的单位为 mm。在计算雨滴电磁散射特性时使用更为广泛。




图 6 雨滴形状模型

b) 雨滴下降速度

雨滴的末速度是计算降雨率时的重要参数，许多实验都对雨滴的末速度进行了测量。Gunn 和 Kiner 以及 Best 的测量结果被广泛应用，主要得出以下结论：

- ① 雨滴的下落速度随着雨滴尺寸的增加而增加。
- ② 当雨滴半径超过 1mm 时，雨滴末速度的增加率逐渐减少。
- ③ 当雨滴半径约为 2.5mm 时，其末速度达到极大值，约为 9m/s。
- ④ 当雨滴半径超过 2.5mm 时，末速度略有下降。

- ⑤ 当雨滴尺寸继续增大时，雨滴会发生破裂并分裂成小雨滴。
- ⑥ 雨滴的下落极限速度受大气压强、温度和湿度的影响。
- 相关研究表明，雨滴末速度的测量大致遵循以下模型：

表 1 雨滴末速度模型

雨滴直径 D (mm)	雨滴末速度 V (m/s)	雨滴直径 D (mm)	雨滴末速度 V (m/s)
0.1	0.256	2.8	7.82
0.2	0.72	3.0	8.06
0.3	1.17	3.2	8.26
0.4	1.62	3.4	8.44
0.5	2.06	3.6	8.60
0.6	2.47	3.8	8.72
0.7	2.87	4.0	8.83
0.8	3.27	4.2	8.92
0.9	3.67	4.4	8.98
1.0	4.03	4.6	9.03
1.2	4.64	4.8	9.07
1.4	5.17	5.0	9.09
1.6	5.65	5.2	9.12
1.8	6.09	5.6	9.14
2.0	6.49	5.8	9.16
2.2	6.90	6.0	9.17
2.4	7.27	6.5	9.17
2.6	7.57	7.0	9.17

因此，雨滴末速度公式有

$$\begin{aligned}
 V &= \left(\frac{0.787}{r^2} + \frac{503}{\sqrt{r}} \right)^{-1} \cdot 10^6 \quad (cm/s) \\
 &= 10 / \left(\frac{0.3148}{D^2} + \frac{2.2495}{\sqrt{D}} \right) \quad (m/s)
 \end{aligned} \tag{6}$$

c) 雨滴尺寸分布模型

雨滴尺寸分布，也被称为雨滴谱，是指在降雨的某一时刻，不同尺寸的雨滴在空间中的分布情况。雨滴谱是研究降雨特性、气象雷达和无线电波传播等方面的重要参数^[10]。它经过广泛的测量和模式化研究。对于无特定要求的场景，通常使用 ITU-R 使用的 Laws-Parsons 雨滴尺寸模型。其分布形式为：

$$N(D)dD = \frac{10^4}{6\pi} \frac{Rm(D)dD}{D^3V(D)} \quad (m^{-3}) \tag{7}$$

d) 水滴介电常数模型

降雨的传播特性与水的复介电特性相关，液态水的复介电特性是计算雨滴散射特性的重要参数。在计算不同波段的液态水的复介电常数时，通常使用相对介电常数 $\varepsilon = \varepsilon_1 - j\varepsilon_2$ 或折射率 $n = n_1 - jn_2$ 来表示，两者之间存在 $n = \sqrt{\varepsilon}$ 关系。液态水的介电特性在波长大于 1mm 时，由水分子的极化特性决定；而在波长小于 1mm 时，由分子中各种谐振吸收所决定，是温度和频率的复杂函数。对于 -20-50 摄氏度，波长大于 1mm 的情景，都可以使用 Ray 公式，此公式下水的介电常数如下：

$$\varepsilon_1 = \varepsilon_\infty + \frac{(\varepsilon_s - \varepsilon_\infty)(1 + \frac{\lambda_s}{\lambda})^{1-\alpha} \sin(\alpha \frac{\pi}{2})}{1 + 2(\lambda_s/\lambda)^{1-\alpha} \sin(\alpha \frac{\pi}{2}) + (\lambda_s/\lambda)^{2(1-\alpha)}} \quad (8)$$

$$\varepsilon_2 = \frac{(\varepsilon_s - \varepsilon_\infty)(\frac{\lambda_s}{\lambda})^{1-\alpha} \cos(\alpha \frac{\pi}{2})}{18.8496 \times 10^{10}} + \frac{(\varepsilon/\lambda)^{1-\alpha} \sin(\alpha \frac{\pi}{2}) + (\lambda_s/\lambda)^{2(1-\alpha)}}{\text{aligned}} \quad (9)$$

其中，

$$\varepsilon_s = 78.54[1 - 4.579 \times 10^{-3}(t - 25) + 1.19 \times 10^{-5}(t - 25)^2 - 2.8 \times 10^{-8}(t - 25)^3] \quad (10)$$

$$\varepsilon_\infty = 5.27134 + 2.16474 \times 10^{-2}t - 1.31198 \times 10^{-3}t^2 \quad (11)$$

$$\alpha = -\frac{16.8129}{t + 273} + 6.09265 \times 10^{-2} \quad (12)$$

$$\lambda_s = 3.3836 \times 10^{-4} \exp(\frac{2513.98}{t + 273}) \quad (13)$$

e) 降雨雨顶高度模型

为了预报地空路径的雨衰减，需要雨顶高度这一参数。由于全球范围内缺乏雨顶高度的数据，通常使用 0°C 等温层高度来近似雨顶高度（即海拔高度）。ITU-R 提供了一种全球雨顶高度模型，可以表示为：

$$h_R = \begin{cases} 5 - 0.075(\varphi - 23) & \varphi > 23^\circ & \text{北半球} \\ 5 & 0^\circ \leq \varphi \leq 23^\circ & \text{北半球} \\ 5 & 0^\circ \geq \varphi \geq -21^\circ & \text{南半球} \\ 5 + 0.1(\varphi + 21) & -71^\circ \leq \varphi \leq -21^\circ & \text{南半球} \\ 0 & \varphi < -71^\circ & \text{南半球} \end{cases} \quad (14)$$

其中， φ 为地球纬度。

(2) 降雨散射特性建模

a) 单个雨滴散射特性建模

研究表明，大尺寸雨滴呈非球形。本文采取点匹配法进行模型构建。一般，在毫米波段内，入射波波长与雨滴尺寸可相比拟，采用扁椭球形雨滴近似计算的结果误差较小，下面将使用点匹配法计算扁椭球形雨滴的散射特性。

假设一椭球形雨滴的等效半径为 a_0 ，其短轴为 a ，长轴为 b ，长短轴之比为

$$\frac{b}{a} = 1 - \frac{0.41}{4.5} a_0 \quad (15)$$

式中 a_0 为等体积半径，即 $\pi a_0^3 = \pi a b^2$ 。




图 7 雨滴散射模型

图中展示了一个扁椭球形雨滴，其中心位于直角坐标的原点。平面波以角度 α 入射到雨滴上，激发雨滴内部的透射场，并引起散射场。 E_i 表示入射波的电场，其极化状态用单位向量 e 表示， K_i 是入射方向的单位向量， E_s 表示散射波的电场， K_s 是散射方向的单位向量。

假设只考虑前向散射和后向散射，并且雨滴在传播方向上无倾斜，则散射波中只有同极化分量。具体而言，如果入射电场是垂直极化的（电场矢量沿 Z 方向），则散射振幅中只有垂直分量；如果入射电场是水平极化的（电场矢量沿 Y 方向），则散射波中只有水平分量。这意味着入射电场的极化方向决定了散射波的极化方向。

当入射角 α 为任意值时，入射波和散射波都可以分解为相互垂直的两个分量，基于球坐标系， E_V^i 和 E_V^s 指向 $\bar{e}_\theta$ 方向， E_H^i 和 E_H^s 指向 $\bar{e}_\phi$ 方向，极化散射矩阵有：

$$\begin{bmatrix} E_H^s \\ E_V^s \end{bmatrix} = \frac{e^{ikr}}{r} \begin{bmatrix} f_{hh} & f_{hv} \\ f_{vh} & f_{vv} \end{bmatrix} \begin{bmatrix} E_H^i \\ E_V^i \end{bmatrix} \quad (16)$$

其中 i 在 origin 处，而 s 距离 origin 距离为 r 。此时，扁椭球雨滴的散射振幅向量有

$$\vec{f}(\vec{K}_i, \vec{K}_s) = \frac{1}{k} \sum_{m=0}^{\infty} \sum_{n=0}^{\infty} j^n \begin{bmatrix} \left(ja_{omn}^s \frac{mP_n^m(\cos \theta)}{\sin \theta} + b_{emn}^s \frac{dP_n^m(\cos \theta)}{d\theta} \right) \cos(m\phi) \cos(\xi) \vec{e}_\theta \\ + \left(-ja_{omn}^s \frac{dP_n^m(\cos \theta)}{d\theta} - b_{emn}^s \frac{mP_n^m(\cos \theta)}{\sin \theta} \right) \sin(m\phi) \cos(\xi) \vec{e}_\phi \\ + \left(-ja_{emn}^s \frac{mP_n^m(\cos \theta)}{\sin \theta} + b_{omn}^s \frac{dP_n^m(\cos \theta)}{d\theta} \right) \sin(m\phi) \sin(\xi) \vec{e}_\theta \\ + \left(-ja_{emn}^s \frac{dP_n^m(\cos \theta)}{d\theta} + b_{omn}^s \frac{mP_n^m(\cos \theta)}{\sin \theta} \right) \cos(m\phi) \sin(\xi) \vec{e}_\phi \end{bmatrix} \quad (17)$$

其中， ja_{omn}^s 与 b_{emn}^s 为散射场奇偶展开系数， ξ 为入射波电场单位向量与 XOZ 夹角，P 为连带 Legendre 函数。若进一步考虑雨滴倾角，单个雨滴散射振幅有：

$$\begin{cases} f'_{vv} = f_v \cos^2 \theta_R + f_h \sin^2 \theta_R \\ f'_{hh} = f_v \sin^2 \theta_R + f_h \cos^2 \theta_R \\ f'_{vh} = f'_{hv} = (f_h - f_v) \sin \theta_R \cos \theta_R \end{cases} \quad (18)$$

b) 双偏振雷达参数模型

① 水平雷达反射率因子 Z_H

Z_H 是水平偏振的雷达反射率因子，其定义式为

$$Z_H = \frac{\lambda^4}{\pi^5 |K_w|^2} \int \sigma_p(D) N_p(D) dD \quad (19)$$

其中 λ 为电磁波的波长， $|K_w|^2$ 为水相粒子的介电常数，一般液态水的介电常数约为 0.93。D 表示降水粒子直径， $\sigma_p(D)$ 是直径为 D 的雨滴的后向散射截面。 $N_p(D)$ 则是降水粒子雨滴谱函数。可以看到，反射率因子的大小主要由降雨的粒子直径与密度决定。

由于双偏振雷达具有水平与垂直两个偏振通道，因此可以获取两个方向的反射率因子数据。在降水粒子分类时，一般选择水平反射率因子数据进行计算。在实际应用过程中，可以通过下式进行计算：

$$\begin{cases} \hat{S}_{HH} = \frac{2}{W} \sum_{i=1}^{W/2} |HH_i|^2 - N_{HH} \\ \hat{S}_{VV} = \frac{2}{W} \sum_{i=1}^{W/2} |VV_i|^2 - N_{VV} \end{cases} \quad (20)$$

$$\begin{cases} Z_H = 10 \log(\hat{S}_{HH}) \\ Z_V = 10 \log(\hat{S}_{VV}) \end{cases} \quad (21)$$

其中 HH 和 VV 分别表示水平与垂直偏振状态下第 i 个脉冲的回波数据，W 为脉冲总数。N 分别表示同为水平和同为垂直偏振方向收发电磁波时的白噪声功率，S 表示水平与垂直偏振状态下的平均功率。

② 差分反射率 Z_{DR}

差分反射率 Z_{DR} 可以利用 HZ 和 VZ 进行定义和计算，表达式为：

$$Z_{DR} = Z_H - Z_V \quad (22)$$

其中 HZ 和 VZ 分别代表水平和垂直方向的反射率因子。根据上述公式可以看出， Z_{DR} 反映了降水粒子的形状是否接近于球形，它主要由降水粒子的空间取向和轴比（即粒子的长轴与短轴的比值）共同决定。当降水粒子形状越接近圆球形时， Z_{DR} 的值越接近于 0。此外，随着液态降水粒子体积的增大，由于受到空气阻力的影响，它们的形状会逐渐扭曲，不再是完全的圆球形^[11]。

③ 比差分传播相移 K_{DP}

比差分传播相移率 K_{DP} 是差分传播相移 Φ_{DP} 随距离的变化程度：

$$K_{DP} = \frac{1}{2} \frac{d\Phi_{DP}}{dr} \approx \frac{\Phi_{DP}(r_2) - \Phi_{DP}(r_1)}{2(r_2 - r_1)} \quad (23)$$

其中，差分传播相移 Φ_{DP} 可以通过下式获取

$$\begin{cases} R_a = \langle HH_i VV_i^* \rangle = \frac{2}{M} \sum_{i=1}^{M/2} HH_i^* VV_i \\ R_b = \langle VV_{i+1} HH_{i+1}^* \rangle = \frac{2}{M} \sum_{i=1}^{M/2} VV_i^* HH_{i+1} \\ \Psi_{DP} = \frac{1}{2} \arg(R_a R_b^*) + \Phi_s \\ \Phi_{DP} = \Psi_{DP} - \delta_{HV} \end{cases} \quad (24)$$

其中 $R_a R_b^*$ 是水平和垂直方向极化的散射回波相关系数， Ψ_{DP} 是雷达后向散射回波相位差信号和即全差分相位。 Φ_s 一般看做是系统相关常数为后向散射差分相移。 δ_{HV} 一般看做杂波误差，通过滤波去除^[12]。

4.3.2 基于物理机理驱动的 NARX-RNN 神经网络构建

前文提到，本题目的本质是基于 Z_H 的过往值和另参数 D_{RZ} 、 K_{DP} 预测后时间的 Z_H 参数。这种变化的本质是气象天气随时间的变化导致，而降雨量变化是导致这一变化的强相关因素之一。基于前文的物理机理，在短时间内，降雨粒子谱分布类型可以看做是不变的，降雨量变化会导致雨滴谱在参数上发生改变，而相同尺寸的单个雨滴的散射特性可以看做不变。因此，双偏振雷达观测量可以看做无数个小观测量（雨滴特性），基于不同的时间（降雨量不同），以不同的组合方式（谱分布参数不同）进行组合的结果。因此，我们对雷达观测量的预测，本质上是对这种小参量组合方式的预测。这种组合方式也就是谱，由于其参数构成往往并不复杂，其变化往往简单但却细微、短暂，因此基于常规方法对其的临近预报往往难以实现。

NARX (Nonlinear Auto-Regressive model with Exogenous Inputs), 即带有外部输入的非线性自回归神经网络, 是一种被证明有效的时间序列预测技术。可以用于处理非线性离散系统的模型, 其原理可以简单概述为

$$y(t) = f \{u(t - D_u), \dots, u(t-1), u(t), y(t - D_y), \dots, y(t-1)\} \quad (25)$$

其中 u , y 分别是网络的输入输出, D_u , D_y 分别为输入输出时延的最大阶数, 通过对过去 D_u 时刻的信息不断与实时测得的雷达观测量融合, 析出未来 D_y 时刻的结果。




图 8 NARX 神经网络结构模型

正如前面讨论的, 基于降雨散射特性机理与双偏振雷达参数计算机理, 我们知道了对于本题目中 Z_H 的临近预报, 本质上是对谱参数变化的临近预报, **这些参数对时间的依赖性可能相对简单和短暂, 而 NARX 模型可以有效地捕捉这些依赖性**。在该模型中, 网络的预测精度可以通过调整模型的超参数来提高。但同样, NARX 神经网络也有着无法忽视的缺点, 如:

① 对数据中的**时间依赖关系进行建模的能力有限**, 因为它们没有能力维持内部状态, 也没有能力随着时间的推移持续提供信息。

② 可能会遇到梯度消失的问题, 即反向传播过程中的梯度变得非常小, 减缓或阻止学习过程。

为了缓解这一问题, 我们引入了 RNN 神经网络 (Recurrent neural network)。这是一种在传统的多层 BP 神经网络的基础上进行改进的神经网络模型。RNN 增加了隐藏层单元之间的横向联系, 通过一个权重矩阵将上一个时间步的神经单元的值传递给当前时间步的神经单元。这种设计**使得神经网络可以加强对时间依赖建模的能力**, 有效地处理有时间序列的机器学习问题。网络计算方法如下:

$$\begin{cases} o_t = g(Vs_t) \\ s_t = f(Ux_t + Ws_{t-1}) \end{cases} \quad (26)$$

其中, 式 1 是用于计算输出层的公式, 输出层是由全连接层组成的, 意味着每个输出层节点都与隐藏层的每个节点相连接。V 代表输出层的权重矩阵, g 表示激活函数。式 2 是用于计算隐藏层的公式, 隐藏层是由循环层组成的。U 代表输入 x 的权重矩阵, W 代表上一次的值作为当前输入的权重矩阵, f 表示激活函数。RNN 模型模型如下:




图 9 RNN 神经网络结构模型

因此，NARX-RNN 混合神经网络满足：

$$T(t) = \sum_{i=1}^l \sum_{j=1}^m w_{ij}(t) u^j(t-i) + \sum_{k=1}^n v_k(t) T(t-k) + a(t) u(t-l) T(t-1) + b(t) u(t-1) T(t-n), \quad (27)$$

在网络构建过程中，首先我们在 1.0km³ 中的 258 个 dir 中随机选取 50 个 dir，每个 dir 中随机选取连续的 20 帧作为训练样本进行数据清洗后读入，其中，样本第 1~2 帧的雷达观测量及 Z_H 作为历史样本值输入，样本第 3~10 帧的三种雷达观测量作为神经网络输入，样本其余后 10 帧的 Z_H 作为网络输出，构建神经网络结构图如下：




图 10 物理驱动的 NARX-RNN 模型

如图 10 所示为本题所使用方法的模型框图。其中，针对任务二的要求，将 η 设置为 0.001，期望误差设置为 1，最大迭代次数设置为 3000 次，系统时滞设置为 2（帧）。依照网络模型所得出的各层神经元权重大小及偏置信息矩阵，基于历史时间信息与观测量，依次向后输出待预测值，同时返回至输入端耦合进行后续预测，直至获得后 10 帧预测数据。

完成上述模型的建立及参数的设置后，为了验证求解的精准度和可靠性，从数据库中随机挑选了三组 dir 内的 10 帧，经过数据清洗后导入训练好的神经网络。随后，在其后 10 帧内随意挑选一帧进行对比展示。对比结果如下图所示。




图 11 网络预测结果

基于上述预测结果，分别从相关系数、均方根误差、相对偏置、分数均方差四个维度进行了预测精度评估。结果如下表。

表 2 图中样例预测精度评估

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)
相关系数(CC)	0.912	0.9141	0.4291
均方根误差(RMSE)	6.7233	3.1651	10.4942
相对偏置(RB)	-0.1754	-0.0871	-0.6431
分数均方差(FRMSE)	1.5761	1.6823	2.7114

其中, 样例(a)-(f)是从训练所用的 1km 数据库中获取的, (g)-(i)是从 3km 数据库中获取的。样例第 1、2、3 列分别是对应帧真实测量得到的 Z_H 数据, 通过神经网络预测得到的 Z_H 数据和 Z_H 真值与预测值之差。可以看到, 样例(a)-(f)的预测结果优异, 其预测结果与真值相关性好(>0.9), 分数均方根低(<2)。但样例(g)-(i)虽然整体预测相似, 但相比真值误差略有区别。比如相关性一般(0.4 左右), 分数均方差高(2.7 左右)。这是由于训练样本和测试样本的雷达作用距离所属不同造成的, 将在后续题目中改进。

4.4 本章小结

题目要求提取双偏振雷达资料中的微物理信息, 通过前一小时内的雷达观测量 (Z_H 、 Z_{DR} 、 K_{DP}), 实现对后续一小时 (10 帧) 的 Z_H 进行临近预报。本文考虑雷达探测的不确定性, 首先建立了基于线性拟合和 RMSE 的 LOF 异常值检测模型, 在时间帧和空间比较上分别搜寻异常点, 使得在数据读取时寻找并替换了异常值。

然后, 分析考虑了降雨雷达特性随时间变化的物理本质是雨滴散射特性在不同谱参数下的雨滴谱下以不同方式排列组合。基于这一物理本质和题目需求, 建立了 NARX-RNN 神经网络, 从 1km 数据库内 258 个 dir 库中随机抽取 50 个库内连续 20 帧的测量数据导入网络进行训练, 多次重复选择直到网络性能逐渐最优的网络。随后随机抽取任意 dir 库中的 10 帧数据作为网络输入, 观察后 10 帧网络结果。结果表明, 该网络在 1km 数据库内性能优异, 误差基本在 10% 以内, 但对于 3km 和 7km 泛化性能较低, 将在后续题目中改善。

五、问题二模型的建立、分析与求解

5.1 问题分析

问题二指出，在常规模型构建中，往往会存在“倾向回归于平均”和“模糊效应”的问题，使得模型不清晰，输入输出不完备。例如在题目一中，仅将前十帧雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ）作为网络输入，而网络输出仅有的后续一小时（10 帧）的 Z_H 值，这时的结果模糊、不完善。因此，本文理解问题二需要在问题一模型的基础上，基于附件一、二文件夹“NJU_CPOL_update2308”和“NJU_CPOL_kdpRain”，进一步挖掘数据，扩充模型输入，使网络模型输入更有条理，更有深度。同时，进一步挖掘双偏振雷达参数与参数之间，参数与降雨微物理特性之间的物理机理，使模型预报的结果在雷达回波纬度和气象微物理参数纬度两方面都更清晰，更细节。最终形成**输入挖掘-输出细化的双驱动去模糊化临近预报模型**。因此，问题二的输入挖掘-输出细化双驱动去模糊化临近预报模型流程图如下：




图 12 问题二思路流程

输入级深度挖掘：针对输入层信息，问题一中单纯将 10 帧的雷达观测量信息导入神经网络，在此时，这 10 帧内的三束信息是相互割裂的。在训练中，神经网络是依靠庞大的数据量，才能学习辨别他们之间的内在关联，这使得模型的输入单一、模糊。为了解决这一问题，本部分将深挖数据，引入梯度、峰值、雷达类型作为补充模型学习依据，是神经网络在构建更全面、立体。

输出级信息细化：针对输出层信息，问题一中仅能预测未来十帧的 Z_H 信息，这种单一信息量在雷达和临近预报领域是明显不充分的。虽然该信息一定程度上可以反应降雨信息，但这种信息是“平均的”，“模糊的”。为了进一步细化输出级信息，本文对输出级做出如下亮点改动：

其一，**雷达回波细节扩充。**基于双偏振雷达运作机理，扩充 Z_V 、 Z_{DR} 、 K_{DP} 三结果输出，形成双极化四输出完备雷达参数数据集，该数据集完整阐述了两个极化方向上的回波

数据以及他们之间的内在关系。

其二，气象微物理细节扩充。基于题目一里对降雨雷达散射特性的建模分析，在获取了双偏振雷达观测信息的前提下，对数据进一步基于物理机理剖分反演，推演出包含气象类型、降水粒子大小、含水量信息，为含水量预估提供进一步支撑。

因此，问题二的输入挖掘-输出细化双驱动去模糊化临近预报模型流程图如下：

5.2 模糊效应问题与可行性分析

5.2.1 模糊效应

模糊效应是一种心理学上的描述性的研究，也是决策研究中必要的一环。简单来说，人脑在进行决策判断和选择时，并不太擅长进行绝对判断，当一个“平均的”结果呈现在面前时，人们往往无法从中提取出有效的信息。比如说在锚定效应的研究中，在对自己完全不了解的领域进行估计时，大脑会围着轮盘上随机转出来的无意义数字打转，死活都要找一个参照点。所以比起有明确概率的选项，无明确概率的选项显得风险很大而期望收益不高。模糊效应，是一种认知偏误。决策由于缺少信息或者是模糊而受到影响。这个效应显示，对于有利的结果，人们倾向于选择概率是确定的那一个。

而在降雨临近预估中，造成思维偏误的原因是关于降雨未来信息的不足（即问题一中的神经网络只能获得雷达 Z_H 观测量），而你认为你有足够的关于降雨预报的信息（即信息量很大）（实际上并没有，因为只有单一信息）。基于充足信息做出的决策让你更有信心，但更有信心不代表这是更好的选择。比如虽然整体上某片区域我预测的同极化回波开始升高，但你并没有在意这片区域的其他参数是否发生了变化（如：非降雨因素造成的衰减、交叉极化散射回波异常等等）。该区域在未来可能也并不是可以预估大概率下雨，而是同样无法确定。

因此，对于模糊效应，通常存在几种产生原因，如下图：




图 13 降雨中模糊效应产生原因

① 数据精度限制：

在雷达降水预报中，观测数据的精度对于预报结果的准确性至关重要。然而，受限于雷达设备的分辨率、噪声干扰、仪器校准等问题，观测数据的精度存在一定的局限性。此外，降雨过程中的复杂气象条件可能会导致数据的不连续性和不稳定性，进而影响到预报结果的可靠性和真实性。

② 数据处理算法局限性：

雷达回波数据处理算法是获取降雨信息的关键步骤。然而，常用的雷达数据处理算法在面对复杂气象环境和不同类型降水（如小尺度降水、雪、冰雹等）时，可能存在着一定的局限性。例如，当前一些数据驱动算法在进行强对流预报时，倾向于生成接近于平均值的预报，即存在“回归到平均（Regression to the mean）”问题，因此预报总是趋于模糊。此外，传统的经验关系和统计模型在描述不同类型降水的特征时可能存在误差，不能完全

准确地提取降雨粒子的大小、相态和含水量等信息。

③ 大气环境复杂性：

大气环境的复杂性是导致降雨预报模糊效应的另一个重要原因。大气中的湍流、气溶胶、颗粒物和尘埃等都会对雷达波束的传播路径和散射特征产生影响，从而使得观测数据受到一定的扰动和干扰。此外，大气中存在的悬浮物质和水变形导致回波信号的复杂形态，进而造成降雨预报结果的模糊性。

5.2.2 可行性分析

为了缓解判断的模糊效应，一般有三种方法：

① 发现影响判断的模糊概率

应对任何问题的第一步都是识别问题。模糊效应的问题是人的系统造成的，基于同样的原因人会合理化你的选择，给出一个看上去非常合理的解释，回避掉你不想承认的真实原因。

② 调整评估手段

一件事件的结果及其效用有很多角度，在一个角度下因为信息缺失而算不清概率的事，在另外一种评估角度下可能就是清晰的。

③ 补足信息

为了使信息逐渐明确并缓解模糊效应，我们可以采取一些措施来补足信息并提高回答的准确性。首先，需要提供更多细节和背景信息。其次，需要基于引用可靠的来源和数据支撑对数据进行分析。在此过程中逐渐明确信息，并最终实现消除模糊效应的目标。使信息逐渐明确。

在几种措施中，第一种模糊概率影响因子复杂，难以定量评估并使用。因此，在降雨临近预报中为了缓解上述的预报的模糊效应，使预报出的雷达回波细节更充分、更真实，本题目主要采取②、③措施。

调整评估手段：在本文中，神经网络就相当于那个产生了“模糊”的大脑，为了使神经网络的评判、反演、计算更加精细、准确，本题目深度挖掘了神经网络的输入层信息，**添加了雷达种类、空间梯度、雷达强点信息三种额外信息输入**，使信息量更充分、规整。

补足信息：在本文中，为了最终实现对降雨量的临近判断，单纯只有 Z_H 是明显不够的。在第一题中我们分析过，降雨量等诸多因素共同影响了降雨的气象模型，从而进一步的影响了降雨的散射模型。因此，为了让后续对降雨临近判断的预估更加“去模糊”，本题目极大拓宽了神经网络输出层信息。首先，在雷达回波细节方面，将原本的单一雷达观测量拓宽为了**全面完备的双极化四要素雷达信息**。其次，进一步的，我们将信息拓展到了气象微物理参数层面，进一步基于物理机理推演出了**气象类型、粒子浓度、含水量三种气象微物理特征**。使得后续对降雨的临近预估更加细节、精准。

5.3 输入层扩展

5.3.1 空间梯度

梯度是一个向量，梯度表示了一个函数在某个点的变化率或斜率，体现该函数在当前位置的变化规律。因此，梯度在一定程度上反应了该函数后续的变化趋势。对于离散二维函数，其计算公式如下：

$$\begin{cases} \frac{\partial f(x,y)}{\partial x} = f(x+1,y) - f(x,y) = g_x \\ \frac{\partial f(x,y)}{\partial y} = f(x,y+1) - f(x,y) = g_y \end{cases} \quad (28)$$

在网络训练时，我们将雷达观测量以时间轴归类作为输入层数据，这可以极大地减少网络计算复杂度。但预测同时，数据的空间信息被忽略了。在双偏振雷达探测时，我们可以收集到相同时间帧不同位置处雷达参数的变化离散数据，这种参数反映了降雨的空间特性，而这种特性，基于第一问中我们对降雨物理机理的分析，会与降雨量共同影响雷达观测量。因此，我们在训练前将对所有时间帧的雷达参数在空间上的最大梯度提取下来，形成了对雷达参数在空间上的补充。将该信息作为网络输入补充能使网络判断更加精准。提取出来的最大梯度结果如下：




图 14 雷达观测量梯度提取结果

可以看到，在梯度提取图中，每个点都有着属于自己当前时间、位置的最大梯度方向。这一方向反映了雨区的分布情况。因此，将该信息作为网络输入补充能使网络判断更加清晰。

5.3.2 空间强信息点提取

在弹载雷达使用中，常常会用到目标强散射点提取。这一功能对目标进行识别分类，以确认目标类型、区分真实目标和干扰起到正向作用。同样的，在基于双偏振雷达探测降雨时，雷达强点也会对雨区判断、雨类型判断等形成正面效应。进一步帮助临近预报更细节，更清晰。

参考对弹载雷达的强散射点提取方法，我们选取 0.7 作为提取阈值，即有

$$R = \begin{cases} \text{强散射点, 若 } R_i^n \geq TH \\ \text{非强散射点, 若 } R_i^n < TH \end{cases}, 1 \leq i \leq M \quad (29)$$

因此，我们在训练前将对所有时间帧的雷达参数 Z_H 在空间上的强散射点提取下来，形成了对雷达参数在空间上的补充。将该信息作为网络输入补充能使网络判断更加精准。提取出来的雷达强散射点结果如下：




图 15 雷达观测强点提取结果

其中，图像中蓝色未知即为雷达强点。可以看到，对于同一次降雨预测，随着时间的进行，降雨强中心会发生偏移。这种偏移是降雨云在对流层系统演变和空气动力结构的影响下运动、生成、消散等的影响。而在不同次降雨，雷达强点位置也不同。因此，将该信息作为网络输入补充能使网络判断更加清晰。

5.3.3 雷达类型区分

在问题一中，我们发现，基于雷达作用距离 1.0km 训练的神经网络在雷达作用距离 3.0km 的测量结果中预估效果不好。这是由于雷达类型不同即雷达作用距离不同造成的。雷达作用距离是雷达固有参数，反映了雷达在照射过程中的探照能力。对于降雨气象雷达，有雷达方程：

$$P_r = \frac{P_t G^2 \lambda^2 \sigma}{(4\pi)^3 R^4 L_s} 10^{-0.2A} \quad (30)$$

考虑降雨可以假设为回波非相关，在有效照射体内，可以得到降雨的雷达气象方程

$$P_{rain} = \frac{P_t G^2 \lambda^2 h \theta_1 \phi_1 \eta}{512 \pi^2 R^2 L_s} 10^{-0.2A} \quad (31)$$

因此，在雷达探测过程中，通常会对雷达的作用距离进行划分。具体来说，首先是盲区，其长度由雷达分辨率和其他因素决定。在本文中，假设盲区的长度为 $l_1 = h/2$ 。在这个区间内，雷达无法接收到任何回波。

从第二段开始，将雷达的有效照射深度 $h/2$ 作为单元来划分作用距离。雷达可以接收到每个距离门的降雨回波功率。在这里，假设每个有效照射体内的雨衰减率相等，因此可以计算出目标回波功率在传播路径上的雨衰减值




图 16 雷达分辨单元模型

因此，考虑降雨衰减和天线噪声温度影响，雷达最大作用距离的计算公式为

$$R_{\max} = \left(\frac{P_t G^2 \lambda^2 \sigma}{(4\pi)^3 k(T_s + \Delta T_a) B_n (S_0/N_0)_{\min} L_s} 10^{-0.2A} \right)^{1/4} (m) \quad (32)$$

其中， T_s 是雷达系统的噪声温度。

因此，可以看到，雷达作用距离是雷达参数区别的参数化表现，不同雷达作用距离的雷达参数存在巨大区别，进一步导致同一地区、降雨量。时间帧下，雷达观测参数也显著不同。因此，为了进一步清晰化雷达参数，需要将雷达类型也作为网络输入。在制作网络输入集后，存在如下对应关系：

$$\begin{cases} 1.0\text{km雷达}, C_s = 1 \\ 3.0\text{km雷达}, C_s = 3 \\ 7.0\text{km雷达}, C_s = 7 \end{cases} \quad (33)$$

在训练时，基于读取数据库的 km 类型，给对应的数据集打上相应的标签。进一步帮助临近预报更细节，更清晰。

5.4 输出层扩展

5.4.1 雷达细节优化：双极化四输出完备雷达参数数据集

除了输入层清晰化外，为了更好地对降雨量进行预测，还需要对输出层进行扩展。在第一问中，网络的输出是 Z_H 参数，这使得雷达信息只包含了一个极化方向的回波赋值信息，对于同极化相位、交叉极化幅值、交叉极化相位都存在缺失。

因此，在这部分，我们对输出的雷达参数数据集做了填补。基于问题一中公式(20)-(24)，我们探讨并知道了双偏振雷达在两种极化方向上的雷达观测信息（包含幅值相位）四种数据的相互关系：

$$\begin{cases} Z_H = 10 \log(\hat{S}_{HH}), Z_V = 10 \log(\hat{S}_{VV}) \\ Z_{DR} = Z_H - Z_V \\ K_{DP} = \frac{1}{2} \frac{d\Phi_{DP}}{dr} \approx \frac{\Phi_{DP}(r_2) - \Phi_{DP}(r_1)}{2(r_2 - r_1)} \\ \begin{cases} R_a = \langle HH_i VV_i^* \rangle = \frac{2}{M} \sum_{i=1}^{M/2} HH_i^* VV_i \\ R_b = \langle VV_{i+1} HH_{i+1}^* \rangle = \frac{2}{M} \sum_{i=1}^{M/2} VV_i^* HH_{i+1} \end{cases} \\ \Psi_{DP} = \frac{1}{2} \arg(R_a R_b^*) + \Phi_s \\ \Phi_{DP} = \Psi_{DP} - \delta_{HV} \end{cases} \quad (34)$$

基于上述关系和已有物理机理研究结果，我们可以对网络进行优化，使其在出输出层生成双极化四输出完备雷达参数数据集，该数据集包含双偏振雷达在两个极化方向上的几乎所有信息。其中包含：

- (1) 同极化散射回波强度（同极化回波幅值信息）；
- (2) 交叉极化散射回波数据（交叉极化回波幅值信息）；
- (3) 差分反射率因子（两极化回波幅度关系）；
- (4) 比差分传播相移（两极化回波相位关系）

随机选取一 dir 的一帧结果，可以看到优化神经网络生成的双极化四输出完备雷达参数如下图：




图 17 优化后的雷达参数数据预测

5.4.2 气象细节优化：气象微物理参数数据集

除了输入层清晰化外，为了更好地对降雨量进行预测，还需要对输出层进行扩展。同时，除了对雷达参数进行扩展外，还可以对气象微物理参数进行扩展。在第一问中，我们系统的分析了降雨气象模型对双偏振雷达观测量的影响。因此，本文也可以利用 Z_H 、 Z_{DR} 和 K_{DP} 等双偏振雷达特征参数反响推演降雨目标粒子的尺寸、相态和形状等气象信息，这有助于推演降雨。

(1) 气象类型

研究表明，不同气象类型的降水粒子的偏振特性不同。基于李海等基于美国国家海洋和大气管理局（National Oceanic and Atmospheric Administration, NOAA）的 NEXRAD 数据库中 KTLX 双偏振雷达所获取的多组实测偏振参量数据研究表明，并利用这些数据构建了包括冰晶、干雪、湿雪、雨、暴雨、大雨滴、霰、雨夹雹等 8 种降水粒子的偏振参量数据库。计算结果如图 18。

基于前文研究，我们知道气象的散射特性本质是粒子散射特性基于气象谱进行组合，因此，基于气象粒子的雷达观测量集合气象物理机理，可以进一步得到降雨区分方法。在 NOAA 降水数据中提供了三种雨降水类型的识别结果，分别是雨、暴雨和大雨滴。

根据图中(a)，可以观察到暴雨粒子的 Z_H 值明显大于雨和大雨滴，达到了 47dBZ。而雨粒子和大雨滴粒子的 Z_H 值相近，约为 23-26dBZ。根据上一节对的介绍，可以得出结论：暴雨的粒子尺寸和浓度都较大，因此 Z_H 值较大；雨粒子尺寸较小、浓度较高，大雨滴粒子尺寸大于雨粒子但浓度较小，因此二者 Z_H 值相近。

根据图中(b)，暴雨粒子和大雨滴粒子的 Z_{DR} 值大于雨粒子。这是因为雨粒子尺寸较小，

形状更接近球形，使得在水平和垂直偏振方向上的反射率因子取值相近，因此 Z_{DR} 值更接近于 0；而暴雨和大雨滴粒子尺寸较大，受空气阻力影响，其形状变为椭球型，因此 Z_{DR} 值较大。因此，本文基于如下判据进行：

$$\begin{cases} Z_H > 8 \\ Z_{DR} < 0.1 \end{cases}, \text{认为是降雨} \quad (35)$$

其他，认为可能不是降雨




图 18 不同气象粒子雷达观测量数据统计

(2) 含水量

雷达照射体积内水凝物粒子的物理特性与其后向散射能力有密切的联系，在 Rayleigh 散射的条件下，雷达观测的反射率因子与雨滴直径的六次方成正比相关^[13]。在用雷达观测降雨时 Rayleigh 散射的假设在某些频段上不再成立。所以通常用等效反射率因子 Z_e 表示，单位是 mm^6m^3 ，由于 Z_e 变化范围很大，往往跨越几个数量级，为了应用方便，通常用 dBZ 来表示反射率因子的大小，即：

$$\text{dBZ} = 10 \lg \frac{Z_e}{Z_0} \quad (Z_0 = 1 \text{mm}^6 \text{m}^{-3}) \quad (36)$$

液态含水量 LWC 和 Z_e 的关系为幂指数关系，即：

$$\text{LWC} = a Z_e^b \quad (37)$$

常见的经验公式如表所示。

表 3 DBZ 回波分类法经验公式

回波强度 Z 分类	反演方法	经验关系
$Z < -17\text{dBZ}$	$\text{LWC} = 4.564Z_e^{0.5}$	Atlas
$-17\text{dBZ} \leq Z < 5\text{dBZ}$	$\text{LWC} = 0.457Z_e^{0.19}$	Baedi
$Z \geq 5\text{dBZ}$	$\text{LWC} = 0.02584Z_e^{0.633}$	Krasnov

(3) 雨滴粒子平均直径反演:

不同高度上的雷达反射率因子值在天气雷达实际观测会给出, 将在不同高度上观测的反射率因子的数值记为 $Z(h_i)(i=1,2,3\cdots I)$, $\hat{Z}(h_i)(i=1,2,3\cdots I)$ 是其计算的相应的模拟值。如果这两个数据相同, 则表明观测值和模拟值是相同的。但是在现实观测中由于各种外界影响因素和粒子的形状、种类等理论模型中的不确定性, 会使得这两个数据存在差异, 差异越小越好, 在每个高度上同理^[14], 即

$$Q_2 = \sum_{i=1}^I \left(\hat{Z}(h_i) - Z(h_i) \right)^2 = \min \quad (38)$$


求解出满足这个关系式的各种粒子的平均直径反演值, 在式(33)中令 Q_2 对平均直径求导并令导数为零, 则有

$$\frac{\partial Q_2}{\partial D_{0j}} = 2 \sum_{i=1}^I \left(\hat{Z}(h_i) - Z(h_i) \right) \frac{\partial \hat{Z}(h_i)}{\partial D_{0j}} = 0 \quad (39)$$

上式为最小二乘法的基本公式, 在计算时, 需要先设置各粒子的平均直径初值, 在每次迭代计算后, 将会得到各种粒子的平均直径反演值。

(4) 气象微物理参数反演展示

基于前文对雷达观测量反演气象类型、降雨含水量、降雨粒子尺寸等气象微物理参数的机理研究, 分别选取 1.0km、3.0km、7.0km 下的\Dir_041\frame_14 数据, 进行气象微物理参数反演。反演结果如下图







图 19 优化后的气象微物理参数预测

可以看到，基于上述物理机理，实现了对降雨气象模型微物理参数反演。

5.4.3 网络性能对比

在完成了对网络输入层和输出层分别的优化后，为了对比比较与第一问中网络的参数性能，按一定规律选取了下列数据进行展示比对：选取了同一 `dir`，同一 `frame` 目标的 DBZ 结果，将 1.0km，3.0km，7.0km 分别带入训练好的神经网络，对比预测值与真值，对比结果如下图

DBZ:






图 20 优化后的神经网络 DBZ 预报效果展示


计算性能参数，结果如下表：

表 4 DBZ 样例预测精度评估

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)
相关系数(CC)	0.8630	0.8980	0.8087
均方根误差(RMSE)	2.9394	2.9827	2.6645
相对偏置(RB)	0.0864	-0.0463	-0.1021
分数均方差(FRMSE)	0.8294	0.6558	0.6905

相比于第一问内的结果，优化神经网络预报的 Z_H 与真值吻合程度基本一致且均有较高水平，说明此时网络针对雷达类型的泛化能力问题已经得到解决。此外，对图中样例进行性能指标分析，可见参数处于较小水平，说明该神经网络模型的预估能力足够优异。

KDP:






图 21 优化后的神经网络 KDP 预报效果展示


为了进一步计算四性能参数，计算结果如下表：

表 5 KDP 样例预测精度评估

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)
相关系数(CC)	0.9144	0.9730	0.9081
均方根误差(RMSE)	0.1255	0.3082	0.1110
相对偏置(RB)	-0.7870	-0.8904	-0.5833
分数均方差(FRMSE)	5.6284	4.8765	3.5123

相比于第一问内的结果，优化神经网络预报的 K_{DP} 与真值吻合程度基本一致且均有较高水平，说明此时网络针对雷达类型的泛化能力问题已经得到解决。对图中样例性能指标分析，可以看到所有参数均处于较小水平，这说明该神经网络模型的预估能力足够优异。

ZDR:






图 22 优化后的神经网络 ZDR 预报效果展示

为了进一步量化网络预报效果，参考第一问同样计算了网络预测结果的性能参数相关系数(CC)、均方根误差(RMSE)、相对偏置(RB)和分数均方差(FRMSE)，计算结果如下表：

表 6 ZDR 样例预测精度评估

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)
相关系数(CC)	0.9901	0.9974	0.9833
均方根误差(RMSE)	0.0537	0.0913	0.0953
相对偏置(RB)	-0.0375	-0.0893	-0.0.143
分数均方差(FRMSE)	-0.0427	-0.0508	-0.0945

可以看到，相比于第一问内的结果，优化后的神经网络基于三种雷达类型回波结果预报的 Z_{DR} 与真值吻合程度基本一致且均有较高水平，说明此时网络针对雷达类型的泛化能力问题已经得到解决。此外，根据对图中样例的预测精度进行性能指标分析，可以看到所有参数均处于较小水平，这说明该神经网络模型的预估能力足够优异。

为了进一步体现网络提升程度用该网络再次拟合第一问结果，做出下表。

表 7 相较第一问样例预测精度提升

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)
相关系数(CC)	05.37%	01.76%	46.94%
均方根误差(RMSE)	56.28%	05.70%	74.60%
相对偏置(RB)	50.74%	46.84%	84.12%
分数均方差(FRMSE)	30.54%	03.88%	59.65%

本表中主要统计相比于第一问可以看到，相比于第一问结果，优化后的神经网络性能

提升比例。其中相对偏置基于绝对值进行计算。可以看到，相比较于第一问，样例(a)-(f)参数都存在一定的提升。而样例(g)-(i)的网络性能参数存在显著提升。这说明相比较第一问，该网络存在两点进步：

① 网络预测能力得到提升

② 网络泛化能力大幅度提升

而显然的，这一进步也说明了随着网络输入输出的清晰、扩展，网络的性能也会随之提升。

5.5 本章小结

题目要求优化第一问中建立的模型，通过降低“模糊效应”，提高雷达回波细节，使其更充分，更充实。本文在调研了什么事“模糊效应”以及模糊效应的缓解方法后，选择了**输入-输出双层拓展的 NARX-RNN 模型**。

首先，我们在扩展细化了输入层数据，加入了**空间变化参量空间梯度、气象变化参量雷达强点、雷达变化参量雷达类型**，进一步扩充了神经网络输入层细节，使得神经网络学习训练更清晰、充分、全面。

然后，我们扩展补充了输出层数据，从**雷达细节参数优化和气象微物理参数补充**两个方面进行。在雷达参数方面，我们最终形成了双极化四输出完备双雷达数据集，包含双偏振雷达两个极化方向上幅值相位信息。在气象参数补充方面，我们充分的调研了雷达参数在反演气象微物理参数的物理机理，并基于机理生成了包含气象类型、降水粒子尺寸、含水量的气象微物理参数集。结果表明，该网络可以实现对未来雷达参数数据和气象微物理参数数据的临近预报。并且，由于输入层的优化，该网络生成的已知雷达参数相比于测量真值更加精确可信，以分数均方差为例，样例性能提升 3%-59%不等。

六、问题三模型的建立、分析与求解

6.1 问题分析

问题三需要基于附件一、二文件夹“NJU_CPOL_update2308”中下属包含的“DBZ”“ZDR”两组次级文件和“NJU_CPOL_kdpRain”文件，建立可进行定量降水估计模型。实现基于的雷达观测量（ Z_H 、 Z_{DR} ；不可使用 K_{DP} ），对后降水量进行定量估计。在第二问中，我们已经探讨明白，只用 Z_H 、 Z_{DR} 进行降雨量预测会产生“模糊效应”，因此还需要对模型进行扩展。因此，本文理解首先基于物理机理研究，利用自研的复杂背景环境散射特性仿真软件，生成不同降雨量下的气象散射特性，并进一步形成不同降雨量下的 Z_H 、 Z_{DR} 仿真数据集。然后，将生成的仿真数据集与题目提供的测量数据集，在第二问和仿真软件的基础上，聚焦 Z_H 、 Z_{DR} 对气象微物理参数的影响，最终建立**基于测算融合的 BP 神经网络降水量反演模型**。

仿真数据生成：基于降雨气象模型和降雨散射特性模型，利用自研的复杂背景环境散射特性仿真软件，仿真生成不同降雨量下的气象散射特性，形成不同降雨量下的 Z_H 、 Z_{DR} 仿真数据集，为后续测算融合提供数据基础。

测算融合 BP 神经网络：基于仿真获取的不同降雨量下的 Z_H 、 Z_{DR} 仿真数据集，融合题目附件提供的降雨实测数据，形成 Z_H 、 Z_{DR} 测算融合数据集。然后在第二问和仿真软件对物理机理的探讨基础上，聚焦 Z_H 、 Z_{DR} 对气象微物理参数的影响，进一步**构建 BP 神经网络**，实现基于雷达观测量（ Z_H 、 Z_{DR} ）的降雨量分析模型。

因此，问题三的基于测算融合的 BP 神经网络降水量反演模型流程图如下：




图 23 问题三思路流程

6.2 仿真数据生成

6.2.1 降雨气象参数

基于自研的复杂环境背景散射特性仿真软件，通过控制降雨各种微物理气象参数，可

以实时生成不同参数控制的降雨气象模型，从而进一步生成降雨散射模型。软件操作主界面如下图：




图 24 软件界面展示

在生成降雨气象模型时，存在如下控制参数：

(1) 降雨类型：

- 毛毛雨：很小的雨，特点为雨滴小，降雨量低；
- 广布雨：最常见，广泛分布、涉及区域广的降雨；
- 雷暴雨：带有强烈雷暴的降雨；

对于三种降雨，基于问题一中对降雨微物理参数的研究与讨论，其主要区别在于雨滴尺寸分布的谱型存在差异，基于 Joss 等人研究结果^[15]，这三种降雨类型对应雨滴谱为：

$$\begin{cases} \text{毛毛雨：} N(D)=3\times10^4 e^{-5.7R-0.21D} \\ \text{广布雨：} N(D)=7\times10^3 e^{-4.1R-0.21D} \\ \text{雷暴雨：} N(D)=1.4\times10^3 e^{-3.0R-0.21D} \end{cases} \tag{40}$$

(2) 降雨大小：

降雨大小基于降雨率进行设置，降雨率即指水平面的降水通量，单位常使用 mm/h，降雨率越大代表当前单位时间单位面积内下降的雨水量越高。以中央气象局发布数据为标准，对降雨量可以进行分类：

表 8 降雨分布指标

类型	降雨量
小雨	$0.1 < R < 2.5 \text{ mm/h}$
中雨	$2.6 < R < 8.0 \text{ mm/h}$
大雨	$8.0 < R < 16 \text{ mm/h}$
暴雨	$R > 16 \text{ mm/h}$

(3) 降雨地区:

东部近海作战环境: 类似温带季风气候环境;

南部近海作战环境: 类似热带气候环境;

中部平原作战环境: 类似温带沙漠/草原内陆气候;

对于三种作战环境, 基于问题一中讨论, 对于不同地区, 由于地理条件差异, 降雨率与其雨滴尺寸分布的映照关系存在不同, 基于赵振维等人研究结果, 这三种地区对应映照关系为


$$D_{\max} = \begin{cases} 2.1919R^{0.1994+0.02733\lg R} \\ 1.8642R^{0.3472-0.02374\lg R} \\ 1.5560R^{0.2490+0.03334\lg R} \end{cases} \quad (41)$$

(4) 降雨尺度: 降雨分布的空间尺度, 单位为 m。


(5) 气象随机种子: 控制降雨粒子随机生成, 为一列随机数字。

6.2.2 降雨气象建模


基于自研的复杂环境背景散射特性仿真软件, 通过输入不同的气象参数, 基于问题一中探讨的降雨气象模型机理, 可以实时生成不同参数控制的降雨气象模型。分别在不同地区、降雨率下建立了降雨, 同时也建立了一些等条件下其他气象模型如下图




(a) 温带, 降雨率 1mm/h




(b) 温带, 降雨率 10mm/h




(c) 温带, 降雨率 20mm/h




(d) 温带, 降雨率 10mm/h



(e) 热带, 降雨率 10mm/h



(f) 内陆, 降雨率 10mm/h



(g) 辐射雾，能见度 0.1km (h) 层云，含水量 0.28 g/m³ (g) 积雨云，能见度 2.5 g/m³

图 25 气象模型生成

观察同一地域，不同降雨量下的降雨模型，可以看到随着降雨量的提升，空间中降雨的粒子密度、含水量产生了明显变化，随着降雨量的升高，降雨粒子密度与降雨含水量也显著提高。进一步的，观察同一降雨量，不同地域的降雨模型，可以看到降雨粒子密度存在变化，但并不剧烈，相反的，降雨的粒子形状出现了较大的区别。**这一结果都与第一问中我们对降雨气象粒子与环境、降雨量等参数的物理机理分析一致。**同时，对比雾、云等气象模型，可以看到相比之于降雨，不同的气象的模型存在明显差异，这也是他们在双极雷达中观测结果不同的本质原因所在。

6.2.3 降雨散射特性建模

基于自研软件，通过输入不同的气象参数，可以实时生成不同参数控制的降雨气象模型。进一步的，基于问题一、二中探讨降雨气象模型电磁散射物理机理，可以进一步获取不同降雨量下的降雨散射特性，从而最终获得降雨的理论雷达观测模型，实现降雨雷达观测数据构建。在所有降雨散射特性中，最能反应降雨对雷达接受参数影响的散射特性分别是降雨衰减与降雨后向散射。我们生成了不同条件下的降雨衰减与后向散射特性：




图 26 降雨散射特性生成

6.2.4 降雨雷达特性建模

基于建立的降雨气象模型、降雨散射特性模型，基于雷达参数，可以进一步仿真计算获取降雨雷达观测量数据。基于第一、二问研究结果，我们可以获得雷达观测量的计算方法¹⁶：

① 水平反射率因子 Z_H ：

$$\begin{cases} Z_H = \frac{\lambda^4}{\pi^5 |K_w|^2} \int \sigma_p(D) N_p(D) dD \\ Z_H = 10 \log(\hat{S}_{HH}), Z_V = 10 \log(\hat{S}_{VV}) \end{cases} \quad (42)$$


② 水平反射率因子 Z_{DR} ：

$$Z_{DR} = Z_H - Z_V \quad (43)$$


其中：

$$\begin{cases} \hat{S}_{HH} = \frac{2}{W} \sum_{i=1}^{W/2} |HH_i|^2 - N_{HH} \\ \hat{S}_{VV} = \frac{2}{W} \sum_{i=1}^{W/2} |VV_i|^2 - N_{VV} \end{cases} \quad (44)$$


因此，基于软件建模结果和上述雷达参量计算机理，建立不同降雨量下的雷达观测量仿真数据集。为了展示这一数据集，我们分别在 1km、3km、7km 下，任意分别在仿真数据集与测试数据集中抽取绘制雷达观测量(Z_H 、 Z_{DR})随降雨量的变化曲线。




(a) 1km DBZ




(b) 1km ZDR




(c) 3km DBZ



(d) 3km ZDR



(e) 7km DBZ



(f) 7km ZDR

图 27 降雨雷达参数生成

可以看到，无论在 1km, 3km 还是 7km 上，仿真生成的降雨雷达参数与实验测量参数趋势均趋于一致。但仿真数据明显变化震荡更小，这是由于虽然仿真数据基于多参数共同控制，虽然这使得在同一降雨量下数据可能出现震荡，但影响因素有限，相比于实测数据中大量的位置变量影响更小。这使得仿真数据和实验数据虽然趋势一致，但震荡范围更小，这也说明仿真数据更聚焦于物理机理影响。

6.3 测算融合 BP 神经网络

6.3.1 测算融合数据集

在第二问中，我们已经探讨明白，只用 Z_H 、 Z_{DR} 进行降雨量预测会产生“模糊效应”，使得对降雨量的预估出现不清晰、不准确的问题。因此，不能简单基于 Z_H 、 Z_{DR} ，还需要对模型进行扩展。

在 6.2 中，我们获得了降雨气象的雷达观测量随降雨量变化的仿真数据库。该数据库反映了降雨粒子构成-气象表征-散射特性-雷达参数的完整物理机理链路，内含了双偏振雷达在探测降雨气象时的本质物理关系。因此，通过将仿真计算数据库与题目附件的雷达实测数据库进行融合重构，形成测算融合降雨-雷达观测量数据集，可以更好地在模型中体现他们之间的深层物理联系。测算融合数据集构建流程如图：




图 28 测算融合数据集建立流程图

6.3.2 基于测算融合数据集的 BP 神经网络预估模型建立

BP 神经网络模型是利用 BP 算法进行计算处理的具有多层神经元结构的神经网络模型，通常由输入层、中间层和输出层三层网络结构组成。其训练学习过程由正向传播计算输出和反向传播修改权值两部分组成。正向传播计算网络输出时，信息经过神经网络正向传递，从输入层经过隐含层的处理后传递到输出层，当前神经元的所处的状态只能改变与其连接的下一层神经元的状态。当输出层的输出值与期望值误差没有达到期望值时，网络就会转入误差反向传播过程，误差信号沿各神经元连接原路返回，并根据 BP 算法的权值修正公式逐一修改每一层神经元的连接权值，这样不断重复修改权值，当最终的神经网络输出与期望输出的误差信号达到允许的范围时结束训练^[17]。

(1) 具体算法流程如下




图 29 BP 算法流程图

● 隐含层的设置

BP 神经网络预测的精准的关键隐含层的个数以及所包含的神经元数量，要根据需解决的问题类型合理的设置神经元的数量。对于本问题来说，样本值总数为 871431 个，经过反复的调参调试，同时兼顾精度和计算速度，将隐含层数设置为 1 层，所包含的神经元个数为 30 个。

● 输入层的设置

对于输入层来说，将 1km/3km/7km 的 Z_H 、 Z_{DR} 六中雷达观测量信息和基于 Z_H 、 Z_{DR} 获取的三种气象微物理参数信息作为系统的输入，因此将输入层设置为 1 个，所包含的神经元设置为 11 个。

● 输出层的设置

本问题中，通过 Z_H 、 Z_{DR} 来估计当前降雨量，因此输出层设置为 1 层，所包含的神经元个数为 1 个。

根据上述描述，针对问题三搭建的 BP 神经网络结构如图 30 所示：




图 30 BP 神经网络结构示意图

(2) 模型求解过程如下：

首先，从附件中随机抽取不同 km、不同 dir 的 100 组数据，将每个 dir 中存在降雨量沿时间帧变化的数据对应三种雷达类型下的降雨量、雷达观测量的对应提取出来，进一步基于雷达观测量获取气象微物理参数，并基于 6.3.1 方法基于同一位置，完成测算融合数据集构建。对每一个对应的数据集进行随机编号作为训练样本 $\mathbf{M} = [\mathbf{M}_1, \mathbf{M}_2, \mathbf{M}_3, \mathbf{M}_4]$ ，其中， $\mathbf{M}_i = [m_1, m_2, m_3, \dots, m_k]$ ($i = 1, 2, 3, 4$) ($k = 1, 2, 3, \dots, k_{\max}$)，代表不同时间、地点雷达观测量、气象微物理参数与降雨量的对应关系， i 表示数据集对应雷达类型编号， $k_{\max}$ 为某一类型降雨量最大维度。最终降雨量矩阵 $\mathbf{M}$ 乱序处理后代入到 Sigmoid 激活函数中，得到隐含层第 j 个节点的输出值，可用公式表示为：

$$f(x) = \frac{1}{1 + \exp[-(x + \theta_1) / \theta_0]} \quad (45)$$

$$r_j = f\left(\sum_{j=1}^n w_{ij} k_j + \theta_j\right) \quad (46)$$

其中， θ_j 为隐含层第 j 节点阈值， k_j 为第 k 个隐含层第 j 个节点， w_{ij} 为输入层第 i 个节点和隐含层第 j 个节点所对应的权值。

在此基础上，基于输出层第 k 个神经元，可以得到输出 α_k 为：

$$\alpha_k = f\left(\sum_{k=1}^p \omega_{kj} r_i + b_k\right) \quad (47)$$

其中， b_k 是输出层节点 k 的降雨量预测值。

一般来说，系统的输出的降雨量 b_k 与实际真实降雨量 t_k 是存在差异的，因此我们进一步的引入了误差函数来对神经网络进行误差矫正，过程如式(48)所示：

$$E = \frac{1}{2} \sum_{k=1}^p (t_k - b_k)^2 \quad (48)$$

其中，基于 Delta 学习规则， ω_{kj} 的修正量设置为

$$\Delta \omega_{kj} = -\eta \frac{\partial E}{\partial \omega_{kj}} \quad (49)$$

其中， η 为学习速率。针对问题三的要求， η 设置为 **0.002**，期望误差设置为 **1.1**，最大迭代次数设置为 **5000** 次。

(3) 预测模型准确性检验

完成上述模型的建立及参数的设置后，为了验证求解的精准度，对附件提供的不同时间不同网格位置下的雷达观测数据，预估此时对应的降雨量数据，然后结合 rain 文件夹中实际的降雨量对比。对比结果如下图所示。




图 31 降雨量估计模型评估

为了进一步量化网络预报效果，参考第一问同样计算了网络预测结果的性能参数相关

系数(CC)、均方根误差(RMSE)、相对偏置(RB)和分数均方差(FRMSE)，计算结果如下表：

表 9 降雨量预测精度评估

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)
相关系数(CC)	0.8317	0.8830	0.8492
均方根误差(RMSE)	1.0849	0.4020	0.4633
相对偏置(RB)	0.8739	0.0833	0.9350
分数均方差(FRMSE)	1.4245	1.7244	1.9571

可以看到，测算融合后的神经网络基于两种雷达观测量的结果预报的降雨量与真值吻合程度基本一致且均有较高水平，分数均方差均小于 2，相关系数则均大于 0.8。这说明该神经网络模型的预估能力可以接受。但明显的，该模型还可以进行进一步优化，优化过程将在第四问中进行。

6.4 本章小结

题目要求利用题目提供的 Z_H 、 Z_{DR} 和降水量数据，设计适当的数学模型，利用 Z_H 及 Z_{DR} 进行定量降水估计。设计模型输入为 Z_H 和 Z_{DR} ，输出为降水量，且不可使用 K_{DP} 变量。本文在考虑输入输出信息不足问题，基于自研软件，完成了对降雨的气象、散射、雷达参数模型建模，通过仿真计算结合题目附件实测数据获取了降雨量-雷达参数测算融合数据库，并在此基础上建立了 BP 神经网络模型，完成了对降雨量的预估。

结果表明，仿真数据更好地展现了雷达探测降雨气象的物理机理，并且可以很好地贴合实测数据。其次，基于测算融合数据集扩充后，BP 神经网络模型性能优异，分数均方差均小于 2，相关系数则均大于 0.8。但明显的，该模型还可以进行进一步优化，优化过程将在第四问中进行。

七、问题四模型的建立、分析与求解

7.1 问题分析

问题四需要设计一种数学模型，使得可以对双偏振雷达参数在强对流降水预报中的贡献进行定量表述和比较。然后，基于这一种评价方式，优化模型数据的融合策略，实现模型对“突发性降雨类型”和“地域信息”降雨的泛化能力提升。因此，本文首先分别在考虑单偏振信息（仅 Z_H ）和考虑双偏振信息（ Z_H 、 Z_{DR} 和 K_{DP} ）的条件下，融合 2、3 问的网络模型，分别对未来时间降雨量进行临近预报。然后，基于熵权-TOPSIS 方法，对相关系数(CC)、均方根误差(RMSE)、相对偏置(RB)和分数均方差(FRMSE)四种网络系数进行权重赋值，得到对预报结果的评估模型，评估双偏振雷达在强对流临近降雨预报中的贡献。最后，基于仿真数据和随机森林，建立突发性降雨分类模型，对附件数据库进行分类标签。然后，在神经网络中输入层加入考虑不同位置、降雨突发与否参数，实现对突发性和局地性强的强对流天气的预估。

评估模型建立与双偏振雷达贡献度评估：分别在考虑单偏振信息（仅 Z_H 、仅 Z_{DR} 和仅 K_{DP} ）和考虑双偏振信息（ Z_H 、 Z_{DR} 和 K_{DP} ）的条件下，融合 2、3 问的网络模型，实现多模融合，建立基准模型。然后，分别导入单偏振/双偏振雷达信息，对未来时间降雨量进行临近预报。利用熵权-TOPSIS 方法，对相关网络的相关系数(CC)、均方根误差(RMSE)、相对偏置(RB)和分数均方差(FRMSE)四种网络系数进行权重赋值，实现对模型预估性能的评估。然后通过前面建立的评估模型，评估双偏振雷达在强对流临近降雨预报中的贡献。

优化数据融合的高泛化性网络模型：基于仿真数据库和随机森林分类模型，建立突发性降雨分类模型，对附件数据库进行分类标签。然后，在神经网络中输入层加入考虑不同位置、降雨突发与否，实现对突发性和局地性强的强对流天气的预估。

因此，问题四的评估模型建立与双偏振雷达贡献度和评估优化数据融合的高泛化性网络模型流程图如下：




图 32 问题四模型建立网络流程图

7.2 评估模型建立与双偏振雷达贡献度评估

7.2.1 考虑单双偏振雷达信息的 NARX-RNN-BP 联合神经网络

为了评判双偏振雷达在临近预估中的贡献度，首先需要建立基准模型，分别考虑双偏振雷达的临近预估和单偏振雷达观测数据，导入基准的临近预估模型。在前三问中，我们基于物理机理实现了通过前面一小时（10 帧）的雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ），基于 NARX-RNN 模型对后续一小时（10 帧）的 Z_H 进行预报。并且，可以基于的雷达观测量（ Z_H 、 Z_{DR} ；不可使用 K_{DP} ），基于测算融合 BP 神经网络对降水量进行定量估计。

因此，在本问中，基于第二问中对降雨微物理参数的推演结果作为桥梁，我们对两种神经网络完成多模型融合，形成了 NARX-RNN-BP 融合神经网络，实现了基于前时间的雷达观测量，临近预报后时间的降雨量数据。链接第 2、3 问模型，将输入层分别设置为只考虑单偏振信息（仅 Z_H 、仅 Z_{DR} 和仅 K_{DP} ）和考虑双偏振信息（ Z_H 、 Z_{DR} 和 K_{DP} ）都考虑共四种情况，建立 NARX-RNN-BP 联合神经网络。接着，计算网络的四性能参数：相关系数 (CC)、均方根误差 (RMSE)、相对偏置 (RB) 和分数均方差 (FRMSE)。随后，根据这些性能参数，基于熵权-TOPSIS 方法构建网络评价模型。

因此，本文建立的 NARX-RNN-BP 联合神经网络示意图如下图：





图 33 NARX-RNN-BP 多模型融合神经网络

基于该构建方法，分别基于单偏振信息（仅 Z_H 、仅 Z_{DR} 和仅 K_{DP} ）和考虑双偏振信息（ Z_H 、 Z_{DR} 和 K_{DP} ）对未来降雨实现预估，随机挑选 dir005 的第 41 帧进行预估，结果如下：






图 34 单、双偏振雷达降雨量预测展示

为了进一步定量分析模型预测性能，计算模型精度性能参数如下表

表 10 降雨量预测精度评估

	样例(b)	样例(c)	样例(d)	样例(e)	样例(f)
相关系数(CC)	0.9987	0.5534	0.5121	0.9152	0.4577
均方根误差(RMSE)	0.3334	8.3988	19.1887	0.5662	14.1923
相对偏置(RB)	-0.0451	1.3361	4.8075	-0.0955	3.2816
分数均方差(FRMSE)	0.2046	5.1521	12.1065	0.3473	8.7061

7.2.2 神经网络反演四性能参数

神经网络反演四性能参数包括、相对配置（RB）、均方误差（RMSE）、相关系数（CC）和分数均方差（FRMSE）。

相对配置（RB）是一种用于评估预测模型预测误差相对于平均偏差的标准化指标。通过它预测模型在平均水平上的偏差和预测误差的相对程度。RB 则更加注重模型的平均偏差，评估模型在平均水平上的预测误差，理解模型的整体偏差。具体计算公式如下^[18]：

$$RB = \frac{\sum_{i=1}^N (R_{QPE} - R_{guage})}{\sum_{i=1}^N R_{guage}} \quad (50)$$

均方误差（RMSE）是一种广泛应用的描述预测模型误差的指标。它衡量了预测值与真实值之间的均方差，通过平方和的方式对预测误差进行了加权。通过对预测误差进行平方和的加权，更注重较大误差的惩罚，因此能够较好地衡量模型的整体拟合程度。具体计算公式如下：

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (R_{guage} - R_{QPE})^2}{N}} \quad (51)$$

相关系数（CC）是一种用于衡量两个变量之间线性关系强度的指标。它只关注于两个变量之间的线性关系，可以在-1 到 1 之间取值，越接近 1 表示正相关性越强，越接近-1 表示负相关性越强，接近 0 表示两个变量之间的关系较弱。CC 作为一种度量线性关系的指标，有助于评价模型对于线性相关性的拟合状况。然而，CC 只适用于线性关系的衡量，当变量之间存在非线性关系时，CC 可能无法准确地评估预测模型的拟合程度。具体计算公式如下：

$$CC = \frac{\text{Cov}(R_{guage}, R_{QPE})}{\sigma(R_{guage})\sigma(R_{QPE})} \quad (52)$$

均方差（FRMSE）是一种较为全面的指标，考虑了因变量的变异程度，对于数据集中存在较大离群值或数据分布不均匀的情况下，能更准确地反映模型的预测能力。它衡量了预测值与真实值之间的均方误差，并考虑到了因变量的变异程度。具体计算方法如下：

$$FRMSE = \frac{RMSE}{\bar{R}_{guage}} \quad (53)$$

在上述 4 个性能参数的公式中， R_{guage} 是雨量站的观测值， $\bar{R}_{guage}$ 是 R_{guage} 对应 $0.1^\circ \times 0.1^\circ$ 的网格点的空间上的平均值大小。 R_{QPE} 是估测的降雨率。（RB）表示 QPE 估测值相对于观测值的误差程度，当 RB 大于 0 时，表示 QPE 高估降雨率；当 RB 小于 0 时，表示 QPE 低估降雨率。相关系数（CC）反映了 QPE 估测值和实际观测值之间的关联度，关联度越高表示估测效果越好。均方误差（RMSE）度量了观测值与 QPE 估测值之间的差距，RMSE 越大表示 QPE 估测的效果越差。相对偏置分数均方差（FRSME）是一种无量纲的统计量，是 RMSE 与观测值均值的比值，可以更好地评估估测误差，特别适用于不同量级的降水事件。

7.2.3 基于熵权-TOPSIS 方法的评估模型建立

熵权值是一种客观而非主观的赋权方法，它能够基于决策矩阵直接计算出权重。其依据的原理是指标的变异程度越小，所反映出的信息量也越少，其对应权值也应该更低，也即是说熵值表示指标数据的离散程度，熵值越小，离散程度越大。

TOPSIS 称为优劣解距离法，是一种常用的综合评价方法，主要通过比较某一评价对象与所有评价对象中的最优解和最劣解的距离来进行排序。

在上一步中，我们获得了网络 4 性能参数，这些参数从多个维度反映了网络拟合结果在各个方面的优秀或问题程度。基于这些数据，我们可以对四种网络结果进行熵权-TOPSIS 模型评估，具体步骤如下：

Step 1: 参数设定及决策矩阵确定。

设 $x = \{x_1, \dots, x_n\}$ 分别为需要进行优先级分级的三种神经网络，指标及对应的权重向量为 $\omega = \{\omega_1, \dots, \omega_n\}$ 。将所有指标数据转换为符合指标越大优先级越高这一要求的数据，保证其同向性。在将获得的决策矩阵进行标准化得到最终的决策矩阵 A。

Step 2: 指标权重确定

在决策矩阵 A 中，假设为第 i 个需求点关于第 j 个指标的贡献度：

$$p_{ij} = \frac{b_{ij}}{\sum_{i=1}^n b_{ij}} \quad (54)$$

用 p_{ij} 计算第 j 个指标的熵 E_j ，其中， $K=1/\ln n$ ，保证 $0 \leq E_j \leq 1$ ：

$$E_j = -K \sum_{i=1}^n p_{ij} \ln p_{ij}, j=1, 2, \dots, m \quad (55)$$

熵权重 $\omega = \{\omega_1, \dots, \omega_6\}$ 中， ω_j 表示第 j 个指标的权重：

$$\omega_j = \frac{1-E_j}{m - \sum_{j=1}^m E_j}, j=1,2,\dots,m \quad (56)$$

Step3: 优先级确定。

对标准化决策矩阵 A，将其乘以对应权重 ω 得到加权后的规范决策矩阵 D:

$$D = \begin{bmatrix} D_{11} & D_{12} & \dots & D_{1m} \\ D_{21} & D_{22} & \dots & D_{2m} \\ \vdots & \ddots & & \vdots \\ D_{n1} & D_{n2} & \dots & D_{nm} \end{bmatrix} \quad (57)$$

计算正理想解 D^+ 和负理想解 D^- :

$$D^+ = \{D_1^+, D_2^+, \dots, D_m^+\}, D_j^+ = \max D_{ij}, i=1,2,\dots,n, j=1,2,\dots,m \quad (58)$$

$$D^- = \{D_1^-, D_2^-, \dots, D_m^-\}, D_j^- = \min D_{ij}, i=1,2,\dots,n, j=1,2,\dots,m \quad (59)$$

计算各评价对象与最优值和最劣值之间的距离:

$$d_i^+ = \sqrt{\sum_{j=1}^m (D_{ij} - D_j^+)^2} \quad (60)$$

$$d_i^- = \sqrt{\sum_{j=1}^m (D_{ij} - D_j^-)^2} \quad (61)$$

计算各评价对象与最优表现值的相对接近度:

$$c_i = \frac{d_i^+}{d_i^+ + d_i^-} \quad (62)$$

c_i 即为各个神经网络性能优异程度, c_i 越大, 优先级越高。基于表 10 五网络四特性参数, 建立熵权-TOPSIS 评估模型, 评估模型中间结果如下:

正向化矩阵:

$$X = \begin{bmatrix} 0.9987 & 18.8553 & 4.8526 & 11.9019 \\ 0.5534 & 10.7899 & 3.4714 & 6.9544 \\ 0.5121 & 0 & 0 & 0 \\ 0.9152 & 18.6225 & 4.9030 & 11.7592 \\ 0.4577 & 4.9964 & 1.5259 & 3.4004 \end{bmatrix} \quad (63)$$

标准化矩阵 Z:

$$Z = \begin{bmatrix} 0.6178 & 0.6491 & 0.6164 & 0.6456 \\ 0.3424 & 0.3715 & 0.4410 & 0.3772 \\ 0.3168 & 0 & 0 & 0 \\ 0.5662 & 0.6411 & 0.6229 & 0.6379 \\ 0.2831 & 0.1720 & 0.1938 & 0.1845 \end{bmatrix} \quad (64)$$

最后得分如下表:

表 11 降雨量预测精度评估

	相对得分	排名
样例(b)	0.3520	1
样例(c)	0.2040	3
样例(d)	0.0101	5
样例(e)	0.3382	2
样例(f)	0.0957	4

根据评估结果，可以看到网络预测精度排名分别是：双偏振全输入网络、KDP 输入网络、DBZ+ZDR 混合输入网络、ZDR 输入网络、DBZ 输入网络。在问题一的研究中已知，双偏振雷达三种雷达观测量中，仅有 DBZ 是单极化信息，ZDR 和 KDP 分别代表了两种极化方向上信息的幅度差和相位比。因此，可以看到，从单极化信息到双极化全信息的过程中，预测精度逐步提高。分别以全参数网络和以仅 DBZ 网络评分为基准，双偏振雷达参数预报贡献可以计算为：

表 12 双偏振雷达临近预报贡献

雷达参数	贡献度
DBZ	02.86%
ZDR	27.18%
+ZDR	55.06%
KDP	57.95%
+KDP	72.82%
+全参数	97.13%

表中，不含加号项代表只含有该雷达信息时的评分相对占比。含加号项代表在加入该双偏振参数后，评分模型评分提升比例。可以看到，双偏振雷达对降雨预估的贡献很大。添加双极化观测量可以提升网络性能，使网络评分上升 55.06%-97.13%不等。

7.3 优化融合的高泛用性网络构建

在前三问中，我们基于物理机理实现了通过前面一小时（10 帧）的雷达观测量（ Z_H 、 Z_{DR} 、 K_{DP} ），基于 NARX-RNN 模型对后续一小时（10 帧）的 Z_H 进行预报。并且，可以基于的雷达观测量（ Z_H 、 Z_{DR} ；不可使用 K_{DP} ），基于测算融合 BP 神经网络对降水量进行定量估计。在 7.2 节中，我们对两种神经网络完成多模型融合，形成了 NARX-RNN-BP 融合神经网络，实现了基于前时间的雷达观测量，临近预报后时间的降雨量数据。然而，在实际使用中，根据物理机理我们可以知道，根据降雨存在局地性、突发性的不同，降雨模型规律存在差异，网络的泛用性能不一定适用，导致无法很好地应对突发性和局地性强。

7.3.1 基于随机森林的突发性判断模型

为了解决网络应对突发性的泛化能力问题，在第三问产生的仿真数据库基础上，基于随机森林模型建立数据分类模型。将附件数据划分为“可能为突发性降雨”和“基本不可能为突发性降雨”两种，实现对网络的突发性泛化性能优化。

(1) 模型构建

随机森林（Random Forest，简称 RF）是一种基于统计学理论模型的机器学习算法，它被广泛应用于解决大规模分类和回归问题，并具有高精度的预测能力。随机森林不仅能够有效地处理大量数据，还自带特征筛选机制，可以评估每个特征对于问题的重要性。此外，随机森林对于异常数据和噪声具有较好的适应性，并且不容易出现过拟合的情况。其由多个决策树模型构成，每个决策树模型都对样本进行分类，最终根据所有决策树的分类结果进行投票来获得最佳输出^[19]。

不同决策树贡献不同的影响力，其贡献度大小可以通过平均袋外数据误差进行体现。通过这种集成学习的方式，随机森林能够更准确地进行预测，其贡献度大小用平均袋外数据误差体现：

$$OobErrorT_i^j = |e_1 - e_2| \quad (65)$$

样本数据平均误差可用下式求得：

$$MOET^j = \frac{\sum_{i=1}^T OobErrorT_i^j}{T} \quad (66)$$

其中， $MOET^j$ 为特征 j 的平均袋外数据误差，随机森林模型中的决策树的数量大小用 T 表示， i 是随机森林模型中决策树的编号。到此，可以进行判断。如果波动使测试误差改变的幅度比较小，说明这个特征值不是很重要。相反，如果特征值很重要，其值的浮动会对测量的结果会造成较大的影响。

另外，随机森林模型的特征权值反映了各个特征值的重要程度占比，表达式为：

$$weight = \frac{MOET^j}{\sum_{k=1}^D MOET^k} \quad (67)$$

其中， $weight_j$ 是特征值 j 的权重， D 是特征总数。在得到所有特征值的特征权值后，按照权重大小顺序排序可以得到特征权值集合 $WeightSet$ ，用公式表述为：

$$WeightSet = [weight_1, weight_2, weight_3, \dots, weight_D] \quad (68)$$

(2) 性能指标

随机森林分类模型的性能指标主要通过混淆矩阵来衡量。混淆矩阵根据样本的真实类别和预测类别将分类结果划分为真正类（TP）、假正类（FN）、真反类（TN）和假反类（FP），并以矩阵形式展示，如下图所示。

真实类	负类0	TP	FN
	正类1	FP	TN
		负类0	正类1
		预测类	

图 35 混淆矩阵示意图

从测试数据得到的混淆矩阵中我们可以计算出测试样本的分类准确率 AC 为：

$$AC = \frac{TP + TN}{TP + FN + FP + TN} \quad (69)$$

分类查全率为 R ：

$$R = \frac{TP}{TP + FN} \quad (70)$$

分类查准率为 P ：

$$P = \frac{TP}{TP + FP} \quad (71)$$

$F1$ 分数：

$$F1 = \frac{2TP}{2TP + FP + FN} \quad (72)$$

$F1$ 分数则反映了查全率 R 和查准率 P 的调和平均数，通常使用 $F1$ 分数来评估测试数据的分类效果，值越接近 1 表示模型的分类能力越好。

(3) 随机森林训练

步骤一：利用问题三的仿真模型，基于突发性指标(降雨率时间梯度、降雨空间坐标等)生成突发性降雨和非突发性降雨数据集，将 N 个数据集采用 **bootstrap**（有放回抽样）随机抽取 k 个新值形成自主样本集，用于构建相同数量的分类树。每次未被抽中的数据样本构成 k 个袋外数据。

步骤二：假设特征空间中有 D 个数量的特征，每轮在已生成的决策树基础上，随机抽取其中一部分由 d 个特征值组成新的特征集，其中特征个数小于等于总特征个数。使用新特征集合生成新的决策树，在多轮操作中生成 k 个相互独立的决策树个数。

步骤三：将生成的 k 个决策树组合形成随机森林，需要注意的是决策树之间是独立的，因此决策树的重要性相同。

上述三个步骤的随机森林分类流程可用流程图表示：




图 36 随机森林算法流程图

构建好模型后，重新生成、挑选新的仿真数据带入训练好的随机森林模型，该模型性能指标如下：




图 37 随机森林混淆矩阵示意图

可以看出，本问构建的随机森林分类模型对不同情况的分类结果精度几乎达到了**100%**，同时 **TPR**（假正类率）和 **FNR**（伪正类率）百分比占比差值几乎达到 **100%**。这说明该随机森林模型性能优异。

基于该网络，随机对附件中的实测数据库进行预测分类，概率结果示例如所示：

表 13 随机森林分类结果示例

编号	0(概率 %)	1(概率 %)	预测结果
Dir007	23.33%	76.67%	1(无突发)
Dir027	63.33%	36.67%	0(有突发)
Dir047	53.33%	46.67%	0(有突发)
Dir067	86.67%	13.33%	0(有突发)
Dir087	60.00%	40.00%	0(有突发)
Dir107	10.00%	90.00%	1(无突发)
Dir127	3.33%	96.67%	1(无突发)
Dir147	100%	0.00%	0(有突发)
Dir167	93.33%	6.67%	0(有突发)
Dir187	40.00%	60.00%	1(无突发)

因此，本文基于该模型对所有训练的数据进行分类判定，形成带有突发性标签的降雨量实测数据集。

7.3.2 基于雷达强点提取和聚类算法的局地性判断模型

在前一小节中，我们实现了对 NARX-RNN-BP 融合神经网络的突发性泛化研究。因此，在本小节中，我们主要聚焦于解决网络的局地性泛化问题。

在第二问中，我们在扩展输出层是完成了对雷达强散射点的提取。对于降雨气候而言，这些强点表征了降雨在正面空间区域内的内在分布规律，是降雨“局地性”的体现。因此，本文基于第二问中的强点提取工作，进一步完成对降雨局地性的 K-Means 聚类算法，实现对降雨数据集的局地性信息提取。

K-Means 聚类算法是一种常用的无监督学习算法，用于将数据集划分为不同的类别，使得同一类别内的数据点更加相似，不同类别之间的数据点差异较大。该模型基于距离度量的思想，通过迭代优化的方式，将数据点划分到 k 个类别中，使得每个数据点与所属类别的聚类中心距离最小。

K-Means 聚类计算步骤如图所示，算法原理为：

- 1.初始化：随机选择 K 个数据点作为聚类中心。
- 2.分配数据点：对于每个数据点，计算其与各个聚类中心的距离，将其分配到距离最近的聚类中心所属的类别。
- 3.更新聚类中心：对每个类别，计算其所有数据点的平均值，更新聚类中心为这些平均值。
- 4.重复步骤 2 和步骤 3，直到达到收敛条件（例如，聚类中心不再发生变化或达到最大迭代次数）。




图. K-Means 聚类计算步骤

K-Means 聚类计算要点：

1. 选择合适的 K 值，即要聚类的类别数，该值需要根据具体问题和数据集进行调整和分析。K 值的选取可以用拍脑袋法，具体的公式为：

$$K \approx \sqrt{n/2} \quad (73)$$

其中，n 代表样本数量。当 K 的值较小时，一般使用手肘法则，具体公式为：

$$D_k = \sum_{i=1}^K \sum dist(x, c_i)^2 \quad (74)$$

2. 选择合适的距离度量方法，在 K-Means 算法中一般采用欧式距离，即：

$$L_2(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}} \quad (75)$$

K-Means 聚类评估：


K-Means 聚类通常使用簇内平方误差（SSE）评价类别内部数据点的紧密程度，即

$$SSE(k) = \sum_{p \in X} distance(p, centroid)^2 \quad (76)$$


其中 p 表示簇中的点，X 是簇内点的集合，distance(p, centroid) 是点 p 到簇质心的距离。各个簇的 SSE 的和就是聚类结果的 SSE，其值越大则表示聚类的质量越不好。

K-Means 聚类模型也有其一些局限性，如对初始聚类中心的敏感性、需要事先确定聚类个数 k、容易受到噪声和异常值的影响等。因此，在应用 K-Means 聚类模型时需要结合实际问题 and 数据集进行综合分析和调整参数，以获得更好的聚类结果。


基于上述理论，随机分别选取同一 dir 下不同时间帧结果和不同 dir 下降雨数据进行雷达强点提取与 K-Means 聚类分析，聚类数目取 1-7，结果如下图：




(a) Dir_005_001




(b) Dir_005_001




(c) Dir_005_041



(d) Dir_005_041



(e) Dir_016_041



(f) Dir_016_041


图 38 降雨强点 K-Means 聚类结果

其中，图像下方灰色图像是第二问中提取的降雨雷达强点数据，图像上方彩点则是雷达强点们的三位体现，纵轴大小反应此点此时的雷达参数强度。不同颜色的彩点代表着不同的 K-Means 分区。可以看到，对于 dir005，随着时间帧向前，降雨分区基本保持不变，但在 dir016 中，降雨局地性则出现显著不同。

7.3.3 考虑局地性和突发性的降雨临近预测多模融合神经网络模型

在前两小节中，我们分别基于仿真数据构建的随机森林分类模型和联合雷达强点提取和 K-Means 聚类模型实现了对降雨及其雷达数据的局地性和突发性参数标签构建。因此，本文在 7.2 节中 NARX-RNN-BP 多模融合神经网络的基准上，在模型输入层添加局地性（位于那一雨区，雨区强点中心）和突发性（是否存在突发雨 0/1）参数，扩充网络输出层，实现对考虑局地性和突发性的降雨临近预测多模神经网络模型建立。

基于该模型，我们选取了一组随着时间变化，存在明显局地性与突发性的 dir 数据进行预测展示：






图 39 优化后的雷达参数数据预测

数据包含第 30dir 第 4、19、27、37 帧的实测降雨值、网络预估降雨值和两者差。可以看到，选取的 dir 包含以下局地性与突发性：

- (1) 开始降雨呈现典型的局地性特征，大体可分为右上方强降雨区和右下方常规降雨区域。
- (2) 第二行图时间上，两个降雨区域开始向不同方面变化，右上角降雨开始逐渐减少至消散，右下方降雨则逐渐向左上方平移
- (3) 第三行时间上，出现强对流下的突发性降雨，右上和右下雨区全部消失，形成了新的中心强降雨区
- (4) 第四行时间上，中心强降雨区在迅速生成后又迅速消失。

而在这过程中，模型预测结果与实测结果趋于一致，说明此时模型针对局地性与突发性泛化能力优异。为了进一步证明这一点，计算网络四性能参数：

表 14 降雨量预测精度评估

	样例(a)-(c)	样例(d)-(f)	样例(g)-(i)	样例(j)-(l)
相关系数(CC)	0.9907	0.9913	0.9851	0.9893
均方根误差(RMSE)	2.6019	0.7628	0.7687	0.2149
相对偏置(RB)	0.3490	0.0760	0.1252	0.0804
分数均方差(FRMSE)	1.1805	0.7448	0.8912	1.1634
评估模型分数	0.4902	0.3897	0.3936	0.4441

可以看到，模型预估相似度极高（ $CC > 98\%$ ），误差极低（ $FRMSE < 1.2$ ），综合性能优异（全面超过 7.2.3 节中网络 10.71% 到 39.26% 不等），进一步佐证模型针对局地性与突发性泛化能力优异。

7.4 本章小结

本章首先分别在考虑单偏振信息（仅 Z_H ）和考虑双偏振信息（ Z_H 、 Z_{DR} 和 K_{DP} ）的条件下，融合第二问和第三问的网络模型，分别对未来时间降雨量进行临近预报。然后，基于熵权-TOPSIS 方法，对相关系数(CC)、均方根误差(RMSE)、相对偏置(RB)和分数均方差(FRMSE)四种网络系数进行权重赋值，得到对预报结果的评估模型，评估双偏振雷达在强对流临近降雨预报中的贡献。最后，基于仿真数据和随机森林，建立突发性降雨分类模型，对附件数据库进行分类标签。然后，在神经网络中输入层加入考虑不同位置、降雨突发与

否参数，实现对突发性和局地性强的强对流天气的预估。

结果表明，**双偏振雷达对降雨预估的贡献很大**。添加双极化观测量可以提升网络性能，使网络评分上升 55.06%-97.13%不等。优化融合的高泛用性网络构建模型预估相似度极高（ $CC > 98\%$ ），误差极低（ $FRMSE < 1.2$ ），综合性能优异（全面超过 7.2.3 节中网络 10.71% 到 39.26% 不等），进一步佐证模型针对局地性与突发性泛化能力优异。

八、模型的评价

8.1 模型的优点

(1) 基于线性拟合和 RMSE 的 LOF 异常值检测模型，在时间帧和空间比较上分别搜寻异常点，基于 LOF 方法对空间位置下的 RMSE 进行异常值分析筛除，最终获得清洗后的“可信”数据集。

(2) 输入挖掘-输出细化的双驱动去模糊化临近预报模型，进一步挖掘数据，扩充模型输入，使网络模型输入更有条理，更有深度。同时，进一步挖掘双偏振雷达参数与参数之间，参数与降雨微物理特性之间的物理机理，使模型预报的结果在雷达回波纬度和气象微物理参数纬度两方面都更清晰，更细节。

(3) 基于测算融合的 BP 神经网络降水量反演模型，基于降雨气象模型和降雨散射特性模型，利用自研的复杂背景环境散射特性仿真软件，仿真生成不同降雨量下的气象散射特性，形成不同降雨量下的 Z_H 、 Z_{DR} 仿真数据集，为测算融合提供了数据基础。

(4) 评估模型建立与双偏振雷达贡献度评估中，通过优化数据融合的高泛化性网络模型，在神经网络中输入层加入考虑不同位置、降雨突发与否，实现对突发性和局地性强的强对流天气的预估。

8.2 模型的缺点

在建模的过程中，对问题进行了一定的条件简化，建模模型可能无法完全捕捉到所有的系统变量和相互关系，导致预测的准确性受到一定限制，在实际的应用中具有一定的局限性。

8.3 模型的推广

将降雨预测模型与其他应用和系统整合，提供实时、准确的降雨预测信息，以支持决策和规划。例如，将降雨预测与水资源管理、灾害预警系统或农业生产等领域进行集成，以实现有效的资源调度和灾害管理。

参考文献

- [1] 魏庆,胡志群,刘黎平. 双偏振雷达差分传播相移的五种滤波方法对比分析[J]. 成都信息工程学院学报,2014,29(6):596-602.
- [2] 郑永光, 张小玲, 周庆亮, 端义宏, 谌芸, & 何立富. (2010). 强对流天气短时临近预报业务技术进展与挑战. 气象, 36(7), 33-42.
- [3] Chen G, Zhao K, Zhang G, et al. Improving polarimetric C-band radar rainfall estimation with two-dimensional video disdrometer observations in Eastern China[J]. Journal of Hydrometeorology, 2017, 18(5): 1375-1391.
- [4] Pan, X., Lu, Y., Zhao, K., Huang, H., Wang, M., & Chen, H. (2021). Improving Nowcasting of Convective Development by Incorporating Polarimetric Radar Variables Into a Deep-Learning Model[J]. Geophysical Research Letters, 48(21), e2021GL095302.
- [5] Zhang, Y., Long, M., Chen, K., Xing, L., Jin, R., Jordan, M. I., & Wang, J. (2023). Skilful nowcasting of extreme precipitation with NowcastNet[J]. Nature, 619, 526–532.
- [6] Kumjian M R. Principles and Applications of Dual-Polarization Weather Radar. Part I: Description of the Polarimetric Radar Variables[J]. Journal of Operational Meteorology, 2013, 1.
- [7] 刘陈帅,张阿思,陈生. 基于 S 波段双极化雷达的变分法的定量降水估计算法[J]. 热带气象学报,2022,38(3):422-432.
- [8] Zhao K, Huang H, Wang M, et al. Recent progress in dual-polarization radar research and applications in China[J]. Advances in Atmospheric Sciences, 2019, 36: 961-974.
- [9] 张鹏,刘西川,周则明,等. 基于实测雨滴谱数据的微波链路和天气雷达降水估计关系研究[J]. 气象,2021,47(7):843-853.
- [10] 任嘉伟. 小样本下的双偏振雷达降水粒子分类研究[D]. 天津:中国民航大学,2019.
- [11] Ravuri, S., Lenc, K., Willson, M., Kangin, D., Lam, R., Mirowski, P., ... & Mohamed, S. (2021). Skilful precipitation nowcasting using deep generative models of radar[J]. Nature, 597, 672-677.
- [12] 郑佳锋,张杰,朱克云,等. 双偏振天气雷达测雨误差及水凝物识别分析[J]. 气象科技,2014,42(3):364-372.
- [13] 周嘉健. 利用天气雷达反射率因子反演降水性层状云中粒子平均直径的研究[D]. 江苏:南京信息工程大学,2017.
- [14] 郭立新, 弓树宏, 吴振森, 等. 对流层传播与散射及其对无线电系统的影响[M]. 西安电子科技大学出版社, 2018.
- [15] 卢昌胜. 微波毫米波雨衰减预测模型研究[D]. 西安电子科技大学,2018.
- [16] 李宏伟,杨国为,王晓艳. 基于改进遗传算法的 BP 网络在降雨量预测中的应用[J]. 青岛大学学报(工程技术版),2010,25(1):10-14.
- [17] 欧阳可赛,黄中华,于俊朋. 基于随机森林的雷达目标多维特征检测方法[J]. 现代雷达,2022,44(7):38-42.

附录

1 自研仿真软件计算代码（QT）

```
1. void boxingtu::on_calculate_clicked(){
2.     tmpvctor_up.clear();
3.     tmpvctor_down.clear();
4.     dnow.clear();
5.     rcs_d.clear();
6.     power_d.clear();
7.     double G1 = Gmax; // 设置 G1 的值为 Gmax
8.     phi0 = 0.; // 设置 phi0 的初始值为 0
9.     int jihua = beam_jihua; // 设置 jihua 的值为 beam_jihua
10.    ui->progressBar->setVisible(true); // 设置进度条可见
11.    ui->label_4->setVisible(true); // 设置 label_4 可见
12.    ui->progressBar->setRange(0,jmax1 * 1.2); // 设置进度条范围
13.    ui->progressBar->setWindowModality(Qt::WindowModal); // 设置进度条模态窗口
14.    ui->progressBar->setValue(jmax1 * 0.1); // 设置进度条的初始值
15.    // 开始计算
16.    if(ywy_class==1){
17.        if(cloud_class==1||cloud_class==2){
18.            iCloud_RCS(f0, pt, G1, beam, pw, 30.); // 根据条件调用 iCloud_RCS 函数
19.            ui->progressBar->setValue(jmax1 * 0.2); // 更新进度条的值
20.        }else{
21.            wCloud_RCS(f0,pt,G1 ,beam,pw,30.); // 根据条件调用 wCloud_RCS 函数
22.            ui->progressBar->setValue(jmax1 * 0.2); // 更新进度条的值
23.        }
24.    }else if(ywy_class==2){
25.        fog_RCS(f0,pt, G1 ,beam,pw,30.); // 根据条件调用 fog_RCS 函数
26.        ui->progressBar->setValue(jmax1 * 0.2); // 更新进度条的值
27.    }else{
28.        Rain_RCS(f0,pt,G1 ,beam,pw,jihua,30.); // 根据条件调用 Rain_RCS 函数
29.        ui->progressBar->setValue(jmax1 * 0.2); // 更新进度条的值
30.    }
31.    dmax.clear(); // 清空 dmax
32.    distancemax = 0; // 将 distancemax 的值设为 0
33.    int jmax = jmax1; // 将 jmax 的值设为 jmax1
34.    double j_delt = 1./ quick_f; // 将 j_delt 的值设为 1/quick_f
```

```

35.     jmax1 << endl; // 输出 jmax1 的值并换行
36.     missile m1 = tmpm; // 将 m1 的值设为 tmpm
37.     double Tt = 0; // 将 Tt 的值设为 0
38.     double dmax_ls = 0; // 将 dmax_ls 的值设为 0
39.     ofstream rcsd; // 创建一个 ofstream 对象 rcsd
40.     rcsd.open("rcsd.txt", ios::trunc); // 打开 rcsd.txt 文件, 使用 trunc 模式
41.     ofstream powerd; // 创建一个 ofstream 对象 powerd
42.     powerd.open("powerd.txt", ios::trunc); // 打开 powerd.txt 文件, 使用 trunc 模式
43.     m1.cor = { m1.cor.x + Tt * m1.v.x, m1.cor.y + Tt * m1.v.y, m1.cor.z + Tt * m1.v.z };
// 更新 m1 的 cor 的值
44.     if (ywy_class == 1){
45.         cali = 1./3. * pi * pow((30. * sin(beam * pi/180.)),2) * 30. * cos(beam * pi/180.)
* pow(fsxs,3); // 根据条件计算 cali 的值
46.     }
47.     else{
48.         cali = 1./3. * pi * pow((30. * sin(beam * pi/180.)),2) * 30. * cos(beam * pi/180.)
* pow(fsxs,3); // 根据条件计算 cali 的值
49.     }
50. }
51.
52. for (int i = ceil(output_vector[rows - 1][0] / timestep); i < int(pulse_time / timestep);
i++) {
53.     tmpvctor_down.push_back({Tt + j * j_delt + timestep * (i + 1),0.0}); // 将时间和
0.0 加入 tmpvctor_down 向量中
54. }
55. dmax.push_back(dmax_ls); // 将 dmax_ls 加入 dmax 向量中
56. srand(rand()); // 设置随机数种子
57. double u1 = (rand() % 100) * 0.01; // 生成 0 到 1 之间的随机数
58. double x_ave = 0.05 * u1 + 1 - 0.05; // 生成均匀分布的粒子
59. x_ave = x_ave * kkk; // 将粒子与 kkk 相乘
60. rcs_d.push_back(10 * log10(ans1.rcs * x_ave)); // 将 ans1.rcs 和 x_ave 相乘, 然后取对
数并乘以 10, 再加入 rcs_d 向量中
61. power_d.push_back(ans1.p * x_ave); // 将 ans1.p 和 x_ave 相乘, 再加入 power_d 向量中
62. dnow.push_back(sqrt(move_x * move_x + move_y * move_y + move_z * move_z)); // 计算
move_x、move_y 和 move_z 的平方和的平方根, 再加入 dnow 向量中
63. rcsd << sqrt(move_x * move_x + move_y * move_y + move_z * move_z) << " " << (10 *
log10(ans1.rcs * x_ave)) << endl; // 将 dnow 和 rcs_d 的最后一个元素输出到 rcsd 文件中

```

```

64.   powerd << sqrt(move_x * move_x + move_y * move_y + move_z * move_z) << " " << ans1.p*
x_ave << endl; // 将 dnow 和 power_d 的最后一个元素输出到 powerd 文件中
65.   if (distancemax < sqrt(move_x * move_x + move_y * move_y + move_z * move_z)){
66.       distancemax = sqrt(move_x * move_x + move_y * move_y + move_z * move_z); // 如
果 distancemax 小于平方和的平方根，将其更新为平方和的平方根
67.   }
68.   double rcsnow = 10 * log10(ans1.rcs * x_ave), pnow = ans1.p * x_ave; // 计算 rcsnow
和 pnow
69.   if (n == 0){
70.       rcsmax = rcsnow; // 如果 n 等于 0，将 rcsmax 更新为 rcsnow
71.       rcsmin = rcsnow; // 如果 n 等于 0，将 rcsmin 更新为 rcsnow
72.       pmax = pnow; // 如果 n 等于 0，将 pmax 更新为 pnow
73.       pmin = pnow; // 如果 n 等于 0，将 pmin 更新为 pnow
74.   }
75.   else{
76.       if(rcsmax < rcsnow){
77.           rcsmax = rcsnow; // 如果 rcsmax 小于 rcsnow，将其更新为 rcsnow
78.       }
79.       if(pmax < pnow){
80.           pmax = pnow; // 如果 pmax 小于 pnow，将其更新为 pnow
81.       }
82.       if(rcsmin > rcsnow){
83.           rcsmin = rcsnow; // 如果 rcsmin 大于 rcsnow，将其更新为 rcsnow
84.       }
85.       if(pmin > pnow){
86.           pmin = pnow; // 如果 pmin 大于 pnow，将其更新为 pnow
87.       }

```

2 自研仿真软件建模代码（QT）

```

1.   void mkconebackground(vector<vector<double>>& yuandwusanweizuobiao) {
2.       srand(zz); // 设置随机数种子
3.       double totdsize = maxcd; // 总大小
4.       double length = pow(totsize, 3); // 总体积
5.       rnum = RAND_MAX; // 随机数最大值
6.       double aaa;
7.       int h = 1;
8.       double conemax = abs(tmpm.v.x);
9.       if (abs(tmpm.v.y) > conemax) {

```

```

10.         conemax = abs(tmpm.v.y);
11.     }
12.     if (abs(tmpm.v.z) > conemax) {
13.         conemax = abs(tmpm.v.z);
14.     }
15.     double vcone[3] = { tmpm.v.x / conemax, tmpm.v.y / conemax, tmpm.v.z /
conemax }; // 轴线向量
16.     double theta = beam * pi / 180.;
17.     double pc0[3] = { vcone[0] + pos0_x,vcone[1] + pos0_y ,vcone[2] +
pos0_z };//
18.     ofstream coneshow;
19.     coneshow.open("coneshow.txt", ios::trunc);
20.     double kbei;
21.     if (ywy_class == 3) {
22.         kbei = 5000. / (10 * log10(rain1.R * 100 + 1));
23.     }
24.     else if (ywy_class == 2) {
25.         kbei = (100. * log10(fog1.V * 1000 + 1));
26.     }
27.     else {
28.         kbei = 10.;
29.     }
30.     for (int i = 0; i < ceil((length * 0.2e6 / kbei) / (maxcd * maxcd * maxcd));
i++) { // 循环空间粒子总数次
31.         aaa = rand();
32.         double x = (aaa / rnum) * totsize;
33.         aaa = rand();
34.         double y = (aaa / rnum) * totsize;
35.         aaa = rand();
36.         double z = (aaa / rnum) * totsize;
37.         double pc1[3] = { x,y,z };
38.         coneshow << x << " " << y << " " << z << endl;
39.         yuandwusanweizuobiao.push_back({ x,y,z });
40.         if (ywy_class == 3) {
41.             for (int iii = 1; iii < 50; iii++) {
42.                 yuandwusanweizuobiao.push_back({ x,y + 0.05 * iii,z });
43.                 coneshow << x << " " << y + 0.05 * iii << " " << z << endl;
44.             }

```



```

45.     }
46. }
47.     cali = h * kbei;
48.     coneshow.close();
49.     cout << "moxjianli _ ed" << endl;
50.     rangexmax = totdsize; rangeymax = totdsize; rangezmax = totdsize;
51.     rangexmin = 0; rangeymin = 0; rangezmin = 0;
52. }

```

3 微物理参数获取程序 (C++)

```

1.     std::vector<double> ZH; // 用于存储 ZH 数据的向量
2.     std::vector<double> ZDR; // 用于存储 ZDR 数据的向量
3.     std::vector<int> particle_type(256*256); // 用于存储粒子类型的向量
4.     std::vector<double> particle_p(256*256); // 用于存储降水强度的向量
5.     std::vector<double> water_content(256*256); // 用于存储含水量的向量
6.     // 假设已经将 ZH 和 ZDR 数据填充到 ZH 和 ZDR 向量中
7.     // 根据经验关系或阈值判断降水粒子类型和形状
8.     for (int i = 0; i < ZH.size(); i++) {
9.         if (ZH[i] > 8 && ZDR[i] > 0.16) {
10.             particle_type[i] = 1; // 根据 ZH 和 ZDR 阈值判断为雨滴
11.         } else {
12.             particle_type[i] = 0; // 其他情况下可以进行进一步分类或标记
13.         }
14.     }
15.     // 根据 ZH 参数估算降水强度
16.     for (int i = 0; i < ZH.size(); i++) {
17.         particle_p[i] = pow(10, 0.1 * ZH[i]); // 假设粒子大小与 ZH 指数关联,降水强度
18.     } // (mm/h)
19.     // 根据 KDP 参数估算降水粒子的含水量
20.     for (int i = 0; i < ZH.size(); i++) {
21.         water_content[i] = 0.05 * KDP[i]; // 假设含水量与 KDP 线性关联, 0.05 为常数 (示
22.     } // 例数值)
23.     // 将结果重新整形为 256x256 的矩阵
24.     std::vector<std::vector<int>> particle_type_2d(256, std::vector<int>(256));
25.     std::vector<std::vector<double>> particle_p_2d(256, std::vector<double>(256));

```

```
26.     std::vector<std::vector<double>> water_content_2d(256,  
std::vector<double>(256));  
27.     for (int i = 0; i < 256; i++) {  
28.         for (int j = 0; j < 256; j++) {  
29.             particle_type_2d[i][j] = particle_type[i * 256 + j];  
30.             particle_p_2d[i][j] = sqrt(particle_p[i * 256 + j]);  
31.             water_content_2d[i][j] = water_content[i * 256 + j];  
32.         }  
33.     }  
34.     return 0;
```