



中国研究生创新实践系列大赛
“华为杯”第二十届中国研究生
数学建模竞赛

学 校 兰州大学

参赛队号 23107300013

1.何婷婷

队员姓名 2.于浩洋

3.朱新彧

中国研究生创新实践系列大赛

“华为杯”第二十届中国研究生

数学建模竞赛

题 目： 基于双偏振订正 NowcastNet 的短临降水估测研究

摘 要:

为了有效应用双偏振雷达信息对强对流降水做出更准确的短临预报,本文构建了 NowcastNet 架构模型作为强对流降水预报的主体,并将其短临预报效果与其他模型作对比,为气象部门做好强对流天气的防御工作提供科学的理论支持和模型参考.

针对提取强对流临近预报双偏振雷达资料中的微物理特征问题,首先使用模糊逻辑算法去除非气象回波,再引入双偏振变量,以纠正信号损失对降水分布和雨量预测造成的影响;接着通过 NowcastNet、ConvLSTM、PredRNN 及 PredRNN-v2 四种模型对降水雷达回波图进行逐步预报;发现 NowcastNet 模型中的演化网络模块能够有效提取出强对流临近预报双偏振雷达资料中的物理信息,且该模型的 CSI 值相较于其他三种模型最高,预测效果最好,说明该模型能够基本模拟强对流极端降水的细节演变情况及物理效应运动形态;最后,将经模糊逻辑去噪与双偏振订正的雷达回波信号输入 NowcastNet 网络架构中,发现加入双偏振变量之后,雷达回波细节更完善,变化幅度更清晰,且去除了一定的气象杂波,说明订正后再进行模型处理能够避免预测结构受到无关变量的影响,经处理后所得到的反射率 Z_H 结果更加科学准确.

针对强对流预报中雷达回波细节存在模糊效应的问题,本文基于 NowcastNet 模型对强对流极端降水进行预测分析.首先构建中尺度演变网络,模拟平流运动等降水过程,接着根据物质连续性方程设置新的可微分神经演变算子,端到端模拟极端降水过程的演变和分布,最后基于反向传播最小化预报累积误差训练网络;发现 NowcastNet 模型生成的雷达回波图细节更客观全面,不仅能够在极大程度上缓解预报的模糊效应,还可以基本模拟降雨强度和落雨区位置的变化,复刻对流导致雨势变化的过程.

针对强对流降水的定量估测问题,本文寻找了雷达反射率与降水量的关系式.首先进行降水与雷达反射率的采样配对,同时对数据进行质量控制;其次基于三次多项式对单偏振雷达降水数据进行拟合,再利用经验公式、分层贝叶斯和线性回归模型对双偏振雷达降水数据进行估测,结果发现不同的拟合关系式对降水估测均存在高估现象,其中单偏振三次多项式拟合关系式对降水量的高估情况最严重,基于线性回归的关系式对降水量估测效果最好.

针对双偏振雷达信息对强对流降水的贡献评估问题,本文从雷达回波外推预测任务和降水定量估测两个方面进行评估.基于问题三得到的雷达反射率与降水量的关系式可得到降水的定量预测,结果显示,加入双偏振雷达信息后,NowcastNet 模型的预测精度 CSI 值提升了 5.65%,说明双偏振雷达信息可以对强对流降水分布情况及降雨量进行修正,使其更加接近于真实的降水演变情况.另外,本文构建了 XGBoost 模型以定量评估双偏振雷达资料在强对流降水估测中的贡献.根据不同高度的双偏振雷达信息进行优化数据融合,通过对比不同数据输入下 XGBoost 模型对降水的预测效果,得出结论:加入不同高度的双偏振雷达信息可以提高模型的预测效果.

关键词:短临降水估测;双偏振雷达; Fuzzy logic 订正;NowcastNet;回归分析;XGBoost

目录

1	绪论	4
1.1	研究背景与意义	4
1.2	研究目的	4
2	模型假设	5
3	符号说明	5
4	流程图	5
5	问题一模型的构建与求解	6
5.1	基于模糊逻辑算法引入双偏振变量	7
5.2	模型简介与结果分析	7
5.2.1	ConvLSTM	8
5.2.2	ConvLSTM 结果分析	9
5.2.3	PredRNN	10
5.2.4	PredRNN 结果分析	11
5.2.5	Predrnn-v2	11
5.2.6	PredRNN-v2 结果分析	14
5.3	基于 NowcastNet 模型提取微物理信息	14
5.4	NowcastNet 模型架构	15
5.4.1	Evolution network	15
5.4.2	Evolution operator	16
5.5	NowcastNet 模型结果	17
5.5.1	Fuzzy logic 与雷达回波双偏振 PIA 订正	18
5.5.2	Fuzzy logic-PIA 订正效果评估	18
6	问题二模型的构建与求解	20
6.1	生成对抗网络	20
6.2	Nowcastnet 生成原理介绍	21
6.3	Nowcastnet 网络训练过程	21
6.3.1	Evolution network 的损失函数设计	21
6.3.2	Generative network 的损失函数设计	23

6.4	Nowcastnet 模型结果	24
7	问题三模型的构建与求解	25
7.1	问题分析	25
7.2	数据处理	25
7.3	雷达降水估测关系式拟合	27
7.3.1	基于三次多项式拟合	27
7.3.2	基于经验公式拟合	28
7.3.3	基于分层贝叶斯回归拟合	29
7.3.4	基于线性回归拟合	31
7.4	模型评价与结果分析	32
8	问题四模型的构建与求解	33
8.1	问题分析	33
8.2	双偏振雷达资料贡献评估	33
8.3	双偏振雷达资料的优化融合策略	35
8.3.1	XGBoost 原理介绍	35
8.3.2	模型求解与结果分析	36
8.3.3	总结	37
9	模型优缺点分析	37
9.1	模型优点	37
9.2	模型缺点	37
	参考文献	37
	附录 A NowcastNet 架构	40
	附录 B Evolution Network	42
	附录 C Generative Network	44

1 绪论

1.1 研究背景与意义

近年来,受全球气候变化的影响,强对流极端天气频发,如何做出更长预警、更加精细和准确的临近预报逐渐成为当今社会关注的重点.强对流主要由空气的强烈垂直运动产生,被称为仅次于地震、热带气旋、洪涝之后的第四灾害性天气^[1].2022年,我国因强对流天气引发的灾害造成的死亡失踪人数和直接经济损失分别占73%和69%.由于强对流天气局地性强、历时短、破坏强度大,给社会带来的损失惨重,重大社会活动、国家防灾减灾以及精细化天气预报的大众化需求都对强对流灾害天气的临近预报提出了更高的客观要求.如何增强对强对流天气的分析评估及监测能力,做好强对流天气的临近预报成为气象部门天气预报工作中的重点和难点.

传统强对流降水短临预报一般采用雷达外推预报,传统雷达仅能发射和接收一个偏振方向上的电磁波,而新型的双偏振雷达可同时发射和接收在水平和垂直两个偏振方向的电磁波,可以根据两个偏振方向上的回波的强度差别、相位关系等信息获得降水粒子的大小、相态、含水量等微物理信息.近年来研究表明,双偏振雷达变量反映的微物理信息里包含了对流系统的演变状态、空间动力结构等关键信息^[2].因此,双偏振雷达变量的应用,理论上对于强对流预报有重要意义.

本文拟根据材料中给出的新型双偏振雷达数据和降水格点数据进行强对流降水短临预报,基于雷达反射率因子和降水之间的关系,采用深度学习策略对降水量进行预测,进而做出更加准确及时的预报,为气象部门积极做好强对流天气的防御工作提供科学的理论支持和模型参考.

1.2 研究目的

基于问题背景描述,题目提供了新型双偏振雷达数据和降水格点数据两个附件,根据以上内容,本文拟解决以下四个问题:

(1) 利用双偏振变量改进强对流预报,建立可提取用于强对流临近预报双偏振雷达资料中微物理特征信息的数学模型.

(2) 当前一些数据驱动算法在进行强对流预报时,倾向于生成接近于平均值的预报,即存在“回归到平均”,预报总是趋于模糊的问题.基于已解决问题设计数学模型以缓解预报的模糊效应,使预报出的雷达回波细节更充分、更真实.

(3) 利用题目提供的 Z_H 、 Z_{DR} 和降水量数据,设计适当的数学模型,利用 Z_H 及 Z_{DR} 进行定量降水估计.

(4) 设计数学模型评估双偏振雷达资料在强对流降水临近预报中的贡献,并优化数据融合策略,以便更好地应对突发性和局地性强的强对流天气.

2 模型假设

为方便问题研究，对题目中某些条件进行基本简化和合理性假设。

1. 假设附件提供的雷达回波数据经过一定的质量控制, 不存在较大的误差;
2. 假设降水只与题中所给雷达数据相关，不考虑次要因素。

3 符号说明

符号	意义
Z_H	水平反射率因子 (dBZ)
Z_{DR}	差分反射率 (dB)
K_{DP}	比差分相移 ($^{\circ}/km$)
R	降水量 (mm/6min)
Z	雷达反射率 (mm^6m^{-3})
a/b	经验性参数
CSI	临界成功指数
B_s	均方根误差
CC	相关系数

4 流程图

本研究流程设计组织如图4.1, 本文主要分为数据处理模块、雷达外推模块、回波-降水关系拟合模块, 以及在之后进行的探索性融合策略分析.




图 4.1 研究流程设计

5 问题一模型的构建与求解

问题一要求应用双偏振变量来改进强对流预报, 同时建立可以提取双偏振雷达资料中微物理特征信息的数学模型. 普通气象雷达资料的变量是 Z_H (水平反射率因子), 即为水平方向的回波强度, 该变量可以初步反映降水强度的大小. 双偏振雷达数据还常用差分反射率及比差分相移 (Z_{DR} 和 K_{DP}) 这两个变量, 分别代表水平和垂直方向在回波强度上的差异及单位距离上降水粒子引起水平和垂直方向回波的相位差, 分别反映了观测区降水粒子的大小和液态含水量. 因此要加入双偏振雷达信息, 本文就需在临近预报的输入中加入不同于普通雷达的其他变量 Z_{DR} 、 K_{DP} .

5.1 基于模糊逻辑算法引入双偏振变量

气象雷达的工作原理是发送电磁波信号, 并接收其反射信号, 接着通过测量反射信号的强度来估算目标区域的降水量或其他气象参数. 然而, 在信号传播过程中, 大气中的水分和其他粒子可以引起信号的吸收和散射, 从而导致信号损失, 使得反射率测量不准确. 主要原因包括:

- 大气吸收: 水分子对微波信号具有吸收能力, 特别是在特定频率范围内. 这会导致信号在穿越大气中时损失能量, 使得反射率值低估.
- 散射: 大气中的粒子 (如雨滴、雪片) 可以引起信号的散射, 使信号传播方向发生变化. 这会导致信号的部分损失.

为了纠正这些信号损失的影响, 以便更准确地估算降水量和降水分布, 一种业界主流方式是采用路径综合衰减 (Path-integrated attenuation, PIA)^[3]. PIA 是一个用于描述雷达信号在穿越大气中传播时由于大气吸收和散射而损失的功率或能量的指标. PIA 通常以对数形式表示, 单位是分贝 (dB).

在本节中, 气象回波 Z_H 将通过特定比差分相移 (K_{DP}) 进行衰减校正, 反射率 $Z_H(x)$ (dBZ) 将通过添加相应的 $PIA(x)$ (dB) 来校正为 $Z_{H,cor}(x)$, PIA 是使用 python 的 wradlib 函数 `atten.PIA_from_Kdp`^[4] 从特定比差分相移 (K_{DP}) 计算:

$$Z_{H,cor}(x) = Z_H(x) + 2\gamma \int_0^x K_{dp}(x)dx = Z_H(x) + PIA(x). \quad (5.1)$$

我们采用模糊逻辑 (Fuzzy logic)^[5] 算法, 对回波点实现模糊分类, 对于分类为非气象回波的样本点, 将 K_{DP} 设置为 0. Fuzzy logic 的高斯函数表达为 $\mu(x) = e^{-\frac{(x-c)^2}{2\sigma^2}}$.

其中, $\mu(x)$ 为隶属函数, 表示输入像素点 x 属于某个模糊集的程度; $c = 30$ 为 Fuzzy logic 的阈值; $\sigma = 10$ 为高斯函数标准差. 根据模糊集函数进行分类, 将阈值设置为 0.1, 根据分类结果去除非气象回波.

对于分类为气象回波的像素点, 我们用 K_{DP} 数据计算 PIA , 将 PIA 添加到分类为气象的雷达回波 Z_H 中, 进而校正回波强度.

5.2 模型简介与结果分析

强对流天气临近预报问题作为气象领域的一个热点问题, 近年来被人们广泛关注. 随着人工智能技术的发展, 不同的深度学习建模技术被应用到雷达回波外推预测任务中, 并取得较好的预测结果. 本文选取对雷达外推预测任务建模效果较好的经典模型作为研究基础, 包括 ConvLSTM、PredRNN 和 Predrnn-v2, 选取的网络参数见数据附件. 下面将对以上模型的原理进行一一介绍, 并给出引入双偏振变量信息的雷达回波外推预测结果.




图 5.2 LSTM 单元示例

5.2.1 ConvLSTM

为探究雷达回波图空间特征, 我们首先选用卷积长短期记忆网络 (Convolutional Long Short-Term Memory)^[6] 对数据进行分析处理. 卷积神经网络 (CNN) 网络可提取多维时间序列数据在空间结构上的关系, 它主要由卷积层和池化层组成, 利用局部连接、权值共享等特征大幅降低模型参数的数量、提取数据特征.

典型的卷积神经网络的结构分为卷积层及池化层. 其中卷积层由多个特征面组成, 每个特征面由多个神经元组成, 其中每个神经元通过卷积核与上一层局部的特征面区域相互连接, 卷积神经网络的卷积层就是通过这样的卷积操作提取不同时间序列数据的不同特征; 池化层在卷积层之后, 也是由多个特征面组成, 每个特征面对应其上一层的一个特征面, 因而不会改变特征面的数量. 池化层的作用是数据特征的二次提取, 对数据进行降维.

长短期记忆模型 LSTM 是一种特殊的循环神经网络模型, 此模型对隐藏层神经元的内部结构进行了改进, 其工作原理是选择性遗忘一些历史信息, 记忆现在的某些新信息, 然后再将过去的记忆和现在合并之后输出. LSTM 算法的基本思路是对递归神经网络进行改进, 将其不同的隐藏单元通过一定的处理, 转变为能够存储信息、拥有一定记忆特性的新单元, 不同单元的构成如图 5.2.

单元内部元素的解释如下:

- 输入节点: 回收并利用前一个时间点的隐藏节点的输出, 接受当前时刻隐藏节点的输入, 将这两者结合作为输入, 之后经过激活函数 $\tanh$.
- 输入门: 输入门的功能是控制输入的信息, 门的输入是由上个节点的输出和当前单元的输入组成, 由于 sigmoid 的输出介于 0-1 这个范围, 因此把输入门的输出与输入隐藏单元节点的输出相乘, 即可控制其输入信息, 因此该部块用 sigmoid 为激活函数.
- 内部状态节点: 输入们将当前输入进行过滤, 与前一时刻的内部状态单元作为输入.

- 忘记门：负责掌握模型内部状态信息并对其进行控制, 用 **sigmoid** 为激活函数, 门的输入是由上个节点的输出和当前单元的输入组成.
- 输出门：负责掌握模型的输出信息并对其进行控制, 输入是由上个节点的输出和当前单元的输入组成, 由于 **sigmoid** 的输出介于 0-1 范围, 因此把输出门的输出与内部状态单元输出相乘, 即可控制其输出信息, 该部块用 **sigmoid** 为激活函数.

该模型对应计算公式如下：

$$\begin{aligned}
i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), \\
f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), \\
o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o), \\
\tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c), \\
C_t &= f_t \odot C_{t-1} + i_t \odot \tilde{C}_t. \\
h_t &= o_t \odot \tanh(C_t)
\end{aligned}$$

其中, W 为权重系数矩阵, i_t 为忘记门, f_t 为输入门, b_i, b_f, b_c, b_o 为偏置矢量, c_t 为内部状态节点, h_t 为中间输出状态, o_t 为输出门.

ConvLSTM 模型首先采用历史数据作为预测模型的输入, 预测值作为输出. 将一维的向量输入到 ConvLSTM 网络中. ConvLSTM 的主要网络模型参数为：

- 卷积神经网络：CNN 网络包括卷积层和池化层, 各层有卷积核和池化核, 大小设定维度向量；激活函数都为 ReLu 或 ELu.
- 长短期记忆神经网络：LSTM 网络包括层单元, 每一层的隐含神经元数目相应设定；激活函数可以选择 ReLu 或 ELu.
- 全连接层：采用单隐含层的深度神经网络作为 ConvLSTM 网络模型的输出层对数据进行拟合预测, 输出结果为 t 时刻的预测值.

ConvLSTM 网络模型主要过程为：输入数据经过 CNN 网络, 通过卷积和池化操作, 实现对数据特征的提取和降维；接着经 CNN 网络处理过的数据输入到 LSTM 网络, LSTM 网络中的遗忘门、输入门和输出门通过大量数据的不断迭代训练调整自身参数, 使它能从 CNN 网络提取的数据信息中学习数据间的时间拟合关系, 从而对预测时间序列输入输出数据进行有效的动态建模, 最后通过 ConvLSTM 网络拟合训练好的数据通过全连接神经网络输出预测值. 整个预测过程需先通过数据进行训练, 确定网络模型参数.

5.2.2 ConvLSTM 结果分析

图5.3是 ConvLSTM 网络对两个降水系统进行外推的结果, 深蓝色框是真实的雷达回波图像, 浅蓝色框是卷积 LSTM 网络在 T 时刻的单个预测, 可以看出 ConvLSTM 模型只能在前两个时间节点模拟到数据的大致轮廓和分布, 降水落区及物理场运动形态可以基本复




图 5.3 ConvLSTM 预测结果对比图

现出来,但降水强度及对流运动等物理信息无法体现出来;且只能预测短期的图像情况,在 $T=3$ 以后该模型基本无法预测图像信息,说明该模型未能完全捕获降水系统的细节,预测效果较差。

5.2.3 PredRNN

PredRNN 是基于卷积神经网络 (ConvLSTM) 的思想,构建堆叠结构存放该模型中的可记忆单元以增添模型的深度,能够提取到更完善的空间特征和极端降水演化规律,改进了 ConvLSTM 中的状态转换函数,规避了卷积神经网络中信息只能通过隐藏状态向上传递、只能水平更新单元格状态的结构问题,更新优化成有锯齿状记忆流的特点:该记忆流沿着自下而上和自上而下的方向传播,所有的 LSTM 共享同一内存,且能够沿着之字状方向进行传递更新,因此 RNN 的不同层可以互相通信各自学习到的动态信息,该模型还基于记忆解耦损失避免记忆细胞学习到数据中的冗余特征,增强了模型架构中的预测能力和结构时空关联能力^[7]。

PredRNN 通过用一种新的时空长短期记忆 (ST-LSTM) 单元取代卷积 LSTM(时空存储单元以 Z 字形方向更新,信息首先跨层向上传递,然后随时间向前传递.使得空间信息能够有效地流动,但由于存储器需要在遥远的状态之间流动更长的路径,因此容易出现梯度消失.在 ST-LSTM 的帮助下, PredRNN 模型实现了标准时间记忆和所提出的时空记忆的同时

流动.ST-LSTM 的方程如下所示:

$$\begin{aligned}
g_t &= \tanh(\mathcal{W}_{xg} * \mathcal{X}_t + \mathcal{W}_{hg} * \mathcal{H}_{t-1}^l), \\
i_t &= \sigma(\mathcal{W}_{xi} * \mathcal{X}_t + \mathcal{W}_{hi} * \mathcal{H}_{t-1}^l), \\
f_t &= \sigma(\mathcal{W}_{xf} * \mathcal{X}_t + \mathcal{W}_{hf} * \mathcal{H}_{t-1}^l), \\
\mathcal{C}_t^l &= f_t \odot \mathcal{C}_{t-1}^l + i_t \odot g_t, \\
g'_t &= \tanh(\mathcal{W}'_{xg} * \mathcal{X}_t + \mathcal{W}_{mg} * \mathcal{M}_t^{l-1} + b'_g), \\
i'_t &= \sigma(\mathcal{W}'_{xi} * \mathcal{X}_t + \mathcal{W}_{mi} * \mathcal{M}_t^{l-1} + b'_i), \\
f'_t &= \sigma(\mathcal{W}'_{xf} * \mathcal{X}_t + \mathcal{W}_{mf} * \mathcal{M}_t^{l-1} + b'_f), \\
\mathcal{M}_t^l &= f'_t \odot \mathcal{M}_t^{l-1} + i'_t \odot g'_t, \\
o_t &= \sigma(\mathcal{W}_{xo} * \mathcal{X}_t + \mathcal{W}_{ho} * \mathcal{H}_{t-1}^l + \mathcal{W}_{co} * \mathcal{C}_t^l + \mathcal{W}_{mo} * \mathcal{M}_t^l + b_o), \\
\mathcal{H}_t^l &= o_t \odot \tanh(\mathcal{W}_{1 \times 1} * [\mathcal{C}_t^l, \mathcal{M}_t^l]).
\end{aligned} \tag{5.2}$$

此算法保留了两个存储单元: $\mathcal{C}_t^l$ 是标准的时间单元, 从 $t-1$ 的前一个节点传递到每个 LSTM 单元内的当前时间步长. $\mathcal{M}_t^l$ 是时空记忆, 它在同一时间步长从 $l-1$ 层垂直传输到当前节点. 对于底部 ST-LSTM 层, 其中 $l = 1$, $\mathcal{M}_t^{l-1} = \mathcal{M}_{t-1}^l$. 本文为 $\mathcal{M}_t^l$ 构造了另一组门结构, 同时在标准 LSTM 中保持了 $\mathcal{C}_t^l$ 的原始门. 最后, 该节点的最终隐藏状态依赖于融合的时空记忆. 将这些从不同方向导出的存储器连接在一起, 然后应用 1×1 卷积层进行降维, 这使得隐藏状态 $\mathcal{H}_t^l$ 与存储单元的维数相同. 与简单的内存级联不同, ST-LSTM 单元对两种内存类型都使用了共享输出, 以实现无缝的内存融合^[8].

5.2.4 PredRNN 结果分析

图5.4是 PredRNN 对相同的两个降水系统的预测结果与真实对比图, 深蓝色框是真实的雷达回波图像, 浅蓝色框是 PredRNN 在 T 时刻的单个预测雷达回波图, 可以看出, 同样作为气象领域经典模型, PredRNN 模型较 ConvLSTM 模型略胜一筹, 可以预测长期的图像情况, 但仍无法完美模拟极端降水强度, 只能复刻出极端降水的落区, 但预测边缘地带过于光滑化, 边缘部分的细节难以模拟出来, 雷达回波细节不够真实充分.

5.2.5 Predrnn-v2

该模型提出了一种新的 RNN 架构, 称为时空内存流, 它改进了卷积 RNN 的状态转换函数. 同时, 该模型构建了时空 LSTM(ST-LSTM), 是 PredRNN 的构建块. 利用一对联合学习并明确解耦的记忆细胞来覆盖时空变化的长期和短期动态. 且改进了训练程序, 以鼓励预测网络从更长时间的观察帧中学习非马尔可夫动力学. 允许模拟环境在决策场景中对代理行为的时空变化.

考虑到 ConvLSTM 的存储单元可以锁存梯度, 从而在递归节点之间存储有价值的信息,




图 5.4 PredRNN 预测结果对比图

因此通过在 Z 字形方向上更新存储状态来改进上述水平存储流, 使其能够更好地将知识从输入传递到输出. 这种内存流的关键方程如下:

$$\begin{aligned}
 g_t &= \tanh(W_{xg} * \mathcal{X}_t \mathbf{1}_{\{l=1\}} + W_{hg} * \mathcal{H}_t^{l-1}), \\
 i_t &= \sigma(W_{xi} * \mathcal{X}_t \mathbf{1}_{\{l=1\}} + W_{hi} * \mathcal{H}_t^{l-1} + W_{ci} * \mathcal{M}_t^{l-1}), \\
 f_t &= \sigma(W_{xf} * \mathcal{X}_t \mathbf{1}_{\{l=1\}} + W_{hf} * \mathcal{H}_t^{l-1} + W_{cf} * \mathcal{M}_t^{l-1}), \\
 \mathcal{M}_t^l &= f_t \odot \mathcal{M}_t^{l-1} + i_t \odot g_t \\
 o_t &= \sigma(W_{xo} * \mathcal{X}_t \mathbf{1}_{\{l=1\}} + W_{ho} * \mathcal{H}_t^{l-1} + W_{co} * \mathcal{M}_t^l), \\
 \mathcal{H}_t^l &= o_t \odot \tanh(\mathcal{M}_t^l).
 \end{aligned} \tag{5.3}$$

具有内存解耦的时空 LSTM: 时空内存状态首先跨层向上更新, 然后前进到下一个时间步长. 它在时间上拉伸状态转换路径, 并在网络的同一级别的水平相邻节点之间添加额外的神经元. 因此, 该结构使网络能够学习短期运动的复杂非线性过渡函数. 然而, 这种深度时间架构也可能带来梯度消失问题. 迂回的内存转换路径可能会使捕获长期依赖关系变得困难. 对于短期复发深度和长期连贯性^[9], 该模型引入了一种双流记忆转换机制, 该机制结合了原始

记忆细胞 C 和新记忆细胞 M, 导出了一个名为时空 LSTM(ST-LSTM) 的复发单元:

$$\begin{aligned}
g_t &= \tanh(W_{xg} * \mathcal{X}_t + W_{hg} * \mathcal{H}_{t-1}^l), \\
i_t &= \sigma(W_{xi} * \mathcal{X}_t + W_{hi} * \mathcal{H}_{t-1}^l), \\
f_t &= \sigma(W_{xf} * \mathcal{X}_t + W_{hf} * \mathcal{H}_{t-1}^l), \\
\mathcal{C}_t^l &= f_t \odot \mathcal{C}_{t-1}^l + i_t \odot g_t, \\
g'_t &= \tanh(W'_{xg} * \mathcal{X}_t + W_{mg} * \mathcal{M}_t^{l-1}), \\
i'_t &= \sigma(W'_{xi} * \mathcal{X}_t + W_{mi} * \mathcal{M}_t^{l-1}), \\
f'_t &= \sigma(W'_{xf} * \mathcal{X}_t + W_{mf} * \mathcal{M}_t^{l-1}), \\
\mathcal{M}_t^l &= f'_t \odot \mathcal{M}_t^{l-1} + i'_t \odot g'_t, \\
o_t &= \sigma(W_{xo} * \mathcal{X}_t + W_{ho} * \mathcal{H}_{t-1}^l + W_{co} * \mathcal{C}_t^l + W_{mo} * \mathcal{M}_t^l), \\
\mathcal{H}_t^l &= o_t \odot \tanh(W_{1 \times 1} * [\mathcal{C}_t^l, \mathcal{M}_t^l]).
\end{aligned} \tag{5.4}$$

通过将 ST-LSTM 作为构建块来代替 ConvLSTM, 给出了最终的 PredRNN 模型. 有两种记忆状态: 首先, $\mathcal{C}_t^l$ 是在每个 ST-LSTM 单元内从 $t-1$ 的前一个节点过渡到当前时间步长的时间记忆. 其次, $\mathcal{M}_t^l$ 是时空记忆, 它在同一时间步长从较低的 $l-1$ ST-LSTM 单元垂直过渡到当前节点. 在 ST-LSTM 的第一个版本的基础上, 构建一种新的解耦损失, 它阻止 $\mathcal{C}$ 和 $\mathcal{M}$ 学习冗余特征. 在每个 ST-LSTM 单元中, 首先在每个时间步长的 $\mathcal{C}_t^l$ 和 $\mathcal{M}_t^l$ 的增量上添加卷积层, 并利用新的去耦损失来显式地扩展它们在潜在空间中的距离. 通过这种方式, 不同的记忆状态被训练成专注于时空变化. 整体存储器去耦方法可以公式化如下:

$$\begin{aligned}
\Delta \mathcal{C}_t^l &= W_{\text{decouple}} * (i_t \odot g_t), \\
\Delta \mathcal{M}_t^l &= W_{\text{decouple}} * (i'_t \odot g'_t), \\
\mathcal{L}_{\text{decouple}} &= \sum_t \sum_l \sum_c \frac{|\langle \Delta \mathcal{C}_t^l, \Delta \mathcal{M}_t^l \rangle_c|}{\|\Delta \mathcal{C}_t^l\|_c \cdot \|\Delta \mathcal{M}_t^l\|_c}.
\end{aligned} \tag{5.5}$$

其中 W_{decouple} 表示由所有 ST-LSTM 单元共享的 1×1 个卷积; $\langle \rangle$ 和 $\|\cdot\|$ 分别是针对每个通道 c 计算的平坦特征图的点积和 l_2 范数. 在训练时, 从等式中导出记忆状态的增量 $i_t \odot g_t$ 和 $i'_t \odot g'_t$. 最终 PredRNN-v2 模型以完全无监督的方式进行端到端训练. 总体培训目标是:

$$\mathcal{L}_{\text{final}} = \sum_{t=2}^{T+K} \left\| \hat{\mathcal{X}}_t - \mathcal{X}_t \right\|_2^2 + \mathcal{L}_{\text{decouple}}. \tag{5.6}$$

其中, 第一项是在每个时间步长对网络输出起作用的帧重建损失, 第二项是来自等式的存储器解耦正则化. Action fusion: $\mathcal{V}_t^l = (W_{hv} * \mathcal{H}_{t-1}^l) \odot (W_{av} * \mathcal{A}_{t-1})$.

$$\mathcal{H}_t^l, \mathcal{C}_t^l, \mathcal{M}_t^l = \text{ST-LSTM}(\mathcal{X}_t, \mathcal{V}_t^l, \mathcal{C}_{t-1}^l, \mathcal{M}_t^{l-1}).$$

其中, $\mathcal{V}_t^l$ 编码先前隐藏状态 $\mathcal{H}_{t-1}^l$ 和在先前时间步长 $\mathcal{A}_{t-1}$ 处采取的动作 $\mathcal{A}_t$ 具有连续的值, 并已转换为与隐藏状态相同的分辨率. 通过在每个 ST-LSTM 单元中结合 $\mathcal{V}_t^l$, 在编码和预测时间步长, PredRNN 学会模拟未来动作序列在长时间段内的后果^[10].

PredRNN-v2 的学习策略由两部分组成:

- 反向计划采样 (RSS): 用于编码时间步长, 并通过随机隐藏真实观察结果来迫使模型了解更多关于长期动态的信息, 随着训练阶段的进展, 概率会降低.
- 计划采样 (SS): 用于预测时间步长, 以缓解训练和推理阶段之间数据流的不一致性.

5.2.6 PredRNN-v2 结果分析




图 5.5 PredRNN-v2 预测结果对比图

图5.5是 PredRNN-v2 外推的预测结果与真实对比图, 深蓝色框是真实的雷达回波图像, 浅蓝色框是 PredRNN-v2 在 T 时刻的单个预测雷达回波图, 可以看出 PredRNN-v2 模型较以上两种模型预测精度有所提高, 不仅能捕捉长期变化, 能够模拟出降水落区和位置变化情况, 且预测降水强度方面有大幅度的提升, 但仍存在普通数据驱动算法在强对流预报中存在的问题, 即过于倾向于生成接近平均值的预报, 有“回归到平均”的问题, 预报过于平滑化, 边缘的变化趋于模糊, 雷达回波细节不够真实充分.

5.3 基于 NowcastNet 模型提取微物理信息

问题一要求提取强对流临近预报双偏振雷达资料中的微物理信息, 上文使用的 ConvLSTM、PredRNN 及 PredRNN-v2 都具有过于平滑、模糊的问题, 且无法有效提取到数据中的物理信息.

为改进这些问题, 本文采用 2023 年 7 月发表在 nature 上的 NowcastNet 模型^[11], NowcastNet

允许端到端对预测误差进行优化, 并通过神经网络框架实现了物理规律和统计知识的统一, 为极端降水事件提供了高分辨率、物理化可解释性及长提前期的临近预报.

5.4 NowcastNet 模型架构

由于极端降水过程持续时间较短, 发生的空间范围小, 且受到大气系统混沌效应及地形、气旋及对流等复杂因素的严重影响, 单纯根据物理方程规律的数值计算模拟技术及基于数据驱动的方法难以对小范围的极端降水事件做出精细准确的临近预报. NowcastNet 基于双偏振雷达观测数据, 将物理信息规律和深度学习相结合, 构建了用于最小化预测误差的物理条件机制以及非线性过程的神经网络框架, 能够更加准确地对极端降水进行短临预报. 其基本架构如图5.6.




图 5.6 NowcastNet 基本架构^[11]

由于问题一着重解决提取强对流临近预报中的为物理特征信息问题, 因此该部分主要介绍 NowcastNet 中的物理机制部分, 剩余复杂网络架构解释详细见第二问的原理分析.

5.4.1 Evolution network

NowcastNet 的 Evolution network(演化网络) 部分将双偏振雷达降水过程进行分解: 极端降水过程中降水系统自身生消导致的变化、降水系统平流移动过程导致的变化, 将观测的雷达回波输入演化网络 (Evolution network), 网络通过双 decoder 架构学习被分解出的平流移动场和生消场两个过程场; 接着基于连续方程的特点描述极端降水过程中的物理规律:

$$\frac{\partial \mathbf{x}}{\partial t} + (\mathbf{v} \cdot \nabla) \mathbf{x} = \mathbf{s}. \quad (5.7)$$

式5.7中, 等式左边的第一项描述了降水过程的局地变化情况, 第二项描述了降水过程中的平流运动情况; 等式右端的 s 为降水强度残差, 生消过程属于 $\mathbf{s}$ 的一部分. $\mathbf{x}$ 、 $\mathbf{v}$ 和 $\mathbf{s}$ 分别表示复合反射率的雷达场、运动场和强度残差场, ∇ 代表梯度算子.

$$\frac{\mathbf{x}(\mathbf{p} + \Delta t \cdot \Delta \mathbf{v}, t + \Delta t) - \mathbf{x}(\mathbf{p}, t)}{\Delta t}. \quad (5.8)$$

式5.8中, $\mathbf{p}$ 和 t 分别代表位置和时间. 残差场 $\mathbf{s}$ 显示了加性演化机制, 如降水强度的增长和衰减. 根据连续性方程, 降水的时间演化可以建模为运动场平流和强度残差加法的组合.




图 5.7 Evolution network 基本架构^[11]

Evolution network 具体结构如图5.7, Motion decoder 用于捕捉降水系统平流移动规律, 而 Intensity decoder 用于捕捉降水系统对流生消的规律, 其 Encoder-Decoders 结构细节如图5.8.




图 5.8 Encoder-Decoders 架构^[11]

5.4.2 Evolution operator

图5.9为 Evolution network 设计的演化算子 (Evolution operator). 本文使用深度神经网络根据过去的雷达观测结果同时预测所有这些场, 这使得能够对复杂的降水演变进行非线性

建模. 该部分结合交互了雷达观测数据和物理信息数据, 基于物理信息构建出的进化网络,




图 5.9 Evolution operator 基本架构^[11]

该结构中含有可微分的神经进化算法, 该进化算子将当前雷达数据作为输入, 预测未来的雷达成长, 在最后一个时间不长通过与运动场平流来演化, 直至推得最终雷达信息; 且为避免在训练过程中的累计误差, 每个时刻雷达信息预测后将进行阶段梯度更新.

5.5 NowcastNet 模型结果

图5.10是本文所使用的模型 (NowcastNet) 对于前述两个降水系统雷达回波的外推结果与真实对比图, 深蓝色框是真实的雷达回波图像, 浅蓝色框是 NowcastNet 在 T 时刻的单个预测雷达回波图. 由图5.10可以看出: NowcastNet 较前述三种模型, 预测效果最好, 不仅能




图 5.10 Nowcastnet 预测结果对比图

够基本模拟出极端降水的强度变化, 还能够复刻降水落区, 极端降水位置变化及极端降水的物理效应运用形态, 且在极大程度上缓解了预报的模糊效应, 预报边缘部分的变化具有较多的雷达回波细节, 较为真实充分地模拟了强对流极端降水的物理细节变化情况, 是以上模型中唯一可以同时保持极端降水线形状和强度的模型, 且完美提供了降水线形成、运动及消

散的清晰预报,能够更好地预测更长时间段内的对流细线演变和细节情况,还可以预测不同对流单元在更长时间内的多尺度演变方法,且该模型对高强度降水的演变提供了更好的预测;在 $T = 6$ 之前都能基本完美模拟极端降水情况, $T = 6$ 之后预测效果略微变差,但仍能捕捉到大量雷达回波细节. 以上说明该模型预测雷达回波细节效果较好,能够基本模拟强对流极端降水的整体和细节变化情况.

5.5.1 Fuzzy logic 与雷达回波双偏振 PIA 订正

基于5.1中利用 Fuzzy logic 算法,与雷达回波双偏振 PIA 订正算法,我们引入双偏振变量 K_{DP} 对输入雷达回波图进行订正,探究双偏振数据对预测精度的效果.

将订正后的雷达回波图输入训练好的 NowcastNet 网络架构推理,用 NowcastNet 外推雷达回波. 由此得到的原始雷达回波、去除气象杂波和修正后的雷达回波结果如图5.11. 图5.11中,本文首先基于 Fuzzy logic 过滤器对雷达回波信号进行去噪订正,右边两幅图为加




图 5.11 加入双偏振雷达变量回波图像变化情况

入不同双偏振雷达变量之后修正的雷达回波图,通过将其对比可以看出,加入双偏振变量之后,雷达回波细节更完善,变化幅度更为清晰,且去除了一定的气象杂波,能够避免预测结构收到无关变量的影响,得到反射率 Z_H 的结果更加准确,纠正这些无关信号损失的影响,以便更加准确科学地估算降水分布情况和降水量.

5.5.2 Fuzzy logic-PIA 订正效果评估

在气象预测模型中,一般使用 CSI 来评测和检验数据预测结果,CSI 即临界成功指数,是对一种预报方法进行客观性地衡量和评估的指标. 该指标同时考虑了空报和漏报两类错误,取值范围为 0-1,1 代表预报完全准确,0 代表预报完全失败,其计算公式如下:

$$CSI = \frac{TP}{TP + FN + FP}.$$

其中, TP, FN, FP 解释如表5.1

表 5.1 混淆矩阵

混淆矩阵	预测负例	预测正例
真实负例	TN(True negative)	FP(False positive)
真实正例	FN(False negative)	TP(True positive)

文中使用的四种方法的 CSI 指数值变化如图5.12.




图 5.12 不同模型 CSI 指数变化情况

由图5.12结果可以看出：不同模型的 CSI 指数均呈下降趋势,说明预测前几个时间节点比预测之后的时间节点更准确；CSI 指数由高到低的模型分别为 NowcastNet、PredRNN-v2、PredRNN 及 ConvLSTM 模型,NowcastNet 方法的 CSI 指数最高,ConvLSTM 模型的 CSI 指数最低,表明本文使用的 NowcastNet 模型真阳性所占比例较大,该模型错误率较低,对真实雷达回波图的拟合效果最好,ConvLSTM 模型预测效果最差.

当前已有的方法可以对极端降水进行临近预报,但预报结果存在强度、位置误差、耗散及模糊等问题；由第一问运用的不同模型可以看出,目前基于数据驱动模型及算法难以合理遵循降水内在的对流守恒等物理规律,且预报误差会逐次累积,不能有效模拟极端降水过程的时空多尺度特征；基于深度学习的算法虽然能够模拟降水过程的非线性系统,但小样本过平滑的问题依旧存在,且在建模过程中缺少一定的物理守恒规则约束,生成数值模拟信息场失真模糊,损失了许多降水过程中的有效信息；基于物理原理的数值计算方法无

法捕捉关键的对流启动等混沌动力学信息. 因此本文运用 NowcastNet 模型对强对流极端降水进行预测分析.

6 问题二模型的构建与求解

6.1 生成对抗网络

基于问题一的建模结果, 我们可以看到 NowcastNet 模型的雷达外推预测结果相比经典模型能很好的缓解预报的模糊效应. 因此本文使用 NowcastNet 模型进行雷达外推预测建模. 在问题一中, 我们主要说明了 NowcastNet 模型在提取微物理信息方面的原理, 下面我们将对 NowcastNet 模型原理做具体介绍.

在介绍 Nowcastnet 之前, 首先介绍一下生成对抗网络 GAN(Generative Adversarial Network). 生成对抗网络结构由一个生成器和一个判别器构成, 生成器基于已有的自然噪声生成样本图像数据; 判别器则衡量生成器生成图像数据样本和真实图像样本数据之间的差异, 判断样本生成的真实性. 经过多次训练后, 生成器的新样本数据生成能力和判别器的真假样本数据判别能力达到最大化. 一直到生成器能够掌握真实样本数据的分布规律, 判别器难以判断生成器生成样本和真实样本数据之间的差异停止, 至此生成对抗网络数据生成满足要求, 生成结束. GAN 在生成过程中的优化博弈过程如式6.9.

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim P_G} [\log(1 - D(G(z)))]. \quad (6.9)$$

式6.9中, P_G 为高斯分布, z 为基于该分布随机采样的自然噪声, 服从 $z \sim P_G(z)$; $D(x)$ 及 $G(z)$ 分别为判别器和生成器; $P_{data}(x)$ 表示数据的真实分布, V 为优化目标函数. 算法整体流程如算法1.

算法 1 生成对抗网络 GAN 训练过程

输入: 真实样本 $x^1, x^2, \dots, x^m$ 、高斯分布随机采样噪声 $z^1, z^2, \dots, z^m$

输出: 经过训练的生成器 G 和判别器 D

- 1: **Step1:** 从数据库中抽样 m 个真实样本 $x^1, x^2, \dots, x^m$.
- 2: 从高斯分布中抽样的 m 个随机噪声 $z^1, z^2, \dots, z^m$.
- 3: 将噪声输入生成器 G , 生成假样本 $\tilde{x}^1, \tilde{x}^2, \dots, \tilde{x}^m, \tilde{x}^i = G(z^i)$.
- 4: 固定 G , 训练 D , 目标为能够辨别生成样本的真假, 即最大化

$$\tilde{V} = \frac{1}{m} \sum_{i=1}^m \log D(x^i) + \frac{1}{m} \sum_{i=1}^m \log(1 - D(\tilde{x}^i)). \quad \theta_d \leftarrow \theta_d + \eta \nabla \tilde{V}(\theta_d).$$

- 5: **Step2:** 从高斯分布中抽样的 m 个随机噪声 $z^1, z^2, \dots, z^m$.
- 6: 固定 D , 训练 G , 目标为能够生成足以欺骗判别器 D 的样本, 即最大化

$$\tilde{V} = \frac{1}{m} \sum_{i=1}^m \log D(G(z^i)). \quad \theta_g \leftarrow \theta_g + \eta \nabla \tilde{V}(\theta_g).$$

- 7: 反复迭代 **Step1**、**Step2**, 直至模型收敛.
-

6.2 Nowcastnet 生成原理介绍

NowcastNet 可分为两个部分, 首先构建中尺度演变网络, 模拟平流运动等展现物理性质的中尺度降水过程, 接着根据质量守恒定律 (物质连续性方程) 设置新的可微分的神经演变算子, 端到端建模极端降水过程中的小公里尺度运动, 且基于反向传播最小化预报累积误差, 这在5.4之中已经详细介绍. NowcastNet 作为一个深度生成模型, 其优势在于, 为了欺骗判别器, 生成器会趋向于生成更加真实的图像, 这也与我们避免结果过度平滑化不谋而合.

NowcastNet 具体描述为首先基于物理机制的 Evolution network 从观测的雷达图像中外推中尺度 (分辨率为 20km) 的确定变化, 得到预测的中尺度雷达数据; 再利用生成对抗网络的 Generator 和 Discriminator 捕捉对流细节, 并且在生成过程中利用中尺度预报作为提示, 进而生成具有细节性的最终预报. 即本对流尺度生成网络基于中尺度变化网络预测结果的条件, 运用概率生成模型更深层次捕获对流生消等混沌过程, 本流程可描述为式6.10.

$$P(\hat{\mathbf{x}}_{1:T} | (\mathbf{x}_{-T_0:0}, \phi; \theta) = \int P(\hat{\mathbf{x}}_{1:T} | \mathbf{x}_{-T_0:0}, \phi(\mathbf{x}_{-T_0:0}), \mathbf{z}; \theta) P(\mathbf{z}) d\mathbf{z} \quad (6.10)$$

式6.10中, 等式右边的 Evolution network ϕ 为提前学习好的中尺度外推网络, 即输入观测的雷达数据 $\mathbf{x}_{-T_0:0}$, 预报未来的中尺度雷达数据 $\phi(\mathbf{x}_{-T_0:0})$. 接着基于 $\phi(\mathbf{x})$ 的约束, 给定随机噪声 $\mathbf{z}$ 及 generative network 的 θ , 求出最终具有对流细节的预报, 最后乘以 $p(\mathbf{z})$, 得到该噪声下最终结果出现的概率. 多次进行噪声采样重复上述过程, 对其进行积分, 进而得到多次随机抽样情况下的集合预报. 该部分基本架构如图6.13, 随机噪声通过 noise projector 加入高维特征中, 如图6.14.

图6.13中, NowcastNet 生成器的 encoder 部分和 Evolution Network 部分设计一致, 而 decoder 架构参考了 Spatially-adaptive denormalization(空间自适应非规范化) 方法进行语义图像合成. SPADE 思想能够更好地保留针对通用规范化层的语义信息^[12]. 如图6.15所示, SPADE 将语义图剥离开, 通过两个卷积网络生成反映语义分布线性回归的斜率项 γ 和截距项 β , 通过 Element-wise 的放缩和偏置, 实现针对语义信息而与原图无关的特殊归一化处理. 这就是语义图在生成器中发挥作用的过程. NowcastNet 中生成部分的原理正是出自此处: 20km 分辨率的中尺度预报就是“语义”, 约束了最后的 1 ~ 2km 分辨率预报结果.

6.3 Nowcastnet 网络训练过程

6.3.1 Evolution network 的损失函数设计

Evolution network 的损失函数: 主要包括 J_{accum} 和 J_{motion} .

$$J_{accum} = \sum_{t=1}^T (L_{wdis}(\mathbf{x}_t, \mathbf{x}'_t)_{bili}) + L_{wdis}(\mathbf{x}_t, \mathbf{x}''_t)). \quad (6.11)$$

式6.11中, $\mathbf{x}_t$ 是观测值, $\mathbf{x}'_t$ 是最后一张观测雷达回波图基于 motion 场移动后的极端降水




图 6.13 NowcastNet 生成器设计架构^[11]




图 6.14 NowcastNet 噪音映射网络设计架构^[11]

预报, x'_t 是在 x_t 上增添了 intensity 后的极端降水预报. 将其分别测算 L_1 距离并优化结合. 加权距离具有式6.12的形式:

$$L_{wdis}(x_t, x'_t) = ||(x_t - x'_t) \odot w(x_t)||_1. \quad (6.12)$$

式6.12中, $w(x) = \min(24, 1 + x)$ 来源于 DGMR^[13], 极端降水量大致遵循对数正态分布, 因此需要添加权重项以平衡不同的降雨量, 本文对降水量使用权重比例分配, 将其剪裁




图 6.15 SPADE 设计架构^[12]

到 24, 用来增加雷达回波中较大强度值的鲁棒性.

损失函数的第二部分是梯度范数形式的运动正则项, 以降水模式寿命过程和连续性方程为动机, 并叠加正则项对 motion 场作惩罚, 即式6.13:

$$J_{motion} = \sum_{t=1}^T (\|\nabla \mathbf{v}_t^1 \odot \sqrt{\mathbf{w}(\mathbf{x}_t)}\|_2^2 + \|\nabla \mathbf{v}_t^2 \odot \sqrt{\mathbf{w}(\mathbf{x}_t)}\|_2^2). \quad (6.13)$$

式6.13中, $\mathbf{v}_1$ 及 $\mathbf{v}_2$ 为 motion 场的经纬向分量, $\nabla \mathbf{v}$ 代表对 $\mathbf{v}$ 变量进行卷积操作, 其中, 卷积核代入固定参数, 无需进行训练, 使用 Sobel 滤波器近似计算, 即式6.14.

$$\partial_1 \mathbf{v} = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix} * \mathbf{v}, \quad \partial_2 \mathbf{v} = \begin{bmatrix} 1 & 2 & -1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} * \mathbf{v} \quad (6.14)$$

总体而言, 训练演化网络的目标为: $J_{evolution} = J_{accum} + \lambda J_{motion}$.

在训练演化网络时, NowcastNet 针对误差累计在多个时间戳的现象采用切断各预报时间点的梯度传播进行处理, 在前向传递时, 上一时刻影响下一时刻的预报, 反向传递时后一时刻不影响前一时刻的预报.

6.3.2 Generative network 的损失函数设计

生成器的目的是预报与真实雷达图像数据类似, 判别器则为了判断生成数据的真伪, 两者均使用交叉熵损失, 以前时间节点的雷达观测值也为对应判别器的输入. 但为更好预报极端降水, 生成器损失函数还有另外一部分, 即首先将预报进行集合平均, 抵消其极端信号被平滑化的问题; 接着分别把观测值和预报值都做最大池化处理, 且计算其对应的 L_1 损失. 具体表达式如式6.15:

$$J_{disc} = L_{ce}(D(\mathbf{x}_{1:T}), 1) + L_{ce}(D(\hat{\mathbf{x}}_{1:T}), 0). \quad (6.15)$$

式6.15中, L_{ce} 是交叉熵损失, 生成网络中的 Nowcast decoder 被训练为通过最小化由公式6.16修改的对抗性损失来混淆判别器:

$$J_{adv} = L_{ce}(D(\hat{\mathbf{x}}_{1:T}, 1)). \quad (6.16)$$

式6.16中, 梯度通过 $\mathbf{x}_{1:T}$ 反向传播, 首先到生成器的 nowcast 解码器, 接着到编码器, 使其能够预测具有对流尺度细节的真实多尺度场; 接着利用 DGMR^[13] 中生成系统预测的思想, 在空间维度上基于最大池化层 Q 聚合 k 个预测 $\mathbf{x}_{1:T}^z$. 在集合预测的基础上, 池正则化被定义为空间池观测值与 k 个空间池预测值的平均值之间的加权距离. 具体表达公式如式6.17:

$$J_{pool} = L_{wdis}(Q(\mathbf{x}_{1:T}), \frac{1}{k} \sum_{i=1}^k Q(\hat{\mathbf{x}}_{1:T}^{z_i})). \quad (6.17)$$

总体来言, 训练生成网络的目标为式6.18.

$$J_{generative} = \beta J_{adv} + \gamma J_{pool}. \quad (6.18)$$

6.4 Nowcastnet 模型结果

图6.16和图6.17是两次降水系统的基于 Nowcastnet 预测外推雷达回波图情况, 即两次彼此不相关的极端降雨情况, 可以看出: 第一个降雨系统6.16能够复刻降水落区, 极端降水位置变化及极端降水的物理效应运用形态, 且在极大程度上缓解了预报的模糊效应, 预报边缘部分的变化具有较多的雷达回波细节, 较为真实充分地模拟了强对流极端降水的物理细节变化情况, 且完美提供了降水线形成、运动及消散的清晰预报. 第二个降雨系统6.17可以体现 Nowcastnet 模型能基本模拟出降雨的强度变化, 预测准确度和落雨区位置精确度较高, 由图6.17能够看出, 该模型准确地预测了真实雷达回波图中上半部分对流增强导致雨势增大, 下半部分对流减弱导致雨势减小的现象, 能够更好地预测更长时间段内的对流细线演变和细节情况. 说明了本文使用的 NowcastNet 模型预测的科学准确性, 且缓解了其他模型的预报模糊效应情况. 需要说明的是, 本题中给出的真实雷达回波图明显为插值得到的图像, 不够真实, 基于计算和查阅资料可知, 该图像是 9 张不同仰角的雷达回波图通过空间插值完成的 (CAPPI); 而本文基于 Nowcastnet 的预测雷达外推回波图细节更全面, 更为接近现实情况.




图 6.16 Nowcastnet 预测结果 1 对比图

7 问题三模型的构建与求解

7.1 问题分析

传统强对流天气临近预报主要依靠雷达等观测资料, 通过外推的方法得到未来时刻的雷达反射率因子, 并进一步使用雷达反射率因子和降水之间的经验性关系 (即 $Z - R$ 关系) 估计未来时刻的降水量^[14]. $Z - R$ 关系是雷达回波反射率与降水之间的经验关系, 由于 $Z - R$ 关系受到地形、降水类型、区域等因素的影响, 其参数变化较大, 造成雷达定量降水估测 (QPE) 精度不高^[15]. 本文利用数据驱动的方法, 基于回归分析给出该区域双偏振雷达关系的经验参数估计值, 并与单偏振三次多项式拟合、分层贝叶斯回归和线性回归结果拟合结果进行对比.

7.2 数据处理

原始数据为 256×256 的格点数据, 本文通过随机提取方形网格数据点作为研究对象, 并将数据处理为反射率与降水的匹配数据对形式, 下文称 $Z - R$ 数据. 由于存在降水量为 0 而雷达回波反射率不为 0 的虚假回波现象, 本文直接将其剔除; 同时对匹配数据均为 0 的数




图 6.17 Nowcastnet 预测结果 2 对比图

据进行删除. 为保证建模数据质量, 参考 [16], 本文数据预处理流程如下:

- 第一步: 使用高度为 1km 的雷达回波数据, 匹配得到 N 例数据;
- 第二步: 遍历所得数据, 若不同反射率因子均为 0, 降水为 0, 则剔除;
- 第三步: 对 $-1 \leq Z_{DR} \leq 5, 0 \leq Z_H \leq 65$ 范围外的数据进行剔除;
- 第四步: 通过水平反射率因子 $Z_H(\text{dBZ})$ 和时雨量 (mm/h) 转换关系式, 得到不同水平反射率因子对应的时雨量, 其中水平反射率因子 Z_H 和时雨量 $Rainfall$ 的转换关系式为式 7.19.

$$Rainfallrate = [10^{(dBz/10)} / 200]^{0.625}. \quad (7.19)$$

参考 [17] 获得降水强度. 不同降水强度用整数 1 至 4 表征, 数值越大, 降水强度越大, 具体划分规则如表 7.2.

- 第五步: 对得到的 Z-R 数据进行二次质量控制. 通过对比真实降水量与通过水平反射率因子 Z_H 转换得到的时降雨量, 剔除绝对误差大于 2.29(误差中位数) 的数据, 最终得到 1157 例建模数据, 对数据进行可视化如图 7.18. 由图 7.19 可知, 水平反射率因子 (Z_H) 与差分反射率 (Z_{DR}) 存在正相关关系, 水平反射率因子与降水量 (R) 存在明显的非线性关

表 7.2 降水强度等级划分标准

时雨量 (mm/h)	降雨强度
> 16	暴雨
8 ~ 16	大雨
2.6 ~ 8	中雨
< 2.6	小雨




图 7.18 处理后的双偏振雷达回波率信息

系. 下文将基于以上数据建立水平反射率因子、差分反射率和降水量的数学模型.

7.3 雷达降水估测关系式拟合

7.3.1 基于三次多项式拟合

根据数据可视化结果可知, 水平反射率因子与降水量符合三次多项式关系, 因此使用三次多项式拟合降雨量 (R) 和水平反射率因子 (Z_H) 的关系式, 结果如7.20.

$$R_1 = 1.0941 \times Z_H + 0.0066 \times Z_H^2 - 0.0002 \times Z_H^3. \quad (7.20)$$

其中将拟合曲线与真实数据进行可视化如图7.19, 可以看到曲线能很好拟合数据趋势.




图 7.19 基于三次多项式拟合的降雨量 (R) 和水平反射率因子 (Z_H) 的关系

7.3.2 基于经验公式拟合

由于算法不能使用 K_{DP} 变量, 因此本文基于 $R - Z_H - Z_{DR}$ 关系法进行双偏振雷达定量估测降水. $R - Z_H - Z_{DR}$ 方法^[16] 的关系式为式7.21.

$$R = aZ_H^b Z_{DR}^c. \quad (7.21)$$

其中, Z 为水平反射率因子, 单位为 $mm^6 m^{-3}$. 需要注意的是, 本文水平反射率因子 Z_H 的单位为 dBZ. 基于最小二乘回归对关系式参数进行估计, 通过直接对式7.22两端取对数, 将参数求解问题转化为多元线性回归模型系数估计问题, 通过求解优化问题7.22得到参数的估计值.

$$\min_{a,b,c} \left(\sum_{i=1}^N (\ln R - \ln a - b \ln Z_H - c \ln Z_{DR})^2 \right). \quad (7.22)$$

以上优化问题本质上为 $\ln R$ 关于 $\ln Z_H$ 与 $\ln Z_{DR}$ 的多元线性回归问题, 使用 python 进行求解, 对应多元线性回归问题的求解结果如表7.3.

表 7.3 基于经验公式的回归结果

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-1.2781	0.177	-7.211	0.000	-1.626	-0.93
$\ln(Z_H)$	0.7257	0.053	13.794	0.000	0.622	0.829
$\ln(Z_{DR})$	0.1409	0.027	5.154	0.000	0.087	0.194

由表7.3可知, 在 0.05 的显著性水平下 $\ln Z_H$ 、 $\ln Z_{DR}$ 对 $\ln R$ 的作用均显著, 具有统计学意义. 得到降水量 R 与 Z_H 和 Z_{DR} 的关系式为7.23.

$$R_2 = 0.2786 \times Z_H^{0.7257} \times Z_{DR}^{0.1409}. \quad (7.23)$$

将得到的回归曲面及真实数据散点可视化如图7.20, 由结果可知, 水平反射率因子 (Z_H) 和差分反射率 (Z_{DR}) 均与降水量 (R) 呈正相关关系, 当 $Z_H > 40\text{dBZ}$ 时, 降雨量随 Z_H 的变化十分迅速, 这与强降雨天气的特点相符.




图 7.20 基于经验公式的 Z_H 、 Z_{DR} 与降水量 R 的关系曲面

7.3.3 基于分层贝叶斯回归拟合

分层贝叶斯回归^[18] 是将贝叶斯参数估计的思想应用至分层模型中, 属于部分池化建模. 贝叶斯线性回归就是在各层级上分别建立线性回归模型, 同时将各层级的回归系数看作一个分布.

由于雷达回波信息主要反映了降水的强度、降水粒子的大小等信息, 而数据性质在不同强度的降水存在差异, 因此数据具有层级结构. 本文根据降水强度对数据进行分层, 将经验公式参数求解问题转换为分层贝叶斯线性回归模型, 假定同一层级的回归系数具有相同的正态先验分布, 如图 [7.21] 所示即为 $\mu^{(i)} \sim N(\mu_0, \sigma_0^2)$.

这里假定同一层级的回归系数具有相同的先验分布, 原则上分层贝叶斯线性回归模型可以将层不断细化. 分层贝叶斯线性回归模型由于将参数看作分布, 可以防止模型过拟合问题. 本文建立分层贝叶斯线性回归的基本步骤如算法 [2].




图 7.21 分层贝叶斯线性回归模型结构

算法 2 分层贝叶斯线性回归

输入: 特征 X 、回归变量 y

输出: 各回归系数 β_i 的分布

- 1: 对数据进行分层. 本文将数据分为两层, 第一层为不同年份的样本数据, 第二层为同一年份下的样本数据.
- 2: 假定各层级模型回归系数的先验分布. 本文假定个体层级的回归系数的先验分布为正态分布, 即 $\beta_i \sim N(\mu_i, \sigma_i^2), i = 1, 2, \dots, m, m$ 为协变量的个数. 其中 μ_i 服从正态分布, σ_i^2 服从半正态分布, 并假定对应的正态分布和半正态分布分别具有相同的参数. 另外假定群体层级的回归系数亦服从正态分布, 其中正态分布的方差服从半柯西分布.
- 3: 进行后验推断. 使用马尔科夫链蒙特卡罗方法 (MCMC, Markov Chain Monte Carlo) 进行后验推断.
- 4: 模型评估诊断与结果分析.

模型求解与结果分析

本文使用 PyMC3^[19] 软件包进行分层贝叶斯线性回归模型的建立与求解. 其中假定各个个体层级回归系数的先验分布的均值服从均值为 0, 标准差为 3 的正态分布, 方差服从尺度参数为 3 的半正态分布. 群组层级回归系数的先验分布的方差服从尺度参数为 5 的半柯西分布.

使用 MCMC 方法采样^[20], 从后验分布中生成样本, 设置迭代次数为 20000 次, 并丢弃前 10000 个样本点, 最终得到各参数后验分布的核密度估计. 使用 Gelman-Rubin 诊断^[21] 来检验模型是否收敛到稳定的后验分布, 经计算得到 Gelman-Rubin 对应统计量的值为 1.00, 可以认为 MCMC 采样链已经收敛. 最终, 得到群体层级回归系数的后验分布的核密度估计结果如图 7.22, 图 7.22 中, 左图给出的是不同降水强度下, 不同协变量对应的回归系数的后验分

布核密度图, 不难看出, 不同降水强度下不同协变量的回归系数的后验分布具有多模态性, 表明不同降雨强度雷达回波反射率具有不同特性; 右图显示了 MCMC 采样链中参数的变化情况, 参数值的迹线图波动较小, 表明模型已经收敛. 进一步, 给出各系数后验分布的均值与方差的数值结果, 具体如表7.4.




图 7.22 分层贝叶斯线性回归各层系数的分布与采样过程

使用参数后验分布的均值作为参数的估计值, 可以得到经验关系式的估计式为

$$R_2 = 0.035 \times Z_H^{1.833} \times Z_{DR}^{-0.004}. \quad (7.24)$$

7.3.4 基于线性回归拟合

直接建立降水量 (R) 与水平反射率因子 (Z_H) 和差分反射率 (Z_{DR}) 的多元回归模型, 通过最小化损失函数7.25, 可以得到关系式7.26.

$$\min_{\beta_0, \beta_1, \beta_2} \left(\sum_{i=1}^N (R - \beta_0 - \beta_1 Z_H - \beta_2 Z_{DR})^2 \right). \quad (7.25)$$

$$R_3 = -1.6861 + 0.1895 \times Z_H + 1.0616 \times Z_{DR}. \quad (7.26)$$

其中, 参数的具体回归结果如表7.5. 由表7.5可知, 在 0.05 的显著性水平下, 回归结果具有统计学意义.

表 7.4 分层贝叶斯回归系数的分布

系数	均值	标准差	<i>Gelman–Rubin</i>	系数	均值	标准差	<i>Gelman–Rubin</i>
μ_{b0}	-3.349	2.289	1.0	σ_{b0}	5.221	1.514	1.0
μ_{b1}	1.833	1.202	1.0	σ_{b1}	2.284	1.033	1.0
μ_{b2}	-0.004	0.089	1.0	σ_{b2}	0.087	0.144	1.0
$b_0[1]$	-0.446	0.149	1.0	$b_1[1]$	0.274	0.048	1.0
$b_0[2]$	-13.002	2.421	1.0	$b_1[2]$	4.131	0.690	1.0
$b_0[3]$	-5.394	4.408	1.0	$b_1[3]$	2.101	1.202	1.0
$b_0[4]$	-4.551	4.691	1.0	$b_1[4]$	2.026	1.234	1.0
$b_2[1]$	-0.007	0.026	1.0				
$b_2[2]$	-0.002	0.037	1.0				
$b_2[3]$	0.004	0.066	1.0				
$b_2[4]$	-0.016	0.089	1.0				
eps	0.687	0.018	1.0				

表 7.5 基于回归分析的降水估测

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-1.6861	0.206	-0.8176	0.000	-2.091	-1.282
Z_H	0.1895	0.009	21.526	0.000	0.172	0.207
Z_{DR}	1.0616	0.115	9.264	0.000	0.837	1.286

7.4 模型评价与结果分析

为评价得到的不同降水量与水平反射率因子和差分反射率的关系式, 本文使用7.27中评价指标^[22].

$$\begin{aligned} B_s &= \frac{\bar{r}}{\bar{g}}, \\ \text{RMSE} &= \sqrt{\frac{\sum_{i=1}^n (r_i - g_i)^2}{n}}, \\ \text{CC} &= \frac{\sum_{i=1}^n (r_i - \bar{r})(g_i - \bar{g})}{\sqrt{\sum_{i=1}^n (r_i - \bar{r})^2 \sum_{i=1}^n (g_i - \bar{g})^2}} \end{aligned} \tag{7.27}$$

其中, $B_s > 1$ 表示高估降水, 反之低估降水. RMSE(Root Mean Square Error) 和 CC(Correlation Coefficient) 均衡量关系式对数据的拟合情况, 其中 RMSE 越小越好, CC 越大越好. 对以上建立的水平反射率因子 (Z_H)、差分反射率 (Z_{DR}) 与降水量 (R) 关系式进行评价, 具体评价结果如表7.6.

由表7.6可知, 不同的拟合关系式对降水估测均存在高估现象, 其中单偏振三次多项式

表 7.6 不同拟合关系式的评价结果

模型/评价指标	B_s	RMSE	CC
R1(三次多项式拟合)	3.766	10.358	0.876
R2(分层贝叶斯回归)	4.867	10.532	0.715
R3(经验公式)	1.506	2.594	0.652
R4(直接回归)	1.000	2.612	0.667

拟合关系式对降水量的高估情况最严重, 基于线性回归的拟合关系式对降水量估测效果最好.

8 问题四模型的构建与求解

8.1 问题分析

从问题三的建模结果中, 我们可以看到双偏振雷达资料的使用可以提高降水的预测精度. 本问我们将从雷达回波外推和降水估测两个建模过程定量评价双偏振雷达资料在强对流降水临近预报中的贡献, 同时给出优化数据融合策略.

8.2 双偏振雷达资料贡献评估

基于问题二得到的雷达回波外推预测值和问题三得到的雷达回波反射率与降水的关系式可以得到未来 T 步降水的预测值. 将其中结果之一可视化展示如图8.23:




图 8.23 Nowcastnet 预测结果

图8.23是加入双偏振雷达信息前后的 Nowcastnet 预测的雷达回波对比图, 绿色代表真

实的雷达回波图, 图片上方图像为未添加双偏振雷达信息的纯外推结果, 下方图像为加入双偏振雷达信息 (Z_{DR} , K_{DP}) 之后的外推结果, T 表示外推的步长, K_{DP} 图像为真实的未来 K_{DP} 数据图像, 第三列是基于已有信息和问题三中线性回归方程计算预测得出的降水分布图像, 第四列是真实的未来一帧降水分布图像。

由图8.23可以看出, 真实降水的细节分布 (红色) 更趋近于加入双偏振雷达数据的预测图象, 说明双偏振雷达资料在强对流降水临近预报中提供了及其重要的信息, 可以对强对流降水分布情况进行修正, 使其更加接近于真实的降水演变情况. 且加入双偏振变量之后, 雷达回波细节更完善, 变化幅度更为清晰, 且去除了一定的气象杂波, 能够避免预测结构收到无关变量的影响, 得到反射率 Z_H 的结果更加准确, 纠正这些无关信号损失的影响, 以便更加准确科学地估算降水分布情况和降水量. 接着使用 CSI 准则评估加入双偏振雷达资料前后的精度提升情况, 结果如下:




图 8.24 NowcastNet 模型订正后降水预报精度提升效果对比

图8.24为不同模型随预测步长的 CSI 指数变化情况, 可以看出: 不同模型的 CSI 指数均呈下降趋势, 说明模型对短期降水量预测更准确; CSI 指数由高到低的模型分别为 Nowcastnet_cor、Nowcastnet、Predrnn-v2、Predrnn 及 ConvLSTM, Nowcastnet_cor 方法的 CSI 指数最高, ConvLSTM 模型的 CSI 指数最低, 表明本文使用的 Nowcastnet 模型真阳性所占比例较大, 该模型错误率较低, 对真实雷达回波图的预测效果最好, ConvLSTM 模型预测效果最差. 同时也说明双偏振雷达信息对 NowcastNet 的强对流极端降水的预测起到重要作用, 可以提升其预测精度, 通过计算得出精度提升了 5.65%.

8.3 双偏振雷达资料的优化融合策略

在问题三的研究中, 我们主要使用回归分析技术展开对水平反射率因子 (Z_H)、差分反射率 (Z_{DR}) 与降水量 (R) 关系的研究, 由于线性模型具有显式的表达式, 因此模型具有很好的可解释性, 但模型对数据的拟合精度不高, 且未使用比差分相移 (K_{DP}) 信息. 这里通过引入比差分相移信息, 同时考虑不同高度的雷达反射率信息. 使用 XGBoost 模型来建模雷达回波反射率与降水量之间的非线性关系, 进一步提高雷达回波资料对降水量预测的精度, 定量评估双偏振雷达资料在强对流降水临近预报中的贡献, 同时优化数据融合策略, 下面对建模细节进行介绍.

8.3.1 XGBoost 原理介绍

XGBoost^[23] 由多棵决策树构成, 每棵树的构造是基于前面已经构造的决策树对目标变量的预测值与真实值之差建模, 是多个基模型组成的加性模型. 算法原理是以目标函数为基础进行残差逼近, 衡量标准为以贪心策略达到目标函数的最小化, 此方法可以有效组合模型, 达到减少偏置的目的, 进而提高模型的预测精度.

该算法可以自定义损失函数, 其目标函数中加入了 L_1 和 L_2 正则化项, 近似于预剪枝, 因此模型的复杂度在每次迭代时实现了对冲, 减少了过拟合现象的发生. 该算法还对损失函数做了二阶泰勒展开. 相对于梯度提升法多了列抽样和 Shrinkage, 降低了每一棵树带来的影响, 从而减小过拟合现象的发生. 还能够通过数据特征信息, 自主学习缺失值的分裂方向, 且该算法支持在特征粒度上的并行. 该算法的原理如算法3:

算法 3 XGBoost 算法原理

1: **Step1:** 定义普通残差逼近目标: $y_t^* = F_t(x_i) = F_{t-1}(x_i) + f_t(x_i)$, 其中, y_t^* 是第 t 次迭代的预测值, $f_t(x_i)$ 是 $t-1$ 次迭代后形成的近似函数, $F_t(x_i)$ 是 t 次迭代后形成的近似函数, $f_t(x_i)$ 是第 t 棵决策回归树对残差的预测数值.

2: **Step2:** 构建 XGBoost 算法的目标函数, 将正则化项引入目标函数中:

$$L(\varphi)_t = \sum_{i=1}^n L[y_i, F_{t-1}(x_i) + f_t(x_i)] + \Omega(f_t), \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\omega\|^2 = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T \omega_j^2$$

其中, $\Omega(f_t)$ 为正则化惩罚项; $L[y_i, F_{t-1}(x_i) + f_t(x_i)]$ 代表近似函数 $F_{t-1}(x_i)$ 与真实值 y_i 之间的差距. T 是每棵决策回归树的叶子节点数, ω_j 是每棵树叶子节点 j 的权重, ω 是叶子节点数量的列向量, λ 是能够控制叶子节点的维数正则化项, γ 为对一整棵决策回归树中所有叶子节点的正则.

3: **Step3:** 对 $L[y_i, F_{t-1}(x_i) + f_t(x_i)]$ 进行二阶泰勒展开:

$$L(\varphi)_t \approx \sum_{i=1}^n \left\{ L[y_i, F_{t-1}(x_i)] + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right\} + \Omega(f_t)$$

$$g_i = \frac{\partial L[y_i, F_{t-1}(x_i)]}{\partial F_{t-1}(x_i)}, h_i = \frac{\partial^2 L[y_i, F_{t-1}(x_i)]}{\partial F_{t-1}^2(x_i)}$$

4: **Step4:** 将目标函数简化: $L(\varphi)_t \approx \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t)$

5: **Step5:** 把正则化项展开且进行合并, 由对样本 n 遍历转变为对叶子节点 j 遍历:

$$\begin{aligned} L(\varphi)_t &\approx \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T \omega_j^2 \\ &= \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) \omega_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) \omega_j^2 \right] + \gamma T \end{aligned}$$

6: **Step6:** 对 Step5 中的公式求其最小值, 得到损失函数的最小值和叶子节点权重 ω_j 的最优值:

$$\omega_j^* = -\frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}, L(\varphi)_t = -\frac{1}{2} \sum_{j=1}^T \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} + \gamma T. \text{ 其中, } L(\varphi)_t \text{ 是树节点分裂的依}$$

据, 判断分类前后目标函数的数值大小, 决定是否进行下一次分裂.

8.3.2 模型求解与结果分析

数据处理与评价指标: 为合理评估不同特征的重要性, 同时消除不同特征的量纲及数值量级影响, 本文对所有特征变量进行 Z-score 标准化处理. 同时将数据按照 8:2 划分为训练集与测试集. 同时模型评价指标与问题三保持一致.

使用均方误差 (Mean Squared Error, MSE) 作为模型优化损失函数, 使用 3 折交叉验证和网格搜索策略进行超参数调整, 分别建立基于单偏振雷达回波资料 (只使用水平反射率因子作为自变量)、全部雷达回波资料、1KM 全部雷达回波资料 and 不同高度全部雷达回波资料的 XGBoost 回归模型, 分别探究单双偏振资料以及不同高度雷达回波资料对降水量估测的建模影响. 在测试集上对训练得到的不同模型进行评价, 具体评价结果见表 8.7.

由结果 (1)(2)(3) 对比可知, 双偏振雷达资料的引入可以校准雷达回波资料对降水的估计精度, 使用全部雷达资料 (结果 (3)) 可以达到最好的建模效果. 由结果 (3)(6)(7) 可知, 通过引入不同高度的雷达回波资料信息, 可以提高模型对数据的拟合精度, 但同时会带来一定的高估现象.

表 8.7 不同输入数据下所建 XGBoost 回归模型的评价结果

结果序号	研究变量	B_s	RMSE	CC
(1)	$Z_H(1km)$	0.978	1.034	0.955
(2)	$Z_H, Z_{DR}(1km)$	0.990	1.119	0.949
(3)	$Z_H, Z_{DR}, K_{DP}(1km)$	1.001	0.332	0.996
(4)	$Z_H, Z_{DR}, K_{DP}(3km)$	0.96	2.704	0.628
(5)	$Z_H, Z_{DR}, K_{DP}(7km)$	0.974	3.026	0.487
(6)	$Z_H, Z_{DR}, K_{DP}(1/3km)$	1.002	0.312	0.997
(7)	$Z_H, Z_{DR}, K_{DP}(1/3/7km)$	1.003	0.213	0.999

8.3.3 总结

基于以上研究, 我们得出:

- 双偏振雷达资料的引入可以提高模型对强对流降水临近预报的精度.
- 在强对流降水临近预报中可以使用不同高度的双偏振雷达资料来优化建模效果.

9 模型优缺点分析

9.1 模型优点

(1) Nowcastnet 网络架构将深度学习与物理规律相结合, 兼具了两者的优势, 不仅延长了预报时效, 还预测出了运动场和强度场信息, 模拟强对流极端降雨的动态演化.

(2) Nowcastnet 模型思想将预报分解为两个部分, 分别为物理规律约束下的确定性中尺度预报以及生成模型驱动的对流尺度预报. 接着将确定性预报又进一步分解为对流和扩散的预报, 实现了“端到端”的训练.

(3) 本文对建模数据进行了误差订正与质量控制, 保证了建模结果的可靠性.

(4) 从反射率因子与降水关系的多个角度研究了双偏振雷达资料在降水定量估测中的应用, 基于不同指标的评价结果给出双偏振雷达资料在降水定量估测中的贡献.

9.2 模型缺点

(1) 由问题 4 结果可知, 不同高度的雷达回波资料可以提高模型建模效果, 但本文未考虑将不同高度的雷达回波信息加入到 Nowcastnet 模型;

(2) 本文给出的反射率因子与降水的关系具有明确的显式表达式, 但模型对数据的拟合效果需要进一步提升.

参考文献

- [1] 郑永光, 张小玲, 周庆亮, 等, 强对流天气短时临近预报业务技术进展与挑战, 气象(7): 10, 2010.
- [2] Chen G, Zhao K, Zhang G, et al., Improving Polarimetric C-Band Radar Rainfall Estimation with Two-Dimensional Video Disdrometer Observations in Eastern China, Journal of Hydrometeorology, 18(5):1375-1391, 2017.
- [3] Overeem A, Vries H D, Sakka H A, et al., Rainfall-induced attenuation correction for two operational dual-polarization C-band radars in the Netherlands, Journal of Atmospheric and Oceanic Technology, 2021.
- [4] Heistermann M, Jacobi S, Pfaff T, Technical Note: An open source library for processing weather radar data (wradlib), Hydrology Earth System Sciences Discussions, 17(2):863-871, 2013.
- [5] Zadeh L A, Fuzzy sets, Information and Control, 8(3):338-353, 1965.
- [6] Shi X, Chen Z, Wang H, et al., Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting, MIT Press, 2015.
- [7] Wang Y, Long M, Wang J, et al., PredRNN: Recurrent neural networks for predictive learning using spatiotemporal LSTMs, 2017.
- [8] 赵杰, 林延奖, 刘燃, 等, 基于 PredRNN++ 模型对南海中尺度涡旋的预测研究, 热带海洋学报:1-15, 2023.
- [9] 兰宇, 伍志方, 唐思瑜, 等, PredRNN 方法在广东雷达回波临近预报中的应用评估, 广东气象, 45(03):58-61, 2023.
- [10] Wang Y, Wu H, Zhang J, et al., PredRNN: A Recurrent Neural Network for Spatiotemporal Predictive Learning, IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(2):2208-2225, 2022.
- [11] Zhang Y, Long M, Chen K, et al., Skilful Nowcasting of Extreme Precipitation with NowcastNet, Nature:1-7, 2023.
- [12] Park T, Liu M Y, Wang T C, et al., Semantic Image Synthesis with Spatially-Adaptive Normalization, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2337-2346, 2019.
- [13] Ravuri S, et al., Skilful Precipitation Nowcasting Using Deep Generative Models of Radar, Nature, 597:672-677, 2021.
- [14] Chen G, Zhao K, Zhang G, et al., Improving Polarimetric C-band Radar Rainfall Estimation with Two-Dimensional Video Disdrometer Observations in Eastern China, Journal of Hydrometeorology, 18(5):1375-1391, 2017.

- [15] Ma J, Luo L, Chen M, et al., Clear-Air Turbulence (CAT) Identification with X-Band Dual Polarimetric Radar Based on Bayesian Approach, *Atmosphere*, 12(12):1691, 2021.
- [16] 吴林林, 利用雨滴谱对移动双偏振雷达进行质量控制及降水估测, 南京信息工程大学, 2014.
- [17] 郭佳, 吴艳锋, 罗丽, 等, CINRAD-SA 偏振雷达定量降水估测算法改进及应用评估, *气候与环境研究*, 25(3):15, 2020.
- [18] Lenk P J, DeSarbo W S, Green P E, et al., Hierarchical Bayes conjoint analysis: recovery of partworth heterogeneity from reduced experimental designs, *Marketing Science*, 15(2): 173-191, 1996.
- [19] Fonnesbeck C, Salvatier J, Wiecki TV, Probabilistic programming in python using pymc3. *PeerJ Computer Science*, 2:e55, 2016.
- [20] Andrieu C, De Freitas N, Doucet A, et al., An introduction to MCMC for machine learning, *Machine learning*, 50:5-43, 2003.
- [21] Gelman A, Rubin D B, Inference from iterative simulation using multiple sequences, *Statistical science*:457-472, 1992.
- [22] Wang G, Liu L, Ding Y, Improvement of Radar Quantitative Precipitation Estimation Based on Real-time Adjustments to ZR Relationships and Inverse Distance Weighting Correction Schemes, *Advances in Atmospheric Sciences*, 29:575-584, 2012.
- [23] Chen T, Guestrin C, XGBoost: A Scalable Tree Boosting System, *Knowledge Discovery and Data Mining*, 2016.

附录 A NowcastNet 架构

nowcastnet.py

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import numpy as np
from nowcasting.layers.utils import warp, make_grid
from nowcasting.layers.generation.generative_network import
    Generative_Encoder, Generative_Decoder
from nowcasting.layers.evolution.evolution_network import
    Evolution_Network
from nowcasting.layers.generation.noise_projector import
    Noise_Projector

class Net(nn.Module):
    def __init__(self, configs):
        super(Net, self).__init__()
        self.configs = configs
        self.pred_length = self.configs.total_length - self.configs.
            input_length

        self.evo_net = Evolution_Network(self.configs.input_length, self.
            .pred_length, base_c=32)
        self.gen_enc = Generative_Encoder(self.configs.total_length,
            base_c=self.configs.ngf)
        self.gen_dec = Generative_Decoder(self.configs)
        self.proj = Noise_Projector(self.configs.ngf, configs)

        sample_tensor = torch.zeros(1, 1, self.configs.img_height, self.
            configs.img_width)
        self.grid = make_grid(sample_tensor)

    def forward(self, all_frames):
        all_frames = all_frames[:, :, :, :, :1]

        frames = all_frames.showspacespermute(0, 1, 4, 2, 3)
        batch = frames.shape[0]
        height = frames.shape[3]
```

```

width = frames.shape[4]

# Input Frames
input_frames = frames[:, :self.configs.input_length]
input_frames = input_frames.reshape(batch, self.configs.
    input_length, height, width)

# Evolution Network
intensity, motion = self.evo_net(input_frames)
motion_ = motion.reshape(batch, self.pred_length, 2, height,
    width)
intensity_ = intensity.reshape(batch, self.pred_length, 1,
    height, width)
series = []
last_frames = all_frames[:, (self.configs.input_length - 1):self
    .configs.input_length, :, :, 0]
# B * 2 * H * W
grid = self.grid.repeat(batch, 1, 1, 1)
for i in range(self.pred_length):
    last_frames = warp(last_frames, motion_[:, i], grid.cuda(), mode
        ="nearest", padding_mode="border")
    last_frames = last_frames + intensity_[:, i]
    series.append(last_frames)
    evo_result = torch.cat(series, dim=1)

evo_result = evo_result/128

# Generative Network
evo_feature = self.gen_enc(torch.cat([input_frames, evo_result],
    dim=1))

noise = torch.randn(batch, self.configs.ngf, height // 32, width
    // 32).cuda()
noise_feature = self.proj(noise).reshape(batch, -1, 4, 4, 8, 8).
    showspacespermute(0, 1, 4, 5, 2, 3).reshape(batch, -1, height
        // 8, width // 8)
feature = torch.cat([evo_feature, noise_feature], dim=1)
gen_result = self.gen_dec(feature, evo_result)
return gen_result.unsqueeze(-1)

```

附录 B Evolution Network

evolution_network.py

```
import torch.nn.functional as F
from nowcasting.layers.evolution.module import *

class Evolution_Network(nn.Module):
    def __init__(self, n_channels, n_classes, base_c=64, bilinear=
        True):
        super(Evolution_Network, self).__init__()
        self.n_channels = n_channels
        self.n_classes = n_classes
        self.bilinear = bilinear
        base_c = base_c
        # inc 为一个DBlock,
        self.inc = DoubleConv(n_channels, base_c)
        self.down1 = Down(base_c * 1, base_c * 2)
        self.down2 = Down(base_c * 2, base_c * 4)
        self.down3 = Down(base_c * 4, base_c * 8)
        factor = 2 if bilinear else 1
        self.down4 = Down(base_c * 8, base_c * 16 // factor)

        self.up1 = Up(base_c * 16, base_c * 8 // factor, bilinear)
        self.up2 = Up(base_c * 8, base_c * 4 // factor, bilinear)
        self.up3 = Up(base_c * 4, base_c * 2 // factor, bilinear)
        self.up4 = Up(base_c * 2, base_c * 1, bilinear)
        self.outc = OutConv(base_c * 1, n_classes)
        # 使用torch.nn.Parameter将不可训练的tensor转换为可训练的tensor并
        # 在该类中进行注册
        self.gamma = nn.Parameter(torch.zeros(1, n_classes, 1, 1),
            requires_grad=True)

        self.up1_v = Up(base_c * 16, base_c * 8 // factor, bilinear)
        self.up2_v = Up(base_c * 8, base_c * 4 // factor, bilinear)
        self.up3_v = Up(base_c * 4, base_c * 2 // factor, bilinear)
        self.up4_v = Up(base_c * 2, base_c * 1, bilinear)
        self.outc_v = OutConv(base_c * 1, n_classes * 2)

    def forward(self, x):
```

```
x1 = self.inc(x)
x2 = self.down1(x1)
x3 = self.down2(x2)
x4 = self.down3(x3)
x5 = self.down4(x4)
x = self.up1(x5, x4)
x = self.up2(x, x3)
x = self.up3(x, x2)
x = self.up4(x, x1)
x = self.outc(x) * self.gamma

v = self.up1_v(x5, x4)
v = self.up2_v(v, x3)
v = self.up3_v(v, x2)
v = self.up4_v(v, x1)
v = self.outc_v(v)
return x, v
```

附录 C Generative Network

generative_network.py

```
import numpy as np
import torch
import torch.nn as nn
import torch.nn.functional as F
from torch.autograd import Function
from nowcasting.layers.generation.module import GenBlock
from nowcasting.layers.evolution.module import *

class Generative_Encoder(nn.Module):
    def __init__(self, n_channels, base_c=64):
        super(Generative_Encoder, self).__init__()
        base_c = base_c
        #DBlock
        self.inc = DoubleConv(n_channels, base_c, kernel=3)
        self.down1 = Down(base_c * 1, base_c * 2, 3)
        self.down2 = Down(base_c * 2, base_c * 4, 3)
        self.down3 = Down(base_c * 4, base_c * 8, 3)

    def forward(self, x):
        x = self.inc(x)
        x = self.down1(x)
        x = self.down2(x)
        x = self.down3(x)
        return x

class Generative_Decoder(nn.Module):
    def __init__(self, opt):
        super().__init__()
        self.opt = opt
        nf = opt.ngf

        ic = opt.ic_feature
        self.fc = nn.Conv2d(ic, 8 * nf, 3, padding=1)

        self.head_0 = GenBlock(8 * nf, 8 * nf, opt)
```

```

self.G_middle_0 = GenBlock(8 * nf, 4 * nf, opt, double_conv=True
)
self.G_middle_1 = GenBlock(4 * nf, 4 * nf, opt, double_conv=True
)

self.up_0 = GenBlock(4 * nf, 2 * nf, opt)

self.up_1 = GenBlock(2 * nf, 1 * nf, opt, double_conv=True)
self.up_2 = GenBlock(1 * nf, 1 * nf, opt, double_conv=True)

final_nc = nf * 1

self.conv_img = nn.Conv2d(final_nc, self.opt.gen_oc, 3, padding
=1)
self.up = nn.Upsample(scale_factor=2)

def forward(self, x, evo):
x = self.fc(x)
x = self.head_0(x, evo)
x = self.up(x)
x = self.G_middle_0(x, evo)
x = self.G_middle_1(x, evo)
x = self.up(x)
x = self.up_0(x, evo)
x = self.up(x)
x = self.up_1(x, evo)
x = self.up_2(x, evo)
x = self.conv_img(F.leaky_relu(x, 2e-1))
return x

```